SEAC：面向大模型工业软件工程知识检索的来源可追溯结构保持分块方法

[作者姓名待确认]

1）（[单位/学院中文全称待确认]，[城市与邮编待确认]）

摘 要 工业软件需求规格、接口说明、数据库设计、技术协议和会议纪要同时包含层级标题、约束语句与大规模表格。固定窗口或通用递归分块容易切断表头与数据行、标题与正文以及结论与其来源，导致大模型虽然检索到语义相似文本，却无法给出可核验的工程证据。本文提出来源可追溯的结构保持分块方法 SEAC。该方法把段落、标题和表格行规范化为带稳定标识的最小单元，联合相邻单元语义距离、结构转移和工程关键信息密度变化构造父块，并以保留表头和标题路径的细粒度子块触发父块返回，从而分离“用于匹配的粒度”与“用于解释的上下文”。在冻结协议下，本文对 10 个企业项目的 89 份文档进行评估，共包含 31841 个解析块和 66981 个可追溯单元；按预先声明的轴向排除规则，检索推断使用 6 个独立项目的 125 个问题。完整 SEAC 的单元平均倒数排名为 0.7937、前 5 命中率为 0.9520，强于最优非 SEAC 基线的 0.7290；相对预先指定的 LlamaIndex 比较器，平均倒数排名提高 0.1003，95% 置信区间为 [0.0042, 0.2008]，但项目级精确双侧检验为 p=0.0625，尚不能据此宣称一般统计优越性。移除表格行子块后平均倒数排名降至 0.6853，而移除父子融合后升至 0.8289。结果表明，当前证据最支持“带表头的行级检索”，并提示完整评分设计仍需在新项目上预注册复验。该方法以最优平面基线 5.50 倍的向量数量换取细粒度定位与来源审计能力，可为大模型驱动的工业软件需求分析、规范核对和责任追踪提供可验证的知识检索底座。

关键词 检索增强生成；文档分块；工业软件工程；来源追溯；结构化文档；质量治理

中图法分类号 TP311.5；TP18　DOI 号：投稿时不提供

SEAC: Provenance-Aware Structure-Preserving Chunking for Large-Model Retrieval over Industrial Software Engineering Documents

[AUTHOR NAME TO CONFIRM]

1) ([Department and Institution to Confirm], [City and Postal Code to Confirm], China)

Abstract Industrial software requirements specifications, interface descriptions, database designs, technical agreements, and meeting records combine hierarchical headings, normative constraints, and large tables. Fixed-window or generic recursive chunking can separate a table row from its header, a section heading from its first content unit, or a decision from its source context. A large-model application may consequently retrieve text that looks relevant while failing to provide accountable engineering evidence. This paper presents SEAC, a deterministic and provenance-aware structure-preserving chunking method for retrieval over industrial software engineering documents. SEAC first normalizes paragraphs, headings, and table rows into traceable units with stable document, block, and unit identifiers. It then constructs coherent parent chunks by combining adjacent-unit semantic distance, structural transition, and change in engineering-key-information density, subject to protected-group and length constraints. Fine-grained retrieval children, especially header-aware table rows with heading-path context, activate their containing parents. This design separates the granularity used for semantic matching from the context returned for interpretation, while preserving the exact source units that triggered a retrieval result. We evaluate the frozen method on 89 documents from ten Chinese enterprise software projects, containing 31,841 parsed blocks and 66,981 traceable units. Seven projects constitute the collectively locked test set. Prespecified, axis-specific exclusion rules leave six independent projects and 125 reviewed questions for retrieval inference, while a partially different set of six projects supports boundary evaluation. Full SEAC obtains unit mean reciprocal rank of 0.7937 and Hit@5 of 0.9520, compared with 0.7290 mean reciprocal rank for the strongest non-SEAC baseline. Against the prespecified LlamaIndex SentenceSplitter comparator, the mean reciprocal rank difference is +0.1003 with a 95% hierarchical-bootstrap confidence interval of [0.0042, 0.2008]. The exact two-sided project-level test nevertheless gives p=0.0625, so the available six project clusters do not establish general statistical superiority. Removing table-row children reduces mean reciprocal rank to 0.6853, whereas removing parent fusion increases it to 0.8289. The locked evidence therefore supports header-aware row-level retrieval more strongly than every element of the original scoring design and motivates a preregistered comparison of the full and simplified variants on new projects. SEAC uses 5.50 times as many vectors as the strongest flat baseline, trading index cost for fine-grained localization, provenance verification, and auditable evidence. These properties make it a candidate retrieval foundation for large-model-driven industrial requirements

analysis, specification consistency checking, change-impact review, and governance workflows in which every generated statement must remain linked to an authorized source artifact.

Key words retrieval-augmented generation; document chunking; industrial software engineering; provenance; structured documents; quality governance

通讯作者：[通讯作者姓名待确认]；E-mail：[长期有效邮箱待确认]；手机：[手机号码待确认]；联系地址：[联系地址与邮编待确认]。

基金项目：[基金项目及编号待确认；没有请填“无”]

1 引言

工业软件的知识并不集中在单一代码仓库或需求文档中。一个可交付系统的业务约束、接口参数、数据库字段、异常处理、审批角色和验收规则，往往分散在需求规格说明书、详细设计、数据库字典、接口文档、技术协议、实施方案、研究报告与会议纪要中。同一事实还可能以模板化表格、自然语言说明和会议结论等不同形式重复出现。对大模型辅助需求分析、设计核查、测试生成和运维问答而言，首要问题并非“能否生成流畅答案”，而是能否定位到正确、完整且可追责的工程证据。

检索增强生成通过把外部知识检索结果作为生成条件，缓解参数化模型的知识时效性与来源不可见问题[1]。稠密段落检索[2]、句向量表示[3]和多语言多粒度嵌入模型[4]使中文工程文档的语义匹配具备可行性。然而，检索器只能在索引单元上工作，因而分块并非中性的预处理步骤。若固定窗口从数据库表中间切开，数据行会失去字段定义；若按空行递归切分，标题可能与第一段正文分离；若只按标题返回整节，字段级问题又会被大量无关上下文稀释。错误的检索粒度会把后续大模型置于“两难”：小块容易匹配但难以解释，大块上下文完整却难以精确定位。

这一矛盾在工业软件中具有治理后果。需求评审需要知道一项约束来自哪份版本的哪一节；自动生成测试用例需要区分同名字段属于哪张表变更影响分析需要把建议回连到原始接口或会议决议；质量审计还需判断回答是否引用了当前用户有权访问的材料。仅返回语义相似文本不能满足这些要求。检索结果必须同时保留文档、解析块、最小单元、父子块以及版本的映射关系，并能够区分“答案文本正确”与“证据位置正确”。

本文研究异构企业软件工程文档的确定性结构保持分块。我们提出 SEAC（Structure- and Evidence-Aware Chunking），将结构化解析结果规范化为带来源标识的单元，以相邻语义、结构变化和工程关键信息密度变化建立父块边界，并专门构造带表头的行级检索子块。子块负责匹配，命中后返回具有连贯上下文的父块，同时保留触发命中的源单元。整个构造过程不调用生成式大模型，所有参数、规则和标识传播均可检查。

本文的主要贡献如下。

（1）提出一种来源可追溯的结构保持分块方法。方法显式保护表格、标题—正文等功能耦合结构，并把语义与工程关键信息信号限制在可复核的确定性边界决策中。

（2）设计父块—子块分离的检索表示。带表头的数据行和带标题路径的细粒度文本作为匹配单元，命中后返回父级上下文，从而同时支持字段级定位和工程语义解释。

（3）在 10 个企业项目上实施冻结、隔离和来源感知的实验协议，覆盖 89 份文档、66981 个单元和 125 个锁定检索问题，并报告人工核验、轴向排除、逐项目结果、层次自助法区间、项目级精确检验与资源开销。

（4）完整报告不利于原方法叙事的结果：预先指定的统计检验未达到 0.05 水平，去除父子融合反而提高平均倒数排名，去除多个边界评分分量影响很小。因此本文把结论限定为当前项目上观察到的机制证据，而不把事后最优消融变体重新包装为已验证的新方法。

本文余下内容安排如下：第 2 节讨论检索粒度、结构化文档与需求追溯工作；第 3 节形式化问题；第 4 节给出 SEAC 方法；第 5 节说明工业数据与冻结实验协议；第 6 节报告结果；第 7 节讨论对智能化工业软件工程开发、保障与治理的意义；第 8、9 节分析机制、局限、伦理与数据可用性；第 10 节总结全文。

2 相关工作

2.1 检索粒度与上下文保持

传统稠密检索多以预先截取的段落为索引单元[2]。Dense X Retrieval 对命题、句子和段落等粒度进行系统比较，说明更小的事实单元有利于定位型问题[5]。Late Chunking 在长上下文中计算表示后再池化局部块，用上下文化嵌入缓解边界信息丢失[6]；RAPTOR 递归聚类并摘要文本，构造多层检索树以恢复跨段信息[7]。这些方法分别关注事实粒度、上下文化表示与层次聚合。SEAC 的不同点在于：它面向已解析的半结构化工程单元

决定确定性边界，并为每个父块和子块保留源文档、源块与源单元标识，不通过字符串近似反推来源。

长上下文模型并未消除分块问题。一方面，更长输入会增加成本并可能引入无关证据；另一方面，模型对证据在上下文中的位置仍然敏感。因而工程检索需要先准确激活小粒度证据，再提供足以解释该证据的局部结构。SEAC 的父子设计即建立在这一分工上：匹配粒度不等同于返回粒度，排序分数也不等同于审计证据。

2.2 结构化技术文档

Docling 等解析工具能够恢复标题层级、阅读顺序和表格结构[8]，但“解析出结构”并不自动回答“哪些相邻元素应组成同一检索上下文”。表格尤其典型：整表向量会稀释行级差异，裸数据行又缺少字段模式。对接口参数表、数据库字典和性能指标表而言，表头与数据行共同决定含义，且表上方标题路径提供模块、接口或实体范围。因此分块器应在结构保护与细粒度索引之间建立显式映射，而非任选整表或单行之一。

工业文档还包含由格式转换产生的碎片、空白单元格、页眉页脚、签署栏以及同一模板的重复段落。若这些噪声直接进入索引，向量数量和误检风险都会增加；若用过强的清洗规则，又可能删除真正的约束。本文将噪声判定规则、受保护结构和人工核验门槛写入冻结协议，使清洗决策能够和正式结果一并审查。

2.3 软件工程追溯与检索治理

需求追溯研究关注自然语言需求与设计、代码、测试等制品之间的链接恢复[9-10]。本文不试图一次性恢复完整的跨制品追踪图，而提供更低层的保证：一个检索结果必须知道自己来自哪份文档的哪些解析块和单元，评价也直接核验这些标识。该保证是后续需求—代码、需求—测试和变更影响链接的基础，能够避免“文本像答案但取自错误实体”的伪成功。

为建立可复现对照，本文选取 LangChain 的递归字符切分器和 LlamaIndex 的句子切分器作为官方框架实现[11-12]，并统一输入单元、嵌入器、最大长度和查询上下文。这样，差异主要来自分块表示，而非更换编码器或检索后生成器。本文还把系统层治理纳入讨论：来源标识必须与访问控制、文档版本和审计日志共同维护，否则可追溯字段只是一项静态元数据，不能构成可执行的治理机制。

2.4 研究空缺与本文边界

已有工作共同建立三项原则：检索粒度会影响事实定位，小粒度单元需要上下文，结构化解析应保留文档元素。但面向异构软件工程文档，仍缺少把三者连接起来、并同时用人工父块边界和精确来源证据评价的确定性方法。大量分块研究在开放域叙事文本或单一问答基准上报告端到端答案分数，难以判断改进来自分块、编码器、重排还是生成器；工程追溯工作则多从已经定义好的需求或代码制品开始，较少讨论原始文档中的表格行和会议结论如何成为可靠证据单元。

SEAC 把研究对象限制在“解析之后、生成之前”的表示层。它不负责 OCR、跨制品链接推断或最终回答生成，也不宣称通过一个边界分数解决工业知识治理。本文只检验三项可观察性质：父块边界是否与参考一致，检索是否返回正确来源与支持片段，以及这些性质需要多少资源。明确分层能够使负面结果具有解释力：例如父子融合不利于 MRR，说明排序设计需要复验，并不否定源单元标识的治理价值；数据库片段命中高而来源 MRR 较低，说明文本相似性仍无法替代实体定位。

与使用大模型直接生成命题或边界的方法相比，确定性方法的优势是版本固定和决策可回放代价是难以理解隐含跨段语义。本文不把“不调用大模型”作为绝对优势，而把它视为工业机密与审计约束下的一种设计选择。未来可以让大模型提供候选结构关系，但仍需冻结模型版本、提示、输出模式和人工门控，并在独立项目上与确定性方法比较。

3 问题定义

3.1 可追溯单元与父子块

设经结构化解析后的文档为有序单元序列

$$D = (u_1, u_2, \cdots, u_n). \tag{1}$$

每个单元 u_i 保存文本、稳定单元标识、源解析块标识、文档类型、块类型、标题路径和可选的受保护组标识。段落和标题各自形成单元；对于表头为 h、数据行为 r_j 的表格，行级文本被规范化为

$$t(r_j) = \mathrm{header}(h) \mathbin{/\!/} \mathrm{row}(r_j). \tag{2}$$

由此，数据行即使离开二维版面仍保留字段模式。父块是若干相邻源单元的有序集合，用于返回连贯上下文；子块是父块内部可独立检索的细粒度表示，用于激活父块。父块和子块均保存其源单元与源解析块的有序标识列表。

3.2 来源正确性与文本支持

对问题 q，令 G(q) 表示所有可合法承载核验支持片段 z(q) 的源单元集合。企业模板可能在多份文档中重复相同段落，故 G(q) 可含多个等价位置。当返回父块的源单元列表与 G(q) 有交集时，判定该排名位置为“单元来源正确”；当返回文本包含核验片段 z(q) 时，判定为“文本支持正确”。二者分别计算平均倒数排名和前 k 命中率。

这种双重定义用于区分两类常见错误。第一类是系统检索到正确数值或约束文本，但来自另一张同名字段表，此时文本支持正确而来源错误第二类是正确父块包含标注单元，但返回片段经过截断后未覆盖最小支持文本，此时来源正确而文本支持不足。面向审计的工业软件问答需要同时报告两种指标，不能只用字符串是否包含答案评估。

3.3 研究问题

本文冻结五个研究问题。RQ1：SEAC 是否更接近人工确认的语义父块边界？RQ2：SEAC 是否提高来源正确和支持片段正确的检索质量？RQ3：效果在不同项目和问题类型上是否一致？RQ4：语义、结构、关键信息、标题上下文、表格子块和父子融合分别产生何种影响？RQ5：提高细粒度与可追溯性需要付出多少索引、构造与查询开销?

4 SEAC 方法

4.1 单元规范化与受保护结构

SEAC 的输入不是原始字符流，而是统一的可追溯单元。解析阶段按阅读顺序提取标题、正文段落、列表项和表格。每个单元获得 `document_id`、`block_id` 与 `unit_id`，并记录标题路径和文档类型。对表格，系统识别有效表头将“表头｜当前数据行”拼接为行级表示；对跨页续表，在表结构能够确定时继承表头。空白、纯页码和已冻结的转换噪声被标记为不可检索，但原始位置仍可由标识回查。

受保护组用于表达先于语义相似度存在的功能耦合。一个源表格的表头和数据行属于同一组标题与其首个有效内容单元不能被任意拆散；同一列表的连续项在长度允许时保持相邻。保护只约束父块构造，不妨碍在子层索引单个数据行。因此，表格可以作为解释上下文整体返回，同时仍以行级向量响应字段、约束和参数问题。

4.2 相邻边界评分

对相邻单元 (u_i,u_{i+1})，计算语义距离 d_i、结构转移 s_i、工程关键信息密度变化 k_i 和连续性惩罚 p_i。语义距离使用归一化 BGE-M3 表示的一减余弦相似度。结构信号在新标题、标题路径变化和受保护组变化时增加。关键信息词表在开发集上冻结，覆盖义务、上限、数据库约束请求方法、字段、状态、接口、流程等中文工程词；密度定义为词表命中数除以正则词元数，k_i 为相邻密度差乘 10 后截断到 1。该词表不承担实体识别，只用于指示技术密集区和叙述区的变化。

令 V 为冻结的工程表达词表，tokens(u) 为单元的正则词元数，单元关键信息密度定义为

$$\rho(u) = \Sigma[v \in V]\ \mathrm{count}(v,u) / \max(1,\mathrm{tokens}(u)). \quad (3)$$

词表包括“必须”“不得”“最大/最小”等义务与限制词，“主键/外键”等数据库约束词，以及请求方法、路径、参数、返回、字段、状态、接口、表名、流程和约束等工程表达。完整 UTF-8 字面量及其配置哈希保存在复现材料中。词表规模有意保持较小，不声称覆盖全部领域实体；它的目的只是以透明方式刻画技术密集文本与一般叙述的突变。

相邻单元的语义距离为

$$d_i = 1 - \cos(e_i, e_{i+1}). \quad (4)$$

其中 e_i 是归一化稠密嵌入。结构转移由新标题、标题路径变化和受保护组变化共同组成，并截断到 1：

$$s_i = \min\{1,\ l_h + 0.7l_{path} + 0.5l_{group}\}. \quad (5)$$

这里 I_h 表示右侧单元为标题，I_path 表示标题路径变化，I_group 表示至少一侧属于受保护组且组标识发生变化。关键信息变化和连续性惩罚分别为

$$k_i = \min\{1,\ 10|\rho(u_i) - \rho(u_{i+1})|\}. \quad (6)$$

$$p_i = 0.35l_{same\text{-}path} + 1.0l_{same\text{-}group}. \quad (7)$$

相同非空标题路径抑制章节内部切分，相同非空受保护组以更强惩罚抑制表格内部切分。受保护组同时还有硬完整性约束：即使消融移除数值惩罚，也不允许产生结构无效的表格父块。因此，“无连续性惩罚”只移除式（7）的两项数值，不删除基础结构合法性。

综合边界分数为

$$b_i = 0.45d_i + 0.30s_i + 0.25k_i - p_i. \quad (8)$$

文档级阈值根据该文档分数的 0.8 分位数以及表格行、标题比例调整：

$$\theta_D = Q_{0.8}(b) + 0.08r_t - 0.05r_h. \quad (9)$$

其中 r_t 和 r_h 分别为表格行与标题占比。表格密集文档中相邻行结构相似，正向调整避免过度切分；标题密集文档具有更明确的组织结构，

负向调整使显式章节更容易形成边界。上述权重与阈值均在锁定测试集释放前冻结。

4.3 父块线性组装

父块构造自左向右进行，最大长度为 512 个 BGE 词元，普通区域软目标为 320，工程词密度达到 0.03 时采用 224 的密集区软目标，最小块长为 48。只有在超过软目标且 b_i 大于文档阈值时才优先切分；超过硬上限则必须切分。若候选切分会分开受保护表格组、拆开标题与首段，或造成过短当前块，则抑制该边界。超长单元先按句号、分号、换行或列表边界切分，最后才使用词元截断。

该过程不读取查询、答案或测试标签，也不包含随机决策。其价值不在于声称任一线性权重具有普适最优性，而在于把边界决策约束在可记录、可重放的参数表面。任何父块均可列出形成它的源单元序列；任何边界均可回显四个分量、阈值和被保护规则覆盖的原因。

4.4 细粒度子块与父块返回

每个父块本身可被索引。非标题、非噪声单元还生成目标 112、最大 176 词元的子块。普通段落子块附加标题路径；表格数据行通常形成一个独立子块，内容包含表头、数据行和标题路径。若单行超长，可按逻辑片段拆分，但所有片段继续携带同一数据行的来源标识。比较方法除“移除标题上下文”消融外使用相同上下文前缀，避免通过额外提示信息给 SEAC 不公平优势。

对父块 p、查询 q，父块稠密得分为 S_p，所属子块得分为 S_c，完整方法的排序分数为

$$S(p,q) = 0.35S_p(q) + 0.65 \max S_c(q). \qquad (10)$$

子块命中时系统返回父块文本，并在检索记录中保留触发子块的源单元标识。这样，下游大模型获得连贯上下文，审计模块仍能知道具体由哪一行或哪一段触发。图 1 总结了从解析、单元规范化、父块构造、子块索引到来源校验的流程。

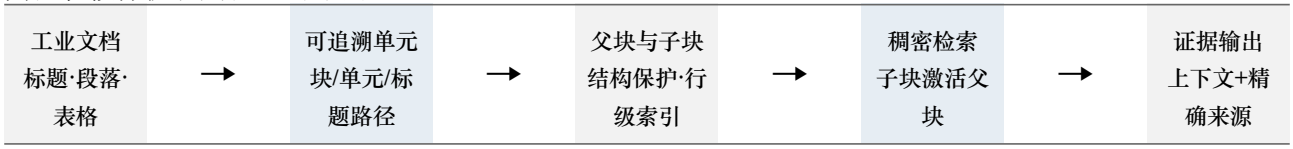


图 1 SEAC 从工业文档到可追溯父块证据的构造与检索流程

4.5 复杂度与可复现接口

对 n 个单元，SEAC 需要 n 次单元嵌入、n-1 次相邻相似度和一次线性组装；忽略编码器成本时，父块构造的时间与存储复杂度均为 O(n)。索引空间等于父块与子块向量数量之和，因此会高于只索引父块的平面方法。正式运行记录语料、问题、边界、配置与实现文件的 SHA-256，Python 与依赖版本、完整命令、随机种子、平台和方法参数；缓存按方法隔离，避免执行顺序复用不相容表示。

4.6 合成示例与失败判定

考虑一个不含真实企业信息的数据库字典片段。章节路径为“设备管理→巡检任务→TASK_ITEM”，表头为“字段名｜类型｜长度｜是否为空｜说明”，数据行为“STATUS｜VARCHAR｜16｜否｜任务状态”。传统行切分只保留“STATUS｜VARCHAR｜16｜否｜任务状态”，查询“巡检任务状态字段能否为空”虽然可能命中，却无法证明“否”对应哪一列，也无法区分另一个表的 STATUS 字段。SEAC 子块写为“标题路径：设备管理→巡检任务→TASK_ITEM；表头：字段名｜类型｜长度｜是否为空｜说明；数据行：STATUS｜VARCHAR｜16｜否｜任务状态”，并携带该行的 `unit_id`。

若该子块得分最高，系统返回包含表名、相邻字段和约束说明的父块，同时在结构化结果中给出 `trigger_unit_id`、`parent_chunk_id`、`source_block_id` 和文档版本。生成器可以回答“该字段不允许为空”，引用行级来源；审阅者则能跳转到原表。若另一个版本也有相同文本且被标注为合法证据，其单元进入 G(q)；若只是另一个实体的模板化字段，文本可能匹配但单元不属于 G(q)，此时片段指标可能成功、来源指标失败。

该例也说明父子表示无法单独解决的情况。若解析器把合并表头识别错误，行级文本会错误若问题本身未说明实体而多个 STATUS 字段都合理，问题参考不唯一；若旧版本未从授权索引移除，正确文本仍可能来自过期文档。SEAC 分别通过结构抽检、证据等价集合和版本映射暴露这些风险，却不能在分块算法内部替代解析修复、问题重写或访问控制。

父块切分也可用同一例检查。标题“TASK_ITEM”与首个字段行受标题—正文约束保护；表内所有行共享表格组，普通得分边界不能把父块随意截断。若整表超过 512 词元，系统在保证每个逻辑行完整的前提下建立多个父块，每个父块复制必要标题和表头信息，子块仍指向原始数据行。由此，硬长度限制不会通过简单字符截断破坏字段模式。

5 工业实验设计

5.1 语料、项目隔离与文档类型

实验语料来自 10 个中文企业软件项目，项目身份以 P01—P10 替代。89 份可解析文档包括需求规格、接口说明、数据库设计、详细设计、技术协议、项目建议书、研究报告与会议纪要，原始格式为 DOCX 和 XLSX。历史格式转换由哈希追踪。另有 6 份当前流水线不支持的 PDF 或 PPTX 被如实披露，但对所有方法一律排除，避免某一方法单独获得额外内容。

项目划分在正式评估前冻结：P01—P02 用于方法开发，P03 用于验证，P04—P10 构成集体锁定测试集。开发集可用于确定词表、参数和规则验证集用于确认流程可运行；锁定集在全部项目的标注、隐私和运行就绪门槛同时满足后才释放指标。表 1 给出语料规模。

表 1 冻结语料与项目划分

划分	项目数	文档数	解析块数	单元数	正则词元数
开发集	2	15	9639	21371	418541
验证集	1	7	3075	5193	103562
锁定测试集	7	67	19127	40417	1155797
合计	10	89	31841	66981	1677900

工业数据的独立性以项目而非问题为单位。来自同一项目的文档模板、术语和标注者判断可能相关，把 125 个问题视为 125 个独立样本会低估不确定性。因此，置信区间和随机化检验均在项目层处理聚类。项目数量而非问题总数是本研究统计功效的主要瓶颈。

5.2 边界参考构造

P01 的 4783 个候选边界由两名人员独立标注并裁决。P02—P10 每个项目按文档和结构分层抽取 300 个候选。一个大语言模型先在看不到 SEAC 预测、基线、检索得分和正式结果的条件下生成盲化预标注；随后人工核验每个项目隐藏随机抽取的 100 个候选和全部风险标记项，人工决定覆盖模型预标注。项目只有在人模一致性 Cohen κ 不低于 0.70 时才进入边界评价[13]。

第一轮核验发现三类未被预先枚举的转换噪声：孤立结构标签、仅含标点的片段和会议纪要签署区。规则修订后同时保存修订前、后协议，并把规则直接解析的样本从 κ 计算中排除。P08 在停止继续增加规则后 κ=0.650，低于门槛，因此仅从边界评价中排除；它仍可参加检索评价。最终提升的边界参考包含 5566 个人工核验边界（77.5%）、387 个确定性规则边界（5.4%）和 1230 个保留预标注（17.1%）。故边界 F1 是与混合参考的一致性，不等价于与完全人工金标准的一致性。

候选抽样使用随机种子 20260804，并按六类结构层分配：标题转移、章节路径转移、同章节连续、表格内部、表格进出和噪声候选。该分层避免随机样本被数量占优的普通段落边界淹没。随机核验组与模型主动标记的困难组互不重叠；κ 只在前者上计算，使一致性估计不被刻意挑选的困难案例系统性拉低，困难组的分歧则单独保留每条预标注记录模型标识、决定性语义关系与是否建议人工复核，人工工作簿不显示模型标签，从而减少确认偏差。

噪声规则的修订是检查第一轮分歧后作出的事后规范，本文不把它描述为预注册内容。修订前/后的 κ 分别为：P02 0.61/0.87，P03 0.56/0.76，P04 0.81/0.89，P05 0.66/0.96，P06 0.42/0.91，P07 0.75/0.98，P08 0.68/0.65，P09 0.75/0.72，P10 0.77/0.76。规则在结构脚手架常见的项目中提高 κ，在较少出现的项目中反而降低 κ，并非统一朝通过门槛的方向调整。P08 修订后仍未达标时，没有继续增加“封面装饰”等缺少标签独立证据的新类别，而是执行预先声明的排除。这一停止规则防止为保留不利项目而持续修改定义。

混合参考的每条记录都带来源状态：`HUMAN_VERIFIED` 表示独立人工核验，`RULE_4_1` 表示由列举噪声规则确定，`LLM_PRELABEL` 表示未被抽到核验且保留盲化预标注。正式分析程序依据该状态审计数量和项目资格；NOISE 仍保存在标注包中，但从二元边界精确率、召回率和 F1 中排除。这样的记录不能消除模型标注偏差，却能使审稿人知道哪些结果依赖何种标签来源。

5.3 问题与证据参考

问题草案由可观察的文档模式生成，再由人工核验自然性、唯一答案、最小证据、支持片段和隐私。模板在多个位置重复的合法证据被表示为等价单元集合，而不是任意指定一个位置。九个项目共审阅 215 个候选，其中 195 个通过人工审

批；一条预先记录的机械规则进一步排除以章节编号开头的 10 个问题，该规则不改写人工判断。

P10 最终只有 11 个批准问题，低于预先声明的每项目 15 问门槛，因此仅从检索评价中排除；其边界数据仍有效。锁定检索集由 P04—P09 的 125 个问题组成。锁定边界集由 P04—P07、P09 和 P10 的 1368 个非噪声候选组成。表 2 明确展示两个评价轴，避免因为一个项目在某一轴不合格而删除其另一轴的有效证据。

问题构造先做机械接地，再做内容和隐私判断。机械检查解析声明的证据单元，验证支持片段确实包含在该单元中、父块关系一致，并检出近重复问题。大语言模型只提供建议性的难度、内容和隐私预审，不具有批准权限。人工核验需要同时确认问题自然、答案唯一、父块正确、最小证据充分、问题类型合理以及隐私状态可接受表格问题还必须能够唯一定位到一行。无法达到这些条件的候选被排除，而不是为满足数量配额强行批准。

企业文档常在技术协议、建议书和需求规格中逐字复用段落，导致“唯一证据位置”并不总是合理。预审中，262 个早期草案只有 71 个可原样保留，124 个需要改写，67 个拒绝。本文因此为每个问题自动解析所有包含支持片段的单元，建立证据等价集合；返回任一合法副本均计为正确。若一个片段出现超过 12 次，则不再视为可接受的等价集合，因为它通常是每个接口都重复的请求方法或模板短语，不能区分实体。观察到的出现次数在 1—8 后直接跳到 18 以上，12 位于样本分布空档中。此类问题必须改写为更具定位性的支持片段或直接排除。

改写只改变问题如何表达信息需求，不编辑原始证据。若支持片段位于表头重复、占位列名或合并单元格造成歧义的表中，候选会被标记，因为字符包含检查无法判断答案是否错误解释了列语义。经补充与机械检查，候选集覆盖 9 个项目；最终人工轮保留 195 个问题。另有一条事后机械规则排除以多级章节编号开头的问题：删除该编号不应改变事实、答案和证据，但编号会把问题范围绑定到文档结构。该规则使用明确正则条件，保留人工工作簿原判断并单列覆盖记录，没有把拒绝改写为批准。

隐私门控只允许 `NO_RISK` 、`ANONYMIZED` 或 `CLEARED` 状态进入正式实验。内部网址、账号凭据、个人身份、客户名称安全架构和专有经营信息必须匿名化或拒绝。自动预筛把问题、答案、支持片段、文件名与章节路径合并扫描，风险标记只说明可能类别，最终判断仍按字段确认。例如，客户名只出现在不公开的文件名中与直接出现在答案中具有不同释放后果；后者优先拒绝，而不是编辑支持片段，因为编辑会破坏同一门控要求的原文包含关系。

表 2 锁定项目覆盖与轴向资格

项目	文档数	单元数	边界评价	检索问题数
P04	17	8532	合格	22
P05	17	8166	合格	17
P06	12	10122	合格	22
P07	8	2496	合格	23
P08	5	4369	排除（κ=0.650）	22
P09	4	5324	合格	19
P10	4	1408	合格	排除（11<15）

5.4 比较方法与公平控制

所有方法使用同一解析单元库存、BGE-M3 稠密向量、512 词元最大长度、问题文本和标题上下文前缀。比较器包括：（1）带重叠固定窗口；（2）本地递归切分；（3）只使用结构规则的切分；（4）语义切分；（5）官方 LangChain RecursiveCharacterTextSplitter 1.1.2；（6）官方 LlamaIndex SentenceSplitter 0.14.23；（7）只索引 SEAC 父块；（8）完整 SEAC。按照受控检索增强生成评价的原则[16]，本文不在不同方法之间更换编码器、检索深度或查询改写。

近年的 LumberChunker、基于伪指令的文档分段和混合分块学习器说明边界本身应被直接评价[17-19]，BERGEN 等基准库也强调把检索和生成环节分开报告[20]。考虑到本研究数据含企业机密，SEAC 构造阶段不调用生成式模型，避免因在线模型版本变化而使边界不可重放；同时不将外部叙事文档数据集上的结论直接替代工业语料验证。

消融实验一次只移除一个组件：语义距离、密度变化、连续性惩罚、自适应阈值、标题上下文、表格行子块或父子融合。完整 SEAC 是在锁定结果开放前指定的主方法。即使某个消融在锁定集上更优，也不能事后替换主方法，否则等同于用测试集选择配置。

5.5 指标、推断与实验环境

边界检测在排除 NOISE 后报告精确率、召回率和 F1。检索同时报告来源单元平均倒数排名（MRR）、Hit@1/3/5，以及支持片段 MRR 和 Hit@1/3/5。MRR 强调首个正确证据的位置，Hit@5 反映有限审阅预算下能否在前五结果找到证据。资源指标包括父块数、检索向量数、构造时间、索引时间和查询延迟。

置信区间采用 10000 次层次自助法[14]：先有放回重采样项目，再在每个被选项目内重采样观察。唯一确认性比较为完整 SEAC 对官方 LlamaIndex 句子切分器的单元 MRR。精确双侧配对检验在项目层交换方法标签，6 个项目产生全部 64 种分配。其他检索和边界比较分别构成次要检验族，并采用 Holm 方法校正[15]；消融保持探索性，不给出因果确认结论。长上下文模型的“中间信息遗失”现象也提示，Hit@k 和来源位置不能由模型上下文长度替代[21]。

正式运行使用 Python 3.12.3、`sentence-transformers` 5.6.0、`langchain-text-splitters` 1.1.2 和 `llama-index-core` 0.14.23，在 Linux ARM64 与 NVIDIA CUDA 环境执行，批量大小 16，随机种子 20260804。表 3 汇总完整 SEAC 的冻结参数。每个 P01—P10 运行均通过方法完整性、哈希一致性和禁止临时标签检查；若显式允许未审问题或临时边界，输出会被标记为不可报告。

表 3 SEAC 冻结参数与实现环境

项目	取值	作用
编码器	BGE-M3，归一化稠密向量	单元与查询表示
最大/软/密集/最小词元	512/320/224/48	父块长度控制
子块目标/最大词元	112/176	细粒度检索
边界权重	语义 0.45；结构 0.30；密度 0.25	相邻边界评分
文档阈值	0.8 分位；表格+0.08；标题−0.05	自适应切分
父/子得分权重	0.35/0.65	父块排序
推断设置	10000 次自助法；项目级精确检验	聚类不确定性
运行环境	Python 3.12.3；Linux ARM64；CUDA	可复现记录

5.6 泄漏控制和完整性门槛

实验程序在正式模式下拒绝临时边界和未审问题；探索模式必须显式开启并给输出加上不可报告标记。各方法的嵌入缓存隔离，避免先运行的方法把不同分块表示留给后续方法。P04—P10 的正式指标在所有锁定项目共同通过 QA、边界、隐私和运行审计后一次性释放。释放后不再修改参数、问题文本、排除规则、主比较器和主指标。

方法代码、冻结配置、标注模式、合成示例、测试、聚合分析、运行清单和哈希可组成审稿材料；原始企业文档和由其直接派生的问题不能公开。该安排不能实现对精确私有语料的公开复跑但可以让审稿人检查算法决策面、正式运行标识和统计分析是否一致，也能在后续受控环境中验证同一哈希输入是否产生相同结果。

5.7 可审查性与不可公开数据下的复现层级

私有工业研究不能把“代码公开”直接等同于“结果可复现”。本文将复现分为四个层级。第一层是方法可检查：公开或送审的实现、冻结配置和单元测试足以说明给定结构化单元时如何产生父块、子块、分数与来源映射。第二层是分析可重算：聚合的逐项目统计和锁定分析文件允许重建区间、精确检验和表格，而不暴露问题原文。第三层是受控可重复：在数据所有者许可的环境中使用记录的哈希、依赖和命令能够对同一输入重跑。第四层是公开可迁移：在合成或公共技术文档上验证接口、格式和相对趋势，但不能声称重现私有语料数值。

每个层级回答不同问题。方法可检查发现实现是否与论文一致；分析可重算发现统计或转录错误；受控可重复发现环境漂移；公开可迁移检验第三方能否使用方法。本文能够提供前两层材料，第三层取决于企业批准，第四层列为下一轮

工作。审稿人不应被要求仅凭论文相信一个不可追踪的“内部运行”，因此正式清单至少保留每项目命令、输入哈希、输出哈希、资格状态和错误断言。

聚合结果也需防止泄露。逐问题查询、答案和片段可能暴露客户业务；逐项目文档类型的稀有组合也可能帮助识别项目。本文只在论文报告匿名项目的文档数、单元数、问题数和评价指标不给出项目名称、文件名、接口路径、人员或精确业务示例。合成示例遵循相同字段模式但不复制企业事实。若程序委员会要求补充材料，应优先提供哈希清单、模式和合成测试；任何原文样本须单独经过数据所有者审批。

版本化是可审查性的另一部分。方法、配置、标注规则和论文表格均应指向同一协议版本 `industrial-seac-formal-analysis-v1.1`。规则修订不能覆盖旧文件，而应保留前后版本和解释。若在投稿后发现排版或文字错误，可修正稿件但不得悄然改变锁定结果；若发现实验实现错误，则需要撤回受影响数字、生成新版本并说明哪些结论改变。该约束使“可追溯”同时适用于研究过程本身。

6 实验结果

6.1 总体边界与检索质量

表 4 给出锁定结果。完整 SEAC 的边界 F1 为 0.5673，95% 置信区间为 [0.4708, 0.6488]；最强非 SEAC 边界基线为结构切分的 0.5032。SEAC 在 6 个合格项目上均更高，但经 Holm 校正的配对比较 p=0.4375，未达到显著水平。固定窗口理论上不预测语义边界，故其边界 F1 为 0。

在 125 个锁定问题上，完整 SEAC 的来源单元 MRR 为 0.7937，95% 置信区间为 [0.7060, 0.8772]，支持片段 MRR 为 0.8561，Hit@5 为 0.9520。最强非 SEAC 检索基线是结构切分，MRR 为 0.7290，观察差值为 0.0647。相对预先指定的 LlamaIndex 比较器，问题加权 MRR 差值为 +0.1003，层次自助法 95% 区间为 [0.0042, 0.2008]；但项目级精确双侧检验 p=0.0625。区间未跨 0 与精确检验未过 0.05 并不矛盾：只有 6 个独立项目时，64 种标签交换使精确检验的分辨率较粗。

表 4 锁定边界与检索结果

方法	边界 F1	单元 MRR	Hit@1	Hit@5	片段 MRR
固定窗口	0.0000	0.5158	0.3680	0.7200	0.1350
本地递归	0.0369	0.6086	0.4480	0.8080	0.7072
结构切分	0.5032	0.7290	0.6080	0.8880	0.8211
语义切分	0.3843	0.6999	0.5680	0.8640	0.8121
LangChain 递归	0.0054	0.6460	0.4960	0.8480	0.7329
LlamaIndex 句子	0.0920	0.6934	0.5520	0.8880	0.7586
SEAC 父块	0.5673	0.6796	0.5280	0.8800	0.7770
完整 SEAC	0.5673	0.7937	0.6800	0.9520	0.8561

该结果支持两项较窄结论。其一，结构感知方法整体优于固定或通用递归切分，说明工业文档布局不是可以忽略的噪声。其二，父块单独索引并不足以产生完整 SEAC 的检索效果，细粒度子层贡献明显。但当前项目数不支持“SEAC 在一般工业场景统计显著优于官方框架”的强结论。

6.2 跨项目一致性

表 5 展示完整 SEAC 与预先指定比较器的逐项目 MRR。SEAC 在 P04、P05、P07、P08 和 P09 上更高，在 P06 上较低。最大正差出现在 P05，P06 则反向约 0.0402。P06 同时是锁定集中单元数最多的项目，因此不能把该反向结果解释为微小项目的偶然波动。逐项目异质性证明了以项目聚类推断的必要性。

表 5 完整 SEAC 与 LlamaIndex 逐项目检索结果

项目	问题数	SEAC MRR	LlamaIndex MRR	差值
P04	22	0.6914	0.5033	+0.1881
P05	17	0.8627	0.6275	+0.2353
P06	22	0.6805	0.7206	−0.0402

项目	问题数	SEAC MRR	LlamaIndex MRR	差值
P07	23	0.8080	0.7360	+0.0719
P08	22	0.8386	0.7224	+0.1162
P09	19	0.9123	0.8557	+0.0566

项目差异可能来自文档结构、重复模板比例、表格密度和问题类型构成，但本文没有在看到结果后人工建立错误类别并据此调参。将这些因素解释为因果变量需要在新项目上预先定义度量与假设。当前表 5 只表明效果不是单个项目独占，同时也不是所有项目方向一致。

6.3 不同问题类型

数值约束问题在样本上最容易，MRR 与 Hit@5 均为 1.0000；流程问题最难，MRR 为 0.5429、Hit@5 为 0.8000。流程答案常跨越连续步骤，一个子块可能匹配到某一步，但标注证据位于相邻单元或另一节。该解释与父子机制一致，却不是经人工逐例确认的错误计数，因而只作为后续假设。

数据库类问题的片段 MRR 为 0.9839，而来源单元 MRR 只有 0.7323，差值 0.2516。同名字段、约束和模板短语会使嵌入器把不同实体中的行视为等价；系统可能找到能回答问题的文字，却没有返回负责该事实的标注源行。若仅报告文本命中，将掩盖这类来源错误。表 6 给出完整分类型结果。

表 6 完整 SEAC 按问题类型的检索结果

问题类型	数量	单元 MRR	Hit@5	片段 MRR
接口	17	0.8211	0.9412	0.8211
接口参数	10	0.7833	1.0000	0.7833
约束	16	0.9167	0.9375	0.9167
数据库	31	0.7323	1.0000	0.9839
功能	23	0.7867	0.9130	0.7867
会议事实	9	0.8370	1.0000	0.8370
数值约束	9	1.0000	1.0000	1.0000
流程	10	0.5429	0.8000	0.5429

6.4 组件消融

表 7 显示，当前数据不支持完整 SEAC 的每个组件。移除表格行子块产生最大不利变化：MRR 从 0.7937 降至 0.6853，Hit@5 从 0.9520 降至 0.8640。相反，移除父子融合把 MRR 提高到 0.8289；移除标题上下文提高到 0.8129，但 Hit@5 降至 0.9280。移除语义距离对 MRR 没有观察影响，其他边界评分消融改变不超过 0.0042。

表 7 锁定单组件消融结果

变体	边界 F1	单元 MRR	Hit@5	相对完整 MRR 变化
完整 SEAC	0.5673	0.7937	0.9520	—
无语义距离	0.5698	0.7937	0.9520	+0.0000
无密度变化	0.5639	0.7959	0.9520	+0.0021
无连续性惩罚	0.5718	0.7979	0.9520	+0.0042
固定阈值	0.5731	0.7959	0.9520	+0.0022
无标题上下文	0.5673	0.8129	0.9280	+0.0192
无表格行子块	0.5673	0.6853	0.8640	−0.1084
无父子融合	0.5673	0.8289	0.9520	+0.0352

消融族为探索性，SEAC 对“无表格行子块”的配对比较经 Holm 校正后 p=1.0000。因此，0.1084 的下降可被解释为带表头行级检索的强候选机制证据，不能被写成已确认的因果必要性。同理，本文不把无融合变体提升为新主方法；这样做将利用同一锁定集选择方法。下一轮独立项目应预先比较完整 SEAC、无融合简化版和最强结构基线。

6.5 资源开销

在 6 个检索项目上，结构切分产生 8891 个向量，完整 SEAC 产生 48912 个父子向量，为前者的 5.50 倍。完整方法构造和索引时间明显增加，平均查询延迟从 15.18 ms 增至 20.93 ms，增加 5.74 ms。表 8 表明，SEAC 不是成本更低的通用替代方案，而是当行级定位、来源校验和可审计上下文值得额外索引成本时的一种工程选择。

表 8 锁定检索集资源开销

方法	向量数	分块时间/s	索引时间/s	查询均值/95 分位/ms
结构切分	8891	0.25	139.46	15.18/18.40
完整 SEAC	48912	112.11	351.12	20.93/27.28

向量增量主要来自父块内部的段落与表格行子块。实际部署可只对接口表、数据库字典和约束表启用行级子块，或在低风险文档中使用结构平面索引；但这种分层策略尚未在本文锁定协议中评价。生产环境还需要测量增量更新而非一次性全量索引，因为父子映射必须在文档版本变化后保持一致。

6.6 排名结果的工程解释

MRR 从 0.6934 提高到 0.7937 并不表示每个问题的正确证据都前移相同距离。该指标对首个正确结果敏感，一个问题从第 5 名升到第 1 名的贡献大于从第 20 名升到第 10 名；Hit@5 则把前五之内视为同等成功。完整 SEAC 的 Hit@5 为 0.9520，说明在固定五条证据审阅预算下，大多数问题能找到合法来源，但仍有约 4.8% 的问题不在前五。对自动执行场景，即使这一比例也不可忽略，系统需要拒答、回退检索或人工复核，而不能把平均指标当作单次请求保证。

来源 MRR 与片段 MRR 的关系也不能简单理解为后者更宽松、因而永远更高。父块可能包含标注源单元，却因规范化或截断不包含最小支持字符串；反之，重复模板可能在错误实体中包含相同字符串。本文同时使用两者，是为了把“找到可回答文字”和“找到应负责的原始位置”分开。在会议事实与流程问题中，最小支持片段可能横跨连续陈述，父块有利于上下文，却未必让触发子块对应标注单元；在数据库问题中，重复字段则造成相反的片段高、来源低现象。

边界 F1 与检索 MRR 也不是单调关系。结构或语义边界更接近人工父块不保证小粒度问题更易匹配，完整 SEAC 与父块-only 共享 0.5673 的边界 F1，却具有明显不同的检索 MRR。消融中若边界 F1 小幅提高而检索不变，也不能据此宣称下游改进。分块研究至少应分别报告表示结构和任务检索，否则一个汇总答案指标无法说明哪一层有效。

逐项目结果中 P06 的反向差值要求部署前进行本地验证。若目标项目的文档类型、表格重复和问题分布接近 P06，直接采用完整 SEAC 可能没有收益。建议用一小组经过来源核验的问题比较结构平面索引与父子索引，再决定是否承担 5.50 倍向量成本。该建议不等于在新项目上调节论文方法；生产选型可以面向本地效用，科研结论仍需按冻结协议评价。

最后，消融表中的正向变化不应被当作多个“提升技巧”。无融合与无标题上下文是在同一锁定集上观察到的探索性结果，二者组合是否更优未知，也可能相互作用。只有在新项目上预先声明组合并保留完整方法作为对照，才能判断简化是否稳定。当前投稿据此采用克制表述：表格行子块是最有希望的机制，完整 SEAC 是被正式检验的方法，而不是把最高数字 0.8289 改写为主结果。

7 面向智能化工业软件工程的应用与治理

7.1 大模型驱动的需求分析

专题关注大模型对工业协议、设备手册、控制逻辑、生产流程和接口规范的需求抽取、理解规范生成、一致性检查与追踪。SEAC 不直接生成需求，而为这些任务提供证据层。对“某接口的超时上限是多少”之类问题，带表头子块可以定位参数与取值，父块补充接口和模块上下文；对“某流程由谁确认后才能执行”之类问题，父块保留连续步骤和角色描述；对“某字段是否允许为空”之类问题，来源标识把答案限定到特定表和字段行。

在需求抽取中，系统可先检索候选父块，再让大模型输出结构化需求，并要求每个字段携带 `document_id/block_id/unit_id`。人工评审界面同时

显示触发子块、返回父块和原文位置。如果生成需求没有有效来源标识，或来源单元不包含相应支持片段，系统应把它标记为未证实，而不是把流畅文本直接写入需求库。SEAC 因而支持“生成—证据—人工确认”的闭环，而非把检索质量等同于需求正确性。

对于规范一致性检查，可将来自需求、接口和数据库文档的可追溯单元组成候选证据对，再由规则或大模型判断字段名、类型、必填性、取值范围和状态机是否一致。来源标识允许冲突报告直接链接两个原始位置，并在文档修订后重新验证。该机制也可扩展到需求—测试追踪：测试生成器只接收有权限的父块，并把每条断言关联到触发子块；审阅者能够判断测试是否覆盖真实约束，而非模型自行补全的常识。

7.2 质量保障与幻觉审计

工业软件对实时性、可靠性和安全性要求较高，大模型输出不能仅以语义合理性验收。本文把来源 MRR 与支持片段 MRR 分开，正对应两类质量风险：错误来源可能导致把另一个设备、接口或版本的约束套用到当前对象；缺少支持片段则意味着引用位置虽相关，却没有证明生成结论部署时可以把两项检查转化为门控规则：没有授权来源、来源版本过期、源单元与结论缺少文本支持，任一条件成立时均不允许自动执行。

表格行子块的结果对缺陷定位和测试生成尤其有意义。数据库与接口表存在大量重复字段，整表检索会把模式稀释，裸行检索又会丢失列名带表头的行级表示同时提供字段模式与局部值，可减少“正确字段名、错误实体”的混淆。本文数据库问题仍出现较大来源—片段差距，说明结构保持不是充分条件；后续还需引入实体标识、稀疏词项、交叉编码重排或模式约束，并保持这些模块的评价与分块评价分离。

SEAC 的确定性构造也有助于复核大模型幻觉。当生成结果被质疑时，审计日志可以回放查询、候选子块、父块得分、来源标识和文档版本，区分错误来自检索缺失、排序错误、生成器忽略证据还是证据本身过期。相比只保存最终提示词，保存检索决策链能够更接近工程责任追踪所需的事实记录。

7.3 版本、访问控制与责任追踪

来源可追溯并不自动等于安全。企业知识库必须把文档访问控制列表传播到父块和子块，查询前或排序后执行授权过滤；否则一个无权查看父文档的用户仍可能通过行级子块看到敏感字段父子映射还需绑定内容哈希与版本号：文档更新后，旧子块不得继续指向已失效父块，审计日志则应保留当时使用的版本，以便解释历史输出。

建议的运行时记录至少包括：调用者与授权范围、查询和时间、编码器及分块配置版本、候选子块及分数、返回父块、源文档版本、生成器版本、最终输出和人工处置。对高风险任务，系统只提供决策支持，不直接执行控制指令或修改生产配置；人工确认者必须能访问原始证据并承担明确职责。该记录结构把方法层来源标识连接到组织层的合规审计和责任边界。

知识产权与许可同样需要在文档层治理。本文语料由企业内部材料组成，不能因为被分块或嵌入就改变其授权范围。检索服务应维护数据所有者、用途、保留期和可再发布状态；面向外部模型的调用要经过脱敏与传输审批。若第三方模型供应商会保留输入，则不能把受限父块直接发送给该服务。SEAC 只提供可执行的来源映射，数据合规仍由部署策略和授权人员决定。

7.4 工程集成边界

完整 SEAC 的 5.50 倍向量成本要求部署团队按风险和文档结构选择策略。数据库字典、接口表和性能约束表最可能从行级子块获益；叙事型方案或短会议纪要可能使用结构父块即可。建议先在离线基准上按文档类型测量来源 MRR、片段 MRR 和索引增量，再决定哪些类型启用父子层。本文没有正式比较这种按类型路由，因此只能作为工程建议，而非已验证结论。

与大模型的接口也应保持最小化。检索返回结构化证据包，包括父块文本、触发子块、来源标识、版本和授权标签；生成器只接收完成过滤的必要证据。输出格式要求逐条结论引用来源标识，无法引用时显式回答“证据不足”。质量流水线分别测试分块、检索、生成、引用和权限过滤，避免用端到端正确率掩盖某个子系统的系统性缺陷。

7.5 软件生命周期中的落点

在需求阶段，来源可追溯检索可用于从协议、手册和会议纪要中抽取候选需求。系统先返回证据包，大模型再生成“主体—动作—对象—条件—约束”结构；评审人员接受、改写或拒绝，并把决定连同来源保存。若后续原文版本变化，系统根据源单元哈希识别受影响需求，触发重新确认。这样，自动抽取不会绕开需求基线管理。

在设计阶段，可将需求证据与接口、数据库和详细设计证据成对检索，检查类型、范围、必填性、状态和错误码的一致性。冲突报告必须展示双方来源，而不是只给出模型判断。对跨文档同名实体，应在标题路径外增加项目内部实体键

本文的数据库来源差距表明，仅有语义嵌入和标题上下文还不足以解决所有实体消歧。

在测试阶段，生成器可从约束子块创建等价类、边界值和异常用例，从流程父块创建场景序列。每个测试断言关联最小证据，便于需求变更时定位需重生成的用例。若一个流程跨多个父块检索层应返回多个独立来源并显式表示顺序；不能让生成器根据常识补齐未检索步骤。端到端评价需要把测试可执行性与证据忠实性分开。

在运维和缺陷分析阶段，SEAC 可索引运行手册、故障案例、会议决议和版本说明，支持故障处置建议引用具体来源。生产日志、调用链和设备状态通常不是本文的静态文档单元，需要由时间窗、实体和访问级别建立另一类索引，再与文档证据融合。本文结果不能直接推广到实时流式数据，但源标识、版本和授权传播原则仍适用。

在治理阶段，审计者可以抽查生成结论是否有授权来源、引用是否仍指向当前版本、模型是否在证据不足时拒答。责任划分应区分数据所有者、知识库维护者、模型开发者、业务审核者和最终决策者。SEAC 提供检索链条的技术记录，不决定法律或组织责任；任何自动化等级提升都需结合任务风险、行业规范和人工审批重新评估。

8 讨论

8.1 当前证据支持的机制

最清晰的机制是“带表头的行级检索、连贯父块用于解释”。只索引 SEAC 父块的 MRR 为 0.6796，加入子层后为 0.7937；移除表格行子块为 0.6853。这三个观察共同说明，字段级问题需要更小的匹配单元。表头复制为行提供模式，标题路径提供实体范围，父块则避免把行级事实与周边约束完全分离。该机制符合接口参数、数据库字段和约束表的语义组成方式。

完整边界评分的支持较弱。去除语义距离不改变锁定 MRR，去除密度、自适应阈值或连续性惩罚也没有造成不利变化。这并不证明这些分量永远无用：它们可能影响父块可读性或在别的文档结构中发挥作用；但当前结果不足以把它们写成检索提升的必要来源。论文因此保留预先指定方法和全部负面结果，并把简化验证留给独立样本。

8.2 父子融合与标题上下文的反向结果

无父子融合变体取得 0.8289 MRR，高于完整方法。一个合理解释是宽父块分数会给包含较多常见术语的上下文过高权重，从而冲淡最相关子块；但本文没有逐问题验证该解释。无标题上下文也提高 MRR，却降低 Hit@5，可能表明模板化标题既能补充范围，也会让不同块的嵌入更相似两项结果都说明“更多上下文”不是单调有益，尤其在高重复工程模板中。

基于锁定集直接采用无融合配置会破坏预先声明的验证边界。下一次研究应在开放新项目之前冻结三个候选：完整 SEAC、只按最优子块排序的简化 SEAC、结构平面基线；同时预先规定主指标、项目最小问题数、边界一致性门槛和编码器这样才能判断 0.8289 是可复现改进还是当前样本上的选择偏差。

8.3 下一轮评价协议

下一轮优先增加独立项目数量，而非只在现有 6 个项目中增加问题。项目级精确检验的分辨率受集群数直接限制，更多同项目问题不能消除模板和术语相关性。新协议还应加入公开的多语言技术文档子集，哪怕规模较小，也能允许第三方从原文复跑并检验中文工程词表是否驱动结果。

其次，应增加端到端但分层报告的生成实验。对每种分块方法使用同一生成器，分别评价答案正确性、引用有效性、无支持断言、人工复核时间与拒答率。检索正确不保证生成器采用证据，答案表面正确也可能引用错误来源。只有把检索与生成指标同时保留，才能判断方法对大模型工业软件任务的真实贡献。

再次，应评价更新和治理成本，包括文档版本变化后的增量重建、子块到当前授权父块的映射、撤销访问权限后的缓存清理、过期证据检测和审计日志完整性。父子索引的维护面比平面索引更大；若更新后映射失真，检索精度提升反而可能带来错误责任归属。

9 有效性、伦理与数据可用性

9.1 构念与内部有效性

边界 F1 衡量与标注父块切分的一致性，不等同于下游答案质量；检索指标隔离分块效果，也不能证明某个生成器的忠实性。提升参考中 77.5% 的候选经人工核验，但保留的大模型预标注可能与 SEAC 共享结构偏好。人模一致性门槛和 P08 排除降低了风险，未完全消除。规则生成的问题草案也可能偏向局部事实问题，尽管所有保留问题都经过人工复核。

内部有效性依赖共同的解析单元库存。若历史格式转换或表格恢复有误，所有切分器都从同一错误输入出发，相对比较可能看不到共同失败本文通过哈希、版本固定、转换抽检、集体释放门槛和统一上下文减少漂移，但没有逐单元人工核对 66981 个单元。混合边界参考也可能与结构型

方法共享偏差；因此本文同时报告检索结果，不以边界 F1 单独证明方法有效。

9.2 结论与外部有效性

两个推断轴都只有 6 个独立项目。项目文档数和问题数不等，层次自助法处理聚类，却不能创造新的独立项目。项目级精确检验只有 64 种分配，故本文报告效应量、区间和方向一致性，不以 p=0.0625 支持一般统计优越性。探索性消融也不能在同一锁定集上承担模型选择证据。

语料为中文企业文档，且以工业管理信息系统为主。结果能否推广到英文制品、源代码、缺陷单、安全关键控制系统、扫描 PDF 或图像型演示文稿尚未建立。被排除的 6 份 PDF/PPTX 可能与已解析材料系统性不同。实验仅使用一个稠密编码器和一个上下文前缀设计；稀疏—稠密混合检索、重排器或其他生成器都可能改变排序。

9.3 隐私、公开与人工责任

原始文档和派生问题包含企业专有信息及潜在身份信息，不能公开。可提供的审稿材料包括非数据依赖实现、冻结配置、标注模式、合成的模式合法示例、自动测试、聚合结果、运行清单和哈希。更广泛的数据开放需要数据所有者书面批准；受控访问可以申请，但不保证获得。论文中的项目编号、统计表和示例均不得用于反推客户身份。

大语言模型仅作为盲化边界预标注工具和问题预审建议工具，未作出隐私、公开、署名或最终标注决定。授权人员确认所有保留问题和隐私判断。论文撰写中使用了生成式人工智能辅助结构调整、语言起草和一致性检查，研究者核验引用、实验输出、数值、图表和文本，并对全部研究与投稿决定负责。核心方法、实验协议、数据处理和结论由作者确定。

10 结论

本文提出面向工业软件工程文档的来源可追溯结构保持分块方法 SEAC。方法将标题、段落和表格行统一为带稳定来源标识的单元，构造连贯父块，并用带表头与标题路径的细粒度子块激活父块。10 个企业项目的冻结研究显示，完整 SEAC 在 125 个锁定问题上取得单元 MRR 0.7937 和 Hit@5 0.9520，观察上优于非 SEAC 基线及预先指定的 LlamaIndex 比较器；但项目级精确检验 p=0.0625，不能宣称一般统计优越性。

消融结果把证据重点从“完整评分公式”收窄到“表格行子块”：移除该组件使 MRR 降至 0.6853，而去除父子融合反而升至 0.8289。该负面结果要求在新项目上预注册比较完整与简化变体。完整 SEAC 的向量量为结构平面基线的 5.50 倍，适用于来源粒度与审计价值足以覆盖额外成本的场景通过把生成结论连接到授权文档、解析块和最小证据单元，SEAC 可作为大模型驱动需求分析、规范核对、测试生成与工程治理的可验证检索基础但端到端生成质量、访问控制与版本更新仍需独立评价。

附录 A 父块与子块构造过程

本附录给出与实现一致的过程描述，便于在不接触私有语料时检查方法决策面。输入是按阅读顺序排列的可追溯单元序列、冻结配置和嵌入器；输出是父块集合、子块集合以及父—子—源单元映射。算法不读取问题、答案、边界参考或锁定项目身份。

步骤 1：规范化输入。对每个解析块生成零个或多个单元。标题保留标题级别并更新标题路径普通段落保留文本和源块位置；列表项保留顺序表格识别表头后为每个有效数据行生成“表头+数据行”表示。空白、页码和确定性噪声保留审计记录但不进入可检索序列。所有输出单元必须具有唯一 `unit_id`，且 `document_id` 和 `block_id` 可解析回源文件清单。

步骤 2：预处理超长单元。若单个单元超过 512 词元，依次尝试在句末、分号、换行、列表边界和其他标点处拆分；只有这些边界均不能满足长度时才按词元回退。拆分片段共享原始源单元标识，并增加片段序号，避免把技术限制导致的片段误当成多个独立来源。表格行拆分不得删除表头或标题路径。

步骤 3：计算相邻信号。批量编码全部有效单元，计算相邻余弦距离；根据右单元类型、标题路径和受保护组生成结构指示量；用冻结词表计算密度及其变化；根据相同路径和相同组生成连续性惩罚。每个候选边界保存 d_i、s_i、k_i、p_i 和最终 b_i，便于对单个异常切分进行回放。

步骤 4：确定文档阈值。仅用当前文档的候选分数计算 0.8 分位数，再按表格行和标题比例调整。若文档没有足够有效相邻对，使用冻结回退阈值并记录原因。阈值计算不能读取其他项目的检索表现。密集区软目标依据当前待组装父块的平均词密度动态选择，但词密度门槛 0.03 在配置中固定。

步骤 5：线性组装父块。初始化空父块，从左至右追加单元。遇到新标题、超过软目标且边界得分达到阈值、或将超过硬上限时产生候选切分随后按顺序检查受保护组、标题—首段耦合和最

小长度；若违反则延迟切分。达到硬上限而结构保护仍阻止切分时，只能在已由步骤 2 安全拆分的逻辑片段之间选择位置。完成父块后记录有序源单元和源块列表、长度、标题路径范围与配置哈希。

步骤 6：生成子块。父块自身形成父级检索项。对父块中的非标题、非噪声单元，按 112 目标和 176 最大词元生成子块；普通文本附加文档类型、标题路径和叶主题，表格行附加表头和标题路径子块必须引用一个父块并保存所有源单元标识，禁止出现无父块孤儿。无表格子块消融只跳过表格行子项；无标题上下文消融只删除前缀；两者不能改变父块内容。

步骤 7：索引与检索。分别编码查询、父级检索文本和子级检索文本。对每个父块取最高子块得分，与父块得分按式（10）融合并排序；无融合变体将父权重设为 0。返回记录包括父块文本、父分数、最高子分数、触发子块、源标识和排名评价程序直接比较源标识与 G(q)，并独立检查返回文本是否包含 z(q)。

步骤 8：完整性断言。正式运行在写出结果前验证：每个父块非空且不超过硬上限；每个子块指向存在的父块；源单元顺序单调；同一父块内受保护组未被非法截断；缓存键包含方法、编码器、配置和语料哈希；正式结果未启用探索标志任何断言失败都会使运行无效，不允许只跳过失败问题或项目。

附录 B 复现、审稿与部署检查项

复现包首先提供冻结配置和实现哈希。配置列出编码器、最大长度、重叠、全部边界权重、结构指示量权重、密度变化缩放、表格/标题阈值调整、父块软目标、子块目标及父子融合权重。实现哈希覆盖分块、单元构造、语义表示与评价代码，避免只记录方法名称却无法确定实际代码版本。

其次，运行清单按项目记录语料、问题和边界文件的 SHA-256，Python 与包版本、平台、设备、批量大小、完整命令、项目划分、边界与检索轴的资格状态以及排除原因。P08 的边界排除原因固定为 κ=0.650；P10 的检索排除原因固定为 11<15。审计程序还检查不能对实际上达到门槛的项目声明排除，从机制上降低结果开放后静默删除不利项目的可能性。

再次，标注材料包含边界标签规则、修订解释记录、盲化预标注、人工核验工作簿、修订前后一致性摘要、规则符合性审计和项目哈希。问题材料包含草案、机械接地结果、模型建议预审人工判断、支持片段、证据等价集合、隐私类别与事后机械排除记录。公开版本只使用合成的模式合法示例；任何包含企业原文的工作簿都留在受控环境。

统计分析脚本固定主方法、主比较器、主指标、随机化单位、交换规则、层次自助法次数和多重比较族。报告表必须能从锁定分析 JSON 机械重建，正文中的 0.7937、0.9520、0.7290、0.1003、区间 [0.0042,0.2008]、p=0.0625、0.6853、0.8289 和 5.50 倍均应与该输出逐项一致。若后续修订只改变文字，不得重新运行并替换锁定数值若发现分析错误，则必须生成新的版本化协议并披露差异。

面向审稿，建议提交包至少保留四类说明。第一类是论文 PDF 和可编辑 Word 稿；第二类是实验与伦理声明，说明私有数据不能公开的原因和可提供的替代材料；第三类是作者与投稿元数据，包括中英文姓名、单位、通信信息、基金和专题选择；第四类是差异说明，明确会议录用不代表《计算机学报》自动录用，若进入推荐阶段仍需按照现场反馈修改并接受期刊内部评审。

面向部署，需额外验证授权传播、版本更新、索引撤销、日志留存和人工接管。任何子块的权限不得宽于源文档；父块引用的全部源单元必须对调用者可见；文档删除或权限收回后，父子向量和缓存应在规定时间内失效；答案引用应携带当时版本与内容哈希；高风险请求应支持拒答和人工复核。上述控制不属于本文离线效果实验，不能用 MRR 替代验收，但它们决定来源可追溯能否真正转化为工程治理能力。

最后，后续独立复验应在打开新项目指标之前书面冻结三种候选方法、项目纳入标准、每项目问题门槛、边界一致性门槛、主指标和生成器设置。若计划比较按文档类型启用子块的成本优化方案，也应预先规定路由规则，不能根据新项目结果挑选文档类型。复验至少报告项目级方向来源与片段双指标、向量增量、索引更新成本和引用有效性，才能判断简化方案是否同时保留检索质量与治理价值。

附录 C 项目与补充指标明细

表 A1 给出 10 个项目的结构规模。词元为冻结正则分词器统计，不是 BGE WordPiece 数；表格数与数据行数用于说明语料的结构密度，不作为方法调参后的解释变量。P04—P10 在指标开放前共同锁定。

表 A1 各项目语料结构明细

项目	划分	文档	解析块	单元	近似词元	表格	表格行
P01	开发	7	4790	10574	194119	839	6623
P02	开发	8	4849	10797	224422	986	6934
P03	验证	7	3075	5193	103562	412	2530
P04	锁定测试	17	4180	8532	301754	474	4826
P05	锁定测试	17	3886	8166	228920	464	4744
P06	锁定测试	12	5623	10122	255278	758	5257
P07	锁定测试	8	1564	2496	59925	172	1104
P08	锁定测试	5	1206	4369	123307	198	3361
P09	锁定测试	4	1606	5324	133710	329	4047
P10	锁定测试	4	1062	1408	52903	62	408
合计	—	89	31841	66981	1677900	4694	39834

表 A2 同时列出噪声规则修订前、后的随机核验组一致性。资格按修订后 $\kappa \geq 0.70$ 判定；P08 被排除后仍保留其原始记录和检索资格。表中原始一致率为修订后随机核验组的一致比例。

表 A2 边界标注一致性审计

项目	修订前 κ	修订后 κ	原始一致率/%	边界资格
P02	0.61	0.87	94.0	合格
P03	0.56	0.76	88.8	合格
P04	0.81	0.89	96.3	合格
P05	0.66	0.96	98.8	合格
P06	0.42	0.91	97.2	合格
P07	0.75	0.98	98.8	合格
P08	0.68	0.65	84.5	排除
P09	0.75	0.72	87.6	合格
P10	0.77	0.76	89.9	合格

表 A3 补充表 4 未展开的边界精确率、召回率和置信区间。SEAC 与父块-only 具有相同父块边界，因此三项点估计相同；两者的检索表示不同不应据此合并其检索结果。

表 A3 锁定边界评价补充指标

方法	精确率	召回率	F1	F1 的 95%置信区间
固定窗口	0.0000	0.0000	0.0000	[0.0000, 0.0000]
本地递归	0.0402	0.0340	0.0369	[0.0051, 0.0783]
结构切分	0.3611	0.8298	0.5032	[0.4108, 0.5859]
语义切分	0.2920	0.5617	0.3843	[0.2779, 0.4800]
LangChain 递归	0.0074	0.0043	0.0054	[0.0000, 0.0265]
LlamaIndex 句子	0.4615	0.0511	0.0920	[0.0367, 0.1570]
SEAC 父块	0.4321	0.8255	0.5673	[0.4704, 0.6486]

方法	精确率	召回率	F1	F1 的 95%置信区间
完整 SEAC	0.4321	0.8255	0.5673	[0.4708, 0.6488]

表 A4 补充检索的 Hit@3 与片段 Hit@5。完整 SEAC 的来源 Hit@3 为 0.9040，说明其优势不只来自把证据挤入第 5 名；片段 Hit@5 与来源 Hit@5 同为 0.9520，但逐问题成功集合未必完全相同。

表 A4 锁定检索评价补充指标

方法	单元 MRR	Hit@1	Hit@3	Hit@5	片段 MRR	片段 Hit@5
固定窗口	0.5158	0.3680	0.6240	0.7200	0.1350	0.1840
本地递归	0.6086	0.4480	0.7200	0.8080	0.7072	0.8480
结构切分	0.7290	0.6080	0.8320	0.8880	0.8211	0.9040
语义切分	0.6999	0.5680	0.8240	0.8640	0.8121	0.8960
LangChain 递归	0.6460	0.4960	0.7440	0.8480	0.7329	0.8720
LlamaIndex 句子	0.6934	0.5520	0.8400	0.8880	0.7586	0.8960
SEAC 父块	0.6796	0.5280	0.8160	0.8800	0.7770	0.8960
完整 SEAC	0.7937	0.6800	0.9040	0.9520	0.8561	0.9520

致谢与人工智能使用声明

本研究使用 OpenAI Codex 辅助论文结构调整、中英文语言起草、图表代码生成与一致性检查。作者对相关工作、实验协议、数据处理、统计方法、全部数值、图表和最终表述进行了人工核验并对研究和投稿决定承担全部责任。生成式人工智能未被列为作者，未决定论文署名、隐私开放正式标注或研究结论。基金与其他致谢信息待作者确认后补充。

参考文献

[1] Lewis P, Perez E, Piktus A, et al. Retrieval-augmented generation for knowledge-intensive natural language processing tasks. Advances in Neural Information Processing Systems, 2020, 33: 9459-9474.

[2] Karpukhin V, Oğuz B, Min S, et al. Dense passage retrieval for open-domain question answering. In: Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing. Online: Association for Computational Linguistics, 2020: 6769-6781.

[3] Reimers N, Gurevych I. Sentence-BERT: Sentence embeddings using Siamese BERT-networks. In: Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing. Hong Kong: Association for Computational Linguistics, 2019: 3982-3992.

[4] Chen J, Xiao S, Zhang P, et al. M3-Embedding: Multi-linguality, multi-functionality, multi-granularity text embeddings through self-knowledge distillation. In: Findings of the Association for Computational Linguistics: ACL 2024. Bangkok: Association for Computational Linguistics, 2024: 2318-2335.

[5] Chen T, Wang H, Chen S, et al. Dense X retrieval: What retrieval granularity should we use? In: Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing. Miami: Association for Computational Linguistics, 2024: 15159-15177.

[6] Günther M, Mohr I, Williams D J, et al. Late chunking: Contextual chunk embeddings using long-context embedding models. arXiv preprint arXiv:2409.04701, 2024.

[7] Sarthi P, Abdullah S, Tuli A, et al. RAPTOR: Recursive abstractive processing for tree-organized retrieval. In: Proceedings of the Twelfth International Conference on Learning Representations. Vienna: OpenReview, 2024.

[8] Auer C, Dolfi M, Carvalho A, et al. Docling technical report. arXiv preprint arXiv:2408.09869, 2024.

[9] Guo J L C, Steghöfer J P, Vogelsang A, Cleland-Huang J. Natural language processing for requirements traceability. arXiv preprint arXiv:2405.10845, 2024.

[10] Ali S J, Naganathan V, Bork D. Establishing traceability between natural language requirements and software artifacts by combining retrieval-augmented generation and large language models. In: Conceptual Modeling. Cham: Springer, 2024: 295-314.

[11] LangChain. langchain-text-splitters 1.1.2. Python Package Index, 2026.

[12] LlamaIndex. SentenceSplitter, llama-index-core 0.14.23. Python Package Index, 2026.

[13] Cohen J. A coefficient of agreement for nominal scales. Educational and Psychological Measurement, 1960, 20(1): 37-46.

[14] Efron B. Bootstrap methods: Another look at the jackknife. The Annals of Statistics, 1979, 7(1): 1-26.

[15] Holm S. A simple sequentially rejective multiple test procedure. Scandinavian Journal of Statistics, 1979, 6(2): 65-70.

[16] Wang X, Wang Z, Gao X, et al. Searching for best practices in retrieval-augmented generation. In: Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing. Miami: Association for Computational Linguistics, 2024: 17716-17736.

[17] Duarte A V, Marques J, Graça M, et al. LumberChunker: Long-form narrative document segmentation. In: Findings of the Association for Computational Linguistics: EMNLP 2024. Miami: Association for Computational Linguistics, 2024: 6473-6486.

[18] Wang Z, Li Y, Zhao Y, et al. Document segmentation matters for retrieval-augmented generation. In: Findings of the Association for Computational Linguistics: ACL 2025. Vienna: Association for Computational Linguistics, 2025: 8063-8075.

[19] Zhao J, Zhang Y, Yang X, et al. MoC: Mixtures of text chunking learners for retrieval-augmented generation system. In: Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics. Vienna: Association for Computational Linguistics, 2025: 5172-5189.

[20] Rau D, Wang S, Déjean H, et al. BERGEN: A benchmarking library for retrieval-augmented generation. In: Findings of the Association for

Computational Linguistics: EMNLP 2024. Miami: Association for Computational Linguistics, 2024: 7640-7663.

[21] Liu N F, Lin K, Hewitt J, et al. Lost in the middle: How language models use long contexts. Transactions of the Association for Computational Linguistics, 2024, 12: 157-173.

[22] Mucha J, Kaufmann A, Riehle D. A systematic literature review of pre-requirements specification traceability. Requirements Engineering, 2024, 29: 119-141.

[23] Wang B, Zou Z, Wan H, et al. An empirical study on the state-of-the-art methods for requirement-to-code traceability link recovery. Journal of King Saud University—Computer and Information Sciences, 2024, 36: 102118.

作者简介

[作者姓名待确认]，性别、出生年份、学位、职称、主要研究方向与长期有效 E-mail 待确认。

Background

Large language models are increasingly embedded in software engineering workflows, but industrial software differs from open-domain text generation in the density of constraints, the heterogeneity of artifacts, and the consequences of unsupported outputs. Requirements, interface specifications, database dictionaries, detailed designs, technical agreements, and meeting records jointly define system behavior. The same term may refer to different modules or versions, while critical evidence is often expressed in a table row whose meaning depends on its header and section path. A retrieval-augmented generation system therefore needs more than semantically similar passages: it needs evidence that remains attributable to the correct artifact location.

Document chunking determines the units visible to a retriever. Fixed windows can cut through a requirement or table. Generic recursive splitters follow separators but do not understand engineering coupling. Heading-only splitters preserve sections yet may return excessive context for field-level questions. Semantic splitters may identify topical shifts while separating a data row from its schema. These errors propagate to downstream generation, citation, consistency checking, and change-impact analysis. Long-context models do not remove the problem because irrelevant context increases cost and evidence can still be overlooked or confused.

SEAC addresses this representation layer. It normalizes paragraphs, headings, and table rows into stable source units, constructs coherent parent chunks with deterministic boundary rules, and indexes fine-grained children that retain heading paths and table headers. A child is used for matching, while its parent provides interpretation context. The retrieval record preserves the exact document, block, and unit identifiers that produced the result. This separation enables two complementary evaluations: whether returned text contains the supporting span and whether it originates from an accountable source unit.

The industrial study follows a frozen protocol because project templates and terminology create clustered observations. Development, validation, and locked-test projects are separated. Questions and boundary references are reviewed before locked metrics are released. Statistical inference resamples or exchanges labels at the project level rather than treating all questions as independent. The study reports negative results and resource costs alongside aggregate gains. In particular, the available evidence supports header-aware table-row retrieval, but it does not validate every component of the full scoring design or establish general superiority with only six independent retrieval projects.

For intelligent industrial software engineering, provenance-aware retrieval can support requirements extraction, interface and database consistency checking, test generation, defect review, and audit logs. It must nevertheless be combined with document-level access control, versioned parent-child mappings, privacy review, and human responsibility. Retrieved evidence can improve the verifiability of a large-model workflow, but it does not by itself authorize automated decisions or guarantee that a generator will faithfully use the evidence.