面向可审计企业检索增强生成的溯源保持型结构感知分块方法

摘要—企业级检索增强生成要求证据既与问题相关，又能够归因到明确来源；然而，传统分块方法可能把需求与其约束分开，把表格行与表头分开，或把接口字段与其所在章节的上下文分开。本文提出 SEAC，一种确定性的结构感知分块方法。该方法构造携带溯源信息的文档单元，保护结构组，综合语义、结构和关键信息密度信号，并将表格行索引为连贯父块的精确子块。冻结研究方案覆盖 10 个企业软件项目中的 66,981 个单元，使用 BGE-M3 嵌入比较 15 种方法。在 6 个符合检索条件的锁定项目和 125 个经人工批准的问题上，SEAC 的单元 MRR 为 0.7937，Hit@5 为 0.9520；最强的非 SEAC 基线方法的 MRR 为 0.7290。与预先指定的 LlamaIndex 比较时，项目配对差异为 0.1003，精确检验 $p = 0.0625$，因此现有证据尚不足以确认其优势达到统计显著水平。SEAC 在 6 个独立满足条件的项目上取得 0.5673 的边界 F1。移除表格行子块后，MRR 降至 0.6853；移除父块融合后，MRR 反而升至 0.8289。因此，SEAC 在付出更高索引成本的同时改善了观测到的证据检索效果与可审计性，但其本身并不能证明生成答案更加安全。

关键词—检索增强生成，文档分块，数据溯源，可审计性，软件工程，可信人工智能

I. 引言

检索增强生成（RAG）利用外部证据为语言模型提供事实依据 [1]。在企业软件工程中，这些证据分散在需求文档、接口规范、数据库字典、详细设计、技术协议、问题记录和会议纪要等材料中。相关事实往往不是一个孤立句子：需求的约束力依赖其义务性措辞及所在章节；接口参数依赖其端点；数据库取值只有放在列标题和约束条件下才有意义。平坦的字符窗口虽然可能检索到表面上合理的词语，却会丢失审计答案所需的关键上下文。

这意味着，透明性问题在生成开始之前就已经出现。如果检索返回的段落无法确定来源单元，或者返回的表格无法区分正确行，下游系统就无法提供可辩护的引用。反之，返回整篇文档会引入更多无关上下文，并可能掩盖真正起支撑作用的文本范围。因此，分块需要在返回上下文的连贯性、细粒度匹配能力和稳定溯源之间取得平衡。

本文提出 SEAC，一种面向可审计企业 RAG 的确定性结构与关键信息感知自适应分块方法。SEAC 将文档解析为具有稳定来源标识的有序单元，防止在受保护结构组内部切分，将相邻语义距离与显式文档信号结合，并构造能够由匹配结果回溯到连贯父块的检索子块。表格行保留其表头和原始行标识，每个返回的父块都携带有序的来源单元谱系。

本文有三点主要贡献。第一，定义了一种保持溯源信息的分块表示，以及适用于异构工程文档的透明边界规则。第二，给出一项冻结的工业评估，其中包含人工批准与隐私发布门控、按评估轴设置的剔除规则，以及按项目聚类的统计推断。第三，同时报告质量与成本，并披露不利的消融结果。本文评估的是证据检索和边界一致性，并不声称仅靠分块就能防止幻觉、提示注入或隐私泄漏。

本文的威胁模型有意保持较窄范围。我们考虑的是一个已经由访问控制选定语料库的授权企业 RAG 服务，但该服务仍必须返回可以检查并追溯的证据。研究范围内的风险包括结构化事实被割裂、来源谱系丢失，以及检索到主题相似但实际错误的表格行。模型失陷、恶意文档、被投毒的嵌入、提示注入和绕过授权不在本文范围内。对治理而言，这一区分十分重要：可追溯分块可作为审查证据，但溯源元数据本身不是访问控制决策，较高的检索排序也不能证明答案忠实。

II. 相关工作

RAG 与稠密段落检索在生成之前将查询连接到外部文本 [1]、[2]。检索粒度会产生重要影响：较小单元有利于定位，但可能丢失上下文；较大单元保留更多上下文，却

会稀释匹配信号 [4]。近期研究探索了长上下文嵌入、递归层次结构、学习式分块混合以及系统化 RAG 设计 [5]-[8]。文档切分本身会显著影响检索质量 [6]，但多数评估使用公开文本或合成变换数据，而不是包含表格和重复规范的保密软件工件。

文档转换系统能够恢复标题、阅读顺序和表格 [9]，但抽取过程本身并不能决定哪些元素应该属于同一个检索单元。软件可追踪性研究将需求与下游工件建立联系 [10]、[11]；当同一段经批准的文本出现在多个文档中时，这类研究强调稳定来源标识和证据等价性的重要性。长上下文研究还表明，仅把证据放入很大的上下文中，并不能保证模型有效利用这些证据 [12]。SEAC 聚焦结构化文档转换与溯源感知企业检索之间尚未解决的接口问题。

III. SEAC

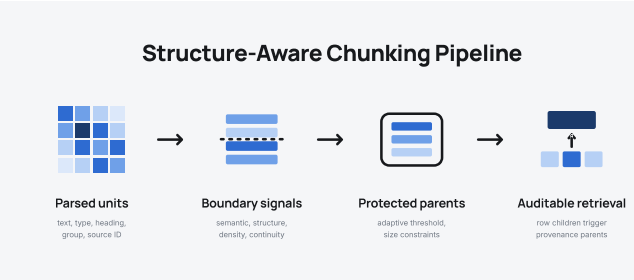


图 1. SEAC 在边界评分、父块构建和子块触发检索过程中保留稳定的来源单元标识。

A. 携带溯源信息的单元

设解析后的文档为有序单元序列（D = (u_1, ..., u_n)）。每个单元保存文本、稳定的单元标识、来源块、文档类型、块类型、标题路径，以及可选的受保护组标识。段落和标题均作为单元。对于表头为 (h) 的表格，将每一行 (r_j) 渲染为

$$t(r_j) = \text{header}(h) \,\|\, \text{row}(r_j)$$

从而使该行在脱离原表格后仍然能够被解释。父块保存构成它的有序单元标识和块标识，因此可以通过标识符而不是近似字符串匹配来判断检索是否正确。

B. 透明边界评分

对于相邻单元，语义距离定义为 (d_i = 1 - cos(e_i,e_i+1))，其中 (e_i) 是归一化稠密嵌入。结构得分 (s_i) 综合新标题指示量、标题路径变化和受保护组转换。冻结的工程词表统计义务、约束、接口、字段、表格、过程和限制等术语，其归一化密度为

$$\rho(u) = \sum_{v \in V} \text{count}(v,u) / \max(1, \text{tokens}(u))$$

相邻密度变化得分为 (k_i = min(1,10|rho(u_i)-rho(u_i+1)|))。连续性惩罚 (p_i) 抑制在同一标题路径内切分，并在实践中禁止在受保护组内部切分。冻结边界得分为

$$b_i = 0.45\, d_i + 0.30\, s_i + 0.25\, k_i - p_i$$

对于文档 (D)，阈值为 (theta_D = Q_0.8(b) + 0.08r_t - 0.05r_h)，其中 (r_t) 和 (r_h) 分别为表格行和标题所占比例。父块构建采用确定性的从左到右扫描：硬上限为 512 个 token，普通目标长度为 320 个 token，高密度区域的目标长度为 224 个 token，最小长度为 48 个 token。当候选切分会拆开受保护组，或使标题与其首个内容单元分离时，该候选切分将被抑制。

C. 分层检索

每个父块都是下游实际返回的上下文。非标题、非噪声单元还会生成检索子块，目标长度为 112 个 token，最大长度为 176 个 token。表格行通常成为独立子块，并保留行级溯源信息。检索文本以前缀形式加入文档类型和标题路径。设父块得分为 (S_p)，子块得分为 (S_c)，完整 SEAC 的排序函数为

$$S(p,q) = 0.35\, S_p(q) + 0.65 \max S_c(q)$$

因此，一条精确的表格行可以激活其父块，而返回文本仍保留附近约束。不计编码器成本时，构建复杂度相对于单元数为线性；索引规模随父块和子块总数增长。

D. 审计接口与信任边界

SEAC 返回父块标识、得分、有序来源单元标识、块标识、文档类型、标题路径和触发检索的子块。使用它的 RAG 服务可以展示作为证据的表格行及附近上下文，审计

人员则可利用同一组标识在版本化语料库中解析原始位置。引用不会从生成文本中重新构造。因此，文档转换、分块构建、检索和答案生成可以成为彼此分离的审计阶段。

实现会随每次运行记录语料库哈希和方法配置。如果文档发生变化，可以在检索前使其派生标识和运行清单失效。这支持变更控制和事故重建，但不决定用户是否有权查看某个来源。运行时授权必须在索引或过滤之前执行，不能仅因某段保密文本的标识可追溯就将其暴露。在本研究中，隐私发布是评估数据的准入门控，而不是算法提供的隐私保证。

IV. 工业评估

A. 语料库与冻结协议

语料库包含来自 10 个匿名企业项目的中文 DOCX 和 XLSX 工件，包括需求文档、API 规范、数据库设计、详细设计、技术协议、会议纪要、方案和研究报告。另有 6 个不受支持的 PDF 或 PPTX 文件被作为实质性跳过项予以披露。表 I 汇总了固定数据划分。P01-P02 为开发项目，P03 为验证项目，P04-P10 共同构成锁定集。任何锁定结果都不得改变参数、问题措辞、基线选择或排除规则。

表 I. 汇总后的工业语料库

划分	项目数	文档数	单元数	正则 token 数	表格行数
开发集	2	15	21,371	418541	13,557
验证集	1	7	5,193	103562	2,530
锁定测试集	7	67	40,417	1155797	23,747
总计	10	89	66,981	1677900	39,834

所有方法均使用 BGE-M3 [3]、512 个 token 的最大长度以及单元级证据。比较方法包括固定窗口、本地递归分割器、仅结构分割器、语义分割器、LangChain [16] 和 LlamaIndex [17] 的官方分割器、非分层 SEAC、完整 SEAC，以及 7 个单组件消融变体。正式比较矩阵共包含 15 种方法。

B. 人工审核与隐私门控

边界参考标签为 BREAK、NO_BREAK 或 NOISE。P01 包含 4,783 个由两名标注者独立标注并经裁决的边界。对于 P02-P10，每个项目抽取 300 个分层候选边界，在冻结规则集下由 Cursor 中的 Claude Opus 5 Thinking 预标注，且预标注过程不接触任何方法输出。随后，人工标注者在盲态下标注每个项目随机抽取的 100 个样本，以及模型标记的全部案例。人工标签覆盖预标注结果。项目只有在 Cohen's kappa 不低于 0.70 时才满足条件 [13]。P08 的 kappa 为 0.650，因此仅从边界评估中剔除，仍可参与检索评估。在最终采纳的 7,183 个候选边界中，77.5% 经人工验证，5.4% 由规则确定，17.1% 保留模型预标注。

问题草稿依次接受机械式证据检查、咨询性质的模型预审和人工批准。证据表示为稳定单元标识集合，因为经批准的文本范围可能在多个文档中合理重复。包含歧义表格行或缺乏区分度文本范围的问题会被拒绝。隐私状态只能由获得授权的人员判定；记录仅在标记为无风险、已匿名化或明确获准时才能进入评估。P10 最终保留 11 个获批问题，低于冻结设定的最小值 15，因此仅从检索评估中剔除。最终，锁定分析包含来自 6 个检索合格项目的 125 个问题，以及来自 6 个边界合格项目的 1,368 个候选边界。

C. 指标与统计推断

单元 MRR 和 Hit@k 要求返回父块的溯源信息包含获批证据单元。文本范围指标还检查最小支撑文本。边界指标在排除 NOISE 后比较相邻单元是否被分入同一父块。本文使用 10,000 次分层 bootstrap 构造 95% 区间，先重采样项目，再重采样项目内条目 [14]。唯一的验证性检验比较 SEAC 与 LlamaIndex SentenceSplitter 的单元 MRR。检验以项目为整体交换全部配对观测，并枚举 6 个项目的全部 64 种符号分配。次要检索和边界检验族采用 Holm 校正 [15]。

D. 公平性与可复现性控制

每种方法接收相同的解析单元、获批问题、证据集合、BGE-M3 编码器、512 个 token 的硬上限和单元级评分。固定窗口和递归重叠方法采用冻结的 64-token 重

叠。在公平上下文条件下，标题路径上下文对所有方法一致应用；只有在上下文本身是被消融变量时例外。无密度变体同时关闭由密度驱动的父块长度选择；无连续性变体仍保留受保护组完整性，防止其通过生成结构无效的父块获利。

正式运行程序拒绝临时标签、未解析证据以及缺少允许性人工隐私判定的问题。程序记录 Python 和各软件包版本、命令行、方法参数、语料库与标注哈希，以及分块和评估实现的哈希。不同方法之间会清除嵌入缓存。全部 10 个项目都必须通过就绪审计后，锁定结果才会发布。这些控制不能消除抽样不确定性，但能防止测试集提前暴露、数据被意外替换，或方法专属预处理在未被发现的情况下改变比较结果。

V. 结果

A. 检索与边界质量

表 II 给出锁定测试结果。SEAC 的单元 MRR 为 0.7937，Hit@5 为 0.9520。最强的非 SEAC 检索基线是仅结构方法，其 MRR 为 0.7290，观测绝对差异为 0.0647。SEAC 的文本范围 MRR 为 0.8561。与预先指定的 LlamaIndex 比较器相比，项目配对 MRR 差异为 0.1003，bootstrap 区间为 [0.0042, 0.2008]，精确双侧检验 $p = 0.0625$。SEAC 在 6 个检索项目中的 5 个上表现更高，但在 0.05 水平下不能拒绝验证性原假设。

表 II. 锁定测试结果

方法	单元 MRR	Hit@5	文本范围 MRR	边界 F1
固定窗口	0.5158	0.7200	0.1350	0.0000
递归分割	0.6086	0.8080	0.7072	0.0369
仅结构	0.7290	0.8880	0.8211	0.5032
语义分割	0.6999	0.8640	0.8121	0.3843
LangChain	0.6460	0.8480	0.7329	0.0054
LlamaIndex	0.6934	0.8880	0.7586	0.0920
SEAC 父块	0.6796	0.8800	0.7770	0.5673
完整 SEAC	0.7937	0.9520	0.8561	0.5673

SEAC 的边界精确率为 0.4321，召回率为 0.8255，F1 为 0.5673，区间为 [0.4708, 0.6488]。最强的非 SEAC 边界基线是仅结构方法，F1 为 0.5032。配对 F1 差异为 0.0640，区间为 [0.0313, 0.0956]，但经 Holm 校正后的 p 值为 0.4375。较高召回率和中等精确率表明，SEAC 倾向于保持结构连贯的切分，但代价是产生更多边界。

B. 消融与成本

表 III 避免只呈现有利的组件结论。移除表格行子块造成最大的观测性能下降：MRR 降低 0.1084，Hit@5 从 0.9520 降至 0.8640。然而，该比较经 Holm 校正后的次要检验 p 值为 1.0000。移除语义距离后，MRR 在小数点后四位以内几乎不变；移除父块融合后，MRR 反而升至 0.8289。移除标题上下文也会提高 MRR，尽管 Hit@5 降至 0.9280。因此，在本基准中，行级证据具有明显作用，但固定父块融合和标题前缀并不具有普遍受支持的收益。

表 III. 单组件消融结果

变体	单元 MRR	Hit@5	相对完整模型变化
完整 SEAC	0.7937	0.9520	0.0000
无语义距离	0.7937	0.9520	0.0000
无密度变化	0.7959	0.9520	+0.0021
无连续性惩罚	0.7979	0.9520	+0.0042
固定阈值	0.7959	0.9520	+0.0022
无标题上下文	0.8129	0.9280	+0.0192
无表格行子块	0.6853	0.8640	-0.1084
无父块融合	0.8289	0.9520	+0.0352

SEAC 共生成 8,746 个父块和 48,912 个检索向量，向量数量是仅结构方法的 5.50 倍。在汇总的锁定集上，分块和索引分别耗时 112.11 s 和 351.12 s。平均查询延迟为 20.93 ms，而仅结构方法为 15.18 ms，增加 5.74 ms。这

体现了明确的“可审计性—质量—成本”权衡，而不是无需代价的提升。

C. 项目级不确定性的解释

SEAC 单元 MRR 的 bootstrap 区间为 [0.7060, 0.8772]。该区间同时反映项目和问题层面的变化，而精确配对检验只有 6 个独立项目符号，因此 p 值只能落在较粗的离散网格上。SEAC 在 6 个项目中的 5 个上取得优势，且配对区间为正，这些结果具有鼓舞性；但 $p = 0.0625$ 仍高于预先设定的阈值。因此，我们保留“验证结果尚无定论”的表述，不把它重新解释为显著，也不在观察数据后更换比较器。

边界结果具有相同的聚类限制。SEAC 在全部 6 个边界合格项目上均高于仅结构方法，但该比较属于包含 14 项检验的次要检验族，经 Holm 校正后的 $p = 0.4375$。这说明汇总候选数量不能替代独立部署：一个项目中的数千个边界，并不等同于数千次项目级重复实验。

VI. 讨论与局限

结果支持一个有限结论：在异构企业文档中，保留表格结构和显式来源谱系能够改善观测到的证据检索效果。单元级指标与文本范围指标回答的是不同审计问题。文本范围匹配说明相关文字出现过；单元匹配说明这些文字来自获批的来源位置。当需求在方案和规范之间复制，或多个表格行具有相同词汇时，这一区别尤其重要。

在运行治理方面，返回的来源谱系可以支持人工审查、事故日志和引用展示。部署系统应随每个答案保存语料库版本，展示触发检索的证据而不隐藏父块上下文，并使授权失败与检索未命中能够被区分。方法参数应在明确的验证协议下调整，而不是针对生产投诉逐项调参。这些控制是 SEAC 的确定性输出所支持的流程建议；本文并未把它们作为面向用户的治理结果进行评估。

SEAC 也是一个透明组件，而不是端到端安全保证。本研究没有测量生成答案的忠实度、对抗性提示、访问控制执行或隐私泄漏。保密输入仍由外部授权和发布门控保护。原始语料库不能公开；匿名工件可以包含代码、冻结配置、模式定义、合成示例、哈希和聚合分析。是否允许受控访问其他工件，取决于数据所有者批准。

有效性受以下因素限制：数据仅来自一个工业环境中的 10 个项目；每个评估轴只有 6 个合格项目簇；文档为中文；仅使用一个嵌入模型；并且不支持以图像为主的文件。混合边界参考中包含模型预标注，尽管每一行都记录了标签来源，并排除了低一致性的 P08。本文披露了对 3 类噪声标签所做的事后澄清，并同时保留澄清前后的标注一致性结果。最后，较高 MRR 未达到验证性显著水平，且父块融合消融结果为负，这两点都说明应在更多独立项目上继续评估，而不能声称 SEAC 具有普遍优越性。

在广泛部署前，组件设计也应进一步简化。表格行子块显示出清晰的观测作用，但固定父块融合增加了向量数量，却没有提高本次锁定 MRR；标题前缀还可能让通用章节名称获得过高权重。后续的成本感知方法应保留行级溯源，同时通过学习或验证确定何时使用父块得分和标题上下文。这样的后续方法必须使用新的冻结测试集；若根据当前结果修改系统，就会把锁定评估转化为开发证据。

VII. 结论

SEAC 将携带溯源信息的单元、受保护结构、透明边界信号和行级子块结合起来，用于可审计企业 RAG。在锁定研究中，SEAC 的单元 MRR 为 0.7937，Hit@5 为 0.9520；相对 LlamaIndex 的验证性优势虽可观察到，但未达到统计显著水平。表格行子块是最明确的有效组件，而父块融合和标题上下文需要重新设计。未来工作应在独立锁定项目下评估端到端答案忠实度、对抗鲁棒性、多语言公开语料库以及学习式成本感知融合。

致谢

为满足双盲审稿要求，资助信息和可能暴露身份的致谢内容暂不披露。如第 IV-B 节所述，本研究使用 Anthropic Claude Opus 5 Thinking 作为有记录的边界预标注工具。OpenAI Codex 协助代码起草、测试生成、论文结构组织和语言编辑。人工审查者覆盖实验预标注结

果，核验分析和文本，并对全部研究工作与发表决定承担最终责任。

参考文献

[1] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, H. Kuttler, M. Lewis, W. Yih, T. Rocktaschel, S. Riedel, and D. Kiela, "Retrieval-augmented generation for knowledge-intensive NLP tasks," in Advances in Neural Information Processing Systems, vol. 33, 2020.

[2] V. Karpukhin, B. Oguz, S. Min, P. Lewis, L. Wu, S. Edunov, D. Chen, and W. Yih, "Dense passage retrieval for open-domain question answering," in Proc. EMNLP, 2020, pp. 6769-6781.

[3] J. Chen, S. Xiao, P. Zhang, K. Luo, D. Lian, and Z. Liu, "M3-Embedding: Multi-linguality, multi-functionality, multi-granularity text embeddings through self-knowledge distillation," in Findings of ACL, 2024, pp. 2318-2335.

[4] T. Chen, H. Wang, S. Chen, W. Yu, K. Ma, X. Zhao, H. Zhang, and D. Yu, "Dense X retrieval: What retrieval granularity should we use?" in Proc. EMNLP, 2024, pp. 15159-15177.

[5] X. Wang et al., "Searching for best practices in retrieval-augmented generation," in Proc. EMNLP, 2024, pp. 17716-17736.

[6] Z. Wang et al., "Document segmentation matters for retrieval-augmented generation," in Findings of ACL, 2025, pp. 8063-8075.

[7] J. Zhao et al., "MoC: Mixtures of text chunking learners for retrieval-augmented generation system," in Proc. ACL, 2025, pp. 5172-5189.

[8] P. Sarthi, S. Abdullah, A. Tuli, S. Khanna, A. Goldie, and C. D. Manning, "RAPTOR: Recursive abstractive processing for tree-organized retrieval," in Proc. ICLR, 2024.

[9] C. Auer et al., "Docling technical report," arXiv:2408.09869, 2024.

[10] J. L. C. Guo, J. Steghofer, A. Vogelsang, and J. Cleland-Huang, "Natural language processing for requirements traceability," arXiv:2405.10845, 2024.

[11] S. J. Ali, V. Naganathan, and D. Bork, "Establishing traceability between natural language requirements and software artifacts by combining RAG and LLMs," in Conceptual Modeling, 2024, pp. 295-314.

[12] N. F. Liu, K. Lin, J. Hewitt, A. Paranjape, M. Bevilacqua, F. Petroni, and P. Liang, "Lost in the middle: How language models use long contexts," Trans. Assoc. Comput. Linguistics, vol. 12, pp. 157-173, 2024.

[13] J. Cohen, "A coefficient of agreement for nominal scales," Educ. Psychol. Meas., vol. 20, no. 1, pp. 37-46, 1960.

[14] B. Efron, "Bootstrap methods: Another look at the jackknife," Ann. Stat., vol. 7, no. 1, pp. 1-26, 1979.

[15] S. Holm, "A simple sequentially rejective multiple test procedure," Scand. J. Stat., vol. 6, no. 2, pp. 65-70, 1979.

[16] LangChain, "RecursiveCharacterTextSplitter, langchain-text-splitters 1.1.2," 2026. [Online]. Available: https://pypi.org/project/langchain-text-splitters/1.1.2/

[17] LlamaIndex, "SentenceSplitter, llama-index-core 0.14.23," 2026. [Online]. Available: https://pypi.org/project/llama-index-core/0.14.23/