分类号：TP391　　单位代码：11057
密　级：公开　　学　　号：222201855082

浙江科技大學
ZHEJIANG UNIVERSITY OF SCIENCE & TECHNOLOGY

硕士学位论文

论文题目：基于 YOLO-SAD 的汽车十字轴轴颈缺陷检测算法研究

作　　者　申航宇
指导教师　祝邦文、曹丽丽
学科专业　机械
二级学院　机械与能源工程学院

提交日期　2024 年　12 月　5 日

中国知网　https://www.cnki.net

A Thesis Submitted to
Zhejiang University of Science and Technology for
Master's Degree

Research on automobile cross shaft journal defect detection algorithm based on YOLO-SAD

Candidate: Hangyu Shen

Supervisor: Bangwen Zhu/Lili Cao

Zhejiang University of Science and Technology

Hangzhou China

December 2024

中国知网 https://www.cnki.net

浙江科技大學
ZHEJIANG UNIVERSITY OF SCIENCE & TECHNOLOGY

基于 YOLO-SAD 的汽车十字轴轴颈缺陷检测算法研究

论文作者签名:_____

指导教师签名:_____

论文评阅人 1：_____

评阅人 2：_____

评阅人 3：_____

评阅人 4：_____

评阅人 5：_____

答辩委员会主席：顾大强\教授\浙江大学

委员 1：朱旭升\高级工程师\杭州东城电子有限公司

委员 2：马红萍\教授\浙江科技大学

委员 3：袁斌\副教授\浙江科技大学

委员 4：张敬强\副教授\浙江科技大学

委员 5：曹丽丽\讲师\浙江科技大学

答辩日期：2024 年 12 月 5 日

中国知网 https://www.cnki.net

摘　要

万向节十字轴作为汽车底盘传动系统中万向传动装置的关键零部件，其性能和可靠性对整个车辆的运行和驾驶体验尤为重要。但受生产过程中撞击、挤压、摩擦等因素影响，其轴颈表面会出现划痕、锈斑等缺陷。这些缺陷会在汽车行驶过程中扩大，降低自身的疲劳寿命，在某些情况下甚至会出现十字轴断裂的情况，极大地威胁了乘客的安全。因此，对十字轴表面缺陷检测存在必要性。传统的人工检测算法效率低的同时主观性强。但是随着汽车需求量的提高，提高生产环境下缺陷检测的效率和准确率成为了当下需要解决的问题。针对这一情况，基于深度学习技术，本文开展了对生产线中万向节十字轴表面缺陷检测技术的研究。

（1）针对当前十字轴轴颈公开数据集缺乏的现状，本文设计了图像采集程序。同时，根据表面缺陷的种类，建立了十字轴轴颈特征检测数据集。

（2）针对十字轴轴颈表面缺陷尺度差异大、背景复杂和小目标缺陷特征提取困难等问题，提出了基于 YOLOv8n 的 YOLO-SAD 算法。首先在特征提取阶段，使用 SPD-Conv 代替传统的下采样方式，能够保留通道维度中的信息，从而提高对小目标缺陷的检测能力；在特征融合阶段，设计了聚合传播特征金字塔网络，减少了多层次特征融合过程中信息的丢失，有助于深层语义和细粒度信息的高效传播；设计了 DyHead-DCNv4 检测头，用于识别特征融合部分融合的多尺度目标信息，增强对尺度、空间位置和任务的感知能力，进一步提升目标检测的精度和鲁棒性。实验结果表明，相比于传统的 YOLOv8n，改进后的算法 mAP@.5 提升了 3.8 个百分点，检测速度为 185 帧/秒，满足实时场景检测任务的需求。

（3）针对工业数据集在某些情况下标注数据较难获得的问题，本文提出基于 YOLOv8 的十字轴轴颈半监督缺陷检测方法。为了从大量无标签数据中获取信息，引入师生模型，对无标签数据生成伪标签，变相的增加了标注数据的数量。使用双阈值法替换单阈值筛选，将伪标签分类为可靠、不确定与不可靠三种标签，降低了低质量伪标签对网络训练的负面影响；同时针对三种伪标签优化了损失函数，以提取不同伪标签的潜在信息。结果表明，相比于 YOLOv8 原模型，本文所提出的方法分别在标记数据占比 5%，10%以及 20%的情况下，mAP@.5 提升了 1.4、1.4 以及 1.9 个百分点，有效地降低了对标注数据的依赖。

关键词：深度学习，目标检测，半监督学习，YOLOv8，师生模型

中国知网 https://www.cnki.net

ABSTRACT

As a key component of the universal transmission device in the chassis transmission system of the automobile, the performance and reliability of the universal joint cross shaft are particularly important to the operation and driving experience of the entire vehicle. However, due to the impact, extrusion, friction and other factors during the production process, scratches, rust spots and other defects will appear on the surface of the journal. These defects will expand during the driving of the car, reducing its fatigue life. In some cases, the cross shaft may even break, which greatly threatens the safety of passengers. Therefore, it is necessary to detect surface defects of the cross shaft. Traditional manual detection algorithms are inefficient and highly subjective. However, with the increase in demand for automobiles, improving the efficiency and accuracy of defect detection in the production environment has become a problem that needs to be solved at present. In response to this situation, based on deep learning technology, this paper conducts research on the surface defect detection technology of the universal joint cross shaft production line.

（1）In view of the current lack of public datasets for cross-shaft journals, this paper designs an image acquisition program. At the same time, a cross-shaft journal feature detection dataset is established based on the types of surface defects.

（2）In order to solve the problems of large scale differences of cross-shaft journal surface defects, complex background and difficulty in extracting features of small target defects, a YOLO-SAD algorithm based on YOLOv8n is proposed. First, in the feature extraction stage, SPD-Conv is used instead of the traditional downsampling method to retain the information in the channel dimension, thereby improving the detection ability of small target defects; in the feature fusion stage, an aggregate propagation feature pyramid network is designed to reduce the loss of information in the multi-level feature fusion process, which is conducive to the efficient propagation of deep semantics and fine-grained information; the DyHead-DCNv4 detection head is designed to identify multi-scale target information fused in the feature fusion part, enhance the perception of scale, spatial position and task, and further improve the accuracy and robustness of target detection. Experimental results show that compared with the traditional YOLOv8n, the improved algorithm has an increase of 3.8 percentage points in mAP@.5 and a

中国知网 https://www.cnki.net

detection speed of 185 frames/second, which meets the requirements of real-time scene detection tasks.

（3）Aiming at the problem that labeled data is difficult to obtain in some cases of industrial data sets, this paper proposes a semi-supervised defect detection method for cross-axle journals based on YOLOv8. In order to obtain information from a large amount of unlabeled data, the teacher-student model is introduced to generate pseudo labels for unlabeled data, which increases the amount of labeled data in disguise. The double threshold method is used to replace the single threshold screening, and the pseudo labels are classified into three types: reliable, uncertain and unreliable, which reduces the negative impact of low-quality pseudo labels on network training; at the same time, the loss function is optimized for the three pseudo labels to extract the potential information of different pseudo labels. The results show that compared with the original YOLOv8 model, the method proposed in this paper improves mAP@.5 by 1.4, 1.4 and 1.9 percentage points when the labeled data accounts for 5%, 10% and 20% respectively, effectively reducing the dependence on labeled data.

Key Words: deep Learning, object detection, semi-supervised learning, YOLOv8, teacher-student model

中国知网 https://www.cnki.net

目 录

第 1 章 引言.....1
1.1 研究背景及意义.....1
1.2 国内外研究现状.....2
1.2.1 目标检测算法研究现状.....2
1.2.2 半监督算法研究现状.....6
1.2.3 汽车十字轴缺陷研究现状.....7
1.3 本文的研究内容.....8
1.4 论文研究内容与章节安排.....9
第 2 章 基于 YOLOv8 改进算法的十字轴轴颈缺陷检测.....10
2.1 YOLOv8 目标检测算法介绍.....10
2.2 改进的 YOLOv8 算法.....11
2.2.1 引入 SPD-Conv 模块.....12
2.2.2 设计并提出 APFPN 聚合传播特征金字塔.....14
2.2.3 设计 Dyhead-DCNv4.....17
2.3 实验结果与分析.....21
2.3.1 网络模型的实验环境.....21
2.3.2 评价指标.....22
2.3.3 Focus Feature 不同深度卷积核的性能对比.....24
2.3.4 不同数量的 DyHead-DCNv4 模块相串联的性能对比.....25
2.3.5 Dyhead-DCNv4 与 Dyhead-DCNv3 性能对比.....25
2.3.6 消融实验与结果分析.....26
2.3.7 不同算法之间的对比实验.....29
2.3.8 可视化实验.....30
2.4 本章小结.....32
第 3 章 基于半监督学习的十字轴轴颈缺陷检测.....32
3.1 引言.....32
3.2 算法设计与实现.....33
3.2.1 引入师生模型.....33
3.2.2 伪标签阈值扩展.....34
3.2.3 损失函数优化.....35
3.3 实验结果以及分析.....36
3.3.1 数据集划分.....36
3.3.2 实验环境和超参数设置.....37
3.3.3 少量标注数据下 YOLO-SAD 与 YOLOv8 结果对比.....38

中国知网 https://www.cnki.net

3.3.4 消融实验分析.....38
3.3.5 不同半监督目标检测算法比较.....39
3.4 可视化效果.....40
3.5 本章小结.....41
第 4 章 图像采集平台搭建.....41
4.1 引言.....41
4.2 实验平台搭建.....42
4.2.1 相机选型.....42
4.2.2 镜头选型.....44
4.2.3 光源选择.....45
4.2.4 整体硬件平台设计.....45
4.3 软件平台搭建.....46
4.4 缺陷类别定义以及数据处理.....47
4.4.1 缺陷类别定义.....47
4.4.2 数据处理.....48
4.5 本章小结.....50
第 5 章 总结与展望.....52
5.1 总结.....52
5.2 展望.....53
参考文献.....54

中国知网 https://www.cnki.net

第 1 章 引言

1.1 研究背景及意义

传动系统是汽车关键部分，负责将发动机动力传输至驱动桥使车轮旋转。驾驶中的颠簸、转速及转向变化要求传动系统能多向传递功率和扭矩，万向传动节因此成为核心[1]。万向节种类多样，按结构分为十字轴式、球笼式、球叉式等，其中十字轴式最为常用，因其结构简单、可靠且高效。球笼式以紧凑结构和等速传动性能著称，球叉式则结构简单、成本低。选择合适的万向节对确保汽车稳定性和性能至关重要。而由于生产工艺和生产设备的复杂性，在生产过程中可能会出现撞击、挤压、摩擦等一系列情况，十字轴轴颈表面常常出现划痕、锈斑、缺肉等各种缺陷，这些缺陷不仅影响着十字轴的外观，同时随着汽车运动中的损耗，这些缺陷可能会导致万向节断裂，影响着整个系统的稳定性。因此，在质检过程中如何高效的检测出缺陷成为了一个亟待解决的实际问题。



图 1-1 工业汽车十字轴示意图

目前我国大多数企业针对十字轴轴颈的缺陷检测多使用人工检测法和半自动机械检测法。人工检测法指工人通过对流水线上经过的工件进行肉眼识别。这种方法不仅成本高、效率不高且实时性较差。同时在肉眼检查过程中容易发生漏检现象。伴随着生产量的增长，工厂对于产品的检测速度和准确度要求越来越高，人工目检法不再能满足实际需求。半自动机械检测法则是使用红外光谱、涡流、

中国知网 https://www.cnki.net

漏磁等特定传感器在流水线上进行工件的间接检测，结合实际数据变化推算出传感器数据与缺陷种类的对应关系。这在一定程度上提高了检测效率，同时检测精度也得到的提升，但是由于工业环境复杂，不同传感器需要提供不同的专用环境，其在许多行业和生产现场都具有局限性，难以满足环境、成本等要求。随着生产效率以及质量要求的提高，这些方法已经无法达到生产节奏的要求，因此如何利用信息技术代替传统方法成为了企业的首要任务。

近年来，受益于深度学习(Deep Learning，DL)的发展，计算机视觉算法也得到了长足的进步[2]。工业生产环境中，通常使用工业相机来对工件进行拍摄，然后使用计算机来对图像进行二次处理从而检测出缺陷的位置以及缺陷的种类。随着深度学习的发展，检测的精度和速度达到了买上了一个新的台阶，为表面缺陷检测提供了强有力的技术保证。

在工业生产过程中，尽管生产机器技术已经相当完备，但获取大量有标注的缺陷图片却成为了一项挑战。这是因为在实际操作中，标注缺陷图片需要专业知识和经验，而工厂工人往往不具备这些条件，因此难以对缺陷数据进行准确标注。此外，由于标注数据的稀缺性，深度学习模型的学习能力也会受到影响，导致其性能下降。为了应对这一难题，半监督学习（Semi-supervised Learning，SSL）[3-4]方法应运而生。这种方法通过结合少量有标签数据和大量无标签数据，旨在达到甚至超越监督学习的精度。本文深入研究了在缺少大量标注数据的情境下，十字轴轴颈缺陷检测的相关算法，旨在解决这一实际生产环境下的重要难题。通过这一研究，我们为传统的汽车零部件企业提供了产业升级、提高产品质量和控制生产成本的重要解决方案，具有重要的实践意义和理论价值。

1.2 国内外研究现状

1.2.1 目标检测算法研究现状

在复杂的工业生产过程中，产品可能会遭遇各种故障和缺陷，例如孔洞、划痕、磨损等。不良的工作条件以及设计和机械制造设备故障是造成这些缺陷的原因。产品的缺陷不仅使企业的成本增高，更可能危机人们的健康和安全。因此，对当前工业来说，生产过后的缺陷检测是必要的。

原始的缺陷检测主要分为人工检测和半自动机械检测。人工检测指检测人员依靠人眼来判断缺陷的存在。这种方法不仅耗费大量人力，并且效率低下且主观

中国知网 https://www.cnki.net

性较高。已经不适用于当前的生产环境。而半自动机械检测是指利用磁化现象[5]或电子感应原理[6]等物理手段对缺陷进行检测。这种方法对工件形状、材料都存在要求，并且适用的缺陷具有局限性。相比于人工检测，因其检测速度较快，成本较低，目前依旧是工业生产中表面缺陷的首选方法[7]。

半自动机械检测法通常包括涡流检测、红外检测以及漏磁检测等。法国洛林连轧公司提出利用涡流探伤设备 EDISOL[8]应用于热连轧铸板坯生产线的板坯裂纹缺陷检测。挪威的 Elkem[9]公司研发了第一条红外检测设备 Therm-o-matic 用来检测带钢表面的缺陷。该方法需要建立材料属性、环境干扰、电流运行参数、感应线圈参数等多种变量与缺陷温度变化之间的联系，因此其检测稳定性较低，对检测环境要求较高，导致可使用范围受限。

随着计算机技术的发展，基于深度学习的缺陷检测算法取得了令人印象深刻的成果。当前基于深度学习的目标检测算法根据过程分为两类，即两阶段目标检测算法和单阶段目标检测算法。图 1-2 展示了目标检测算法的发展路线。

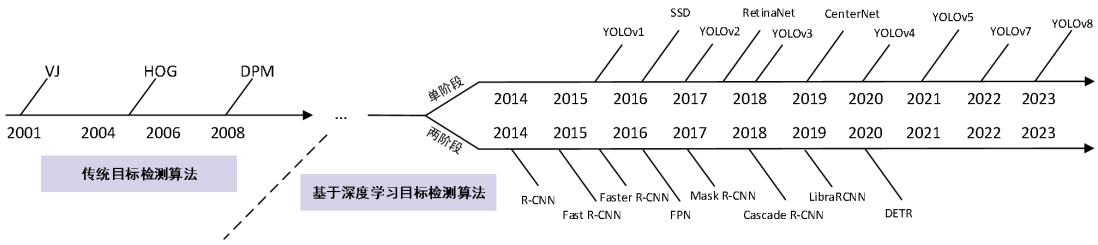


图 1-2 目标检测算法的发展路线

两阶段目标检测算法首先从图像中生成候选区域，随后对这些候选区域进行目标分类和位置定位。这个过程分包含两个独立的步骤，第一步是生成候选区域，第二步则包括目标分类和位置回归等操作来进一步处理候选区域。代表性算法有 R-CNN、Faster R-CNN 等。

2014 年，Girshick 等[10]提出了使用深度学习进行目标检测的网络模型 R-CNN。与传统的目标检测算法，R-CNN 的主要改进点主要有以下三点：(1) 区域建议阶段，算法采用了选择性搜索网络，这种方法解决了传统目标检测算法中使用滑动窗口生成候选框时计算量过大的问题。(2) 使用 CNN 对图像中的区域进行特征提取，解决了传统目标检测方法中特征表达能力不足的问题。(3) 算法结合 SVM 分类器，使用回归算法对目标边界进行补偿和修正，从而减少感兴趣区域与实际

中国知网 https://www.cnki.net

目标之间的差异，提高了目标检测的准确性。R-CNN 在对输入图像进行分割后，会对每个分割后的区域执行卷积操作，然而这些区域存在这或多或少的重叠，因而会产生许多重复的无效计算。

为了提高模型的计算效率和性能，Fast R-CNN[11]和 Faster R-CNN[12]在 R-CNN 的基础上进行了相应的改进，分别引入感兴趣区域池化层（Region of Interest Pooling，RoI Pooling）以及区域建议网络（Region Proposal Network，RPN）来改进候选区域生成的过程，使得整个流程更加高效和端到端。并且 Faster R-CNN 极大地推动了目标检测的发展，为后续的检测算法提供了重要的理论基础。

两阶段目标检测算法包含两个步骤：首先生成感兴趣的候选区域，然后对这些候选区域进行分类和位置回归。这就导致网络计算量较大，检测速度比较慢，难以满足实际场景中实时检测的需求。为了解决这些问题，单阶段目标检测算法应允而生，其主要以 YOLO 系列算法、SSD 算法为主。

2016 年，Redmon 等提出了首个基于回归分析的目标检测算法 YOLO[13]（You Only Look Once）。算法摒弃了选取候选框的操作，直接采用回归的方法对目标对象进行分类和位置定位，是连接端到端的目标检测。YOLO 首先将输入图片划分为 S×S 个网格。对于每个网格，算法生成 B 个检测框。每个网格负责预测中心位置恰好落在网格之内的待检测目标的位置和类别。对于 C 个可预测的类别，YOLO 输出为一个 S×S×(B×5+C)的向量。其中，S×S 为划分为网格的数量，*B* 为每个网格所要预测的 bounding box 的数量，5 表示对于格子内的每个 bounding box，都要预测 5 个值，即 bounding box 的四个坐标属性和置信度。相比于两阶段模型，YOLO 在检测速度上有了巨大提升。

同年，Liu 等提出了 SSD[14]（Single Shot Multi-box Detector），一种高效的单阶段目标检测算法，因其能够同时预测目标的类别和位置，且具备较高的检测速度，常被应用于实时场景。SSD 的主要优势在于其使用了多个不同尺度的特征图，从而提升了对多尺度目标的检测能力。为了应对正负样本的不平衡问题，SSD 采用了 Hard Negative Mining 策略。用于检测过程中产生的负样本远多于正样本，SSD 根据置信度对负样本排序，然后只选择那些误差较大的负样本参与训练，通常会按照正负样本（如 1:3）进行筛选。这种方法减少了大量容易分类的负样本的影响，确保模型更加专注于困难的负样本和少量的正样本，从而提升检测精度。

中国知网 https://www.cnki.net

2017 年，Redmon 提出了 YOLO9000[15]，即 YOLOv2 算法，相比于 YOLOv1，YOLOv2 的改进如要有以下几点（1）采用 Darknet-19 作为特征提取网络，使用 BN（Batch Normalization）[16]来代替 Dropout 层，并添加在每个卷积层后面，这个改进一定程度上提升了模型的收敛速度，同时减少了过拟合的情况，（2）相比于 Faster R-CNN 人工预设的 anchors，YOLOv2 使用 K-Means[17]聚类算法自动寻找尺寸合适的 anchor。同时，为了限制预测框出现的位置，YOLO 预测框的位置预测延续了 YOLOv1 中的方式，而宽高则采用相同的指数形式。YOLOv2 有着更快的检测速度和检测精度。

YOLOv3[18]是 Remon 等继续对 YOLO 系列算法的升级。首先将骨干网络中的 Darknet19 升级为 Darknet53，牺牲了少量速度的同时大大提高了检测精度。其次，引入了特征金字塔网络[19]（Feature Pyramid Networks，FPN），采用多尺度的特征融合进行目标检测，有效融合了不同层级的特征信息，使得网络对各种尺寸的目标都有更好的检测能力。

随后 YOLO 又进行了多个版本的更迭，在不同方面提升了检测精度和检测速度。当前，YOLO 系列最成熟的版本是 YOLOv8，由 Ultralytics 开发的模型，该框架目前支持图像分类、物体检测以及实例分割任务，且是一个兼容 YOLO 历史版本的框架，是开发者能够自由切换并进行实验对比。此外，该框架引入了新的功能，进一步提升了模型的性能和灵活性。因此，本文将其作为基线算法并对其改进。

基于深度学习目标检测算法的表现优异，让其在表面检测领域有着广泛的应用。Chen[20]等人提出在 Faster R-CNN 引入可变性卷积以及特征金字塔网络（Feature Pyramid Network，FPN）网络以提高对铝合金表面小目标缺陷的提取能力，然而优化后的模型对缺陷的检测能力仍然较弱，并且对于不明显的缺陷呈现低召回率。同样针对 Faster R-CNN 效率低的问题，Deng[21]在发动机缸体水道检测任务中引入 Faster R-CNN 的同时，使用 kmeans+聚类算法以优化锚框，提高了目标框的定位能力，相比传统 Faster R-CNN 模型 mAP 提高了 4%。而为了改进检测模型对于多尺度缺陷效果不明显的问题，Guo 等人[22]将单阶段目标检测框架 YOLOv5 应用到钢材表面缺陷检测任务中，并通过在骨干网络和检测头中引入基于 Transformer 设计的 TRANS 模块，增强了检测器对不同尺度物体的动态调整能力，mAP 达到了 75.2%，相比于 YOLOv5 提高了 7%。Li 等人[23]将 SSD

中国知网 https://www.cnki.net

应用到灌装线上容器密封面的缺陷检测任务中，提出将 Mobile-Net 与 SSD 相结合，该方法能够更准确，更快速的自动检测表面缺陷。同样的，张凯等人将 Mobile-Net v3[24]与 YOLOv4 结合并应用到发电机定子表面检测任务中，mAP 达到了 98.3%并且模型体积缩小了 84.5%。

1.2.2 半监督算法研究现状

深度学习以数据为驱动，其性能与标注数据的数量成正相关。如图 1-3 所示，根据数据集中标注的占比，机器学习可以分为三种学习方式：监督学习、半监督学习和无监督学习，监督学习是指使用完全标注的数据集，并对标签进行学习，常用于分类和回归问题。半监督学习则是结合少量标注数据和大量伪标注数据，通过标注数据指导模型学习，再利用未标注数据提升模型的泛化能力。无监督学习只利用未标注数据，目标是发现数据中的隐藏结构，常见于聚类和降维任务。

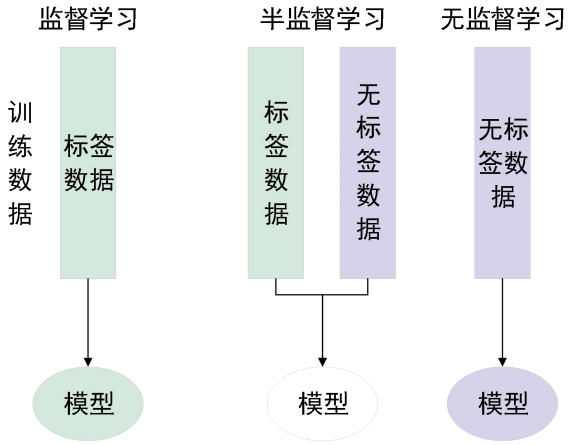


图 1-3 监督学习、半监督学习、无监督学习模型数据组成

半监督学习通过利用伪标签数据的潜在结构信息来提升模型的泛化能力。首先将标记数据放入模型进行学习，然后通过一致性正则化、伪标签等技术迭代优化，最终在未知数据上实现更高的预测精度。相比于传统方法，它解决了工业缺陷图像中标记数据不足的问题。2020 年，Soohn 等人[25]首先将半监督学习方法引入到目标检测领域中，其受半监督图像分类算法以及 FixMatch[26]的启发，提出了 STAC，它无缝的扩展了基于自训练即伪标签和增强驱动的一致性正则化方法。STAC 首先使用所有带标注数据训练教师模型，然后使用通过教师模型来为无标签数据生成伪标签，然后将伪标签数据和有标签数据同时用于学生模型训练。

中国知网 https://www.cnki.net

然而 STAC 依然存在某些问题，即训练不是端到端的，同时，伪标签只在最终训练开始前生成一次，训练过程中不更新，不会随着训练的进行而有所改进。针对这个问题，Zhou 等人[27]提出了 Instant-Teaching 方法，此方法引入了即使反馈机制，通过与教师模型交互快速获取未标注数据的指导信息，从而优化学习效率，同时，Instant-Teaching 还结合多个模型的预测结果，通过集成学习策略提升模型的准确率，降低模型的偏差，提高最终性能。然而，Instant-Teaching 模型主要使用固定的教师模型参数，而学生模型的训练效果对教师的依赖较大，难以在整个训练过程中动态更新教师模型。同时，模型生成的伪标签容易受到数据分布不均衡和伪标签偏差的影响，可能导致学生模型的性能不稳定。针对这些问题，Liu 等人[28]提出了 Unbiased Teacher 方法，在学生教师模型中引入 EMA（Exponential Moving Average），使用学生模型学习结果更新教师模型，这有助于稳定训练，提高泛化能力，减轻所谓的伪标注有偏问题。随后，Xu[29]等人提出了 Soft Teacher，不仅简化了训练过程，还对定位数据的不确定性进行了评估，它将无标签数据的预测结果送进教师模型，并将教师模型产生的分数计算分类损失。同时，Soft Teacher 为了解决分类分支和检测分支预测不一致性的问题，提取通过 Box Jittering 选择可靠的边界框来训练学生模型的定位分支，解决了定位精度和前景分值捆绑问题。Soft Teacher 在 COCO 数据集上获得了 44.5%的 mAP。相对于 SOTA 提升了 3.6%的 mAP。

1.2.3 汽车十字轴缺陷研究现状

传统的汽车零件制造车间一般使用寿命较高，对车间的改造较慢。这造成了车间内缺乏相关的智能设备对其进行检测。大多数汽车零部件制造厂商依然依靠传统的检测方法，即人工识别。相关检测人员通过用肉眼观察的方式来检测工件表面是否有明显的缺陷，而对于某些微小的缺陷则会忽略，这大大提高了相关工件的损坏率。

当前，针对汽车十字轴表面缺陷的相关研究较少。工业视觉检测的目标大部分由金属钢材表面、芯片等构成，而这些工业材料与汽车十字轴表面构成存在着明显差异，即轴表面由曲面和倒角组成。因此，传统的工业视觉检测方法并不适用于十字轴表面检测。孙慧平[30]提出用十字轴夹持器和转向器、工位转换机构以及智能相机来完成对十字轴缺陷的检测以及分选。相比于肉眼检测，提高了检测

中国知网 https://www.cnki.net

效率，但依然达不到实时检测的要求。LI[31]提出用改进的 YOLOv5 算法来对金属轴进行检测，通过引入 CBAM 和 BIFPN 模块，在缺陷数据集上达到了 93.6%的 mAP，然而 FPS 只有 16.7，精度较高但速度不足。淡卫波[32]在 YOLOv5 的基础上提出了结构重参数化的方法，缩小了网络的参数量，并达到了更高的准确率和推理速度。上述算法尽管在准确率和速度上就有提升，但对于十字轴缺陷检测来说仍然存在以下几点问题：

（1）十字轴表面缺陷复杂，缺陷尺度差异较大，而现有的针对十字轴的缺陷检测方法对小目标缺陷的检测能力不足，这会导致准确率较低、漏检率较高的问题。因此，如何在缺陷复杂的情况下提高对小目标缺陷的检测能力是本文的第一目标。

（2）在部分工业环境中，缺陷数据标注困难，标注工作的成本较高，因此，如何利用有限的十字轴缺陷数据集达到训练出高效的且具有鲁棒性的模型是本文的第二目标。

（3）当前十字轴公开数据集缺乏，这样是导致针对汽车十字轴研究较少的原因之一。因此，如何设计一个采集速度快、资源消耗少的采集系统是本文的第三目标。

1.3 本文的研究内容

针对上节所提出的十字轴轴颈缺陷检测当中的诸多问题，本文使用监督算法和半监督算法对生产环境下的十字轴轴颈检测开展研究，主要研究内容包括以下几个方面：

（1） 针对当前汽车十字轴轴颈缺陷数据集缺少的情况，本文与某企业合作，设计并构建了针对生产环境下的汽车十字轴图像采集程序，并构建了多种缺陷的十字轴轴颈缺陷数据集。

（2） 针对十字轴轴颈表面背景复杂，缺陷尺度差异大，小尺度缺陷占比较高的情况，本文设计并提出了基于 YOLOv8 的缺陷检测模型 YOLO-SAD，相比于 YOLOv8，检测准确度提高了 3.8 个百分点，检测速度达到了 185 帧每秒。

（3） 针对生产环境中某些情况下标注数据获取困难的问题，本文引入师生模型

中国知网 https://www.cnki.net

开展半监督十字轴轴颈缺陷检测，同时优化了伪标签阈值筛选策略以及配套的损失函数，实验结果表明了引入策略的有效性。

1.4 论文研究内容与章节安排

本论文主要包括 5 章，具体安排如下：

第一章：对该领域的研究进展以及背景进行分析，分析了基于深度学习的表面缺陷检测和十字轴轴颈检测的发展历程和研究现状，并分析了现有研究面临的挑战，确定本文的主要研究内容。

第二章：基于 YOLO8n 的十字轴轴颈表面缺陷检测改进。本章基于 YOLOv8n，对网络模型的特征提取部分、特征融合部分以及检测头部分分别进行改进，并做出详细的说明。最后对本章改进算法和其他常规的检测算法进行实验对比和结果分析，以此证明本章所提算法对十字轴表面缺陷检测的有效性。

第三章：基于半监督学习的十字轴轴颈表面缺陷检测算法改进。本章首先对引入的师生模型以及伪标签阈值扩展进行了详细的阐述。其次，针对伪标签阈值扩展，进行了损失函数的优化。最后通过实验证明了所提方法的有效性。

第四章：图像采集系统。针对十字轴缺陷公开数据集缺少的情况，本章展示了基于 Vision Master 以及 PLC 的图像采集系统的设计。介绍了系统硬件装置的选择、软件平台搭建以及数据图像的预处理过程。

第五章：总结与展望。对本文所有研究的内容，以及取得的成果进行总结，并对现阶段的不足和下一步要做的工作进行概括，最后对未来工作进行展望

中国知网 https://www.cnki.net

第 2 章　基于 YOLOv8 改进算法的十字轴轴颈缺陷检测

2.1　YOLOv8 目标检测算法介绍

当前，YOLO 系列最成熟的版本是 YOLOv8，由 Ultralytics 开发的模型，该框架目前支持图像分类、物体检测以及实例分割任务，且是一个兼容 YOLO 历史版本的框架，是开发者能够自由切换并进行实验对比。此外，该框架引入了新的功能，进一步提升了模型的性能和灵活性。YOLOv8 主要由输入模块、主干、颈部、头部四部分组成，如图 2-1 所示。

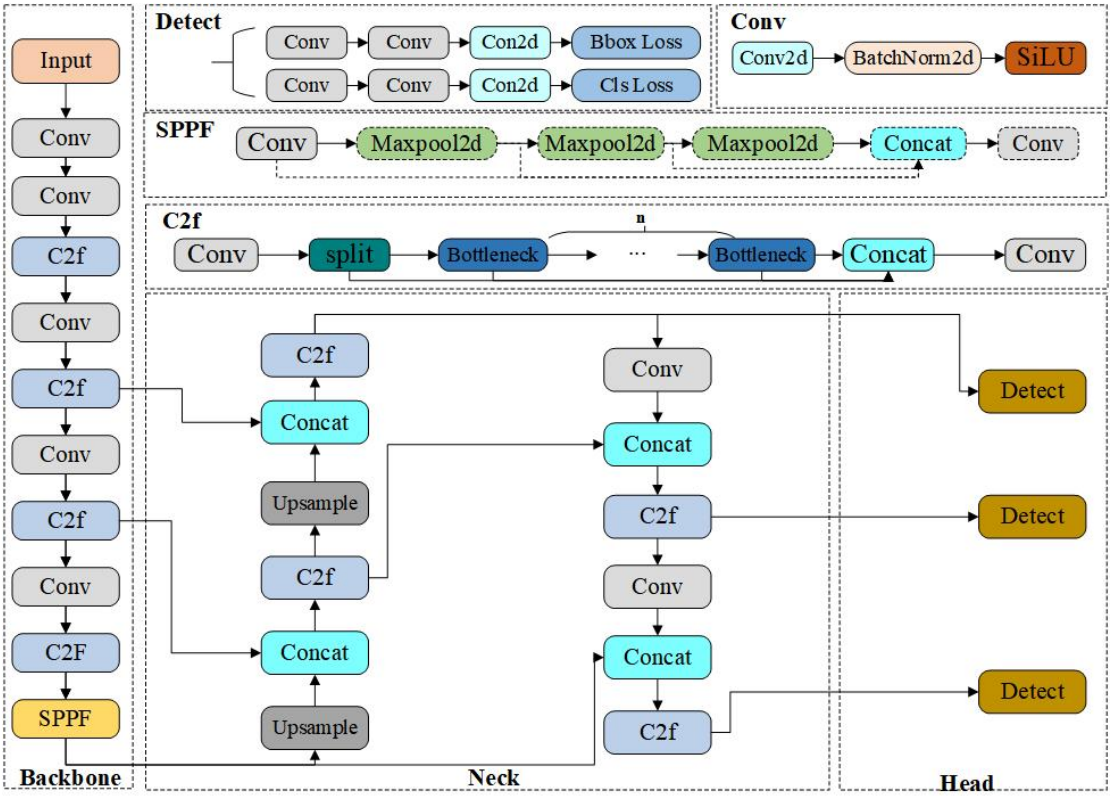


图 2-1　YOLOv8 结构图

输入模块：为了避免数据集中不同的图像存在不同的长度和宽度，YOLOv8 算法对输入图像进行了预处理以适应大小，提升了图像数据处理的效率。使模型减少黑边的增加，输入图像默认的大小为 640×640。除此之外，YOLOv8 还引

中国知网　https://www.cnki.net

用了 Mosaic 数据增强、Copy paste 数据增强、Mix Up 数据增强等数据增强方法，这些方法增强了图像背景的复杂度，并且提高了模型的泛化能力和鲁棒性。

主干网络（backbone）：backbone 的主要作用是提取特征。受 YOLOv5 的启发，YOLOv8 采用 CSPDarkNet53 作为其骨干网络。该骨干网络由 Conv、C2f 以及 SPPF 三个模块组成。Conv 模块由标准卷积 Conv2d, 批量归一化 Batch Normalization（BN）以及 SiLU 激活函数三个功能模块组成。而 C2f 的设计灵感来自于 C3 模块以及 ELAN，使得 YOLOv8 能够在保证轻量化的同时获得更丰富的梯度信息。SPPF 受到 SPPNet 的启发，进行了相应的重设计，通过减少池化核的数量显著提升了计算速度[33]，特别是在移动端或资源受限设备上。

颈部（neck）：neck 主要负责图像浅层细节特征与深层语义特征的融合。YOLOv8 的 neck 部分融合了特征金字塔网络（feature pyramid network，FPN）和路径聚合网络（path aggregation network，PAN）的概念。FPN 将分辨率低、语义信息量大的高层特征和分辨率高、语义信息量小的低层特征进行融合，得到了各个尺度上语义丰富的特征。此外，PAN 提出使用自适应特征池化来加快底层与上层之间的信息流动，提供了自下而上的强局部化特征，在整个特征层次的较低层添加精确的局部化信号，缩短较低层与上层之间的信息路径，并提出一种自适应特征池，可以有效的将有用信息从每个特征传播到子网络[34]。除了用 c2f 模块取代 C3 模块外，YOLOv8 的 neck 部分还省略了 YOLOv5 中 PAN-FPN 上采样阶段的卷积结构。

头部（head）：head 主要负责生成目标检测的输出结果。YOLOv8 的 head 部分采用了目前比较流行的解耦头（decoupled head）结构，同时利用 DFL（Distributional Focal Loss）的思想，将分类头和检测头分离。此外，head 有三个检测层，分别对用从 neck 中得到的三种不同长宽比的 anchor，分别用于对目标进行预测和回归，YOLOv8 算法的 anchor box 对数据集具有自适应性，可以根据不同的数据集自动调整对应的 anchor box。

2.2 改进的 YOLOv8 算法

YOLOv8 提供了 N、S、M、L、X 五种尺度大小不同的模型，根据网络的缩放系数，以适应不同的应用场景和硬件要求。轻量版本的 YOLOv8n 平衡了检测精度以及检测速度，更加适合于工业场景。因此，本文选取 YOLOv8n 作为基础

中国知网 https://www.cnki.net

算法。同时针对十字轴轴颈表面缺陷尺寸大小多样、分布密集、背景复杂等特点，在 YOLOv8n 的基础上建立了一个利于工业实时检测十字轴轴颈缺陷的 YOLO-SAD 算法。在 Backbone 中引入由 SPD 层和非跨步卷积(Non-strided-Conv)组成的 SPD-Conv[35]替换传统的下采样卷积，提升了模型对小尺寸检测的能力；设计了一种新的特征金字塔网络，即 APFPN，将原始特征进行聚合，并通过传播机制使具有丰富上下文信息的特征扩散到各个检测尺度；提出一种新的 DyHead-DCNv4 检测头，在统一框架内整合尺度、空间、任务三种注意力机制，显著地提高了对象检测头的表示能力。YOLO-SAD 算法网络结构如图 2-2 所示。

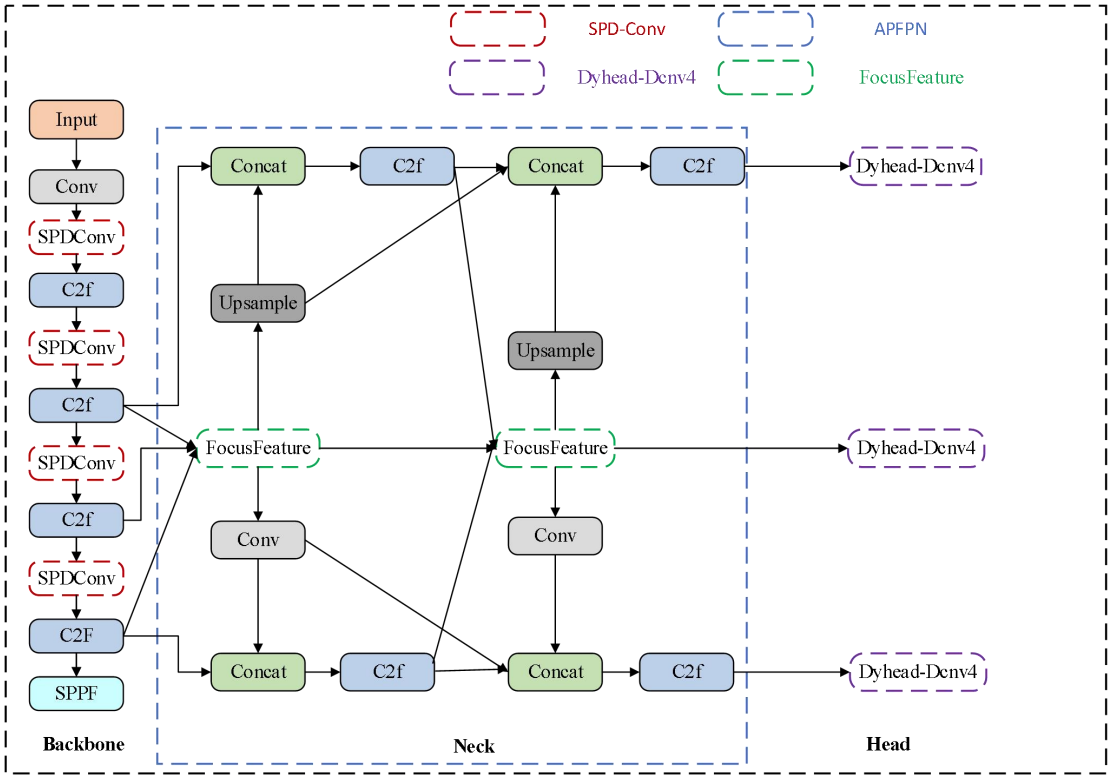


图 2-2　YOLO-SAD 网络结构图

2.2.1　引入 SPD-Conv 模块

在工业缺陷检测任务中，小尺寸的缺陷检测是一项非常具有挑战性的工作，较小的对象意味着本身具有较低的分辨率，低分辨率限制了模型需要学习的上下文信息。传统模型在预测过程中往往更加侧重于大目标，这导致了小目标的检测率显著降低。造成这一现象的主要原因在于卷积神经网络中所采用的跨步卷积和池化操作。尽管在训练输入数据的分辨率与目标尺寸均处于适中状态时，这些操作所忽略的像素信息对模型性能的影响相对较小，但在处理低分辨率小目标数据

中国知网　https://www.cnki.net

时，基于这种设计理念的卷积神经网络会出现细粒度信息丢失的问题，进而导致模型学习到的特征不够充分，从而影响了小目标的检测效果。针对十字轴轴颈缺陷数据集包含磕碰、锈斑、缺肉等缺陷分辨率低，尺寸小的问题，引入 SPD-Conv，用以替代原有卷积网络中的跨步卷积和池化层。SPD 模块由两部分组成：空间深度卷积（Space-To-Depth, SPD）层和 Non-Strided convolution(Conv)层。SPD 层采用了一种独特的原始图像转换技术，通过对特征映射进行下采样，在通道维度上保留了全部信息，确保了信息无损失。这一特性在处理不同大小特征图的拼接或对大特征图进行下采样时尤为重要，因为 SPD 层能够保证不丢失任何特征数据，从而提高了数据处理的准确性和效率。其在处理具有低分辨图像和小物体的任务上，相比传统的深度学习模型具有较好的表现。scale 为 2 的 SPD-Conv 层图 2-3 所示，（a）代表输入特征，（b）-（d）代表空间扩展，（e）代表步长为 1 的普通卷积。对于任意输入的大小为 $S\times S\times C$ 的特征图 X，在通过空间方向和深度方向分解成一系列子特征图 $f_{x,y}$，每个子特征图由公式 2-1 所示：

$$\begin{aligned} f_{0,0} &= X[0:S:scale, 0:S:scale] \\ f_{1,0} &= X[1:S:scale, 0:S:scale] \\ f_{0,1} &= X[0:S:scale, 1:S:scale] \\ f_{1,1} &= X[1:S:scale, 1:S:scale] \end{aligned} \tag{2-1}$$

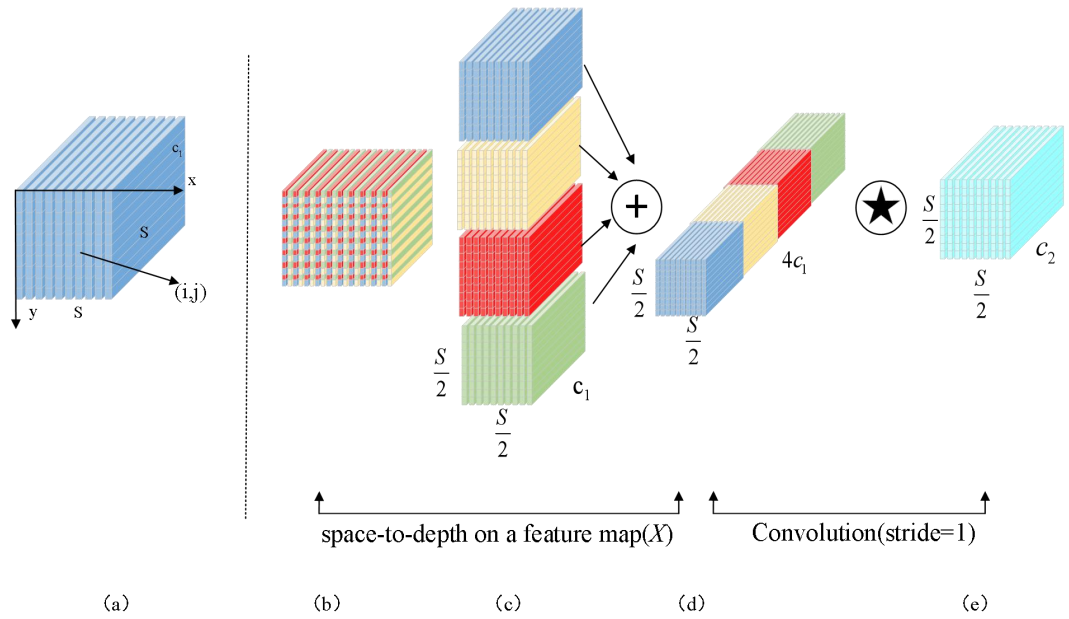


图 2-3　scale 为 2 的 SPD-Conv 层示意图

公式 2-1 的子特征图 $f_{x,y}$ 由 $x(i,j)$ 中所有可按比例 $scale$ 整除的 $i+x$ 和 $i+y$ 组成。

中国知网　https://www.cnki.net

子特征图 $f_{x,y}$ 的大小均为 $(\frac{S}{scale},\frac{S}{scale},C_1)$，由原始特征图下采样得到。当 *scale*=2 是，可以得到四个子特征图 $f_{0,0}$，$f_{1,0}$，$f_{0,1}$，$f_{1,1}$。每个子特征图的大小为 $(\frac{S}{2},\frac{S}{2},C_1)$。将所有子特征图沿通道维度连接，得到空间维度降低 2(*scale*)倍，通道维度增加 4($scale^2$)倍的特征图。最后,(d)-(e)通过一个步长为 1 的卷积层将 X' 转换为最终特征图 $X''(\frac{S}{scale},\frac{S}{scale},C_2)$。虽然使用步长为 2 或 3 的普通卷积也能得到由特征图到 X 的 X'' 转变，但这种转变不会生成中间特征图 X'，从而导致特征信息的丢失。

2.2.2 设计并提出 APFPN 聚合传播特征金字塔

特征金字塔网络的主要任务是将从主干网络中提取的多尺度特征进行有效聚合，这一策略已经被广泛证实对目检测任务具有有效性。传统的 FPN 通过构建一个自上而下的特征金字塔，将高层的强语义特征传递到底层，从而增强整个金字塔的语义信息。然而，FPN 在传递语义信息的同时，对定位信息的传递效果并不理想。PANet 在 FPN 的基础上，添加了一个自下而上的金字塔路径，将底层的定位特征传递到高层，这样，形成的金字塔既包含了丰富的语义信息，又保留了准确的定位信息。尽管如此，在网络运行的过程中，目标特征依然会在跨层传播与交互过程中存在信息丢失或者退化的现象[36]。在这种情况下，针对十字轴轴颈缺陷尺度跨度大，深层语义和细粒度信息利用不充分的问题，本文设计一种聚合传播特征金字塔网络（Aggregate Propagation Feature Pyramid Network, APFPN），其结构图如图 2-4 所示。

中国知网 https://www.cnki.net

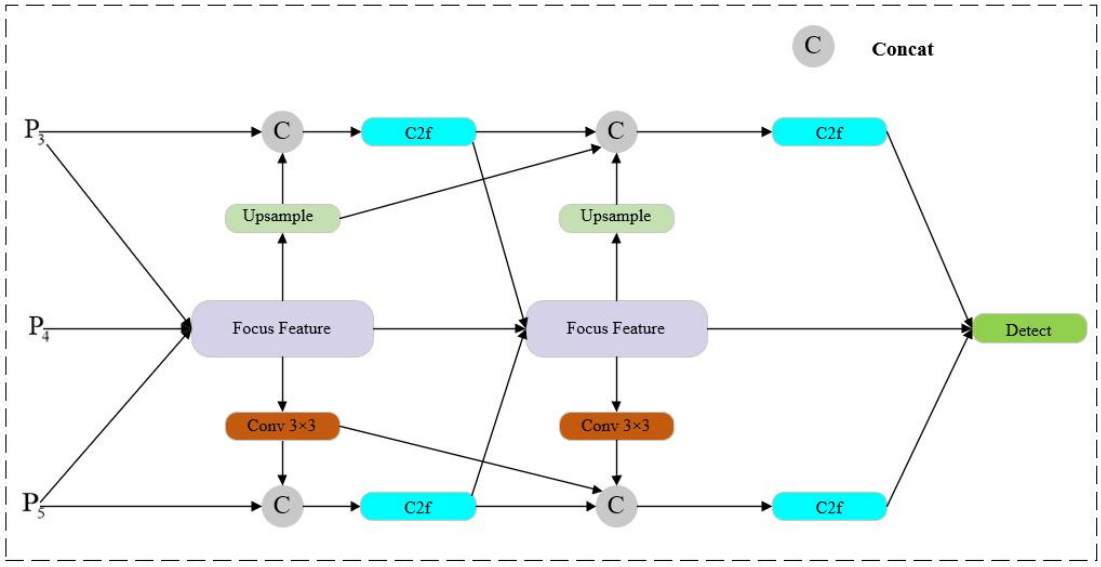


图 2-4　APFPN 网络结构

针对 PANet 在跨层传播时存在信息丢失或者退化的问题，APFPN 直接将从骨干网络中提取到的多个层次特征在 Focus Feature 中直接交互，有效减少了传输信息衰减，而捕获高层语义的能力得到了增强，并对细粒度的信息保持了高度敏感性。同时，APFPN 还保留了 PANet 自上而下和自下而上的特征传递路径，并且在两个层次间，直接融入 Focus Feature 模块提取的特征，提升了对不同尺度目标检测能力。APFPN 聚合的特征经过三个分支进行处理：（1）通过上采样与 P3 尺度特征融合，然后通过 C2f 模块混合来自不同空间的通道维度和语义信息（2）通过 3*3 卷积下采样操作与 P5 尺度进行融合，同样通过 C2f 模块进行融合（3）直接输入 Focus Feature 模块并进行输出。最后，上述三个分支输出的多尺度特征作为下一阶段模块的输入。APFPN 网络原理如下，首先给定输入图像经过主干网络的特征提出得到多尺度特征，表示为 $P_i, i \in \{1,2,3,4,5\}$，其中表示原始输入图像的 $1/2^i$ 倍尺寸图。然后不同分辨率特征 $P_i, i \in \{3,4,5\}$ 被引入到颈部网络中。将三种级别的信息经过特征聚焦模块（Focus Feature）有效融合浅层与深层特征，并将融合特征传递给下一层的各个级别的特征中。融合的特征信息能够有效地补充在层次传播中丢失的语音和空间维度信息。具体为

$$N_4 = FocusFeature(P_3, P_4, P_5) \tag{2-2}$$

$$C_4 = FocusFeature(N_3, N_4, N_5) \tag{2-3}$$

其中，$P_i, i \in \{3,4,5\}, N_i, i \in \{3,4,5\}$ 表示每个层次的特征信息，N_4 、C_4 表示

中国知网　https://www.cnki.net

特征融合模块，$FocusFeature(\cdot)$ 表示特征聚合模块进行融合操作。

在上述聚合扩散过程中，为促进不同级别空间特征和不同层级语义之间的信息交换，本文提出特征聚焦模块（Focus Feature），如图 2-5 所示。

与以往依赖大核或者扩张卷积来扩大感受野的方法不同，Focus Feature 并行排列多个不同大小的深度卷积，不进行扩张，并提取不同感受野上的特征信息。这些特征信息包括局部和全局上下文信息，有效地提高了模型检测多尺度目标的性能。Focus Feature 模块是一个 Inception 风格的模块[37-38]。它包含一个 Concat 操作来收集多个层次的局部信息，然后一组并行的深度卷积来捕获跨多个尺度的上下文信息。Focus Feature 模块由尺寸对齐和信息融合两部分组成。在尺寸对齐部分中，采用 Adown 下采样模块，双线性插值以及卷积操作将低维信息 $L_3 \in \mathbb{R}^{H_l \times W_l \times C_l}$ 、中间层信息 $L_4 \in \mathbb{R}^{H_m \times W_m \times C_m}$ 以及高维信息 $L_5 \in \mathbb{R}^{H_h \times W_h \times C_h}$ 进行尺寸对其后进行相加而得到融合特征 L 。

$$Z^{(m)} = \mathrm{DWConv}_{k^{(m)} \times k^{(m)}}(L) \tag{2-4}$$

$$\mathrm{O}=\mathrm{Conv}_{1\times1}(L + \sum_{m=1}^{4} Z^{(m)}) \tag{2-5}$$

其中 L 为经过融合后的特征，$Z^{(m)}$ 是通过第 m 次 $k^m \times k^m$ 深度卷积（DWConv）提取的上下文特征，$Conv_{1\times1}$ 表示卷积核大小为 1×1 的卷积操作。在本文中，设置 $k^m = (m+1)\times2+1$ 。最后，公式（2-5）通过大小 1×1 的卷积融合了局部和上下文特征，1×1 卷积是一种通道融合机制，用于整合不同感受野大小的特征，通过这种方式，Focus Feature 可以在不影响局部纹理特征完整性的情况下捕获广泛的上下文信息，而 O 表示 Focus Feature 模块的输出。

中国知网 https://www.cnki.net

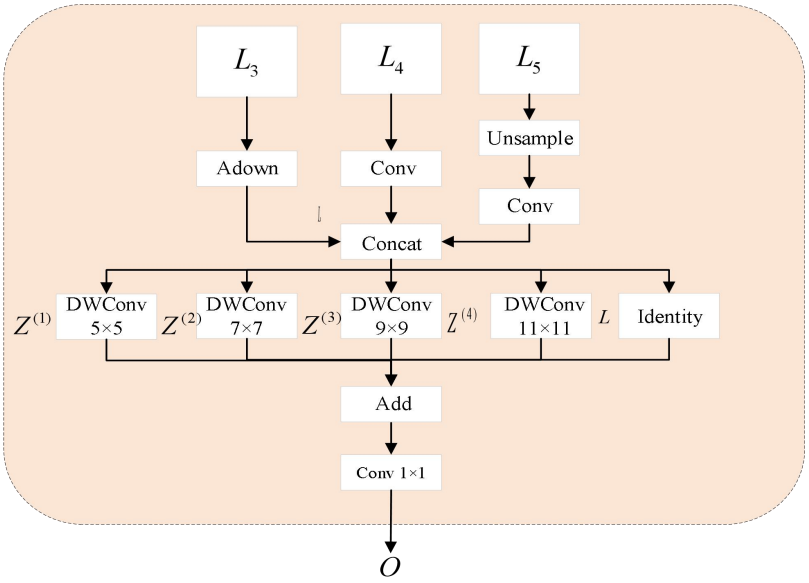


图 2-5　Focus Feature 模块

2.2.3　设计 Dyhead-DCNv4

优秀的目标检测头需要关注输入向量的多种形式的特征，其中包括尺度性、空间性以及任务性。缺陷检测问题中尺度问题十分重要，物体所产生的缺陷不止一种，种类之间甚至单个种类缺陷大小均不相同，因此检测头需要识别多尺度特征。同时，由于拍摄角度的不同，即使同样的缺陷由于空间的旋转平移也会出现差别。而任务性则是要求检测头能够自适应的支持各种任务，无论是单/两阶段的检测器，还是基于框/中心/关键点的检测器。十字轴轴颈表面缺陷存在尺度差异较大的问题，同时由于工业场景下生产环境复杂，导致缺陷可能存在于轴颈表面的各个位置。因此，十字轴轴颈表面缺陷的种类以及位置在图像中分布具有随机性。而 YOLOv8 原有的检测头存在一些局限性。首先，它仅从单一尺度对模型进行预测，无法满足对多尺度目标的检测要求。其次，原检测头的参数量较小，检测能力有限，难以挖掘特征中的空间结构信息。针对这些问题，本文在 YOLOv8n 头部网络引入 DyHead[39]（Dynamic Head）。DyHead 通过尺度感知、空间感知、任务感知三个不同的方面提高模型的检测能力和特征表达能力，并利用自注意力机制去强化这三种感知能力。同时，考虑到如果对完整的特征信息进行注意力的计算可能会导致模型参数量过大，DyHead 将三种注意力转换为序列形式排布，其中每个序列注意力只聚焦于其中一个模块，构造为一个嵌套注意力函数，公式描述为：

中国知网　https://www.cnki.net

$$W(F)=\pi_c(\pi_s(\pi_L(F)\cdot F)\cdot F)\cdot F \tag{2-6}$$

其中，$F \in \mathbb{R}^{L\times S\times C}$ 表示从检测层上得到的三维特征张量。$\pi_L(\cdot)$、$\pi_S(\cdot)$ 以及 $\pi_C(\cdot)$ 分别为尺度感知注意力模块、空间感知注意力模块以及任务感知注意力模块。并分别直接作用到 F 的 L 、S、C 三个维度上。单个 DyHead 块的结构图如图 2-6 所示。三个注意力模块的计算过程分别表示为：

Dyhead 首先引入了尺度感知注意力，目标尺度的差异对应了不同尺度的特征，改进 F 不同级的表达能力可以有效提升目标检测网络的尺度感知能力。更具不同尺度的特征在语义上的重要性对其进行动态融合：

$$\pi_L(F)\cdot F=\sigma[f[\frac{1}{SC}\sum_{S,C}F]]\cdot F \tag{2-7}$$

其中 $f(\cdot)$ 是一个由近似于 1×1 卷积运算所组成的线性函数，以实现特征降维，$\sigma(x)=\max(0,\min(1,\frac{x+1}{2}))$ 是 Hard-sigmoid 激活函数。

随后 Dyhead 引入了空间感知注意力，以聚焦对不同空间位置的判别能力。不相似目标形状的不同几何变换对应了特征的不同空间位置，改进 F 不同空间位置的表达能力大幅提升了目标检测网络的空间感知能力。模块首先采用可变性卷积对注意力学习稀疏化，然后进行特征跨尺度集成：

$$\pi_S(F)\cdot F=\frac{1}{L}\sum_{l=1}^{L}\sum_{k=1}^{K}w_{l,k}\cdot F(l;p_k+\Delta p_k;c)\cdot\Delta m_k \tag{2-8}$$

其中 K 为稀疏采样位置的个数，$p_k+\Delta p_k$ 是一个由自学习空间位移量 Δp_k 所决定的可移动位置，以用来聚焦于一些判别位置。而 Δm_k 是位置 Δp_k 处的一个自学习重要性标量，其两者可以通过 F 中间层级得到输入特征进行学习。经过空间位置感知注意力，特征进行了稀疏化，聚焦于不同位置的前景目标。

最后为了提高联合学习与目标表达能力泛化性，加入了任务感知注意力：

$$\pi_c(F)\cdot F=\max(\alpha^1(F)\cdot F_c+\beta^1(F),\alpha^2(F)\cdot F_c+\beta^2(F)) \tag{2-9}$$

F_c 是第 c 个通道的特征切片，而 $[\alpha^1,\alpha^2,\beta^1,\beta^2]^T=\theta(\cdot)$ 是一个超参数，用来学习控制激活阈值。$\theta(\cdot)$ 首先对 $L\times S$ 维进行全局平均池化降维，然后使用两个全连接层和一个归一化层，最后使用位移的 Sigmoid 函数将输出归一化为[-1，1]。经过任务感知注意力后，特征会基于不同下游任务形成不同的激活。这三

中国知网 https://www.cnki.net

种注意力机制在模型中顺序应用，并且可以共同反复堆叠多次来构成所需的 DyHead 块。

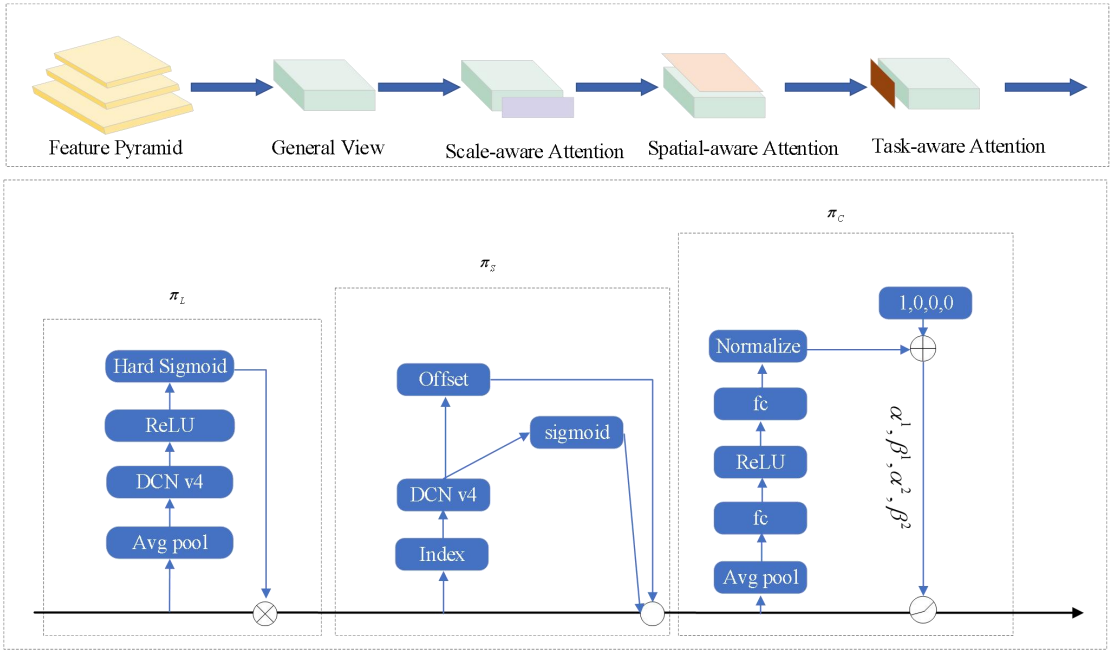


图 2-6　DyHead-DCNv4 结构图

同时，在目标检测任务中，待检目标多变的尺度和形状使得传统卷积方法难以适应，导致模型提取的特征极易受背景信息中无效成分的干扰，影响网络模型的检测性能。为了解决此问题，本文提出将可变形卷积引入 DyHead 模块中，提高了检测头对不同尺度缺陷特征的检测能力。图 2-7 展示了常规卷积与可变形卷积的运行原理。

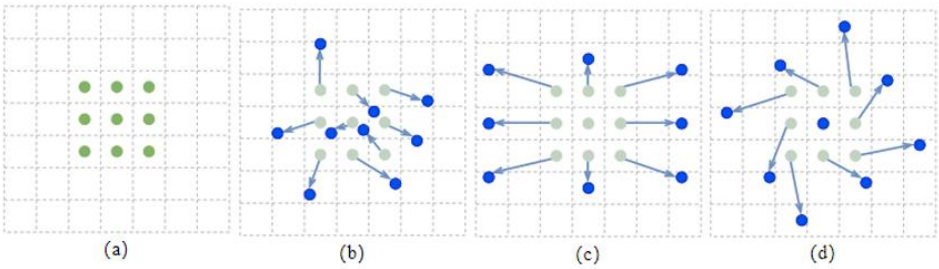


图 2-7　常规卷积与可变形卷积的采样示意图（(a)为常规卷积(b)-(d)为可变形卷积）

中国知网　https://www.cnki.net

-1, -1	-1, 0	-1, 1
0, -1	0, 0	0, 1
1, -1	1, 0	1, 1

图 2-8 相对位置坐标矩阵 R

在可变性卷积中，通过对相对位置坐标矩阵 R 增加一个偏移量 Δp_n 进行扩张，于是可变形卷积的前向计算公式可表示为：

$$y(p_0)=\sum_{p_n\in R} w(p_n)\cdot x(p_0+p_n+\Delta p_n) \tag{2-10}$$

$$\{\Delta p_n \mid n=1,2,...,N\}, N=|R| \tag{2-11}$$

其中，$x(p)$ 表示输入特征图中位置 p 处的特征。$y(p_0)$ 表示输出特征图中位置 p_0 处的特征。在不规则和偏移位置上的采样为 $p_n+\Delta p_n$，由于偏移量 Δp_n 通常为分数，比较难处理，所以上式通过双线性插值实现：

$$x(p)=\sum G(q,p)\cdot x(q) \tag{2-12}$$

$$G(q,p)=g(q_x,p_x)\cdot g(q_y,p_y) \tag{2-13}$$

$$g(q,p)=\max(0,1-|q-p|) \tag{2-14}$$

其中，p 表示一个任意的位置。q 表示 x 范围内所有整数位置。$G(\cdot,\cdot)$ 表示双线性插值核。

可变形卷积的具体实现过程如下，首先，将尺寸为 $B\times H\times W\times C$ 的输入特征图进行卷积操作，得到大小为 $B\times H\times W\times(2\times N\times N)$ 的特征图。其中，N 表示卷积核的尺寸，乘 2 表示每个卷积采样点都要学习一个偏移量的 offset，而 offset 是借助坐标 (x,y) 来进行描述的；其次，将偏移量与原坐标相加，以找到特征点经过偏移量后的位置；再者，由于偏移量通常为分数，因此采用双线性插值法对该位置对应的坐标进行修正。最后，将变换后的特征图作为最终的输出结果。

本文在 DyHead 检测头的基础上将标准卷积替换为可变性卷积 v4[40]（Deformable Convolution v4,DCNv4），对其命名为 DyHead-DCNv4 模块。DCNv4 从

中国知网 https://www.cnki.net

两个关键方面解决了 DCNv3 的局限性:（1）去除空间聚合中的 SoftMax 归一化,增强空间聚合的动态性和表现力;（2）优化内存访问,减少了非必要的内存访问操作。优化过程如图 2-9 所示。DCNv4 使用一个线程来处理同组的多个通道，这些通道共享采样偏移量和聚合权重。这样有效地减少了内存读取和双线性插值系数计算等工作负载，并且可以合并多个内存访问指令。这些改进明显加快了收敛速度,并大幅提高了处理速度,其中转发速度是 DCNv3 的 3 倍以上。

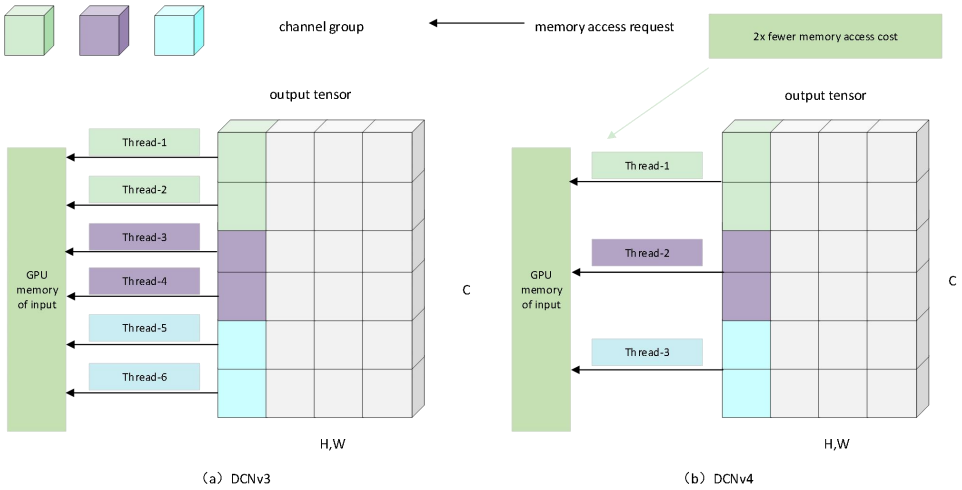


图 2-9　DCNv4 优化示意图

2.3　实验结果与分析

2.3.1　网络模型的实验环境

为了验证本文提出的 YOLO-SAD 算法的有效性，在自制的十字轴轴颈数据集上进行消融实验，并于目前主流的检测模型进行对比。本实验均在 Ubuntu20.04 系统平台上完成。使用的 CPU 型号为 16 vCPU intel(R) Xeon(R) platinum 8481。使用的显卡型号为 NVDIA GeForce RTX 4090D(24GB)。部署环境为 Python3.8。深度学习框架为 Pytorch 1.11.9，加速计算架构为 CUDA12.0;

同时，为了保证实验的公平性和对比性，模型在训练时不使用预训练权重。图像尺寸为 640×640 像素;参数学习率（learning-rate）为 0.01;动量（momentum）为 0.937;权重衰减系数(weight-delay）为 0.0005;批样本大小（batch size）为 16;迭代次数（epoch）为 300。训练时长大约 8-20 小时。具体参数如表 2-1 所示。

中国知网 https://www.cnki.net

表 2-1 实验参数设置

参数名称	设定值
图像尺寸	640×640
学习率	0.01
动量	0.937
衰减系数	0.0005
批样本大小	16
迭代次数	300

2.3.2 评价指标

目标检测领域常用一些指标来评估模型的检测性能，能够帮助我们了解模型的优劣程度，以便进行改进和优化。本文主要采用精确率（Precision，P）、召回率（Recall，R），单类平均精度值（Average Precesion，AP）、所有类别平均精度值（meanAverage Precision, mAP）、模型每秒检测帧数（Frames Per Second，FPS）、模型参数量（Params）、模型计算量（Giga Floating-point Operations Per scrond,GFlops）。

混淆矩阵		预测值	
		Positive	Negative
真实值	True	TP	FN
	False	FP	TN

图 2-10 混淆矩阵示意图

在引入这些指标之前，需要了解模型预测出结果的几种情况：

（1）真正例（True Positive, TP）：被正确的预测为正例的个数，即实际为正例且被模型预测为正例的实例数。

（2）假正例（False Positive, FP）：被错误地预测为正例的个数，即实际为负例但被模型预测为正例的实例数

（3）真负例（True Negative, TN）：被正确地预测为负例的个数，即实际为负例且被模型预测为负例的实例数。

（4）假负例（False Negative, FN）：被错误地预测为负例的个数，即实际为正例但被模型预测为负例的实例数。

中国知网 https://www.cnki.net

四种结果组成的混淆矩阵如图 2-10 所示。而精准率与召回率的确定就与这四种情况息息相关。

精准率表示的是一个分类器对于正负样本的判断准确率，具体为在所有被检测为正的样本中检测正确的所占的比例，又称为正样本的查准率，这个参数所确定的正样本是以检测结果为标准的，其公式为：

$$P=\frac{TP}{TP+FP}\times 100\% \tag{2-15}$$

召回率指的是在所有检测的正样本中被正确检测出来所占的比例，又称正样本的查全率，该参数的正样本判断是样本本身的所属，即先确定为正样本再由分类器进行判断，其公式为：

$$R=\frac{TR}{TP+FN}\times 100\% \tag{2-16}$$

IoU 是评价算法模型的预测精度的一个重要标准，IoU 越大，说明使用该算法进行检测时生成的预选框与真实框之间的差异越小，算法模型的检测精度越高。IoU 计算示意图如下图所示。在目标检测算法中，通常会设置一个 IoU 阈值，从而筛选出可信度较高的预测框，然后把检测结果输入到分类器进行分类得到最终的检测结果。其公式为：

$$\mathrm{IoU}=\frac{\text{预测框}\cap\text{真实框}}{\text{预测框}\cup\text{真实框}} \tag{2-17}$$

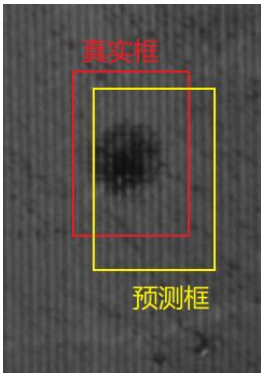


图 2-11 IoU 计算示意图

AP 值是针对单个类别的评估指标，衡量了目标检测算法在给定类别下的预测精度。它与精确率和召回率有关。AP 值是不同召回率情况下精确率的均值，也就是 P-R 曲线下面积，计算公式如下：

中国知网 https://www.cnki.net

$$AP = \int_0^1 PdR \tag{2-18}$$

mAP 值则是针对多个类别的评估指标，它是所有类别的 AP 值的平均值。是用来衡量整个模型性能的指标，值越大表示性能越好。其中 mAP@.5 值的是当 IoU 阈值为 0.5 时的平均精度，也就是检测框与真实框之间的 IoU 大于 0.5，则将该检测框视为正确检测，否则将其视为错误检测；mAP@.5:95 指的是当 IoU 从 0.5 到 0.95 时的平均精度，这意味着对于 IoU 从 0.5 到 0.95 相比于 mAP@.5 则为更全面，可以更精准地评估模型的性能。然而考虑到计算复杂度以及实际引用需求，mAP@.5 能够在保证一定精度的情况下，计算效率更高，因此，本文采用 mAP@.5 作为主要精度评价指标，计算公式如下，N 表示检测的类别总数。

$$mAP = \frac{\sum_{i=1}^{N} AP_i}{N} \tag{2-19}$$

FPS 表示模型每秒所能处理的图片数，也称为帧率。用于衡量模型的实时性能。通常用于 FPS 达到 40 帧/s 便能够满足实时检测的要求，计算公式如下：

$$FPS = \frac{TotalTime}{NumFigure} \tag{2-20}$$

Param 即模型参数数量，指模型在训练过程中需要学习的参数数量。用于衡量模型的复杂度，值越大模型就越复杂，需要更多的存储和计算资源来执行推理。

GFlops 即模型计算量，表示模型执行推理所需的浮点运算次数。用于衡量模型的计算量，计算量越大，模型的推理时间也就越长。

2.3.3 Focus Feature 不同深度卷积核的性能对比

Focus Feature 采用一组并行的深度卷积来捕获多尺度的上下文信息，其中卷积的大小影响模型的检测性能。本文对比了多组不同大小的卷积核对模型性能的影响。结果表明，由于纹理信息提取有限，仅使用较小的 5×5 卷积核会导致性能不佳。随后采用多尺度核结构，大小范围为从 5×5 到 11×11，步长为 2。在此设置下，模块变现出最佳性能。接下来，测试了当核大小增加，步长为 4 的情况下，性能不是最优的。进一步仅使用大核的实验导致计算量增加但性能下降，分别下

中国知网 https://www.cnki.net

降了 1.8%和 2.1%，这表明大核可能会引入背景噪声并导致性能下降。

表 2-2 不同卷积核性能对比

卷积核大小	mAP@.5/%	GFLOPs	参数大小/MB	FPS/(帧/s)
(5,5,5,5)	76.9	**9.0**	**2.92**	256.4
(5,7,9,11)	**77.8**	9.4	3.04	**285.7**
(5.9.13.17)	77.1	9.8	3.18	250
(11,11,11,11)	76	9.7	3.14	217.4
(15,15,15,15)	74.8	10.3	3.34	185.19

2.3.4 不同数量的 DyHead-DCNv4 模块相串联的性能对比

DyHead-DCNv4 模块可以实现串联来改变模型的性能。本文对比了不同 DyHead-DCNv4 模块数量对模型的影响。具体对比实验结果如表 3-3 所示。从结果可以看出,串联操作会增加模型计算复杂度,并且并不是串联的数量越多性能就会越好,反而随着串联模块的增加,模型的性能缺逐渐降低。因此，本文只串联 1 块 DyHead-DCNv4 模块进行预测输出。

表 2-3 不同数量 DyHead-DCNv4 模块性能对比

模块数量	mAP@.5/%	GFLOPs	参数大小/MB	FPS/(帧/s)
1	76.7	10.7	3.09	169.5
2	76.5	12.3	3.20	208.3
3	74.7	13.9	3.30	185.2
4	75.7	15.5	3.41	165.9

2.3.5 Dyhead-DCNv4 与 Dyhead-DCNv3 性能对比

为了比较 DCNv4 与 DCNv3 的优劣情况，本文将 Dyhead 与两者分别结合后加入到基础模型 YOLOv8 中并进行实验。具体的实验结果如图 2-12 以及表 2-4 所示。图 2-12 展示了训练过程中模型的损失变化情况，如图所示，相比于 Dyhead-DCNv3，Dyhead-DCNv4 模型具有更快的收敛速度以及更低的损失结果。

中国知网 https://www.cnki.net

同时，如表 2-4 所示，在检测精度相仿的情况下，Dyhead-DCNv4 相较于 Dyhead-DCNv3 具有更少的参数量和计算量，并且 FPS 也更高。这些对比表明，经过优化，DCNv4 收敛更快，并且极大地减少了模型的参数量，因此，本文采用将 Dyhead-DCNv4 加入模型。

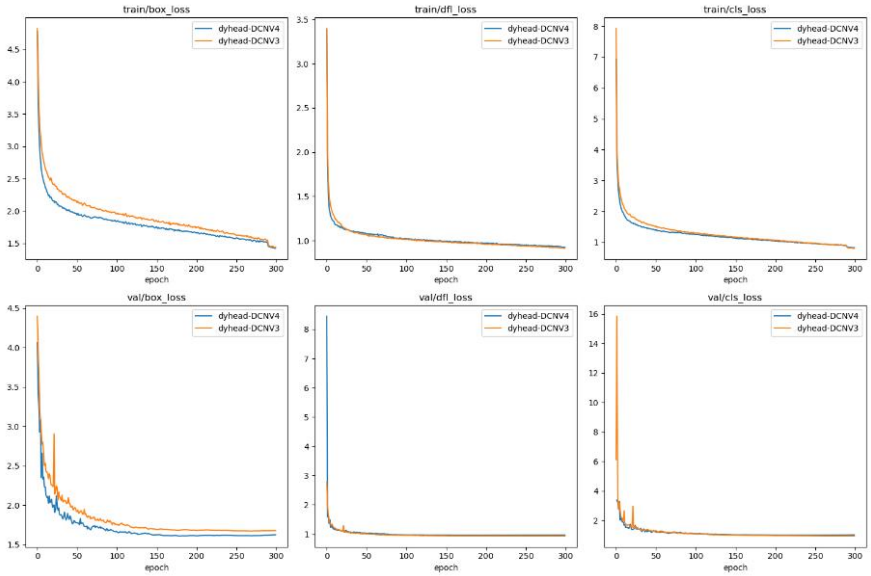


图 2-12　Dyhead-DCNv4 与 Dyhead-DCNv4 模型 loss 对比图

表 2-4　Dyhead-DNCNv3 与 DyHead-DCNv4 模块性能对比

模型	mAP@.5/%	GFLOPs	参数大小/MB	FPS/(帧/s)
Dyhead-DCNv3	76.4	17.1	3.51	143.2
Dyhead-DCNv4	76.7	10.7	3.09	169.5

2.3.6　消融实验与结果分析

为了验证本文添加的 SPD-Conv 模型、APPFPN 模型以及 DyHead-DCNv4 检测头用在 YOLOv8 模型对十字轴轴颈缺陷检测的有效性,将各个改进网络进行消融实验对比,实验过程中保持参数一致,且不适用预训练权重,结果如表所示,“√”代表引用了此模块。

中国知网　https://www.cnki.net

表 2-5 消融实验结果

YOLOv8n	SPD-Conv	APFPN	DyHead-DCNv4	P/%	R/%	mAP@.5/%	mAP@.5:95/%	参数大小/MB	GFLOPS	FPS/s
√				74.5	73.1	76.1	44.9	3.0	8.1	333.3
√	√			81.6	69.9	77.0	45.8	4.7	11.6	270
√		√		80.5	73.4	77.7	45.2	3.04	9.4	344
√			√	80.7	76.8	76.7	45.7	3.09	10.7	169.5
√	√	√		82.2	74.1	79.2	46.2	4.21	12.2	384.6
√	√	√	√	83.1	73.3	79.9	46.4	4.25	13.8	185.2

通过表 2-5 的实验结果证明了当各个模块加入进模型，模型在准确率（P）、召回率（R）和平均精度（mAP）等方面都有不同程度的提升。将 SPD-Conv 加入到主干网络后，mAP@.5 由 76.1%提升到了 77%,mAP@.50:95 提升了 0.9%，并且 precision 从 74.5%提升到了 81.6%,表明加入 SPD-Conv 后，模型对于小目标的检测能力得到的提升,但是会增加计算量和模型大小。使用 APFPN 替换原颈部网络后，precision、recall 以及 mAP@.5 均有提升，对改进模型性能贡献最佳，说明 APFPN 增强了模型的特征融合能力。将 DyHead-DCNv4 模块与 YOLOv8n 算法进行融合，precision、mAP@.5 以及 recall 分别提升了 6.2 百分点、0.4 个百分点以及 3.7 个百分点，说明 DyHead-DCNv4 模块可以更好的融合上下文信息，识别多尺度目标。组合使用多个模块可以进一步提升 precision，但会提升模型大小。最后将各个模块结构结合起来，将它们的优势取长补短。结合后的模型在 precision、recall 以及 mAP@.5 上都达到了最高，且 FPS 为 185.2 帧每秒，仍然满足实时性检测的需求。

为了了解不同改进策略对数据集中不同缺陷检测性能的影响，本文对五种表面缺陷中每一种曲线的 precision、recall 以及 mAP@.5:95 进行详细的分析。表 2-6 展示了不同改进策略对五种缺陷 precision 的影响。其中欠加工的准确率最高，这主要是由于欠加工类的缺陷尺寸较大，相比其他缺陷来说特征较为明显，对于模型来说更加容易学习。而缺肉和磕碰准确率高主要是由于两者缺陷较小，同时十字轴表面过于微小的缺陷没有被标记，导致预测时模型可能将其预测为真，从而影响模型的精确率。可以看出，YOLO-SAD 在所有种类缺陷上 precision 均有提升。

中国知网 https://www.cnki.net

表 2-6　不同改进策略对 Precision 的影响

Model	缺肉	磕碰	欠加工	锈斑	倒角	平均
YOLOv8n	62.5	65.1	94.5	78.6	72.8	74.7
YOLOv8n+SPD-Conv	71.9	73.2	94.9	88.3	79.1	81.5
YOLOv8n+APFPN	74.1	74.3	92.9	80.9	**79.9**	80.4
YOLOv8n+DyHead-DCNv4	55.5	62.0	94.6	74	68.2	70.9
YOLO-SAD	**73.3**	**76.8**	**96.3**	**91.1**	78.2	**83.1**

表 2-7 展示了不同改进策略对数据集中不同缺陷召回率的影响，从结果可以开出，由于欠加工缺陷特征较为明显，导致其召回率仍为最高。而缺肉的召回率相对较低，这主要是因为这总缺陷尺寸较小，不易被检出。

表 2-8 展示了不同改进策略对数据集中不同缺陷平均精度（mAP@.5:95）的影响。从结果可以看出，除了欠加工其他缺陷的平均精度值都普遍较低，主要是由于工件表面背景噪音过多，而缺陷相对小，在计算预测框和真实框的 IOU 值较为困难，会存在较大的误差，所以，几类缺陷的平均精度较低。本文提出的 APFPN，将多尺度信息广泛传播，提升了对小目标缺陷的检测能力，相比于原 YOLOv8n 模型，平均精度有显著提升。

表 2-7　不同改进策略对 Recall 的影响

Model	缺肉	磕碰	欠加工	锈斑	倒角	平均
YOLOv8n	55.6	81.0	100	66.9	62.1	73.1
YOLOv8n+SPD-Conv	48.3	78.5	99.7	72.7	53.0	69.9
YOLOv8n+APFPN	53.1	76.6	98.9	81.8	55.6	73.2
YOLOv8n+DyHead-DCNv4	56.0	84.1	100	77.6	66.1	76.8
YOLO-SAD	56.0	79.5	**98.9**	**72.8**	59.3	73.3

表 2-8　不同改进策略对 mAP@.5:95 的影响

Model	缺肉	磕碰	欠加工	锈斑	倒角	平均
YOLOv8n	30.5	42.2	76.8	47.9	27.2	44.9

中国知网　https://www.cnki.net

YOLOv8n+SPD-Conv	30.1	41.6	76.6	53.8	26.9	45.8
YOLOv8n+APFPN	31.0	41.7	77.6	49.2	**26.7**	45.2
YOLOv8n+DyHead-DCNv4	29.4	42.4	78.0	45.5	26.7	44.4
YOLO-SAD	32.2	**42.9**	**77.8**	**50.2**	27.9	46.2

表 2-9 消融实验结果不同算法的性能对比

Model	mAP50/%	GFLOPs	参数大小/MB	FPS/(帧/s)
YOLOv3-Tiny	64.2	18.9	12.1	357.1
YOLOv5	72.5	2.5	7.1	434
YOLOv7-Tiny	62.2	12.1	6.0	222.2
YOLOv8n	76.1	8.1	3	333.3
YOLO-SAD	79.9	13.8	4.25	185.2

2.3.7 不同算法之间的对比实验

为了进一步验证本文算法改进的合理性和有效性，在各项参数指标不变的情况下，与当前主流的目标检测算法 YOLOv3-tiny、YOLOv5、YOLOv7-tiny[41]和 YOLO8n 算法进行对比实验，实验结果见表 2-9。由表 2-9 数据可知，YOLOv3-tiny 算法、YOLOv5s 算法和 YOLOv7-tiny 算法的 mAP@.5 相对于 YOLO-SAD 算法分别下降了 15.7、7.4、17.7 个百分点。为了进一步说明本文改进的有效性，本文对几种模型的 Recall、Precision、mAP@.5 以及 mAP@.5:.95 进行了对比，结果如图 2-13 所示，可以看到在四项指标中，本文提出的 YOLO-SAD 均表现出了最好的性能。综上所述，可以看出 YOLO-SAD 算法相较于目前主流的目标检测算法，对于十字轴轴颈的缺陷检测具有更加出色得到检测性能。

中国知网 https://www.cnki.net

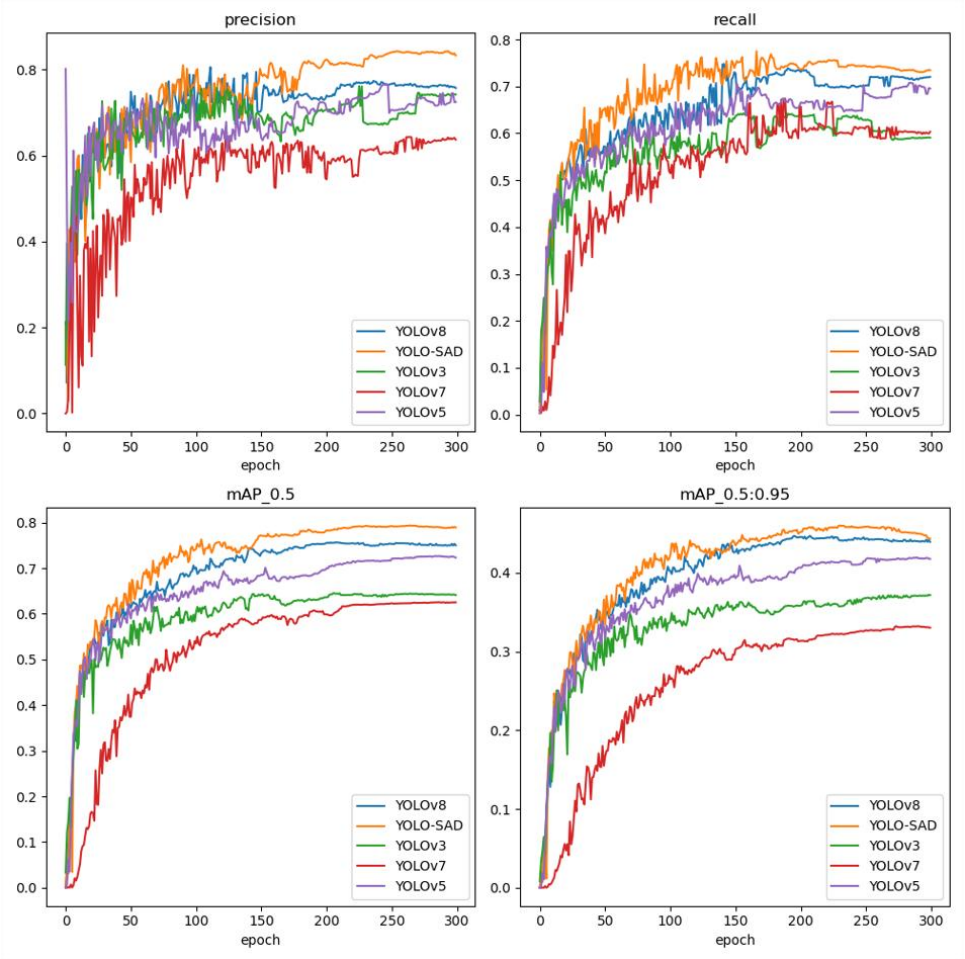
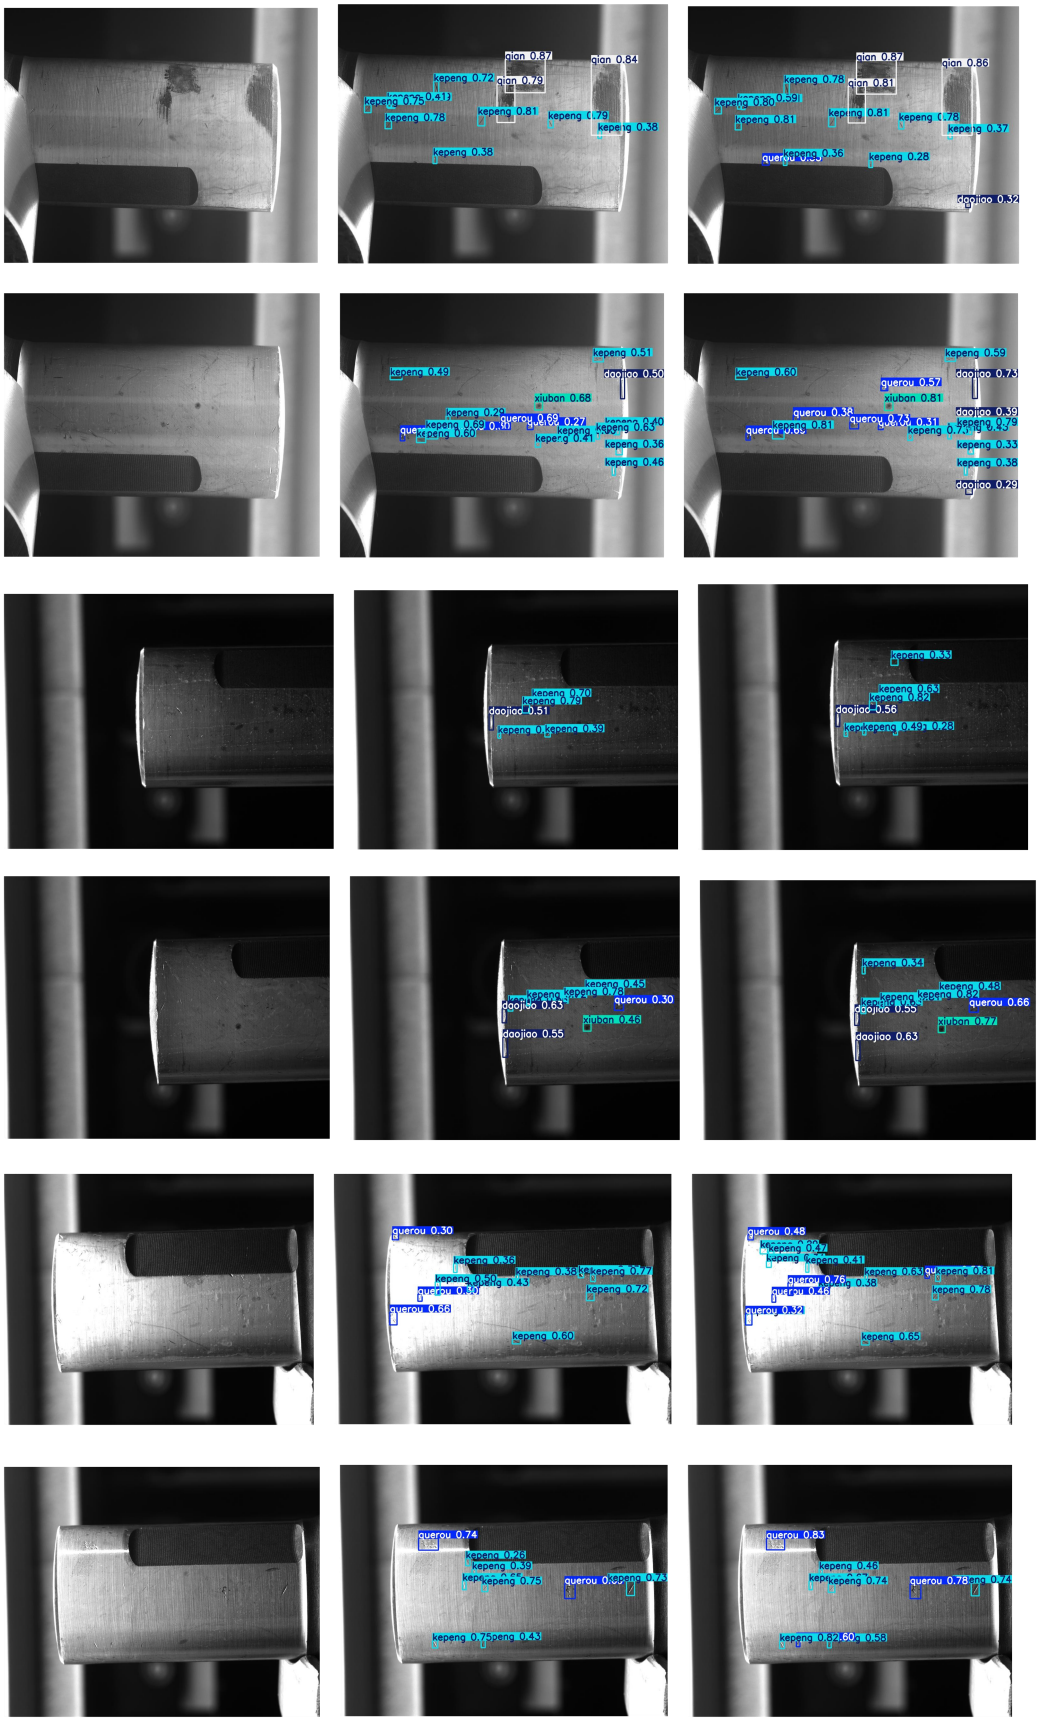


图 2-13　不同模型各项指标对比图

2.3.8　可视化实验

为了更加直观的展示本文改进算法在十字轴轴颈检测任务中的检测效果，以原始图为基准，对比 YOLOv8n 和本文提出的 YOLO-SAD 算法的实际检测情况，如图 2-14 所示。第一列为十字轴轴颈缺陷数据集；第二列为原始算法 YOLOv8n 的检测效果；第三列为改进后算法的检测效果。观测图片结果可知，针对三种不同的光照，即暗光、正常光、强光环境下，YOLOv8n 原模型对于小目标、密集目标的检测能力明显下降，并且存在误检和漏检的情况。而改进后的 YOLO-SAD 算法在感知能力方面具有明显优势，能够检测出更多目标，具有更低的误检和漏检概率，且能够在不同场景下表现出良好的性能。综上所属，本文提出的 YOLO-SAD 算法能够在复杂多变的场景中实现更加高效的检测效率。

中国知网　https://www.cnki.net



（a）原图　　（b）YOLOv8　　（c）YOLO-SAD

图 2-14　YOLOv8n 与本文 YOLO-SAD 检测效果对比

中国知网　https://www.cnki.net

2.4 本章小结

在本章中，深入探讨了对 YOLOv8n 模型进行的一系列改进，以优化其在十字轴轴颈缺陷检测任务中的表现。

(1) 针对模型的特征提取部分，本文引入 SPD-Conv 来代替传统的下采样方式，提升了模型对小尺寸缺陷检测的能力。

(2) 提出了一种特征金字塔模型，即 APFPN，通过定制的特征聚合模块和特征扩散机制，能让每个尺度的特征都具有详细的上下文信息，更利于后续目标的检测和分离。

(3) 为了进一步提升模型的性能，本文提出了 Dyhead-DCNv4 检测头来代替传统的 YOLOv8n 检测头，用于识别多尺度目标，弥补标准卷积在长距离建模能力和自适应空间聚合能力上的不足，更好的完成检测任务。

与传统 YOLOv8n 算法相比，YOLO-SAD 算法取得了更好的结果，mAP@.5 呈现明显提升，达到了 79.9%，提升了 3.8 个百分比，而计算量以及参数上并没有过多的增加。FPS 达到了 185.2 帧每秒，符合任务的实时性要求。

第 3 章 基于半监督学习的十字轴轴颈缺陷检测

3.1 引言

本文在第二章研究了针对十字轴轴颈的表面缺陷检测方法，并对其进行研究和改进，得到的精度进一步提升的目标检测方法。然而，在实际生产任务中，受多方面影响，例如（1）工件生产技术完备，短时间内无法收集到足够的缺陷。

中国知网 https://www.cnki.net

（2）生产下工人缺少专业知识，无法准确的标注数据等使得获取标注数据的时间长、成本高昂。如果将这些有限的标注数据则直接应用到全监督，可能会出现过拟合问题，极大地限制了监督模型的检测能力，难以达到令人满意的检测效果。半监督学习技术为解决这一问题提供了有效方法，其能够借助大量未标注数据来提高检测模型的泛化能力和准确性。而当前半监督学习在目标检测领域面临的一个难题是如何从无标注数据中挖掘到高质量的潜在信息。针对这个问题，本章提出了一种以师生网络为基本框架的伪标签阈值扩展半监督十字轴轴颈表面缺陷检测模型。首先引入教师学生网络来对无标签数据继续伪标注并进行半监督训练。同时，将传统的单置信度标签筛选方法扩展为双置信度筛选，将标签分为可靠、不确定和不可靠三种类型，减少低质量伪标签对学生网络的负面影响的同时，保留中等质量的伪标签并进行信息提取。最后，针对三种标签，优化了损失函数。实验结果表明，本章模型可以在标注资源有限的情况下，训练高效且准确的检测模型。

3.2 算法设计与实现

3.2.1 引入师生模型

师生模型是知识蒸馏[42]中的核心概念，它包含两个神经网络模型，教师模型和学生模型。通过让学生模型学习教师模型的输出，从而在保持高性能的同时提高模型的准确率。随后，师生模型这一思想被应用于半监督学习领域。流程是先让教师模型在已标注数据上进行训练，然后教师模型根据学习到的权重，对无标注数据进行标注，生成伪标签。学生模型随后利用这些伪标签继续训练，从而实现模型准确率的提升。

本文引入师生模型的理念，选用 YOLOv8 作为基础模型实现网络半监督训练，整体框架如图所示。具体来说，训练过程包含两个阶段：预训练阶段和相互学习阶段。在预训练阶段，学生网络使用全部标注数据进行预训练，通过反向传播更新自身参数，并在训练完成后将学习到的参数复制给教师网络。随后，使用得到预训练权重的教师网络对无标注数据进行预测，并选取预测概率最大的一类作为伪标签数据对应的伪标签。而在相互学习阶段，通过设置的选取比例分别选取不同数量的标注数据和无标注数据形成一个训练批次进行训练。教师模型负责

中国知网 https://www.cnki.net

为无标注数据生成伪标注，而学生模型则负责进行训练，并通过指数移动平均（EMA）将学习到的参数更新教师模型，从而获得更稳定的伪标注，其中教师模型参数更新方法表示如下：

$$\alpha\theta_t + (1-\alpha)\theta_s \rightarrow \theta_t \tag{3-1}$$

其中，α 是平滑超参数，通常设置为 0.9，θ_t 和 θ_s 分别表示教师模型和学生模型的参数。通过这样的循环反复，逐渐提高整个模型的检测精度。

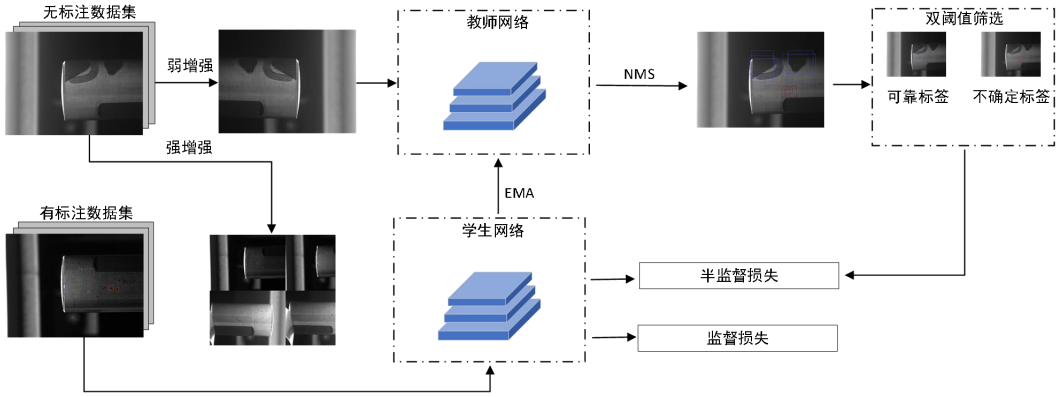


图 3-1　本章所提出师生模型框架图

3.2.2　伪标签阈值扩展

对于教师模型利用无标注数据生成为伪标注，模型将其看成是“真实标签”并进行损失计算。传统的半监督分类模型首先通过非最大抑制（Non-Maximum Suppression NMS）技术来融合过多的伪标注从而避免伪标注之间的冗余，然后通过设置一个高阈值的置信度分数来过滤那些低置信度的伪标注。筛选策略如公式 3-2 所示。

$$g(h,w) = \begin{cases} Object & \mathrm{c(h,w)} > \tau \\ Background & \mathrm{c(h,w)} \le \tau \end{cases} \tag{3-2}$$

其中，$c(h,w)$ 是 (h,w) 处的预测分数，$g(h,w)$ 是相应的伪标签。

根据学者的研究，过滤低置信度的伪标签能够在降低模型计算量的同时提高类别标签的准确性，但是高阈值可能会让本来具有正确类别信息的伪标注被误筛为背景。同时，目标检测任务中的伪标签相比于分类任务更加复杂，同时包含了类别与位置两种信息，大部分半监督模型忽略了类别得分与定位信息之间并没有

中国知网　https://www.cnki.net

强相关性，即不能只通过伪标注类别分数的高低来反应定位精度。为此，本章扩展伪标签筛选阈值，将单一阈值 τ 扩展为双阈值 τ_1，τ_2（$\tau_2 > \tau_1$）。高于 τ_2 的值定义为目标，低于 τ_1 的值定义为背景，而介于两者之间的伪标签定义为不确定伪标签，具体公式如下。

$$g(h,w)=\begin{cases} Object & c(h,w)>\tau_1 \\ Uncertain & \tau_1 \le c(h,w) \le \tau_2 \\ Background & c(h,w)>\tau_2 \end{cases} \tag{3-3}$$

3.2.3 损失函数优化

损失函数的作用是利用反向传播算法来修正模型预测与实际结结果之间的偏差，从而指导训练想着正确方向进行。因此，恰当的损失函数对于模型训练来说至关重要。为了让损失函数与双阈值的为标签相适配，本文对损失函数进行了重新设计。

半监督学习损失由两部分组成，分别是监督损失和无监督损失。具体公式如下所示：

$$L = L_{\text{sup}} + \lambda L_{un\,\text{sup}} \tag{3-4}$$

其中，L_{sup} 表示有监督损失，即有标签图像损失，而 $L_{un\text{sup}}$ 表示无监督损失，即无标签图像的损失，λ为平衡系数，本章框架中取值为 4。L_{sup} 沿用 YOLO 系列中的标准损失函数，由分类损失（$loss_{cls}$）、定位损失（$loss_{conf}$）和置信度损失（$loss_{loc}$）三部分损失函数组成。所以本章采用的师生模型中，在使用有标签数据进行训练时损失函数如公式 3-5 所示，其中 y 表示有标签数据的标签，f 表示预测值。

$$Loss(y,f)=loss_{cls}+loss_{conf}+loss_{loc} \tag{3-5}$$

其中，置信度损失和分类损失使用二元交叉熵损失（Binary Cross Entropy Loss, BCE）来计算，而定位损失则采用 CIoU Loss[43]，具体计算公式如下：

$$loss_{cls}=\sum_{h,w} BCE(X^{cls}_{(h,w)}, Y^{cls}_{(h,w)}) \tag{3-6}$$

中国知网 https://www.cnki.net

$$loss_{conf} = \sum_{h,w} BCE(X^{conf}_{(h,w)}, Y^{conf}_{(h,w)}) \tag{3-7}$$

$$loss_{loc} = \sum_{h,w} CIoU(X^{loc}_{(h,w)}, Y^{loc}_{(h,w)}) \tag{3-8}$$

其中，$X_{(h,w)}$ 表示学生模型的输出，$Y_{(h,w)}$ 表示教师模型生成的预测结果。

对于无监督损失，其组成部分与监督损失相同，也分为分类损失、定位损失以及置信度损失。在传统半监督模型中，对于高于设置的阈值τ的伪标签，模型认定其为有用标签，对其进行完全的损失计算，而低于τ的伪标签，模型将其丢弃。而在引入伪标签双阈值之后，本章对 $L_{un\sup}$ 进行的优化：对于得分高于 τ_2 的伪标签，模型将认为其与真实标签一致性较高，将其判定为有效数据，因而对其进行全方位损失计算，包括置信度、分类、定位损失，以充分利用这些数据优化模型。对于分数高于 τ_1 而低于 τ_2 的不确定性标签，则采取更加细致的处理方式。偶遇这些伪标签内可能存在目标，但是其分类分数和定位分数不足以依赖，因此只对其进行置信度损失的计算，以降低这些不确定性伪标签对模型训练的负面影响。对于置信度更低的伪标签（分数小于 τ_2），模型将其认定为背景噪音或者当前阶段模型无法正确理解的数据，只计算这些伪标签与零标签之间的交叉熵损失，以减少噪声对模型的影响。通过细化损失函数计算策略，可以提升模型对复杂数据的处理能力和鲁棒性。具体的损失函数设置如下：

$$loss^{conf}_{\text{un sup}} = \sum_{(h,w)} \begin{cases} BCE(X^{conf}_{(h,w)}, 0) & \varsigma_{(h,w)} < \tau_1 \\ +BCE(X^{conf}_{(h,w)}, Y'^{conf}_{(h,w)}) & \varsigma_{(h,w)} \geq \tau_1 \end{cases} \tag{3-9}$$

$$loss^{cls}_{un\sup} = \sum_{(h,w)} BCE(X^{cls}_{(h,w)}, Y'^{cls}_{(h,w)}) \quad \varsigma_{(h,w)} > \tau_2 \tag{3-10}$$

$$loss^{loc}_{un\sup} = \sum_{(h,w)} CIoU(X^{loc}_{(h,w)}, Y'^{loc}_{(h,w)}) \quad \varsigma_{(h,w)} > \tau_2 \tag{3-11}$$

其中，$Y'^{cls}_{(h,w)}$、$Y'^{conf}_{(h,w)}$ 以及 $Y'^{loc}_{(h,w)}$ 表示图像位置 (h,w) 处伪标签的分类得分，置信度得分以及定位得分。$\varsigma_{(h,w)}$ 为 (h,w) 处的预测分数。

3.3 实验结果以及分析

3.3.1 数据集划分

中国知网 https://www.cnki.net

表 3-1 数据集划分

比例	标注数据集	未标注数据集	测试集
5%	192	3648	960
10%	384	3456	960
20%	768	3072	960

本章使用与第二章相同的十字轴轴颈数据集，并将其分为训练集和测试集，其中，训练集是由有标注和无标注数据共同组成。而测试集则全部采用有标签数据。同时，为了模拟半监督学习处境下的数据集，同完整训练集中分别提取 5%，10%以及 20%占比的有标签数据集作为三种不同的标注数据集，其余数据的标签不计入实验，作为未标注数据放入数据集。具体划分情况如表 3-1 所示。

3.3.2 实验环境和超参数设置

表 3-2 实验参数设置

参数名称	设定值
图像尺寸	640×640
学习率	0.01
动量	0.937
衰减系数	0.0005
批样本大小	8
训练批次	1000
平衡系数 λ	4
τ_1	0.3
τ_2	0.9

本实验使用 YOLOv8 作为基础的目标检测器，且均在 Ubuntu20.04 系统平台上完成。使用的 CPU 型号为 16 vCPU intel(R) Xeon(R) platinum 8481C。使用的显卡型号为 NVDIA GeForce RTX 4090D(24GB)。部署环境为 Python3.8。深度学习框架为 Pytorch 1.11.9，加速计算架构为 CUDA 12.0；模型图像尺寸：640×640 像素；参数学习率（learning-rate）为 0.01；动量（momentum）为 0.937；权重衰减系数（weight-delay）为 0.0005；批样本大小（batch size）为 8（标注图像是 2 张，无标注图像是 6 张）；无监督损失平衡系数λ设置为 4，阈值 τ_1 、 τ_2 分别设置为 0.3 和 0.9 训练批次设置为 1000 轮，其中前 300 轮只对标注数据进行训练，达到

中国知网 https://www.cnki.net

模型预热的效果。具体参数设置如表 3-2 所示。

3.3.3 少量标注数据下 YOLO-SAD 与 YOLOv8 结果对比

为了确保基础模型的适配性，在确保环境相同条件下，设计了对比实验。对第二章所提的 YOLO-SAD 与 YOLOv8 在三种不同比例的数据集上进行了对比实验，实验结果如图 3-2 所示。

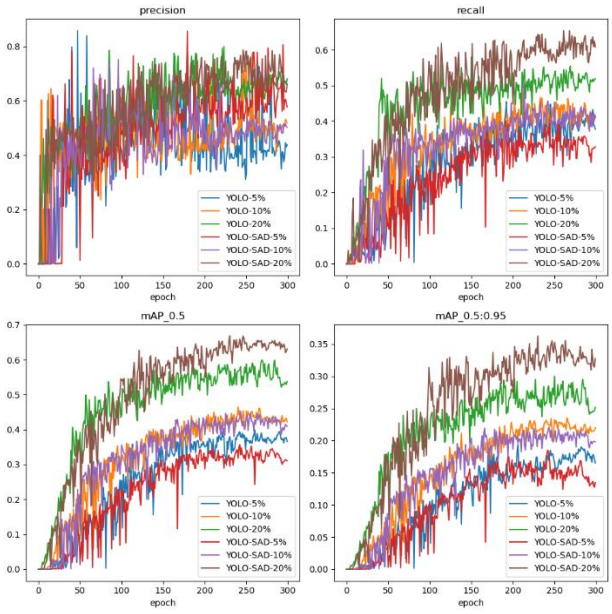


图 3-2　不同比例数据集下 YOLO-SAD 与 YOLOv8 实验精度对比

从实验结果可知，在 5%以及 10%比例数据集下，YOLOv8 在 mAP@.5 以及 mAP@5:95 相比于 YOLO-SAD 更高，而在 20%比例下，YOLO-SAD 则具有优势。这可能是因为 YOLOv8 基础性能较好，更具有普适性。而 YOLO-SAD 主要针对某种缺陷（小目标），因此需要更多的学习数据。所以，为了适配半监督模型标注数据集少的情况，本章采用 YOLOv8 作为基础算法。

3.3.4 消融实验分析

为了验证提出的策略在半监督十字轴轴颈缺陷检测模型的有效性，本章在相同的实验环境下，设计了消融实验。实验在三种不同比例的数据集上比较了算法的 mAP 精度值。实验结果如表 3-3 所示。

中国知网　https://www.cnki.net

表 3-3　消融实验结果对比

Model	mAP@50/%		
	5%	10%	20%
YOLOv8	42.2	44.7	59.3
YOLOv8+师生模型	42.7	45.5	60.1
YOLOv8+师生模型+双阈值及损失函数	43.6	46.1	61.2

从表中对比结果可以看出，引入师生模型后的模型相比原模型的 mAP 在不同标注比例的数据集上分别提高了 0.5、0.8、0.8 个百分点，说明该策略对于提高模型性能是有效的，证明了师生模型在模型中的积极作用，说明了通过教师模型对无标注数据预测的伪标签可以在一定程度上提高模型的鲁棒性。继续引入双阈值策略之后，模型在不同比例数据集上分别提高了 0.9、0.6、1.1 个百分点，证明了即使在低置信度下的伪标签也存在有效信息，通过双阈值可以利用更多的伪标签数据来对模型进行更新。如图 3-3 所示，我们可以更加直观地看到不同策略对于模型性能地提升效果。

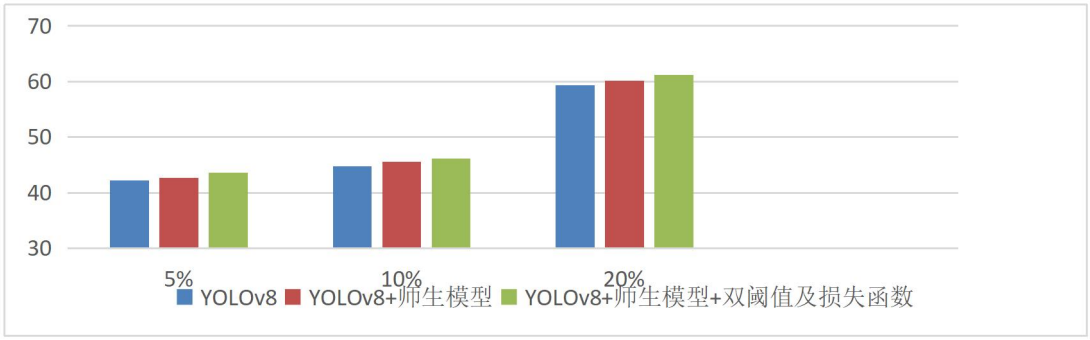


图 3-3　消融实验结果对比

3.3.5　不同半监督目标检测算法比较

为了进一步验证本章算法的有效性，将本章所提出算法与现阶段几种流行的半监督目标检测算法在相同比例数据集上继续对比实验，实验结果如表 3-4 所示。

表 3-4　不同半监督检测算法实验对比

Model	mAP@.5/%		
	5%	10%	20%
STAC	32.1	40.7	56.4

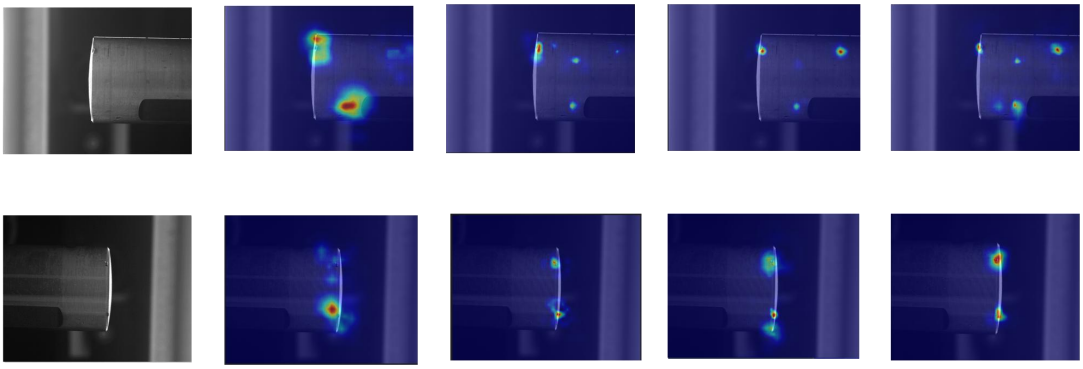
中国知网　https://www.cnki.net

Instant Teaching	37.9	44.1	59.1
Unbiased Teacher v2	38.6	45.2	60.5
Ours	43.6	46.1	61.2

可以看出，本章算法在各个有标注比例数据集上的检测精度均有提升，证明了该算法的先进性。并且相比于标注数据集占比较大的情况，更低比例时本章提出的算法提升更加明显，说明双阈值在保留更多低置信度伪标签的同时，也从这些标签中提取到了更多的特征信息，具有更高的提取效率，更加适合标注数据集缺乏的任务。

3.4 可视化效果

为了进一步验证本章所提出方法的有效性，本节采用 HiResCAM[44]方法对检测结果进行了可视化分析。相比于 Grad-CAM[45]有时会突出显示模型实际上未使用的位置，HiResCAM 保证只突出显示模型用于进行每个预测的位置，能够清晰反应模型的检测效果且具有更强的可解释性。各个模型均使用 10%有标注数据集，其检测结果由图 3-4 所示。



(a)原图 (b)STAC (c)Instant Teaching (d)Unbiased Teacher V2 (e)Ours

图 3-4 HiRes-CAM 热力图可视化结果

由图所知，本章所提出的算法能够准确的聚焦于轴颈缺陷且定位精度较高。

中国知网 https://www.cnki.net

与之相比，Unbiased Teacher V2 和 STAC 的能够有效地关注到缺陷上，但是其定位精度不高，同时存在漏检的情况。而 Instant Teaching 能够将各个缺陷检测出来，但是其标签置信度不高。热力图可视化结果表明，本文提出的基于师生模型的半监督检测在十字轴轴颈缺陷检测中具有良好效果。

3.5 本章小结

本章针对工业环境下某些情况下大量标签数据集获取困难的问题，提出了使用基于 YOLOv8 的半监督学习的特征检测模型。为了利用无标签数据中的信息，首先引入师生模型，负责生成伪标签与训练网络，改善了训练中数据样本缺少的问题；其次，引入了伪标签双阈值扩展，将传统的单阈值置信度筛选扩展为双阈值筛选，将伪标签划分为可靠、不确定以及不可靠三种标签。同时，针对这三种不同质量的伪标签，优化了损失函数，使得损失函数与之对应。增加了在低置信度伪标签中提取信息的能力。实验结果表明，本章所提的半监督算法对十字轴轴颈缺陷检测的检测效果优于其他半监督方法，有效的降低了对标注数据的依赖性。

第 4 章 图像采集平台搭建

4.1 引言

本章分为三个关键步骤，如下图所示。首先，搭建线下实验平台，其中包括各种硬件的选择和配置，以确保图像的顺利采集。其次，设计软件流程，完成对十字轴表面缺陷的自动化采集。最后，对缺陷数据集进行了预处理，最终构建了一个完备的十字轴轴颈缺陷数据集。该平台能够对工件进行自动化采集，后续通过软件能够实现对工件的在线检测。

中国知网 https://www.cnki.net

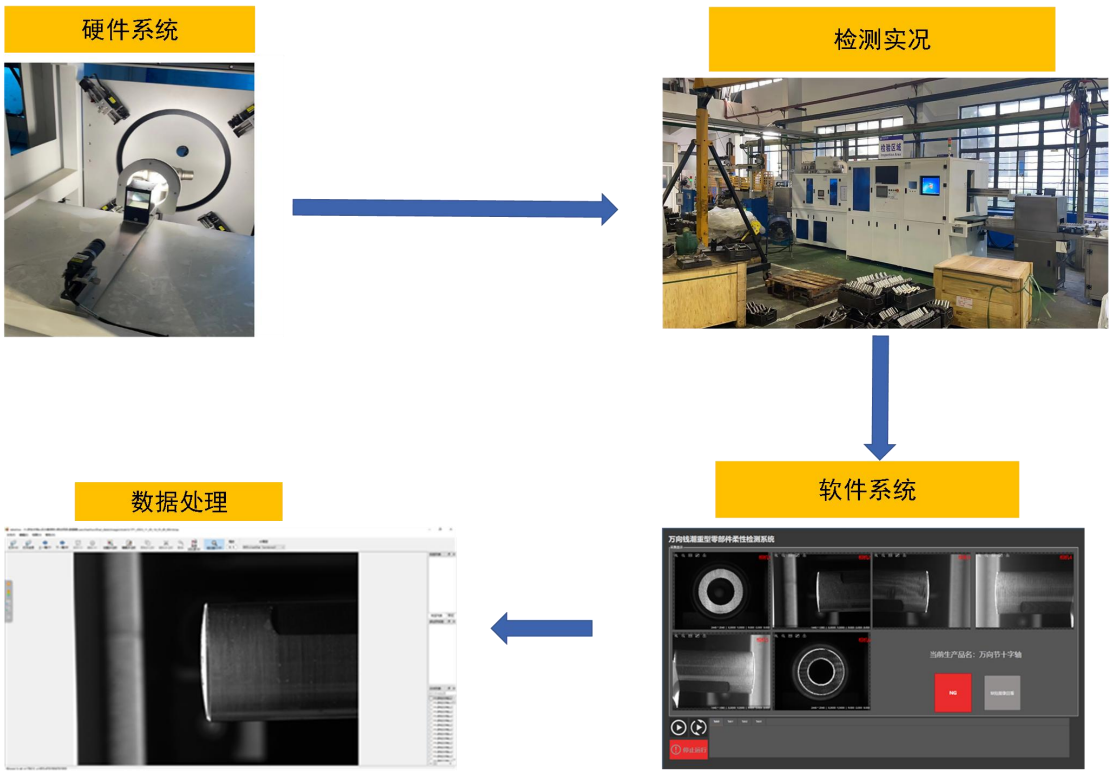


图 4-1 十字轴轴颈图像采集平台

4.2 实验平台搭建

本文所检测的对象为工业十字轴轴颈表面，缺陷可能存在不同尺寸且分布在轴颈的各个位置，因此，视野主镜头主要聚焦在十字轴的轴颈部位。检测过程中，十字轴工件放置在传送带上。到达检测位置后，由机械臂将工件移动到及碗型光源中间，并且旋转拍照，拍照结束后再由机械臂将工件移除，随后重复执行以上步骤。实验过程中，相机、镜头与光源的选择至关重要。因此，在本节中，详细介绍了相机与镜头的选型过程，以保证后续拍摄出高质量的图像。

4.2.1 相机选型

相机作为实验中最重要的组成部分，选型至关重要。工业场景下，存在各种恶劣的工作环境，例如高温、低温、振动、灰尘等。相比于普通相机通常需要稳定的工作环境，工业相机则具有更强的环境适应能力，能够适应更广泛的工作范围。因此，本实验选择工业相机作为采集相机。

根据相机的传感器类型，相机通常分为面阵相机和线阵相机。线阵下降及的感光原件呈线状，只有一行或少数几行感光元素。这种相机在扫描的过程中，每

中国知网 https://www.cnki.net

次只能获取图像的一行或者几行像素信息。因此为了获取完整的二维图像，线阵相机通常需要与运动相机配合，逐行扫描相机表面。相比之下，面阵相机的感光元件呈面状，可以一次性获取二维图像信息，其像素矩阵排列整齐，每个像素点都能够独立地接受光线并转换为电信号，从而生成完整的图像。面阵相机的分辨率通常由像素数量和像素尺寸决定，像素越高，分辨率越高，图像细节越丰富。因此，鉴于本文的检测需求，采用了更适合的面阵相机。

相机的芯片类型答题分为 CCD(Charged Coupled Device)和 CMOS（Complementary Metal-Oxide Semiconductor)两类，两者在成像方面各有优劣，主要区别如下表[46]所示。

表 4-1 CCD、CMOSOS 相机对比一览

CCD	CMOS
受同步时钟控制	光电传感器采集光信号
较慢	较快
较大	较小
技术成熟，画质较高	容易受噪声印象，画质较差
工艺复杂，成本高	集成度高， 成本低
连接复杂度低，解析度高	具有极高的解析度
全局快门	卷帘、全局快门均有

与 CCD 相机相比，CMOS 结构相对简单，并且与现有的大规模集成电路生产工艺相同，从而生产成本比较低。并且两者也有着不同的原理，CMOS 的信号是以点为单位的电荷信号，CCD 则是以行为单位的电流信号。相比来说，CMOS 更为敏感，并且也有更快的速度，更加省点。同时 CMOS 传感器还可以在每个像素基础上进行信号方法，这种方式能够避免任何无效的传输操作，所以只需要少量能量消耗就可以进行快速的数据扫描，同时噪音也有所降低，因此，在机器世界领域具有广泛的应用。

结合上文提出的检测要求，以及上述对相机介绍，本文选择传感器类型为 CMOS 类型的相机。考虑到需要在拍摄清晰的缺陷图片的同时保持良好的计算速

中国知网 https://www.cnki.net

度，本文选择使用 1024×1280 的分辨率。帧率方面，为了达到实时检测的标准，选择 FPS 大于 35 的相机。综上所属，本文选择海康威视 MV-CS016-10GM 型号相机，其相机重要参数如下表所示。

表 4-2 MV-CS016-10GM 相机详细参数

功能	参数
传感器类型	CMOS
传感器型号	IMX296
靶面尺寸	1/2.9”
分辨率	1440 × 1080
最大帧率	65.2fps
快门方式	全局快门
曝光模式	支持自动曝光、手动曝光、一键曝光等模式

4.2.2 镜头选型

在工业视觉任务中，镜头的作用是将工件成像到相机的传感器芯片上，形成图像。因此，镜头的选型至关重要，它直接影响了成像的质量、清晰度和检测的性能。影响工业相机选型的主要参数有焦距、视野、工作距离、分辨率等。

焦距：焦距指从镜头到焦点的距离，通常用毫米表示。焦距越长，镜头方法的程度就越大，视野就越窄，比较适合拍摄近距离物体的细节。而焦距越短，放大的程度就越小，视野就越广，适合拍摄远距离物体。

视野:也称视场范围，指镜头能够拍摄到的范围，通常用水平、垂直或对角线的角度来表示。焦距越长，视野就越窄，只能拍摄到距离物体较远的景物。焦距越短，视野就越广，能够拍摄到较为接近镜头的景物。

工作距离:指被拍摄对象与镜头之间的距离。选择合适的工作距离非常关键，以确保能够捕捉到物体的清晰图像。在拍摄近景物体中，需要较短的焦距和较近的工作距离；在拍摄远景物体时，需要较长的焦距和较远的工作距离。焦距、工作距离、视野范围的数量关系可以以如下公式所示。

$$WD = \frac{F \times f}{L} \tag{4-1}$$

其中，WD 表示工作距离。L 表示相机芯片的尺寸，F 表示视野范围，f 表示

中国知网 https://www.cnki.net

焦距。

分辨率：体现成像系统再现物体或特征细节的能力。高分辨率图像具有更多的细节，可以呈现更多的信息，同时也就需要更多的存储空间以及计算资源。

综上所属，在选择了海康威视 MV-CS016-10GM 型号相机的基础上，结合本文的实际检测场景需求，最后选用的镜头型号为 MVL-HF0624M-10MP 镜头。

4.2.3 光源选择

在视觉系统中，作为直接影响采集图像质量的因素，选择合适的照明方案尤为重要。通过正确选择配置光源。目前工业场景中的光源按其所处的工业和照明方式可以分为条形光源、圆顶光源、环形光源、同轴光源、低角度环光、背光源等。各种光照外观如图 4-2 所示



（a）同轴光源 （b）条形光源 （c）背光源

（d）低角度环光 （e）圆顶光源 （f）环形光源

图 4-2 工业界常用光源

其中，圆顶光源通过将光源安置在一个圆弧状的灯罩内，光线可以均匀的照射在被检测工件的表面。同时，这样的设置可以消除阴影和反射，从而提供均匀柔和的照明，有助于生成高质量的如图像。因此，本实验采用圆顶光源作为实验光源。

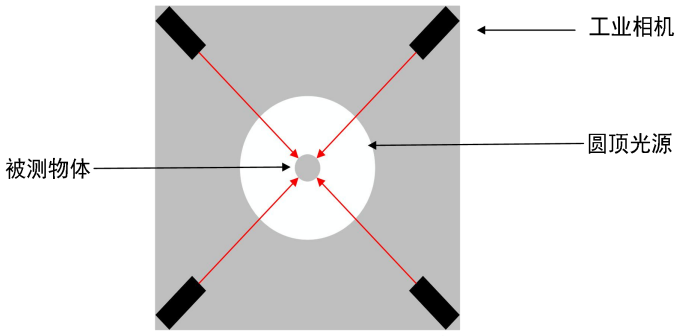
4.2.4 整体硬件平台设计

在选择好关键的硬件之后，本节对整体缺陷检测平台进行了系统行的构建。最终完成了搭建效果如图 4-3 展示。

实验平台由四个摄像头以及圆顶光源组成，设备的机械手通过软件控制。在

中国知网 https://www.cnki.net

完成前期对工件的清洗吹干之后，机械手臂将工件移动到圆顶光源中心。此时，圆顶光打开，提供均匀的照明。然后拍摄平台四个摄像头对工件进行 360 度的拍摄。在一个轴颈拍摄完成，底座进行旋转，将其余的轴颈分别转到光源中心，再次进行拍摄。



（a）圆顶光照明示意图



（b）真实硬件实验平台

图 4-3 光源示意图与真实硬件实验平台

4.3 软件平台搭建

本文采用 Vision Master 算法平台（以下简称 VM）与 PLC 同时控制流水线的运作。VM 算法开发平台是海康机器人自主开发的机器视觉软件，致力于为客户提供快速搭建视觉应用、解决视觉检测难题的算法工具， 能满足视觉定位、尺寸测量、缺陷检测以及信息识别等机器视觉应用。VM 与 PLC 通过 ModBus 协议进行交流，分别对十字轴四个轴颈以及端面进行拍摄。该软件的主界面如图所示：

中国知网 https://www.cnki.net



图 4-4 VM 主界面

在数据采集的过程中，首先启动相机供电，连接到计算机，并进行相机 IP 地址的设置。接下来。由于存在多个相机，VM 与 PLC 通过 Modbus 进行通信，当工件处于不同位置时，PLC 通过设置信号电平的高低，同时 VM 工件位置，VM 控制相机拍摄。具体的通信协议如图 4-5 所示。

4.4 缺陷类别定义以及数据处理

4.4.1 缺陷类别定义

针对十字轴表面缺陷的特点，本文确定了缺肉、划痕、欠加工、倒角和锈斑五种缺陷。下面给出五种缺陷的定义，并且图 4-6 展示了五种缺陷示意图。

（1）缺肉：面积大于 2mm×2mm 的不规则凹坑缺陷

（2）磕碰：面积大于 1mm×1mm，深度 0.5mm 以上的尖锐划痕

（3）锈斑：面积在 1mm×1mm 以上的黑色圆状黑斑

（4）欠加工：面积在 1mm×1mm 以上的螺纹状表面

（5）倒角：轴颈边缘处缺陷

中国知网 https://www.cnki.net

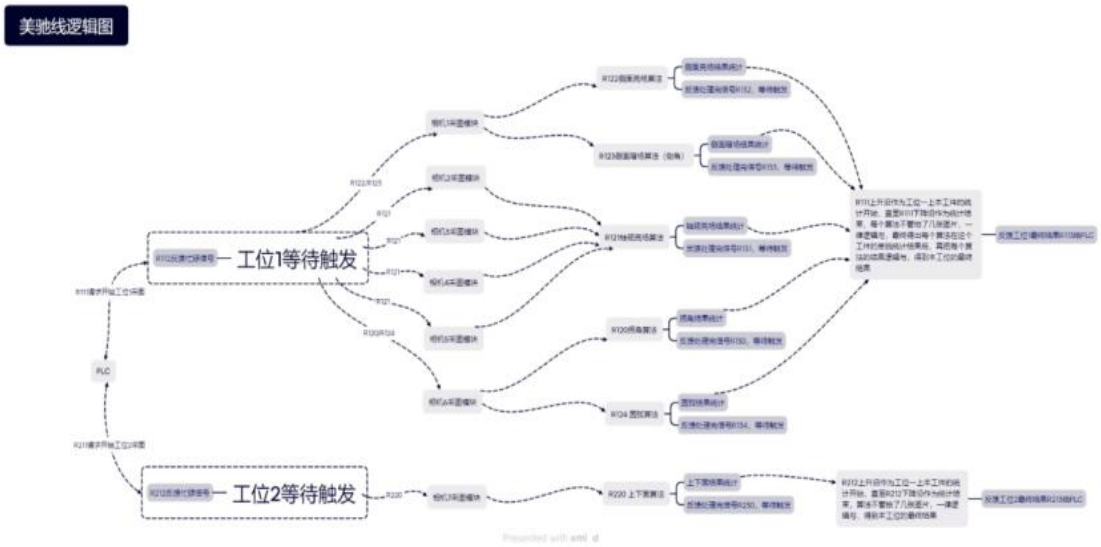


图 4-5 通信协议逻辑图

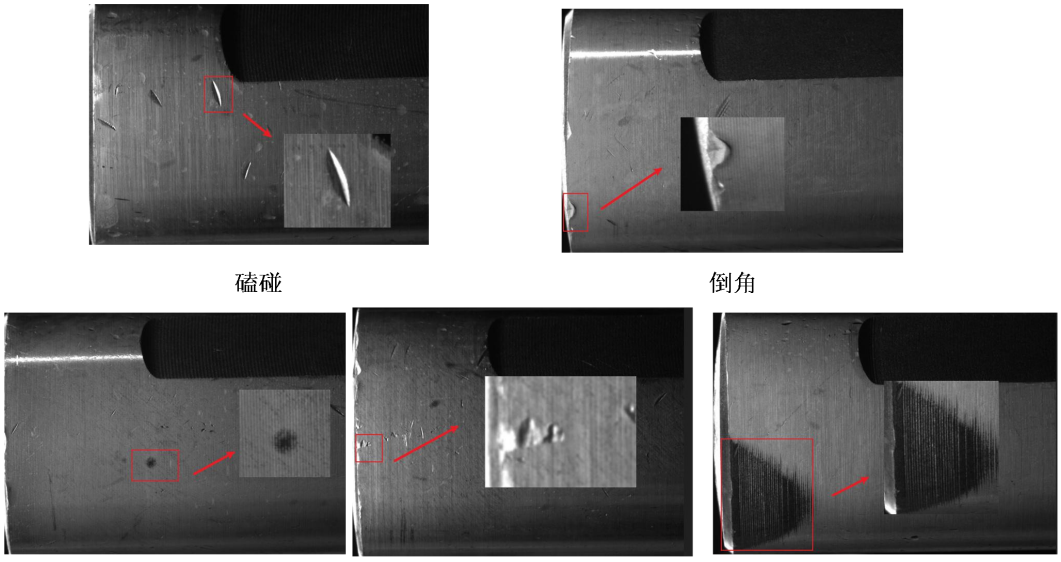


图 4-6 五种缺陷示意图

4.4.2 数据处理

在完成数据采集工作之后，进入数据处理阶段。首先，根据相机位置的不同，拍摄的图像包括十字轴的轴颈以及端面图像。本文选择对十字轴轴颈表面进行拍摄。使用 LabelMe 软件对缺陷部分机型标注，生成相应的 Json 标签，该软件的界面如图 4-7 所示。同时，生成的 Json 标签如图 4-8 所示。

LabelMe 是一个用于图像标注的开源工具，在本文中用于创建训练数据。首

中国知网 https://www.cnki.net

先，通过左上角的“打开目录”按钮打开之前采集的为保住图像，然后在“更改输出路径”选项中设置 Json 标签的保存路径。接下来，为每个类别的缺陷分配名称，并使用标注工具准确绘制缺陷的边界框即可。

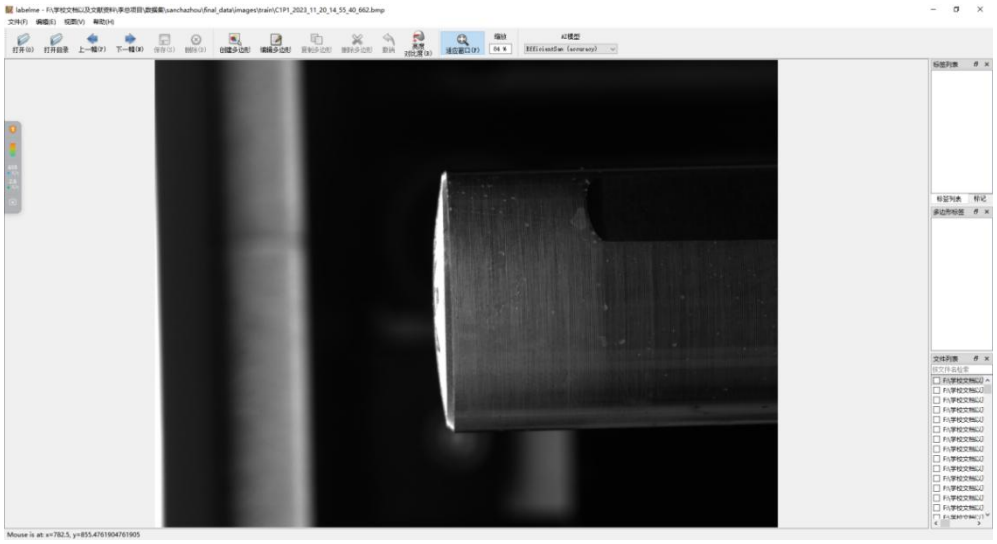


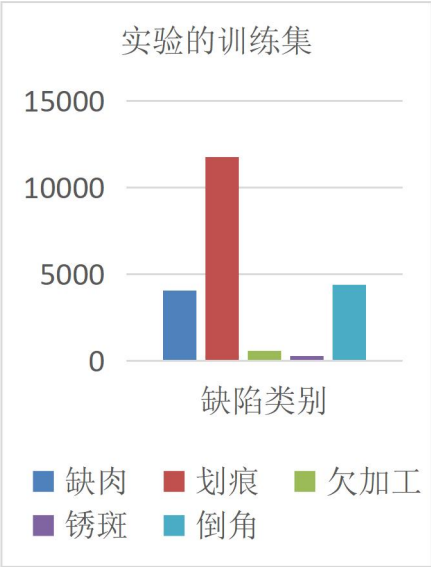
图 4-7 LabelMe 标注示意图



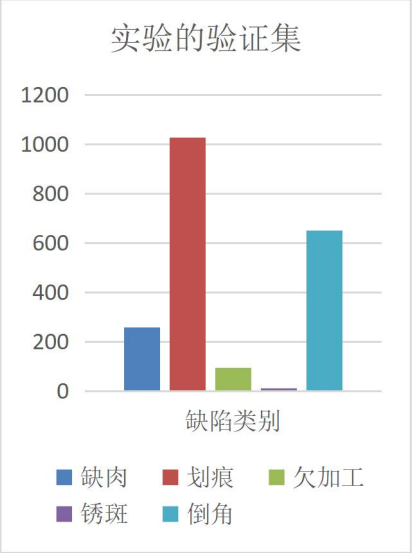
图 4-8 Json 文件标注信息

实验获得十字轴轴颈图片 4800 张，本文将实验数据集按 9:1 划分训练集和验证集。如图 4-9 所示，为本文训练集和验证集中标签框数量分布情况。

中国知网 https://www.cnki.net



(a) 实验训练集类别标签数量分布



(b) 实验验证集类别标签数量分布

图 4-9 实验数据集缺陷类别标签数量分布

4.5 本章小结

本章针对十字轴轴颈缺陷数据的采集设计了一套采集方案，包括硬件平台搭建、软件平台搭建以及数据处理。硬件平台中需要用到的相机、镜头以及光源等器件，本文基于对十字轴轴颈尺寸以及相机、镜头和光源的分析，确定了以 1024×1280 分辨率的海康威视 MV-CS016-10GM 型号相机以及 MVL-HF0624M-10MP 镜头和圆顶光源作为实验研究的最终硬件配置。此外，还通过 Vision Master 以及 PLC 实现了对整合流水线的控制以及相机采集顺序的控制，然后对采集到

中国知网 https://www.cnki.net

的十字轴轴颈缺陷数据进行了标注以便后续的算法测试。

中国知网 https://www.cnki.net

第 5 章 总结与展望

5.1 总结

作为汽车传统系统的重要组成部分，保证十字轴的质量至关重要。本文针对工业环境下十字轴轴颈生产过程中的表面缺陷，本文改进了现有目标检测算法，并针对数据集缺乏的情况下，选择半监督学习模型来实现缺陷检测。本文的主要工作和成果包括以下方面。

（1）针对当前十字轴轴颈公开数据集缺少的情况，本文设计了以 Vision Master 以及 PLC 为控制系统的十字轴表面缺陷采集程序。根据十字轴表面缺陷的种类，建立了缺陷种类为磕碰、缺肉、欠加工、锈斑以及倒角的十字轴轴颈缺陷数据集。该数据集的构建是为了支持本研究的深度学习算法，使其能够在实际工业生产环境中进行有效的缺陷检测和分类，保证十字轴的质量，提高生产效率。

（2）针对现有的目标检测算法对小目标以及复杂背景下检测效果差的问题，本文基于 YOLOv8n 检测模型提出了三点改进策略。首先在特征提取阶段，引入 SPD-Conv 代替传统的下采样方式，以尽量保留通道维度中的信息，从而提高了对小目标缺陷的检测能力。在特征融合阶段，设计了一种新的特征金字塔网络，即聚合传播特征金字塔网络，将特征提取阶段提取的特征传播的全局的各个阶段，减少了多层次特征融合过程中信息的丢失，有助于深层予以和细粒度信息的高效传播。同时，设计了 DyHead-DCNv4 检测头用于识别特征融合部分融合的多尺度信息，增强对尺度、空间位置和任务的感知能力，进一步提升目标检测的精度和鲁棒性。实验结果表明，本文提出的 YOLO-SAD 改进模型相比较改进前，各项指标均有所提升，这说明本文改进的模型对十字轴轴颈检测是有效的。

（3）针对工业数据集在某些情况下标记数据获取成本高的问题，本文提出使用基于半监督学习的十字轴轴颈缺陷检测方法。首先引入师生模型，以对无标签数据继续特征提取，同时实现模型的半监督训练。其次，使用双阈值法替换单阈值筛选，将伪标签分类为可靠、不确定与不可靠三种标签，降低了低质量伪标签对网络训练的负面影响，同时针对三种标签优化了损失函数。结果表明，所提出的半监督模型能够在低置信度的伪标签中提取有用的特征信息，提高了对无标签数据的利用率以及检测性能。

中国知网 https://www.cnki.net

5.2 展望

针对工业十字轴轴颈表面缺陷，本文进行基于全监督和半监督的研究，并提出了相应的改进策略，且都有良好的表现。但由于十字轴表面缺陷的复杂性，仍存在一些困难和挑战需要解决。因此，本文的工作还需要进一步优化和完善。在未来的工作汇总，可以从以下方面进行改进：

(1)十字轴轴颈表面背景复杂，存在许多细微的缺陷以及其他影响缺陷的异物，例如油污、水渍等，这些会影响 YOLO-SAD 的检测效率，导致 Precision 以及 Recall 较低，因此，后续需要对模型进一步改进，以降低异物的影响。

(2)第二章实验表明，YOLO-SAD 算法相比于 YOLOv8n 算法在模型参数量、计算量上均有增加。可能无法适配生产环境中的受限（容量小、计算性能差）设备，因此，后续可以对模型进行轻量化改进，尝试使用剪枝或对模型进行压缩，进一步减少模型的空间占用，提高推理速度。

中国知网 https://www.cnki.net

参 考 文 献

[1] 刘惟信. 汽车车桥设计[M]. 清华大学出版社，2004.

[2] 吴文. 基于深度学习的 ABVS 图像病变检测方法研究[D]. 北京交通大学, 2021.

[3] Zhou X, Belkin M. Semi-supervised Learning by Higher Order Regularization[C]//International Conference on Artificial Intelligence and Statistics. JMLR Workshop and Conference Proceedings, 2011.

[4] Van Engelen J E, Hoos H. A survey on semi-supervised learning[J]. Machine learning, 2020, 109(2): 373-440.

[5] 王晓娟. 压力容器制造中常用无损检测方法与应用[J]. 化工装备技术,2014,35(01):34-36.

[6] HELIFA B, OULHADJ A, BENBELGHIT A, et al. Detection and measurement of surface cracks in ferromagnetic material using eddy current testing[J]. NDT & E International, 2006, 39(5):384-390.

[7] D'ACCARDI E, PALUMBO D, TAMBORRINO R, et al. A Quantitative Comparison among Different Algorithms for Defects Detection on Aluminum with the Pulsed Thermography Technique[J]. Metals, 2018,8(10):859

[8] 刘玮, 李儒彬, 曹蒙, 李融, 王兴强. 无损检测技术在和谐型机车牵引电机C6修中的应用研究[J]. 铁道机车车辆, 2018, 38(02): 100-102.

[9] 刘波. 对于机车车钩钩舌干法磁粉探伤的具体研究[A]. 中国铁道学会材料工艺委员会第五届无损检测学组磁粉、渗透、涡流及射线无损检测学术交流会论文集[C].北京师范大学出版社, 2018:176-182.

[10] Girshick R, Donahue J, Darrell T, et al. Rich Feature Hierarchies for Accurate Object Detection and Semantic Segmentation[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2014:580-587.

[11] Girshick R. Fast r-cnn[C]//ICCV.2015:169.

[12] Ren S, He K, Girshick R, et al. Faster R-CNN: Towards real-time object detection with region proposal networks[J]. IEEE transactions on pattern analysis and machine intelligence, 2016, 39(6): 1137-1149.

[13] Redmon J. You only look once: Unified, real-time object detection[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2

中国知网 https://www.cnki.net

016.

[14] Liu W, Anguelov D, Erhan D, et al. Ssd: Single shot multibox detector[C] //Computer Vision–ECCV 2016: 21-37.

[15] Redmon J, Farhadi A. YOLO9000: Better, Faster, Stronger[J].IEEE, 2017:6 517-6525.

[16] Ioffe S ,Szegedy C. Batch Normalization: Accelerating Deep Network Trai ning by Reducing Internal Covariate Shift[J].arXiv preprint,2015:1502.03167.

[17] Macqueen J B. Some Methods for Classification and Analysis of Multivar iate Observations[J]. 1966.

[18] Redmon J. Yolov3: An incremental improvement[J]. arXiv,2018:1804.0276 7.

[19] Lin T Y, Dollár P, Girshick R, et al. Feature pyramid networks for objec t detection[C]//Proceedings of the IEEE conference on computer vision and patt ern recognition. 2017: 2117-2125.

[20] Chen K, Zeng Z, Yang J. A deep region-based pyramid neural network f or automatic detection and multi-classification of various surface defects of alu minum alloys[J]. Journal of Building Engineering, 2021,43:233-245.

[21] Deng Y, Li W J, Lin S Y, et al. Detection method of water channel def ects in engine block based on deep learning[C]//Journal of Physics: Conference Series. IOP Publishing, 2022,2366(1):12-20.

[22] Guo Z, Wang C, Yang G, et al. Msft-yolo: Improved yolov5 based on tr ansformer for detecting defects of steel surface[J]. Sensors, 2022, 22(9): 3467.

[23] Li Y, Huang H, Xie Q, et al. Research on a surface defect detection algo rithm based on MobileNet-SSD[J]. Applied Sciences,2018, 8(9):16-78.

[24] Koonce B, Koonce B. MobileNetV3[J]. Convolutional Neural Networks wi th Swift for Tensorflow: Image Recognition and Dataset Categorization,2021:12 5-144.

[25] Sohn K, Berthelot D, Carlini N, et al. Fixmatch: Simplifying semi-supervi sed learning with consistency and confidence[J]. Advances in neural informatio n processing systems, 2020, 33: 596-608.

[26] Sohn K, Zhang Z, Li C L, et al. A simple semi-supervised learning fram ework for object detection[J]. arXiv preprint arXiv:2005.04757,2020.

[27] Zhou Q, Yu C, Wang Z, et al. Instant-teaching: An end-to-end semi-super vised object detection framework[C]//Proceedings of the IEEE/CVF conference

中国知网 https://www.cnki.net

on computer vision and pattern recognition. 2021: 4081-4090.

[28] Liu Y C, Ma C Y, He Z, et al. Unbiased teacher for semi-supervised obj ect detection[J]. arXiv:2102.09480,2021.

[29] Xu M, Zhang Z, Hu H, et al. End-to-end semi-supervised object detection with soft teacher[C]//Proceedings of the IEEE/CVF international conference on computer vision.2021:3060-3069.

[30] 孙慧平. 汽车十字轴视觉检测系统的研究[J]. 汽车零部件, 2013(10): 44-46.

[31] Li B, Gao Q. Defect Detection for Metal Shaft Surfaces Based on an Im proved YOLOv5 Algorithm and Transfer Learning[J]. Sensors, 2023, 23(7): 376 1.

[32] 淡卫波. 基于深度学习的十字轴表面缺陷检测算法研究[硕士学位论文][D]. 杭州:浙江科技大学,2022.

[33] HE K, ZHANG X, REN S,et al.Spatial Pyramid Pooling in Deep Convolu tional Networks for Visual Recognition[J].IEEE Transactions on Pattern Analysi s & Machine Intelligence, 2014, 37(9):1904-16.

[34] Liu S, Qi L, Qin H, et al. Path aggregation network for instance segment ation[C]//Proceedings of the IEEE conference on computer vision and pattern re cognition. 2018: 8759-8768.

[35] SUNKARA R, LUO T. No more strided convolutions or pooling: A new CNN building block for low-resolution images and small objects[C]//Joint Euro pean conference on machine learning and knowledge discovery in databases.Ch am: Springer Nature Switzerland,2022:443-459.

[36] JIANG Y, TAN Z, WANG J,et al.GiraffeDet: A Heavy-Neck Paradigm fo r Object Detection[J].arXiv:2202.42-56.

[37] SZEGEDY C, VANHOUCKE V, IoffeS,et al.Rethinking the Inception Arc hitecture for Computer Vision[C]//Proceedings of the IEEE conference on comp uter vision and pattern recognition.2016:2818-2826.

[38] YU W, ZHOU P,YAN S,et al.InceptionNeXt:When inception meets convne xt[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Patter n Recognition. 2024: 56

[39] DAI X, CHEN Y, XIAO B, et al. Dynamic head: unifying object detectio n heads with attentions[C]//Proceedings of the IEEE/CVF Conference on Comp uter Vision and Pattern Prcognition,2021:7373-7382

中国知网 https://www.cnki.net

[40] XIONG Y, LI Z, CHEN Y, WANG F,et al. Efficient deformable concvnets:rethinking dynamic and sparse operator for vision application[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition.2024:5652-5661.

[41] WANG C Y, BOCHKOVSKIY A, LIAOH Y M. YOLOv7: trainable bag-of-freebies set new state-of-art for real time object detectors[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition.2023:7464-7475.

[42] Hinton G, Vinyals O, Dean J. Distilling the Knowledge in a Neural Network[J]. Computer Science, 2015, 14(7):38-39.

[43] Zheng Z, Wang P, Liu W, et al. Distance-IoU loss: Faster and better learning for bounding box regression[C]//Proceedings of the AAAI conference on artificial intelligence. 2020, 34(07): 12993-13000.

[44] Draelos, Rachel Lea, et al. Use HiResCAM instead of Grad-CAM for faithful explanations of convolutional neural networks.[C]//arXiv:20021.08891,2020

[45] Selvaraju, Ramprasaath R, et al. Grad-CAM: Visual explanations from deep networks via gradient-based localization.[C]//Proceedings of the IEEE international conference on computer vision. 2017.

[46] 冯增卓.视频监控系统中高清 CCD 和 CMOS 传感器技术特点的研究[J].农家参谋,2020(24).

中国知网 https://www.cnki.net