分类号：TP241.3　　单位代码：11057
密　级：非保密　　学　　号：222101855083

浙江科技大學
ZHEJIANG UNIVERSITY OF SCIENCE & TECHNOLOGY

硕士学位论文

论文题目：基于图像增强和 YOLO 算法的复杂场景车辆检测改进

作　　者： 张张详

指导教师： 陈宁教授

学科专业： 机械

二级学院： 机械与能源工程学院

提交日期 2024 年 12 月

中国知网　https://www.cnki.net

A Thesis Submitted to
Zhejiang University of Science and Technology for
Master's Degree

Dissertation Title Improvement of Vehicle Detection in Complex Scenes Based on Image Enhancement and YOLO Algorithm

Candidate: Zhang Zhangxiang
Supervisor: Chen Ning

Zhejiang University of Science and Technology
Hangzhou China
December 2024

中国知网 https://www.cnki.net

浙江科技大學
ZHEJIANG UNIVERSITY OF SCIENCE & TECHNOLOGY

基于图像增强和YOLO算法的复杂场景车辆检测改进

论文作者签名:_____

指导教师签名:_____

论文评阅人 1：_____

评阅人 2：_____

评阅人 3：_____

评阅人 4：_____

评阅人 5：_____

答辩委员会主席：董红召\教授\浙江工业大学

委员 1：何令华\高级工程师\浙江微松冷链科技有限公司

委员 2：吴坚\教授\浙江科技大学

委员 3：白冰\副教授\浙江科技大学

委员 4：翁卫兵\副教授\浙江科技大学

答辩日期：2024 年 12 月 2 日

中国知网 https://www.cnki.net

浙江科技大學
ZHEJIANG UNIVERSITY OF SCIENCE & TECHNOLOGY

Improvement of Vehicle Detection in Complex Scenes Based on Image Enhancement and YOLO Algorithm

Candidate's signature:_____

Supervisor's signature:_____

Thesis reviewer 1：_____

Thesis reviewer 2：_____

Thesis reviewer 3：_____

Thesis reviewer 4：_____

Thesis reviewer 5：_____

Chair： Dong Hongzhao/Professor/Zhejiang University of Technology

Committeeman1： He Linghua/Senior Engineer/Zhejiang Weisong Cold Chain Technology Co., Ltd

Committeeman2： Wu Jian/Professor/Zhejiang University of Science and Technology

Committeeman3： Bai Bing/Associate Professor/Zhejiang University of Science and Technology

Committeeman4： Weng Weibing/Associate Professor/Zhejiang University of Science and Technology

Date of oral defence： 2024.12.2

中国知网 https://www.cnki.net

摘　要

随着自动驾驶技术的快速发展，车辆检测在复杂环境（如低光照、雨天等恶劣天气条件）下的精度问题成为当前领域的关键挑战之一。雨天时，雨滴附着在摄像头镜头上导致图像模糊，显著降低了检测准确性；在低光环境下，车辆图像中的噪声和光晕干扰也会严重影响车辆识别效果。此外，现有的目标检测算法（例如 YOLOv8）尽管在实时性上有较大优势，但在应对远距离、部分遮挡车辆以及复杂背景时，漏检和误检现象依然严重。为了解决这些问题，本文提出了多项创新性改进：

（1）针对雨滴附着导致的图像模糊问题，设计了一种基于生成对抗网络（GAN）的去雨算法。通过引入 Inception 模块和卷积块注意力机制，模型能够在保留图像多尺度细节的同时，减少计算复杂度和网络参数量，显著提升去雨效果。实验结果显示，该算法在标准测试集上的峰值信噪比（PSNR）达到了 32.68 dB，结构相似性指数（SSIM）为 0.941，均优于主流去雨算法。

（2）针对低光环境下车辆图像质量较差的问题，提出了一种改进的光照自适应校正算法。通过 V 通道照度信息提取和自适应伽马校正函数，结合导向滤波和残差图的加权融合，显著提高了图像的亮度和对比度，实验表明，PSNR 提升至 32.85 dB，SSIM 为 0.938，显著优于改进前算法。

（3）为解决复杂场景下检测性能不足的问题，本文提出了改进的 DB-YOLOv8 算法，结合 ECA 注意力模块与双向特征金字塔，增强了对远距离及部分遮挡车辆的检测精度。此外，通过 DCN 与 Focal-EIOU 损失函数优化模型的定位精度，实验表明，改进后的算法定位精度较改进前模型提升约 8%，漏检和误检率显著降低。

（4）本文将轻量化后的 DB-YOLOv8 算法成功部署到嵌入式设备树莓派 4B 上，结合 MobileNetV3 和 GSConv 模块进行优化，借助 OpenVINO 框架和 Intel NCS2 神经计算棒，加速了推理速度，实现了在资源受限环境下的准确检测。

关键词： 深度学习，恶劣环境，图像增强，车辆识别，树莓派

中国知网 https://www.cnki.net

Abstract

With the rapid development of autonomous driving technology, the accuracy of vehicle detection in complex environments (such as low-light, rainy, and other adverse weather conditions) has become a major challenge in the field. In rainy conditions, raindrops adhering to camera lenses can cause image blurring, significantly reducing detection accuracy. In low-light environments, noise and glare in vehicle images also severely affect recognition performance. In addition, existing object detection algorithms, such as YOLOv8, though advantageous in real-time performance, still suffer from significant false positives and false negatives when dealing with long-distance, partially occluded vehicles and complex backgrounds. While YOLOv9, YOLOv10, and YOLOv11 have made optimizations over YOLOv8, detection accuracy in complex environments remains to be improved. To address these issues, this paper proposes several innovative improvements:

(1) A rain-removal algorithm based on Generative Adversarial Networks (GAN) is designed to tackle the image blurring caused by raindrops. By introducing the Inception module and Convolutional Block Attention Mechanism (CBAM), the model preserves multi-scale image details while reducing computational complexity and network parameters, significantly enhancing rain-removal performance. Experimental results show that the algorithm achieved a Peak Signal-to-Noise Ratio (PSNR) of 32.68 dB and a Structural Similarity Index (SSIM) of 0.941 on standard test sets, outperforming mainstream rain-removal algorithms.

(2) To address the issue of poor image quality in low-light environments, an improved illumination adaptive correction algorithm is proposed. Through V-channel illumination extraction and adaptive gamma correction, combined with guided filtering and weighted fusion of residual maps, the brightness and contrast of images are significantly enhanced. Experimental results show that PSNR improved to 32.85 dB and SSIM reached 0.938, significantly outperforming baseline algorithms.

(3) To solve the problem of underperformance in complex scenes, this paper proposes an improved DB-YOLOv8 algorithm, incorporating ECA attention

中国知网 https://www.cnki.net

mechanisms and a bi-directional feature pyramid network (BiFPN) to enhance the detection accuracy of long-distance and partially occluded vehicles. Additionally, by optimizing the model's localization accuracy using DCN and Focal-EIOU loss functions, experiments demonstrate that the improved algorithm achieved an approximately 8% increase in localization accuracy compared to the baseline model, with a significant reduction in false positives and false negatives.

(4) The lightweight DB-YOLOv8 algorithm was successfully deployed on the embedded device Raspberry Pi 4B. Combined with the optimization of MobileNetV3 and GSConv modules and utilizing the OpenVINO framework and Intel NCS2 Neural Compute Stick, inference speed was accelerated, enabling accurate detection in resource-constrained environments.

Key words: Deep Learning, Adverse Conditions, Image Enhancement, Vehicle Recognition

中国知网 https://www.cnki.net

目　录

第 1 章 绪论.....1
1.1 课题研究背景及意义.....1
1.2 国内外研究现状.....2
1.2.1 基于单幅图像的去雨研究现状.....2
1.2.2 基于 Retinex 的图像增强研究现状.....4
1.2.3 车辆检测国内外研究现状.....4
1.3 研究内容.....6
第 2 章 改进的单幅图像雨滴去除模型.....8
2.1 GAN 算法的基本原理及网络结构.....8
2.2 改进的生成网络结构.....10
2.3 生成器网络改进.....11
2.3.1 Inception 模块的引入.....11
2.3.2 ResNet 的引入.....11
2.3.3 注意力机制引用.....12
2.4 判别网络结构改进.....15
2.5 实验结果与分析.....16
2.5.1 数据集和实验细节.....16
2.5.2 评价指标.....17
2.5.3 不同算法的去雨滴性能比较.....18
2.5.4 消融实验结果分析.....19
第 3 章 夜间道路图像增强算法.....22
3.1 MSR 算法理论概述.....22
3.2 MSR 算法的不足与局限性分析.....22
3.3 改进的算法设计.....25
3.3.1 照度与反射分量的分离与处理.....25
3.3.2 自适应伽马校正的亮度调整.....26
3.3.3 自适应融合加权的反射分量优化.....30
3.4 改进的自适应伽马校正与 MSR 算法框架.....32
3.5 实验结果及分析.....33
3.5.1 实验结果主观分析.....33
3.5.2 实验结果客观分析.....35
第 4 章 复杂环境车辆识别算法改进.....37
4.1 搭建车辆检测系统.....37
4.2 YOLOv8 模型.....38

中国知网 https://www.cnki.net

4.3 YOLOv8 算法改进.....39
4.3.1 引入可变性卷积.....40
4.3.2 加入通道注意力.....41
4.3.3 改进的多尺度检测和加强特征融合.....43
4.3.4 优化边界框损失函数.....44
4.4 实验及仿真结果.....47
4.4.1 DB-YOLOv8 的结构说明.....47
4.4.2 数据集.....47
4.4.3 实验环境与评价指标.....48
4.4.4 改进 DB-YOLOv8 网络的训练.....49
4.5 图像增强算法有效性实验.....50
4.6 消融实验.....51
4.7 对比试验.....52
4.8 可视化结果对比.....53
4.9 本章小结.....55
第 5 章 算法在树莓派上的部署与实现.....56
5.1 DB-YOLOv8 算法轻量化.....56
5.1.1 轻量化车辆检测算法.....56
5.1.2 对比试验.....58
5.1.3 消融实验.....58
5.2 嵌入式设备选择.....61
5.3 树莓派构建深度学习环境.....63
5.4 测试结果与分析.....64
5.5 本章小结.....65
第 6 章 总结与展望.....66
6.1 总结.....66
6.2 展望.....66
参考文献.....68

中国知网 https://www.cnki.net

第 1 章 绪论

1.1 课题研究背景及意义

近年来随着我国道路交通和机动车数量的快速增长，截至 2024 年，我国机动车已达 4.4 亿辆[1]。虽然这一增长促进了物流业和公共交通等行业的繁荣，但也带来了严峻的交通安全挑战。根据交通部门的统计数据，每年因交通事故死亡的人数超过数十万，且夜间事故的发生频率比白天高出约 1.8 倍[2]。这一现象突显了在光线不足条件下行车安全的重要性，尤其是智能驾驶在复杂环境中，前方车辆状态的精准检测已成为科研人员的重点研究方向。

车辆检测技术是智能交通系统的关键组成部分，其检测的准确性直接关系到行车安全与系统整体性能的优劣。传统的车辆检测方法，例如 Haar 级联分类器[3]、可变形部件模型[4]，虽然在一些应用场景下具有一定效果，但在夜间或恶劣天气条件下表现不佳。例如，Haar 级联分类器依赖于预定义的特征，容易受到光照变化的干扰；DPM 在遮挡条件下表现较好，但其计算复杂度高，难以满足实时应用的需求。

夜间行车时，低光照导致图像对比度下降和边缘模糊，使得车辆检测的难度大大增加；而在雨天，快速下落的雨滴不仅会在摄像头捕捉的图像中形成雨纹，甚至可能产生雨雾效应，进一步降低图像清晰度。这些因素严重干扰了传统基于图像特征提取和目标跟踪的算法，导致车辆检测和智能监控系统的性能下降。为应对这些挑战，近年来图像增强技术与卷积神经网络（CNN）的结合逐渐成为研究热点。图像增强技术能够通过提升图像的亮度和对比度，改善低光照环境下的图像质量；GAN 则被用于雨天场景下的图像去雨处理，能够有效去除雨滴干扰，恢复清晰的图像。这些技术结合 CNN 模型自动学习图像特征的能力，使得在复杂环境下的车辆检测精度显著提升。

尽管深度学习方法在车辆检测领域取得了显著进展，夜间和雨天等复杂场景依然对模型的识别准确性提出了挑战。例如，低光照条件下的模型识别准确性仍有待提升，雨滴的遮挡也可能导致漏检或误检现象。因此，进一步探索将图像增强技术与深度学习模型有机结合，以提高车辆检测系统在复杂环境下的

中国知网 https://www.cnki.net

稳健性和适应性，对于确保行车安全、减少交通事故以及推动自动驾驶技术的发展具有重要意义。

1.2 国内外研究现状

1.2.1 基于单幅图像的去雨研究现状

由于单幅图像缺乏时间信息，这对模型的建模能力提出了更高的要求。目前，图像去雨技术主要分为两大类：基于先验知识和卷积神经网络（CNN）的去雨方法。

（1）基于先验知识的方法：

Kim 等人[5]提出了一种利用非局部均值滤波去除雨滴的方法，通过分析像素的旋转角度和椭圆核纵横比来定位雨线，并结合邻域像素和自适应权重进行滤波。Zhu 等人[6]通过将图像分解为无雨的背景层 B 和雨线层 R，利用先验信息（如稀疏表示和雨水方向估计）去除雨线，同时通过联合训练消除 B 层中的雨线细节和 R 层中的非雨线细节。Zhang 等人[7]提出了一种卷积编码去雨算法，利用通用卷积滤波器和稀疏与低秩表示分别处理背景和雨线，直接对整幅图像进行操作，无需分块处理。Li 等人[8]则提出了一种基于高斯混合模型的先验方法，该方法可适应不同方向和尺度的雨线。总体而言，基于先验知识的方法虽然计算速度较快，但容易导致图像过度平滑，损失高频信息。

（2）基于卷积神经网络（CNN）的方法：

随着 CNN 的迅速发展，研究人员越来越多地使用其来处理单幅图像的去雨问题。传统的先验知识方法常会导致去雨后雨痕残留或图像过度平滑，进而丢失高频细节。相比之下，CNN 的应用为解决这些问题带来了新的思路。Fu 等人[9]提出了一种名为 DerainNet 的深度神经网络，通过学习雨天图像与无雨图像的映射来实现去雨效果。该方法先使用引导滤波器将图像分为高频和低频层，并主要在高频细节层上进行训练，从而更有效地处理雨滴信息。谷腾飞等人[10]提出了一种基于长短期记忆模块（LSTM）的递归网络图像去雨算法。该算法结合卷积块、残差块和 LSTM，通过多层递归去除雨滴，并使用注意力融合模块增强对雨纹特征的提取效果。刘忠洋等人[11]提出了一种基于注意力机制的多尺度特征融合图像去雨方法。该方法通过多尺度注意力残差模块提取不同尺度的

中国知网 https://www.cnki.net

雨纹特征，利用局部和全局特征融合模块增强去雨效果，并通过坐标注意力和像素注意力进一步优化图像细节。刘越等人[12]提出了一种基于生成对抗网络的去雨算法，通过多尺度残差网络和卷积门控循环单元来检测并去除图像中的雨滴，在处理不同大小和形状的雨滴时表现出色。Wang 等人[13]提出了一种可训练的感知损失函数，能够捕捉像素误差和视觉特征差异，在去雨和去噪任务中表现优异。Zheng 等人[14]提出了多尺度密度感知网络，通过多尺度特征提取应对不同雨滴密度对图像维度和特征的影响，能够有效处理复杂的雨滴场景。Li 等人[15]提出了一种基于注意力机制的去雨生成对抗网络技术，增强了网络对雨滴区域的感知能力，尤其在雨滴较大或分布密集的情况下，去雨效果显著提升。Sun 等人[16]采用局部注意力机制处理雨痕密集区域，并提出了 RainNet 模型，该模型通过增强局部注意力的方式，有效处理了雨痕集中的区域。Chen 等人[17]提出了多尺度残差生成对抗网络，通过多尺度残差结构提升了模型在复杂雨滴场景中的处理能力，尤其在大范围雨滴问题上表现出色。Xu 等人[18]提出了一种多尺度注意力残差密集网络，用于单张图像的去雨处理。该方法结合了多尺度特征提取、注意力机制和残差密集连接结构，能够更好地去除雨滴，同时保留图像的细节信息。Chen 等人[19]提出的 CycleGAN 模型通过无监督学习解决了不需要成对训练数据的问题，尤其在没有配对样本的情况下，极大提升了图像去雨的效果。Wang 等人[20]提出了 Mask-DerainGAN，通过在生成网络中引入深度卷积层，能够更好地处理细雨和雨痕问题，并且在去除雨滴的同时保留了图像的细节和清晰度。Qian 等人[21]的方法展示了 GAN 在不同密度和形态雨滴场景中的泛化能力，提升了其在复杂场景下的去雨效果。

以上可以得知近几年 GAN 在图像去雨任务中得到了广泛应用，并取得了显著进展。是因为 GAN 通过生成器和判别器之间的博弈，能够生成高质量且接近真实的图像。尽管基于 GAN 的去雨方法在处理复杂场景中取得了显著进展，但仍存在一些不足之处。现有的 GAN 去雨方法在处理高维度数据和雨滴分布不均的场景时，容易出现细节丢失的问题，尤其是在处理小雨滴或雨痕时，模型对细微特征的捕捉能力较弱。此外，由于 GAN 的网络结构复杂，计算负担较大，处理速度较慢，因此如何在提升去雨效果的同时减少计算复杂度，仍是需要解决的重要问题

中国知网 https://www.cnki.net

1.2.2 基于 Retinex 的图像增强研究现状

Retinex 理论最早由 Edwin Land 在 20 世纪 70 年代提出，用于解释颜色恒常性现象[22]。这一理论通过模拟人类视觉系统，提出图像的光照与物体固有属性共同决定图像的观测。基于此理论，逐渐发展出了一系列图像增强，如单尺度 Retinex（SSR）、多尺度 Retinex（MSR）以及带颜色恢算法复的多尺度 Retinex（MSRCR），广泛应用于低光照图像的增强[23]。这些算法在提升图像对比度和颜色恒常性方面取得了显著进展，应用领域从低光照扩展到雾天、雨天及水下等复杂场景。Xiao 等人[24]提出通过色调映射对图像照明进行调整，增强了图像保真度，使其更加自然。Kimmel 等人[25]提出的变分 Retinex 模型，通过优化光照和反射估计，显著提升了图像质量，但其计算复杂度较高。为了解决此问题，Park 等人[26]提出了自适应低光增强方法，通过空间权值映射实现了去噪和纹理保留的平衡。Chang 等人[27]通过高斯加权双边滤波技术减少了增强过程中的光晕效应，并有效抑制了暗区的噪声。Fu等人[28]优化了Retinex模型的病态问题，通过交替方向乘子法和概率模型提高了光照和反射的估计。李福文等人[29]提出将 RGB 颜色空间转化为 HSV 空间，并仅对亮度通道进行增强，降低了计算复杂性，保留了图像的颜色属性。Gianini 等人[30]提出了基于马尔科夫随机链的 Retinex 模型，增强了图像与人眼视觉一致性。Ma 等人[31]结合引导滤波和高斯滤波，进一步提升了图像边缘与细节的保留效果。Cai 等人[32]提出的 Retinexformer 模型，利用 Transformer 框架结合照明引导模块，减少了低光照下的噪声。Xu 等人[33]引入梯度图和拉普拉斯正则化器，改善了去噪与增强效果。Chen 等人[34]提出的多尺度卷积神经网络（MSCNN）在复杂光照场景下显著提升了图像细节保留与增强的效果。

这些基于 Retinex 的改进方法在低光照条件下表现优异，但在处理复杂场景时仍存在不足。例如，极端光照下可能会引发色彩失真或过度增强。在不同场景中，模型的泛化能力不够强，尤其在极暗环境下，难以准确建模光照与反射信息。在增强图像亮度的过程中，细节丢失或噪声引入依然是一个挑战。

1.2.3 车辆检测国内外研究现状

车辆检测是计算机视觉领域中的一项重要任务，其目标是自动从图像或视频中识别并定位车辆的位置和大小。该任务应用广泛，不仅涵盖交通流量监测，

中国知网 https://www.cnki.net

还包括自动驾驶、智能交通系统等多个领域，具有巨大的发展前景。

车辆检测的挑战在于不同环境下的复杂性，如光照变化、遮挡、背景干扰等。但是检测算法的实时性和精确度也非常重要，因为这些因素直接影响自动驾驶和交通监控系统的安全性和可靠性。

近几年基于深度学习的车辆检测技术，特别是 CNN 的应用，取得了显著的进展。通过自动提取图像中的多层次特征，这些方法大幅提升了检测的精度和鲁棒性。早期的传统车辆检测方法，如背景建模、特征提取与分类、模板匹配、边缘检测等[35-38]，在一定程度上可以完成检测任务，但由于依赖于手工设计的特征，在应对环境变化、目标遮挡和复杂背景时，检测准确度和鲁棒性均不理想。与传统方法相比，深度学习模型能通过 CNN 自动提取图像的多层次特征，在处理复杂交通场景中表现出更强的泛化能力。目前车辆检测算法主要分为两类：一阶段目标检测器和二阶段目标检测器。二阶段检测器，如 R-CNN 及其变体（Fast R-CNN、Faster R-CNN）[39-41]，在精度上表现优异，但其计算复杂度较高，无法满足实时性要求。相对而言，YOLO 系列和 SSD 等一阶段目标检测器在检测速度方面具有优势，但在小目标检测、遮挡和复杂光照条件下存在一定局限。

为应对这些局限性，研究者们对 YOLO 和 SSD 模型进行了多项优化。Wang 等[42]通过在 YOLOv7 中引入 Mobilenetv3 骨干网络和高分辨率特征金字塔结构，部分解决了隐藏行人漏检的问题。Li 等[43]通过改进非极大值抑制（NMS）技术，提升了高度重叠场景下目标的检测精度。刘晶等[44]通过归一化通道注意力机制，提升了 YOLOv7 对小目标的识别能力。而刘丽等[45]则通过使用 FAS_C2f 模块优化了模型的参数量和计算量，使其在保持高效特征提取的同时，降低了复杂度。

在 YOLOv8 的研究上，刘浩翰等[46]通过优化 YOLOv7-tiny 模型，增强了其泛化能力；周飞等[47]通过引入基于相似性的注意力机制（SIMAM）并替换 YOLOv8 的骨干网络，提升了检测精度与速度。张利丰等[48]提出了 RBT-YOLO，减小模型体积的同时，保持了优秀的检测性能。Zheng 等[49]针对全景图像中的小目标检测进行了优化，显著提升了检测准确性。Niu 等[50]通过上下文引导的深度残差学习技术，增强了 YOLOv8-CGRNet 在复杂环境中的表现。Liu 等[51]通过级联融合策略改进了 YOLOv8n，在小目标的语义和位置信息识别方面取得了

中国知网 https://www.cnki.net

显著进展。Li 等[52]则通过整合 BIFPN 和 SimAM 模块，进一步提高了 YOLOv8 在小目标检测上的精度和特征表现能力。Adegbola 等人[53]在 YOLOv9 模型中采用了轻量化设计，通过减少网络层数和参数量，优化了小目标检测的性能。李琳等人[54]提出了一种结合 Haar 小波下采样优化 YOLOv9 的道路车辆和行人检测算法，通过小波变换保留图像细节信息，进一步提升了小目标检测的精度。Zhou 等人[55]提出的 YOLOv10 模型采用了新的特征融合策略，结合跨层特征连接和双向特征金字塔网络，显著提升了检测速度和精度。申静等人[56]通过优化特征融合和引入多尺度检测，进一步提高了 YOLOv10s 在车辆与行人检测中的精度和速度，但在小目标和复杂遮挡场景下，模型的鲁棒性仍有改进空间。黄毅等人[57]针对无人机的复杂背景检测，在 YOLOv10 提出了一种多尺度检测模型，优化了轻量级网络结构和小目标检测头，提升了检测性能。Chen 等人[58]提出的 YOLOv11 模型结合了多任务学习的框架，提升了模型在复杂场景下的泛化能力，通过联合训练分类、检测和分割任务，使模型在多个任务上表现良好。

这些研究在车辆检测领域取得了长足进展，但仍然存在若干问题亟待解决。当前的改进大多集中在速度和精度的提升，但在复杂天气条件（如雨天）和极端光照条件（如低光照）下的鲁棒性仍有待加强。虽然部分研究针对小目标检测进行了优化，但在目标遮挡、高背景噪声等复杂场景中，模型的检测精度仍不够理想。模型的参数复杂度和计算效率之间仍存在难以平衡的问题，尤其是在资源有限的嵌入式系统或边缘设备上实现实时检测时。这些问题为未来车辆检测技术的发展指明了方向，需要进一步优化去雨、低光照增强技术，以及结合深度学习的改进模型，以提高模型在复杂场景下的综合表现。

1.3 研究内容

第一章：绪论，本章首先介绍了论文的研究背景与意义，讨论了随着道路交通和机动车数量增长所带来的交通安全问题。接着本文回顾了单幅雨滴去除、低光照图像增强及车辆识别技术的发展历程与现状，分析了这些技术在夜间和恶劣天气条件下所面临的挑战。传统车辆检测方法在复杂环境中往往表现出精度不足，因此，本文旨在通过结合深度学习算法和图像增强技术，提升车辆识别在复杂环境下的性能。

中国知网 https://www.cnki.net

第二章：在探索恶劣环境下车辆检测的图像增强技术时，本文采用了多种创新方法以应对雨天和低光照条件带来的挑战。针对雨天图像中的雨滴干扰问题，提出了一种基于生成对抗网络（GAN）改进的去雨模型。该模型通过引入先进的生成与判别机制，能够精准地识别并去除图像中的雨滴，从而恢复图像的清晰度和细节，为雨天场景下的车辆检测提供了更为可靠的图像输入。

第三章：为了改善低光照条件下的图像质量，本文提出了一种基于改进 Retinex 理论的低光照图像增强模型。该模型利用 Retinex 理论的优势，通过优化光照分量的处理，显著提升了图像的亮度和对比度，使车辆特征在昏暗环境中也能得到清晰呈现。

第四章：复杂环境下的车辆识别算法改进，本章详细介绍了 DB-YOLOv8 模型的优化与改进。本文通过引入多项技术创新，包括可变形卷积网络（DCN）、高效通道注意力机制（ECA）、双向特征金字塔网络（BiFPN）以及 Focal-EIOU 损失函数，显著提升了 YOLOv8 模型在复杂场景下的检测精度，尤其是在光线变化较大或存在遮挡的情况下。实验结果表明，改进后的 DB-YOLOv8 模型在多个评估指标上均优于主流车辆识别模型，展现了更强的鲁棒性和泛化能力。

第五章：算法在树莓派上的部署与实现，本章重点介绍了如何将改进后的 DB-YOLOv8 算法成功部署在嵌入式设备上，以实现车辆检测的实际应用。本文选择树莓派 4B 作为硬件平台，结合 OpenVINO 框架和英特尔神经计算棒 NCS2 实现模型的加速推理，确保了复杂环境下的实时检测效果。通过对比实验，验证了轻量化模型在资源有限的嵌入式设备上依然能够有效运行，并显著提高了处理速度，表明该方法适用于实际交通场景中的车辆检测任务。

第六章：总结与展望，本章总结了本文的主要研究成果，包括在恶劣环境下的图像增强模型、改进的 DB-YOLOv8 算法及其在嵌入式设备上的成功部署。同时，本文对未来的研究方向进行了展望，指出可以进一步优化轻量化模型的推理效率，并拓展其在更多复杂交通场景中的应用，以应对更严峻的技术挑战。

中国知网 https://www.cnki.net

第 2 章 改进的单幅图像雨滴去除模型

在第一章中，已经指出了现有 GAN 去雨方法的不足之处，主要表现在处理高维度信息和不均匀雨滴分布时容易导致细节丢失。并且这些模型在不同场景中的泛化能力较弱，难以适应多变的雨滴形态和复杂的环境条件。Inception 模块和注意力机制虽然在图像处理任务中得到了广泛应用，但其在去雨任务中的结合仍较少探索。具体来说，Inception 模块虽然擅长进行多尺度特征提取，但在处理复杂高维度信息和细雨滴区域时，应用潜力尚未充分挖掘；而注意力机制虽然能提升对特定区域的关注，但目前的研究多局限于较为简单的场景，对于复杂和多维度雨滴分布的处理能力仍显不足。

为了解决上述问题，本文提出了一种结合 Inception 模块和注意力机制的 GAN 模型。Inception 模块通过多尺度特征提取，有效捕捉不同大小雨滴的细节，改善了雨滴分布不均的问题；注意力机制能够自适应地关注图像中的关键雨滴区域，提升去雨处理的精度。通过这两者的结合，模型在多变的雨天场景中表现出更强的适应性，能够保留更多的图像细节，并显著提升整体图像的增强效果。

2.1 GAN 算法的基本原理及网络结构

生成对抗网络由生成器和判别器两个核心组件组成。生成器的任务是学习并模拟真实数据的分布，从而生成与真实数据相似的图像；而判别器则负责区分输入数据是来自真实数据集还是由生成器生成。通过对抗的优化过程，生成器试图欺骗判别器，使其认为生成的图像是真实的；而判别器则不断优化以更好地区分真实图像和生成图像。

GAN 的训练是一个典型的极小极大优化问题。生成器的目标是生成尽可能逼真的图像，而判别器则通过评估生成图像的真实性，提升对真实和生成图像的区分能力。具体损失函数可以表示为：

$$\min_{G}\max_{D} E_{R\sim P_{\text{obast}}}\left[\log\left(D(R)\right)\right] + E_{I\sim P_{\text{number}}}\left[\log\left(1-D\left(G(I)\right)\right)\right] \qquad (2\text{-}1)$$

中国知网 https://www.cnki.net

其中，G 表示生成器，D 表示判别器，I 为退化图像（如因雨滴模糊的图像），而 R 为干净的真实图像。生成器通过生成清晰无雨的图像来优化自身，而判别器则通过识别生成图像与真实图像的差异来优化。

在本文的去雨任务中，GAN 框架通过生成器和判别器的协同工作去除图像中的雨滴，恢复清晰的图像。生成器通过一系列反卷积操作逐步将低维的噪声向量转化为高维图像。判别器则通过一系列卷积操作，判断输入图像是否为真实图像或生成的图像。生成器和判别器的结构分别如图 2-1 和图 2-2 所示。

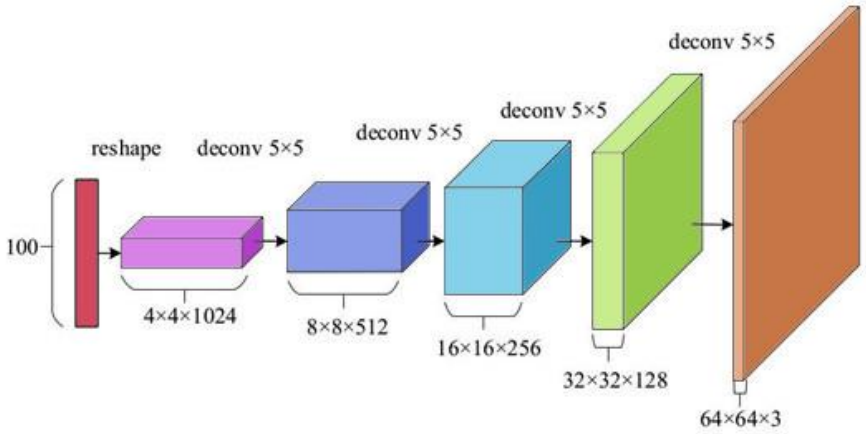


图 2-1 生成网络结构

生成器的输入是一个 100 维的噪声向量，经过全连接层处理为 4×4×1024 的特征图，然后通过多次反卷积操作生成逐步扩展的特征图，最后输出大小为 64×64×3 的图像数据。

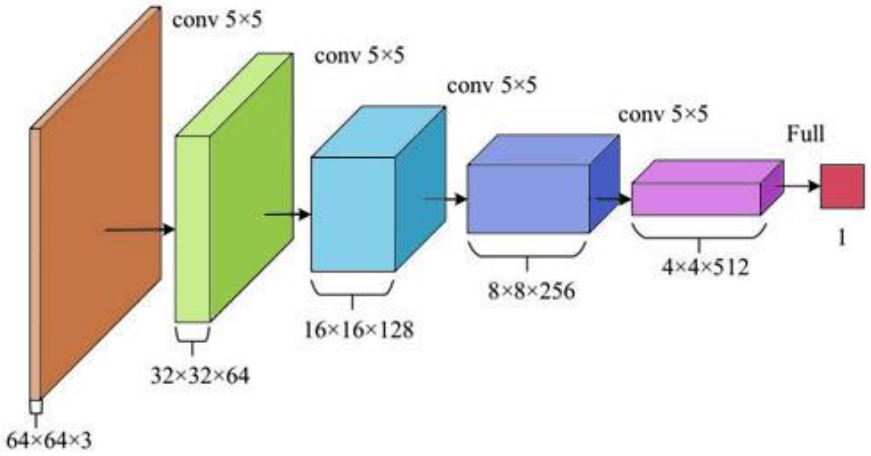


图 2-2 判别网络结构

中国知网 https://www.cnki.net

判别器则通过卷积操作提取输入图像的空间特征，并将其进行二分类，以判断输入图像的真实性。

通过对抗训练，生成器逐渐学会生成更为逼真的无雨图像，而判别器则不断提高对生成图像和真实图像的区分能力。最终，这种协同训练过程使得生成器能够生成接近真实的清晰图像。

2.2 改进的生成网络结构

为了提升去雨任务中生成网络的效果，本文对生成器进行了结构性改进，提出了一个由三个主要模块组成的改进生成网络，整体结构如图2-3所示。该网络包括以下部分：

（1）Inception 模块：通过并行卷积和池化操作提升网络的多尺度特征提取能力，并降低计算复杂度。

（2）深度残差网络：通过残差连接缓解深层网络的梯度消失问题，确保深层特征能够有效传递。

（3）卷积块注意力模块：引导网络关注关键的空间和通道特征区域，提升对图像细节的恢复能力。

通过这三个模块的结合，生成器能够更好地提取图像中的重要特征，减少计算负担并增强对雨滴区域的聚焦和清晰图像的生成能力。

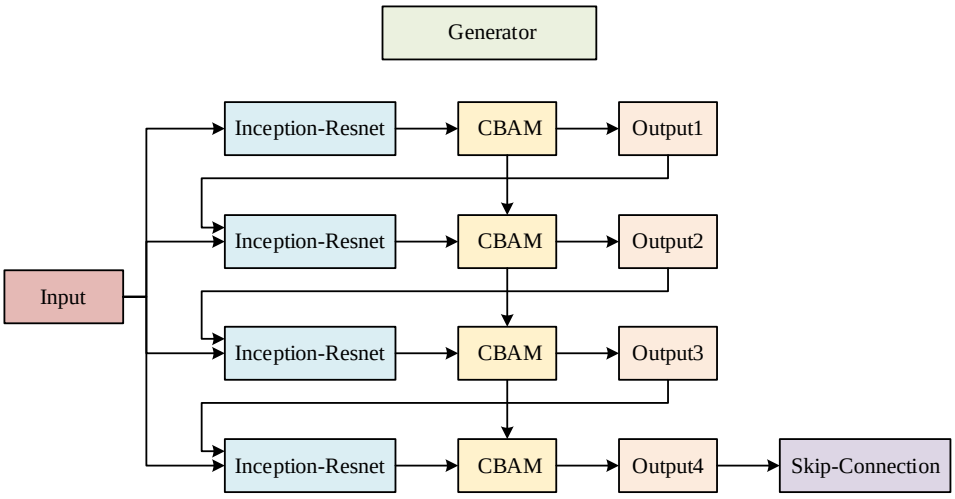


图 2-3 改进的生成网络结构

中国知网 https://www.cnki.net

2.3 生成器网络改进

2.3.1 Inception 模块的引入

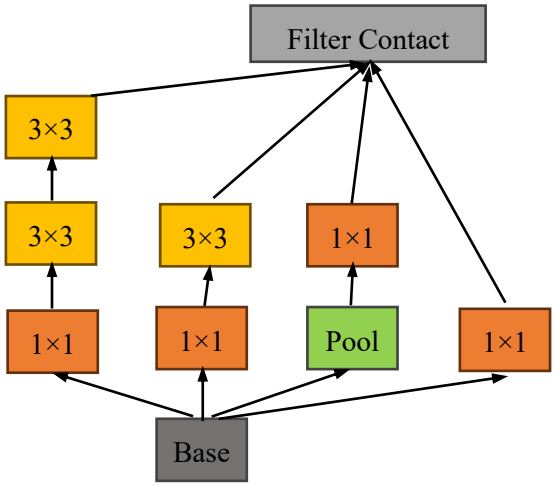


图 2-4 Inception 模块

Inception 模块最早由 Szegedy 等人[59]在 GoogLeNet 模型中提出，其设计目的是通过并行的多种卷积和池化操作获取丰富的多尺度特征，并显著降低计算量。Inception 模块通过 1×1 卷积层对特征图进行降维，再使用 3×3 卷积层进行特征提取，这种方法有效减少了大约 75%的计算量，显著提高了网络效率。

在本研究中，借鉴了 Inception 模块的多尺度特征提取优势，将其应用于去雨任务。Inception 模块的引入使网络能够在处理不同大小的雨滴和背景时，提取多尺度特征，同时降低了参数量和计算负担。与 Qian 等在 Raindrop 去除任务中使用的传统卷积层不同，本文通过 Inception 模块的多尺度卷积操作，不仅提升了对不同雨滴尺寸的适应能力，还在保持图像清晰度的同时提高了计算效率。图 2-4 展示了 Inception 模块的结构。

尽管深层网络能够捕捉更多信息，但随着网络的加深，梯度爆炸或梯度消失问题会导致训练难度增加，网络的优化效果反而变差。为了解决这一瓶颈问题，本文引入了 ResNet 结构（参见图 2-5）。

2.3.2 ResNet 的引入

中国知网 https://www.cnki.net

深度残差网络由 He 等人[60]提出，最初应用于图像分类任务，其优势在于通过残差连接有效解决了深层网络中的梯度消失和退化问题。残差连接的关键在于直接将浅层特征传递到深层，仅需学习浅层与深层特征的差异，而非重新学习整个映射，从而避免信息丢失和训练过程中的梯度问题。

具体而言，ResNet 通过残差函数 F(x)=H(x)−x 来间接求解映射 H(x)。这种结构通过跳跃连接确保输入 x 能够顺利传递到更深的层中。当网络达到最优状态时，若继续增加网络深度，残差函数 F(x) 可以趋近于零，从而保持输出与输入一致，即 H(x)=x，确保下一层网络的稳定性。这一设计不仅简化了深层网络的训练过程，还加速了与 Inception 模块的联合训练。图 2-5 展示了 ResNet 的结构。

在本研究中，我们将 ResNet 引入生成器的设计，确保深度网络在处理复杂的雨滴干扰时，能够保持特征信息的有效传递，避免因网络加深而导致的性能退化。与 Fu 等提出的基于残差网络的去雨方法不同，他们主要将残差连接用于去除场景中的降雨，而我们的改进不仅通过 ResNet 保持了深层特征的传递，还结合了多尺度的 Inception 模块，进一步增强了生成器对复杂雨滴区域的处理能力，提升了去雨任务的整体效果。

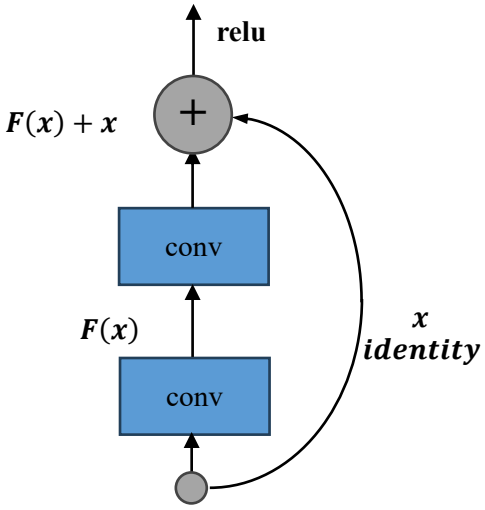


图 2-5 Resnet 结构

2.3.3 注意力机制引用

注意力机制已被广泛应用于图像处理任务，特别是在目标定位和特征提取

中国知网 https://www.cnki.net

中表现优异。该机制通过引导网络将计算资源集中在图像的关键区域，显著提高了视觉识别与分类的性能。在去雨任务中，注意力机制对生成清晰、无雨的图像至关重要，它能够帮助网络识别并重点关注需要去除雨滴的区域，同时确保背景细节得到充分恢复。如图 2-6 所示，本文采用了卷积块注意力模块（CBAM）来增强特征提取的效果。CBAM 结合了空间注意力（Spatial Attention）与通道注意力（Channel Attention），分别从空间和通道维度分析图像特征，提升对关键信息的捕捉能力，最终加强网络对重要特征的表达与利用。

图 2-6 展示了 CBAM 模块的网络结构：F 表示输入特征，A_c为通道注意力模块输出，F_c表示添加通道关注后的中间特征，A_s为空间注意力模块输出，F_s表示最终经过空间注意力后的特征。

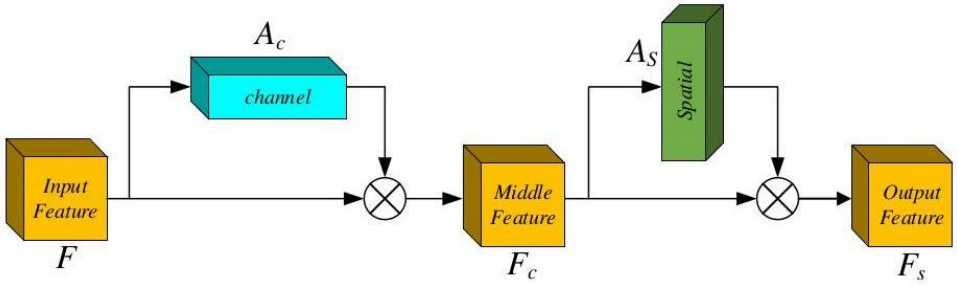


图 2-6 CBAM 示意图

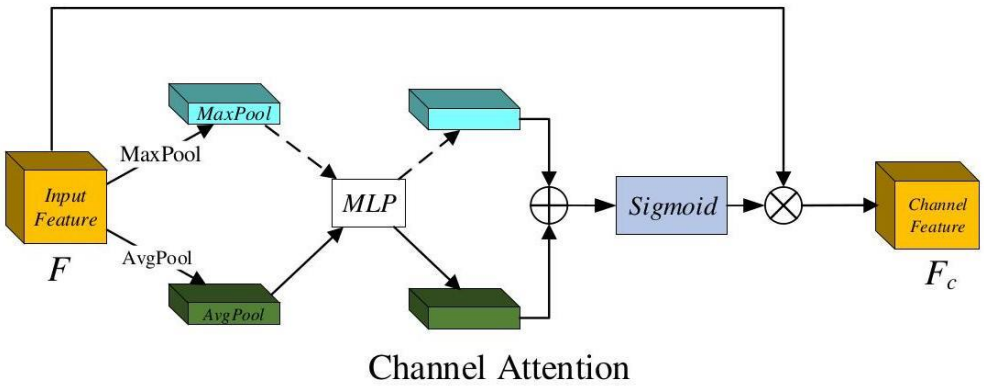


图 2-7 通道注意力示意图

通道注意力模块A_c的具体结构如图 2-7 所示，输入特征图F的维度为$C * H * W$，其中C代表特征图的通道数，H和W分别表示特征通道的高度和宽度。通过分别使用最大池化和平均池化操作，对每个通道的空间特征进行聚合，得到维度为$C * 1 * 1$的聚合结果。接着通过一个共享的多层感知机（MLP）分别计算

中国知网 https://www.cnki.net

出对应的通道注意力图，并将最大池化和平均池化的特征图结果进行相加整合。经过 Sigmoid 激活函数后，最终得到值在 0 到 1 之间的通道注意力权重, 将该权重与原始输入特征进行通道逐元素相乘，即可得到加权后的中间特征图，其表达式如式 (2-2) 所示。:

$$F_c = F + s\left(\mathrm{MLP}\left(\mathrm{AvgPool}(F)\right) + \mathrm{MLP}\left(\mathrm{MaxPool}(F)\right)\right) \tag{2-2}$$

其中 s 表示 Sigmoid 激活函数，MLP 表示多层感知机网络，$AvgPool$ 表示平均池化，MaxPool 表示最大池化。

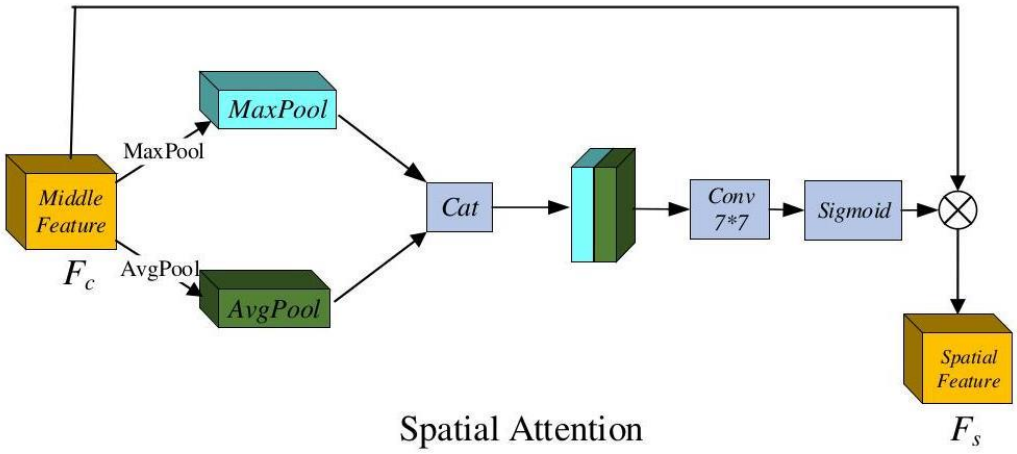


图 2-8 空间注意力示意图

空间注意力模块A_s的具体结构如图 2-8 所示，对于中间特征图F_c，首先也使用最大池化和平均池化操作。与通道注意力模块的池化操作不同，空间注意力模块中，最大池化和平均池化用于聚合每个空间位置在不同通道上的特征值，得到维度为$1 * H * W$的注意力结果。将最大池化和平均池化的结果在通道维度上拼接后，使用尺寸为 7*7 的卷积核进行卷积操作和通道变换，接着通过 Sigmoid 激活函数将卷积结果转换为范围在 0 到 1 之间的空间权重图。然后将该权重与中间特征图按空间位置逐元素相乘，得到添加了空间注意力的最终结果，如式 (2-3) 所示。

$$F_s = F_c + s\left(\mathrm{Conv}_{7*7}(\mathrm{cat}[\mathrm{AvgPool}(F_c), \mathrm{MaxPool}(F_c)])\right) \tag{2-3}$$

s、$AvgPool$、$MaxPool$含义与通道注意力模块中的对应符号相同，这里不再重复解释。 Conv_{7*7} 表示卷积核为 $7 * 7$ 的卷积操作，F_c 表示空间关注度模块

中国知网 https://www.cnki.net

得输入特征图，cat 表示按照通道的拼接操作，如式 (2-4) 所示：

$$\mathrm{cat}\left(x1_{c1,m,n}, x2_{c2,m,n}\right) = x3_{c1+c2,m,n} \tag{2-4}$$

这里$x3$表示特征拼接的结果，$c1+c2$代表 $x3$的通道数，其中$c1$ 和$c2$分别表示输入特征$x1$和$x2$的通道数，m 和 n 分别表示特征的宽度和高度。通过引入空间注意力模块，网络在通道注意力的基础上，能够进一步捕捉图像中重要特征的空间位置，提升关键区域的表达能力。该操作确保网络更好地关注雨滴干扰区域，有效增强了图像的去雨效果。

2.4 判别网络结构改进

为了更好地区分生成器生成的图像与真实图像，许多基于 GAN 的方法采用了全局和局部内容一致性的评估方式。全局判别器负责检测整张图像的整体一致性，判断是否存在任何异常，而局部判别器则专注于图像中的较小区域，尤其适用于已经确定可能存在伪造的特定区域（例如，图像生成过程中需要还原的区域）。然而在去雨任务中，特别是在测试阶段，网络无法事先知道哪些区域受到雨滴影响并需要修复。因此，判别网络必须能够自主检测和定位这些退化区域。

为了解决这一问题，本文引入了基于注意力循环网络生成的注意力图，来指导判别网络聚焦于重要区域。具体而言，从判别网络的中间层提取特征，并将这些特征输入卷积神经网络中。随后，依据 CNN 的输出生成注意力图，并结合注意力图调整损失函数的计算方式。通过这种方式，网络的判别过程能够更好地专注于图像中需要修复的区域。

将提取出的特征与判别网络的原始特征相乘，再传递至下一层。这样可以引导判别器重点关注图像中的关键区域，即雨滴干扰严重的部分，最终提升判别网络的判断准确性。在最后一层中，通过一个全连接层输出，决定输入的图像是真实的还是生成的伪图像。图 2-9 展示了判别网络的结构。

判别网络由六个卷积层组成，卷积核大小为 (3,3)，并包含一个大小为 1024 的全连接层。我们从倒数第三个卷积层中提取用于判别的特征。通过结合这些特征与注意力图的引导，判别网络能够更加准确地评估图像的真实性。

中国知网 https://www.cnki.net

判别网络的整体损失函数可以表示为：

$$L_{\mathrm{D}}(O,R,A_{\mathrm{N}}) = -\log\big(D(R)\big) - \log\big(1 - D(O)\big) + \gamma L_{\mathrm{nap}}(O,R,A_N) \quad (2\text{-}5)$$

其中 Lmap 是从鉴别器内部层提取的特征与最终注意图之间的损失：

$$L_{\mathrm{map}}(O,R,A_N) = L_{\mathrm{MSE}}\big(D_{\mathrm{map}}(O),A_N\big) + L_{MSE}\big(D_{\mathrm{map}}(R),0\big) \quad (2\text{-}6)$$

MSE 表示均方误差（Mean Squared Error）。该损失函数通过比较生成图像与真实图像的特征差异，并结合注意力图的输出，确保判别器能够更有效地区分真实图像和生成图像。

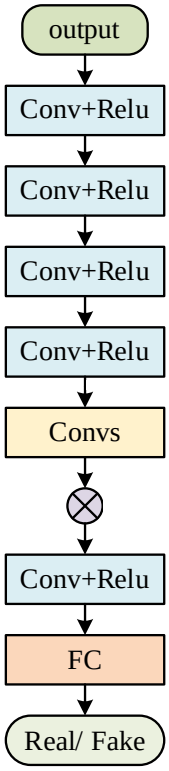


图 2-9 判别网络的结构

2.5 实验结果与分析

2.5.1 数据集和实验细节

本研究使用了 Qian 等人提出的 Raindrop 数据集进行模型训练和测试。该数据集的训练集由 861 对图像组成，每对包含一幅带有雨滴的图像及其对应的干净图像。测试集被划分为 test-a 和 test-b 两个部分。Test-a 包含 67 对雨滴/干净图像，这些图像在拍摄时相机对齐效果较好，因此较为容易去除雨滴。Test-b 包含

中国知网 https://www.cnki.net

236 对图像，相比 test-a 更具挑战性，因为其背景复杂，雨滴影响更严重，因此雨滴去除难度较大。

实验环境所涉及的相关软硬件配置参数如表 2-1 所示。

表 2-1 实验环境相关配置参数

环境	配置	参数
硬件环境	CPU	Intel(R) 12th Gen Intel(R) Core(TM) i5-12400
	内存	24G
	GPU	NVIDIA GeForce RTX 3080 Ti
	显存	12G
软件环境	操作系统	Ubuntu 18.04
	PyTorch	1.11.0
	Cuda	11.3.0
	Python	3.8

2.5.2 评价指标

通常情况下，人眼可以直观地观察图像增强算法的效果。然而，人眼观察同一区域的不同图像时，容易受到周围区域的影响，而且不同观察者对同一图像的评价也可能因主观意识而有所不同。因此，单凭主观方法评估图像质量是不足的，客观的评价指标是量化图像质量的关键。

本文采用两种常见的客观评价指标：峰值信噪比（PSNR）和结构相似性指数（SSIM）来评估算法的性能。PSNR 主要用于衡量图像的重建质量，PSNR 值越高，表明图像质量越好，失真越小；SSIM 则更符合人眼对图像质量的感知，衡量两幅图像在亮度、对比度和结构上的相似度，SSIM 值越高，说明两幅图像的相似度越大，算法效果越好。

（1）峰值信噪比 (Peak Signal to Noise Ratio，PSNR)。PSNR 是对生成图像与真实图像的像素点间的误差进行衡量，计算公式如式(2-14)。

$$P_{\mathrm{PSNR}} = 10\lg\left(\frac{M_{\mathrm{MAX}}^2}{M_{\mathrm{MSE}}}\right) \tag{2-7}$$

式(2-14)中，$\mathrm{M_{MSE}}$ 代表图像之间的均方误差，$\mathrm{M_{MAX}}$ 代表图像最大像素值。PSNR 值越大，表示图像受噪声影响越小，图像失真率越低。

中国知网 https://www.cnki.net

（2）结构相似性指数 (Structure Similarity Index，SSIM)。SSIM 用于衡量生成图像与真实图像之间的相似度，由来图像的亮度、对比度和结构三个部分组成，并且用图像的平均灰度值作为图像的亮度，计算公式如式(2-15)。

$$S_{\text{ssim}} = L(X,Y)C(X,Y)S(X,Y) \tag{2-8}$$

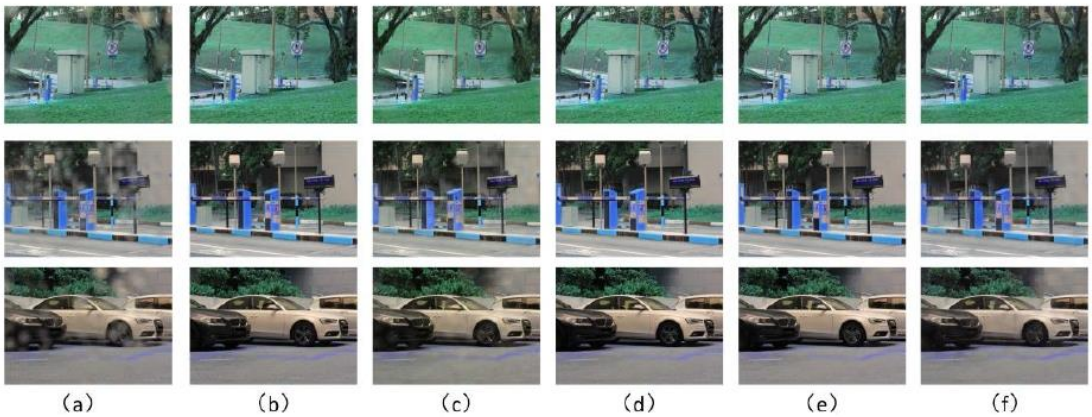
式(2-15)中，L 表示图像 X 和 Y 的亮度比较，C 表示图像 X 和 Y 的对比度比较，S 表示图像 X 和 Y 的结构比较。SSIM 值越大,表示图像保留的细节特征越多。

2.5.3 不同算法的去雨滴性能比较

为了对比不同算法在去除雨滴方面的性能，本文采用了 Qian 等人提出的 Raindrop 数据集其包含 861 对雨滴图像及其相应的干净图像。测试集划分为 Test-a 和 Test-b，样本数分别为 67 和 236。在此基础上，本文与几种主流的雨滴去除算法进行了性能对比，包括 AttGAN[61]、Quan[62]等人提出的方法和 MAXIM[63]。表 2-2 展示了这些算法在去除雨滴任务中的性能指标——PSNR 和 SSIM。本文所提出的算法在这些指标上均优于其他算法，表明其在处理不同形状和复杂雨滴去除方面的表现更加优异。

表 2-2 不同雨滴去除算法性能指标对比

数据集	指标	AttGAN	QUAN	MAXIM	Our
Testa	PSNR(dB)	31.51	31.47	31.87	32.68
	SSIM	0.901	0.923	0.935	0.941
Testb	PSNR(dB)	24.92	25.35	25.74	26.11
	SSIM	0.809	0.819	0.827	0.841



中国知网 https://www.cnki.net

图 2-10 不同去雨滴算法的对比结果图

图 2-10 展示了不同去雨滴算法的对比实验结果，其中(a)为原始雨滴图像，(b)、(c)、(d)分别为 AttGAN、Quan 等人方法和 MAXIM 方法的去雨结果，(e)为本文算法的去雨结果，(f)为无雨的干净图像作为对比参考。从实验结果可以看出，AttGAN 方法（图 2-10(b)）在一定程度上去除了图像中的雨滴，但部分区域仍存在雨滴残留，尤其是在车体表面和背景区域，图像模糊度较高，细节丢失明显。Quan 等人的方法（图 2-10(c)）相比 AttGAN 有一定的改进，整体清晰度提升，但在某些复杂场景下，去雨效果仍然不够彻底，仍能看到少量雨滴的影子。MAXIM 方法（图 2-10(d)）在细节恢复方面表现较好，但去雨的结果略显过度处理，导致部分区域出现了过度锐化的现象。

相比之下，本文提出的去雨算法（图 2-10(e)）在去雨效果上表现出色。实验结果表明，本文方法能够有效去除图像中的雨滴，且在保持图像原有细节的同时，减少了处理过程中的失真。车体表面、背景物体及远处的细节得到了较好的恢复，视觉上接近无雨的干净图像（图 2-10(f)）。因此，本文方法在去雨性能和图像细节保留方面优于现有的其他方法，验证了所提算法的有效性和优越性。

2.5.4 消融实验结果分析

为了验证改进模型中每个模块对雨滴去除性能的影响，我们在测试数据集上进行了消融实验。消融实验的目的在于通过逐步移除或添加网络中的某些模块，分析其对去雨效果的影响。本文提出的改进包括 Inception 模块、ResNet 残差网络 和 CBAM 注意力机制。基础网络（M1）包括生成对抗网络的基础架构，消融实验分别加入或移除这些模块来评估其贡献。具体的消融实验设计如下：

M1：基础网络框架 —— 包含生成网络和判别网络的基本 GAN 结构，不包含任何改进模块。

M2：基础网络 + Inception 模块 —— 在基础网络的生成器中加入 Inception 模块，用于提升多尺度特征的提取能力。

M3：基础网络 + Inception 模块 + ResNet 结构 —— 在 M2 的基础上，加入 ResNet 残差网络，缓解深层网络的退化问题并稳定训练过程。

M4：基础网络 + Inception 模块 + ResNet 结构 + CBAM 注意力机制 —— 在

中国知网 https://www.cnki.net

M3 的基础上，加入卷积块注意力模块（CBAM），使生成网络能够更有效地关注雨滴区域和背景细节。

表 2-3 展示了在不同网络结构下的 PSNR 和 SSIM 指标，详细对比了各个改进模块对去雨效果的影响。

表 2-3 消融实验中不同网络模型的去雨结果性能指标对比

网络模块	M1	M2	M3	M4
基础网络框架	√	√	√	√
Inception 模块	-	√	√	√
ResNet 模块	-	-	√	√
CBAM 模块	-	-	-	√
PSNR(dB)	29.85	31.10	32.05	32.85
SSIM	0.873	0.905	0.922	0.938

实验分析：

M1：基础网络框架

基础网络框架（M1）为生成对抗网络（GAN）的基础结构，在没有任何改进的情况下，PSNR 为 29.85 dB，SSIM 为 0.873。虽然基础 GAN 已经具备一定的雨滴去除能力，但对于复杂的雨滴场景，效果较为有限，图像细节部分仍有损失。

M2：Inception 模块的引入

将 Inception 模块加入生成网络后，网络在多尺度上更有效地提取了图像特征。实验结果表明，Inception模块提升了PSNR（从29.85 dB提升至31.10 dB），SSIM 从 0.873 提升至 0.905。说明 Inception 模块有效提高了生成网络处理不同尺寸和形状雨滴的能力，并减少了运算负担。

M3：ResNet 结构的引入

在 M2 的基础上加入 ResNet 残差结构，进一步提升了去雨效果。实验结果显示，PSNR 从 31.10 dB 提升至 32.05 dB，SSIM 从 0.905 提升至 0.922。ResNet 通过残差连接避免了深层网络的退化问题，使得生成网络能够在保持信息传递

中国知网 https://www.cnki.net

的同时，稳定地训练深层结构，从而生成更高质量的无雨图像。

M4：CBAM 注意力机制的引入

最后，加入 CBAM 注意力机制后，网络对雨滴区域和背景信息的关注能力显著增强。CBAM 模块使网络在雨滴去除过程中能够更好地聚焦于图像中被雨滴干扰的区域，增强了细节恢复能力。实验结果显示，PSNR 进一步提升至 32.85 dB，SSIM 达到 0.938，表明 CBAM 对于提升生成图像的细节恢复和全局一致性效果非常显著。

由实验得知改进的基于生成对抗网络（GAN）的去雨模型，通过生成网络和判别网络的协同工作，有效去除雨滴并恢复清晰图像。生成网络引入了 Inception 模块、ResNet 结构以及 CBAM 注意力机制，显著提升了去雨效果和图像细节的保留。

中国知网 https://www.cnki.net

第 3 章 夜间道路图像增强算法

在处理低照度和光照不均的图像时，传统方法通常依赖于伽马校正或单一的多尺度 MSR 算法。然而仅使用这些方法往往无法有效提升夜间图像的增强效果。为了解决这一问题，本文深入探讨了 MSR 算法的不足，并提出了一种结合自适应伽马校正与 MSR 的改进算法。该方法通过提取图像的照度分量，有针对性地处理不同光照区域。最后，本文通过主观和客观评估，全面比较了改进算法与其他相关算法的性能。

3.1 MSR 算法理论概述

Retinex 理论的图像增强技术，主要用于提高图像的对比度和颜色保真度，特别适合处理低光照和光照不均匀的图像。Retinex 理论由 Edwin Land 提出多尺度 Retinex（MSR）算法，认为人类视觉系统感知的颜色和亮度不仅取决于物体的反射特性，还与周围环境的光照条件相关。MSR 算法通过模拟这一机制，进行图像处理。MSR 算法的核心思想是将图像分解为不同尺度的细节层，通过在各个尺度上处理图像，增强图像的局部对比度和细节，同时抑制过亮或过暗区域。具体操作包括对图像进行多尺度的高斯滤波，提取不同频率的信息，并将这些信息合并，得到增强后的图像。该算法的优点在于能够很好地处理光照不均匀的图像，增强对比度，同时保持图像的自然感。然而它也有可能在某些场景中引入伪影或色彩失真，针对这些问题，许多后续的改进方法不断提出。

3.2 MSR 算法的不足与局限性分析

MSR 算法本质上是多尺度加权的单尺度 Retinex (SSR) 算法的扩展，融合了小尺度、中尺度和大尺度的优势，既实现了图像色彩的还原，又压缩了图像的动态范围。通过小、中、大尺度的多尺度融合，MSR 算法在图像增强中起到了较好的作用，特别是在图像细节保留和亮度调整方面具有一定的优势。然而，这种方法在实际应用中仍然存在一些局限性和不足。

中国知网 https://www.cnki.net

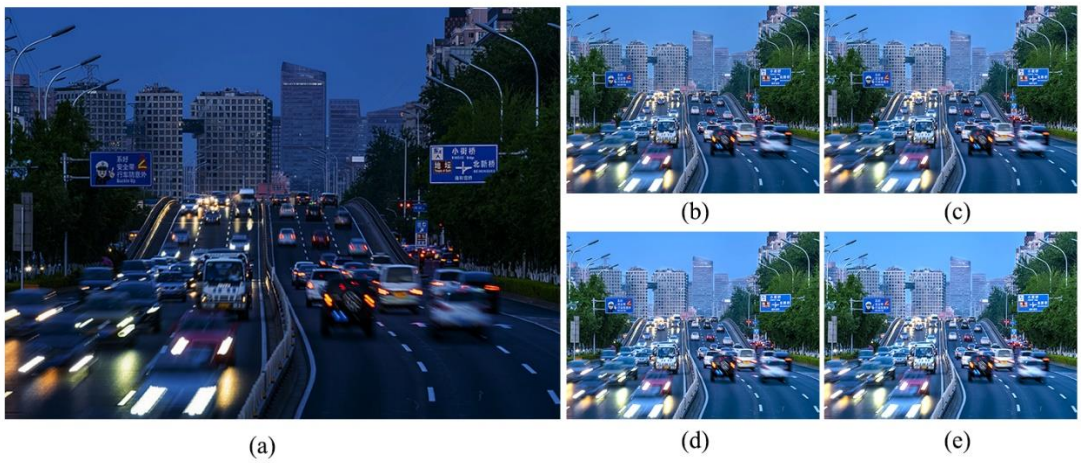


图 3-1 低照度户外图像 SSR 及 MSR 增强效果

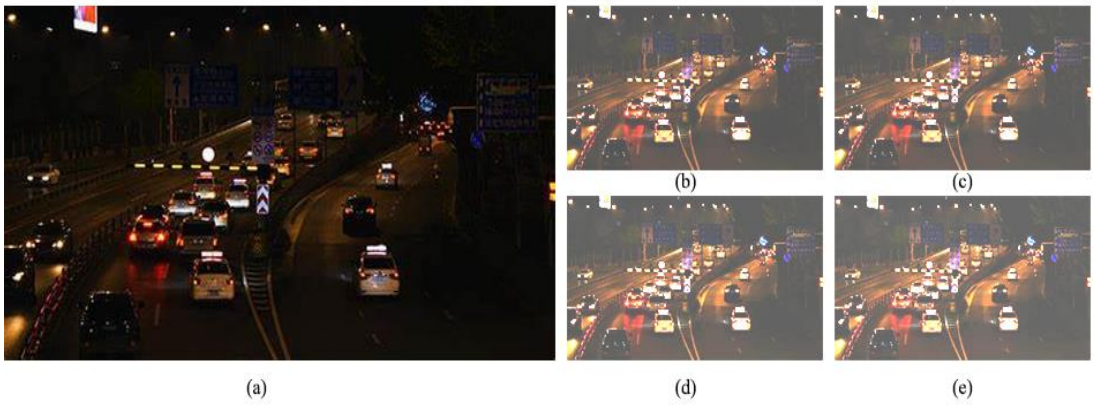


图 3-2 夜间道路低照度图像 SSR 及 MSR 增强效果

在不同尺度下，MSR 算法会对图像产生明显不同的处理效果。如图 3-1 和图 3-2 所示，采用小尺度（如 σ1 = 15）时，尽管能保留更多图像细节，但却容易造成颜色信息的损失，图像中明显出现黑色阴影区域，特别是在低光照条件下，这种阴影现象尤为突出。大尺度（如 σ3 = 250）则有效平衡了图像的整体亮度，但细节处理不足，图像呈现偏白且模糊，导致色彩保真度不高。中尺度（如 σ2 = 80）效果介于两者之间，虽然能够在亮度和平衡之间取得一定的妥协，但细节与颜色的保留仍未达到理想的状态。不同尺度下处理的局限性表明，MSR 算法在统一不同尺度的增强效果时存在一定困难。而且 MSR 算法在低照度环境下的局限性更加显著。对于夜间复杂光照场景，MSR 算法往往难以应对大范围的亮度变化。整体来看，MSR 算法会导致图像的颜色信息丢失，细节模糊，特别是在光线变化明显的场景中，图像的对比度会显著下降，呈现出较高

中国知网 https://www.cnki.net

的灰度分布。这种增强后的图像虽然提升了亮度，但却缺乏视觉层次感，难以满足实际应用中对图像细节的识别需求。例如，在夜间道路图像中，光线复杂多变，单一的 MSR 处理往往无法准确区分亮度较高的灯光区域和暗部区域，导致亮度高的区域出现过曝现象，而低亮度区域的细节则被忽略，从而影响图像整体的视觉质量。

通过观察图 3-3 的直方图可以看出，随着尺度参数的增大，MSR 算法的增强效果趋向于接近大尺度的处理结果，而小尺度的影响逐渐减弱，这反映了在固定参数设置下，MSR 算法无法有效处理不同类型的图像。这意味着，MSR 算法在处理低照度复杂场景时，采用固定尺度参数的做法存在一定的局限性，未能适应图像中不同区域的多样性需求。不同图像、不同场景下的复杂光照变化要求对尺度进行动态调整，以实现更精准的增强效果。否则，固定尺度的应用可能导致图像的细节丢失或不必要的过度增强，影响图像处理的整体效果。

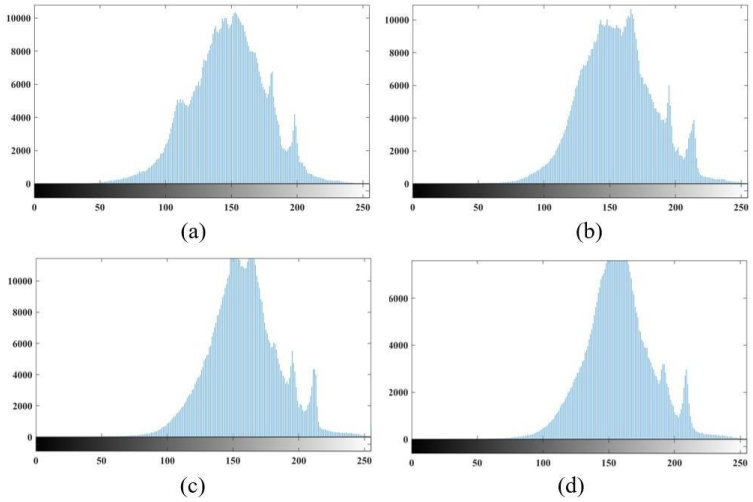


图 3-3 夜间道路低照度图像直方图分布

综上所述，虽然 MSR 算法在提升图像亮度和压缩动态范围方面具有一定的效果，但在夜间低照度图像处理时，面临着细节丢失、颜色饱和度降低、对比度不足等问题。这些问题严重限制了 MSR 算法在复杂光照场景中的应用。为了在夜间图像增强任务中取得更好的效果，下一步的研究将集中于改进 MSR 算法，通过动态调整尺度参数及结合其他增强技术，提升图像细节的保留和整体视觉效果。

中国知网 https://www.cnki.net

3.3 改进的算法设计

3.3.1 照度与反射分量的分离与处理

基于 Retinex 理论，一幅图像可以分解为两部分：照度分量 L(x, y) 和反射分量 R(x, y)。照度分量主要表示图像的整体亮度结构，而反射分量则主要反映图像的细节和纹理特征。由于人眼对亮度信息比颜色信息更加敏感，提取并优化图像的照度分量，可以显著提升图像的亮度表现，校正不均匀的光照条件，确保图像亮度均匀并自然呈现。

在处理夜间低照度彩色图像时，直接对 RGB 三个通道分别进行处理，会增加计算复杂度，并导致色彩失真。因此，本研究将图像转换到 HSV 色彩空间，重点处理 V 通道（亮度信息），这样既能减少计算时间，又能确保色彩的保真度。处理完成后，再将图像转换回 RGB 空间，以获得最终的增强效果。

在照度分量提取过程中，应用了 MSR 算法的多尺度高斯滤波，这种方法能够压缩动态范围，并从不同尺度提取图像的细节和亮度信息。具体而言，MSR 使用多种尺度的滤波器来平衡图像的整体亮度与局部细节。为了达到最佳效果，本文选取了三个典型的尺度，分别为小尺度、中尺度和大尺度，具体对应图像边长的 3%、13% 和 30%（见图 3-4）。每个尺度都有相同的权重分配，以确保在各个尺度下提取均衡的信息。

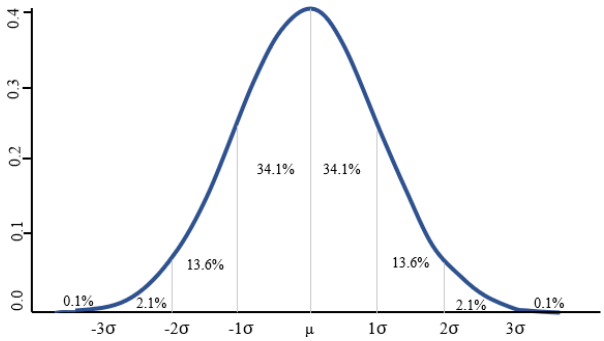


图 3-4 正态分布的 3σ 图像

此外，滤波器的模板尺寸 H 需要根据所选的尺度 σ 进行匹配。根据正态分布的 3σ 原则，本文选择滤波模板的大小为 4 倍的 σ（如图 3-4 所示），以确保滤波器能够覆盖大部分图像区域，同时避免过小的模板导致信息丢失或过大的模板增加计算复杂度（图 3-5 展示了不同模板尺寸下的处理效果）。这种滤波策略

中国知网 https://www.cnki.net

能够确保照度信息的提取兼顾到图像的细节与整体亮度。

通过这个多尺度滤波操作，最终我们得到了图像的照度分量 L(x, y)，该分量主要包含图像的低频信息，也就是整体的亮度结构。接下来，我们通过公式 R(x, y) = V(x, y) / L(x, y) 提取出反射分量 R(x, y)，其中 V(x, y) 是 HSV 色彩空间中的亮度通道，L(x, y) 是前述通过滤波获得的照度分量。反射分量则包含了图像的高频信息，包括细节和纹理。

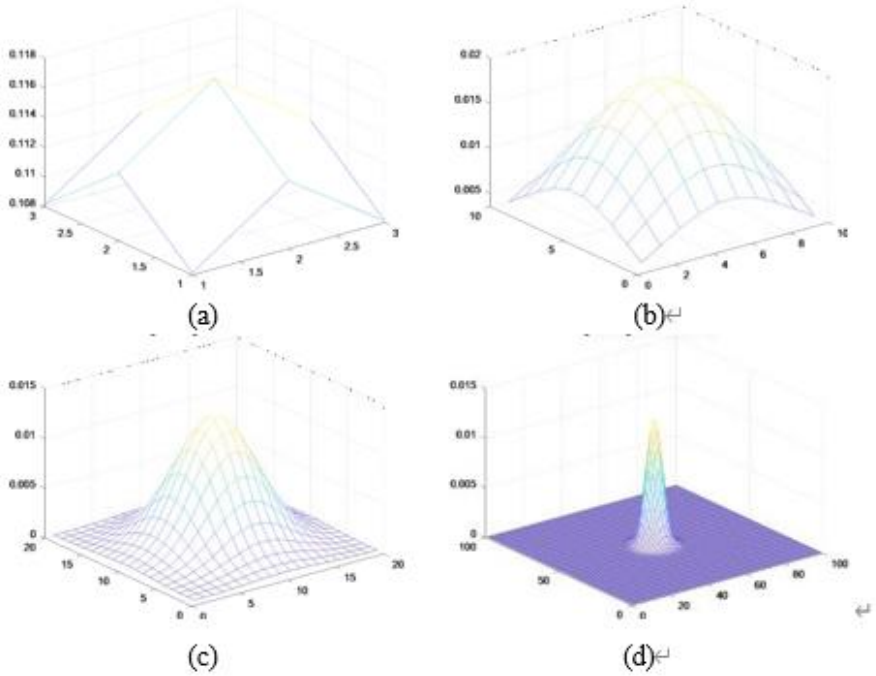


图 3-5 σ=5 对应不同模板尺寸的高斯模型分布

图 3-4 直观展示了正态分布中的 3σ 范围，这个范围涵盖了 99.7% 的图像数值，说明大多数数据点都集中在 μ±3σ 区间内。而图 3-5 展示了不同模板尺寸对图像细节的处理效果，通过对比不同模板大小的处理结果，我们可以看到，选择合适的模板大小对保持细节和控制计算复杂度至关重要。

通过照度和反射分量的分离处理，能够分别优化图像的亮度和细节，使图像的亮度得到提升的同时，细节也能得以保留与增强。这种方法特别适用于夜间低照度图像的处理，避免了传统增强方法中常见的高亮区域过度处理或细节丢失的问题，更好地适应夜间图像增强的需求。

3.3.2 自适应伽马校正的亮度调整

成功提取图像的照度分量 L(x, y) 之后，本文进一步对图像的光照分布特性

中国知网 https://www.cnki.net

进行了详细分析，设计出了一条自适应的亮度调整曲线。该曲线的设计思路是，在保持图像细节的前提下，通过压制过亮区域并提升暗部细节，来解决光照不均匀的问题。基于这一思想，本文提出了一种结合亮度分布特性和伽马校正的自适应亮度调整方法。该方法的核心是通过对图像中不同位置的光照强度进行分析，动态调整伽马校正系数，使得光照分布更加均匀，从而提高整体图像质量，增强视觉效果。

为确保算法评估的公平性，本文实验基于中山大学公开的低照度夜间道路图像数据集（DATMO）。该数据集包含了 1200 张夜间驾驶过程中采集的街道图像，涵盖了丰富的场景，能够有效测试算法在多种复杂条件下的适用性。通过对该数据集图像亮度特征的统计分析发现，大多数图像的亮度均值集中在 75 左右，且亮度范围主要分布在 [0, 100] 区间，显示出整体亮度偏低、光照不均匀的特性。因此，本文算法的目标是针对这些低亮度图像进行照度分量的校正和亮度调整，以提升整体亮度并改善光照分布不均的现象。

由于本研究主要针对 HSV 色彩空间中的 V 通道（亮度分量）进行处理，所以希望最终经过调整后的 V 通道亮度值分布在 [0, 1] 之间，而不仅仅是简单地通过传统伽马校正提升低光照部分、压制高光照部分。本文在此基础上进一步优化，力求提升整个图像的亮度分布均匀性，使其不仅在局部得到增强，同时在整体上保持均衡的亮度效果。

在对目标图像数据集的分析中，V 通道的亮度分布如图 3-6 所示。分析表明，这些夜间道路图像的亮度分布主要集中在 [0, 0.45] 区间，整体亮度较低，均值位于 [0.18, 0.23] 区间。这表明图像的亮度集中在较暗区域，且分布不均，图像呈现偏暗特性。因此，图 3-7 中的直方图直观展示了 V 通道原始图像及其提取出的照度分量的亮度分布情况，大部分亮度集中在直方图的左侧，显示出整体的亮度不均现象。

中国知网 https://www.cnki.net

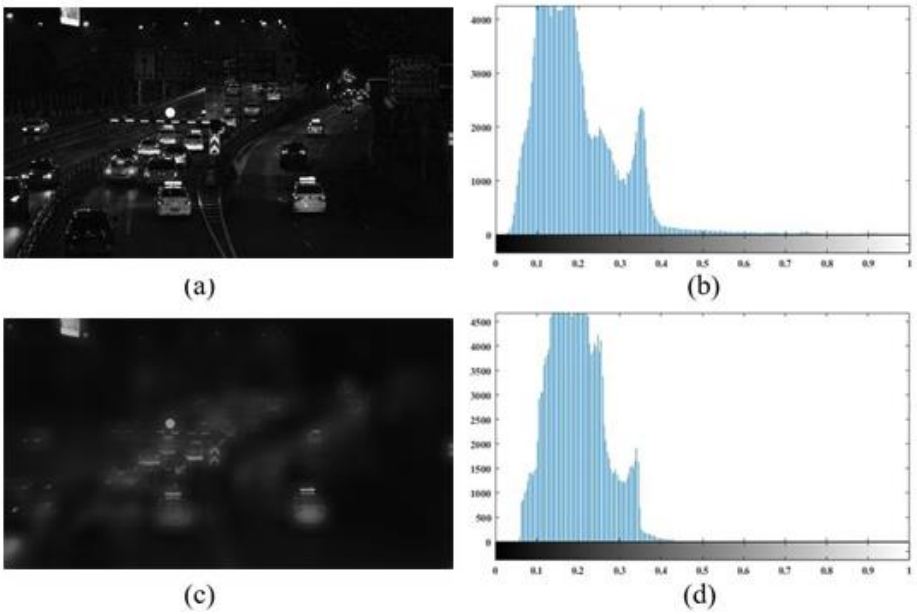


图 3-6 夜间低照度图像直方图分布

在进行亮度校正时，针对每幅图像，首先提取其 V 通道，然后将其进一步分解为照度分量 L(x, y) 和反射分量 R(x, y)。这一分解的目的是避免直接校正 V 通道时引发图像细节的丢失或噪声放大。

为了更好地适应夜间道路图像的亮度特征，本文构建了一种基于伽马校正的不均匀光照自适应二维伽马校正函数。通过提取的照度分量 L(x, y)，该伽马校正函数能够有效提升低亮度区域的细节表现，同时抑制高亮度区域的过度曝光现象，实现图像亮度的自适应调整。

该自适应伽马校正函数的公式如下：

$$L(x,y)' = L(x,y) \tag{3-1}$$

$$Y = \frac{-\exp(L(x,y) - m)}{\log(m)} - m \tag{3-2}$$

$$m = mean(mean(L(x,y)) \tag{3-3}$$

其中，L(x, y)' 表示校正后的照度分量，γ 为调整后的伽马系数，m 为提取出的照度分量 L(x, y) 的均值。图 3-7 和图 3-8 展示了在不同亮度均值下，伽马系数 γ 的变化以及对应的亮度校正效果。可以看到，当亮度均值较小时，伽马系数会变小，从而增强暗部细节；而当亮度均值较大时，伽马系数则增大，拉伸亮度的效果相对较弱。

中国知网 https://www.cnki.net

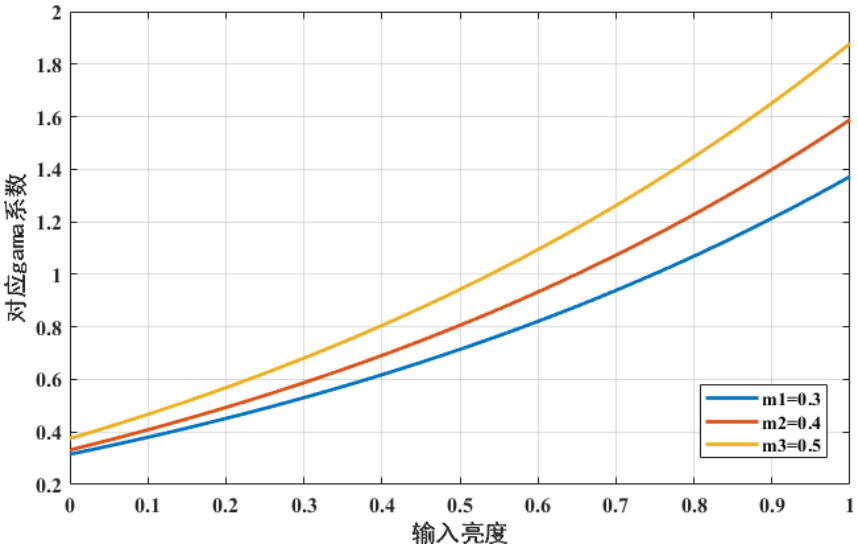


图 3-7 不同光照条件下自适应伽马校正系数大小

根据上述低照度图像特点可知，其整体亮度偏低，大部分区域图像亮度小于 0.5，且均值在 0.3 附近，整体偏暗，所以在图像拉伸时不同于传统的伽马校正曲 线，为了更好的整体亮度效果，我们希望将图像的亮度大小处于[0,m]区间的部分，尽可能将其拉伸至[0,S]区间；亮度大小处于[m,1]区间的部分，将其拉伸至[S,1]区 间，其中 S 大小为[0.45,0.55]，使其靠近图像中值大小附近，达到最终图像整体偏亮的效果。

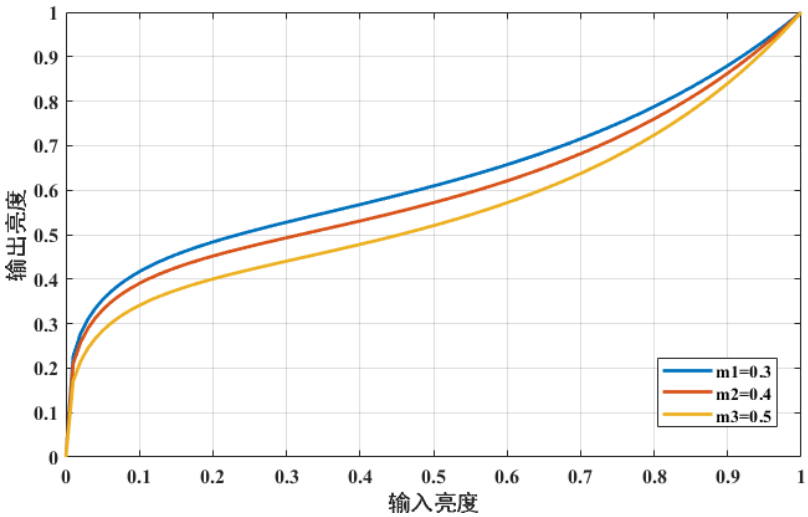


图 3-8 不同光照条件下校正前后图像亮度变化

如图 3-8 所示，经过自适应伽马校正处理后的图像亮度得到了明显的提升，尤其是低亮度区域的视觉效果显著改善。同时，过亮区域的曝光现象也得到了

中国知网 https://www.cnki.net

有效的控制，图像整体呈现出更加均匀的亮度分布，避免了传统伽马校正过程中可能出现的亮度过度增强或暗部细节丢失等问题。

最后，通过图 3-9 的分析，校正后的图像亮度在整体上更为均衡，直方图显示，校正后的光照分量的灰度值更加集中在 0.5 附近，动态范围得到了改善，亮度分布趋于均匀。结合 V 通道的直方图分布（图 3-9(d)），校正后的亮度分布更加均匀，对比度显著提升。由此可见，本文提出的二维伽马校正方法能够自适应地调整图像亮度，不仅有效解决了亮度不均匀的问题，还显著提高了图像质量。

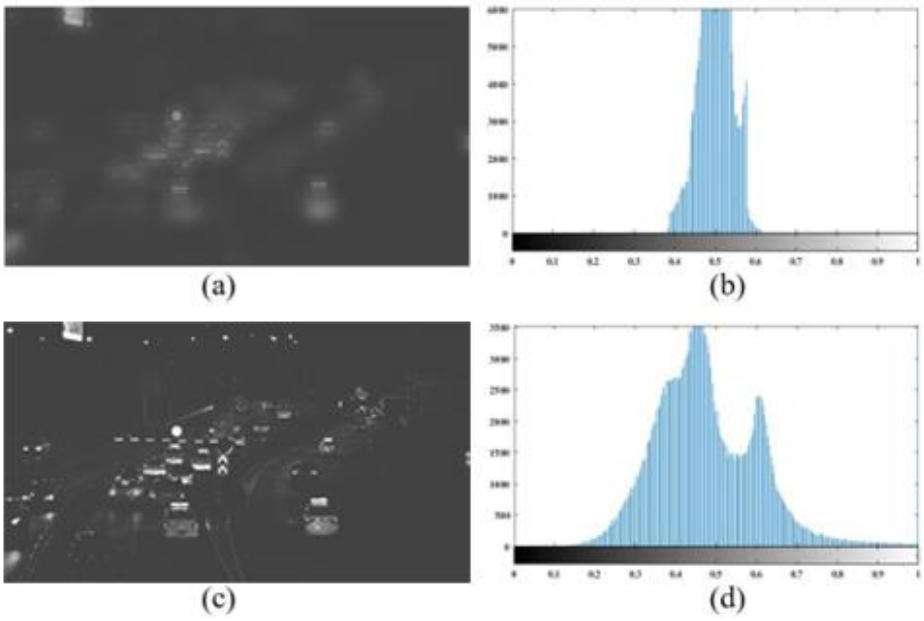


图 3-9 本节自适应伽马函数增强后的图像及其直方图分布

3.3.3 自适应融合加权的反射分量优化

通过照度分量我们可以随之得到反射分量 $R(x,y)$，由之前构建的照度-反射模型可知，在去除光照后，我们认为图像的反射分量中存在着大量的高频细节信息，与此同样也存在很多的干扰和噪声，为了减少夜间噪声对图像的干扰，我们尝试在此时对反射分量进行处理，希望能够在减小噪声的同时，还可以实现对图像细节的增强及边缘锐化，方便在后续的场景应用中实现对图像更准确的观察识别。

为了实现边缘的增强和噪声的消除，我们最终选择引导滤波。主要由于它具有以下几个特性：

中国知网 https://www.cnki.net

1．速度快。引导滤波通过作为一种边缘自适应的图像滤波技术，无论选择的窗口大小和强度如何，只有近似线性时间的消耗，是目前速度最快的边缘保持滤波手段之一。

2．边缘保持。引导滤波内部结合方差等手段可以较好的发现图像的边缘，可以克服双边滤波速度慢的同时，实现对图像的边缘保持。

3．应用场景广泛。引导滤波技术不仅可以用于去噪，还可以在图像的羽化、去雾、抠图及 HDR 等场景中广泛应用。

总结下来它在实际的应用中具有平滑图像且对边缘较好保持的优点，同时具有令人满意的计算速度。

对反射图 R 经过引导滤波操作后，我们得到了反射分量去噪后的滤波图像 R_guide，接下来我们将 R 与 R_guide 进行做差获得对应的残差图 R_sub，由于引导滤波的平滑特性，我们可知在做差后的残差图像会对图像的边缘纹理特征进行体现，这就类似于对反射分量的细节信息及边缘再提取的过程。为了能够对边缘实现一定的锐化，我们采取融合加权的方式将反射图和残差图进行融合，得到最终的 R_res，为了平衡不同图像的权值，采取了自适应加权的方式，公式如下：

$$R_guide = guidefilter(R, R, r, w) \tag{3-4}$$

$$R_sub = R - R_guide \tag{3-5}$$

$$R_res = \omega^{*}R + (1-\omega)^{*}R_guide \tag{3-6}$$

将式(2-21)带入(2-22)得到如下公式：

$$R_res = R_guide + \omega^{*}R_sub \tag{3-7}$$

由公式(2-23)可以看出，这相当于在去除噪声得到的平滑滤波图像上叠加了一定程度的边缘信息，以实现边缘锐化效果。其中$\omega = e^{(T\cdot 10)}$，T 代表原图 V 通道求取的平均梯度大小。

本文通过将加权值的大小ω与图像的平均梯度进行关联，通过之前介绍可知平均梯度具有反应图像细节变化和边缘信息的能力。对于低照度的夜间道路图像来说，可以近似认为随着平均梯度的增加，图像中就存在更多的细节信息。同时为了保证加权值归一化，通过公式推导，本文得到最后的结果图等于在去除噪声的引导滤波图基础上加上一定系数的残差图，系数的大小与图像的梯度大小

中国知网 https://www.cnki.net

有关，边缘细节越丰富后者叠加的程度就越高，这样就可以在对反射图像的噪声抑制的同时实现边缘增强，从而进一步提高最终图像的质量。

如下图3-10分别是反射图像的引导图、残差图，以及由加权进行融合后的反射图以及优化后的 R 分量还原得到的 V 分量图像。最后将处理得到的结果转换回 RGB 空间，得到最终的结果图。

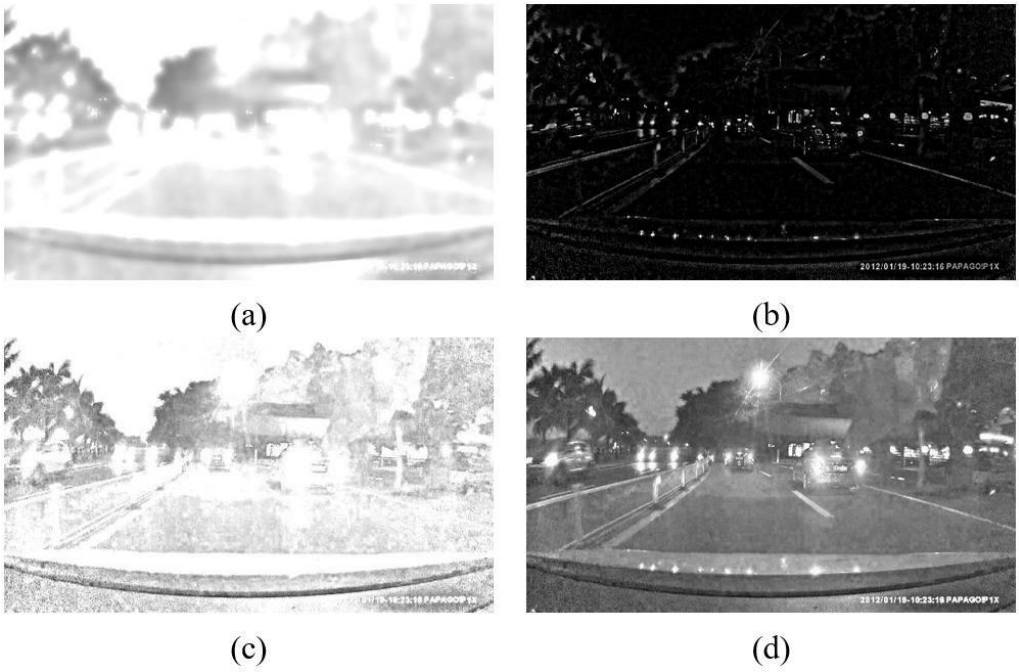


图 3-10 反射分量优化示意图

3.4 改进的自适应伽马校正与 MSR 算法框架

通过前文分析的 MSR 算法对于夜间低照度图像存在的问题，并结合 HSV 空间的特点，将图像从RGB 转到HSV 空间，并对其中的V 分量单独进行处理，通过将图像分为照度和反射分量两部分分别优化，实现对光照分量的校正。

在对光照分量矫正的过程中，本节提出一种结合光照分布特性改进的自适应伽马校正图像增强算法，可以根据光照特性来自适应的调整伽马系数的大小，实现对亮度较低部分的增强，亮度较高区域的抑制，从而实现对夜间低照度不均匀图像的亮度校正效果，除此之外，结合引导滤波加权融合对图像的反射分量进行了去噪和边缘保持，最后将图像转回 RGB 空间进行显示。经过改进后图像的整体算法框架如下图 3-11 所示，具体步骤如下：

中国知网 https://www.cnki.net

第一步：输入夜间图像，将其转换到 HSV 空间，并单独提取 V 分量处理。

第二步：根据确定好的高斯尺度和模板大小，对 V 分量进行多尺度光照分量提取，获得光照分量 $L(x,y)$ 和反射分量 $R(x,y)$ 。

第三步：根据夜间图像特点，确定二维自适应伽马校正函数，进行光照分量 $L(x,y)$ 亮度分布调整及均匀化。

第四步：对反射分量进行引导滤波去噪，并得到其残差图。结合图像的边缘梯度信息确定自适应参数的大小，进行反射分量的优化。

第五步：根据上述优化处理得到的反射分量和光照分量，确定重新合成后的 V 分量，然后结合 H、S 分量，将其转换回 RGB 色彩空间，得到最终的低照度图像增强结果。

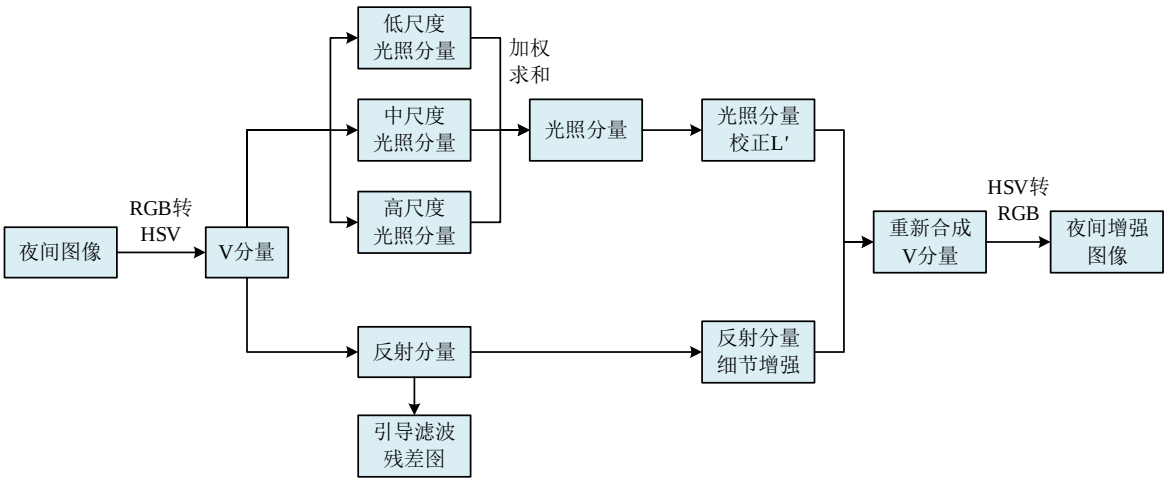


图 3-11 基于伽马校正的自适应夜间图像增强算法框架

3.5 实验结果及分析

为了评价分析本章提出的优化后的自适应伽马校正算法，本文选取了夜间图像数据集(DATMO)中的图像进行了测试实验，并和一些现有的经典及最新算法如：SSR、RBMP、LIME、Fu 进行对比，同时本章还与深度 Retinex-Net 单独进行比较，接下来将从主客观两个方面对图像进行综合评价。

3.5.1 实验结果主观分析

我们挑选了多张真实不同的场景下的夜间图像来对算法的有效性及普适性

中国知网 https://www.cnki.net

进行验证。在主观评价相关指标中，从图像的整体亮度改善、对比度的增强、图像的饱和度和自然性，以及图像的细节如车道线边界、车辆的边界、对天空区域的处理及灯光等方面来进行综合的分析对比。

通过对下图 3-12、图 3-13、图 3-14 的观察可以发现，SSR 算法无论在何种场景下处理后的图像呈现整体颜色偏白，颜色失真并且对比度较差。RBMP 算法虽然在一定程度上对图像进行了增强，但是可以发现对比其他算法整体亮度依旧偏暗，视觉上存在一定的模糊现象。LIME 算法对图像的亮度的增强效果虽然明显，但是可以发现如图 3-12（d）图像暗区域噪声也随之被放大，图 3-13（d）对于较亮场景则存在明显的过增强现象。在 Fu 等人提出的变分增强算法中，算法复杂度较高，无法满足实时性的要求，并且增强后的图像亮度较低，局部色彩信息丢失。本文改进算法处理后的效果不仅在图像整体的亮度有了很大的提升，颜色更加符合人眼的视觉模型，道路、车辆、树木的边缘更加明显易于分辨，场景中存在的路灯、车灯等处理后没有出现过曝现象，整体过渡自然。

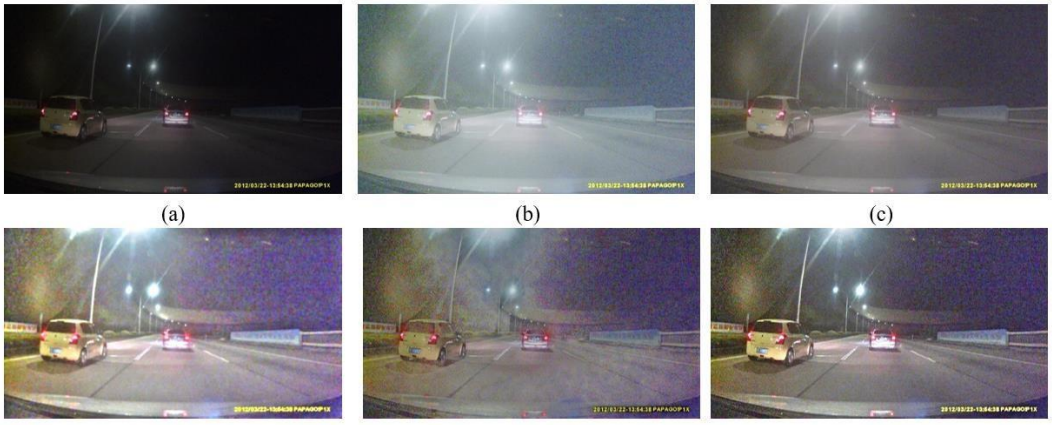


图 3-12 夜间图像 1 的增强效果对比图

中国知网 https://www.cnki.net

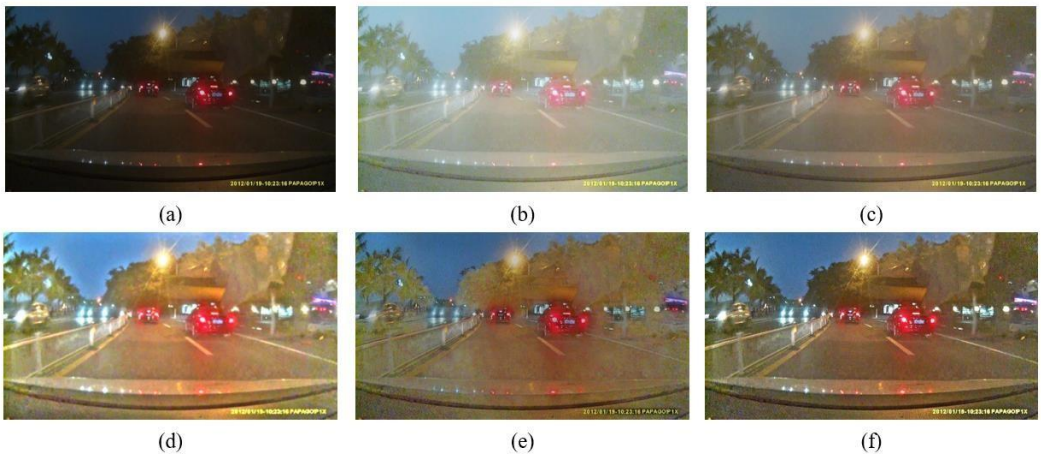


图 3-13 夜间图像 2 的增强效果对比图



图 3-14 夜间图像 3 的增强效果对比图

3.5.2 实验结果客观分析

为了减少单张图像带来的结果偶然性，并验证不同算法在多种场景下的稳定性，本文通过对 DATMO 数据集进行整理，然后对该数据集在多种算法下的客观分析评价结果进行统计并取均值，结果如下表 3-1。可以发现本章算法在边缘梯度、标准差和峰值信噪比等方面有着较好的表现，尤其是边缘梯度相较于原始图片有了接近一倍的提升，相对于其他算法有着明显的优势，这也说明了改进的算法可以有效提升图像的细节、对比度并丰富整体图像信息。在结构相似性这一指标中，虽然改进的算法仅次于 RBMP，但是可以发现 RBMP 对于夜间低照度道路图像在其他指标较低。同时结合主观评价可以发现该算法在图像的边缘和细节处理上效果较差。所以从算法处理后的效果以及结合各质量评估指标测试数据来看，改进的算法在一定程度上有效地提高了图像的对比度和清晰度，使图

中国知网 https://www.cnki.net

像看起来更加自然，对于低照度图像的增强有着较好的效果，提高可读性。

表 3-1 不同算法增强后的客观评价结果

性能指标	原图	SSR	RBMP	LIME	Fu	本章算法
边缘梯度	1012.751	1259.369	1153.512	1516.557	1440.818	1961.1
标准差	22.332	26.714	27.127	34.686	23.455	34.971
峰值信噪比	-	6.719	11.147	7.311	11.181	11.461
结构相似性	-	0.292	0.488	0.248	0.387	0.449

该小节通过解释 MSR 算法及其现存的一些问题，并在其基础上进行了优化改善。提出了一种结合图像亮度特点的算法并对夜间低照度图像进行了有效增强，使得图像在亮度、对比度、细节上都有了较大的改善。通过主客观的对比分析手段，验证了所提出的算法在不同低光照场景下效果的有效性和稳定性。

中国知网 https://www.cnki.net

第 4 章 复杂环境车辆识别算法改进

在复杂的道路环境中，车辆检测面临诸多挑战。雨天中的雨滴和雨痕影响图像清晰度，而夜间低照度下的光照不均进一步增加了检测的难度。为了解决这些问题，本文提出了一种综合方案，分别对去雨处理、夜间图像增强和车辆检测进行了优化。

在雨天场景下，采用了去雨处理方法，有效去除了雨滴和雨痕的干扰，改善了图像的视觉质量。针对夜间低照度情况，使用了自适应伽马校正与改进的 MSR 算法，提升了图像的整体亮度和细节，使其在复杂光照下更加清晰自然。

图像处理完成后，进一步应用了优化的 DB-YOLOv8 车辆检测模型，以应对各种道路环境中的车辆检测挑战。该模型结合了 ECA 机制、可变形卷积（DCN）、双向特征金字塔网络（BiFPN）和 Focal-EIOU 损失函数，提升了在复杂环境中的检测性能和准确性。通过这些优化，系统在雨天和夜间条件下的车辆检测效果得到了显著提升。

4.1 搭建车辆检测系统

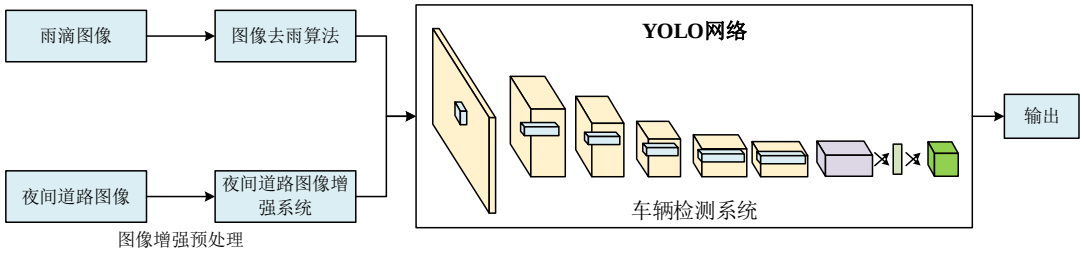


图 4-1 车辆检测系统流程图

基于前面提出的夜间道路图像增强算法和雨滴去除算法，结合 YOLOv8 卷积神经网络，可以构建一个完整的车辆检测系统。系统架构如图 4-1 所示。车载前置摄像头捕捉到的图像会首先进入图像预处理模块，该模块集成了前文提到的图像增强系统。在此模块中，针对道路图像进行增强处理，包括低照度图像增强和雨滴去除，以提高图像的清晰度和可用性。完成图像预处理后，经过增强的图像会被传输至车辆检测模块。该模块基于 YOLOv8 卷积神经网络的车辆

中国知网 https://www.cnki.net

检测算法，能够对图像中的车辆进行目标检测，并使用目标框将检测到的车辆标记出来。该系统不仅能够提高夜间和复杂天气条件下的图像质量，还能有效提升车辆检测的准确性。

4.2 YOLOv8 模型

YOLOv8 模型根据网络深度（depth_multipe）和宽度（width_multipe）的变化分为五个版本：YOLOv8n、YOLOv8s、YOLOv8m、YOLOv8l 及 YOLOv8x。这两个参数分别决定了网络中的子模块数和卷积核数。YOLOv8n 以较小的模型尺寸和快速的处理速度为特点，但在准确性方面略逊；而 YOLOv8x 则在准确度上表现出色，但模型较大，处理速度较慢。

YOLOv8 的结构流程包含四个主要部分：输入层（input）、骨干网（Backbone）、颈部（Neck）以及检测头（Head）。如图 4-2 所示在输入层，YOLOv8 继续采用 Mosaic 数据增强技术，通过对四张输入图片进行随机裁剪、缩放和排列，合成一张新的图片，以增强对小尺寸目标的检测能力。基于 YOLOX 提出的策略，YOLOv8 在最后的迭代阶段禁用数据增强功能，使模型能够学习到更贴近实际的图像特征，从而提高其在实际场景中的适用性和稳健性。

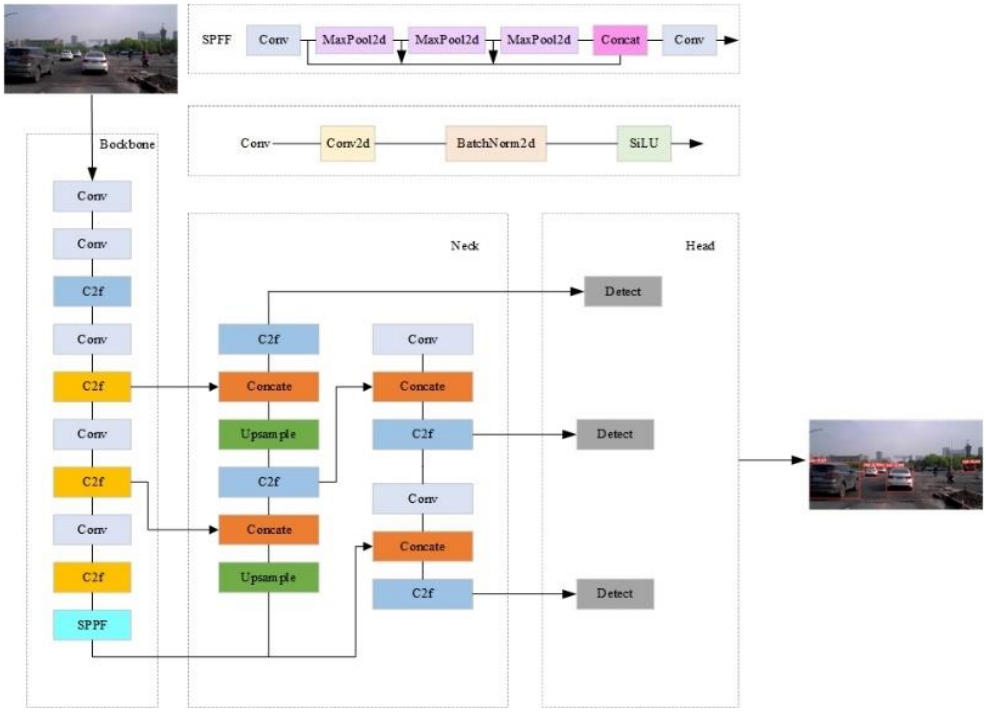


图 4-2 YOLOV8 模型图

中国知网 https://www.cnki.net

4.3 YOLOv8 算法改进

在自动驾驶环境下，针对车辆的检测需求和设备的硬件性能限制，本文采用了 YOLOv8n 作为基础算法模型。然而，在实际应用中，YOLOv8n 面临诸多挑战。其主要问题在于，标准卷积核不足以有效捕捉不同尺寸车辆的特征，尤其是在复杂背景条件下对小型车辆的检测，易于发生误检和漏检。

为应对这些问题，本文实施了关键性的优化措施。首先，鉴于车辆形状的多样性，文章通过在主干网络的第 5、7、9 层集成可变形卷积（DCN），优化了卷积窗口以更贴合实际车辆形态，增强了对各种尺寸车辆的适应性。其次，为了提高在低照明条件下的特征识别能力，在网络的 Neck 部分集成了 ECA 注意力简化模块与 BiFPN 双向特征金字塔网络，在第 12、15、16、18、22、24、26 层进行融合，这不仅提高了关键特征的提取效率，还增强了特征的整合能力。此外，通过结合 BiFPN 与 P2 层的优化，进一步提升了对不同尺度信息的识别能力，从而提高了车辆检测的精准度。最后，采用 Focal-EIOU 损失函数替代传统的 CIOU 损失，增强了模型在复杂场景下的适应性和学习效率，从而提高了检测精度和泛化能力。

通过这些综合性的改进，显著增强了模型在自动驾驶场景下的车辆识别性能，有效地缓解了 YOLOv8n 算法在复杂环境中遇到的问题。

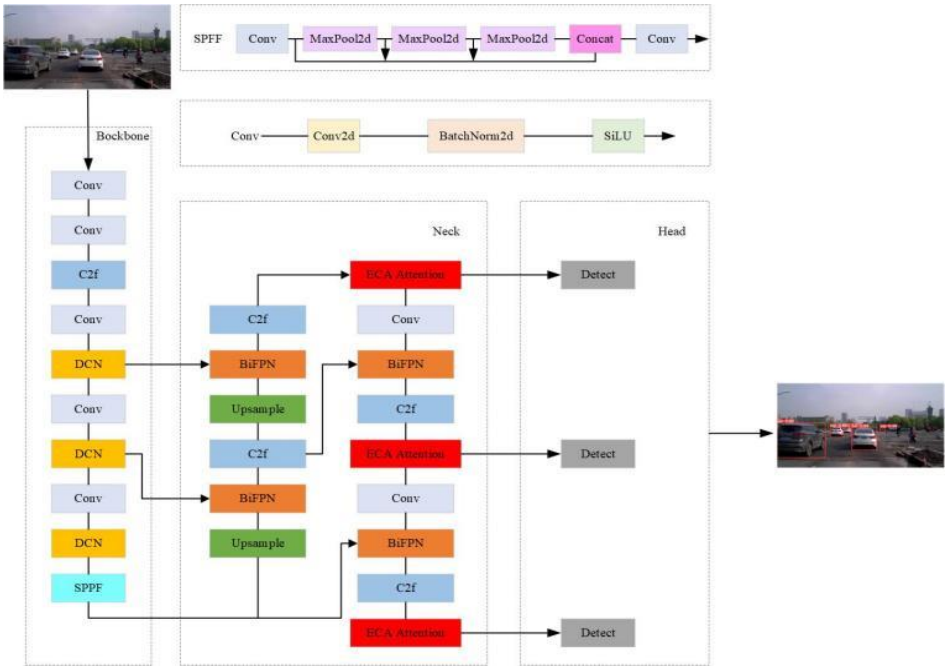


图 4-3 YOLOV8 算法改进模型

中国知网 https://www.cnki.net

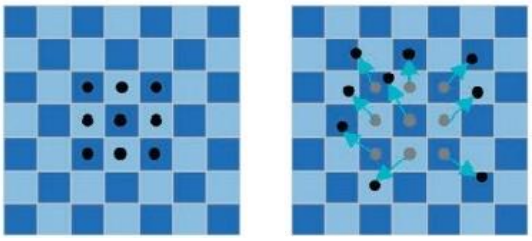
4.3.1 引入可变性卷积

在深度学习初期，标准卷积操作广泛应用于图像处理，其中相同的卷积核被均匀应用于整个图像。这种方法在处理变形或区域性特征变化时显示出了一定的限制。为了增强模型的感受野并捕获更复杂的特征信息，引入了空洞卷积（也称为膨胀卷积）。空洞卷积通过在卷积核中插入空间间隔来扩大其覆盖的范围，从而扩大感受野并捕捉更宽广的上下文信息。尽管空洞卷积增加了感受野，但它的采样模式仍然是固定的。

为了解决这些限制并进一步提升模型对图像中变化的适应性，开发了可形变卷积 [64]。这种方法允许卷积核的采样点动态地适应图像中局部特征的变化。可形变卷积通过加入可学习的偏移参数，使得卷积核的采样位置和形状可以根据图像中的具体特征进行动态调整。这种自适应的特性使得模型能够更加有效地处理非刚性的变形、遮挡以及复杂背景等问题。

可形变卷积的核心在于其采样位置的灵活性和学习能力，这使得卷积过程能够更贴合实际物体的形态变化，从而提高模型对于图像中变化特征的适应性和识别能力。这种技术的引入能很大程度优化模型的性能。

从图中可以看出，可形变卷积的采样位置是可变的，或者说是可学习的，因此可形变卷积可以更 好的考虑到物体形状变化。



(a)传统卷积 (b)DCN

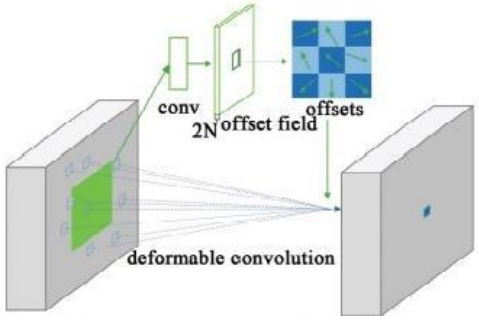


图 4-4 DCN 解释图

中国知网 https://www.cnki.net

在图 4-4 所示的 DCNv1 模型中，空洞卷积虽然增加了感知域，但同时也提高了参数量，可能导致模型复杂度上升，内存需求增加，以及在训练和推理过程中对计算资源的需求提高。考虑一个包含K个采样点的卷积核，其中每个采样点 k 的权重和偏移量分别用w_k和p_k表示，例如，对于 K 等于 9 的情况，采样点p_k被设置为{(-1,-1)，(-1,0)，...，(1,1)}，形成 3×3 的卷积核布局。这里，x_p和y_p代表输入和输出特征图中位置 p 的特征值。当仅调整偏移量，可调节的可变形卷积表达式如下：

$$\mathrm{y}(p)=\sum_{k=1}^{K} w_k x(p+p_k+\Delta p_k) \tag{4-1}$$

与 DCNV1 的固定空洞卷积率相比，DCNV2 引入了可变空洞卷积率，允许在不同层次和感受野中使用多样的空洞卷积率。这一可变调整策略赋予了 DCNV2 更强的能力在不同尺寸层面捕获并融合上下文信息，提升了模型对多尺度特征的识别效率。通过给每个采样点分配权重，改良后的 DCN 模型能够更细致地处理各种尺度的特征。

$$\mathrm{y}(p)=\sum_{k=1}^{K} w_k x(p+p_k+\Delta p_k)\Delta m_k \tag{4-2}$$

Δp_k和Δm_k分别代表第k个采样位置的可学习偏移量和调制因子。调制因子Δm_k的值被限制在[0,1]之间，而Δp_k为一个不受限制的实数值。因为p+p_k+Δp_k可能是一个分数位置，所以在计算输入特征映射x时，采用了双线性插值来处理p+p_k+Δp_k。这两个参数通过在输入特征映射 x 上使用的独立卷积层获得，此卷积层保持与现有卷积层相同的空间分辨率和扩张率。输出层有 3 K个通道，前 2 K个通道代表学习到的偏移量Δp_k，余下的K个通道通过 sigmoid 层处理后，产生调制因子Δm_k。在这个特定的卷积层中，核的初始权重设为零，因此Δp_k和Δm_k的初始值分别设为 0 和 0.5。为了学习偏移和调制参数，额外的卷积层的学习速率被设置为现有层的十分之一。通过在标准卷积中引入可学习的位移，DCN 增强了模型的适应性和性能。能够适应目标的形状变化。在车辆检测中，这意味着网络可以更灵活地处理由于不同角度或远近造成的车辆形状扭曲。

4.3.2 加入通道注意力

在光线较弱或目标特征与背景相似的情况下，传统的 YOLOv8 算法在执行

中国知网 https://www.cnki.net

卷积操作时可能会遗失一些关键的目标特征，特别是对于车辆这类目标。这一问题加之车辆类型的多样化，可能导致模型在进行目标识别时产生过分细致的划分，进而增加了由于背景信息引起的识别错误。此外，由车辆元素组成的复杂图像进一步增加了算法识别时的挑战，因为这些元素可能与背景融合，使得目标与背景的区分变得更加困难。

为了应对这些挑战，本章在 YOLOv8 的基础架构中加入了有效的通道注意力机制，即 ECA[65]模块。ECA 模块的引入旨在将模型的计算焦点更加集中于车辆的主要特征上，通过增强对车辆关键属性的识别能力，同时减少背景信息带来的干扰。ECA 通过对不同通道的特征进行加权，能够突出对目标识别有贡献的特征，而抑制那些无关或干扰性的信息，从而提高了目标检测的准确性和鲁棒性。

ECA 模块的核心优势在于其高效的特征选择能力，它通过自适应地调整通道间的权重，精确地捕捉到与目标识别直接相关的特征。这种机制不仅提升了对车辆等目标的检测性能，特别是在复杂环境或光线不足的情况下，还显著降低了模型对背景噪声的敏感度，确保了算法在各种场景下的稳定性和可靠性。

通过整合 ECA 通道注意力模块，YOLOv8 算法得以在保持高效性的同时，显著提升对车辆等小目标的识别准确率，尤其在背景复杂或光照条件不理想的情况下，能够有效降低错误识别和遗漏检测的风险。这种改进有助于提高车辆检测的精度。

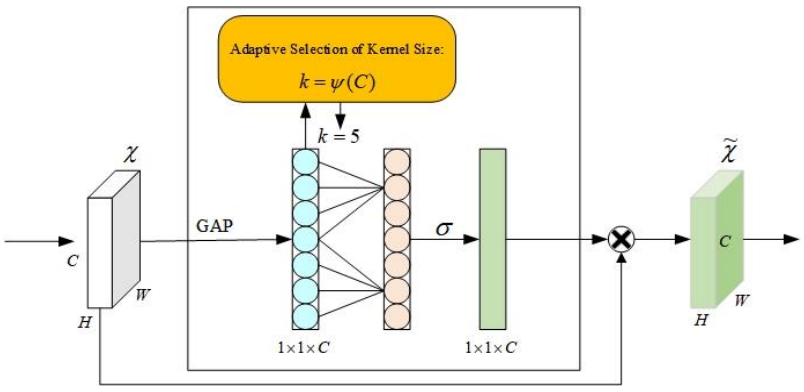


图 4-5 ECA 机制模型

如图所示 ECA（Efficient Channel Attention）机制通过采用一以下是 ECA 模

中国知网 https://www.cnki.net

块的结构图。种高效的通道注意策略，有效地简化了模型结构，同时提升了性能。这一机制的核心在于用一维卷积替代了传统 SE（Squeeze-and-Excitation）机制中的全连接层，从而降低了模型的复杂度。ECA 首先通过全局平均池化对输入的特征图进行处理，为每个通道生成一个全局感受野的通道描述符。当通道数为 C 时,卷积核大小 k 的自适应函数定义为：

$$k = \phi(C) = \left| \frac{\log_2(C)}{\gamma} + \frac{b}{\gamma_{\text{odd}}} \right| \tag{4-3}$$

其中一维卷积的核大小 k 与通道数 C 成正比，这样做不仅减少了模型的参数数量，而且增强了模型捕捉通道间依赖的能力。其中，odd 表示向上取最近的奇数，该文 γ 和 b 分别取 2 和 1。

与传统注意力机制相比，ECA 通过精简的设计提高了计算效率和模型性能。它避免了复杂的全连接层，减轻了模型的计算负担，同时保持了对关键特征的有效捕捉。这种自适应的通道交互策略允许 ECA 更灵活地捕获通道间的相关性，从而更精准地对输入特征进行重标定。通过这种机制，ECA 能够在不同的深度学习任务中，如图像分类、目标检测和实例分割，提供更加准确和鲁棒的性能。

总之，ECA 机制通过其创新的结构设计，在降低模型复杂度的同时，实现了对模型性能的显著提升。

4.3.3 改进的多尺度检测和加强特征融合

在 YOLOv8 中，融合层主要由 FPN[66]-PAN[67]结构组成。然而不同主干网络输出的分辨率及其在融合时的贡献度存在不一致性。特征金字塔通过建立自上而下的融合路径，实现了图像语义信息与特征信息的有效结合，但受限于信息流动的单一方向。路径聚合网络结构中，浅层特征和高层语义信息通过求和操作直接融合，导致特征融合效果不足。一些节点仅从单一节点获取输入，这增加了参数数量并导致效率低下。为提高模型效率，本文引入了 BIFPN[68]作为特征融合模块，并对其进行了改进。改进后的 BIFPN 结构如图 4-6 所示。

中国知网 https://www.cnki.net

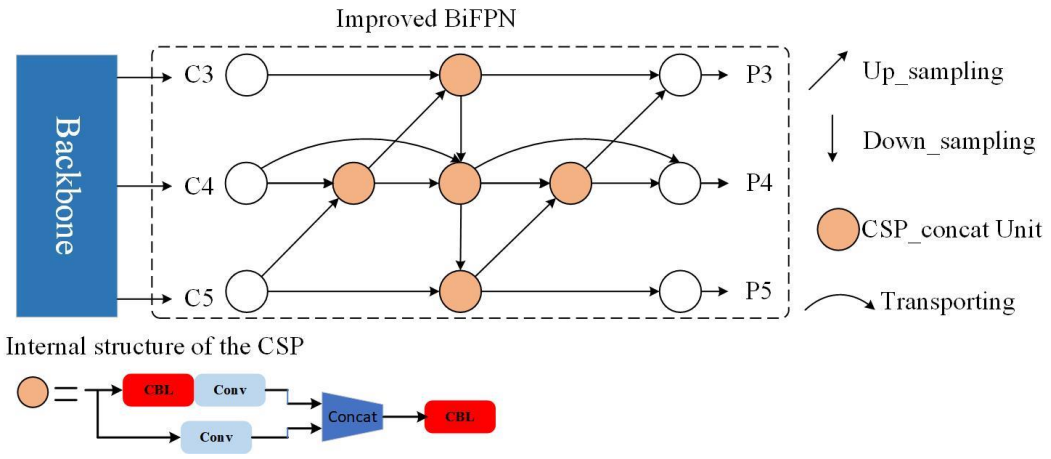


图 4-6 改进的 BIFPN 结构图

特征信息首先由 CSPDarknet 提取，并传递到改进后的 BIFPN 进行特征融合。与原始 BIFPN 的五层输入不同，改进版 BIFPN 设计了三层多尺度特征映射输入，以匹配 YOLOv8 骨干网络的输出。BIFPN 采用了加权特征融合机制，使得权重信息在各个特征层之间共享，每层的贡献度清晰，确保网络在训练时能够逐步学习到每个输入特征的相对重要性。原始 BIFPN 使用了深度分离卷积，导致卷积层数增加，引发梯度信息的重复计算问题。而普通卷积层在解决这一问题上效果有限，因此改进版将其替换为 CSP 模块。CSP 模块在不增加计算负担的情况下，有效减轻了梯度重复计算问题，同时维持了改进 BIFPN 的整体性能。

综上 BIFPN 与改进 BIFPN 的主要区别有两点：首先，原始 BIFPN 采用五层输入，而改进后的 BIFPN 调整为三层输入，以适配 YOLOv8 骨干网络的输出；其次使用 CSP 模块替代了普通卷积，以实现更高效的信息融合，并缓解深度卷积层导致的梯度重复计算问题。通过这些改进，BIFPN 在保持高效特征融合的同时，显著提升了网络的检测性能。

4.3.4 优化边界框损失函数

YOLOv8 目标检测算法其性能依赖于对图像中对象的精确定位，这通过边界框回归实现。边界框损失函数在这一过程中起着关键作用。尽管 YOLOv8 原本采用的 CIoU 损失函数能够有效地优化重叠区域、中心点距离和边界框比例，但它在处理样本不均衡时可能会遇到问题，并可能遭遇梯度消失，这会影响收敛速度和检测精度。

中国知网 https://www.cnki.net

为了解决这些问题，研究者们引入了 EIoU 损失函数，该函数在度量边界框的三个几何属性方面更为明确：重叠面积、中心点位置以及边界框的尺寸。这有助于解决样本不平衡问题，并避免梯度消失或爆炸。

此外，为了进一步提高锚框的质量，Focal loss 被与 EIoU 损失函数相结合，形成了 Focal-EIoU 损失函数。这种结合继承了 Focal loss 在处理难易样本时的优势，并增强了 EIoU 在几何属性上的敏感性，使得模型在收敛速度和定位精度上都有所提升。

在 IoU 系列损失函数的发展中，一个高效的边界框回归损失应当综合考虑重叠面积、中心点距离及长宽比[69]。CIoU 损失函数正是基于 DIoU 损失函数进一步发展而来，增加了对长宽比一致性的惩罚项，以保证预测框与实际目标框之间的比例一致性。CIOU 数学表达式如下：

$$\mathrm{CIoU} = \mathrm{IOU} - \frac{\rho^2(b,b^{gt})}{c^2} - \alpha v \tag{4-4}$$

$$\alpha = \frac{v}{(1-\mathrm{IOU})+v} \tag{4-5}$$

$$v = \frac{4}{\pi^2}\left(\arctan\frac{w^{gt}}{h^{gt}} - \arctan\frac{w}{h}\right)^2 \tag{4-6}$$

在公式(3-4)、(3-5)和(3-6)中，参数 α 用于调整比例平衡，变量 b 代表预测的边界框，而变量 v 用于衡量预测框与真实框在宽高比一致性上的指标。这里b^{gt}表示真实边界框，w^{gt}和h^{gt}分别指代真实框的宽度和高度。同样地，w 和 h 表示预测框的宽度和高度。CIOU（Complete Intersection over Union）损失函数主要考虑边界框回归的三个方面：重叠区域的大小、中心点之间的距离以及宽高比。然而，CIOU 主要依据宽高的相对比例而非绝对数值，这导致在对预测框进行回归时，其宽度和高度不能同时增加或减少，从而可能出现比例失衡的问题。为了解决这个问题，提出了 EIOU 损失函数，它在 CIOU 的基础上进一步细化了预测框与真实框宽高比一致性的损失项，并计算预测框的宽度和高度与其最小外接框之间的差异，以此克服 CIOU 在处理宽高比近似线性关系时的限制。EIOU 函数 表达式如下：

$$\begin{aligned} L_{\mathrm{EIoU}} &= L_{\mathrm{IoU}} + L_{\mathrm{dis}} + L_{\mathrm{asp}} \\ &= 1 - \mathrm{IoU} + \frac{\rho^2(b,b^{\mathrm{gt}})}{(w^c)^2+(h^c)^2} + \frac{\rho^2(w,w^{\mathrm{gt}})}{(w^c)^2} + \frac{\rho^2(h,h^{\mathrm{gt}})}{(h^c)^2} \end{aligned} \tag{4-7}$$

在公式(3-7)中，w^c和h^c分别表示能同时包含真实框和预测框的最小外接框

中国知网 https://www.cnki.net

的宽度和高度。符号ρ^2用于计算两个框中心点之间的欧氏距离。通过 EIOU 损失函数的定义，我们可以看到它主要由三部分组成：IoU 损失L_{IoU}，中心点距离损失L_{dis}和宽高比损失L_{asp}。EIOU 在继承了 CIOU 的重叠区域和中心距离损失的基础上，对宽高比损失进行了优化，直接最小化预测框与真实框的宽度和高度差异，从而加快了收敛速度并缓解了 CIOU 中正负样本不平衡的问题，同时提升了边界框识别的效果。

EIOU 损失函数特别关注于将宽高比的损失细分，通过计算预测框的宽高与最小外接框宽高的差异来加速收敛，并提高回归精度。进一步地，在 EIOU 的基础上，为了提高预测框的质量和识别精度，引入了 Focal Loss。这是因为在目标边界框回归过程中，高质量锚框（误差小）的数量通常少于低质量锚框（误差大），后者会产生较大的梯度影响训练效率。Focal Loss 通过在损失函数中为每个类别引入一个权重因子$\alpha\in[0,1]$，来解决样本不平衡问题，进而优化训练过程和提升模型性能。FocalL1 Loss 的表达式如下：

$$L_{\mathrm{focalL1}} = -\frac{\alpha x^2(2\ln(\beta x)-1)}{4},\ 0 < x \le 1;\ \frac{1}{e} \le \beta \le 1 \tag{4-8}$$

$$L_{\mathrm{focalL1}} = -\alpha\ln(\beta)\,x + C,\ x > 1;\ \frac{1}{e} \le \beta \le 1 \tag{4-9}$$

在公式(3-8)和(3-9)中，设定 $\alpha=e*\beta$，其中 C 为固定常数。Focal Loss 通过引入一个调节参数来降低易分类样本的权重，从而集中关注于难以分类的样本。Focal-EIOU 损失函数的开发旨在克服样本质量不均的挑战，它通过降低那些与真实框重叠较少的大量预定锚框的损失值，减少这些锚框在预测框回归优化中的影响，使得模型更专注于高质量锚框的训练。Focal-EIOU 损失函数的公式为：

$$L_{\mathrm{Focal-EIoU}} = \mathrm{IoU}^{\gamma} L_{\mathrm{EIoU}} \tag{4-10}$$

在此框架中，γ是一个调节项，用于控制异常值的抑制程度。Focal loss 的加入对 EIOU 损失进行权重调整，使得与真实框的 IoU 值高的预测框承受更大的损失。这种加权机制对于优化预测框的回归精度特别有效，尤其是在处理小目标检测问题时，它能够解决因小目标样本稀缺和分辨率低导致的梯度爆炸问题，从而提高对小目标的识别能力。

中国知网 https://www.cnki.net

4.4 实验及仿真结果

4.4.1 DB-YOLOv8 的结构说明

在本章中，我们详细介绍了一个结构精细的车辆检测流程——DB-YOLOv8 算法，它通过三个精心设计的阶段实现高效的图像处理：图像预处理、特征提取和后处理。

在图像预处理阶段，我们首先调整输入图像的尺寸以符合模型规格，然后采用如马赛克技术的数据增强方法来丰富模型的训练数据集，最后进行图像标准化，标准化过程旨在消除光照变化和颜色偏差对模型训练的潜在影响。接着，图像被引入到主干网络，这一阶段的关键任务是从图像中精确提取特征，并预测感兴趣的区域。这些特征提取的技术为车辆检测模型提供了必需的视觉信息。最终，在后处理阶段，采用 Soft-NMS 对重叠边界框执行柔性阈值筛选，这一过程不仅减少了误检，而且确保了最终结果的高可信度。通过这一策略，仅高置信度的检测框被保留，从而完成了从原始图像到精确车辆检测结果的转换。

整个 DB-YOLOv8 算法的设计，旨在将复杂的图像数据转化为准确的检测结果，不仅提高了处理速度，也确保了结果的精度，尤其是在动态且挑战性的交通环境中。

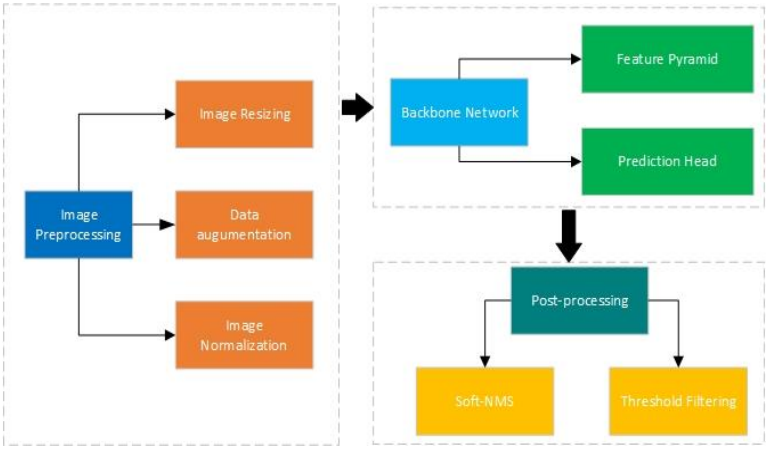


图 4-7 算法流程图

4.4.2 数据集

为了促进自动驾驶技术的进步，精确的车辆检测成为一个至关重要的研究领域。在自动驾驶和交通监控系统中，对于车辆的快速准确识别是确保安全性

中国知网 https://www.cnki.net

和流畅交通的基础。针对这一挑战，构建了 MNCD（多条件车辆检测）数据集，该数据集专门针对各种复杂场景下的车辆检测问题而设计。MNCD 数据集由多个场景组成，包括城市街道、郊区道路、农村小径以及高速公路等多样化的道路条件，确保了系统在不同的驾驶环境中都能维持高性能。为了进一步提高检测系统的适应性，该数据集包含了在多种气象条件下采集的图像，如晴朗、雨天和雾霾等，这些多天气情况的数据对于增强模型的鲁棒性至关重要。

数据集的图像由在杭州地区布置的车载摄像头系统采集得到，每张图像都经过专业的手工标注，包括精确的边界框定位，这些精细的标注信息是确保车辆位置和尺寸识别准确性的关键。此外，我们将所有车辆统一标注为“车辆”类别，这一策略简化了数据集的结构，使研究者可以集中精力改进车辆检测的准确率，而不是分类。

MNCD 数据集含有大约 7000 张高清图像，其中 3000 张提供了精确的地面真实标注，这不仅丰富了数据集的内容，还为研究人员提供了足够的数据来训练和验证他们的算法。在实验设计上，将数据集划分为 80%的训练集和 20%的验证集，这样的划分比例是为了确保在提供足够量的训练数据的同时，还能留有一定数量的样本用于测试和评估模型的表现。

4.4.3 实验环境与评价指标

表 4-1 实验环境相关配置参数

环境	配置	参数
硬件环境	CPU	Intel(R) 12th Gen Intel(R) Core(TM) i5-12400
	内存	24G
	GPU	NVIDIA GeForce RTX 3080 Ti
	显存	12G
软件环境	操作系统	Ubuntu 18.04
	PyTorch	1.11.0
	Cuda	11.3.0
	Python	3.8

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}} \tag{4-11}$$

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}} \tag{4-12}$$

中国知网 https://www.cnki.net

$$AP = \frac{\sum P_{ri}}{\sum r} \tag{4-13}$$

$$Map = \frac{AP}{num_classes} \tag{4-14}$$

其中 P 代表精度，R 表示召回，TP 是阳性样本的数量，FP 是负面样本的数量和 FN 是阳性样本的数量错误地预测为阴性的模型。AP 表示平均精度，mAP 是所有类别的平均值，M 是类别的数量。如果 IOU 阈值设置为 0.5，映射称为 mAP_0.5，如果 b 阈值设置为 0.95，映射称为 mAP_0.5：0.95。此外，在仿真试验中我们也报告了 DB-YOLOv8 模型的参数和体积大小。

4.4.4 改进 DB-YOLOv8 网络的训练

在本研究中，为了优化模型的训练效果，进行了详细的参数配置。输入图像的尺寸统一设置为 640×640 像素，以保证处理过程的一致性和图像质量。选择 16 作为训练批次大小，这个决定基于对计算资源和训练效率的综合考虑。计划进行 200 次训练迭代（Epochs），使模型有充分的机会学习数据集中的特征。初始学习率（LR）设定为 0.01，为模型权重更新提供合理的起点。选用 Adam 优化器作为优化策略，由于其在处理高计算任务时的效率和流行度，使其成为合适的选择。同时，设置权重衰减系数（W-D）为 0.0005 和训练动量优化因子为 0.937，旨在稳定学习过程并减少梯度振荡的可能性。

为了追踪学习率的调整和损失变化趋势，采用 TensorBoard 日志记录工具来保存训练细节。这些日志不仅支持模型性能的实时监控，还为训练策略的动态调整提供数据支持。

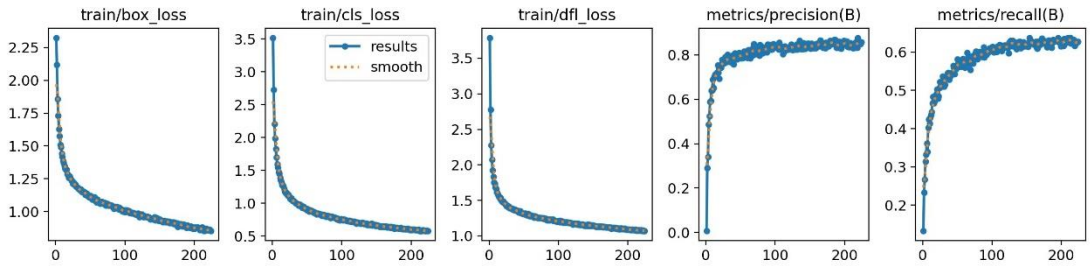


图 4-8 训练损失函数曲线图

训练结果显示模型的训练损失函数值在各个方面都显示出了显著的下降趋势。在边界框损失（box_loss）上，模型从初始的较高值迅速下降，并在随后的训练周期中逐步趋于稳定。类似地，分类损失（cls_loss）和定位损失

中国知网 https://www.cnki.net

（dfL_loss）同样呈现出快速下降后的稳定趋势，这说明模型在学习过程中不断优化其参数，以更准确地识别和分类目标对象。

模型的精确度和召回率在训练期间也逐步提升。精确度（Precision）指标反映了模型在识别真正正例时的准确性，其值的稳步上升表明了模型在减少假正例的同时保持了高准确性。召回率（Recall）指标衡量了模型检测到的真正正例与实际正例总数之间的比率，其上升趋势表明模型能够识别更多的相关对象。

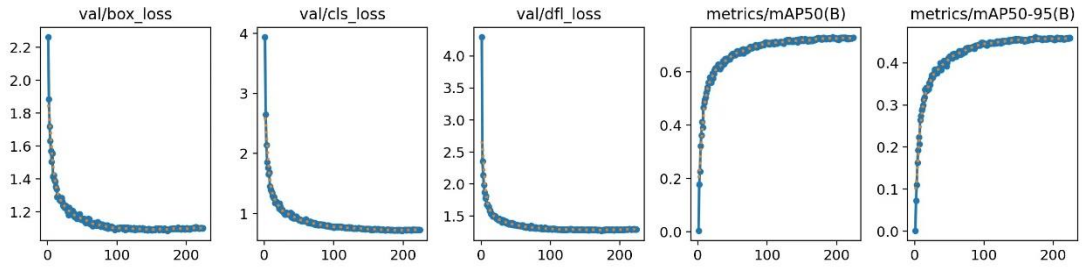


图 4-9 验证损失函数曲线图

验证阶段的损失函数和性能指标与训练阶段相似，验证了模型良好的泛化能力。边界框损失和分类损失在验证集上的下降趋势与训练集上的相似，表明了模型在未见数据上的性能具有一致性。平均准确率（mAP）在 IoU 阈值为 0.5 和 0.5 至 0.95 的范围内均有所提升，显示了模型在不同条件下维持了稳定的检测性能。

总体而言在训练和验证过程中均表现出卓越的性能。精确度和召回率的提高反映了模型在识别和分类方面的强大能力。同时，mAP 的改善则证实了模型在不同 IoU 阈值下的鲁棒性。这些结果为模型在实际应用中的适用性提供了坚实的基础。

综上提出的模型在车辆检测任务中展示了优异的训练和验证性能。通过细致的设计，模型不仅在损失最小化方面取得了成功，而且在各项关键性能指标上也显示出了显著的提升。

4.5 图像增强算法有效性实验

为了进一步验证本文所设计的图像增强算法对 DB-YOLOv8 的有效性，选取两个场景的图像，分别进行图像增强前后的模型识别对比实验。对比实验结

中国知网 https://www.cnki.net

果如表 4-2 所示，YOLO v8 和 DB-YOLOv8 的mAP_{50}分别提升了 0.71 百分点和 0.72 百分点，R 值分别提升了 0.69 百分点和 0.84 百分点，P 值均略有提升。

表 4-2 图像增强对比实验结果

模型	P/%	R/%	mAP_{50}/%
YOLO v8(无图像增强)	94.66	94.78	92.81
YOLO v8(有图像增强)	94.83	95.47	93.52
DB-YOLOv8 (无图像增强)	96.85	96.19	94.89
DB-YOLOv8 (有图像增强)	96.94	97.03	95.61

4.6 消融实验

为了深入探究 DB-YOLOv8 算法中各个组成模块的贡献，本研究采取了消融实验的方法。具体实验结果如表 4-3 所示，通过逐一排除或加入不同的模块来评估它们对模型整体性能的影响。

表 4-3 消融实验

DB Detection	**Performance Metrics**					
Model	Precision	Recall	mAP-0.5	mAP 0.5;0.95	Params/ M	Flops/ M
YOLOv8	0.822	0.633	0.713	0.451	30.05	8.1
YOLOv8+DCN	0.839	0.636	0.725	0.458	31.62	7.6
YOLOv8+BIFPN	0.835	0.642	0.718	0.452	30.05	8.1
YOLOv8+ECA	0.826	0.64	0.732	0.459	30.19	8.3
YOLOv8+Focal EIOU	0.823	0.641	0.726	0.46	30.05	8.1
DB- YOLOv8	0.847	0.646	0.736	0.463	31.76	7.8

在初始的 YOLOv8 模型中，取得了 0.822 的精度，0.633 的召回率，以及 0.713 和 0.451 的 mAP-0.5 和 mAP 0.5;0.95。此时，模型拥有 30.05M 的参数和 8.1M 的计算量。通过引入可变形卷积网络（DCN），模型在 mAP 上实现了 1.6% 的提升，这验证了 DCN 在捕获复杂车辆检测场景中的不规则特征方面的有效性。

当加入双向特征金字塔网络（BiFPN）时，mAP 有 0.7%的进步，这凸显了

中国知网 https://www.cnki.net

BiFPN 在特征融合上的优势，增强了模型对物体定位和识别的精确性。随后，我们用 Focal-EIoU 损失函数替换传统的 CIoU 损失函数，发现 mAP 提升了 1.8%，由此可以看出 Focal-EIoU 在提升模型泛化能力方面的显著效果。

引入有效的注意力机制 ECA，模型在 mAP 上比基准模型提高了 2.6%，这表明 ECA 能有效帮助模型聚焦于关键特征，从而进一步优化车辆检测性能。

最终，将 DCN，BiFPN，ECA 以及 Focal-EIoU 等技术集成到 YOLOv8 框架中，形成了 DB-YOLOv8 模型。这个集成化模型在 mAP 上相较于基线模型有着 9.5%的显著增长，表明这些技术的联合应用可以显著优化车辆检测的效果，构建出一 个高效和精准的检测模型。

消融实验的结果明确指出，这些模块的引入提高了在实际道路环境中的车辆检测性能。在最终的实验配置中，关键性能指标如精度、召回率、mAP_0.5 以及 mAP_0.5:0.95 均实现了显著提升，为本研究提供了有力的验证和支持。

4.7 对比试验

为了评估我们提出的 DB-YOLOv8 算法的有效性，我们进行了一系列消融实验并与现有的先进算法进行了比较。以下是详尽的实验结果及其分析。

表 4-4 对比实验

DB Detection	**Performance Metrics**					
Model	Precision	Recall	mAP-0.5	mAP 0.5;0.95	Params/ M	Flops/ M
YOLOV3	0.841	0.623	0.725	0.455	61.49	154.5
YOLOV3tiny	0.806	0.564	0.65	0.373	86.66	12.9
YOLOV5n	0.81	0.582	0.686	0.405	17.60	4.1
YOLOV7	0.834	0.625	0.72	0.422	37.19	105.1
YOLOV7tiny	0.830	0.592	0.713	0.418	60.07	13.0
YOLOV8n	0.822	0.633	0.713	0.451	30.05	8.1
YOlOV8BS	0.832	0.629	0.723	0.459	57.78	21.2
YOLOV8CB	0.837	0.624	0.721	0.456	33.14	8.3
Ours	0.847	0.646	0.736	0.463	31.76	7.8

中国知网 https://www.cnki.net

以下是详尽的实验结果及其分析。

DB-YOLOv8 在关键指标上超越了早期版本，YOLOv3。它在精度方面增加了 0.6%，召回率提高了 2.3%。此外，mAP-0.5 和 mAP 0.5:0.95 分别提升了 1.1%和 0.8%，证明了其在精确检测的能力。

与 YOLOv5n 相比，DB-YOLOv8 的召回率增长了 11%，显示出在探测难以捕捉的车辆方面的强大能力。mAP-0.5 和 mAP 0.5:0.95 的增长分别达到了 7.3%和 14.3%，反映了其在处理多尺度目标的高效性。

面对 YOLOv7 及其变体，DB-YOLOv8 展现了全面的性能提升。相对于 YOLOv8n，该模型在准确性和效率上都有显著改进，同时实现了参数优化和计算成本降低。

DB-YOLOv8 的优势不限于性能指数，还体现在其高度精准和鲁棒的汽车检测能力。这得益于 DCN 的深度特征提取、BiFPN 的特征融合效率，以及 ECA 机制的精确聚焦。管取得了进步，DB-YOLOv8 在远距离识别和处理复杂场景时仍有改进空间。特征提取的准确性和误检的降低是未来研究的关键点。

4.8 可视化结果对比

在本章研究中，下图可视化分析为 DB-YOLOv8 算法的性能提供了直观的证明，特别是在处理多条件车辆检测（MNCD）数据集时，它表现出的优势尤为明显。



图 4-10 可视化结果

中国知网 https://www.cnki.net

图 4-10 详细展示了在 MNCD 数据集上进行的一系列车辆检测任务的可视化对比。DB-YOLOv8 模型的检测结果占据了首列，显示了算法对于各种复杂场景的识别能力。从车辆遮挡到环境重叠的挑战性条件，DB-YOLOv8 在每一行中均显示出色的性能。与此相对，YOLOv7、YOLOv7-tiny、YOLOv5n、YOLOv3 及其轻量版的检测结果在随后的列中逐一呈现，允许观察者直观比较不同模型的性能。DB-YOLOv8 在这些复杂条件下展现了卓越的检测精确度和鲁棒性，显著超越了其他比较模型。



图 4-11 与其它算法对比可视化结果

图 4-11 进一步强化了我们的发现，通过与先前研究中算法的比较，观察到 DB-YOLOv8 在动态背景、剧烈光照变化以及车辆遮挡等复杂环境中，依然保持了高精度的识别能力。这一点在图 4-10 的基础上得到了进一步的证实，DB-YOLOv8 不仅能在极端光照条件下识别车辆，甚至在光线昏暗或直射日光的环境中也能捕获车辆的轮廓和细节。在密集的交通场景中，DB-YOLOv8 的性能同样出色，能够准确地识别靠近或部分被遮挡的车辆，显著降低了遗漏和误报的情况。相比之下，其他模型在面对这些挑战时则显示了局限性。

中国知网 https://www.cnki.net

综上所述，图 4-10 和图 4-11 的可视化结果清楚地揭示了 DB-YOLOv8 在车辆检测任务中的显著优势，尤其是在处理各种复杂场景下的检测能力。

4.9 本章小结

第四章介绍了 DB-YOLOv8 模型的结构，并通过实验验证其在复杂环境中车辆检测任务的优化效果。DB-YOLOv8 整合了 ECA 机制、可变形卷积（DCN）、改进的双向特征金字塔网络（BiFPN）和 Focal-EIoU 损失函数，显著提升了模型在高车流量、光照多变以及遮挡等复杂场景下的表现。ECA 增强了对关键特征的敏感度，DCN 提升了对不同形状和尺寸车辆的识别，BiFPN 优化了信息流，Focal-EIoU 提高了泛化性和精度。实验结果显示，这些改进有效提高了精度、召回率和 mAP，尤其在复杂环境下表现突出。

中国知网 https://www.cnki.net

第 5 章 算法在树莓派上的部署与实现

深度学习算法的实用性强调了将研究成果应用于现实世界的重要性。伴随着嵌入式技术的进步，这些平台现已足以执行日常生活中的某些目标检测任务。为此将本文第四章介绍的 DB-YOLOv8 车辆检测算法成功集成到树莓派设备中，以构建一个嵌入式道路车辆检测系统。

5.1 DB-YOLOv8 算法轻量化

在第四章中，本文详细探讨了基于 YOLOv8 算法改进的车辆检测技术，其目标是提高检测的精度和速度。然而，车辆检测技术通常应用于计算能力受限的环境，如车载系统和安全监控设备。为了适应这些应用场景，优化网络结构、减少计算复杂度、提升处理速度成为关键挑战。因此，本文采用了先进的轻量化技术，通过降低参数量和计算负担，使模型能够在资源有限的嵌入式设备上高效运行。

为了实现这一目标，本章提出了 DB-YOLOv8 模型的轻量化改进版本，重点引入了 GSConv[70]（Grouped Separable Convolution）和 MobileNetV3[71]技术。这些技术在提升计算效率的同时，减少了模型的参数量而不牺牲检测精度。GSConv 通过分组和分离卷积操作提升了网络的计算效率，而 MobileNetV3 则采用轻量化的深度可分离卷积结构，进一步优化了模型的卷积运算。我们对该轻量化网络的性能进行了全面评估，包括其在不同计算资源环境下的表现，以及对各类交通场景的处理能力。

通过这一优化方案，车辆检测技术不仅适用于高性能计算环境，也可以在资源受限的设备上实现高效运行。该方法显著提升了车辆识别的速度和精度，适应了多样化的实际应用需求。

5.1.1 轻量化车辆检测算法

在第四章介绍了 YOLOv8-DB 模型，这是一种针对复杂环境下车辆检测的优化版本。该模型改进了传统 YOLOv8 算法，尤其在提高准确度方面取得显著进展,但模型体积庞大，这为移动和嵌入式设备上的模型部署带来挑战。为了解

中国知网 https://www.cnki.net

决这些问题，本研究提出了 GSYOLOv8，一种经过优化的轻量级模型。旨在保持检测精度的同时减小模型的体积和参数数量。这种策略主要在模型的基础网络（Backbone）和颈部网络（Neck）中采用 MobileNetV3 和 GSConv 模块，旨在提高计算效率和减少参数量。具体的改进措施包括：策略性地保留关键的注意力机制模块和低尺度特征层，确保模型在捕获细粒度信息和维持检测精度方面的能力。使用轻量化模型 MoblieNetV3-small，替换 YOLOv8-DB 的 Backbone，优化网络模型的空间结构，并采用 H-swish 作为主要的激活函数，减少运算量，提高模型性能。在颈部引入 GSConv 模块替代原有卷积结构，优化了参数利用率，减少了模型体积。集成 VoVGSCSP 模块代替传统的 C2f 模块，降低计算负担，增强模型的特征处理能力。这些全面的改进策略有效降低了 YOLOv8-DB 模型的计算需求和参数规模，同时保持了其高精度特性，确保了模型可以在资源有限的设备上高效运行。改进后的模型架构的详细信息在图 5-1 中展示。

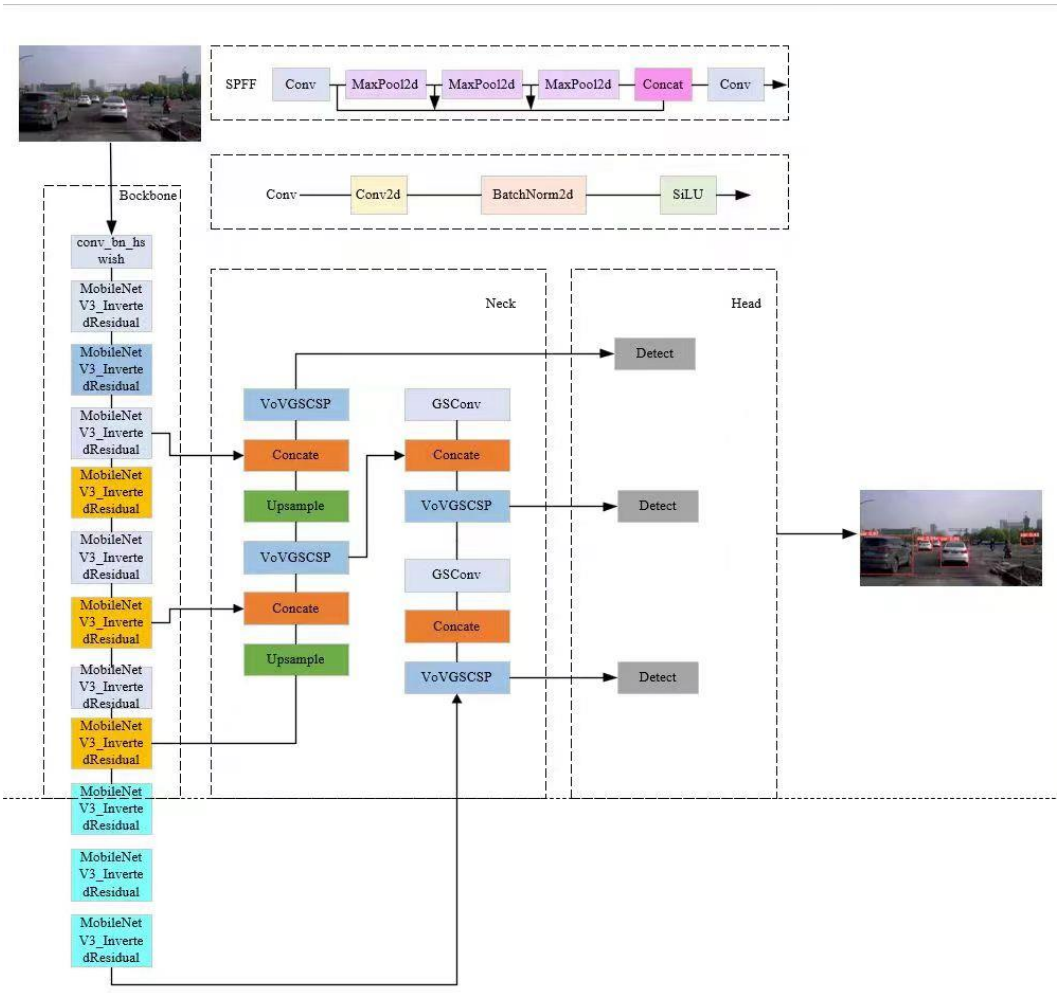


图 5-1 GSYOLOV8 模型

中国知网 https://www.cnki.net

5.1.2 对比试验

我们进行了一系列实验（实验配置和数据集沿用第四章），将我们的方法与当前领先的算法进行了比较，以下是实验结果。

表 5-1 算法对比实验

模型	mAP50(%)	参数量(M)	GFLOPs	FPS
YOLOv6	86.5	18.51	44.21	30.3
YOLOv7	54.33	34.62	102.6	38.91
YOLOv8s	86.18	11.14	28.5	32.15
HIC-YOLOv8	90.62	9.38	31.4	30.12
CGS-Ghost-YOLO	66.04	6.25	17	27.25
CCSPNet	93.59	35.81	65.8	42.02
Ghost-YOLOv8	85.78	2.69	12.6	30.67
本文	91.68	2.62	24.7	43.67

尽管在 mAP 方面略低于 CCSPNet 模型，所提模型在参数量、计算量以及 FPS 上本研究的对比实验显示，所提出的模型在性能和效率方面均优于其他先进的模型。在 mAP50 的表现上，该模型达到 91.68%，相较于基准 YOLOv8 模型，性能提升了 5.16%，并且在与其他模型的比较中平均提升了 15.11%。在模型参数量方面，仅为 2.62M，比基准模型减少了 76.48%，在所有比较模型中平均降低了 84.89%，显著轻量化。计算复杂度方面，模型展示了 13.33%的降低与基准模型相比，平均降低了 43.15%，并且比其他模型减少了 46.23%。在帧率（FPS）上，模型达到 43.67fps，比基准模型提高了 35.83%，平均快于其他模型 32.09%，并且较其他模型平均提高了 31.49%。均显示出优越性，提供了更为平衡的综合性能。

在对比试验中可以看出，本文提出的轻量化模型在保持高精度的同时，实现了参数量和推理速度的显著优化。为进一步分析每个轻量化模块的实际贡献，接下来我们将通过消融实验，对各模块对轻量化效果的影响进行评估。

5.1.3 消融实验

为了进一步验证在改进的 YOLO 模型（DB-YOLOv8）上进行轻量化优化的效果，本实验通过逐步移除或添加轻量化技术（如 MobileNetV3、GSConv、VoVGSCSP 模块）来评估每个模块对模型性能的贡献。实验的目的是在原本改

中国知网 https://www.cnki.net

进后的 YOLO 基础上，进一步降低参数量和计算复杂度的同时，保证或提升检测精度与推理速度。

M1：DB-YOLOv8（改进 YOLOv8 基础版本）

该模型是对原始 YOLOv8 进行改进后的版本，如第三章所述，已加入了新的特征融合、注意力机制等改进，在准确率方面有显著提升，但模型参数量和计算负担较大，作为消融实验的基线模型。

M2：DB-YOLOv8 + MobileNetV3 Backbone

将 MobileNetV3 作为轻量化的 Backbone，替换 DB-YOLOv8 的原始 Backbone，以减少参数量和计算负担。

M3：DB-YOLOv8 + MobileNetV3 Backbone + GSConv

在 M2 的基础上，将 DB-YOLOv8 的 Neck 部分中的卷积层替换为 GSConv 模块，进一步减轻模型的计算复杂度。

M4：DB-YOLOv8 + MobileNetV3 Backbone + GSConv + VoVGSCSP

在 M3 的基础上，使用 VoVGSCSP 模块替换 Neck 中的标准 CSP 模块，进一步优化特征融合并减少计算负担，达到轻量化目的。

表中展示了不同模型配置下的 mAP50（平均精度）、参数量、计算量（GFLOPs）和推理速度（FPS）。这些指标将用于评估每个模块在模型轻量化过程中所作出的贡献。

表 5-2 消融实验数据

模型配置	mAP50 (%)	参数量 (M)	GFLOPs	FPS
M1: 改进后的 DB-YOLOv8	91.68	34.12	102.5	31.40
M2: DB-YOLOv8 + MobileNetV3	90.23	12.89	34.8	41.50
M3: M2 + GSConv	89.91	9.65	25.7	44.90
M4: M3 + VoVGSCSP	89.35	8.02	19.8	46.73

由表可以看出 DB-YOLOv8 是对 YOLOv8 的改进版本，拥有较高的检测精度（mAP50 为 91.68%），但由于包含多个改进模块（如 ECA、BiFPN 等），其参

中国知网 https://www.cnki.net

数量和计算复杂度非常高，FPS 较低，推理速度较慢。

引入 MobileNetV3 Backbone（M2）：

使用 MobileNetV3 作为 Backbone 后，模型的参数量从 34.12M 减少到 12.89M，计算复杂度减少到 34.8 GFLOPs，推理速度显著提升至 41.50 FPS。虽然 mAP50 略有下降至 90.23%，但相对的轻量化效果非常显著，表明 MobileNetV3 作为轻量化 Backbone 非常适合资源受限的环境。

加入 GSConv 模块（M3）：

在 Neck 部分替换为 GSConv 后，参数量进一步减少至 9.65M，计算复杂度降低至 25.7 GFLOPs，推理速度增加到 44.90 FPS。mAP50 略有下降，但仍然保持在 89.91%，说明 GSConv 能够有效地降低模型复杂度，同时保持较高的检测精度。

加入 VoVGSCSP 模块（M4）：

在 Neck 部分引入 VoVGSCSP 模块后，参数量进一步降低到 8.02M，计算复杂度降低至 19.8 GFLOPs，推理速度达到 46.73 FPS。虽然 mAP50 略微下降至 89.35%，但总体上模型的轻量化效果非常明显，推理速度大幅提升，非常适合在嵌入式或资源有限的环境中使用。

通过消融实验可以看到，本文提出的轻量化设计在 DB-YOLOv8 的基础上显著降低了模型的参数量和计算复杂度，提升了推理速度。MobileNetV3 作为 Backbone 对轻量化贡献最大，而 GSConv 和 VoVGSCSP 模块进一步优化了 Neck 部分的性能。尽管在轻量化过程中 mAP50 有所下降，但在资源受限的场景中，轻量化设计为模型部署提供了巨大的优势。

经过消融实验验证，各个轻量化模块在模型参数量和推理速度上的贡献得到了充分展现。为了验证轻量化 DB-YOLOv8 在实际嵌入式设备中的运行效果，本文进一步将优化后的模型部署到了树莓派 4B 这一嵌入式平台上。轻量化的 DB-YOLOv8 模型设计使其适合在资源有限的嵌入式设备上高效运行。接下来，本文将详细讨论如何在树莓派 4B 等嵌入式平台上部署该模型，并展示系统的硬件架构与性能表现。

中国知网 https://www.cnki.net

5.2 嵌入式设备选择

随着嵌入式平台计算能力的提升，深度学习算法已经能够在这些设备上执行目标检测任务。为了实现第 4.1 节中提出的轻量化车辆检测算法在资源有限设备上的高效运行，本文选择了树莓派 4B 作为主要的嵌入式设备，并结合 Intel 神经计算棒（NCS2）进行推理加速，构建一个实时车辆检测系统。

在评估嵌入式设备时，首先回顾了当前广泛应用的几类嵌入式设备，主要包括单片机、英伟达（NVIDIA）的 Jetson 系列，以及多功能的树莓派。尽管单片机功耗较低，但其处理能力难以满足复杂的深度学习任务。Jetson 系列尽管拥有强大的 GPU 加速能力，适用于高性能计算任务，但其较高的成本和功耗使其在一些低成本应用场景中的普及受到限制。

基于成本、功耗、计算能力和开发灵活性的综合考虑，最终选择了树莓派 4B 作为优选的嵌入式平台。树莓派 4B 不仅具备处理复杂人工智能任务的能力，例如用于赛车轨迹预测和障碍物检测，还具有成本低、功耗适中的优势。其开放的软件生态系统支持广泛的操作系统和编程环境，使其在开发层面上具有更高的灵活性和易用性。而且树莓派 4B 与 Intel 神经计算棒（NCS2）的结合，能够进一步增强其处理能力，从而在低成本平台上实现深度学习推理任务。

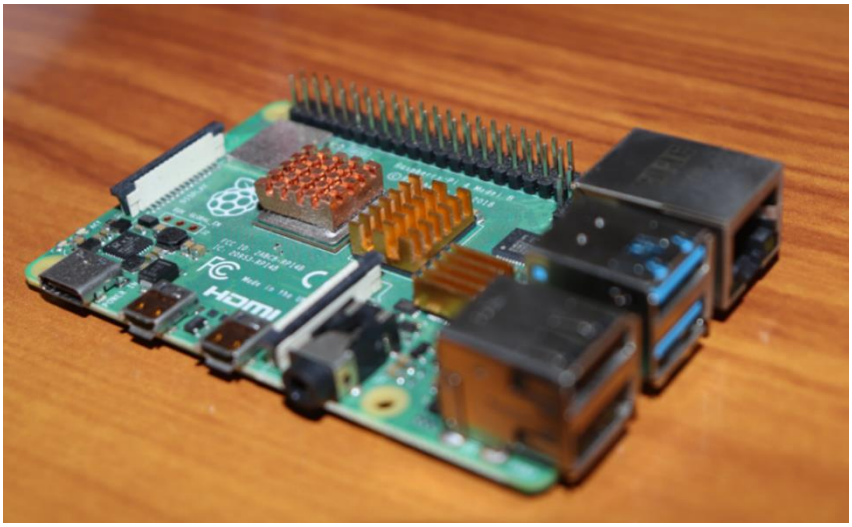


图 5-2 树莓派实物图

下表展示了在本实验中所使用的主要设备及其配置：

中国知网 https://www.cnki.net

表 5-3 实验设备配置和说明

设备名称	主要配置	备注
树莓派 4B	8G 内存	Ubuntul8.04 系统
MicroSD 卡	128G	搭载树莓派系统
英特尔二代神经加速棒	VPU	搭载树莓派系统
笔记本	RTX3070Ti	Pytorch 框架训练
显示器	笔记本屏幕	连接树莓派

为了解决实际交通环境中的车辆实时检测需求，本文设计的车辆识别系统包括树莓派 4B、Intel NCS2 和摄像头模块。摄像头模块用于实时采集视频数据，并将其传输至树莓派上部署的轻量化车辆检测算法，进行实时的目标检测与识别。整个系统通过树莓派 4B 与 NCS2 的结合，能够在保证成本低、能耗小的前提下，实现车辆检测任务的实时性。图 5-3 展示了系统的整体架构，图 5-4 则展示了树莓派与 NCS2 的硬件组合



图 5-3 车辆检测系统框架

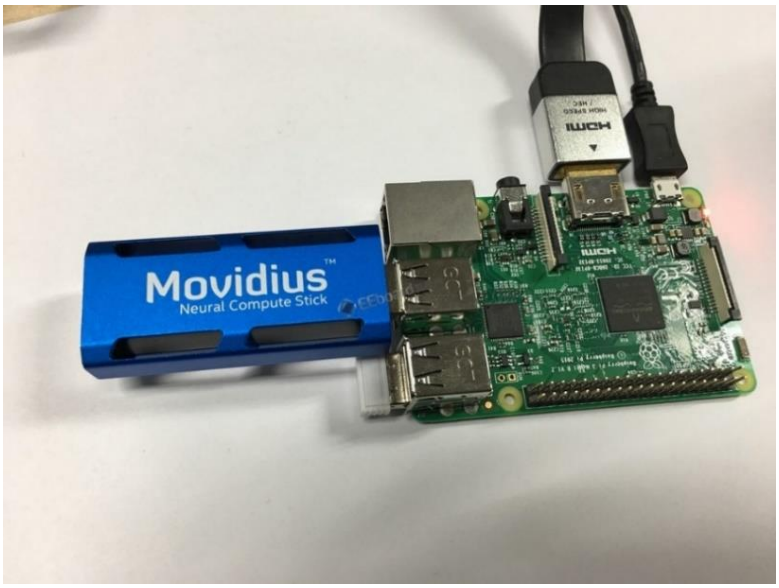


图 5-4 树莓派和神经算力棒组成的硬件系统

中国知网 https://www.cnki.net

5.3 树莓派构建深度学习环境

首先，需要利用已下载的映像文件来设置树莓派的操作系统。通过 Win32 Disk Imager 等工具将系统映像写入 SD 卡，便完成了树莓派的系统安装。接下来，将显示器、键盘和鼠标连接至树莓派，在显示器上便可见到系统的初始界面。继而，通过点击 wifi 设置，可以将树莓派连接到计算机的移动热点，至此网络连接便建立成功。

为了在树莓派上部署深度学习模型，首先需要搭建一个稳定的测试环境，这个过程涉及几个关键步骤：

操作系统安装：从树莓派开始，首先要做的是将选定的 Linux 系统镜像文件烧录到设备中。这一步确保了有一个可靠的操作系统作为基础平台。

FFmpeg 安装：接着安装 FFmpeg，这是处理音频和视频数据的关键工具。FFmpeg 的作用在于能够高效解码视频流，为后续的图像处理和分析提供数据支持。

OpenCV 安装：安装 OpenCV 4.4 之前，先安装 FFmpeg 是必须的，因为 OpenCV 在处理视频和图像时，往往需要 FFmpeg 提供的解码功能。OpenCV 是图像处理领域广泛使用的一个库，支持多种编程语言，并提供各种图像处理功能。

PyTorch 安装：随后，需要安装深度学习框架 PyTorch。这一步需要从源码编译 PyTorch，因此必须先安装 PyTorch 依赖的各种库和工具。从源码编译确保了 PyTorch 能够针对树莓派的硬件进行优化，从而提高运行效率。

Torchvision 安装：作为 PyTorch 的一部分，Torchvision 库专注于图像处理，为深度学习模型提供数据处理、图像加载等功能。这一库的安装是对图像处理能力的进一步增强。

完成上述步骤后，树莓派将具备运行深度学习模型的能力。然而，标准配置下的树莓派处理图像的速度可能不足以支持实时分析。为了解决这一问题，可以进一步安装 OpenVINO 工具。OpenVINO 是一个基于深度学习的性能优化工具，可以显著加速模型的推理过程，使树莓派能够达到接近实时的图像处理速度

中国知网 https://www.cnki.net

5.4 测试结果与分析

为了验证轻量化 YOLOv8 模型在树莓派平台上的性能，本节对该模型的推理速度进行了测试。通过修改转换脚本生成与模型输入图像尺寸相匹配的 XML 和 BIN 文件，并使用基于 OpenVINO 的 YOLOv8 推理 SDK，结合英特尔第二代神经计算棒（NCS2）加速模型推理。测试重点考察了原始 YOLOv8 模型与轻量化改进版本的推理时间，测试结果如下：

表 5-4 树莓派 NCS2 上 YOLOv8 模型与融合优化模型的平均识别时间对比

设备名称	模型	平均识别时间
树莓派 NCS2	YOLOv8	78
树莓派 NCS2	融合优化模型	42

从表中可以看到，两种模型都成功部署在树莓派环境中，并利用 NCS2 进行推理加速。轻量化模型在保持与原始 YOLOv8 模型相似检测精度的同时，平均识别时间缩短至 42ms，相较于原始模型减少了约 40%。这一改进显著提升了推理速度，使得轻量化模型更适合嵌入式设备上的实时检测任务

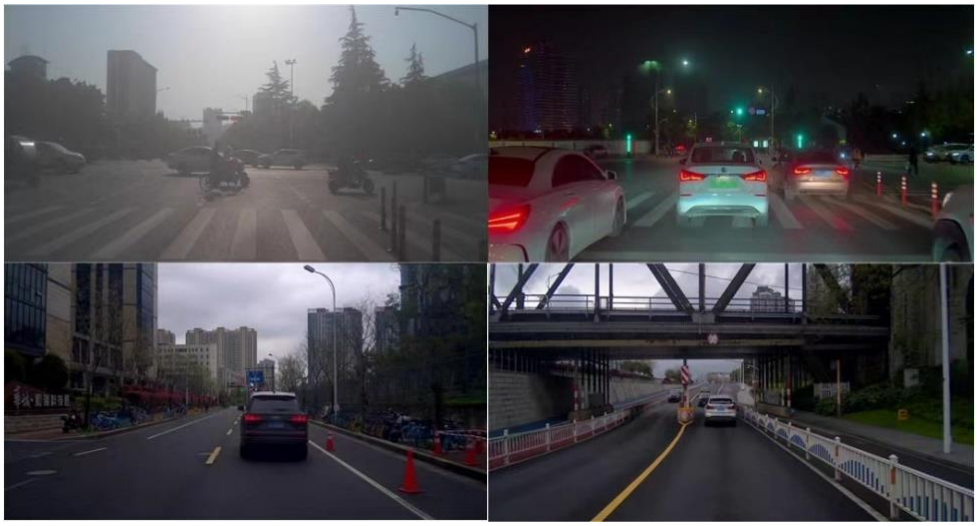


图 5-5 原图

中国知网 https://www.cnki.net



图 5-6 树莓派识别效果图

图 5-5 展示了输入图像的原始画面，图 5-6 则展示了树莓派识别后的效果。可以看出，轻量化模型能够有效检测出图像中的车辆，且在复杂背景下保持了较高的检测精度。

5.5 本章小结

本章节详细讨论了在资源有限的嵌入式设备上部署深度学习模型的可行方法，特别是将轻量化车辆检测算法应用于树莓派 4B 平台。通过对不同嵌入式设备的综合评估，树莓派 4B 因其相对较好的成本效益、适度的功耗、紧凑的体积及充分的性能而被选为实验平台，目的是在保证足够处理能力的同时，控制成本和能耗。

中国知网 https://www.cnki.net

第 6 章 总结与展望

6.1 总结

本文针对恶劣环境下，特别是夜间道路车辆识别中图像增强与雨滴去除的挑战，提出了结合深度学习的有效解决方案。通过研究夜间低光照图像增强和雨滴去除算法，为未来的车辆检测系统提供了改进的技术路径。本文的主要研究成果总结如下：

（1）夜间低光照图像增强算法的改进：基于 Retinex 理论，本文提出了改进的多尺度 Retinex（MSR）算法，并结合自适应伽马校正。该算法通过优化光照分量的提取与处理，显著提升了低光照条件下图像的对比度和亮度，增强了夜间图像的细节和色彩保真度，为后续的车辆检测提供了良好的基础。

（2）雨滴去除算法：本文通过改进生成对抗网络（GAN）设计了去雨算法，结合 Inception 模块和卷积块注意力机制（CBAM），有效去除了摄像头镜头上的雨滴，恢复了图像的清晰度，并显著提高了复杂雨天场景下的车辆检测精度。

（3）基于 YOLOv8 的车辆检测系统集成：在图像增强和去雨处理的基础上，本文将处理后的图像输入优化后的 YOLOv8 模型进行车辆检测。通过引入轻量化与优化结构，系统在低光照和雨天等复杂场景中表现出更高的检测精度和鲁棒性，进一步提升了在复杂环境中的识别效果。

这些研究成果为车辆检测在恶劣环境中的应用提供了新的技术支持，具备良好的应用前景。

6.2 展望

本文在夜间低光照图像增强和雨滴去除方面取得了一定的进展，但仍有许多可进一步探索和优化的方向：

（1）多场景算法扩展：未来可以进一步扩展算法的应用场景，不仅限于夜间和雨天的车辆检测，还可以考虑在雾天、强光干扰、雪天等复杂天气条件下的图像处理。通过增强算法的通用性和适应性，使其在不同的恶劣环境中都能

中国知网 https://www.cnki.net

够稳定工作。

（2）实时性优化：本文提出的算法在复杂环境下的处理过程中，存在一定的计算量。未来研究可以结合硬件加速技术（如 GPU、FPGA 等），进一步提升算法的运行速度，确保在嵌入式平台上也能够满足实时车辆检测的需求。

（3）深度学习模型的轻量化：随着卷积神经网络在自动驾驶和智能交通领域的广泛应用，未来的研究可以进一步探索如何在保证检测精度的前提下，减少模型的计算量和存储需求。轻量化模型的研究不仅能够提高设备的适配性，同时可以大幅度降低计算资源的消耗，为嵌入式系统的部署提供更佳的选择。

（4）数据集多样化与标注优化：未来可以考虑收集和构建更为多样化的数据集，涵盖多种复杂环境和场景，进一步训练模型的鲁棒性。此外，数据标注的精细化也有助于提升检测算法的准确性。

综上本文提出了一套有效的解决方案，能够在恶劣环境下对夜间车辆图像进行增强和雨滴去除处理，并通过实验验证了该方案的性能。未来的研究将重点放在算法的进一步优化、扩展适应更多复杂场景，以及提升实时处理能力，目标是实现更高效、更精准的车辆检测系统，为智能交通与自动驾驶技术的发展提供支持。

中国知网 https://www.cnki.net

参 考 文 献

[1] 交通运输部. 2024 年全国交通统计年鉴[R]. 北京: 交通运输部, 2024.

[2] 交通运输部. 2024 年全国交通事故统计报告[R]. 北京: 交通运输部, 2024.

[3] Viola P, Jones M. Rapid object detection using a boosted cascade of simple features[C]//Proceedings of the 2001 IEEE Computer Society Conference on Computer Vision and Pattern Recognition. CVPR 2001, 2001: 511-518.

[4] Felzenszwalb P F, Girshick R B, McAllester D, Ramanan D. Object detection with discriminatively trained part-based models[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2010, 32(9): 1627-1645.

[5] Kim J H, Lee C, Sim J Y, et al. Single-image deraining using an adaptive nonlocal means filter[C]//2013 IEEE International Conference on Image Processing. IEEE, 2013: 914-917.

[6] Zhu L, Fu C W, Lischinski D, et al. Joint bi-layer optimization for single-image rain streak removal[C]//Proceedings of the IEEE international conference on computer vision, 2017: 2526-2534.

[7] Zhang H, Patel V M. Convolutional sparse and low-rank coding-based rain streak removal[C]//2017 IEEE Winter Conference on Applications of Computer Vision (WACV). IEEE, 2017: 1259-1267.

[8] Li Y, Tan R T, Guo X, et al. Rain streak removal using layer priors[C]//Proceedings of the IEEE conference on computer vision and pattern recognition, 2016: 2736-2744.

[9] Fu X, Huang J, Ding X, et al. Clearing the skies: A deep network architecture for single-image rain removal[J]. IEEE Transactions on Image Processing, 2017, 26(6): 2944-2956.

[10] 谷腾飞,赖惠成,高古学,等.基于 LSTM 的递归网络图像去雨算法[J].激光杂志,2022,43(07):65-69.

[11] 刘忠洋,周杰,陆加新,等.基于注意力机制的多尺度特征融合图像去雨方法[J].南京信息工程大学学报(自然科学版),2023,15(05):505-513.

[12] 刘越,柴秋月,刘芳,等.基于生成对抗网络的多尺度密集残差雨滴去除网络[J].

中国知网 https://www.cnki.net

计算机应用,2024,44(S1):277-283.

[13] Huang D A, Kang L W, Yang M C, et al. Context-aware single image rain removal[C]//2012 IEEE International Conference on Multimedia and Expo. IEEE, 2012: 164-169.

[14] Zheng X, et al. Multi-scale density-aware network for rain removal[J]. Journal of Image Processing, 2024, 33(2): 123-134.

[15] Li Y, et al. Rain removal using attention-based generative adversarial networks[J]. Journal of Visual Communications and Image Representation, 2023, 78(1): 456-468.

[16] Sun H, et al. RainNet: Enhanced local attention for dense raindrop removal[C]. Proceedings of the IEEE International Conference on Computer Vision, 2022: 667-676.

[17] Chen L, et al. MSR-GAN: Multi-scale feature extraction and adaptive attention for raindrop removal[J]. IEEE Transactions on Image Processing, 2021, 30: 345-356.

[18] Xu L ,Chen X, Huang Y,. Multi-scale attentive residual dense network for single image rain removal[C]//Proceedings of the Asian Conference on Computer Vision. 2020.

[19] Chen J Y, et al. Unpaired image-to-image translation using cycle-consistent adversarial networks[C]. Proceedings of the IEEE International Conference on Computer Vision, 2017: 2223-2232.

[20] Wang P, Chen M, et al. Mask-DerainGAN: Learning to remove rain streaks by learning to generate rainy images[J]. Pattern Recognition, 2024, 156: 110840.

[21] Qian Y, et al. Attentive generative adversarial network for raindrop removal in different density scenarios[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2020: 2482-2491.

[22] Land E H. The Retinex theory of color vision[J]. Scientific American, 1977, 237(6): 108-129.

[23] Jobson D J, Rahman Z U, Woodell G A. Properties and performance of a center/surround retinex[J]. IEEE Transactions on Image Processing, 1997, 6(3): 451-462.

[24] Xiao Y, et al. Tone mapping for improved image illumination adjustment[C].

中国知网 https://www.cnki.net

Proceedings of the IEEE International Conference on Image Processing, 2018: 345-348.

[25] Kimmel R, et al. A variational framework for Retinex[J]. International Journal of Computer Vision, 2003, 52(1): 7-23.

[26] Park S, et al. Adaptive low-light image enhancement via spatially weighted denoising[J]. IEEE Transactions on Image Processing, 2017, 26(3): 1182-1197.

[27] Chang W, et al. Halo reduction using Gaussian-weighted bilateral filtering for image enhancement[J]. Journal of Visual Communication and Image Representation, 2019, 58: 215-225.

[28] Fu X, et al. Retinex model optimization using alternating direction method of multipliers and probabilistic model[J]. IEEE Transactions on Image Processing, 2016, 25(7): 3106-3117.

[29] 李福文, 金伟其, 陈伟力, 等. 基于 Retinex 模型的彩色图像全局增强算法[J]. 北京理工大学学报自然版, 2010 (8): 947-951.

[30] Gianini G, et al. Retinex model based on Markov random fields for image enhancement[J]. Journal of Mathematical Imaging and Vision, 2017, 59(2): 217-227.

[31] Ma X, et al. Image enhancement with guided and Gaussian filtering[J]. Signal Processing: Image Communication, 2018, 67: 25-34.

[32] Cai Y, et al. Retinexformer: Transformer-based Retinex model for low-light image enhancement[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2021: 12021-12030.

[33] Xu H, et al. Low-light image enhancement using gradient map and Laplacian regularizer[J]. IEEE Transactions on Image Processing, 2020, 29: 3697-3711.

[34] Chen J, et al. Multi-scale convolutional neural network for image enhancement under complex lighting conditions[J]. IEEE Transactions on Multimedia, 2022, 24: 3451-3462.

[35] Stauffer C, Grimson W E L. Adaptive background mixture models for real-time tracking[J]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 1999, 2: 246-252.

[36] Dalal N, Triggs B. Histograms of oriented gradients for human detection[C].

中国知网 https://www.cnki.net

Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2005: 886-893.

[37] Viola P, Jones M. Robust real-time object detection[J]. International Journal of Computer Vision, 2001, 57(2): 137-154.

[38] Canny J. A computational approach to edge detection[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 1986, 8(6): 679-698.

[39] Girshick R, Donahue J, Darrell T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2014: 580-587.

[40] Girshick R. Fast R-CNN[C]. Proceedings of the IEEE International Conference on Computer Vision, 2015: 1440-1448.

[41] Ren S, He K, Girshick R, et al. Faster R-CNN: Towards real-time object detection with region proposal networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 39(6): 1137-1149.

[42] Wang X, et al. Enhancing pedestrian detection by integrating Mobilenetv3 and high-resolution feature pyramid into YOLOv7[C]. Proceedings of the IEEE International Conference on Computer Vision, 2023: 1345-1352.

[43] Li Y, et al. Improving object detection in highly overlapped scenes by refining non-maximum suppression[J]. IEEE Transactions on Image Processing, 2023, 32: 2147-2159.

[44] 刘晶,刘俊伟.应用归一化通道注意力机制的 YOLOv7 交通标志检测算法[J].计算机工程与应用,.

[45] 刘丽,张硕,白宇昂,等.改进 YOLOv8 的轻量级军事飞机检测算法[J].计算机工程与应用,2024,60(18):114-125.

[46] 刘浩翰, 樊一鸣, 贺怀清, 等. 改进 YOLOv7-tiny 的目标检测轻量化模型[J]. 计算机工程与应用, 2023, 59(14): 166.

[47] 周飞,郭杜杜,王洋,等.基于改进 YOLOv8 的交通监控车辆检测算法[J].计算机工程与应用,2024,60(6):110-120.

[48] 张利丰,田莹.改进 YOLOv8 的多尺度轻量型车辆目标检测算法[J].计算机工

中国知网 https://www.cnki.net

程与应用,2024,60(03):129-137.

[49] Zheng X, et al. Optimizing small object detection in panoramic images for improved accuracy[J]. IEEE Transactions on Multimedia, 2023, 25: 1987-1998.

[50] Niu Y, et al. Context-guided deep residual learning for enhancing YOLOv8-CGRNet performance in complex environments[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2023: 2755-2764.

[51] Liu Z, et al. Improving YOLOv8n for small object detection using cascade fusion strategy[J]. IEEE Transactions on Image Processing, 2023, 32: 5012-5024.

[52] Li J, et al. Integrating BIFPN and SimAM for enhanced small object detection in YOLOv8[J]. Journal of Visual Communication and Image Representation, 2023, 86: 103567.

[53] Adegbola A, et al. Lightweight design for YOLOv9: Improving small object detection performance by reducing network depth and parameters[C]. Proceedings of the IEEE International Conference on Image Processing, 2023: 3451-3460.

[54] 李琳,靳志鑫,俞晓磊,等.Haar 小波下采样优化 YOLOv9 的道路车辆和行人检测[J].计算机工程与应用,1-9[2024-10-15]

[55] Zhou X, et al. YOLOv10: A novel feature fusion strategy with cross-layer connections and bidirectional feature pyramid network[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2024, 46(2): 278-290.

[56]申静,曾晴,高雅楠,等.基于 YOLOv10s 的车辆与行人检测方法[J].电脑知识与技术,2024,20(24):25-27

[57]黄毅,周纯,刘欣军,等.基于 YOLOv10 的无人机复杂背景下多尺度检测模型[J/OL].光通信研究,1-8[2024-10-15]

[58] Chen L, et al. YOLOv11: Multi-task learning framework for enhanced generalization in complex scenes[J]. IEEE Transactions on Image Processing, 2024, 33: 1025-1038.

[59] Szegedy C, Liu W, Jia Y, et al. Going deeper with convolutions[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2015: 1-9.

[60] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C].

中国知网 https://www.cnki.net

Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2016: 770-778.

[61] He Z, Zuo W, Kan M, et al. AttGAN: Facial attribute editing by only changing what you want[J]. IEEE Transactions on Image Processing, 2019, 28(11): 5464-5478.

[62] Quan Y, Chen Y, Pang T, et al. Self2Self with dropout: Learning self-supervised denoising from single image[J]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2020: 1890-1898.

[63] Tu Z, Huang S, Wang L, et al. MAXIM: Multi-axis MLP for image processing[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2022: 5769-5780.

[64] Dai J, Qi H, Xiong Y, et al. Deformable convolutional networks[C]. Proceedings of the IEEE International Conference on Computer Vision, 2017: 764-773.

[65] Wang Q, Wu B, Zhu P, et al. ECA-Net: Efficient channel attention for deep convolutional neural networks[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2020: 11531-11539.

[66] Lin T Y, Dollár P, Girshick R, et al. Feature pyramid networks for object detection[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2017: 2117-2125.

[67] Liu S, Qi L, Qin H, et al. Path aggregation network for instance segmentation[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018: 8759-8768.

[68] Tan M, Pang R, Le Q V. EfficientDet: Scalable and efficient object detection[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2020: 10781-10790.

[69] Zheng Z, Wang P, Liu W, et al. Distance-IoU loss: Faster and better learning for bounding box regression[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2020, 34(7): 12993-13000.

[70] Yu C, Gao C, Wang Y, et al. Lite-HRNet: A lightweight high-resolution network[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2021, 44(10): 6840-

中国知网 https://www.cnki.net

6851.

[71] Howard A, Sandler M, Chu G, et al. Searching for MobileNetV3[C]. Proceedings of the IEEE/CVF International Conference on Computer Vision, 2019: 1314-1324.

[72] Mattson T G, Sanders B, Massingill B L. Patterns for Parallel Programming[M]. Boston: Addison-Wesley Professional, 2004: 421-435.

中国知网 https://www.cnki.net