学校代码	10608
学　　号	2021208540014 72
分 类 号	TP183
密　　级	公开



广西民族大学

GUANGXI MINZU UNIVERSITY

硕士学位论文

基于深度学习的多目标跟踪算法研究

研 究 生 姓 名：胡瑞聪

导师姓名职称：邱季 讲师

专业学位类别：电子信息

专业学位领域：电子信息

所 属 学 院：电子信息

年　　级：2021 级

论文完成时间：2024 年 12 月

中国知网 https://www.cnki.net

分类号：TP183　　密级：公开

广西民族大学

硕士研究生学位论文

论文题目　基于深度学习的多目标跟踪算法研究

专业学位类别　电子信息

研究生姓名　胡瑞聪

指导教师　邱季

论文完成日期：2024 年 12 月 15 日

中国知网　https://www.cnki.net

基于深度学习的多目标跟踪算法研究

摘 要

近年来，计算机视觉领域的研究取得了长足进展，多目标跟踪作为基础视觉任务之一，不仅需要检测视频序列中感兴趣的目标实例，还需要持续跟踪和维护其运动轨迹，这在诸如智能安防、智慧城市、自动驾驶等应用场景中具有重要价值。然而，真实场景下的视频数据往往存在目标遮挡、重叠、存在小目标等复杂情况，这为多目标跟踪任务带来了严峻挑战，迫切需要研究人员针对性地提出有效的解决方案。因此，本文针对上述多目标跟踪问题，开展了优化目标算法，改进跟踪时的匹配策略研究，主要工作内容如下：

（1）为解决多目标跟踪过程中小目标对象跟踪失败的问题，在 YOLOX 算法的基础上，在特征融合阶段，采用来自 4 个不同尺度的特征层，涵盖从高分辨率到低分辨率的丰富特征信息。与此同时，通过采用上下文跳跃连接的方式，将深层次的语义特征与浅层次的细粒度特征进行有效融合，并融合坐标注意力机制，从而增强网络了对小目标对象的友好度。为了验证模型有效性，使用 CrowdHuman 图像数据集进行了实验，实验表明模型在各项指标中均取得优异的结果，说明了算法设计的有效性，有效解决了小目标对象跟踪失败的问题。

（2）本文在已有基础上进一步提出一种以观测为核心融合重识别的多目标跟踪方法，当目标重叠发生身份切换时，采用基于目标外形的 IoU 匹配帮助目标正确匹配。并采用新的匹配策略，以观测为核心融合重识别，从而有效找回跟踪中丢失的目标，提升算法性能。为全面评估算法的性能，在权威的 MOT17 和 MOT20 数据集上进行了大量实验测试。实验结果表明，该算法在多项评估指标上均展现出优异表现，验证了算法设计的有效性。

（3）采用本文提出的多目标跟踪算法设计并实现了一个公共场所人群智能监控系统，用于对公共场所人群进行智能监控。

关键词：深度学习　目标检测　行人重识别 卡尔曼滤波器

中国知网 https://www.cnki.net

Research on multi-object tracking algorithm based on deep learning

ABSTRACT

In recent years, the field of computer vision has witnessed tremendous advancements. Among the foundational vision tasks, multi-object tracking (MOT) stands out, demanding not only the detection of interesting target instances within video sequences but also their continuous tracking and motion trajectory maintenance. This task holds immense value in various application scenarios, including smart security, smart cities, and autonomous driving. However, real-world video data often presents complex challenges such as target occlusion, overlapping, and the presence of small targets, posing significant hurdles for MOT tasks and necessitating targeted and effective solutions from researchers. To address the aforementioned multiple object tracking issues, extensive research has been conducted to develop optimized target algorithms and improve matching strategies during tracking. The main contents of this work are outlined as follows:

(1) To address the challenge of tracking failure for small target objects in MOT, based on the YOLOX algorithm, in the feature fusion stage, feature layers from four different scales are adopted, covering rich feature information from high resolution to low resolution. Meanwhile, deep semantic features are effectively merged with shallow fine-grained features by adopting context skip connections. Additionally, the integration of a coordinate attention mechanism further enhances the network's affinity for small target objects. To validate the model’s effectiveness,

中国知网 https://www.cnki.net

experiments were conducted using the CrowdHuman image dataset. The results demonstrated exceptional performance across all indicators, confirming the algorithm's efficacy and resolving the tracking failure for small target objects.

(2) Expanding upon existing foundations, this work introduces a novel observation-centric multiple object tracking method that integrates re-identification capabilities. In scenarios where identity switches occur due to object overlap, we employ an appearance-based Intersection over Union (IoU) matching approach to facilitate accurate object association. A new matching strategy, centered around observation and integrating re-identification, is adopted to effectively retrieve lost targets during tracking and improve the algorithm's performance. To comprehensively evaluate the algorithm's performance, extensive experimental tests were conducted on the authoritative MOT17 and MOT20 datasets. The experimental results showcase the algorithm's exceptional performance across several evaluation indexes, validating the effectiveness of the design.

(3) Leveraging the multi-target tracking algorithm proposed in this paper, a crowd intelligent monitoring system tailored for public places is designed and implemented. This system enables efficient crowd monitoring and analysis, leveraging the advanced tracking capabilities developed in this work.

KEYWORDS: deep learning; object detection; person re-identification; kalman filter

中国知网 https://www.cnki.net

目 录

1 绪论.....1
1.1 研究背景和意义.....1
1.2 目标检测国内外研究现状.....2
1.3 多目标跟踪国内外研究现状.....3
1.3.1 传统方法.....3
1.3.2 基于深度学习的多目标跟踪.....4
1.4 本文研究目标与内容.....7
1.5 本文结构安排.....8
1.6 本章小结.....8
2 多目标跟踪研究相关理论基础.....10
2.1 多目标跟踪的基本原理及步骤.....10
2.1.1 目标检测.....11
2.1.2 外观特征提取.....11
2.1.3 位置预测.....11
2.1.4 数据关联.....12
2.1.5 多目标跟踪中的卡尔曼滤波器.....12
2.2 行人重识别技术.....14
2.3 数据集及评价指标.....14
2.3.1 数据集.....14
2.3.2 评价指标.....15
2.4 本章小结.....16
3 面向小目标的行人检测算法.....18
3.1 引言.....18
3.2 YOLOX 目标检测算法.....19
3.2.1 YOLOX 网络结构.....19
3.2.2 Anchor-free 设计.....21
3.3 检测算法改进.....21
3.3.1 特征融合设计.....22
3.3.2 融合自注意力机制.....23
3.4 实验过程和数据分析.....25
3.4.1 数据集.....25
3.4.2 实验环境及其配置.....25
3.4.3 评价指标.....25
3.4.4 实验结果分析.....26

中国知网 https://www.cnki.net

3.4.5 检测对比.....27
3.5 本章小结.....27
4 以观测为核心融合重识别的多目标跟踪方法.....29
4.1 引言.....29
4.2 算法整体框架.....31
4.3 融合观测和重识别的目标找回平滑参数方法 Re-OCROS.....31
4.3.1 基于观测的找回方法.....32
4.3.2 基于外貌的找回方法.....32
4.4 基于找回的平滑卡尔曼参数策略.....36
4.5 基于目标外形的 IoU 匹配 Shape-IoU.....36
4.6 实验结果与分析.....36
4.6.1 实验环境搭建.....36
4.6.2 对比试验.....37
4.6.3 消融实验.....40
4.7 本章小结.....41
5 公共场所人群智能监控系统.....42
5.1 需求分析.....42
5.1.1 可行性分析.....42
5.1.2 功能性需求分析.....42
5.1.3 非功能性需求分析.....43
5.2 系统架构和总体功能设计.....43
5.3 系统开发环境.....45
5.4 系统主要功能实现.....46
5.4.1 数据管理页面.....47
5.4.2 监控模块.....47
5.4.3 智能分析界面.....48
5.5 本章小结.....51
6 总结与展望.....52
6.1 总结.....52
6.2 展望.....52
参考文献.....54

中国知网 https://www.cnki.net

1 绪论

1.1 研究背景和意义

视频监控系统在当代社会中扮演着日益重要的角色，成为确保公共安全的关键基础设施。随着信息化时代的来临，视频监控的应用范围已远远超出传统的政府、金融等特殊领域，逐渐覆盖到学校、景区、交通枢纽等公共场所。特别是在国家大力推动智慧城市[1]建设的背景下，智能化视频分析和处理技术对于实现城市运行的高效管理和安全防控具有重要意义。

随着光学成像技术和移动终端设备的不断发展和普及，视频数据在日常生活和专业领域中的应用越来越广泛。大规模视频数据的快速积累，为智能信息处理带来了前所未有的机遇和挑战。一方面，视频数据蕴含着丰富的时空视觉信息，对于事件检测、行为分析、异常监测等诸多任务具有重要价值。另一方面，视频数据的高维特征、动态时变性质以及海量数据量，对计算效率和存储资源提出了极高的要求。因此，处理和理解视频中包含的信息是当前迫切需要解决的问题。近年来，借助人工智能和计算机视觉技术[2]的蓬勃发展，视频理解领域取得了令人瞩目的研究进展。

然而，在面对大量视频数据时，传统的视频监控系统需投入大量人力进行识别和筛查，效率低，且容易出现疏漏，难以满足实际的需求。随着计算机视觉技术的发展，视频监控系统的智能化升级有了技术支撑。智能视频监控系统通过自动化的目标检测和跟踪算法，能够减少人工参与，提高监控效率，实现对动态场景的智能分析和异常行为识别，为安防决策提供及时的信息支持。

多目标跟踪是一种计算机视觉技术，用于同时追踪和识别多个移动目标，其中多目标行人跟踪是其重要应用之一，本文的多目标跟踪泛指行人跟踪。作为视频理解的基础任务之一，多目标跟踪[3-5]已在学术界和工业界引起广泛关注，展现出巨大的应用潜力。多目标跟踪技术广泛应用于各个领域，包括智能监控、自动驾驶以及体育分析等[6-8]。在公共安全方面，该技术能够实现对多个目标的同步监控，显著增强了安防系统的功能。对于蓬勃发展的无人驾驶领域而言，多目标跟踪堪称核心技术，使车辆能够准确把握周遭环境的实时变化。

在竞技体育中，这一技术为赛事分析和选手评估提供了翔实可靠的数据基础，推进了体育科学的发展。此外，它在交互设计、AR/VR 等新兴领域发挥着不可替代的作用，为用户创造了更为直观和沉浸式的体验。在城市治理和商业运营领域，多目标跟踪的应用促进了资源的合理配置，提升了管理效率。随着多目标跟踪技术的不断精进和应用范畴的持续

中国知网 https://www.cnki.net

拓展，它将推动计算机视觉和人工智能的整体进步，为解决现实世界中的复杂问题开辟新的途径。这项技术不仅能提升各行业的生产效率，还可能孕育出创新的商业模式和研究方向，对社会进步和科技创新产生深远影响。因此，深化多目标跟踪技术的研究与优化，对于加速科技发展、改善生活品质和促进经济繁荣都具有重大的实际意义。

早期的多目标跟踪主要基于人工设计的特征描述符，存在鲁棒性差、计算复杂的缺陷，难以应对复杂多变性的实际场景。随着深度学习技术的快速发展，使用深度卷积神经网络[9]技术，基于检测的多目标跟踪（DBT，Detection-Based Tracking）方法逐渐成为视频理解领域的研究热点。该类方法通过端到端的神经网络模型，能够自动从数据中学习视觉特征表示，并将目标检测和数据关联有机结合，展现出优异的目标检测和跟踪能力，为智能视频监控系统的发展注入新的动力。

然而，在复杂的场景下，多目标跟踪仍存在一些难点待解决。第一，小目标物体跟踪失败问题。第二，当目标发生重叠时，可能会发生身份切换。第三，在目标丢失时候，由于噪声累计问题，会发生目标找回失败的情况。因此，本文采用 DBT 范式在跟踪算法进行改进，并应用到公共场所人群智能监控系统，该系统在安防领域有着良好的应用价值和意义。在多目标跟踪过程中，目标检测(Object Detection)和目标跟踪(Object Tracking)是两个密切相关且相互依赖的步骤。

通常情况下，目标检测是在目标跟踪之前进行的。目标检测的作用是在给定的图像或视频帧中,定位感兴趣的目标物体，并给出它们的边界框位置。一旦目标被检测到并获得了它们的初始边界框位置，目标跟踪算法就会进行处理，在连续的视频帧中跟踪和预测目标的运动轨迹。目标检测和目标跟踪这两个步骤在多目标跟踪系统中是紧密协作、相互依赖的。目标检测为跟踪提供了初始目标状态，而目标跟踪则在时间维度上对目标进行持续跟踪和预测。

1.2 目标检测国内外研究现状

在计算机视觉领域，目标检测技术扮演着基础性的重要角色，为诸多高层次视觉任务奠定了坚实的基础。作为一项核心基础技术，目标检测一直受到了广泛的研究关注，学术界在这一领域取得了一系列重要的理论和技术创新成果。

目标检测旨在从给定的图像或视频数据中自动定位感兴趣目标的位置和范围，为后续的目标识别、跟踪、行为分析等高层视觉任务提供了必要的前置支持。借助目标检测技术，计算机视觉系统能够准确获取场景中各种目标实例的精确空间位置信息，这是实现智能理解和决策的关键一环。

当前，基于深度神经网络的目标检测算法可分为两大主流范式,基于锚框（Anchor-Based）检测和无锚框（Anchor-Free）检测。基于锚框的检测方法最早在 R-CNN

中国知网 https://www.cnki.net

算法[10]提出并得到广泛应用。该范式的核心思想是在图像不同位置和尺度预先设定一组参考框（即锚框），然后通过对锚框进行分类和回归来获得最终的目标检测结果。尽管性能出色，但 R-CNN 仍存在计算效率低下等缺陷。为了解决效率问题，后续的 Fast R-CNN[11]和 Faster R-CNN[12]对算法流程进行了重大改进，将整个检测过程端到端地集成到单个神经网络中，极大地提高了计算效率。其中，Faster R-CNN 在网络中引入了 Region Proposal Network（RPN）模块，实现了高效的候选框生成。在 Faster R-CNN 的基础上，学术界和工业界展开了广泛而深入的研究。一方面，通过设计新颖的网络结构（如 R-FCN[13]、Mask R-CNN[14]、SiamRPN[15, 16]等）、优化目标函数（如 Cascade R-CNN[17]、RetinaNet[18]等）、引入注意力机制等策略，不断提升检测精度。另一方面，一些工作专注于特定的应用场景，如 FPN[19]用于解决多尺度目标检测。

Anchor-Based 机制需要预设大量锚框，冗余得得训练框会导致训练正负样本不均衡，并且训练难度大。因此，Anchor-Free 的目标检测方法应运而生。Redom 等人[20]在其研究中提出了 YOLOv1 方法，该方法将图像均匀划分为固定大小的单元格，通过对包含目标中心点的单元格进行边界框和类别概率的回归。该方法将目标检测任务转化为成对关键点的检测问题。Law 等人[21]提出了 CornerNet 方法，该方法通过利用 corner pooling 辅助网络，CornerNet 能够更好地定位目标的关键点，从而实现准确的目标检测。然而，该方法在后处理方面较为复杂。

1.3 多目标跟踪国内外研究现状

多目标跟踪一直是计算机视觉领域的核心任务之一，常指多行人跟踪。早期基于滤波[22, 23]的传统方法虽然在简单场景下表现尚可，但难以泛化到复杂的真实场景中。随着深度学习技术的蓬勃发展，基于深度神经网络的多目标跟踪方法应运而生，展现出强大的场景适应能力，推动了该领域的长足进步。在本小节将对多目标跟踪领域国内外研究现状进行简单梳理与介绍。

1.3.1 传统方法

多目标跟踪技术最早被用于军事领域，旨在持续监测和追踪多个运动目标的轨迹。由于其显著的应用价值，多目标跟踪问题迅速吸引了众多学者的研究兴趣，成为计算机视觉和信号处理等交叉学科的热点课题。在该技术的起步阶段，多目标跟踪主要基于雷达等传感器获取的信号数据，通过一系列滤波算法和时空建模方法对目标运动轨迹进行估计和追踪。其中，经典的滤波跟踪算法包括卡尔曼滤波及其扩展形式、粒子滤波等，能够在噪声环境下对目标状态进行有效估计。

卡尔曼滤波器是多目标跟踪领域的经典算法之一，其起源可追溯至上世纪 60 年代。

中国知网 https://www.cnki.net

Kalman 等人[24]最初提出了这一基于状态空间模型的递推估计方法，用于估计动态系统的内在状态，并对其未来状态进行预测。在多目标跟踪任务中，卡尔曼滤波技术被广泛应用于目标运动轨迹的建模。其核心思想是基于目标在历史帧中的状态观测值，通过线性动态系统模型和最优化估计，对目标在当前时刻的状态进行估计，并预测其在下一时刻可能出现的位置和运动状态。由于其简单高效、具有良好的数学理论基础，卡尔曼滤波成为早期多目标跟踪研究的主流方法。

Yu 等人[25]提出了一种基于马尔可夫决策过程（MDP，Markov Decision Process）的跟踪框架。该方法将跟踪过程建模为一系列的状态转移，利用目标在历史帧中的运动轨迹信息，结合当前观测，通过 MDP 模型估计目标在未来时刻的可能状态，实现了对目标运动的有效预测和建模。Danelljan 等人[26]提出利用预训练的卷积神经网络作为特征提取器，自动从原始图像数据中学习出具有语义的高级特征表示，并将其输入到基于相关滤波器的跟踪框架中。

尽管深度学习技术的兴起为多目标跟踪任务带来了新的解决范式，但卡尔曼滤波及其变体由于计算高效、收敛性强的优点，仍被广泛应用于目标运动预测、数据关联[27]等环节，发挥着不可或缺的作用。

1.3.2 基于深度学习的多目标跟踪

随着计算机硬件的进步，深度学习飞速发展，以深度学习为理论基础的多目标跟踪算法也取得较大突破。目前国内外多目标跟踪主要分为三种范式：检测导向的多目标跟踪（DBT，Detection-Based Tracking）、联合检测嵌入模型（JDE，Jointly Learns the Detector and Embedding Model）以及基于 transformer 的跟踪（TBT，Tracking By Transformer）。因此，本小节对这三种范式的多目标跟踪算法进行研究。

（1）DBT：DBT（DBT，Detection-Based Tracking）是一种基于目标检测的两阶段跟踪方法，它主要包括目标检测和特征提取两个关键步骤，如图 1.1 所示。首先是对视频帧利用目标检测算法（如 YOLO[20, 28-33]、Faster R-CNN[12]、SSD[34]等深度学习模型）识别帧中的目标对象，然后用关联模型对每个边界框内的目标进行重识别（Re-ID，Re-identification）特征提取。根据两阶段提取的外貌特征和运动信息，通过 Re-ID 特征向量的距离比较方法和目标区域交并比（IoU），并利用匈牙利算法和卡尔曼滤波器[24]进行关联，实现目标跟踪。

Ge 等人[35]提出了一种快速的在线多目标跟踪算法（SORT），通过目标检测算法产生检测框，利用卡尔曼滤波器得到预测框，计算检测框和预测框的 IoU，最后用匈牙利匹配算法将 IoU 作为损失，完成跟踪。2017 年，Wojke 等人[36]在此基础上提出两阶段算法 DeepSORT，在原来的设计上引入外观特征提取网络，联合外貌信息和运动信息进行预测。

中国知网 https://www.cnki.net

Zhang[37]等人针对跟踪过程中由于遮挡、模糊等造成的低分预测框直接丢弃导致的跟踪失败，设计了两阶段的关联匹配方法 ByteTrack，第一阶段对高分预测框进行关联匹配，第二阶段对低分预测框进行关联匹配，为避免低分目标遮挡造成的跟踪错误，第二阶段只采用 IoU 匹配，有效减少了目标丢失。

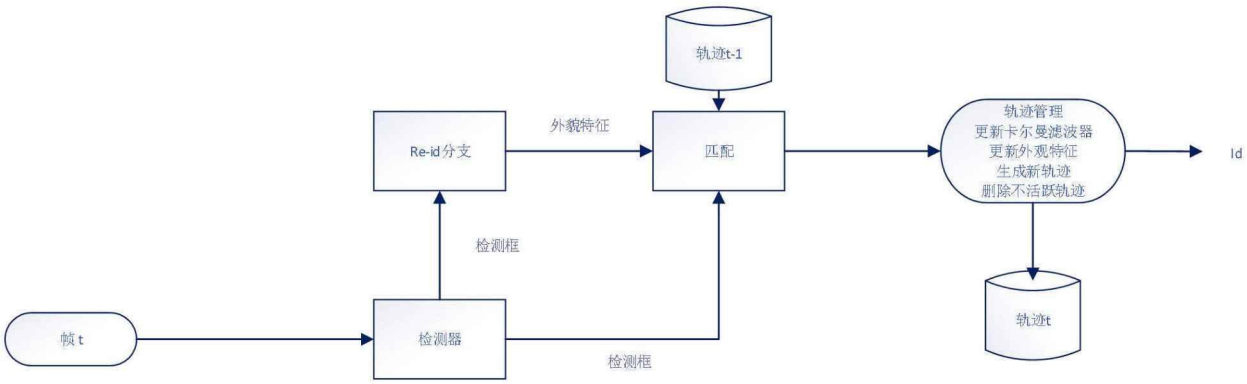


图 1.1 DBT 流程示意图

Du 等人[38]采用更强大的外观特征提取器，并针对相机运动造成的运动预测误差，在运动分支采用摄像机运动补偿，提出了 DeepSort 的升级版 StrongSORT 算法。Cao 等人[39]针对多目标跟踪中出现的误差积累、目标丢失等问题，提出了 OC-SORT 算法，有效解决了这些问题。Aharon 等人[40]在引入相机补偿特征追踪器的同时设计了一种简单有效的 IoU 和 Re-ID 余弦距离相融合的方法，提出了具有良好鲁棒性的 BoT-SORT 算法。K 等人[41]通过自适应阈值匹配机制，显著提升多目标跟踪系统在复杂场景下的目标关联精度和鲁棒性。Stanojevic 等人[42]通过优化相似性度量和检测置信度，在保持高精度的同时提升了跟踪性能，特别是在复杂场景和目标遮挡情况下，有效地解决了传统多目标跟踪算法面临的挑战。

该范式采用了模块化设计，将目标检测和目标跟踪分为两个独立模块，先利用强大的目标检测器获得目标位置，再基于检测结果进行跟踪，具有方便融合上下文信息和较快速度的优点，是当前主流、成熟的范式之一，同时也面临来自端到端联合学习方法的挑战。

（2）**JDE：**JDE（JDE，Joint learns the Detectors and Embedding）是一种的端到端目标跟踪方法，其特点在于避免了传统两阶段方法中的信息丢失。JDE 直接在连续的图像帧中进行目标跟踪，而无需首先进行目标检测。JDE 方法通过目标检测器和 RE-ID 技术同步在同一个主干网络上提取目标对象和外貌特征，之后通过类似 DBT 的方法实现跟踪。这种方法在一些实际应用中可能更为高效，尤其是在资源受限或对实时性要求较高的情境下。

中国知网 https://www.cnki.net

然而，JDE 在处理目标外观变化较大或者遮挡较严重的情况时可能面临一些挑战。

传统两阶段 DBT 跟踪范式，需要先进行检测再提取外观特征，使得跟踪的效率较低。Wang 等人[43]针对该问题提出了多目标跟踪新范式 JDE 算法，采用一个共享模型学习的网络同步进行目标检测和特征向量提取，大幅提高了跟踪的速度。Zhang 等人[44]发现重识别和目标检测具有竞争关系，之前的方法大多偏向于检测，针对这些问题作者提出了基于无锚 CenterNet 的 FairMot 算法，该算法采取无锚的设计，提取更加低维的特征，平衡了跟踪中的不公平问题，有效提高了跟踪的精度。Liang 等人[45]提出 CSTrack 算法，该算法引入互注意力机制以减轻重识别和检测任务之间的竞争，以极小的代价提升了跟踪的性能。

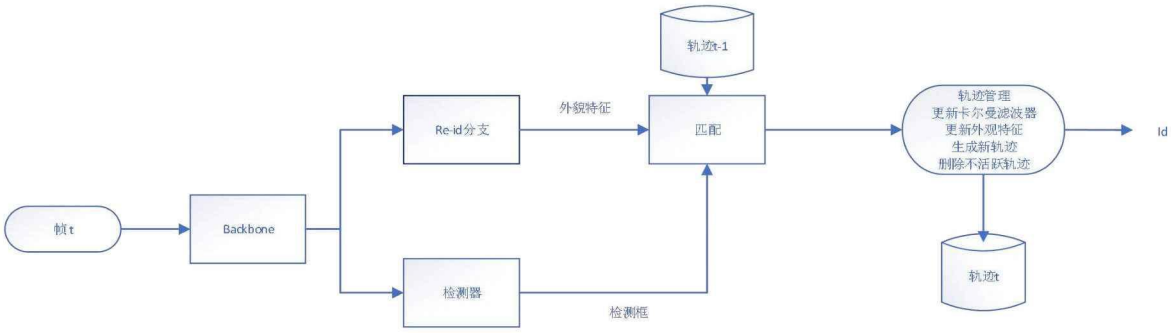


图 1.2 JDE 流程图示意图

Liang 等人[46]针对目标模糊等造成的目标被误分类为背景的情况，设计了一种再检查网络以解决此问题。Zhang 等人[47]在先前基于关联度的多目标追踪框架 Tracktor 的基础之上，提出了一种创新的改进方案。他们引入了深度光流估计模块，通过预测目标在相邻帧之间的像素位移，估算跟踪目标在当前帧的潜在位置。随后，将光流预测结果与该帧的目标检测结果融合，产生最终的目标追踪输出。通过光流模块的辅助，可以在一定程度上缓解基于检测器的单帧跟踪存在的漏检错误问题。

该范式将目标检测、ReID 特征嵌入和数据关联统一在同一深度神经网络中进行端到端优化训练，充分利用了目标检测、外观特征和运动模型等多种线索，通过联合多任务损失函数实现各模块之间的相互促进，摆脱了传统两阶段方法的误差传递问题，是当前该领域非常重要和有影响力的算法范式之一。

(3) TBT：TBT（TBT，Transfomer-Based Traking）是一种基于 Transformer[48]的多目标跟踪方法。Shun 等人[49]首开先河，将 Transformer 引入多目标跟踪领域，提出 TransTrack 算法，该算法具有两个 transfomer 分支，一个分支将目标 query 作为输入产生检测框，另

中国知网 https://www.cnki.net

一个分支将上一帧的目标特征作为跟踪 query 作为输入产生跟踪框，最后用匈牙利算法将两种框进行 IoU 匹配完成跟踪。Meinhardt 等人[50]提出 TrackFomer 算法，该算法将跟踪目标作为 transformer 解码器的 Query 输入，在时空上以自回归的方式跟随这个目标，如图 1.3 所示。Xu 等人[51]提出 TransCenter 算法，该算法采用基于 Transformer 的预测热力图架构，采用像素级别的多种尺度查询，利用一个双解码器的 Transformer，全局预测目标中心热力图完成跟踪。Zeng 等人[52]提出 MOTR 算法，利用强化学习进行多目标跟踪。该范式利用 Transformer 的自注意力机制，能够有效建模目标之间的相关性,捕捉目标间的相互影响和上下文依赖关系，从而实现更准确的目标关联和轨迹预测。与传统的基于检测或 Re-ID 特征的方法相比，TBT 避免了人工设计的数据关联策略,而是通过数据驱动的方式自主学习目标之间的交互模式。此外，TBT 还能很好地融合多模态信息，如运动、外观和场景上下文等，提高了跟踪的鲁棒性。与端到端的联合检测跟踪范式（如 JDE）相比，TBT 主要关注于目标级别的建模和推理，模型复杂度较低。TBT 作为一种新兴而有前景的范式，与现有的 DBT、JDE 等范式形成了良好的补充和交叉，为多目标跟踪任务提供了新的解决思路。

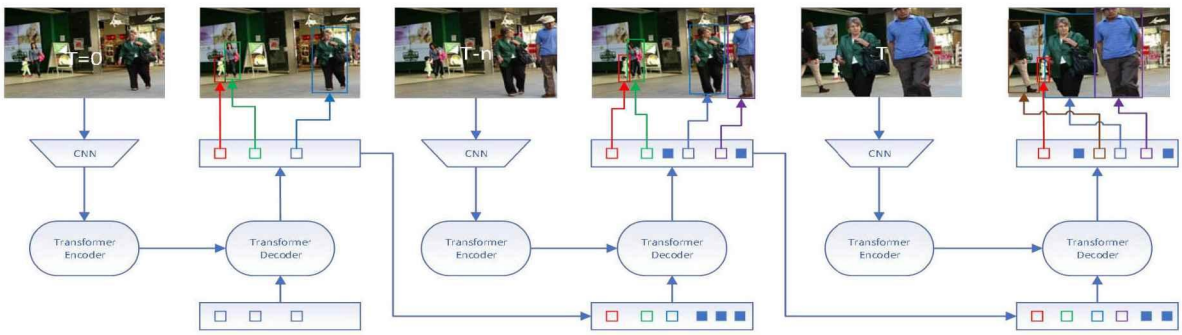


图 1.3 TrackFomer 流程示意图

1.4 本文研究目标与内容

针对上述研究现状和复杂场景下漏检、身份切换、目标丢失等问题，本文着重分析 DBT 策略检测阶段和数据关联阶段，即在检测阶段改进网络结构，提高网络检测能力：在数据关联阶段，提出观测为核心融合重识别的多目标跟踪方法；将算法用于公共场所人群智能监控系统。本文的具体研究内容如下：

（1）为解决多目标跟踪过程中小目标对象跟踪失败的问题，在 YOLOX 算法的基础上，在特征融合阶段，采用来自 4 个不同尺度的特征层，涵盖从高分辨率到低分辨率的丰富特征信息。与此同时，通过采用上下文跳跃连接的方式，将深层次的语义特征与浅层次

中国知网 https://www.cnki.net

的细粒度特征进行有效融合，并融合坐标注意力机制，从而增强网络了对小目标对象的友好度。为了验证模型有效性，使用 CrowdHuman 图像数据集进行了实验，实验表明模型在各项指标中均取得优异的结果，说明了算法设计的有效性。

（2）本文在已有基础上进一步提出一种以观测为核心融合重识别的多目标跟踪方法，当目标重叠发生身份切换时，采用基于目标外形的 IoU 匹配帮助目标正确匹配。并采用新的匹配策略，以观测为核心融合重识别，从而有效找回跟踪中丢失的目标，提升算法性能。为全面评估算法的性能，在权威的 MOT17 和 MOT20 数据集上进行了大量实验测试。实验结果表明，该算法在多项评估指标上均展现出优异表现，从多个角度验证了算法设计的有效性。

（3）采用本文提出的多目标跟踪算法设计并实现了一个公共场所人群智能监控系统，用于对公共场所人群进行智能监控。用户可以在桌面软件端对公共场所区域进行智能监控，第一时间发现异常情况，帮助做好及时响应。

1.5 本文结构安排

本论文主要分为六章，如下所示：

第一章，绪论。详细探讨目标追踪领域的最新研究进展，对近年来的研究成果进行综述，说明了本文的主要工作和论文结构安排。

第二章，多目标跟踪研究相关理论基础。探讨行人检测与跟踪相关理论基础，主要包括多目标跟踪中的卡尔曼滤波器、行人重识别技术，以及相关数据集。

第三章，基于 YOLOX 的行人检测。在 YOLOX 基础上改进特征融合模块，并融合坐标注意力机制，提高对小目标对象的跟踪能力。

第四章，以观测为核心融合重识别的多目标跟踪方法。并采用新的匹配策略，以观测为核心融合重识别，从而有效找回跟踪中丢失的目标，提升算法性能。采用基于目标外形的 IoU 匹配帮助目标正确匹配。在 MOT17，MOT20 数据集上进行评估。

第五章，基于多目标跟踪算法的公共场所人群智能监控系统。

第六章，总结和展望。

1.6 本章小结

在多目标跟踪任务中，对移动目标进行精确检测和持续跟踪是一项具有挑战性的研究课题。现有方法在复杂场景下往往难以平衡检测精度和跟踪稳健性。本章旨在综述多目标跟踪算法的研究进展，重点关注多目标跟踪解决方案，并分析现有解决方案的优缺点。

首先，阐释多目标跟踪问题的研究背景及意义，强调其在视频监控、智能驾驶等领域的重要应用价值。其次，回顾目标检测算法的发展历程，重点介绍基于深度学习的目标检

中国知网 https://www.cnki.net

测技术及其在多目标跟踪中的应用。随后，系统梳理国内外学者在多目标跟踪任务上的研究成果，对主流方法的技术原理、性能表现及局限性进行剖析，指出有待进一步解决的关键问题。

在此基础上，概括说明本文的研究内容和创新之处，并简要介绍论文的组织结构。

中国知网 https://www.cnki.net

2 多目标跟踪研究相关理论基础

近年来，深度学习技术的迅猛发展在工业领域内取得了令人瞩目的成就。各行业纷纷将这一前沿技术融入自身发展之中，催生出一系列创新产品与智能化生产线。例如，人工智能公司 OpenAI 推出智能聊天工具 Chat GPT，华为公司则在自动驾驶汽车领域取得了显著突破。这些产品的持续研发与迭代，不仅丰富了市场应用，也反过来也推动了深度学习技术的不断精进和完善。

传统机器学习系统由于高度依赖于人工设计和选择特征向量，因此存在诸多缺陷和挑战。首先，特征工程是一项艰巨的任务，需要耗费大量的人力和计算资源。研究人员需要基于领域知识和经验，对原始数据进行复杂的预处理、转换和提取，以获取对任务有效的特征表示。其次，手工设计特征的方法缺乏通用性和扩展性，难以适用于数据分布发生变化或任务发生改变的情况。最后，传统机器学习模型对特征的质量和表征能力高度敏感，特征工程的失误可能导致模型性能的严重下降。而深度学习的出现在一定程度上改善了当前环境，深度学习大致可分为两个部分：特征提取和数据训练。特征提取将数据输入预先构建的卷积神经网络，实现自动特征提取，对计算机性能要求较高。数据训练则通过不断反向传播，调整神经网络参数，最终生成最优特征提取模型，实现人工智能学习任务，代替人工干预。

基于深度神经网络的建模方法已成为解决多目标跟踪任务的主流范式。本章将依次介绍本文使用的多目标跟踪技术、行人重识别技术等深度神经网络模型的结构和原理。最后，系统梳理多目标跟踪领域中常用的公开数据集及其评测标准。

2.1 多目标跟踪的基本原理及步骤

目前，主流的多目标跟踪算法有四个部分：目标检测、外观特征提取、位置预测和数

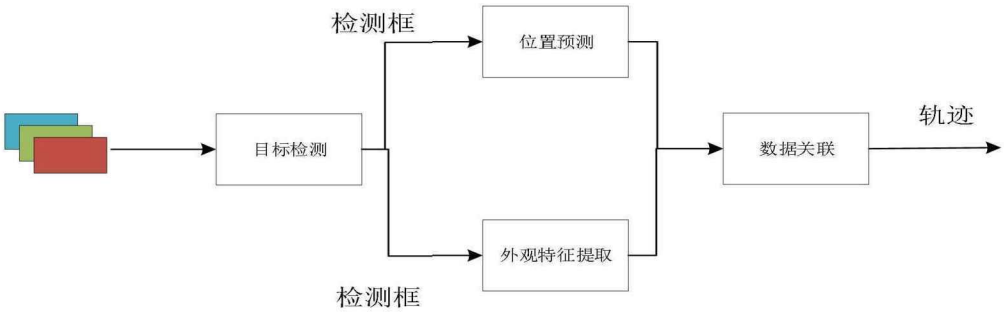


图 2.1 多目标跟踪的基本步骤

中国知网 https://www.cnki.net

据关联，如图 2.1 所示。

2.1.1 目标检测

目标检测作为多目标跟踪中的重要环节，其性能在很大程度上决定了整个跟踪系统的精确度和鲁棒性。首先，在视频序列中，新目标可能会不断出现或离开视野，因此需要依赖高效准确的目标检测模块来及时发现和定位这些目标，为后续跟踪奠定基础。其次，准确的目标定位是实现精确跟踪的前提条件，检测模块的性能直接影响轨迹构建的质量。第三，由于目标运动和出现的随机性，高性能的检测器能够有效降低目标漏检和错检的情况，从而减少跟踪的中断和错误关联。鉴于目标检测对多目标跟踪的重要性，当前主流的先进跟踪算法大多采用了最新的目标检测网络作为检测模块，如 YOLO 系列、Detection Transformer (DETR)[53]等，这些网络凭借创新的网络设计和损失函数，展现出优异的检测精度和速度，为高质量的多目标跟踪奠定了坚实基础。只有持续优化检测环节，才能最终实现高精度、高效率的多目标跟踪，满足实际应用的需求。

2.1.2 外观特征提取

外观特征提取是多目标跟踪算法中的关键环节，旨在学习具有区别度的视觉表示，为目标之间的区分和身份维持提供支撑。在深度学习技术兴起之前，研究人员主要依赖手工设计的特征描述子来表征目标的外观信息。然而，这些手工特征在描述目标细节和语义信息方面存在明显不足。随着深度学习在计算机视觉领域的蓬勃发展，基于卷积神经网络的自动特征学习方法应运而生，为多目标跟踪算法带来了新的机遇。大量先进的跟踪方法借鉴了行人重识任务中的相关技术，通过训练深度卷积网络直接从原始图像数据中学习目标外观表示，显著提升了特征的有效性。

2.1.3 位置预测

位置预测是多目标跟踪算法中不可或缺的一个环节，其目的在于捕捉目标的运动规律，并对其在未来时刻的位置进行合理预测。这一过程通常借助滤波技术或深度神经网络等模型，对目标的位置、速度等运动相关信息进行建模和估计。精准的运动状态预测对于跨帧目标的有效关联至关重要，是实现高质量轨迹构建的基础。在简单场景下，如目标数量有限、遮挡情况较少，仅依靠目标检测结果和运动状态预测就能获得较为理想的跟踪性能。然而，在复杂场景中，由于目标密集、外观相似性高等问题，单一依赖运动信息或外观特征都难以实现可靠的目标识别和关联。这种情况下，运动状态建模能够为目标关联过程提供有力的空间位置约束，与外观特征相互补充，共同提升算法的鲁棒性和准确性。因此，对运动状态进行高效建模是多目标跟踪算法设计的关键所在。目前，该领域的主流方法包

中国知网 https://www.cnki.net

括基于滤波技术（如卡尔曼滤波、粒子滤波等）的传统模型，以及基于深度神经网络的端到端建模方式。

2.1.4 数据关联

数据关联是多目标跟踪算法的最终环节，其核心目标是基于目标的外观特征和运动状态信息，实现检测结果与已有轨迹的准确匹配和关联。这一环节的性能直接决定了跟踪系统的整体精度和鲁棒性。在传统方法中，匈牙利算法和贪婪算法是数据关联的主流选择。当输入的外观和运动特征质量较高时，这些算法能够较为可靠地完成目标关联。然而，在复杂场景下，由于遮挡、相似性干扰等因素，输入特征的可靠性会受到严重影响，从而导致关联错误和身份交换的发生。为了应对这一挑战，近年来出现了一些基于深度学习的创新性方法。部分工作尝试利用图神经网络或卷积神经网络等强大的模型，端到端地学习目标之间的相似性度量，并基于此实现数据关联。这些方法的优势在于，能够从原始数据中自动挖掘出高维度的语义特征表示，增强了目标关联的鲁棒性。如何设计更加高效、可解释的数据关联模块，并将其与检测、特征提取等其他模块相结合，实现整体的联合优化，将是多目标跟踪算法发展的重要方向之一。只有各个环节相互协同、性能全面提升，才能最终实现高精度、高效率的多目标跟踪，满足真实场景的应用需求。

2.1.5 多目标跟踪中的卡尔曼滤波器

卡尔曼滤波器是一种递归算法，主要用于对系统状态进行估计。该滤波器通过融合系统的动态模型和实际测量数据，以动态方式更新系统状态的估计。算法的关键步骤包括预测和更新。在预测步骤中，利用系统的动态模型对下一个时刻的状态进行预测，并考虑估计的不确定性。而在更新步骤中，通过与实际测量数据进行比较，权衡预测的状态估计与测量之间的不确定性，以获得更准确的系统状态估计。卡尔曼滤波器通过连续迭代这两个步骤，能够在系统动态变化和测量误差存在的情况下，实现对系统状态的最优估计。

在多目标跟踪中，卡尔曼滤波器会融合预测框和检测框得到一个更加符合实际的跟踪结果。目标的八维状态向量为

$$\mathrm{X} = (\mathrm{x}, \mathrm{y}, \mathrm{s}, \mathrm{r}, \mathrm{v_x}, \mathrm{v_y}, \mathrm{v_s}, \mathrm{v_r}) \tag{2.1}$$

其中 x 、 y 代表目标中心点的坐标，s 表示检测框的面积，r 表示检测框宽高比， v_x、v_y代表目标中心点坐标的变化率，v_s代表目标框的面积变化率，v_r代表目标宽高比的变化率。这里定义一个状态转移矩阵 F 更新目标的状态信息

中国知网 https://www.cnki.net

$$F=\begin{bmatrix}1&0&0&0&1&0&0&0\\0&1&0&0&0&1&0&0\\0&0&1&0&0&0&1&0\\0&0&0&1&0&0&0&1\\0&0&0&0&1&0&0&0\\0&0&0&0&0&1&0&0\\0&0&0&0&0&0&1&0\\0&0&0&0&0&0&0&1\end{bmatrix} \tag{2.2}$$

可以通过状态转移矩阵 F 和上一时刻状态向量X_{t-1}得到目标 t 时刻的预测状态X_t

$$\hat{x}_t = FX_{t-1} \tag{2.3}$$

它运用匀速建模的方式，假设在一段时间内前四个向量的变化率保持不变。除了对目标的匀速建模，因为现实中还存在噪声，状态方程

$$X_t = FX_{t-1} + Bu_{t-1} + w_{t-1} \tag{2.4}$$

其中u_{t-1}为输入信号，X_{t-1}为状态变量，w_{t-1}为过程噪声。

观测方程

$$Z_t = HX_t + v_t \tag{2.5}$$

v_t 表示观测噪声。

因此为了更准确地估计目标位置，需要引入协方差矩阵，用以描述真实值与估计值之间的误差关系，由公式 2.6 得先验协方差$P_t^{'}$，A 为状态转移矩阵，P_{t-1}为协方差矩阵，Q 为误差矩阵

$$P_t^{'} = AP_{t-1}A^T + Q \tag{2.6}$$

可由预测过程得出卡尔曼增益K_t,

$$K_t = \frac{P_t^{'}H^T}{HP_t^{'}H^t+R} \tag{2.7}$$

其中H表示测量系统参数，R为观测噪声得方差。

后验估计$\widehat{X}_t$为

$$\widehat{X}_t = \hat{x}_t^{'} + K_t(z_t - H\widehat{X}_t^{'}) \tag{2.8}$$

其中 H 为测试系统参数

中国知网 https://www.cnki.net

最后更新卡尔曼增益P_t

$$P_t = (1 - K_t H)P_t^{'} \tag{2.9}$$

2.2 行人重识别技术

行人重识技术是计算机视觉和模式识别领域的一项研究，专注于解决行人重新识别（Re-ID, Re-identification）的问题，旨在在不同摄像头的视野中准确地识别相同的行人，以实现跨摄像头的行人追踪和监测。在多目标追踪任务当中，一般采用该方法提取目标的外观特征，并将其用于数据关联以帮助正确跟踪目标。

一般行人重识别系统包括五个步骤：

（1）搜集原始数据：首先需要通过网络或者摄影获取原始视频数据。由于原始视频可能存在运动模糊、光线干扰等问题，原始视频可能存在大量的噪声，因此还需要对图像就行清晰，得到干净的数据。

（2）标注：通常通过人工手动或者电脑辅助裁剪所有的人物图像，得到包含人物图像的边界框。

（3）模型训练：使用上面两部产生得数据训练一个具有判别性和鲁棒性的 Re-ID 模型。训练的模型广泛用于表征学习，距离度量学习或它们的组合。

（4）行人检索：测试阶段进行行人检索。给定一个查询目标和一个图库集，使用在前一阶段学习的 Re-ID 模型提取特征表示。通过对计算的查询到库的相似性进行排序，获得检索到的排名列表。

2.3 数据集及评价指标

在深度学习中，数据集的重要性不言而喻。深度学习模型需要大量高质量的数据集进行训练和优化，从而获得良好的泛化能力。数据集在深度学习中扮演着基础性和关键性的角色。高质量、多样化和足够大的数据集是深度学习模型取得良好性能的先决条件，也推动着算法和模型的创新发展。选用权威数据集 MOT17、MOT、CrowedHuman 作为本文实验的数据集。

2.3.1 数据集

（1）MOT17

MOT7 数据集是一个公开的多目标跟踪数据集，该数据集拥有 14 个视频序列，包含

中国知网 https://www.cnki.net

1342 个行人，平均每个视频序列 96 个行人，一共 11235 张图片。MOT17 数据集包含了各种不同的场景，例如室内、室外、人行道等，固定的相机和运动的相机。MOT17 数据集包含多种具有挑战性的场景，例如目标重叠、拥挤的人群、快速移动等，这些对算法具有较高要求。

（2）MOT20

MOT20[54]数据集是多目标跟踪领域的一个公开数据集，该数据集有 8 个视频序列，一半划分为训练集，一半划分为测试集，相较于 MOT17 数据集，它有更多的跟踪目标，所有视频序列一共有行人 3456 个，平均每个视频序列有 432 个行人。MOT20 数据集场景更加复杂，行人更加密集，具有极高的挑战性。

（3）CrowedHuman

CrowdHuman[55]数据集是一个大规模数据集，主要用于行为理解和人体检测研究。该数据集的目标是提供多样化、真实世界的人体图像，以帮助研究人员开发和评估人体检测算法的性能。CrowdHuman 数据集包含超过 15000 张图像，其中 339565 个人体实例，涵盖了各种场景，包括户外、户内、城市街道等。人体实例的特征也具有多样性，包括不同年龄、性别、衣着等。这使得 CrowdHuman 数据集在人体检测和行为理解方面具有挑战性。

2.3.2 评价指标

多目标跟踪中由于目标遮挡、目标模糊、光照不均等复杂情况，目标可能出现跟踪丢失和身份切换，多目标跟踪目的是保证每个目标的身份保持不变，算法准确处理各种场景下的目标关系。为了正确评估算法，采取定量的方式，根据算法产生的轨迹和数据集中真实的轨迹的差异，提出不同角度的评价指标。图中箭头向上表示该指标数值越大越好，箭头向下反之。

MOTA 指标是评估多目标跟踪算法的整体性能，该指标由误检 fp_t、漏检fn_t和身份交互 IDS_t所得，计算公式如下：

$$MOTA = 1 - \frac{\sum t\,(fn_t + fp_t + IDS_t)}{\sum t\, g_t} \tag{2.10}$$

IDP 计算公式：

$$IDP = \frac{IDTP}{IDTP + IDFP} \tag{2.11}$$

中国知网 https://www.cnki.net

2.1 评价指标

指标名称		说明
MOTA	↑	跟踪准确度
IDF_1	↑	识别准确的检测与目标实际标注值和计算检测的目标平均数之比
ID_S	↓	目标身份切换的次数
MT	↑	轨迹中大于 80%准确度的轨迹数目
ML	↓	轨迹中小于 20%准确度的轨迹数目
FP	↓	跟踪错误的次数
FN	↓	跟踪中漏检的次数
IDP	↑	识别身份 ID 信息的精准度
IDR	↑	识别身份 ID 信息的召回率

IDR 计算公式：

$$IDR = \frac{IDTP}{IDTP+IDFN} \tag{2.12}$$

IDF_1 指标公式：

$$IDF_1 = \frac{2IDTP}{2IDTP+IDFP+IDFN} \tag{2.13}$$

IDFP 代表跟踪中虚检的目标数，IDTP 代表跟踪中正确匹配的个数，IDFN 代表漏检的目标数。

2.4 本章小结

本章首先阐述了多目标跟踪任务的核心概念，解析其所涉及的关键技术环节，包括目

中国知网 https://www.cnki.net

标检测、运动估计和目标关联等，并详细说明每个环节的具体实现方式和技术细节。其次，介绍该领域中广泛使用的公开数据集，包括数据集构建方法、场景类型等，分析各数据集的特点及适用场景，为算法设计和性能评估提供支撑。最后，论述多目标跟踪任务的标准评价指标体系，解释各项指标的定义和计算方式，以衡量算法的检测和跟踪性能。

中国知网 https://www.cnki.net

3 面向小目标的行人检测算法

3.1 引言

DBT 范式的多目标跟踪是基于目标检测的算法，所以检测器在多目标跟踪过程中是举足轻重的。本文中的小目标指目标边界框面积与整幅图像比值为 0.01%~0.6%的物体，在复杂的多目标跟踪场景中，往往存在小目标对象，这些小目标检测长期以来是目标检测中的一个难点，由于小目标物体的体积小，显示在图像上的面积较小，小目标的特征不太明显，这会导致使用传统的目标检测模型无法达到高精度和低漏检率。小目标由于其固有的像素点有限这一特性，极易遭受背景环境的干扰影响。这种干扰源于小目标本身所包含的前景信息有限，使其与背景难以区分。背景区域的颜色、纹理等信息往往会淹没目标本身的特征，从而导致小目标无法被正确检测和分割出来。这一现象在复杂背景环境下尤为明显，给小目标检测带来了极大的挑战。如图 3.1 所示，图中存在大量小目标行人，图像中白衣行人所含像素信息很少，很可能受到背景的干扰，使得检测器性能降低。



图 3.1 小目标示意图

小目标检测的失败将直接导致后续的目标跟踪过程中发生目标丢失，从而影响整个跟踪系统的鲁棒性和可靠性。这一挑战的存在，阻碍了多目标跟踪技术在真实场景中的广泛

中国知网 https://www.cnki.net

应用，限制了其在智能视频分析等领域的应用潜力。

针对以上的问题，本章首先介绍了目前主流的目标检测算法 YOLOX，主要在两个方向进行了研究，一是在特征融合阶段，采用来自 4 个不同尺度的特征层，涵盖从高分辨率到低分辨率的丰富特征信息。另外融合了坐标注意力机制，减少背景干扰，从而增强网络了对小目标对象的友好度。最后对改进的模型进行了实验分析，为后面改进多目标跟踪算法做好了前期工作。

3.2YOLOX 目标检测算法

YOLOX 是旷视科技于 2021 年提出的一种高性能目标检测模型，之前的 YOLO 系列论文都采用 anchor-based 的方法进行目标检测，这会带来很多的问题。例如增加计算量，在特征图上每个特征点会设置了三个不同尺寸的锚框，因此整个特征图会产生大量的预测框，与之伴随的是巨大的计算量。YOLOX 检测器使用 anchor-free 方式，并采用解耦头部和领先的标签分配策略 SimOTA 等先进的检测技术，降低了计算量，在许多大数据集中实现了最先进的检测结果。相较于前期 YOLO 算法，YOLOX 在检测速度和精度两个方面都取得了显著提升，模型结构和策略的优化使其能更高效地利用计算资源，进一步增强了性能表现。

除目标检测任务外，YOLOX 模型还可广泛应用于行人重识别、实例分割等领域。经过多个公开数据集的验证，其出色的检测效果使其成为目标检测领域的重要技术方案之一。YOLOX 的提出不仅拓展了 Anchor-Free 策略在单阶段目标检测器中的应用场景，同时也为设计更高效、更精准的目标检测模型提供了新的思路。

3.2.1YOLOX 网络结构

YOLOX 网络结构不同于 YOLO 系列网络结构，采用解耦头，详细网络结构见图 3-2。YOLOX 网络结构分为四个部分：首先是图片输入端；然后是 backbone 部分，在多种尺度提取图像特征；第三部分是特征融合部分，该部分对第二部分提取的多尺度特征进行融合；最后一个部分是解耦头部分。其中 backbone 部分有三个结构：

(1) 卷积部分，与大多数目标检测模型相同，YOLOX 由许多卷积层堆叠而成，每个卷积层包含多个不同的卷积核，网络利用卷积层得到图像的特征，每个卷积核对输入数据提取的特征互不相同，卷积层卷积核数量越多，能够提取的特征就越丰富。卷积运算的本质是在输入数据上滑动卷积核，并通过卷积核参数对输入数据进行加权求和，提取出局部特征响应。不同卷积层的神经元之间采用局部连接的方式，权值在不同神经元之间共享，这一设计大幅减少了权值和偏置的数量，加快了训练过程。局部连接指的是卷积层节点仅与前一层的部分节点相连，学习局部特征。卷积核在输入图像的不同区域作卷积运算，检

中国知网 https://www.cnki.net

测相同的特征模式。通过层层叠加的卷积操作，YOLOX 能够高效地从输入图像中提取出多尺度、多语义层次的特征表示，为后续的目标检测任务奠定基础。

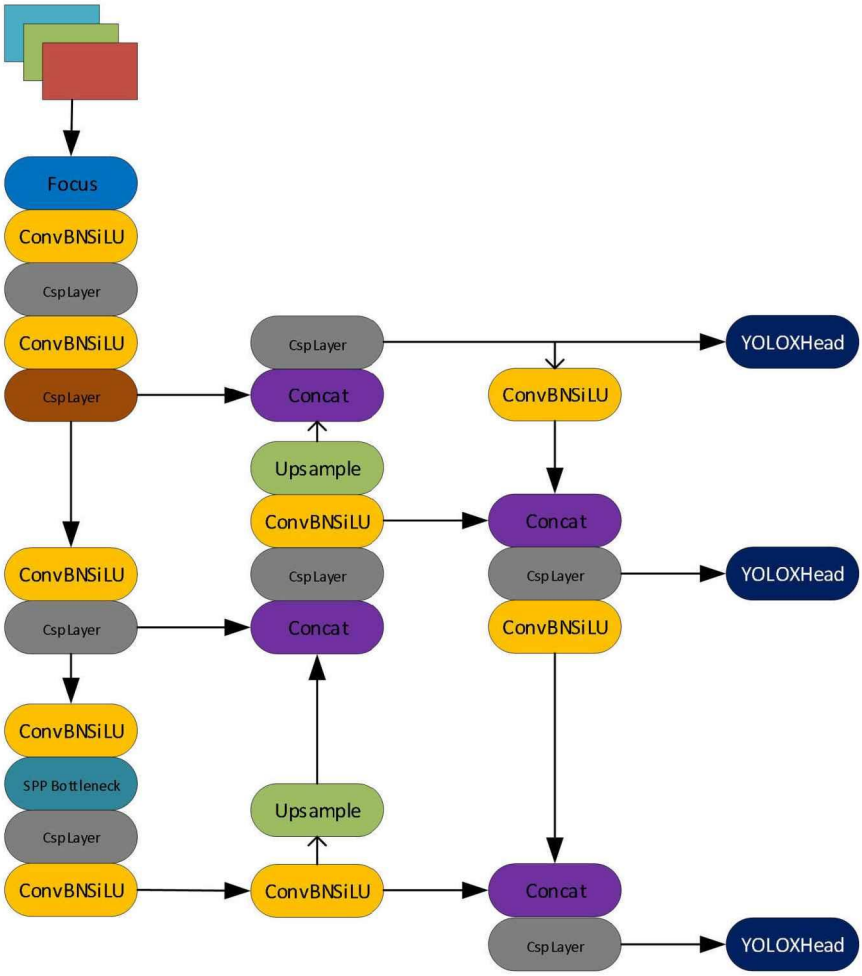


图 3.2 YOLOX 网络结构

(2) CspLayer 模块结构与残差结构采用了类似的设计思路，旨在解决深度神经网络中的梯度消失或爆炸问题。CSP 结构的输入首先经过一系列卷积和残差模块的处理，产生的特征图再与原始输入进行拼接，作为该阶段的输出。该结构的核心在于将特征图分成两个部分，分别经过不同的卷积模块提取特征，最后将提取的特征融合。通过将梯度的变化集成于特征图，CSP 结构在减少计算量的同时，能够保持较高的检测精度，并有利于加深网络的深度。

(3) SPP Bottleneck，该模块在在深层对图像特征进行提取。

YOLOX 通过 backbone 进行特征提取后会得到三个尺度的特征，这三个尺度的特征具有不同的分辨率，然后通过第三部分进行融合，得到不同分辨率的三种特征，在此基础上

中国知网 https://www.cnki.net

进行不同尺度目标的检测。在三个尺度上通过不共享参数的解耦头进行预测。

3.2.2 Anchor-free 设计

YOLOX 之前的 YOLO v2、YOLO v3 等都采用 anchor-based 的设计，而锚框的设计会带来很多问题：

1. 正负样本严重不平衡问题

在特征图上，每个特征点都会产生三个不同尺寸大小的锚框，这会导致预测框中绝大部分都是负样本，使得正负样本严重不平衡。

2. 增加计算量

在一张大小为 100×100 的特征图上，一般每个特征点会设置三个不同尺寸大小的锚框，从而得到 30000 个预测框，带来巨大的计算量。

3. 调参的挑战

锚框的尺寸在训练中是个敏感的超参数，这增加了调参的复杂性。

为了解决这些问题 YOLOX 中采用无锚框的设计，使用解耦头，见图 3.3。无锚框的设计使得每个特征点只有一个预测框，是锚框方法的三分之一，极大的降低了计算量，缓解了正负样本严重不平衡问题，并且避免了锚框调参。YOLOX 会预测 cls+4+1 个参数在特征图每个位置上，其中 cls 表示类别数，4 表示预测的检测框参数，1 表示 object ness。

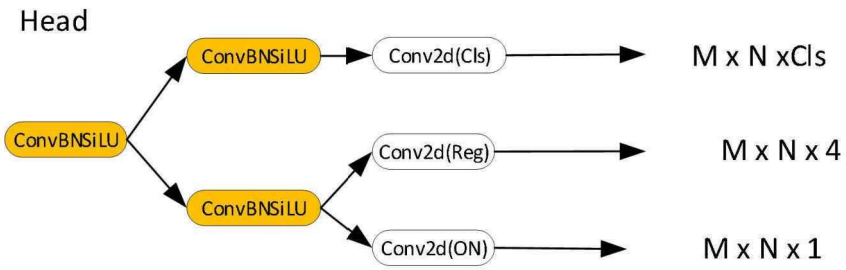


图 3.3 YOLOX Head

YOLOX 会在每个位置通过 Head 直接得到 4 个预测框参数 (X, Y, W, H)，X 和 Y 表示在预测中心点上的偏移量，W 和 H 表示检测框的宽和高。

3.3 检测算法改进

在一些多目标跟踪场景下存在很多小目标，而检测算法在这些场景下表现不佳，这会出现漏检，进而导致在跟踪过程中跟踪失败。在不同场景下，对小目标的定义标准存在差

中国知网 https://www.cnki.net

异。现有的定义方式主要以目标边界框面积作为衡量小目标的主要因素。鉴于小目标定义的多样性，以及实际环境中图像分辨率的不固定性，本文采用相对尺度来定义研究对象。具体而言，将目标边界框面积与整幅图像面积之比在 0.004%~0.56%范围内的目标定义为小目标，作为研究的重点对象。针对小目标难以检测的问题，以 YOLOX 作为基础网络进行了优化，设计了一种包含注意力机制浅层特征的四层特征融合结构，具体网络结构如图 3.4 所示。

图中在 YOLOX 三层特征的基础上，新加入了一层更加浅的特征，帮助提取小目标的特征。Coordinate Attention 表示注意力机制。

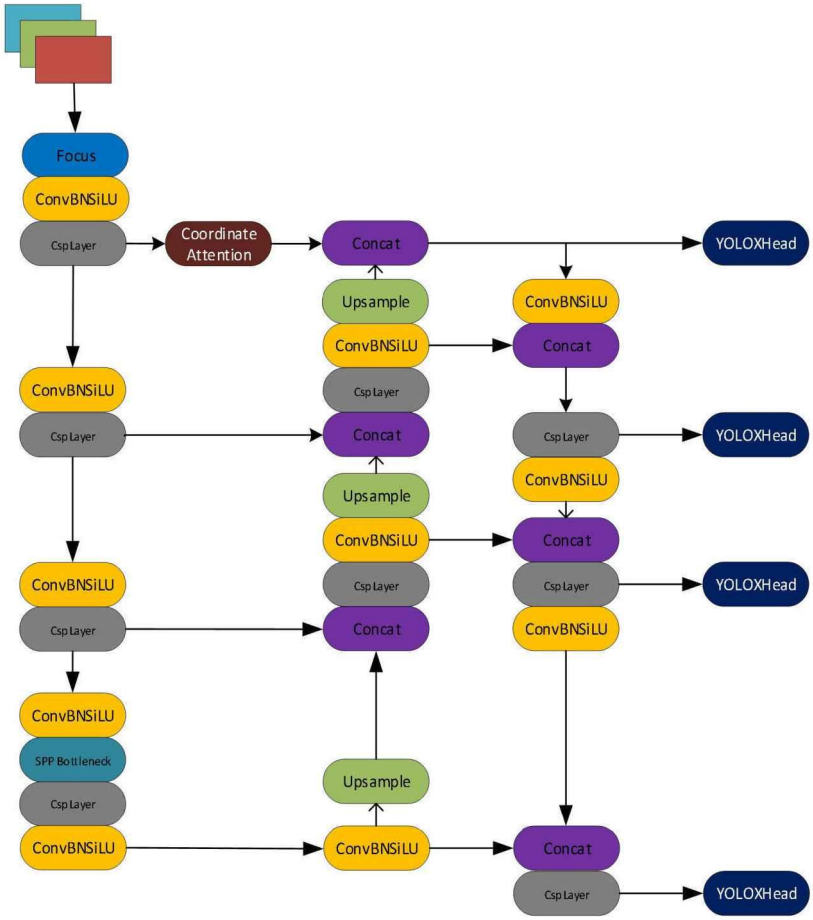


图 3.4 改进后的网络结构

3.3.1 特征融合设计

由于目标的大小、尺度和环境不同，多尺度特征在目标检测任务中非常重要。使用多尺度特征有助于模型更好地捕捉不同大小的目标，提高检测性能。例如，在目标检测中，

中国知网 https://www.cnki.net

多尺度结构可使模型更好地处理不同大小的目标，提高模型的通用性，捕捉图像细节和纹理信息，提高模型的准确性，由于模型过于关心特定尺度的细节信息，提高模型的准确性，可以降低过度拟合的风险，提高模型的鲁棒性。在目标检测领域常常使用特征金字塔[56]（FPN，Feature Pyramid Network）来处理多尺度特征，特征金字塔网络是一种用于多尺度特征提取的网络结构，旨在解决目标检测中不同大小目标的特征提取问题。其主要思想是通过在网络中添加横向连接来构建特征金字塔，从而使网络能够在不同层次上提取不同分辨率的特征。FPN 引入了一种自上而下的特征传播机制。具体来说，高分辨率的特征图（通常是最顶层的特征图）会通过向上采样的方式转移到相邻的低分辨率特征图上。这样，较高层次特征图的上下文信息就能传递到较低层次，从而提供更丰富的上下文信息。自下而上的横向合并将低分辨率特征图与相邻的高分辨率特征图连接起来。这些耦合操作是通过单个 1x1 卷积层进行的，这样特征图中的通道数量就能匹配。通过这种方式，较低的特征图可以接收来自较高特征图的上采样信息，从而提高对上下文的感知能力。来自 FPN 的多尺度特征图被发送到目标检测网络的不同分支，以提高对不同大小目标的检测能力。

为了帮助提取小目标的特征，在 YOLOX 模型的基础上，将原始的三层特征结构添加 160*160*125 的浅层特征尺度转化为四层特征结构。小目标由于自身的特征有限，原本的网络提取的特征过深会导致小目标特征较少，而添加的浅层特征具有更高的分辨率，增加了浅层特征，能保存更多关于小型目标的信息，从而在多尺度特征融合过程中充分利用浅层特征。浅层特征提取层提取的特征包含边缘、纹理等更具体的特征信息，在检测小型目标更有效。按照四层特征设计的四头结构结合四个预测头进行小目标预测，四头结构可以减轻目标尺度快速变化带来的负面影响，增加的预测头由浅层高分辨率特征生成，对小目标更加敏感，显著提高小目标的检测性能。

3.3.2 融合自注意力机制

坐标注意力[57]（CA，Coordinate Attention）将全局均值池分成两个一维特征编码，分别沿图像的水平和垂直方向进行特征聚合，从而在注意通道中加入位置信息，生成方向和位置感知的注意图，帮助网络更好地识别并定位感兴趣的物体。在四层特征当中，新增加的浅层特征位置信息更加丰富，在有利于小目标检测，为了减少小目标被背景干扰，使模型更加关注目标所在区域，在该层特征前嵌入坐标注意力机制。对于图像视野比较大，前景目标比较小的各类图像，此结构融入模型中在检测精度上会有显著提升，且额外开销较小。对于图像视野很大而前景目标相对较小的任何类型的图像，将这种结构嵌入模型可以显著提高检测精度，而额外成本很小。

通过主干网络提取得到浅层特征层后，将浅层特征放进坐标注意力机制得到与输入维度一样的增强后的特征层，在再将该特征输入后面的网络，使得特征层中包含更多的前景

中国知网 https://www.cnki.net

目标信息。坐标注意力机制结构如图 3.5 所示，令输入特征为 $X = [x_1, x_2, x_3, \ldots, x_c] \in \mathbb{R}^{C\times H\times W}$，通过坐标注意力机制得到加强特征，其中$(h, w)$为输入特征层的高宽，C 代表特征层通道数。

为了保留位置信息，首先分别通过两个空间池化[58]核$(H, 1)$和$(1, W)$由公式 3.1 和 3.2 得到包含空间信息的特征z^h和z^w。

$$z_c^h(h) = \frac{1}{W}\sum_{0\le i<w} X_C(h, j) \tag{3.1}$$

$$z_c^w(w) = \frac{1}{H}\sum_{0\le j<H} X_C(j, w) \tag{3.2}$$

通过上面的池化后，将具有空间信息的特征z^h和z^w由公式 3.3 拼接在一起并通过一个

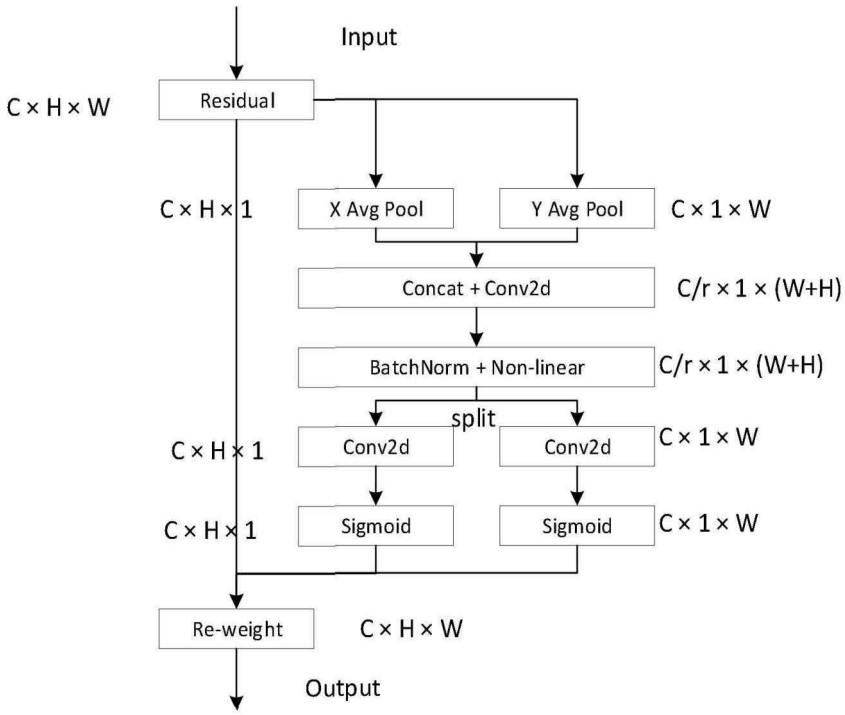


图 3.5 坐标注意力机制

卷积变换得到中间特征映射 f，这里$[,]$表示拼接操作，δ为 Sigmoid 激活函数，$F_1(\ )$表示卷积操作。

$$f = \delta\left(F_1([z^h, z^w])\right) \tag{3.3}$$

之后通过 1×1 的卷积操作将中间特征 f 变为和原始特征相同通道数的特征，通过

中国知网 https://www.cnki.net

Sigmoid 激活函数后，得到特征图在高度上的注意力权重g^h，得到特征图在宽度上的注意力权重g^w 。见公式 3.4，3.5。

$$g^h = \sigma\left(F_h\left(f^h\right)\right) \tag{3.4}$$

$$g^w = \sigma\left(F_w\left(f^w\right)\right) \tag{3.5}$$

最后将原始特征图每一个特征点与对应的在高度上的注意力权重和在宽度上的注意力权重相乘，得到坐标注意力块的输出 Y。见公式 3.6。

$$y_c(i,j) = x_c(i,j) \times g_c^h(i) \times g_c^w(j) \tag{3.6}$$

3.4 实验过程和数据分析

3.4.1 数据集

本文实验数据集采用旷世发布的用于行人检测的 CrowdHuman[55]数据集，该数据集中的图片数据大多来自 google 搜索。CrowdHuman 数据集拥有大量图片数据，其中测试集五千张，验证集 4370 张，训练集更是有一万五千张。平均每张图片有 22.6 个目标行人，共有 470000 个实例。

多目标跟踪场景中具有很多人口密集的场景和多样的场景，而 CrowdHuman 拥有平均每张有 22.6 个目标，非常多样的场景，相较于 CityPersons 的 7 个目标和 KITTI 的一个目标，单一的车载摄像收集的数据，CrowdHuman 拥有更加密集的人口密度，多样的场景，更加匹配多目标跟踪场景。

3.4.2 实验环境及其配置

本文的实验在硬件方面，处理器为 Intel(R) Core(TM) i7-12700K CPU @ 3.60GHz，RAM 为 32GB，显卡为 NVIDIA GeForce RTX 4090。在软件方面，使用的系统是 Windows 11 专业版，实验平台是 PyTorch。batch_size 为 64，epoch 为 400，学习率为 $1e^{-4}$。

3.4.3 评价指标

对于 YOLOX 的性能评估，主要的评价指标如表 3.1 所示：

召回率 Recall 的计算公式为

$$\text{Recall} = \frac{\text{TP}}{\text{TP+FN}} \tag{3.7}$$

中国知网 https://www.cnki.net

准确度 Precision 的计算公式为

$$\text{Precision} = \frac{\text{TP}}{\text{TP+FP}} \tag{3.8}$$

单类平均准确度 AP 的计算公式为

$$\text{AP} = \int_0^1 \text{P(r)dr} \tag{3.9}$$

表 3.1 目标检测评价指标

指标名称	说明
TP	正样本被正确检测的数量
FP	负样本被检测为正样本的数量
FN	正样本为被检测为负样本的数量
Recall	召回率，如公式 3.7 所示
Precision	准确度，如公式 3.8 所示
AP	单类平均准确度，如公式 3.9 所示
mMR	对数平均漏检率

3.4.4 实验结果分析

CrowdHuman 数据集存在大量密集小目标的场景，本章节通过在该数据集上进行实验，验证本章节提出算法的有效性，实验结果见表 3.2。

表 3.2 基准数据集 CrowdHuman 上的实验结果对比

Method	AP_{50}↑	Recall↑	mMR↓
Faster-RCNN	85.0	90.2	50.4
RetinaNet[59]	81.7	88.6	57.6
FCOS[60]	86.1	**94.2**	54.9
PAA	86.0	92.0	52.2
DETR	72.8	82.7	80.1

中国知网 https://www.cnki.net

OUR	**86.5**	91.8	**49.3**

表 3.2 对比了本文提出的算法与当前主流目标检测模型在 CrowdHuman 验证集上的检测性能。其中，选取了基于 Transformer 的 DETR 模型和两阶段检测器 Faster-RCNN 等作为对照，它们分别代表了探测器领域的最新发展方向。

实验结果表明，在这一具有挑战性的高密度人群数据集上，本文算法在平均精度等主要评价指标上均显著超越了 DETR 和 Faster-RCNN 等主流方法。具体来看，本文算法的AP_{50}值为 86.5，而 DETR 和 Faster-RCNN 的AP_{50}值分别为 72.8 和 85.0，性能差距分别达到了 13.7 和 1.5。在 mMR 指标上达到了 49.3，远低于其他算法，代表算法能够检测到更多的目标物体。在 Recall 指标上表现为 91.8，仅低于 FCOS、PAA 算法。这一优秀的表现进一步验证了算法在复杂拥挤小目标场景下的出色检测能力。

3.4.5 检测对比

为了检验模型在真实场景下的检验效果，收集了 100 张极具挑战性的公共场所小目标行人图像，总共 2005 个目标，进行对比实验。实验设置相同的置信度阈值进行检测，并将检测结果与 YOLOX 模型的检测结果进行对比，检测结果表 3.3 所示。

表 3.3 检测结果对比图

模型	正确检测数	误检数	漏检数
YOLOX	1806	13	186
OUR	1953	24	38

对比原始 YOLOX 模型和改进后模型的检测结果可以看出，改进过后的模型检测出小目标行人的数量相较于原始模型有显著提升，漏检数远低于原始模型。虽然误检目标的数量大于原始模型数量，但是相较于原模型检测器的整体性能是提升的。这表现验证了本文算法在复杂拥挤小目标场景下拥有出色的检测能力。

3.5 本章小结

本章主要对 YOLOX 的整体结构基础进行了详细的介绍，还对其核心改进进行介绍。在 YOLOX 算法的基础上，在特征融合阶段，采用来自 4 个不同尺度的特征层，涵盖从高分辨率到低分辨率的丰富特征信息。与此同时，通过采用上下文跳跃连接的方式，将深层

中国知网 https://www.cnki.net

次的语义特征与浅层次的细粒度特征进行有效融合，并融合坐标注意力机制，从而增强网络了对小目标对象的友好度。为了验证模型有效性，在 CrowdHuman 图像数据集进行了实验，在AP_{50}指标上取得 86.5 的优异表现，证明了算法设计的有效性。

中国知网 https://www.cnki.net

4 以观测为核心融合重识别的多目标跟踪方法

近年来得益于图形处理器（GPU）的快速发展，目标检测和行人重识别领域取得了巨大的进步，基于这两者的多目标跟踪算法的性能得以提升。然而，传统的运动模型仍然存在大量问题。在一些场景中，存在遮挡、模糊等情况，导致目标丢失、身份切换等问题，而在基于卡尔曼滤波器的算法当中，当目标丢失时，由于长时间没有匹配到目标，误差会不断积累放大，卡尔曼滤波器的估计存在巨大误差。大多数的多目标跟踪算法过分依赖于运动模型的状态估计，而没有充分利用观测信息。在重叠的目标匹配中，传统匹配策略可能造成匹配错误，从而造成身份切换。

4.1 引言

常见的基于运动模型的多目标跟踪算法存在许多缺陷。

（1）例如 SORT，在某一时刻目标被遮挡，由于检测不到目标，就会发生目标丢失，SORT 采用的卡尔曼滤波器借助于观测值在每帧更新后验参数以获得更加精确的跟踪结果，而当没有目标时，误差会不断积累放大。

卡尔曼滤波器对于噪声十分敏感，在连续的帧间，根据线性运动系统，可以根据公式 2.2 求得下一帧的位置。

$$x_{t+1} = x_t + v_x\Delta t \ , \quad y_{t+1} = y_t + v_y\Delta t \tag{4.1}$$

当水平帧率很高的时候，在连续的帧间可以设$\Delta t = 1$。假设目标中心位置（x，y）遵循正态分布，即 $x \sim n(\mu_x, \sigma_x^2)$，$y \sim n(\mu_y, \sigma_y^2)$。根据公式 2.2 可以得到时间 t 与 $t + \Delta t$ 间 x 和 y 的估计速度v_x和v_y

$$v_x = \frac{x_t+\Delta t-x_t}{\Delta t}, \ v_y = \frac{y_t+\Delta t-y_t}{\Delta t} \tag{4.2}$$

估计速度噪声分布遵循$\delta_{v_x \sim n\left(0,\frac{2\sigma_x^2}{(\Delta t)^2}\right)}$， $\delta_{v_y \sim n\left(0,\frac{2\sigma_y^2}{(\Delta t)^2}\right)}$，所以当$\Delta t$ 越小的时候，分布方差越大，说明速度估计的噪声越大。在大多数的多目标场景当中，帧间的位移大多只有几个像素而已，而估计噪声的量级已经与该值相同，可见类似 SORT 的算法对状态噪声十分敏感。当目标连续时，在观测值的监督下可以在一定程度上修正误差，减少噪声的影响。

然而当目标丢失了一段时间，那么误差就会被放大。假设每一帧间时刻目标中心位置

中国知网 https://www.cnki.net

估计是独立的，而基于马尔可夫的卡尔曼滤波器严重依赖于前一时刻，当目标因为遮挡等无法匹配性的观测值的时候，卡尔曼滤波器只能依靠自身进行预测。在 t+T 时，根据公式 4.3 得到目标的位置估计(x_{t+T}, y_{t+T})

$$x_{t+T} = x_t + Tv_x \ , y_{t+T} = y_t + Tv_y \tag{4.3}$$

帧间估计噪声$\delta_{x_t} \sim n(0,2\sigma_x^2)$，$\delta_{y_t} \sim n(0,2\sigma_y^2)$。然而，在一段时间 T 目标丢失的情况下噪声$\delta_{x_{t+T}} \sim n(0,2T^2\sigma_x^2)$，$\delta_{y_{t+T}} \sim n(0,2T^2\sigma_y^2)$，位置估计的误差会被放大，如果假设$\sigma_x$和$\sigma_y$与目标位移量级相当，那么 10 帧遮挡后，误差可达目标大小，导致跟踪失败。

（2）在密集场景下，会出现很多重叠目标，这时可能会导致跟踪失败，而出现身份切换、目标丢失等问题。在数据关联步骤可由公式 4.4 得到代价矩阵，用于度量检测框和跟踪框重叠程度，再用贪心算法完成身份匹配。当 IoU 取值区间为 0 到 1，当等于 1 时表示他们完全重叠。

$$\mathrm{IoU}(a,\ b) = \frac{|a \cap b|}{|a \cup b|} \tag{4.4}$$

然而在密集场景下会出现一个跟踪框与多个检测框重叠的情况，如图 4.1 所示不同

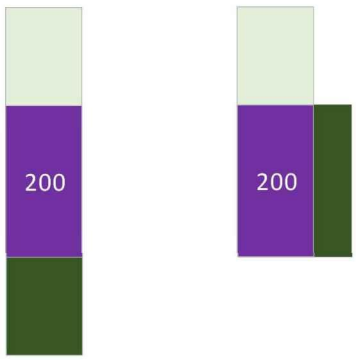


图 4.1 重叠检测框

形状的检测框可能和同一跟踪框具有相同的 IoU 距离，不同形状相同面积的淡绿色检测框和跟踪框重叠的面积相同。而目标形状一般是不会变化，例如一个的身高体型在一个水平里面是固定不变的，而 IoU 距离在这种情况下并不能帮助正确地完成跟踪。

中国知网 https://www.cnki.net

为了解决上述问题，在第三章的基础上，引入融合观测和重识别的目标找回平滑参数方法 Re-OCROS 以缓解误差累计放大的问题，采用基于目标外貌的 IoU 匹配 Shape-IoU 去解决重叠目标匹配错误的问题。

4.2 算法整体框架

本章在第三章改进的检测器之上，提出融合观测和重识别的目标找回平滑参数算法，如图 4.2。算法主要包含两个新设计的关键子模块，即融合观测和重识别的目标找回平滑参数方法 Re-OCROS 和基于目标外貌的 IoU 匹配 Shape-IoU。

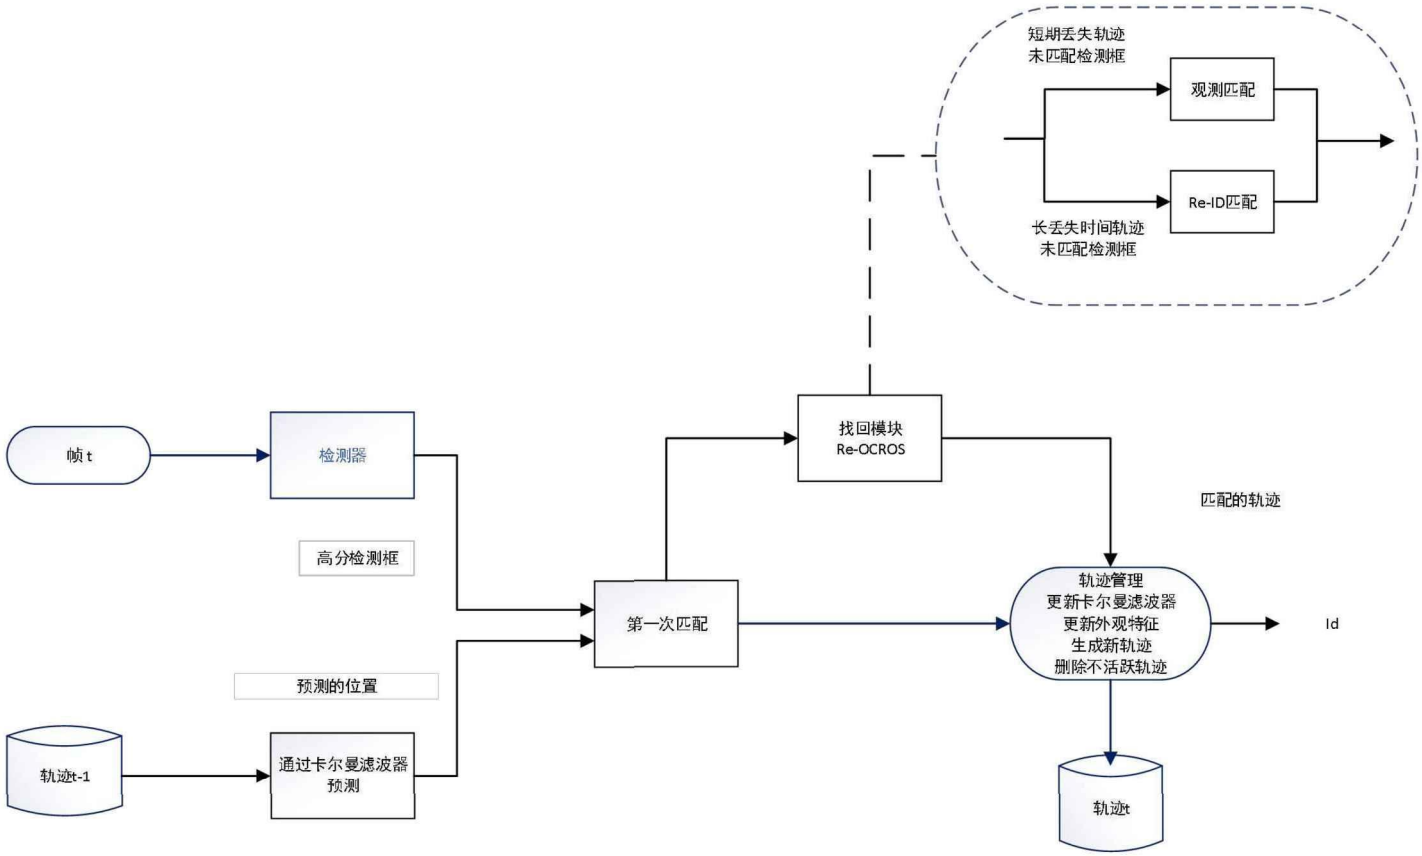


图 4.2 算法整体框架

4.3 融合观测和重识别的目标找回平滑参数方法 Re-OCROS

本节详细介绍融合观测和重识别的目标找回平滑参数方法 Re-OCROS，其针对不同的丢失时间采用不同的找回策略去平滑卡尔曼滤波器的参数。具体来说在短丢失时间情况下

中国知网 https://www.cnki.net

下采用基于观测的找回平滑方法，在长丢失时间情况下采用基于 Re-ID 的找回平滑方法。

短时间目标丢失情况下，依赖卡尔曼滤波器预测的轨迹位置和真实位置存在巨大误差。卡尔曼滤波器使用观测来辅助卡尔曼滤波器状态估计的传递，目标丢失时，缺少目标信息来修正卡尔曼滤波器的参数，更加以估计为中心，存在较大状态噪声。然而随着目标检测技术的进步，目标识别的精度大幅提升，假设观测噪声$\delta_{ox}\sim\mathcal{N}(0,\sigma_{ox}^2)$，$\delta_{oy}\sim\mathcal{N}(0,\sigma_{oy}^2)$，发现$\sigma_{ox}<\sigma_x$和$\sigma_{oy}<\sigma_y$，即观测的噪声小于估计的噪声。所以在短丢失时间内应该以观测为中心去找回目标。

长丢失时间情况下，依靠卡尔曼滤波器已经难以预测目标的真实位置，在该情况下采用重识别的方法找回目标去平滑参数。采用 Re-ID 模型提取特征表示，建立丢失目标特征库，通过计算目标与特征库的距离产生代价矩阵，最后通过贪心算法完成身份匹配。

4.3.1 基于观测的找回方法

在多目标跟踪过程中，目标常常由于遮挡、出界等原因而暂时丢失。在这种情况下，如果仅依赖运动估计预测目标状态，由于噪声的累积效应，预测精度将快速下降，难以维持跟踪的连续性和准确性。相比之下，基于观测的匹配策略能够有效避免噪声放大的问题，从而获得更加精确的跟踪性能。

鉴于此，本文提出一种创新的丢失目标恢复机制。具体而言，记录每个目标最后一次被成功观测时的位置信息，并在后续较近的跟踪帧中，将该位置与当前帧的观测结果进行匹配，旨在重新检出之前丢失的目标。该策略不仅能够及时发现并修复由于遮挡等情况导致的目标丢失问题，而且避免了完全依赖运动估计模型的风险，从而有效提升了跟踪系统的鲁棒性和精度。

该机制的关注目标最后已知的位置信息，并与当前观测结果进行相关性分析，从而恰当地处理目标的暂时消失。该机制在更短的丢失时间内使用，与基于外貌的找回方法联合找回丢失的目标。通过实验验证，所提出的策略能够显著降低目标丢失率，提高跟踪的连续性和一致性，为解决复杂场景下的多目标跟踪任务提供了一种行之有效的解决方案。

4.3.2 基于外貌的找回方法

在长丢失时间情况下，本文采用重识别方法找回目标。目标长时间丢失情况下，目标的运动状态可能已经改变，并且卡尔曼滤波器累积了大量噪声，因此采用重识别的方法，依靠外貌特征找回目标。通过 Re-id 模型抽取长丢失时间目标的特征，建立丢失目标特征库，在数据连接阶段，将检测器产生的未匹配目标通过 Re-ID 模型抽取特征，再与特征库对比找回丢失的目标。本文使用 ResNeSt50[61]作为 backbone，采用 FastReID [62]库中的 SBS

中国知网 https://www.cnki.net

网络作为重识别特征提取器。

（1） ResNetst

ResNeSt 采用分散注意力网络，让模型更加关注输入中相关的特征，而降低对无关特征的关注，如图 4.3。ResNeSt 将输入分为 K 个基组，每个基组中又分为 r 个分散的小组，每个小组通过卷积层再一起输入分散注意力网络。最后将 k 个基组的输出沿着通道维度连接起来再通过一个卷积层和输入进行残差链接。

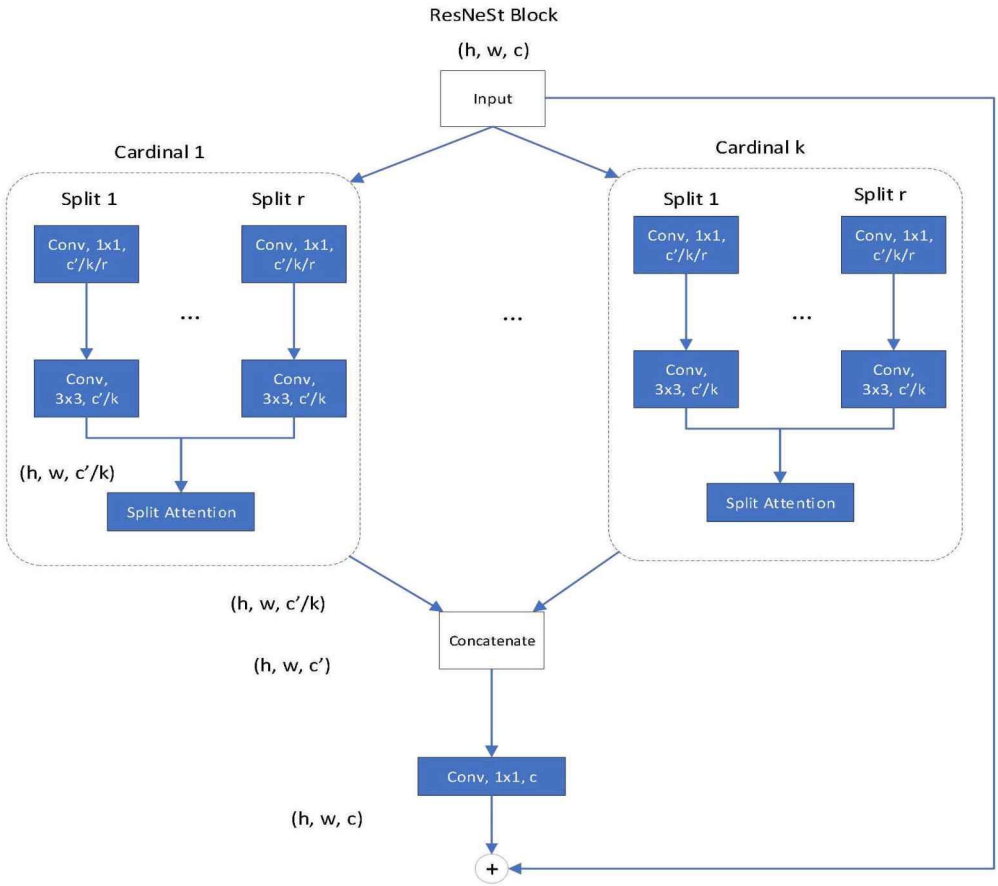


图 4.3 ResNeSt 网络结构图

分散注意力（Split Attention）将多个输入进行加权，如图 4.4，由公式 4.5 得基组 K 的特征$\widehat{U}^k$，$\widehat{U}^k \in \mathbb{R}^{h\times w\times c/k}$，k∈1、2、3…K，(H，W，C)为为输出特征图大小。

$$\widehat{U}^k = \sum_{j=R(k-1)+1}^{Rk} U_J \tag{4.5}$$

这里由公式 4.6 得全局的上下文信息s^k，$s^k \in \mathbb{R}^{c/k}$。

中国知网 https://www.cnki.net

$$s_c^k = \frac{1}{H\times W}\sum_{i=1}^{H}\sum_{j=1}^{W}\widehat{U}_c^k(i,j) \tag{4.6}$$

通过通道级软注意力得到基组的特征$V^k \in \mathbb{R}^{H\times W\times C/J}$，这里可由公式 4.6 得第 c 个通道的特征$V_c^k$。

$$V_c^k = \sum_{i=2}^{R} a_i^k(c)U_{R(k-1)+i} \tag{4.7}$$

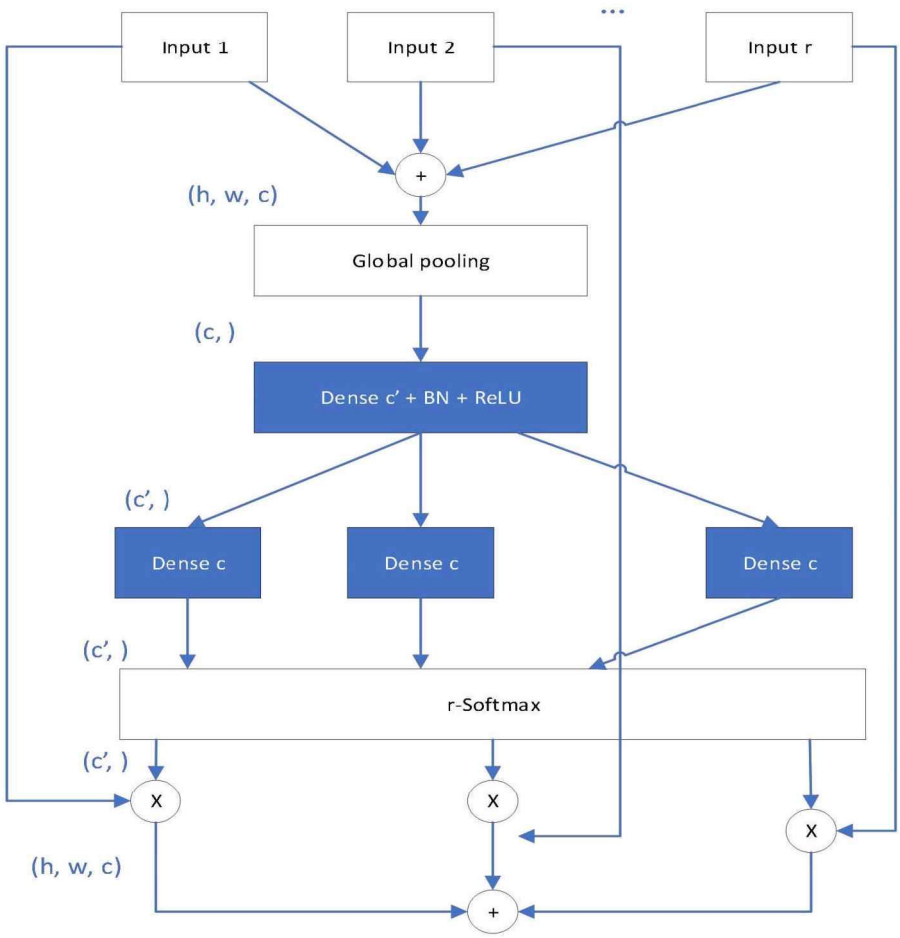


图 4.4 分散注意力机制网络结构图

这里软权重$a_i^k(c)$可由公式 4.8 得

中国知网 https://www.cnki.net

$$a_i^k(c)=\begin{cases}\dfrac{exp\left(\varrho_i^c(s^k)\right)}{\sum_{j=1}^{R}exp\left(\varrho_i^c(s^k)\right)} & if\ R>1\\ \dfrac{1}{1+exp\left(-\varrho_i^c(s^k)\right)} & if\ R=1\end{cases} \tag{4.8}$$

其中ϱ_i^c决定每个 split 中的第 c 个通道的权重，ϱ_i^c基于全局上下文特征表示s^k。

（2）BOT

BOT 是一个强大的行人重识别基准模型。BOT 在数据处理上采用随机擦除数据增强，以一定概率随机遮挡输入图像的一块区域，提高模型鲁棒性。BOT 设计了一个 BNNeck 结构，在特征向量后添加 BN 层，分别用于 ID loss 和 triplet loss，使两种 loss 目标一致。

（3）基于余弦距离的外貌特征度量及更新

在多目标跟踪过程中，外貌信息对于相似度计算至关重要。当追踪过程中存在长时间丢失目标的情况时，运动信息不足，需要外貌信息来判断是否为同一个跟踪目标。在前面的章节中已对外貌特征提取网络做了相关介绍，而本小结对外貌特征度量和外貌特征的加权融合研究。

基于余弦距离的外貌特征度量与加权融合是一种用于评估个体相似性的学术方法，其通过计算余弦距离以度量外貌特征之间的相似性。外貌特征通常以向量的形式表示，余弦距离的计算提供了一种有效的度量方式，通过评估两个特征向量之间的夹角来捕捉它们之间的方向性相似性。

A1 和 B1 表示两个向量表示两个目标的外貌信息，那么可由公式 4.9 得两个目标之间的

$$\mathrm{d}(\mathrm{A1},\ \mathrm{B1})=1-\frac{\mathrm{A1}\cdot\mathrm{B1}}{\|\mathrm{A1}\|\cdot\|\mathrm{B1}\|} \tag{4.9}$$

余弦距离 d。其中 $\mathrm{A1}\cdot\mathrm{B1}$ 表示两个向量的内积，$\|\ \ \|$表示对向量的模。余弦距离越接近 1 表示两个向量越相似，则两个目标越有可能是同一个跟踪对象。

在跟踪过程中，因为观测角度、光线等因素，目标的外貌会不断发生变化，为了减少减小因突发性变化或噪声引起的波动，提高估计的稳定性和鲁棒性，本文使用指数移动平均（EMA，Exponential Moving Average）对外貌特征进行更新，用e_i^t表示目标 i 在 t 时刻的外貌特征向量，公式为:

$$e_i^t=\alpha e_i^{t-1}+(1-\alpha)f_i^t \tag{4.10}$$

其中f_i^t表示 t 时刻观测到的外貌特征向量，动量项$\alpha=0.9$。EMA 可以通过对这些观测值进行加权平均来估计目标的当前状态，而不仅仅依赖于单一时刻的观测值，提高了跟踪系统的鲁棒性。

中国知网 https://www.cnki.net

4.4 基于找回的平滑卡尔曼参数策略

在多目标跟踪过程中，常因为遮挡、模糊等情况发生目标丢失。而在运动模型卡尔曼滤波器严重依赖每一时刻的观测者来辅助更新，一段时间的目标丢失会使卡尔曼滤波器不断累计误差，导致跟踪失败。在前面的小节中已对如何找回丢失目标做了相关的介绍，本小节研究根据前面两种方法找回的目标平滑卡尔曼参数。

假设目标丢失之前最后一次观测为O_{t1}，因为一些原因目标丢失了一段时间，一段时间后找回目标时的观测为O_{t2}。根据目标丢失的位置和找回位置以及丢失时间得到目标的虚拟深度，最后生成一条虚拟观测轨迹$\widehat{O}_t$，公式为：

$$\widehat{O}_t = Traj_{virtual}(O_{t1}, O_{t2}, t), t_1 < t < t_2 \tag{4.11}$$

根据虚拟轨迹通过公式 2.1-2.9 重新更新卡尔曼滤波器的参数，减少误差累计。

4.5 基于目标外形的 IoU 匹配 Shape-IoU

在密集场景下会出现一个跟踪框与多个检测框重叠的情况，不同形状的检测框可能和同一跟踪框具有相同的 IoU 距离，而导致身份切换。而目标形状一般是不会变化，例如一个人的身高体型在短时间里面是固定不变的，而 IoU 距离在这种情况下并不能帮助正确的完成跟踪。

为了解决上述问题，采用基于外形的 IoU 进行匹配。通过对检测的形状引入约束，该方法旨在增大跟踪框与形状不一致检测框之间的距离，以及减小与形状一致检测框之间的距离，公式：

$$\mathrm{SIoU} = \mathrm{IoU} - \frac{|h_a - h_b|}{|h_c + \gamma|} - \frac{|w_a - w_b|}{|w_c + \gamma|} \tag{4.12}$$

h_a、h_b、h_c分别表示跟踪框、检测框和重叠框的高，w_a、w_b、w_c分别表示跟踪框、检测框和重叠框的宽，γ真实验设置为10^{-7}。

4.6 实验结果与分析

4.6.1 实验环境搭建

本章实验详细的硬件配置表如图表 4.1

中国知网 https://www.cnki.net

表 4.1 硬件配置

硬件类型	配置详情
处理器	12th Gen Intel(R) Core(TM) i7-12700k
显卡	NVIDIA GeForce RTX 4090

软件配置表如图表 4.2

表 4.2 软件配置

软件类型	版本
Windows 11	1301.2312.2011.0
NVIDIA 驱动	550.09
CUDA	11.8
Python	3.11.5
Pytorch	2.1.0
PyCharm	17.0.7

4.6.2 对比试验

本节将探讨所提出方法在多个公共数据集上的实验结果，并与当前领先的跟踪算法进行深入对比。通过系统的实验验证，旨在全面评估该方法在不同场景和数据集下的性能，并与其他算法进行客观比较。

本章节通过在公开的多目标跟踪数据集 MOT17 和 MOT20 上进行实验，验证本章节提出的多目标跟踪算法的有效性。实验结果见表 4.3、4.4。箭头向上代表数据值越大越好，

中国知网 https://www.cnki.net

箭头向下反之，加粗部分代表该指标的最优结果。表 4.3 是本章方法在 MOT17 数据集上的对比结果。

实验结果显示，本研究提出的多目标跟踪框架在公开数据集上 MOT17 上取得了优良的性能表现，在主要评估指标如多目标跟踪精度（MOTA）、多目标跟踪精确度（MOTP）等方面优于目前该领域内的主流方法。具体而言，与基于目标检测的经典方法 ByteTrack 相比，本文算法在IDF_1和 HOTA 两个指标上分别高出 0.5 和 0.6，展现出更为精准的身份识别和跟踪能力。同时，本文方法也优于联合检测外观表达的多目标跟踪方法 FairMOT 算法，MOTA 提升了 5%，证明本文的框架拥有更好的性能。此外，还将本文方法与基于 Transformer 的 TransTrack 算法进行了对比，结果表明本文算法的 MOTA 值高出 3.5%，

表 4.3 MOT17 数据集上的对比

Method	MOTA↑	IDF_1↑	HOTA↑	FP(10^4)↓	FN(10^4)↓	ID_s↓
MOTR	71.9	68.4	57.2	2.11	13.6	2，115
FairMOT	73.7	72.3	59.3	2.75	11.7	3303
CenterTrack	67.8	64.7	52.2	18.4	16.0	2583
ByteTrack	**80.3**	77.3	63.1	2.55	**8.37**	3567
TransTrack	75.2	63.5	54.1	5.02	8.64	3603
OC-SORT	78.0	77.5	63.2	1.51	10.8	1950
Ours	78.7	**77.8**	**63.7**	**1.48**	10.4	**1798**

说明方法在长期目标跟踪方面具有更强的稳健性。本文提出的 Shape-IoU 对于提升多目标跟踪的整体性能起到了关键作用。实验结果表明，在ID_s指标方面，本文的算法优于其他的算法，展现出了优异的表现，身份切换大幅低于其他主流方法。这一优异表现主要得益于所引入的 Shape-IoU 指标，通过对目标形状、尺寸和纵横比等几何特征进行约束，极大地降低了身份混淆、丢失等错误的发生概率，确保了多目标跟踪的整体稳健性。

为了全面评估所提出算法在高密度拥挤场景下的跟踪性能，在权威的 MOT20 数据集

中国知网 https://www.cnki.net

上进行了大规模实验测试。MOT20 数据集由多个高拥挤度监控视频组成，能够极为严格地考验多目标跟踪算法在复杂环境下的稳健性和精确度。将本文方法的实验结果与当前该领域的其他前沿算法进行了对比，具体数据见表 4.4 所示。表中粗体字和下划线分别标注了各项指标下的最优性能。

在 MOT20 这一具有极高挑战性的多目标跟踪基准测试中，本文提出的算法分别在 MOTA 和 IDF1 上取得了 76.2%和 75.9%的评分。具体而言，与其他先进方法相比，本文的算法显著减少身份切换和漏检情况的发生。与其他跟踪方法相比，即 $\mathrm{FP}(10^4)$ 减少了 1.02~8.7， $\mathrm{ID_s}$降低了 373~4396。

表 4.4 MOT20 数据集上的对比

Method	MOTA↑	$\mathrm{IDF_1}$↑	HOTA↑	$\mathrm{FP}(10^4)\downarrow$	$\mathrm{FN}(10^4)\downarrow$	$ID_s\downarrow$
FairMOT	61.8	67.3	54.6	10.3	8.89	5243
TransTrk	65.0	59.4	48.5	2.72	15.0	3608
CSTrack[63]	66.6	68.6	54.0	2.54	14.4	3196
ByteTrack	**77.8**	75.2	61.3	2.62	**8.76**	1223
TransCt	58.5	49.6	43.5	6.42	14.6	4695
Ours	76.2	**75.9**	**62.2**	**1.6**	10.6	**850**

在 JDE 范式算法中，CSTrack 在 MOTA 指标上取得了最高的评分，然而与本文算法相比仍然存在 9.6%（76.2-66.6%）的明显差距。在$\mathrm{IDF_1}$指标上，其分别以 8.6%（75.9%-67.3%）和 7.3%（75.9%-68.6%）的优势超越了 JDE 范式算法 FairMOT 和 CSTrack。

与 TBT 范式多目标跟踪算法 TransTrk 和 TransCt 相比，本文算法在 MOTA 指标上超出了它们 11.2%（76.2%-65.0%）和 17.7%（76.2%-58.5%）。而在 IDF1 指标上，本文算法相比 TransTrk 和 TransCt 分别取得了 16.5%（75.9%-59.4%）和 26.3%（75.9%-49.6%）的优势。在 TBD 范式算法中，虽然本文算法在 MOTA 指标上落后于 ByteTrack，但是该算法的 ID_s指标上的表现远远不及本文算法。这一定程度上说明本文算法在维持目标身份信

中国知网 https://www.cnki.net

息的能力并不弱于 ByteTrack，证明算法在减少身份切换上的有效性。

通过上述大量实验对比和数据分析，可以看出本文提出的多目标跟踪算法在诸多评价指标上均展现出明显的优越性。目标的关联度提高，ID 切换次数减少，丢失情况减少，跟踪准确度和关联匹配度均有增益，缓解因目标遮挡和目标运动复杂造成的身份切换、丢失等问题。

4.6.3 消融实验

为了全面评估本文提出的 Re-OCROS 模块和 Shape-IoU 匹配策略的有效性，进行了精心设计的消融实验，系统地分析了这两种创新技术在不同算法环节的独立贡献，并量化了它们对整体性能的提升程度。本论文在多目标跟踪数据集 MOT17 上进行了消融实验，实验结果见表 4.5。

表 4.5 消融实验

Shape-IoU	Re-OCROS	HOTA	MOTA	IDF1	$IDs\downarrow$
		63.2	78.0	77.5	1950
√		63.2	78.0	77.6	1813
	√	63.6	78.7	77.8	1924
√	√	**63.7**	**78.7**	**77.8**	**1798**

在上述内容中，提出了两种创新性技术模块：Re-OCROS 模块和基于目标外形的 Shape-IoU 匹配策略。针对于此模块的消融实验研究中，设计了三组对比实验来验证上述两个模块对算法整体性能的提升作用:

（1）基线实验:移除 Re-OCROS 模块和 Shape-IoU 匹配策略，保留其他模块不变。该实验可以反映出创新模块对整体算法框架的重要性。

（2）Shape-IoU 单因素实验:仅引入 Shape-IoU 匹配策略，排除 Re-OCROS 模块的影响。通过与基线实验的对比，可以量化 Shape-IoU 在重减少目标身份切换方面的贡献。

中国知网 https://www.cnki.net

（3）Re-OCROS 单因素实验:仅引入 Re-OCROS 模块，而不使用 Shape-IoU 策略。该实验旨在评估 Re-OCROS 模块在优化跟踪精度和减少目标丢失方面的作用。

通过上述精心设计的消融实验，能够全面剖析两个创新模块在不同环节的独立贡献，并准确量化它们对整体算法性能的提升程度。

首先，当同时移除 Re-OCROS 模块和 Shape-IoU 策略时，多目标跟踪网络的性能出现明显下降，多目标跟踪精度（MOTA）只有 78.0%，这充分说明了创新模块对算法整体性能的重要性。

其次，单独引入 Re-OCROS 模块后，由于其优化了目标匹配机制，算法的 MOTA 值相较基线提升了 0.7%，同时身份切换错误 ID_s也有所下降。这验证了 Re-OCROS 模块在提高跟踪精确度和找回丢失目标方面的积极作用。

再者，仅引入 Shape-IoU 匹配策略，由于其合理利用了目标几何信息，有效降低了错误的身份关联，因此 ID_s指标大幅降低至 1924，且其他指标如多目标跟踪精确度也得到一定改善。

最后，当同时引入两种创新模块时，本文算法在 MOTA 和 ID_s两个核心指标上均取得了优异表现，凸显了它们的协同增益效应。

消融实验的结果数据进一步证实了本文提出的 Re-OCROS 模块和基于目标外形的 Shape-IoU 匹配策略对于提升多目标跟踪算法的整体性能作用显著。Shape-IoU 匹配策略有助于避免目标身份 ID 的频繁切换，Re-OCROS 模块帮助找回丢失目标，有效提高了算法的跟踪性能。

4.7 本章小结

本章中提出了 Re-OCROS 模块和基于目标外形的 Shape-IoU 匹配策略，并将它们融合至基于检测的多目标跟踪框架之中，形成了一种以观测为核心融合重识别的跟踪方法。首先，通过分析现有多目标跟踪算法的不足，发现在拥挤、遮挡等复杂环境中，身份混淆、目标丢失等问题仍然广泛存在，这严重影响了跟踪的准确性和稳定性。为解决这一痛点，提出了 Re-OCROS 模块和 Shape-IoU 策略。前者通过优化匹配机制，帮助找回丢失目标；后者则利用目标几何信息，减少了错误的身份关联。对该方法的设计思路进行详细说明，并且以图示的形式给出并介绍了以观测为核心融合重识别的多目标跟踪方法。为验证所提出方法的有效性，在权威的 MOT17 和 MOT20 数据集上进行了大规模实验测试。实验结果显示，MOT17 数据集中，本文的算法在身份切换错误和 HOTA 指标上分别取得了 1798 和 63.7 的优异表现。在 MOT20 数据集重，本文的算法在身份切换错误和 HOTA 指标上分别取得了 850 和 62.2 的优异表现。这充分证明了本章节提出的以观测为核心融合重识别的多目标跟踪方法可以有效缓解了复杂场景下的目标漏检及身份切换等问题。

中国知网 https://www.cnki.net

5 公共场所人群智能监控系统

目前，智能监控系统使用基于深度学习的多目标跟踪和目标检测等方法对视频数据流进行视频分析。本文在不改变其他设定的条件下，将本文的算法应用于公共场所人群智能监控系统中，有效提升公共场所的安全防范能力。

5.1 需求分析

在城市化快速发展和公共场所人流增加的背景下，构建高效、准确的人群智能监控系统成为城市管理的重要一环。本文旨在通过应用基于深度学习的多目标跟踪和目标检测技术，提高公共场所人群智能监控系统的性能和多目标跟踪的精度。需求分析报告将对系统的可行性、功能性需求和非功能性需求进行详尽分析，以确保系统的设计和开发能够顺利实现预期目标。

5.1.1 可行性分析

公共场所人群智能监控系统的可行性主要是以下几个方面。

(1) 技术可行性。首先，系统的架构包括视频采集端、云服务端、后台服务端和客户端。监控摄像头作为视频采集端，通过云服务端协议将实时采集的数据传输到后台服务端。这一架构设计符合现代分布式系统的标准，充分利用云服务的高效性和可扩展性。云服务端的选择为整个系统提供了稳定且高度可靠的数据传输通道。基于深度学习的多目标跟踪和目标检测技术已经在计算机视觉领域取得显著的成果，这为公共场所人群智能监控系统的技术实现提供了可靠的基础。

(2) 操作可行性。基于 QT 的前端操作页面简单明了，不需要培训就可使用。系统运行为市面上常见的 Windows10 系统，安装无门槛。

(3) 经济可行性。智能监控系统的成本主要为人力和算力硬件，具有经济可行性。系统视频分析需要高性能显卡，除此之外系统没有其他高额成本，整体开发成本低廉。

5.1.2 功能性需求分析

本系统旨在构建一种高效智能的视频监控与行为分析平台，用于公共场所人群活动的实时监测和异常事件检测。该系统的总体设计理念和核心功能模块如下：

1. 视频采集与管理模块

该模块负责实时获取监控区域的视频流数据，并通过优化的传输协议将其传递至后端服务器进行进一步处理。同时，也支持对历史视频数据的存储、检索和回放功能，确保监

中国知网 https://www.cnki.net

控过程的连续性和完整性。

2. 基于深度学习的智能分析模块

该模块集成了本文设计的多目标跟踪算法，可自动对视频图像进行智能分析，包括人群检测与跟踪、目标行为识别等。具体功能包括:人群汇集异常检测与报警、人员活动区域越界报警、可疑异常行为检测报警等，有效提升公共场所的安全防范能力。

3. 信息存储与管理模块

该模块建立了标准化的数据库系统，用于存储和管理视频元数据、分析结果及相关信息，确保数据的安全性和可追溯性。用户可方便地查阅人群统计信息、异常行为事件记录、目标对象身份等，也可对这些信息进行编辑和维护，为决策分析提供支撑。

4. 可视化呈现与交互模块

该模块提供直观、高效的图形用户界面，直接在线展示实时监控画面和智能分析结果，并支持多维度数据交互式可视化，使系统操作人员能够高效获取所需信息。

该系统将视频监控技术与先进的智能分析手段相结合，不仅能够对公共场所人群活动实现全面监控，还能智能识别潜在安全隐患，为确保公共安全提供有力保障。

5.1.3 非功能性需求分析

（1）性能需求。在高人流量场景下，系统需要保持高稳定性和实时性，确保对异常事件的及时响应，同时能够处理大规模数据流，保证监控结果的准确性。

（2）安全性。数据传输和存储需要采用加密技术，确保系统在设计和运行中符合信息安全标准，防止未经授权的访问和数据泄露。

（3）可扩展性。系统应具备良好的可扩展性，以适应不同规模和需求的公共场所，且在未来城市发展中能够灵活升级和扩展。

（4）用户体验。用户界面的设计应考虑操作人员的使用体验，符合人体工程学原理，减轻操作负担，提高工作效率。

5.2 系统架构和总体功能设计

系统包括监控端、云服务端、后台服务端以及桌面软件四个关键部分。云服务端的数据库服务器和流媒体服务器分别负责数据的存储和传输，为整个系统提供了基础支持。后台服务端是系统的核心设计和实现模块，包括实时监控与回放、人工智能分析、数据管理等三个业务模块化功能。

在后台服务端的设计中，实时监控与回放模块实现了对实时视频流的监控以及历史视频的回放功能。人工智能分析模块则负责对行人行为进行智能分析，包括行人检测、轨迹分析等。数据管理模块用于管理系统的各类信息，如用户权限、设备状态等。这些功能模

中国知网 https://www.cnki.net

块的协同工作使得整个系统具备了对行人活动的全方位监控和智能分析的能力。

值得注意的是，数据库服务器负责高效地存储系统产生的大量数据，而流媒体服务器则实现了数据的实时传输，使得监控系统能够快速响应和处理各类信息。整个系统的架构不仅考虑到了技术的先进性，也注重了对用户需求的充分满足。通过清晰的模块划分和功能设计，行人智能监控系统在实现监控、分析和管理等方面都具备了强大的能力。

行人智能监控系统的核心功能模块涵盖实时监控与回放模块、人工智能分析模块以及数据管理模块，如图 5.1。

实时监控与回放模块，承担着对实时视频流的监控以及历史视频回放功能。通过此模块，系统能够实时地对监测区域进行观察，并提供对过去记录的灵活检索与回溯。这一功能对于行人活动的动态监控和历史数据的复盘具有重要意义。

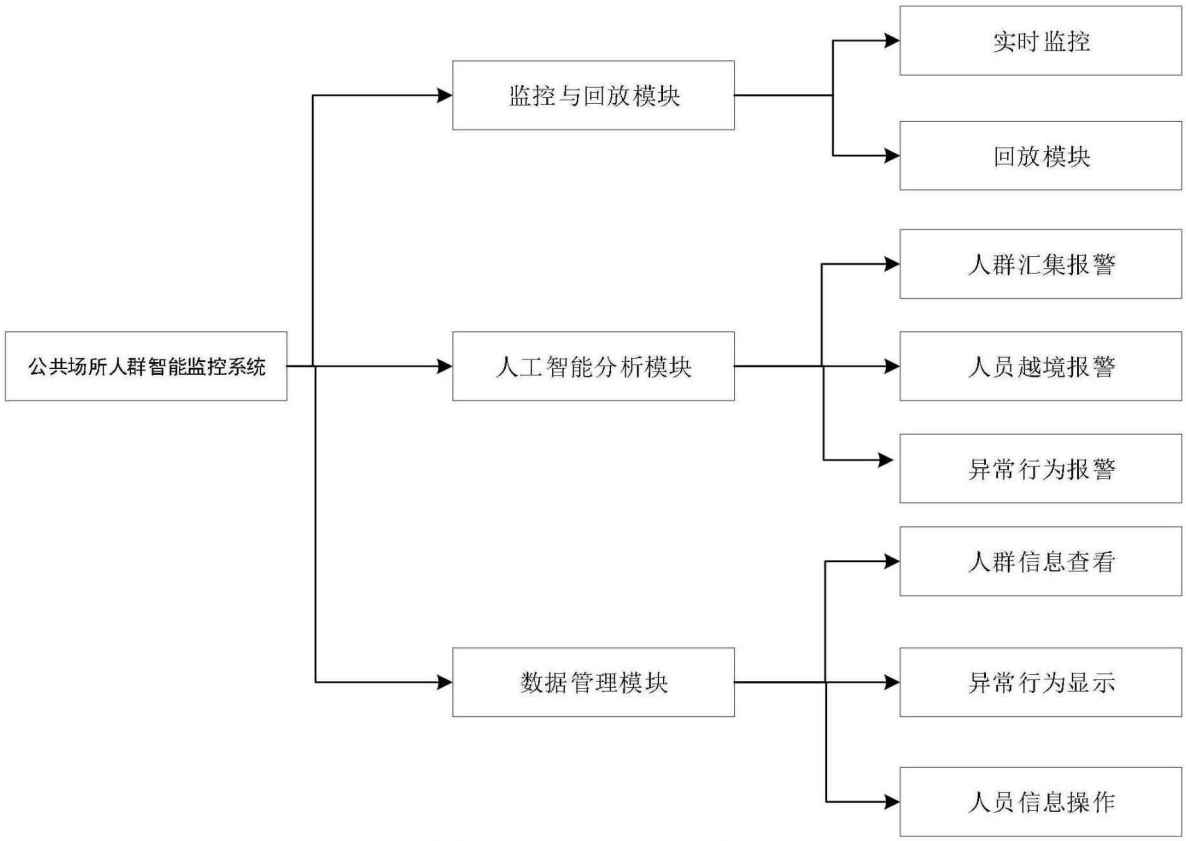


图 5.1 公共场所人群智能监控系统功能模块图

人工智能分析模块是系统的核心，负责对行人行为进行智能分析。该模块包括人群集聚预警，人员异常分析等功能，以实现对监测场景中行人活动的自动识别和分析。通过深度学习等先进技术的应用，智能分析模块有效地提高了系统对复杂场景下行人行为的准确性和智能性。

中国知网 https://www.cnki.net

数据管理模块则专注于对系统内各类信息的管理。其中包括用户权限管理、设备状态管理等内容，旨在保障系统的稳定运行和安全性。通过此模块，系统管理员能够高效地进行对系统整体状态的监控和调控。

这些功能模块共同构建了一个高效且全面的行人智能监控系统，其在实时监控、智能分析和信息管理等方面均具备卓越性能，为实际应用提供了强有力的技术支持。

5.3 系统开发环境

公共场所人群智能监控系统主要使用编程语言为 Python、C++，系统功能开发使用 Windows 系统，数据库采用 MySQL，编译器主要使用 Pycharm 和 Qt Creator，系统开发使用的软硬件的配置见表 5.1。

表 5.1 系统开发软硬件配置

	名称	配置
硬件配置	CPU	Intel®Core^{TM} i5-7300HQ CPU @2.50 GHz
	内存	8GB
	显卡	NVIDIA GeForce RTX 1050
	操作系统	Windows10
	硬盘	500GB 固态硬盘
软件配置	编译和开发环境	Pycharm2023.1.4、Qt Creator 11.0.2
	编程语言	Python3.8、C++

多目标跟踪算法的研究主要是在云服务器上进行，使用 Python 作为编程语言，Pytorch 作为人工智能分析模块的框架，所使用软硬件配置见表 5.2。

中国知网 https://www.cnki.net

表 5.2 云服务器软硬件配置

	名称	配置
硬件配置	CPU	Intel®Core^{TM} i7-12700K CPU @3.60 GHz
	内存	32GB
	显卡	NVIDIA GeForce RTX 4090
	操作系统	Windows11
	硬盘	1TB 固态硬盘
软件配置	编译和开发环境	Pycharm2023.1.4、Qt Creator 11.0.2
	编程语言	Python3.8

5.4 系统主要功能实现

账号登录是保证系统安全和用户能否进入系统的关键步骤，系统首先要实现登录功能。



图 5.2 登录界面

中国知网 https://www.cnki.net

用户个人为管理者，登陆后即可使用系统，登录界面如图 5.2 所示。

5.4.1 数据管理页面

数据管理模块为系统提供了集中式的违规事件管理功能，数据管理页面如图 5.3 所示。用户可在此查看已记录的违规行为及相关人员信息，包括唯一的目标跟踪 ID、身份属性以及违规详情等。



图 5.3 数据管理页面

该模块不仅呈现违规事件的概览，还支持对事件信息进行编辑、补充和删除等二次处理操作，以完善事件记录的完整性和准确性。通过集中管理违规信息，系统能为相关部门提供高效的事后分析和取证支持，有助于进一步优化安防策略，提高应对突发事件的能力。该模块的设计注重信息的可追溯性和可维护性，为安防系统的事件管理提供了系统化的解决方案。

5.4.2 监控模块

中国知网 https://www.cnki.net

监控模块构建了一个综合性视频监控系统，整合了实时监控、视频回放、视频截图以及监控关闭四项核心功能。用户登录系统后，默认进入实时监控与回放页面。在该页面，用户可执行实时监控操作，根据设备 ID 选择查看单个或多个摄像头采集的实时视频流。若需回溯特定时间段的监控视频，可切换至视频回放功能。在观看过程中，如发现某一关键画面蕴含重要信息，用户可通过视频截图功能将该画面保存。另外，系统还为用户提供了关闭监控视频流的选项，以节省带宽资源。该模块的设计注重功能的完整性和实用性，为视频监控提供了全方位的支持。

5.4.3 智能分析界面

智能分析模块赋予系统行人检测与跟踪的能力，可对实时监控视频流进行智能分析，实现人员越境预警、人群汇集报警和异常行为报警三项核心功能。该模块基于多目标跟踪算法，具备准确识别和持续跟踪行人目标的能力。

（1）人群汇集报警功能旨在发现异常人群聚集行为，可有效预防违法集会、滞留堵塞等安全隐患，界面如图 5.4 所示。



图 5.4 人员汇集报警

中国知网 https://www.cnki.net

用户可根据实际需求，设置行人群聚集人数阈值参数，规定触发预警所需的最少人数。一旦发生人员聚集且达到预设阈值，系统将实时捕获违规画面并在桌面软件端呈现相关信息，以提醒工作人员及时处理。该功能可广泛应用于人群密集场所的安防监控，如商场、车站、游乐场等，提高了异常事件的发现效率和响应速度。

用户可以通过点击阈值键自由设置该区域内的正常人数，用设置完行汇集阈值，用户才能使用人员聚集预警。超过阈值，系统页面就会显示异常，并且发出预警信息。

（2）人员越境预警功能允许用户设定禁止通行的虚拟边界，如图 5.5 所示。



图 5.5 人员越境警报

一旦发生越界事件，系统将捕捉并显示违规者的画面以及相关信息，以供后续分析处理。越界预警功能模拟现实场景中的禁止入内措施，通过在监控视频画面上设置虚拟边界线，对非法穿越行为实施智能预警。该功能基于行人检测与多目标跟踪算法，将检测框中心点视为行人位置，当中心点穿过边界线时，系统将触发预警并记录违规事件的详细信息，包括违规者人数、发生时间、地点以及截取的违规画面等，并通过桌面软件界面展示、短

中国知网 https://www.cnki.net

信与即时通讯工具推送等多种渠道将预警信息告知用户。

该功能的设计灵活性较强，允许用户根据实际需求设置边界线的位置。通过虚拟边界的设计巧妙地模拟了现实世界的非法入侵检测，并将人工监控的功能智能化、自动化，提高了监控的效率和质量，可广泛应用于重要区域的安防监控。

图中草坪范围内为非法区域，当有人进入该区域，系统就会将越境人员标红，记录人员信息，并发送举报信息。

（3）异常行为报警。该功能旨在及时发现疾速移动的可疑目标、以及碰撞情况的发生，可用于防范各类突发安全事件，如图 5.6 所示。



图 5.6 异常行为检测

用户可设置运动速度阈值，当系统检测到目标运动速度超过该阈值时，将触发预警并记录相关信息。该功能基于视频分析技术，能够精准测量目标在监控画面中的运动速率，并对超速行为作出及时响应。异常奔跑预警可广泛应用于各类安防场景，如禁区监控、反劫持防护等，能够在第一时间发现异常情况，提高安防人员的响应能力。同时，系统还会保留异常事件的画面资料，以便事后分析和取证使用。该功能的设计体现了预警机制的智

中国知网 https://www.cnki.net

能化和高效性。

行人运动速度的计算基于目标跟踪算法，通过分析连续视频帧中目标的位移变化来估算其运动速率。具体来说，以 t-1 时刻目标框中心坐标 (x_1, y_1)为起点，t 时刻目标框中心坐标(x_2, y_2)为终点，目标在两帧间的运动距离 s 可通过欧几里德距离公式计算：

$$s = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2} \tag{5.1}$$

已知视频的帧率，可求得两帧间的时间间隔Δt，目标速度 v 可通过速度公式计算：

$$v = \frac{s}{\Delta t} \tag{5.2}$$

该速度估算方法借助目标跟踪技术，能够精确捕捉目标在时空坐标上的位移变化，从而实现对行人运动速率的实时监测。异常行为报警功能即基于此，当系统检测到某一区域内目标的运动速率超过事先设定的阈值时，或者两个相近目标速度骤降为 0，将自动触发预警并记录相关信息，以防范潜在的安全风险。

5.5 本章小结

本章围绕行人智能监控系统的开发，先行对系统的技术可行性以及功能需求和非功能需求进行了分析和评估。在此基础上，依据工程化的设计方法，完成了系统的总体架构设计、功能模块划分。随后，针对系统的主要功能模块，采用面向对象的开发范式，实现了具体的程序代码。最后，对系统的关键功能点给出了必要的说明，阐明了系统实现的技术路线和算法思路。该系统的开发遵循了严格的软件工程规范，注重理论分析和需求调研的指导作用，并在设计和实现层面体现了高度的模块化和可维护性。

中国知网 https://www.cnki.net

6 总结与展望

6.1 总结

随着智能化技术的不断发展，将计算机视觉技术融入视频监控系统，实现对海量视频数据的自动化分析与理解已成为当前研究的热点领域。行人作为监控场景中最常见的目标类型之一，对其实现高精度的检测、跟踪和行为分析无疑是关键。通过对行人目标的实时检测和跟踪，系统可以进一步对其未来行为进行预测和分析，为监控人员提供有力的决策支持，提升监控区域的管理效率和安全性。

本文主要工作可总结如下：

（1）深入调研和系统梳理了多目标跟踪领域国内外的最新研究进展，全面分析了当前主流方法的技术路线、关键机制以及优缺点。在此基础上，指出了该领域目前所面临的主要挑战与不足，为本文的研究方向奠定了理论基础。

（2）在目标检测阶段，针对多目标跟踪场景下存在很多小目标漏检问题，设计了一种融合注意力机制的对小目标友好的目标检测方法。在基础网络 YOLOX 的基础上，在特征提取阶段新增加了一层更加浅的特征，帮助提取小目标的特征。并在这层特征上融合坐标注意力，帮助网络更好地识别并定位感兴趣的物体。

（3）在多目标跟踪中，针对漏检、身份切换等问题，设计了一种结合重识别以观测为核心的目标找回平滑参数跟踪方法。针对目标重叠时会发生身份切换问题，设计了一种基于目标外貌的 IoU 匹配策略，帮助系统跟踪正确的目标。在匹配阶段，设计了种新的匹配策略，在目标丢失找回时，短时间以观测为中心，长时间以外貌为中心，帮助系统正确找回目标，减少了系统误差。

（4）为验证所提出算法的实际应用价值，本文基于该算法框架，设计并实现了一套面向公共场所的人群智能监控系统。该系统将多目标跟踪技术与人流量统计、行为分析等模块相结合，可实现对目标的精准检测、持续跟踪，并对目标运动轨迹、人群聚集及异常行为等进行智能分析，为公共安全管理提供技术支持。

6.2 展望

基于检测的多目标跟踪是当前计算机视觉领域的热点研究方向，在视频监控、智能驾驶、行为分析等诸多领域具有广泛的应用前景。本文对该领域的关键机制和代表性模型进行了系统梳理，在深入分析现有方法的优缺点基础上，提出了一种改进的多目标跟踪算法并将其应用于视频监控系统。尽管如此，该方法在实际应用中仍存在一些不足：

中国知网 https://www.cnki.net

（1）运行成本高。当前提出的多目标跟踪算法虽然取得了较好的性能表现，但其复杂的模型结构和大量的参数也带来了计算开销的显著增加，这在一定程度上限制了算法在资源受限环境下的实际应用。在实际运用中，系统的计算能力和运行成本往往是重要的考量因素，过于复杂的算法模型将难以真正推而广之。因此，在保持算法精度的前提下，如何进一步简化模型结构、减少参数冗余、降低计算复杂度，将是未来改进的重点方向。

（2）对象太单一。本文所提出的多目标跟踪算法主要针对视频监控场景中的行人目标。然而，在实际应用中，监控对象的类型往往多种多样，除行人外还包括车辆、动物等不同种类的运动目标。然而，现有的公开数据集在目标类型的覆盖范围上存在明显局限性，大多数多目标跟踪数据集仅提供了行人目标的标注，缺乏对其他目标类型的支持，这在很大程度上制约了多类别多目标跟踪算法的研究和发展。因此，如何扩展算法，完善多种类多目标跟踪数据集，以适应更加广泛的目标类型，将是未来研究的重要方向。

（3）跨摄像头目标跟踪。本文提出的多目标跟踪算法目前仅适用于单个摄像机视角的情况，而在实际应用场景中，由于单一摄像机的有限视野范围，难以对目标实现长时间、长距离的连续跟踪。不同摄像头之间，由于光线、视角等问题，同一目标在不同摄像头中，外貌特征可能不同，并且卡尔曼滤波器难以实现在不同摄像头中的位置估计，跨摄像头目标跟踪难以实现。因此，如何实现跨多个摄像机视野的目标跟踪是急需解决的重要问题。

中国知网 https://www.cnki.net

参考文献

[1] 席广亮, 甄峰, 傅行行, 等. 2019 年智慧城市研究与实践热点回眸[J]. 科技导报, 2020,38(03):157-163.

[2] Voulodimos A, Doulamis N, Doulamis A, et al. Deep learning for computer vision: A brief review[J]. Computational intelligence and neuroscience, 2018,2018(1):7068349.

[3] Kalake L, Wan W, Hou L. Analysis based on recent deep learning approaches applied in real-time multi-object tracking: a review[J]. IEEE Access, 2021,9:32650-32671.

[4] 伍瀚, 聂佳浩, 张照娓, 等. 基于深度学习的视觉多目标跟踪研究综述[J]. 计算机科学, 2023,50(04):77-87.

[5] Luo W, Xing J, Milan A, et al. Multiple object tracking: A literature review[J]. Artificial intelligence, 2021,293:103448.

[6] 陈之射, 阳威. 计算机视觉及网络领域中人工智能的运用[J]. 华东科技, 2022(01):108-110.

[7] Poppe R. A survey on vision-based human action recognition[J]. Image and vision computing, 2010,28(6):976-990.

[8] Zhao Y, Xiong Y, Wang L, et al. Temporal action detection with structured segment networks[C], 2017,2914-2923.

[9] LeCun Y, Bengio Y, Hinton G. Deep learning[J]. nature, 2015,521(7553):436-444.

[10] Girshick R, Donahue J, Darrell T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation: Proceedings of the IEEE conference on computer vision and pattern recognition[C], 201,580-587.

[11] Girshick R. Fast r-cnn: Proceedings of the IEEE international conference on computer vision[C], 2016,39(6): 1137-1149.,.

[12] Ren S, He K, Girshick R, et al. Faster r-cnn: Towards real-time object detection with region proposal networks[J]. Advances in neural information processing systems, 2015,28.

中国知网 https://www.cnki.net

[13] Dai J, Li Y, He K, et al. R-fcn: Object detection via region-based fully convolutional networks[J]. Advances in neural information processing systems, 2016,29.

[14] He K, Gkioxari G, Dollár P, et al. Mask r-cnn: Proceedings of the IEEE international conference on computer vision[C], 2017,2961-2969.

[15] Li B, Yan J, Wu W, et al. High performance visual tracking with siamese region proposal network: Proceedings of the IEEE conference on computer vision and pattern recognition[C], 2018,8971-8980.

[16] Li B, Wu W, Wang Q, et al. Siamrpn++: Evolution of siamese visual tracking with very deep networks: Proceedings of the IEEE/CVF conference on computer vision and pattern recognition[C], 2019,4282-4291.

[17] Cai Z, Vasconcelos N. Cascade r-cnn: Delving into high quality object detection: Proceedings of the IEEE conference on computer vision and pattern recognition[C], 2018,6154-6162.

[18] Lin T, Goyal P, Girshick R, et al. Focal loss for dense object detection: Proceedings of the IEEE international conference on computer vision[C], 2017,2980-2988.

[19] Lin T, Dollár P, Girshick R, et al. Feature pyramid networks for object detection: Proceedings of the IEEE conference on computer vision and pattern recognition[C], 2017,2117-2125.

[20] Redmon J, Divvala S, Girshick R, et al. You only look once: Unified, real-time object detection: Proceedings of the IEEE conference on computer vision and pattern recognition[C], 2016.

[21] Law H, Deng J. Cornernet: Detecting objects as paired keypoints: Proceedings of the European conference on computer vision (ECCV)[C], 2018,734-750.

[22] Yang C, Duraiswami R, Davis L. Fast multiple object tracking via a hierarchical particle filter: Tenth IEEE International Conference on Computer Vision (ICCV'05) Volume 1[C], IEEE, 2005, 1: 212-219.

[23] Okuma K, Taleghani A, De Freitas N, et al. A boosted particle filter: Multitarget detection and tracking[C]//Computer Vision-ECCV 2004: 8th European Conference on Computer Vision, Prague, Czech Republic, May 11-14, 2004. Proceedings, Part I 8. Springer Berlin Heidelberg, 2004: 28-39.

中国知网 https://www.cnki.net

[24] Kalman R E. A new approach to linear filtering and prediction problems[J]. 1960.

[25] Xiang Y, Alahi A, Savarese S. Learning to track: Online multi-object tracking by decision making[C]//Proceedings of the IEEE international conference on computer vision. 2015: 4705-4713.

[26] Danelljan M, Hager G, Shahbaz Khan F, et al. Convolutional features for correlation filter based visual tracking: Proceedings of the IEEE international conference on computer vision workshops[C], 2015,58-66.

[27] 柴文光, 陈香远. 单目视觉多目标跟踪方法的数据关联策略综述[J]. 现代计算机, 2021,27(23):112-118.

[28] Redmon J, Farhadi A. YOLO9000: better, faster, stronger: Proceedings of the IEEE conference on computer vision and pattern recognition[C], 2017,7263-7271.

[29] Farhadi A, Redmon J. Yolov3: An incremental improvement[C]//Computer vision and pattern recognition. Berlin/Heidelberg, Germany: Springer, 2018, 1804: 1-6.

[30] Li C, Li L, Jiang H, et al. YOLOv6: A single-stage object detection framework for industrial applications[J]. arXiv preprint arXiv:2209.02976, 2022.

[31] Wang C, Bochkovskiy A, Liao H M. YOLOv7: Trainable bag-of-freebies sets new state-of-the-art for real-time object detectors: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition[C], 2023,7464-7475.

[32] Ge Z, Liu S, Wang F, et al. Yolox: Exceeding yolo series in 2021[J]. arXiv preprint arXiv:2107.08430, 2021.

[33] Bochkovskiy A, Wang C, Liao H M. Yolov4: Optimal speed and accuracy of object detection[J]. arXiv preprint arXiv:2004.10934, 2020.

[34] Liu W, Anguelov D, Erhan D, et al. Ssd: Single shot multibox detector: Computer Vision–ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11–14, 2016, Proceedings, Part I 14[C], 2016. Springer.

[35] Bewley A, Ge Z, Ott L, et al. Simple online and realtime tracking: 2016 IEEE international conference on image processing (ICIP)[C], 2016,3464-3468.

[36] Wojke N, Bewley A, Paulus D. Simple online and realtime tracking with a deep association metric: 2017 IEEE international conference on image processing (ICIP)[C], 2017. IEEE.

中国知网 https://www.cnki.net

[37] Zhang Y, Sun P, Jiang Y, et al. Bytetrack: Multi-object tracking by associating every detection box: European Conference on Computer Vision[C], 2022:1-21. Springer.

[38] Du Y, Zhao Z, Song Y, et al. Strongsort: Make deepsort great again[J]. IEEE Transactions on Multimedia, 2023, 25: 8725-8737.

[39] Cao J, Pang J, Weng X, et al. Observation-centric sort: Rethinking sort for robust multi-object tracking: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition[C], 2023:9686-9696.

[40] Aharon N, Orfaig R, Bobrovsky B. BoT-SORT: Robust associations multi-pedestrian tracking[J]. arXiv preprint arXiv:2206.14651, 2022.

[41] Shim K, Ko K, Hwang J, et al. Adaptrack: Adaptive Thresholding-Based Matching for Multi-Object Tracking: 2024 IEEE International Conference on Image Processing (ICIP)[C], 2024:2222-2228. IEEE.

[42] Stanojevic V D, Todorovic B T. BoostTrack: boosting the similarity measure and detection confidence for improved multiple object tracking[J]. Machine Vision and Applications, 2024,35(3):1-15.

[43] Wang Z, Zheng L, Liu Y, et al. Towards real-time multi-object tracking: European Conference on Computer Vision[C], 2020:107-122. Springer.

[44] Zhang Y, Wang C, Wang X, et al. Fairmot: On the fairness of detection and re-identification in multiple object tracking[J]. International Journal of Computer Vision, 2021,129:3069-3087.

[45] Liang C, Zhang Z, Zhou X, et al. Rethinking the competition between detection and reid in multiobject tracking[J]. IEEE Transactions on Image Processing, 2022,31:3182-3196.

[46] Liang C, Zhang Z, Zhou X, et al. One more check: making “fake background” be tracked again: Proceedings of the AAAI Conference on Artificial Intelligence[C], 2022, 36(2): 1546-1554.

[47] Zhang J, Zhou S, Chang X, et al. Multiple object tracking by flowing and fusing[J]. arXiv preprint arXiv:2001.11180, 2020.

[48] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017,30.

中国知网 https://www.cnki.net

[49] Sun P, Cao J, Jiang Y, et al. Transtrack: Multiple object tracking with transformer[J]. arXiv preprint arXiv:2012.15460, 2020.

[50] Meinhardt T, Kirillov A, Leal-Taixe L, et al. Trackformer: Multi-object tracking with transformers: Proceedings of the IEEE/CVF conference on computer vision and pattern recognition[C], 2022:8844-8854.

[51] Xu Y, Ban Y, Delorme G, et al. TransCenter: Transformers with dense representations for multiple-object tracking[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022,45(6):7820-7835.

[52] Zeng F, Dong B, Zhang Y, et al. Motr: End-to-end multiple-object tracking with transformer: European Conference on Computer Vision[C], 2022:659-675. Springer.

[53] Carion N, Massa F, Synnaeve G, et al. End-to-end object detection with transformers: European conference on computer vision[C], 2020:213-229. Springer.

[54] Dendorfer P, Rezatofighi H, Milan A, et al. Mot20: A benchmark for multi object tracking in crowded scenes[J]. arXiv preprint arXiv:2003.09003, 2020.

[55] Shao S, Zhao Z, Li B, et al. Crowdhuman: A benchmark for detecting human in a crowd[J]. arXiv preprint arXiv:1805.00123, 2018.

[56] Lin T, Dollár P, Girshick R, et al. Feature pyramid networks for object detection: Proceedings of the IEEE conference on computer vision and pattern recognition[C], 2017:2117-2125.

[57] Hou Q, Zhou D, Feng J. Coordinate attention for efficient mobile network design: Proceedings of the IEEE/CVF conference on computer vision and pattern recognition[C], 2021:13723-13722.

[58] 陈超, 齐峰. 卷积神经网络的发展及其在计算机视觉领域中的应用综述[J]. 计算机科学, 2019,46(03):63-73.

[59] Lin T, Goyal P, Girshick R, et al. Focal loss for dense object detection: Proceedings of the IEEE international conference on computer vision[C], 2017:2980-2988.

[60] Tian Z, Shen C, Chen H, et al. FCOS: A simple and strong anchor-free object detector[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2020,44(4):1922-1933.

[61] Zhang H, Wu C, Zhang Z, et al. Resnest: Split-attention networks: Proceedings of the

中国知网 https://www.cnki.net

IEEE/CVF conference on computer vision and pattern recognition[C], 2022:2736-2746.

[62] He L, Liao X, Liu W, et al. Fastreid: A pytorch toolbox for general instance re-identification: Proceedings of the 31st ACM International Conference on Multimedia[C], 2023:9664-9667.

[63] Luo H, Gu Y, Liao X, et al. Bag of tricks and a strong baseline for deep person re-identification: Proceedings of the IEEE/CVF conference on computer vision and pattern recognition workshops[C], 2019.

[64] Liang C, Zhang Z, Zhou X, et al. Rethinking the competition between detection and reid in multiobject tracking[J]. IEEE Transactions on Image Processing, 2022,31:3182-3196.

中国知网 https://www.cnki.net