江南大学

硕 士 学 位 论 文

题　　目：基于深度学习的小目标检测算法研究

英文并列题目：Research on Small Object Detection Algorithm Based on Deep Learning

研　究　生：李木子

专　　业：软件工程

研 究 方 向：智能软件技术

导　　师：蒋亦樟

指导小组成员：

学位授予日期：2024 年 12 月

答辩委员会主席：邓赵红

江 南 大 学

地址：无锡市蠡湖大道 1800 号

二〇二四年十二月

中国知网 https://www.cnki.net

摘 要

随着人工智能技术的不断发展和进步，目标检测已经成为当前热门的机器视觉任务之一，其主要目的就是准确检测出各种目标所在区域以及对应的分类。目标检测作为部分计算机视觉应用技术的基础，在各行各业发挥着重要作用，如智能监测、灾难救援、农林植保、行人检测等。小目标检测作为目标检测任务中的重难点问题，近年来受到人工智能和计算机视觉领域的广泛关注，成为当下的一个重要研究课题。然而，现如今的小目标检测算法中标签分配仍然存在样本分配不平衡、小目标在高级特征图中有效分辨率较少、小目标检测在不同层损失权重不平衡等问题。针对上述问题，本文对小目标检测模型做了如下改进：

（1）针对基于 IoU 阈值的方法中对位置偏差非常敏感的问题，本研究在 RetinaNet 中引入有效感受野的概念，根据感受野有效性服从高斯分配的特点，对特征金字塔图像的特征点构建二维高斯分布建模，有利于直接获得样本分配度量，增强检测算法对有效小目标特征提取的准确性。对标签分配存在样本分配不平衡的问题，本研究采用有效感受野与真实值（Ground Truth，GT）区域之间的高斯距离作为度量标准，减少了离散小目标检测的误差，提高了小目标检测的准确性。针对小目标检测正负样本选取不平衡的问题，本研究通过计算特征点有效距离进行样本排序，引入分配特征掩码以减少低质量样本，提高小目标样本选取有效性，增强小目标检测性能。所提出算法在 VisDrone2019 和 TinyPerson 数据集上进行了实验，结果表明本文模型在平均精度跟检测速度评价指标数值上具备一定的优越性。

（2）针对小目标在低分辨率特征图中有效分辨率较少的问题，本研究在 RetinaNet 中重用 CNN 不同层的多尺度特征图，添加额外的金字塔级别来构建特征金字塔，增强特征金字塔对小目标有效特征的提取能力。针对高分辨率特征图中小目标分布稀疏导致的计算冗余问题，本研究提出一种基于级联查询的高分辨率稀疏小目标检测算法，通过低分辨率特征图的位置信息指导高分辨率特征图的小目标检测，减少在高分辨率特征图中小目标检测的计算冗余，增加小目标特征在特征融合过程中的权重，加快小目标检测结果的计算。对小目标检测在不同层损失权重不平衡的问题，本研究采用基于 FocalLoss 的查询头，平衡不同层计算正负样本损失的权重，减少低质量样本的数量。所提出算法在 VisDrone2019 和 TinyPerson 数据集上进行了实验，结果表明本模型相比较于其他基于特征金字塔的模型取得了优异的性能

关键字：小目标检测；RetinaNet；特征金字塔；多层级特征查询机制

中国知网 https://www.cnki.net

Abstract

With the continuous development of the artificial intelligence technology, object detection has become one of the current popular machine vision tasks. Its main purpose is to accurately detect various target areas and make corresponding classification. As the basis of multiple computer vision application technologies, object detection plays an important role in all walks of life, such as intelligent monitoring, disaster rescue, agriculture and forestry protection, pedestrian detection and so on. As an important and difficult problem in object detection tasks, small object detection has been widely concerned in the field of artificial intelligence and computer vision in recent years, and has become an important research topic. However, there are still some problems in label allocation of small object detection algorithms, such as unbalanced sample allocation, less effective resolution of small targets in high-level feature maps, and unbalanced loss weight of small object detection in different layers. To solve the above problems, this paper makes the following improvements to the small object detection model.

(1) Firstly, the method based on the IoU threshold is very sensitive to position deviation. Therefore, the concept of effective receptive fields is introduced into RetinaNet. And two-dimensional Gaussian distribution models is built for feature points of the feature pyramid image according to the fact that the receptive field effectiveness follows the characteristics of Gaussian distribution. It is conducive to directly obtaining sample allocation measures and enhancing the accuracy of the detection algorithm for effective feature extraction of small targets. Secondly, the sample distribution is unbalanced in the label allocation. To solve the problem, the Gaussian distance between the effective field of perception and the Ground Truth (GT) region is used as the measurement standard in this study. It can reduce the detection error of discrete small target and improve the accuracy of small object detection. Thirdly, the selection of positive and negative samples for small object detection is unbalanced. To solve the problem, the samples are sorted by calculating the effective distance of feature points, and the distributed feature mask is introduced to reduce low-quality samples, improve the detection effectiveness of small target samples, and enhance the detection performance of small targets. The proposed algorithm is tested on data sets of VisDrone2019 and TinyPerson. The results shows that the proposed model has certain advantages in the evaluation indicators of average accuracy and detection velocity.

(2) Firstly, small targets have less effective resolution in low-resolution feature maps. To solve the problem, multi-scale feature maps of different layers of CNN are reused in RetinaNet, and additional pyramid levels are added to build feature pyramids, to enhance the feature pyramid's capabilities to extract effective features of small targets. Secondly, there is computational redundancy, which is caused by sparse distribution of small and medium-sized targets in high-resolution feature maps. A high resolution sparse small object detection algorithm is proposed on the basis of the hierachical query. The location information of low resolution feature maps is used to guide the small object detection in high-resolution feature maps, to reduce the computational redundancy of small and medium-sized object detection in high-resolution feature maps, increase the weight of small target features in the process of

中国知网 https://www.cnki.net

feature fusion, and speed up the calculation of small object detection results. Thirdly, the loss weight of the small object detection is unbalanced in different layers. The FocalLos-based query header is used to balance the weights of positive and negative sample losses in different layers to reduce the number of low-quality samples. The proposed algorithm is tested on datasets of VisDrone2019 and TinyPerson. The results shows that the proposed model achieves excellent performance, compared with other feature pyramid-based models.

Keywords: Small object detection; RetinaNet: Feature Pyramid; Multi level feature query mechanism

中国知网 https://www.cnki.net

目　录

第一章 绪论.....1
1.1 研究背景及意义.....1
1.2 国内外研究现状.....3
1.2.1 传统目标检测研究现状.....3
1.2.2 基于深度学习的目标检测研究现状.....4
1.2.3 小目标检测研究现状.....5
1.2.4 研究难点.....7
1.3 主要研究内容.....8
第二章 基础理论与方法.....10
2.1 基于深度学习的目标检测算法.....10
2.1.1 双阶段算法.....10
2.1.2 单阶段算法.....12
2.1.3 有锚框算法.....13
2.1.4 无锚框算法.....14
2.2 特征金字塔.....15
2.3 目标检测数据集与评价指标.....16
2.4 本章小结.....17
第三章 基于高斯有效距离和样本分层分配的小目标检测算法.....18
3.1 引言.....18
3.2 基于无锚框的目标检测技术介绍.....18
3.2.1 基于无锚框的模型.....18
3.2.2 正负样本选择.....19
3.2.3 标签分配策略.....20
3.3 EGDA-Retina Net 模型概述.....20
3.4 方法设计.....21
3.4.1 高斯距离样本分配度量.....22
3.4.2 高斯距离正负样本分层分配策略.....24
3.5 实验及结果分析.....24
3.5.1 实验设置.....25
3.5.2 目标检测深度学习框架.....25
3.5.3 本文模型与经典模型精度对比结果分析.....26
3.5.4 本文模型与经典模型实时性对比结果分析.....27
3.5.5 总体可视化结果分析.....27
3.5.6 与经典模型可视化对比结果分析.....29

中国知网 https://www.cnki.net

3.6 本章小结.....30
第四章 基于级联查询的高分辨率稀疏小目标检测算法.....31
4.1 引言.....31
4.2 基于单阶段目标检测介绍.....31
4.2.1 RetinaNet 概述.....31
4.2.2 多尺度模型.....33
4.2.3 查询机制.....34
4.3 QS-RetinaNet 模型概述.....36
4.4 方法设计.....37
4.4.1 特征金字塔的改进.....37
4.4.2 级联查询加速计算.....38
4.4.3 改进后的 QS-RetinaNet 模型训练.....39
4.5 实验及结果分析.....40
4.5.1 实验设置.....40
4.5.2 本文模型与经典模型对比结果分析.....41
4.5.3 消融实验分析.....41
4.5.4 可视化结果分析.....42
4.6 本章小结.....43
第五章 结论与展望.....44
参考文献.....46

中国知网 https://www.cnki.net

第一章 绪论

1.1 研究背景及意义

随着人工智能技术的不断发展和进步，目标检测已经成为当前热门的机器视觉任务之一，其主要目的就是准确检测出各种目标所在区域以及对应的分类。目标检测作为部分计算机视觉应用技术的基础，在各行各业发挥着重要作用，如智能监测、灾难救援、农林植保、行人检测等[1]。小目标检测作为目标检测任务中的重难点问题，已经逐渐成为机器视觉领域的前沿方向。深度学习模型对于大规模图像集中检测小目标具有更高的效率与精度，可作为其它复杂视觉任务的基础，这使得小目标检测技术在众多领域中展现出了巨大的应用潜力和实际价值。

作为机器视觉领域的代表，目标检测算法可以根据目标物体的尺寸分为大、中、小三类。本文主要研究的即是小目标物体的目标检测，但由于小目标的定义很广泛，目前还没有一个具体的标准，所以本文对小目标的定义主要集中在两个方面：第一个是相对尺度的小目标定义标准，例如从比例出发，比较目标与整体图像的整体比例；同时也可以从从边界框出发，比较目标物体边界框以及整体图像的边界框来确定小目标标准。学者 Chen[2]认为同一类别中所有目标实例的相对面积，即边界框面积与图像面积之比的中位数在 0.08%~0.58%之间。在 Chen 提出的观点中，对小目标的定义范围缩小得更加具体，可以直接用数值的大小来定义一个物体是否属于小目标，但这类定义方法也存在很大的缺陷，比如在数据预处理中，可能无法统一，以及模型结构的改变会使得原本分类为小目标的物体变成分类为中目标，使用此类定义方法后，对不同大小尺度的目标检测性能也很难得到统一的评估结果。第二个小目标定义方法则为绝对尺度小目标定义，此方法的原理是利用了绝对像素大小的思想，最典型的例子则是目前前沿的目标检测数据集 MS COCO 集，统一将小于 32 像素×32 像素归纳为小目标个体。如图 1-1 所示，既是一个多分类的目标检测实例，图中的黄框和红框分别代表着检测出来的是行人或者模特，旁边的数字则代表着检测结果的置信度。

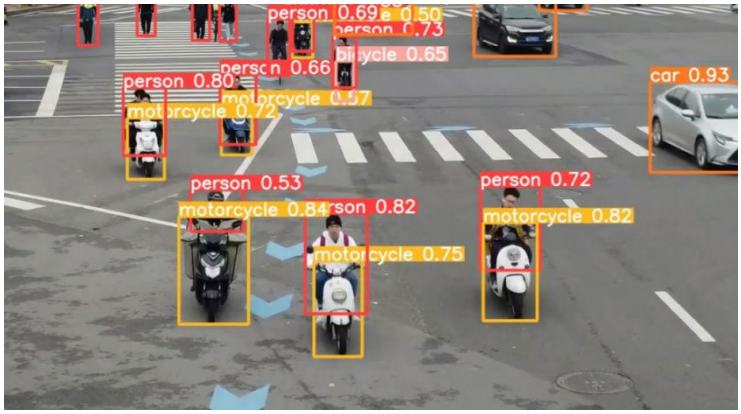


图 1-1 目标检测结果示例图

小目标检测当前的发展主要由两个方面所驱动：传统的方法和基于深度学习的方法。其中通过使用深度卷积神经网络（CNN）自动学习图像中的特征表示，并结合区

中国知网 https://www.cnki.net

域提取技术和分类器进行目标检测，是目前机器视觉中绝大部分模型选择的操作方法。其中，一些代表性的方法包括 R-CNN[3]、Fast R-CNN[4]、Faster R-CNN[5]、YOLO[6][7][8]系列和 SSD[9]。这些方法在大规模数据集上进行训练，在目标检测的性能和效率方面取得了巨大的提升。小目标检测结果示例如图 1-2 所示，可以检测出多个特征区域的目标。



图 1-2 小目标检测结果示例图

R-CNN 是首个将深度学习引入目标检测的方法。它将图像划分为多个候选区域，通过 CNN 提取每个区域的特征，再由分类器进行目标检测。但因为需要对每个区域进行独立的前向传播，导致模型速度较慢。其后，Fast R-CNN 改进了 R-CNN 的速度问题，将整个图像作为输入，以 CNN 为核心构建特征提取主干网络，然后通过 RoI 池化层从特征图中提取感兴趣区域的特征，并使用分类器和回归器进行目标检测。到如今，Faster R-CNN 在原来的基础上进一步提高了模型检测的速度，它引入了一个额外的区域候选网络（RPN）用于生成候选目标边界框。RPN 先使用卷积神经网络生成候选框，然后通过非极大值抑制筛选出最终的候选框，最后通过 RoI 池化层和分类器进行目标检测。

YOLO 系列和 SSD 是两种实时目标检测方法。YOLO 系列使用回归算法作为提高检测模型性能的思路来应用在目标检测问题中，该算法会将每一个图像划为网格，并在网格中将图像中的目标边框以及对应的类别和概率直接标注出来，直接从图像中预测目标边界框和类别概率。SSD 使用多个尺度的卷积滑动窗口来检测目标，从不同层次的特征图中提取目标信息。这些基于深度学习的目标检测方法可以在大规模数据集上进行了训练，能够有效地检测各种尺寸、姿态和遮挡的目标，并取得了显著的性能提升。

现如今，目标检测任务仍然面临一些挑战，尤其是在小目标检测任务方面。小目标因具有较小的尺寸，易受噪声、背景和其他目标的干扰，在现有的通用目标检测算法中表现不佳。研究者们正在不断探索新的方法和技术来改善小目标检测模型的性能，如使用注意力机制、特征增强和联合训练等。

小目标检测因为需要在稀少的像素中提取特征，在计算机视觉领域中一直是一个难以破解的难题。其中，由于微小目标（小于 AI-TOD[10]中定义的 16×16 像素）缺乏识别特征，微小目标检测是最具挑战性的任务之一。目前在目标检测中广泛使用的通

中国知网 https://www.cnki.net

用目标检测方法通常无法在小目标检测任务上提供令人满意的结果，针对小目标的特点在此基础上进行改进是当前小目标研究领域的主要途径之一。具体例子如图 1-3 所示，当正样本区域位于图像边角，且负样本区域占据特征图的绝大部分时，这种不平衡并未使得模型倾向于预测负样本。



图 1-3 尺度样本分配示例图

通用目标检测可以分为两种主要的方法：基于锚框和无锚框。基于锚框的方法是较早提出的目标检测方法之一，它通过在图像上放置一系列预定义尺寸和比例的锚框来进行目标检测。锚框是一种矩形框，代表了图像中可能存在目标的位置区域。通常，锚框会以多种尺度和比例进行设置，以适应不同大小和形状的目标。该方法首先使用一个候选框生成器在图像上以滑动窗口的方式生成一系列候选框，并计算每个候选框与锚框的相似度。然后，使用一个分类器和回归器对候选框进行分类和位置调整，得到最终的目标检测结果。然而，基于锚框的方法存在一些问题。首先，锚框的设置需要经验和人工选择，对于不同的数据集和场景需要进行相应的调整，依赖先验知识和泛化能力。其次，由于锚框的数量较多，较大的计算量会影响算法的速度。此外，对于存在目标重叠和目标尺度变化的情况，基于锚框的方法可能会产生较多的误检和漏检。现如今，基于锚框的方法因为其技术成熟，收敛快，精度高，可操作性强等特点，仍然被使用于小目标检测算法领域。

小目标检测作为一个技术难点，在推动深度学习和计算机视觉发展等方面起到了关键作用。同时，它在安全监控、医疗、环境保护、自动驾驶等多个领域的实际应用，极大地提高了相关领域的技术水平和服务能力。随着技术的进一步发展与运用，小目标检测的应用范围和影响力预计将进一步扩大。

1.2 国内外研究现状

小目标检测作为目标检测问题中的重难点，受到了全球众多研究机构和学者的关注。国内外在这一领域的研究现状呈现出一些共同特点，同时也有各自的研究重点和特色。

1.2.1 传统目标检测研究现状

目标检测长期以来一直是研究和应用的热点。尽管深度学习的兴起极大地推动了

中国知网 https://www.cnki.net

目标检测技术的发展，但分析传统目标检测方法的研究现状仍然非常重要。

传统目标检测方法步骤较为冗余，将需要检测的图像输入网络后，传统目标检测方法还要经过以下三个步骤，分别是生成候选区域、提取特征、分类目标。生成候选区域一般采用选择性搜索和滑动窗口的方法，特征提取常采用方向梯度直方图（Histogram Of Oriented Gradients，HOG）[11]、尺度不变特征变换（Scale-Invariant Feature Transform，SIFT）[12]、加速稳健特征（Speeded Up Robust Features，SURF[13]）等特征描述符。

2001 年，V-J 人脸检测器特征提取部分使用了 Haar 算法，分类器使用了 AdaBoost 算法[14]，两者结合实现了人脸的实时检测。2005 年，Dalal 等特征提取使用 HOG 算法，分类器使用 SVM 算法[15]，两者结合实现了行人检测。2010 年出现的可变形部件模型[16]使得传统目标检测登上了新的高度。该模型基于组件进行检测，对多个子部件进行预测得到不同的特征图，然后进行整合形成融合特征，并对融合特征进行分类、回归获得最终检测结果。如上所述的方法都是传统目标检测算法，不适合大型数据集或者更加精细的小目标检测，相较于当前的目标检测算法存在较大的短板。

最初的目标检测研究方向集中在基础图像处理技术领域，如边缘检测、轮廓提取等，使用简单的模板匹配和几何形状识别技术来检测图像中的目标。随着对各种特征描述符的进一步研究，研究者开始关注如何从图像中提取有效的特征，如纹理、颜色和形状等。现如今，目标检测算法引入统计学习方法，从学习较为简单的特征到现在对目标的深度学习，达成了从传统的目标检测算法到现在的基于深度学习的目标检测算法的演变。研究者开始将目光投到更复杂和多变的环境中，优化算法以处理更大的图像数据库和更复杂的目标类型为目标。

1.2.2 基于深度学习的目标检测研究现状

基于深度学习的目标检测算法大致可分为双阶段和单阶段方法，也可以分为有锚框和无锚框算法。最初，深度学习在计算机视觉中的应用相对有限，主要集中在图像分类任务上。后来，研究者开始尝试将深度学习技术应用于更复杂的视觉任务，包括目标检测、姿态估计、图像分割等。2014 年，由学者 Girshick 首次提出将区域卷积神经网络（R-CNN），运用于目标检测算法网络，R-CNN 先通过选择性搜索提取候选区域，然后对每个区域使用 CNN 提取特征，最后通过 SVM 进行分类。2015 年，为解决 R-CNN 计算效率较低的问题，Girshick 等进一步提出了 Fast R-CNN[4]，该模型引入 ROI Pooling 来共享计算，同时在一个统一的网络中完成特征提取和分类。同年，Ren 等提出了 Faster R-CNN，其中引入了区域提议网络（RPN），使得候选区域的提取也能通过深度学习实现，从而进一步提高了目标检测的速度和精度。2016 年，Redmon 等提出了 YOLO 算法，一个具有里程碑意义的算法。它将目标检测视为一个回归问题，能够在单次前向传播中同时预测多个边界框和类别概率，大幅提高了检测速度。同年，Liu 等提出了 SSD，该算法通过在多个尺度上进行目标检测，改进了对不同大小目标的检测能力。

中国知网 https://www.cnki.net

随后的几年中，YOLO 和 SSD 等算法经历了多次迭代和优化，如 YOLOv5、YOLOv8、SSD 的多个改进版本等，其准确性、速度和鲁棒性得到提高。此外，新的算法和框架不断涌现，例如 CornerNet[17]、CenterNet[18]等，这些算法尝试从不同角度解决目标检测中的挑战。

基于深度学习的目标检测算法的发展历程反映了从初步探索到成熟应用的过程。随着深度学习技术的不断进步，目标检测算法在速度、准确性和适应性方面都取得了显著的提升。这一领域仍然非常活跃，持续有新的方法和技术被提出，以应对更复杂的应用需求和挑战。每种方法都有其独特的优势和应用场景。基于区域的方法在精度上通常较优，但计算成本较高；单阶段方法在速度上有优势，适合实时检测任务；有锚框方法和无锚框方法分别提供了不同的策略来处理目标的大小和形状差异。深度学习在目标检测领域的发展不断推动这些方法的创新和优化。

1.2.3 小目标检测研究现状

小目标具有在图中所占的比例小，像素少，难以区分背景与目标等特征，相对于大目标更难以检测，这导致小目标物体检测成为了前沿的研究方向。经典的目标检测算法如 YOLO 等模型对于公共数据集的检测效果良好，是因为公共数据集中的目标多数为大尺度或者中尺度数据集，但对于小目标物体来说，经典的目标检测算法所检测出来的精度远远不够。其主要原因是小目标物体图像中占据的像素较少、内在的特征过少、特征不明显且容易受到环境噪声的影响等。另一层原因是网络模型在训练时会漏检测很多小目标语义特征，造成正负样本不平衡的现象，从而影响小目标物体的检测精度。现如今对于小目标检测的改进主要从以下几个方向进行：多尺度特征融合、上下文信息利用、注意力机制、数据增强和模型优化等。

多尺度特征融合是利用回归检测等方法将不同尺度的信息集合于一体，得到更加完整的特征图。如果仅使用单一尺度进行检测小目标，会错失很多在不同尺度下的小目标特征和语义细节信息。为了获得更完整的信息特征，一般使用基于多尺度的神经网络算法模型来对小目标进行检测，但此方法相较于单一尺度来说参数量以及计算复杂度会增加，平衡好精度以及复杂度也是该领域重要方向。基于多尺度的神经网络算法模型结构有很多种，可以通过引入一个轻量级的特征融合模块来实现多尺度融合。Li 等提出 FSSD[19]算法就应用了这一思想，通过在 SSD 基础上增加轻量级多尺度特征融合模块，实现对不同尺度特征层的检测与融合。Liu 等人在 2018 年提出 RFB Net[20]算法模型，该模型的核心思想也是引入轻量级的 RFB 模块，利用 RFB 中的多分支卷积结合更多不一样的卷积核以及膨胀卷积，实现多尺度特征的融合，增加算法检测的精度。Zhang 等人在 2018 年提出 RefineDet 算法[21]，该算法一定程度上解决了无法同时兼顾检测精度和算法检测速度的问题。首先，该算法使用 ARM 模块来模拟两阶段目标检测算法中的候选框，获取并移除过多负样本锚框。然后，使用 ODM 模块进行更加精细的操作，将 ARM 检测出来的锚点作为本模块的输入，将其回归到精确的目标位置中。Lin 等人提 FPN 结构[22]，该结构的特点是通过融合相邻的特征层，得到语义更加丰富的特

中国知网 https://www.cnki.net

征图，因为浅层特征拥有更多的边缘细节，所以让更多的浅层特征参与到检测小目标个体中，从而提高检测精度。但是 FPN 算法模型也存在一定的短板，比如其连接方式以及特征传递路径会造成一部分的特征丢失，为了解决此类问题，Liu 等人在 2018 年提出了双向特征融合路径的 PANet 模型[23]。该模型使用两个不同方向路径的聚合模块，分别是自上而下的 PA 以及自下而上的 PAM，缩短了特征的传递路径，从而提高模型检测精度。Ghaisi 等提出了基于神经搜索架构 NAS-FPN[24]，使用神经网络自我学习寻找到最佳的双向融合结构。Tan 等提出了 EfficientDet 算法[25]，使用一种基于自适应加权的双向特征融合 Bi-FPN 来训练学习得到各层特征层的最佳权重，实现具有针对性的特征融合方式，提高各类难检测目标的检测精度。

上下文信息指的是目标物体对应的像素与这一块区域或者周围像素存在的联系，可以通过上下文信息推导出目标物体的相对位置、类型、大小等重要信息，挖掘上下文信息的关联性是小目标检测算法模型中重要的方法。Fu 等提出 DSSD[26]算法，采用 ResNet101 作为骨干网络，并添加反卷积层和反馈连接，提高特征提取能力，进而提高小目标检测精度。Huang 等提出一种基于级联思想的 DenseNet[27]算法，通过前馈的方式将当前特征层与其他特征层进行连接，每一层的输出等于之前所有层的输出，减少卷积网络下采样中感受野增大造成的信息丢失。DenseNet 算法在不增加额外参数的情况下丰富了特征信息，提高了中小型目标的检测精度。Xu 等在 Faster R-CNN 基础上引入知识图谱提出 Reasoning R-CNN[28]，设计一个类别级别的知识图谱对目标存在的关系和属性进行自适应编码，共享特征类别中的基本特征，利用先验的上下文信息解决小目标检测问题。Lim 等提出 FA-SSD[29]算法，提取深层网络小目标周围像素的附加特征，将其作为目标的上下文信息连接多尺度特征，并使用注意力机制减少背景阴影信息，提高小目标检测精度。Shen 等使用一种特征聚合模块（Feature Aggregation Module，FAM[30]）聚合目标的上下文信息，为室内小尺度人群检测提供额外的细节信息。Fu 等提出 IR R-CNN[31][32]算法，对隐含的区域间关系进行编码，构建关注于初始区域特征建模内部稀疏语义的语义模块和关注于对象位置和形状信息编码的空间布局模块，集成对象之间的稀疏关系和上下文信息，提高小目标检测精度。

数据增强是目前机器视觉中的一项重要技术，主要方法是通过平移、旋转、镜像、加噪等操作来增加训练集中数据的多样性和丰富性，使得模型在训练过程中拥有更多可参考的目标特征，同时这种方法也可以在直接提高目标检测的效果的同时兼顾了算法的鲁棒性和适用性。针对通用算法模型的数据增强策略有 MixUp[33]、CutMix[34]、CutOut[35]等，但这些方法对小目标物体检测效果提升很小，主要原因在于小目标像素少，目标小，极易融合于背景且分辨率低。针对这一现象，Kisantal 提出了两种数据复制策略[36]：首先采用复制策略，多次地复制同一张图片，为模型提供更多的参考量，提高模型的泛化能力。然后通过裁剪、平移等方法，尽量让一张图片中出现更多的小目标样本，使模型在训练过程中的参考样本更加丰富。这两种方法都极大地提高了模型的检测精度。

综上所述，当前的算法模型对于精度的提升以及算法复杂度的降低都有不错的效

中国知网 https://www.cnki.net

果，但在正负样本分配不平衡，多尺度上下文信息挖掘等方向仍存在较大的改进空间。

1.2.4 研究难点

传统目标检测任务中检测的目标多数为大目标或中目标，同样的方法作用于小目标缺乏针对性。因小目标在图像中像素占比少，存在覆盖面积小、包含信息少，现如今小目标检测算法主要存在以下几个难题：

(1) 检测特征少。小目标检测在绝对尺度和相对尺度两方面都存在着目标特征图有效分辨率少的情况。由于小目标物体在特征图中整体面积占比较小，使得目标像素少，语义特征缺乏，极易融合于背景且分辨率低。以上的情况都会对小目标检测工作带来极大的阻碍，降低算法模型的检测精度。

(2) 对目标特征高精度定位。由于小目标物体在特征图中整体面积占比较小，像素分辨率较低，因此在特征图中定位小目标的边界框相对于大尺度和中尺度来说难度更大。具体来说，当小目标在预测中的像素误差偏移些许，会造成其总体结果误差变得很大，而相对于大尺度和中尺度的影响则很小。除此之外，有锚框算法模型仍是现今通用目标检测算法中的主流模型，综合考虑检测难度、标注成本等各种因素的影响，且有锚框检测模型大部分锚框匹配的都为大尺度或是中尺度目标物体，缺少小目标锚框的预设和设计经验。匹配锚框的缺少，进一步提升了模型检测出小目标物体的难度。

(3) 小目标检测数据集较少。现有的目标检测数据集大部分集中在大尺度和中尺度的目标检测领域，在小目标这一领域的数据集较少。目前主流的小目标检测数据集为MS COCO[37]，小目标占比较高，达31.62%，但是每幅图像包含的实例过多，小目标分布不均匀。研究者出于对标注成本、标注难度、算法适配度、标注效率及数据集适用性等多方面因素的考虑，小目标数据集的收益会远远低于大尺度或者中尺度目标检测数据集，这也导致了小目标数据集的缺乏。同时在标注小目标数据集时，因为小目标自身的特性，也很容易出现例如遗漏、错标等一系列状况。总而言之，目前小目标检测领域的数据集数量较少，质量有待提高，同时这也是该领域正在优化的方向。

(4) 样本不均衡问题。通常有锚框算法模型会预先在目标图像中设置一系列大小不一的锚框，目的是为了明确目标样本的位置，以及分辨该样本属于正样本还是负样本。此方法简便，但也存在漏洞。如果预先设置的锚框与图片中小目标的真实锚框差距较大，会使得本该应用在小目标的锚框变成了检测大中尺度目标的锚框，这一现象导致了模型训练时大中尺度样本数量远多于小目标样本数量，造成样本不均衡问题。如何解决模型训练中大中尺度样本占绝大部分的现象也是该领域需要解决的难点问题之一。

综上所述，以上的四类问题都是阻碍小目标检测领域进展的关键。目前研究者们在各个维度的研究都有新进展，但是在大型的公共数据集上进行实验时，大尺度和中尺度目标的检测精度仍远高于小目标检测精度。由此可见该领域的算法模型改进仍有较大的可进步空间，也是本文的主要研究方向。

中国知网 https://www.cnki.net

1.3 主要研究内容

针对小目标中有效信息获取困难，目标检测计算量大，多尺度样本分配不平衡等问题，本文围绕基于深度学习的小目标检测算法展开研究，旨在从样本分配和查询机制两方面对 RetinaNet 进行改进，以达到在保证检测速度的同时显著提高小目标检测精度的目的。本文主要研究内容如下：

(1) 针对小目标检测在基于 IoU 阈值的方法中对位置偏差非常敏感，标签分配存在样本不平衡等问题，本文提出一种基于高斯有效距离和样本分层分配的小目标检测方法—EGDA-RetinaNet。首先，引入感受野有效性服从高斯分布的思想，对特征金字塔图像的特征点进行二维高斯分布建模，直接获得样本分配度量，加强检测算法对有效小目标特征的提取。其次，采用有效感受野与真实值区域之间的高斯距离作为度量标准，减少了离散小目标检测的误差，平衡了小目标正/负样本的选取比例，提高了小目标检测的准确性；最后，设计更适合小目标的分层标签分配策略，通过计算特征点有效距离进行样本排序，引入分配特征掩码以减少低质量样本，提高小目标样本选取有效性，增强小目标检测性能。

(2) 针对小目标在低分辨率特征图中有效分辨率较少，高分辨率特征图中小目标分布稀疏等问题，本文提出一种基于级联查询的高分辨率稀疏小目标检测算法—QS-RetinaNet。首先，在 RetinaNet 中重用 CNN 不同层的多尺度特征图，添加额外的金字塔级别来构建特征金字塔，提高特征图中小目标的有效分辨率，增强特征金字塔对小目标特征的提取能力。其次，设计一种级联特征金字塔多层级特征的查询机制，通过高级特征图的位置信息指导低级特征图的小目标检测，减少在高分辨率特征图中小目标检测的计算冗余，增加小目标特征在特征融合过程中的权重，加速小目标检测结果的计算。最后，优化基于 FocalLoss 的查询损失函数，平衡不同层的损失，调整正负样本权重，增加小目标模型的关注度，提高边界框回归精度。

本文围绕基于深度学习的小目标检测方法展开研究，共五章，具体内容如下：

第一章：绪论。首先介绍了小目标检测的研究背景与意义，然后说明了小目标检测领域的国内外研究现状以及该领域所面临的研究难点，最后总结了本文的研究内容和整体结构。

第二章：基础理论与方法。首先介绍了基于深度学习的目标检测算法相关理论，然后介绍了小目标检测经典方法—特征金字塔，最后列举了目标检测的评价指标。

第三章：基于高斯有效距离和样本分层分配的小目标检测算法。针对于小目标检测在基于 IoU 阈值的方法中对位置偏差非常敏感，标签分配存在样本不平衡等问题。本文通过建模高斯概率分布度量与真实值距离作为正负样本分配依据，并优化分配策略增加小目标正样本占比。该方法在数据集 VisDrone 和 TinyPerson 上进行实验验证，与经典模型分别进行了对比实验、消融实验和可视化实验。实验结果均表明了本文模型具有更好的性能。

第四章：基于级联查询的高分辨率稀疏小目标检测算法。针对于小目标在低分辨

中国知网 https://www.cnki.net

率特征图中有效分辨率较少，高分辨率特征图中小目标分布稀疏等问题，在 RetinaNet 基础上优化多尺度特征提取模型，通过级联查询引导小目标定位。最后，在数据集 VisDrone2019 上进行验证，分别进行了与经典模型的精度对比实验、与经典模型的实时性对比实验和总体可视化实验，实验结果均表明了本文模型具有更好的性能。

第五章：结论与展望。首先对前几章节内容进行总结，介绍了本文主要工作和创新点，然后针对本文存在不足提出了改进和未来展望。

中国知网 https://www.cnki.net

第二章 基础理论与方法

2.1 基于深度学习的目标检测算法

基于深度学习的目标检测方法可以根据其架构和处理方式被分为几个主要类别，这些分类反映了不同方法在处理目标检测问题时的核心思想和策略。按检测步骤划分，基于深度学习的目标检测算法大致可分为双阶段和单阶段方法。按锚框划分，基于深度学习的目标检测算法大致可分为有锚框和无锚框算法。

2.1.1 双阶段算法

双阶段目标检测器是一种基于 CNN 的目标检测算法，在流程上分为两个阶段来实现目标检测：第一阶段使用 RPN 生成候选区域，第二阶段使用 RoI 池化层提取候选区域中的特征并进行目标分类和边界框回归。如图 2-1，双阶段目标检测器通常由骨架网络、颈部网络和头部网络组成。

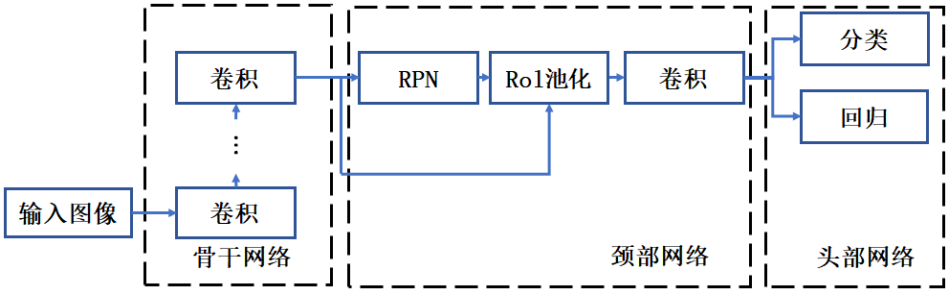


图 2-1 双阶段目标检测流程图

骨干网络：骨干网络（Backbone Network）是用于从输入图像中提取图像特征的深度网络，通常是预训练的深度卷积神经网络模型，如 VGG、ResNet 等。这个网络通常包含多个卷积层、池化层和激活函数，以学习图像的高层次特征。骨干网络的作用主要是将图像信息进行层层抽象，提取不同尺度、不同语义层次的特征并将其传递给后续的网络模块，使得模型能够更好地理解图像内容。

头部网络：头部网络（Head Network）是用于处理从骨干网络中提取的特征，并进行目标检测的最终输出。头部网络通常包括分类器和回归器两个主要部分，它们分别负责目标的类别分类和边界框位置的回归。

颈部网络：颈部网络（Neck Network）是双阶段目标检测器中的一个可选的网络模块，用于进一步提取 RPN 生成的候选区域中的特征。颈部网络通常使用 RoI 池化操作将每个候选区域内的特征映射到固定大小的特征图上，以便输入到下一阶段的网络模块进行分类和边界框回归。

RPN：RPN 是双阶段目标检测器中的第一阶段网络模块，通过卷积神经网络将输入图像映射到一组候选区域，并为每个候选区域分配一个得分，以表示该候选区域包含目标的可能性。在 RPN 中，使用锚框（Anchor）来生成候选区域，锚框是一组预定义的尺寸和长宽比，覆盖输入图像的不同区域。RPN 生成的候选区域将被传递给下一

中国知网 https://www.cnki.net

阶段的网络模块。

R-CNN 是由 Girshick 等[3]在 2014 年提出的一种具有开创性的目标检测算法。R-CNN 是基于双阶段的目标检测算法，它使用 CNN 从图像中提取特征并进行目标识别。R-CNN 首先使用选择性搜索算法生成图像的多个候选区域，然后将这些候选区域作为输入传递给卷积神经网络，以提取特征。在第二阶段时，R-CNN 使用 SVM 分类器识别每个候选区域是否包含物体。R-CNN 是当时物体检测领域中最先进的算法之一，它提供了高准确性和高精度的检测结果。该模型经过训练提高检测性能，并且可以检测不同的目标类型。然而，R-CNN 的缺点是速度较慢，因为需要在单张图像上进行多次卷积计算，且 R-CNN 模型的内存需求也较高。

Fast R-CNN 也是由 Girshick 等[4]在 2015 年提出的目标检测算法，该算法是对原有 R-CNN 算法的一次改进。Fast R-CNN 的主要特点是使用了 RoI 池化层，该层通过对候选目标区域进行重采样，以便更快地从中提取特征。这样的优化使得 Fast R-CNN 比 R-CNN 更快，更高效，使 Fast R-CNN 的模型也更容易训练，并且适用于处理大型图像数据集。

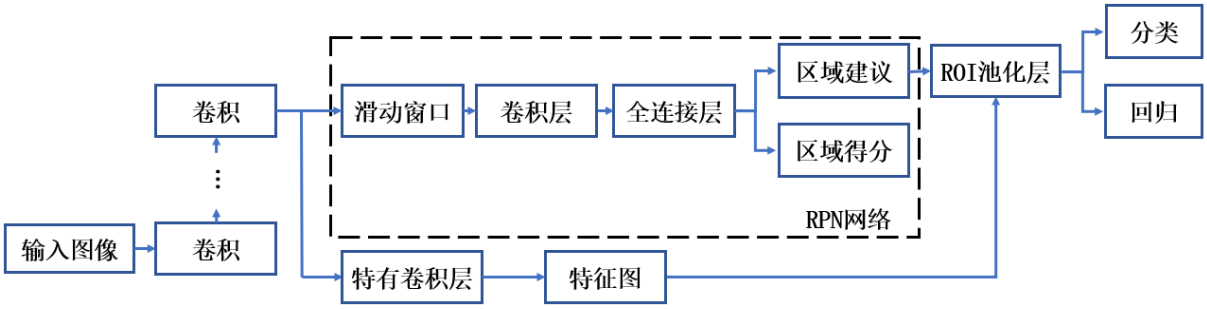


图 2-2 Faster R-CNN 流程图

然而 Fast R-CNN 仍存在一些缺点需要进一步改进。其一是特征提取的复杂性，因为 Fast R-CNN 在分类和定位阶段使用了同一个特征提取网络。这导致了特征提取网络在处理大量数据时变得过于复杂，造成计算效率降低。Faster R-CNN[5]是由 Shaoqing Ren，Kaiming He 和 Ross Girshick 在 2015 年提出的一种目标检测算法，它是在 Fast R-CNN 的基础上改进得到的，用于解决 Fast R-CNN 算法的一些问题。

Faster R-CNN 中使用了卷积神经网络 CNN 作为特征提取器，首先经过一个卷积层和一个池化层从原图中提取特征图像。然后通过 RPN 网络将特征图分割成多个区域并从特征图像中对目标存在的区域定位，利用目标初步的位置信息继续训练，获得更精确的位置。最后把提取到的精确位置区域信息输入 ROI 池化层并池化成固定长度的数据，进行最后的分类和边界框回归，如图 2-2 所示。Faster R-CNN 与 Fast R-CNN 的主要区别在于它通过引入了 RPN 替代 Fast R-CNN 中使用的选择性搜索算法，用于生成候选区域。与选择性搜索算法相比，RPN 算法不仅能够准确地生成候选区域，而且可以端到端地与检测网络一起训练，因此可以在速度和准确率上取得更好的表现，RPN 算法还能够共享特征提取器的计算，在一定程度上减少计算量和内存占用。

Faster R-CNN 中的 RPN 网络接收特征图作为输入，然后输出一系列候选框。RPN 网络首先对输入的特征图进行卷积操作，然后对每个卷积位置预测多个候选框，同时

中国知网 https://www.cnki.net

为每个候选框预测一个置信度得分，用于区分前景和背景。RPN 网络的输出是一组候选框，每个候选框由四个坐标值和一个置信度得分组成，坐标值用于表示候选框的位置和大小，置信度得分用于表示该候选框是否包含目标物体，这样能够避免人工选择候选目标区域的时间和空间代价。而且 Faster R-CNN 采用了一种快速的卷积神经网络用于特征提取，从而提高了算法的运行速度。Faster R-CNN 广泛应用于各种目标检测任务，例如人脸检测、行人检测和车辆检测等，应用场景也很广泛，主要用于图像分析、视频监控、机器人操作和交通控制等方面。

2.1.2 单阶段算法

单阶段目标检测器是一种基于 CNN 的目标检测算法，在流程上仅通过单个阶段来实现目标检测，在使用骨干网络提取特征后，直接对特征图进行回归。如图 2-3 所示，单阶段目标检测器通常由骨干网络和头部网络组成。

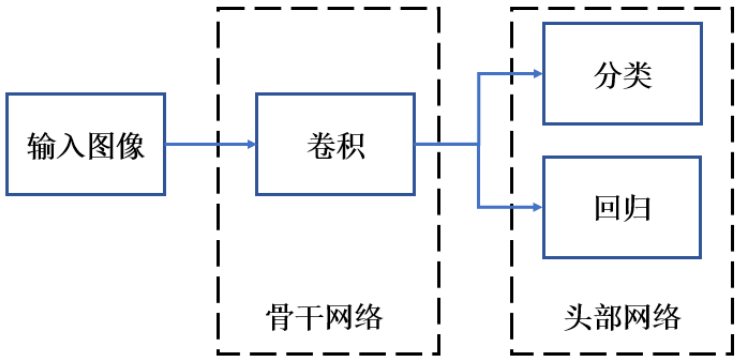


图 2-3 单阶段检测器结构图

分类：目标分类主要是使用头部网络中用于目标分类的分类器，处理接收到的骨干网络提取的特征，并对每个预定义的锚框或先验框进行目标类别的分类。其输出结果是一个表示每个类别置信度的概率分布。

回归：边界框回归通常是使用头部网络中用于边界框回归的回归器校正由骨干网络生成的预测边界框的位置。具体来说，对于每个锚框或先验框使用回归器输出偏移量，以此调整锚框的位置，使其更准确地表示目标。

单阶段目标检测方法相对于双阶段目标检测方法更加快速简单，单阶段方法直接从整个图像中提取特征并进行目标检测，无需额外的候选框生成步骤，减少了检测所需的时间成本。同时，因为单阶段方法通常在图像上密集地预测目标的位置和类别，而不是仅在候选区域上进行预测，在面对需要全局性检测的目标时表现更好。

单阶段目标检测在发展历史中经历了多个重要的阶段，YOLOv1[38]作为单阶段目标检测的奠基之作，是由 Joseph 等在 2015 年提出的一种具有开创性的目标检测算法。它通过将目标检测任务转化为一个回归问题，实现了端到端的目标检测。YOLOv1 的设计简单高效，但对小目标的检测性能相对较弱。

在 YOLOv1 提出之后，又一单阶段目标检测经典网络 SSD 由 Liu 等[9]在 2016 年提出，结合了 YOLO 和 Faster R-CNN 的部分特点。类似于 Faster R-CNN，SSD 采用 RoI 池化来从多尺度的特征图中提取固定大小的特征向量，这有助于保持模型对目标的准

中国知网 https://www.cnki.net

确感知，并支持后续的分类和回归任务。同时，SDD 通过引入多尺度的先验框（Anchor Boxes）来解决不同尺寸目标的检测问题。SSD 借鉴了 YOLO 的密集先验框采样策略，通过在图像中密集生成先验框，确保了模型对目标的全局感知能力。这使得 SSD 能够有效地检测不同尺寸和位置的目标。SSD 的这些特点综合了 YOLO 和 Faster R-CNN 的优势，使其在目标检测任务中表现出色。这种结合使得 SSD 能够兼顾准确性和速度，成为一种在实际应用中广泛使用的单阶段目标检测算法。

然而 SSD 作为单阶段目标检测的集大成者，仍然存在正负样本数量不均衡的问题。2017 年，RetinaNet 由 Tsung-Yi Lin 等[错误!未找到引用源。]在论文"Focal Loss for Dense Object Detection"中首次亮相。该方法引入了特征金字塔网络（Feature Pyramid Networks，FPN）和焦点损失（Focal Loss），解决了单阶段目标检测中正负样本不平衡和小目标检测的问题。在目标检测任务中，由于负样本的数量通常远远多于正样本，传统的交叉熵损失容易导致模型对负样本过度自信，从而影响了对正样本的关注。Focal Loss 通过调整损失函数的权重，降低易分类样本对总体损失的贡献，使得模型更关注难以分类的正样本，有效缓解了类别不平衡问题。RetinaNet 在小目标检测和正负样本不平衡场景下取得了显著的性能提升。

2.1.3 有锚框算法

有锚框算法通过区分各区域像素生成来描述空间位置的不同缩放比和长宽比的边界框，有锚框算法的工作原理分为四部分：

首先，有锚框算法对输入的初始特征图目标特征区域内设置一组特定缩放比和长宽比的参考锚框，通过锚框去覆盖目标特征可能出现的区域以及目标特征的大小。

其次，对第一步生成的锚框进行匹配与计算。一般使用交并比作为评价匹配效果的参数，对于两个不同的锚框（初始特征图生成的锚框和真实目标特征锚框）通常使用杰卡德系数（Jaccard Index）作为交并比的结果，计算预测锚框与真实锚框的交集面积与并集面积的比值，取值范围为 0~1。若数值较低，则代表预测锚框与真实锚框相交区域少，为负样本；若数值较高，则代表真实锚框包含了预测锚框较多区域，为正样本。最理想情况是完全重叠，即比值为 1。

然后，通过 2.1.1 与 2.1.2 介绍的双阶段算法和单阶段算法可知，有锚框算法将目标检测任务简化为分类与回归任务。在模型的训练阶段，对预测锚框进行分类与回归任务，确定锚框内是否有目标以及目标的类别、调整锚框的大小和位置来锁定目标。

最后的预测阶段，会存在相似且重叠的锚框，为了精确输出结果，通常会利用非极大值抑制输出（NMS）来合并同属于一个类别的预测锚框，消除冗余锚框，简化输出。

中国知网 https://www.cnki.net

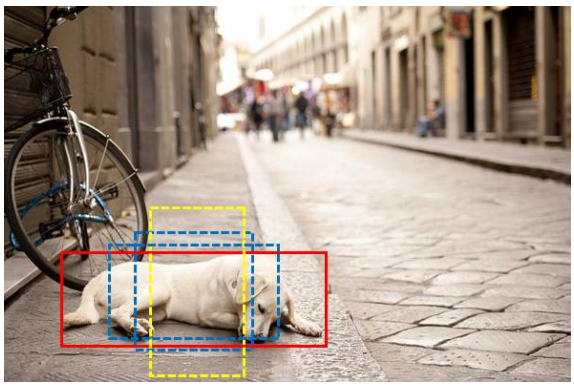


图 2-4 有锚框算法实例

有锚框算法广泛运用于各种目标检测任务中，已经成为深度学习目标检测主流技术之一，代表的算法模型有 R-CNN 系列、YOLO 系列和 SSD 等。有锚框算法实例如图 2-4 所示,蓝色虚线框代表正样本框，黄色虚线框代表负样本框，红色实线框代表真实值。

2.1.4 无锚框算法

无锚框算法与有锚框算法相对应，该算法也是目前目标检测领域新兴的主流算法之一。它在目标检测过程中无需依赖生成的边界锚框，而是依赖关键点、关键中心等更为灵活的区域实现目标检测，主要的无锚框算法类型有以下几类：

基于关键点的无锚框算法。2019 年提出的算法 CornerNet[17]使用一个卷积将目标特征区域的边界视为一对关键点（取左上角和右下角），然后通过组合点形成检测框，达到将目标检测问题转换成关键点搜寻及组合问题。

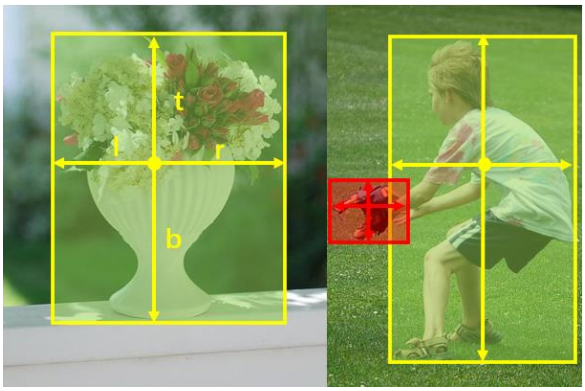


图 2-5 FCOS 无锚框算法实例

基于中心点的无锚框算法。2019 年提出的基于中心点的无锚框算法 CenterNet[18]与 CornerNet 关键点算法思想相似，该模型主要为两个结构，首先通过传统特征提取主干网络作为编码器对输入特征图进行提取。然后利用编码器上采样后的特征送入 CenterNet 解码器的三分支进行预测，通过热图预测出中心点。若在预测的特征目标点处存在中心点，则会产生一个 KeyPoint。除了中心点的预测外，CenterNet 也同时对目标特征尺寸进行了预测，确定出中心点对应的缩放比和长宽比。FCOS[40]是目前最常用的无需锚框的物体检测算法之一，发表于 ICCV 2019。FCOS 的检测效果完全可以媲美基于锚框的单阶段法检测效果，避免了和 anchor box 相关的计算、超参的优化，检测流程较为简单，检测速度相对较快，核心思想是将铺设锚框变为了铺设锚点进行物体检

中国知网 https://www.cnki.net

测。FCOS 算法实例如图 2-5 所示。

2.2 特征金字塔

特征金字塔[22](Feature Pyramid Network，FPN)是 2017 年由 Lin 等提出的一种用于处理目标检测中不同尺度物体的技术。它通过构建多尺度的图像特征图集合，使得神经网络能够有效地捕捉和处理不同尺度的目标。特征金字塔的核心思想是通过构建一组具有不同分辨率的特征图，以适应多尺度的目标。这些特征图被组织成金字塔形状，底层对应于较大尺度的特征图，而顶层对应于较小尺度的特征图。特征金字塔的构建基于图像金字塔的思想，通过不断降低图像分辨率来获得尺度变换。

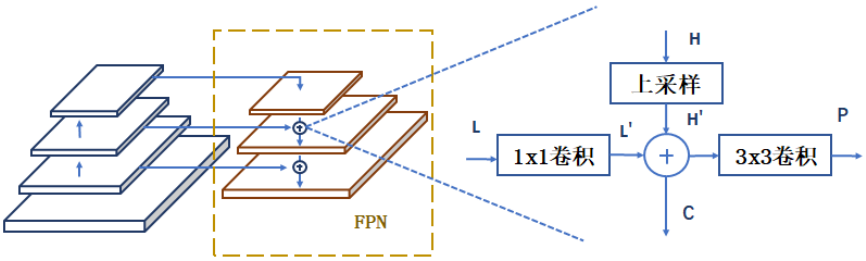


图 2-6 特征金字塔网络结构

深层特征图中含有浅层特征图所缺乏的高级语义信息，而经过卷积层的不断作用，深层特征图也逐渐丢失浅层特征图中的丰富位置和细节信息。许多检测模型都只在最顶层的特征图上做检测，降低了模型对目标的定位能力。而 FPN 的主要思想是将深层特征图中的丰富的语义信息通过一定的方式传递到浅层特征图中，使得浅层的特征图中也能包含一定的语义信息，从而增强多个尺度上的语义表达。如图 2-6 所示，左边对应着主干网络的前向传播过程，右边则对应着自顶向下的 FPN 结构。首先将左边特征图经过 1×1 卷积核减少通道数，然后通过横向连接与右边上采样后的特征图进行特征融合，最后的 C 模块主要是用于消除上采样的混叠效应。

在目标检测任务中，特征金字塔的应用尤为显著。经典的目标检测框架，如 Faster R-CNN 和 RetinaNet，都采用了特征金字塔结构。通过在不同层次的特征金字塔上执行目标检测，这些方法能够有效地捕捉和处理不同尺度的目标。以 RetinaNet 为例，RetinaNet 利用特征金字塔强化初始检测的特征，分别将得到的低层特征和上采样后的高级特征进行特征融合，融合后的特征经过一个 3x3 的卷积得到用于检测的强化后的特征图。本文利用 FPN 对初始的检测层进行强化，并结合下采样得到 P3-P7 共 5 层多尺度特征，最后传入检测子网络进行目标分类和位置回归。

处理多尺度特征的方法因任务和模型而异，但通常包括以下几种常见的技术：

图像金字塔：图像金字塔是通过在不同尺度下生成图像副本来实现的。这些副本可以通过高斯金字塔或拉普拉斯金字塔等技术得到。在特征金字塔中，这些图像副本可以用作底层的特征图。

卷积金字塔：卷积金字塔使用不同大小的卷积核来对输入图像进行卷积操作，从而获得多尺度的特征图，这种方法在深度学习中经常用于构建特征金字塔。

空洞卷积：空洞卷积（或膨胀卷积）是通过在卷积核之间引入空洞来扩大感受野

中国知网 https://www.cnki.net

的技术。通过调整空洞卷积的膨胀率，可以在不引入过多参数的情况下获得多尺度的特征响应。

转置卷积：转置卷积（反卷积）通过上采样输入特征图，使其具有更高的分辨率。这可以用于构建特征金字塔的高层。

2.3 目标检测数据集与评价指标

目标检测数据集是机器视觉领域中用来训练和评估算法性能的重要组成部分，常有的经典目标检测数据集有以下几种。

2014 年由微软公司提出的 MS COCO[37]数据集是一个大规模的目标检测、语义分割、实例分割等数据集，由 33 万张图片组成，共分为 80 多个类别，该数据集的图片中目标特征通常与场景一起出现，更符合目标检测的任务要求。

Pascal VOC 数据集[42]是一个随着时间发展而不断添加和完善的数据集。其中最著名的为 VOC2007 和 VOC2012，其特点是结构编排清晰，标注完整，信息丰富，适合目标检测领域中算法间的性能比较。

KITTI 数据集[43]在 CVPR2012 中被德国卡尔斯鲁厄理工学院和丰田美国技术研究中心联合提出。该数据集是专门为自动驾驶研究开发的目标检测数据集，其中包含了很多传感器采集的数据，如 LIDAR 激光雷达系统、红外相机和 IMU 数据测量单位等。由传感器采集的数据可以用于评估自动驾驶领域的各种算法，如目标检测、目标跟踪、三维重建等等。KITTI 数据集已经成为评估自动驾驶算法性能的重要基准之一。

VisDrone2019 数据集[32]是 AISKYEYE 团队于 ICCV2019 研讨会中提出。该数据集拥有丰富的数据内容，分为视频与图片，且涵盖面广泛，包括了环境、物体、密度等等。其多样化的标注信息也助于学者应用于各种场景，提高模型准确性与泛化性。但该数据集也有一定的限制，比如其标注成本高、计算资源需求量大，这也会限制一部分无法拥有与之匹配资源的学者进行使用学习。其次该数据集在实际应用中的挑战性会很大，学者往往需要十分深入了解当前的目标检测模型机制以及算法结构等，才可以准确提出创新点，有效提高算法模型的精度。

对于小目标检测通常有两类评价指标，分别是精度检测与速度检测。

在单目标检测中，一般使用平均精度（Average Precision，AP）[53]来衡量算法的检测精度。在多目标检测，通常使用所有类别的平均精度（mean Average Precision，mAP）[54]来衡量模型的检测精度，mAP 的计算使用 AP 值的平均值。在本文的实验中，小目标检测的精度采用的是总体样本平均精确度 mAP，某一类小目标平均精度 AP、小目标平均召回率 AR。精确度（Precision，P）[55]是指预测正确的正样本数量占所有预测为正样本数量的百分比。召回率（Recall，R）是指预测正确的正样本数量占实际为正样本数量的百分比。AP 是 P-R（Precision-Recall，P-R）[56]曲线下的面积。具体计算公式如下：

$$P = \frac{TP}{TP+FP}, \tag{2-1}$$

$$R = \frac{TP}{TP+FN}, \tag{2-2}$$

中国知网 https://www.cnki.net

$$AP = \int_0^1 PdR, \tag{2-3}$$

$$mAP = \frac{\sum_{i=1}^{m} AP_i}{m}, \tag{2-4}$$

如图 2-7，这里的 TP、TN、FP、FN 分别是预测为正样本实际是正样本，预测为负样本实际是负样本，预测为正样本实际是负样本，预测为负样本实际是正样本。m是样本类别数量。此外，还涉及到的指标有 AP_{50} 与 AP_{75}，分别代表了 IoU 分别为 0.5 与 0.75 时所对应的平均精度。

混淆矩阵		预测值	
		Positive	Negative
真实值	Positive	TP	FN
	Negative	FP	TN

图 2-7 混淆矩阵

除此之外，小目标物体识别算法还有其他方面的评价指标，如模型复杂度采用参数量（Parameters，Params ），具体计算公式如下：

$$Params = C_o \times (k_w \times k_h \times C_i + 1), \tag{2-5}$$

这里的C_o表示输出通道数，C_i表示输入通道数，k_w、k_h分别表示卷积核宽、高。在本文的小目标检测检测速度指标采用 FPS，代表一秒时间处理的帧数，单位是 f/s(帧/秒)。在一秒的时间内检测图片数量越多，检测速度越快。

2.4 本章小结

本章主要对小目标检测的相关理论进行了系统的介绍。在 2.1 节，对基于深度学习的目标检测算法进行概述。在 2.2 节对特征金字塔原理进行阐述，为后面的检测算法奠定基础。在 2.3 节对于目标检测的评价指标进行了汇总，以及介绍了本文所采用的评价指标，体现了小目标检测算法的精度与速度。

中国知网 https://www.cnki.net

第三章 基于高斯有效距离和样本分层分配的小目标检测算法

3.1 引言

随着人工智能技术的不断发展和进步，目标检测技术在图像处理、视频监控、智能驾驶等领域有着广泛的应用。然而，目前的目标检测技术在小目标检测方面还存在着一些问题，如误检、漏检等，这限制了它们在实际应用中的表现。

为了提高对小目标的检测效果，本章提出了一种基于无锚框模型的小目标检测改进方法。在 RetinaNet 模型上引入有效感受野替代传统的理论感受野可以提高小目标检测算法中特征提取的有效性，在此基础上对特征图进行高斯建模并计算概率分布距离。通过高斯距离度量预测值和真实值之间的差异，减少了离散小目标检测的误差，平衡了小目标正/负样本的选取比例，提高了小目标检测的准确性。

在实验部分，本章采用了 VisDrone2018 数据集训练和利用 MS-COCO 数据集指标评估所提出的小目标检测方法的性能。实验结果表明，本章提出的基于 RetinaNet 目标检测模型改进后在小目标检测方面表现优异，相比于原模型具有更高的准确率和更低的误检率，具备更好的实用性和应用前景。

3.2 基于无锚框的目标检测技术介绍

通用目标检测算法主要可以分为两种：基于锚框和基于无锚框。基于锚框的方法是较早提出的目标检测方法之一，它通过在图像上放置一系列预定义尺寸和比例的锚框来进行目标检测。锚框是一种矩形框，代表了图像中可能存在的目标的位置和形状。通常，锚框会以多种尺度和比例进行设置，以适应不同大小和形状的目标。该方法首先使用一个候选框生成器，通过在图像上滑动窗口的方式生成一系列候选框，并计算每个候选框与锚框的相似度。然后，使用一个分类器和回归器来对候选框进行分类和位置调整，最终得到目标的检测结果。然而，基于锚框的方法存在一些问题。首先，锚框的设置需要经验和人为的选择，对于不同的数据集和场景，需要进行不同的调整。其次，由于锚框的数量较多，计算量较大，会造成算法运行速度较慢。此外，对于存在目标重叠和目标尺度变化的情况，基于锚框的方法可能会产生较多的误检和漏检。

无锚框的方法是近年来发展起来的一种目标检测方法。与基于锚框的方法不同，无锚框的方法不需要预先定义锚框，而是直接回归目标的位置和类别。在小目标检测方面，无锚框的方法具有较快的检测速度和更好的检测效果，但在某些情况下仍然存在一定的缺陷。

3.2.1 基于无锚框的模型

无锚框目标检测算法是在有锚框目标检测算法的基础上发展而来，早期学者通过为待检测的目标设计合适的锚框来进行特征检索。锚框（box）最早在 Faster R-CNN 模型中被使用，到现在仍然是众多目标检测算法的优选。使用锚框的目标检测算法适用于解决需要精确定位、目标大小多样的检测问题。锚框的选取多为通过 k-means 聚类方

中国知网 https://www.cnki.net

法或人工设计出来一组矩形框，这样的矩形框具有固定的尺寸，对于合适的目标能够很好地表达目标数据集中分布的长宽比，好的锚框设计也能极大提高目标检测算法的性能。然而随着目标检测需求的进一步提高，在应对形变较大或像素较少的候选目标时，使用有锚框的目标检测算法会导致定位精确度下降，这对于小目标预测结果有着直接的影响。除此之外，由于小目标在像素少的同时还伴随密集出现的特点，使用有锚框的模型来检测小目标需要重新设计新尺度的锚框，成片出现的密集小目标还会使图像上的锚框密集化。大量的锚框需要在计算交并比时花费更多的内存，锚框的设计也需要众多的超参数，容易造成模型整体运行速度降低，调参困难等问题。且因为小目标具有像素少、特征少，候选框中容易出现大量的负样本等问题，从而导致正负样本不平衡，降低召回率，影响最终检测结果与速度。由此可知，有锚框的算法在小目标检测算法领域存在诸多问题。

与此同时，基于点的无锚框算法因其解决了锚框算法存在的计算量大，操作复杂，人工设计锚框调参困难等问题，逐渐成为当前的研究热点。2018 年，Law 等提出了一种全新的无锚框目标检测算法 CornerNet[17]。在此之前，无论是单阶段还是双阶段的目标检测算法，其前沿研究都无法脱离锚框。CornerNet 通过使用边框的对角关键点来检测目标，并通过卷积网络生成热图，分别描绘同一类目标所有实例的两个对角信息，在无锚的情况下实现定位和分类，简化了后处理操作。同时，CornerNet 引入了一种新的角池化层，从而更好地定位图像中目标边界框的对角关键点。相对于有锚框算法，CornerNet 通过寻找对角关键点减少了计算量，在离散目标定位方面具有更高的效率，提高了目标检测算法的性能和速度，进而实现端到端的检测。2019 年，Duan 等[18]发现 CornerNet 网络在池化过程中只能提取到目标边缘特征，最后因为缺少内部特征使模型存在很多误检问题。为了解决该问题，Duan 等在检测左右对角关键点的同时通过中心点池化得到中心关键点，提出了一种基于关键点的网络 CenterNet。此外，与 CenterNet 同期出现了许多无锚框算法如 RepPoints、FoveaBox、FCOS 等，其中 RepPoints[41]通过可变形卷积学习获得代表点集来表示目标，角度新颖，不仅能进行目标检测，还能充分表现物体的精细结构。RepPoints 为了使具有代表性的点落在目标上，从第一次回归的结果中计算得到可变形卷积的偏移量，在分类和第二次回归时使用可变形卷积根据偏移量进行分类和预测位置，进一步优化特征质量。

3.2.2 正负样本选择

在小目标检测中，明确合适的正负样本选择方法是至关重要的一步，它对于模型的准确性和性能起着重要作用。下面介绍一些常用的正负样本选择方法：

IoU 阈值法：通过比较预测范围与已知真实值之间的交并比来决定正负样本的选择，是目标检测中常见的方法。在目标检测中，如果预测框与所有真实值之间的交并比计算结果小于某个阈值，那么认定其为负样本；如果预测框与任何一个真实目标的交并比计算结果大于某个阈值，那么认定其为正样本。这种方法简单直观，但在存在大量预测框的情况下会增加计算 IoU 的时间复杂度。

中国知网 https://www.cnki.net

样本平衡法：由于正样本数量往往明显少于负样本数量，为了平衡正负样本之间的比例，可以采用样本平衡的方法。常见的做法是在训练采样时，在正负样本中均匀采样一定数量的样本进行训练。比如可以设置一个采样比例，保持正负样本的数量相对均衡。

难易样本挖掘法：目标检测中存在难易样本分布不平衡的问题，而难样本通常对于模型的训练和性能提升有着更大的贡献。因此，一种常用的方法是通过难易样本挖掘来选择正负样本。具体而言，先使用初始模型预测候选框的得分，然后根据得分进行排序。选择得分较高的候选框作为正样本，而较低得分的候选框作为负样本。通过这种方式，可以使模型更加关注难样本，从而提升模型的准确性。

粗分类器预选法：为了减少目标检测算法的计算量，可以先使用一个快速的粗分类器将候选框进行初步筛选，并选择得分较高的候选框作为正样本。这样可以减少需要处理的候选框数量，提高算法的运行效率。

需要注意的是，上述方法并不是相互独立的，通常可以将它们结合起来进行使用。针对数据集和实际应用场景选择适合的正负样本选择方法，可以帮助模型更好地学习目标的特征，提高目标检测的准确性和鲁棒性。同时，由于目标检测任务的特殊性，对于正负样本选择的方法仍然需要在细节上根据具体情况进行进一步调整和优化，以达到最佳效果。

3.2.3 标签分配策略

目标检测中常用的标签分配策略有三种：最大重叠法、困难负样本挖掘法和随机采样法。最大重叠法把真实目标框和所有候选框进行 IoU 计算，将 IoU 值最大的候选框分配给真实目标框。如果一个候选框的 IoU 值小于某个阈值，则不分配给任何一个目标框。困难负样本挖掘法主要用于训练过程中负样本的挖掘。在每个图像中，将 IoU 值与预设阈值不重叠的框标注为负样本，当负样本过多时，选取一部分最难的样本进行训练，以提高分类器的性能。随机采样法将正样本和负样本分别标注，正负样本之间的比例根据需求进行调整，然后从训练集中随机采样一定数量的正负样本，用这些样本来训练分类器。

这三种标签分配策略各有优点和缺点。最大重叠法更加精确，可以提高检测精度，但当目标相对较小、分布密集或出现遮挡时，分配结果可能不够准确。困难负样本挖掘法则更加注重负样本的选择，在目标稀少、负样本占主导的情况下效果较好。随机采样法简单直接，可以有效避免样本的不均衡问题，但数据量较大时，训练效率可能较低。综合来说，在构建目标检测模型的过程中需要研究者根据实际应用情况进行选择，并且通过实验观察到的结果进行调整，尤其是对于小目标检测模型需要选择更灵敏的分配策略。

3.3 EGDA-RetinaNet 模型概述

针对小目标检测在基于 IoU 阈值的方法中对位置偏差非常敏感，标签分配存在样

中国知网 https://www.cnki.net

本不平衡等问题，提出一种基于高斯有效距离和样本分层分配的小目标检测方法—EGDA-RetinaNet。整体方法流程如图 3-1 所示。

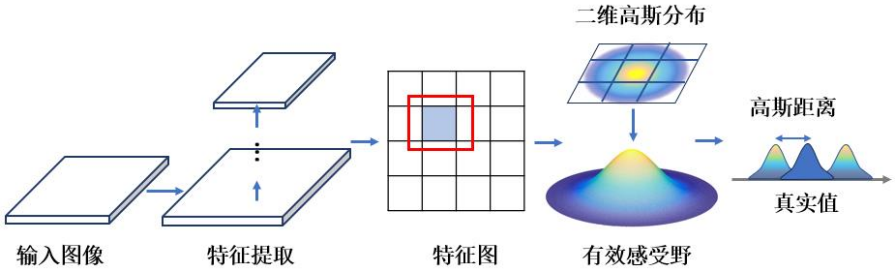


图 3-1 EGDA-RetinaNet 结构流程

（1）EGDA-RetinaNet 模型设计如图 3-1 所示。首先，为解决小目标检测在基于 IoU 阈值的方法中对位置偏差非常敏感，在 RetinaNet 中引入有效感受野的概念，根据感受野有效性服从高斯分配的特点，对特征金字塔图像的特征点构建二维高斯分布建模，直接获得样本分配度量，加强检测算法对有效小目标特征的提取。其次，为解决标签分配存在样本分配不平衡的问题，采用有效感受野与真实值（Ground Truth，gt）区域之间的高斯距离作为度量标准，减少了离散小目标检测的误差，平衡了小目标正/负样本的选取比例，提高了小目标检测的准确性。最后，为解决小目标检测正负样本选取不平衡的问题，通过计算特征点有效距离进行样本排序，引入分配特征掩码以减少低质量样本，提高小目标样本选取有效性，增强小目标检测性能。

（2）模型预训练。模型的预训练是机器学习任务中重要的一部分。在小目标检测算法模型中，仅仅靠 VisDrone2019 数据集的训练结果作为初始模型的训练权重是远远不够的。为了提升模型精度和泛化性，使得模型有一个较高标准的初始条件，本文先将检测模型以 MS COCO 数据集为主进行预训练，得到预训练权重，再将该权重对 VisDrone2019 数据集和 TinyPerson 数据集进行迁移训练，获得需要的训练模型。

3.4 方法设计

RetinaNet 是一种广泛使用的目标检测模型，在小目标检测方面有着不错的表现。然而小目标检测仍然存在基于 IoU 阈值的方法中对位置偏差非常敏感，标签分配存在样本分配不平衡等问题，为了提高小目标检测效果，本文还需要一些改进措施。

一种方法是引入有效感受野的思想，并通过计算有效感受野和真实值之间的高斯距离来替代 IoU 在小目标检测中的度量。直接获得样本分配度量，减少了离散小目标检测的误差，加强检测算法对有效小目标特征的提取，提高了小目标检测的准确性。然而，仅仅通过有效性度量只能提升检测模型对小目标正样本的提取，无法解决正负样本分配不平衡的问题。

另一种方法是结合有效感受野高斯距离设计更适合小目标的分层标签分配策略，通过计算特征点有效距离作为度量标准进行样本排序，引入分配特征掩码以减少低质量样本，提高小目标样本选取有效性，增强小目标检测性能。

中国知网 https://www.cnki.net

3.4.1 高斯距离样本分配度量

由于小目标缺乏区分性特征，通用目标检测方法在小目标领域一直存在着锚框与先验不重叠问题，导致小目标正样本缺乏。常用方法多为采用启发式锚框预设来保证小目标有更多的正样本，然而小目标检测过程中 IoU 常出现零值，这使得网络对小目标关注较少。为了增加网络对小目标的关注度，本文通过引入一种服从高斯分布的有效感受野先验，构建一种更有利于小目标的基于高斯有效感受野的样本分配度量。

在传统的卷积神经网络中，不同层的特征图具有不同的感受野大小，较浅的层通常具有更高的分辨率和较小的感受野，而较深的层则具有较大的感受野和较低的分辨率。这导致小目标检测任务中，较深层的特征图很难捕捉到小尺寸目标的信息。通用目标检测算法构建 FPN 特征金字塔以达到同时检测不同尺度的目标的效果，这种方法实际上是通过改变感受野，获取特征点不同尺度的信息。本文可以通过对感受野建模来描述目标检测任务中的特征信息，直接获得样本分配度量，而无需设计启发式锚框预设或尺度分组。

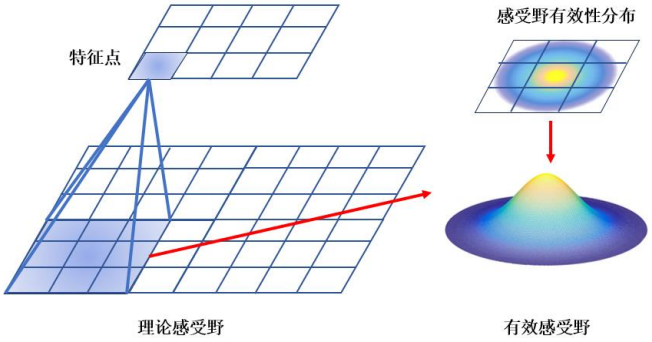


图 3-2 有效感受野

首先选择直接测量有效感受野与真实值区域之间的高斯距离，以此作为样本分配的度量标准，从而摆脱小目标检测任务中正/负样本选取失衡的问题。由于感受野的有效区域服从高斯分布，其有效性从中心迅速衰减。在实际的网络中感受野的有效范围达不到计算的理论感受野的大小，只占理论感受野的一部分，如图 3-2 所示。因此，在本文的实验中引用了有效感受野这个概念作为生成候选框的一个先验，并寻求通过二维高斯分布建模将每个特征点的理论感受野中的信息量表达转换为有效感受野对特征的有效性表达。

有效感受野和理论感受野具有相同的中心点，每个特征点的有效感受野仅占据理论感受野的一部分。设小目标检测模型中第 n 层卷积核为k，第n层的步长为S_n，第 n 层的有效感受野为erf_n，理论感受野为trf_n：

$$trf_n = trf_{n-1} + (k-1)\prod_{n=1}^{n-1} S_n \tag{3-1}$$

然后对特征点进行高斯建模。由于有效感受野无法得到精确的数值计算结果，为了获得有效感受野高斯分布模型，将理论感受野半径的一半作为有效感受野的半径er，将有效感受野半径的平方用作标准卷积核的二维高斯分布的协方差Σ_e。设特征点a的坐标为(x_a, y_a)，特征点处有效感受野二维高斯分布的均值向量为μ_e，对有效感受野进行

中国知网 https://www.cnki.net

为二维高斯分布建模$n_e = N_e(\mu_e, \Sigma_e)$，其中

$$\mu_e = \begin{bmatrix} x_a \\ y_a \end{bmatrix}, \Sigma_e = \begin{bmatrix} er_a^2 & 0 \\ 0 & er_a^2 \end{bmatrix} \tag{3-2}$$

考虑到理论感受野步长变化分布均匀，不利于小目标检测，为了衡量特征点的有效感受野与 gt 的匹配度量，需要将 gt 建模为二维高斯分布$n_g = N_g(\mu_g, \Sigma_g)$。参考无锚框检测方法中的中心目标检测，检测的目标主体多聚集在边界框的中心点，将每个标注框的中心点作为高斯均值向量，分别取锚框两个边长一半的平方作协方差矩阵，即

$$\mu_g = \begin{bmatrix} x_g \\ y_g \end{bmatrix}, \ \Sigma_g = \begin{bmatrix} \frac{w_g^2}{4} & 0 \\ 0 & \frac{h_g^2}{4} \end{bmatrix} \tag{3-3}$$

其中(x_g, y_g)为真实值 gt 边界框的坐标，w_g和h_g为真实边界框的宽和高。

本文参考了高斯分布之间的几种经典距离，最后选择了 Wasserstein 距离[44]和 K-L 散度[45]作为有效感受野距离。下面，将分析讨论两个高斯距离计算得到的有效感受野距离，在小目标检测任务中度量正负样本的优缺点。

Wasserstein距离：度量了两个概率分布之间平均距离的最小值。Wasserstein距离来自最优传输理论，常用来表示两个完全没有重叠的概率分布之间的相似度。为了衡量特定目标之间的几何特征差异，本文将 Wasserstein 距离映射到特征空间，以欧几里得距离代替计算，得到有效感受野和 gt 二维高斯分布n_e和n_g之间二阶 Wasserstein 距离的平方$W_2^2(n_e, n_g)$：

$$W_2^2(n_e, n_g) = \left\| \left([x_a, y_a, er_a, er_a]^T, \left[x_g, y_g, \frac{w_g}{2}, \frac{h_g}{2} \right]^T \right) \right\|_2^2 \tag{3-4}$$

在小目标检测任务中经常出现真实值与大多数先验框没有重叠的情况，样本分配无法将这些候选框的优先级排序到某个gt。Wasserstein距离的主要优点是可以测量两个不重叠的分布，有利于解决小目标检测过程中先验框没有重叠的问题，它可以度量特征图中所有点与某个真实值之间的相似度，使得小目标检测可以通过具体的有理数值为模型补偿更多正样本。

Kullback-Leibler Divergence[46]：K-L 散度起源于信息论，常用于衡量两个近似概率分布的差异程度，K-L 散度越大，两个概率分布的差异越大。在计算两个高斯分布之间的 K-L 散度可以得到一个封闭形式的函数，则二维高斯分布n_e和n_g之间的 K-L 散度D_{KL}如下：

$$D_{KL}(n_e \| n_g) = \frac{1}{2} \left(tr(\Sigma_g^{-1} \Sigma_e) + (\mu_g - \mu_e)^{\top} \Sigma_g^{-1} (\mu_g - \mu_e) + \ln \frac{|\Sigma_g|}{|\Sigma_e|} - 2 \right) \tag{3-5}$$

将二维高斯分布带入计算公式并将公式展开逐一计算，最终我们得到：

$$D_{KL}(n_e \| n_g) = \frac{2er_a^2}{w_g^2} + \frac{2er_a^2}{h_g^2} + \frac{2(x_a - x_g)^2}{w_g^2} + \frac{2(y_a - y_g)^2}{h_g^2} + \ln \frac{w_g}{2er_a} + \ln \frac{h_g}{2er_a} - 1 \tag{3-6}$$

K-L 散度具有两个二维高斯分布之间的尺度不变性，尺度不变性对于目标检测至关

中国知网 https://www.cnki.net

重要。但对于两个分布之间的重叠可以忽略不计的情况，K-L 散度具有不对称性，不能作为两个分布之间的距离。经过综合考量，最终选择了 Wasserstein 距离和 KL 散度作为有效果感受野距离衡量标准，然后对高斯距离进行非线性变换，得到归一化值范围在 0~1 之间的有效感受野高斯距离。

3.4.2 高斯距离正负样本分层分配策略

在机器学习中，训练模型常常需要一个样本集，其中包含正例（positive）和负例（negative）。现在常见的正/负样本分配方法主要有两种，一种是基于锚框的目标检测算法，根据 IoU 设置阈值来决定正/负样本；另一种是无锚框目标检测算法，根据点与对应 gt 距离设置权重划分正/负样本。由于小目标通常在基于 IoU 阈值和基于点先验的任务中表现都不太好，本文选择基于有效感受野高斯距离对小目标进行排序分配。

在有效感受野距离理论的基础上，本文提出了有效感受野高斯距离分配策略。在分配之前，基于 3.4.1 节的方法计算特征点和 gt 之间的距离矩阵。然后，本文对 gt 对应的每个特征点计算出的有效距离进行排序，选取特征点特定 gt 的前 k 个结果作为正样本。为了避免为那些已经分配了足够样本的 gt 再次引入过多低质量样本，本文引入分配特征掩码m，其中m是二进制值。经过初步计算，得到分配结果a_1和相应的掩码m。然后重复上述排序策略并为每个 gt 补充正样本，得到分配结果a_2。本文通过以下公式得到最终的分配结果a：

$$a = a_1 m + a_2(1 - m) \tag{3-7}$$

结合有效感受野高斯距离和对应的正/负样本分配策略，可以得到完整的基于 RetinaNet 的小目标有效性高斯检测算法。

3.5 实验及结果分析

本章的研究内容是针对基于无锚框的目标检测模型中的 RetinaNet 目标检测算法进行改进，使其能提升对小目标的检测效果。

本章实验环境为 Ubuntu 操作系统，CPU 为 Intel® Core™ i7-12700 CPU @2.30 GHz，内存为 16 GB。GPU 为 NVIDIA GeForce RTX 3090，显存为 24 GB，内存大小为 16 GB。使用 PyTorch 深度学习[47]框架和 Python 编程语言进行 RetinaNet 模型的实现和优化。同时，使用 CUDA11.3.1 和 CUDNN8.2.1 对 GPU 进行加速。

所有实验均在具有 1 个 NVIDIA RTX 3090 GPU 的计算机上进行，模型训练基于 PyTorch，核心代码基于 MMdetection[48]。ImageNet 预训练模型[49]用作主干。所有模型均使用随机梯度下降(SGD)优化器进行 12 epoch 的训练，其中动量为 0.9，权重衰减为 0.0001，批量大小为 2。初始学习率设置为 0.005，并在第 8 和 11 epoch 衰减。此外，RPN 提案的数量设置为 3000。在推理阶段，置信度得分设置为 0.05 以过滤掉背景边界框，并且对于前 3000 个边界框，NMS IoU 阈值设置为 0.5。所有其他参数设置与 MMDetection 中的默认值相同。除 VisDrone2019 上的实验外，评估指标遵循 AI-TOD 基准。

中国知网 https://www.cnki.net

3.5.1 实验设置

表 3-1 EGDA-RetinaNet 实验参数设置

参数名	参数值	说明
Weight decay	0.0001	防止模型过拟合的正则化项
Batch size	16	每次迭代中使用的样本数
Leaning rate	0.01	控制模型参数更新的步长
Epochs	50	模型训练的总轮数
momenta	0.9	过去梯度在当前的影响权重

在进行小目标检测算法改进的实验时，需要设置实验参数，以便对算法性能进行评估和比较，本文选择 VisDrone2019 数据集和 TinyPerson 数据集来进行实验，评估小目标检测算法的性能和改进效果。VisDrone2019 数据集具备了训练效率高、标注信息丰富等优势，是一个针对无人机视觉应用的大规模数据集，包含了多种类型的视觉场景和目标类别。该数据集包含了 263 个无人机拍摄的视频序列，涵盖了 13 个城市、2612 个场景和 647660 个标注框。标注目标包括行人、车辆、自行车、三轮车等，其中小目标占比较大，提供了小目标检测算法的有效测评。

TinyPerson 数据集作为小目标专用的数据集，具备标注质量高、包含大量小目标实例等优势，是一个针对小目标、微小目标以及复杂背景的海上快速救援数据集。该数据集包含了 72651 个目标实例，被分为两类：船上的、躺在水里的、身体一半以上在水里的人（sea person）和陆地上的人（earth person）。

COCO 数据集具备了大规模的图像和丰富的标注，其包含了多种复杂场景中的目标，有助于模型学习更丰富的视觉特征，是当前目标检测领域数据集的权威和标杆。这个数据集以 scene understanding 为目标，是一个大型的、丰富的目标检测数据集，数据集内的图像主要从复杂的日常场景中截取，图像中的目标通过精确的分割进行位置的标定。图像包括 328,000 影像和 2,500,000 个标签，提供的类别有 80 类，有超过 33 万张图片，其中 20 万张有标注，整个数据集中个体的数目超过 150 万个。

3.5.2 目标检测深度学习框架

目前流行的深度学习框架如 TensorFlow[50]、PyTorch、Keras[51]、Caffe[52]等，都可以用来进行目标检测任务。这些框架提供了丰富的预训练模型、模型构建和训练的 API、数据处理和增强的工具等，使得目标检测的实现变得更加简单和高效。其中，TensorFlow 提供了 Object Detection API，提供了训练和评估常用的目标检测模型，如 Faster R-CNN、SSD、YOLO 等。PyTorch 提供了一系列基于 TorchVision 的目标检测模型，如 Faster R-CNN、Mask R-CNN 等，并支持自定义网络和训练过程。Keras 则提供了易用的高层 API，很方便地搭建和训练目标检测模型。Caffe 则以速度和内存占用小著称，适合于实时目标检测。这些深度学习框架为目标检测任务的实现提供了方便和高效的工具和支持。

实验使用了 PyTorch 框架对 RetinaNet 网络进行了实现和优化改进。PyTorch 是一个使用 Python 编写的科学计算库，主要用于深度学习和人工智能方面的研究。PyTorch 提

中国知网 https://www.cnki.net

供了强大的 GPU 加速支持和动态计算图机制，使得神经网络的设计、训练和推理都更加高效、灵活和易用。PyTorch 以动态图为主要特点，能动态的构建计算图，能够快速进行迭代开发，同时也支持静态图。PyTorch 提供了众多常用的深度学习模型，如卷积神经网络、循环神经网络、生成对抗网络等，并支持自定义模型的构建和训练。此外，PyTorch 还提供了 Tensor、Variable、Module 等丰富的 API，能够进行张量运算、梯度计算、模型构建和训练等。同时，PyTorch 也提供了 TorchVision、TorchText、TorchAudio 等扩展库，支持计算机视觉、自然语言处理、音频处理等领域的深度学习任务。PyTorch 还推出了 PyTorch Lightning、PyTorch Ignite 等高级 API，简化了模型训练的过程。

PyTorch 的三大功能模块包括 Tensor、Autograd 和 Module。其中 Tensor 是 PyTorch 中最基本的数据结构，类似于 Numpy 中的多维数组，支持 GPU 计算和各种数学运算。Autograd 是 PyTorch 的自动求导模块，自动计算张量的梯度，简化了模型的训练过程。Module 则是 PyTorch 的模型构建模块，支持自定义模型的构建和训练，提供了丰富的 API 和模型层。这三个模块共同组成了 PyTorch 的基础架构，使得 PyTorch 成为一个灵活、高效、易用的深度学习框架。

实验中使用了 PyTorch 函数库，并结合 Nvidia 3090 显卡的 CUDA 加速功能，能够在 GPU 上进行并行计算，从而提高训练效率和准确性。CUDA 是一种并行计算框架，能让 GPU 具备并行处理数据的能力，快速地进行复杂的计算，包括卷积等深度学习任务。通过使用 PyTorch 函数库，方便地调用 CUDA 进行卷积运算，大幅度减少了训练时间和计算成本，同时提高了模型训练的效率和精度，特别是对于计算密集型的深度学习任务来说，CUDA 的使用为模型的训练带来显著的优势。

3.5.3 本文模型与经典模型精度对比结果分析

表 3-2 本章模型在 VisDrone2019 数据集上与经典模型精度对比

模型	骨干网络	有无改进	mAP	AP_{50}	AP_{75}
FCOS	ResNet-50	无	28.3	36.5	29.2
FCOS*	ResNet-50	无	30.1	43	32.4
YOLOv4	Daeknet-53	无	30.8	52.5	38.7
RetinaNet	ResNet-50	无	29.3	46.9	32.9
EGDA-RetinaNet	ResNet-50	有	36.4	55.5	41.1

为了验证本算法的有效性及先进性，在基于 VisDrone2019 数据集下将本算法模型 EGDA-RetinaNet 与四种主流的小目标检测模型进行精度对比，分别是 FCOS 以及引入了 FPN 机制的 FCOS*，YOLOv4 以及基线模型 RetinaNet。其中 FCOS 为 2019 年提出的经典不依赖预设锚框的小目标检测算法模型；FCOS*为 2022 年提出的前沿算法模型；YOLOv4 是基于多尺度预测的经典目标检测算法。通过与经典模型和前沿模型的对比，更能显示出本文算法的有效性。

由表 3-2 的实验结果可看出，本文模型均优于所比较模型。相对于改进前的基线模型 RetinaNet 来说，本文模型在平均精度 mAP 上提升了 24%，AP_{50} 和 AP_{75} 分别提升了

中国知网 https://www.cnki.net

18.3%和 25%；在与经典的目标检测模型的比较中，相较于性能最好的 YOLOv4，本文模型在 mAP、AP_{50} 和 AP_{75} 三个指标上分别提升了 7.7%、5.8%和 6.2%。总体而言，本文模型基于高斯有效距离和样本分层分配，在小目标检测中识别的信息更全面，精度更高，在精度对比实验中均取得了最好的效果。

3.5.4 本文模型与经典模型实时性对比结果分析

表 3-3 本章模型在 VisDrone2019 数据集上与经典模型实时性对比

模型	骨干网络	有无改进	Params	FPS
FCOS	ResNet-50	无	60M	38
FCOS*	ResNet-50	无	63M	40
YOLOv4	Daeknet-53	无	78M	29
RetinaNet	ResNet-50	无	66M	35
EGDA-RetinaNet	ResNet-50	有	72M	33

为了分析模型的实时性，在基于 VisDrone2019 数据集下与 3.5.3 的对比对象一致，将本文算法模型与四个经典模型进行实时性比较。由表 3-3 可以看出，本文模型在基于高斯有效距离和样本分层分配后，参数量 Params 增加了 6M，在四种模型的对比中，参数量只比 YOLOv4 降低了 6M。在运算速度 FPS 上，本文模型与其它经典模型对比相差并不大。根据 EGDA-RetinaNet 与经典模型实时性对比结果分析原因：首先第一点，部分模型采用了轻量级模型结构，更为简化，所以参数量跟计算复杂度也会随之变小；其次主要原因是，本文面对对象为小目标物体，若要保证模型检测精度的前提条件则是增大图片的分辨率，因此在检测速度 FPS 方面会有所降低；最后由于引入了二维高斯分布建模以及分配特征掩码，使得计算量增加，参数量以及计算速度下降，这是在模型改进过程中结构变复杂后带来的后果。但在结合表 3-2 时可发现，本文模型较其它模型在精度上都有提升，在牺牲少量速度后可提升精度。本文模型在实时性方面效果略低于经典模型的总体效果，这也是本文第四章解决的主要问题方向，如何使用更加快速的查询机制进行小目标物体识别，如何同时兼顾计算量、运行速度以及精度。

3.5.5 总体可视化结果分析

为了更直观得观察本文提出的算法模型检测效果，本节选用模型检测后的各类结果图片做可视化分析，具体如下所示：

针对小目标检测在基于 IoU 阈值的方法中对位置偏差非常敏感问题，本文对特征金字塔图像的特征点构建二维高斯分布建模，直接获得样本分配度量，提高对小目标的检测。如图 3-3 所示，该图中的目标是数个紧密相连的人，十分考验算法模型对位置偏差的分辨效果，其次由于图中小目标缺乏区分性特征，容易导致锚框与先验不重叠，小目标正样本缺乏而使得检测结果精度降低。由可视化结果可知，本文算法模型面对紧密连接的目标对象时，依然能准确地检测出微小物体的位置，图中的定位误差和由于定位物体紧密相连所带来的干扰对模型的检测效果影响不大。

中国知网 https://www.cnki.net



图 3-3 针对位置偏差敏感的改进结果可视化



图 3-4 针对小目标检测正负样本选取不平衡的改进结果可视化

针对小目标检测正负样本选取不平衡的问题，本文通过计算特征点有效距离进行样本排序，引入分配特征掩码以减少低质量样本，增强小目标检测性能。如图 3-4 所示，这也是我们实际的检测场景中常遇到的情况，正样本（期望检测到的目标对象）往往只占据整个图像中极小的一部分。且负样本（不包含目标对象的背景部分）区域占总体特征图的绝大部分时，通常来说，这种失衡的正负样本比例会导致模型训练过程中会偏向于预测目标为负样本。本文通过在有效感受野距离理论的基础上，提出了感受野高斯距离分配策略，精细计算特征点有效距离，通过综合指标评估，对样本进行排序，赋予图像目标不同的优先级，使得算法模型能更加有效地聚焦于关键正样本，然后通过分配特征掩码，调整关键位置上的目标权重，减少负样本对模型在学习中的干扰。根据可视化结果可知，图像中正样本仅位于右下角的一小部分，而背景的负样本：水中倒影、白云、山峰等占据了绝大部分空间，模型依然能准确检测出游船上的小目标，正负样本不平衡并未使得模型倾向于预测负样本。

中国知网 https://www.cnki.net

3.5.6 与经典模型可视化对比结果分析



图 3-5 EGDA-RetinaNet 与经典模型可视化对比

为了更直观的对比本文模型相较于 YOLOv4、FCOS 等经典模型的精度优势，本文对三个模型的识别结果进行了可视化对比。图 3-5 展示了 EGDA-RetinaNet 与经典模型可视化对比结果，此实验利用了 TinyPerson 数据集进行实验，由于 TinyPerson 数据集有两大特点，首先其背景简单，一般只识别海里的人以及陆地的人；其次目标对象的数量庞大，前者可以使得目标更加凸显，后者可以使对比更加清晰。其中 A 为 EGDA-RetinaNet 对于数据集的识别结果可视化，B-E 分别为 YOLOv4、FCOS*、FCOS 和 RetinaNet 的识别结果可视化。从图中可以看出，在加入高斯有效距离和样本分层分配后，本文模型相较于其它模型来说明显的区别是对于海滩上的人识别的数量更多，精确度也更高，再者因为引入了有效感受野与真实值区域之间的高斯距离作为度量标准，减少了离散小目标检测的误差，对于滑板、遮阳伞、汽车等样本的错误识别也大大降低，解决了其它模型的误检问题。综上所述，可视化对比结果证明，本文模型在在小目标识别方面具有很好的效果，能解决大部分的漏检与误检问题。

中国知网 https://www.cnki.net

3.6 本章小结

本章主要研究了 EGDA-RetinaNet 小目标的检测方法，针对小目标检测在基于 IoU 阈值的方法中对位置偏差非常敏感，标签分配存在样本分配不平衡等问题，提出一种基于高斯有效距离和样本分层分配的小目标检测方法—EGDA-RetinaNet。首先，引入感受野有效性服从高斯分布的思想，对特征金字塔图像的特征点进行二维高斯分布建模，直接获得样本分配度量，加强检测算法对有效小目标特征的提取。其次，采用有效感受野与真实值区域之间的高斯距离作为度量标准，减少了离散小目标检测的误差，平衡了小目标正/负样本的选取比例，提高了小目标检测的准确性。最后，设计更适合小目标的分层标签分配策略，通过计算特征点有效距离进行样本排序，引入分配特征掩码以减少低质量样本，提高小目标样本选取有效性，增强小目标检测性能。

实验表明 EGDA-RetinaNet 有效地提升模型对小目标的检测效果。通过对比实验验证了改进方法的可行性。在原有 RetinaNet 基础上引入有效感受野能够有效提升目标检测性能，再使用分层样本分配策略进一步平衡正负样本的选取比例。实验结果表明，本章提出的改进方法在小目标检测方面具有很好的应用价值，对于深度学习在目标检测领域的发展和应用具有一定的参考意义。

中国知网 https://www.cnki.net

第四章 基于级联查询的高分辨率稀疏小目标检测算法

4.1 引言

由于特征金字塔高层特征图在多次上采样过程中容易丢失小目标部分特征，使得如何获得细节特征清晰的小目标一直是个难题。缺少细节特征的小目标会损失很多语义信息以致干扰最终目标检测，从而无法获得令人满意的结果。当前主要通过特征增强、多尺度训练、特征金字塔等来增加小目标细节特征。特征增强方法利用注意力机制等其他特征增强技术，恢复图像中目标的清晰度，提高对小目标特征的敏感性。但对高分辨率特征图中的小目标恢复效果不佳，并且在高级别特征层中难以平衡图像质量和计算量，同时，训练和检测高像素图像特征层需要花费更多的内存进行计算，尤其是在小目标检测的分类和回归阶段。通常情况下，研究者会设计算法选择数据量较少特征层进行特征融合计算，缺点是深层特征的有效特征较少，损失函数难以收敛。

为此，本文对如何在增加有效特征信息的同时减少检测模型整体的计算量进行研究，提出了 QS-RetinaNet 模型，一种基于级联查询的高分辨率稀疏小目标检测方法。该方法旨在解决小目标在高级特征图中有效分辨率较少和低级特征图中目标分布稀疏等问题，在优化检测性能和提升速度上取得平衡。一方面，在 RetinaNet 中重用 CNN 不同层的多尺度特征图，添加额外的金字塔级别来构建特征金字塔，提高特征图中小目标的有效分辨率，增强特征金字塔对小目标特征的提取能力；另一方面，提出一种级联特征金字塔多层级特征的查询机制，通过高级特征图的位置信息指导低级特征图的小目标检测，减少在高分辨率特征图中小目标检测的计算冗余，增加小目标特征在特征融合过程中的权重，加快小目标检测结果的计算。此外，优化基于 FocalLoss 的查询损失函数，平衡不同层的损失，调整正负样本权重，增加小目标模型对整个特征金字塔的关注度，提高边界框回归精度。

4.2 基于单阶段目标检测介绍

近年来，目标检测模型主要以单阶段目标检测器为主。单阶段目标检测在一次前向传递内直接检测图像中的目标位置和类别。相比于两阶段目标检测方法，单阶段方法更加高效，设计更加紧凑和端到端，因为它们无需在第一阶段生成候选框，而是直接在整个图像上完成目标检测任务，不涉及额外的中间阶段。典型的单阶段目标检测器（如 YOLO、SSD、RetinaNet）通常由骨干网络提取特征，提取到的特征信息通过头部网络被直接用于预测目标的分类和定位，最后用损失函数度量模型的预测结果与真实值之间的差距，通过反向传播算法优化模型参数。整个网络一起进行端到端的训练，没有显式的颈部网络用于生成候选框。

4.2.1 RetinaNet 概述

RetinaNet [错误!未找到引用源。] 发表于 2017 年 ICCV 的“Focal Loss for Dense Object Detection”，标志着单阶段网络首次超越双阶段网络。相对与双阶段目标检测算法，

中国知网 https://www.cnki.net

单阶段目标检测算法通过一个阶段完成目标的类别预测和边界框回归，简化了检测流程，通常能提供更快的推理速度。

近些年，RetinaNet 在对小目标的检测性能上相较于其他模型更为出色。传统目标检测模型可能因为对小目标的不敏感而表现不佳，而 RetinaNet 通过特征金字塔网络和 Focal Loss 的联合作用，使得模型更能够捕捉小目标的特征，提高了在复杂场景中的适用性。RetinaNet 的成功激发了后续研究者对单阶段目标检测模型的关注。该模型被广泛应用于图像识别、视频分析、自动驾驶等领域。在自动驾驶领域，RetinaNet 的高效性能使得车辆能够更精确地感知周围环境，从而提高了驾驶安全性。在研究领域，RetinaNet 作为一种先进的单阶段目标检测模型为后续研究提供了有益的启示，为未来的研究和产业应用奠定了基础。

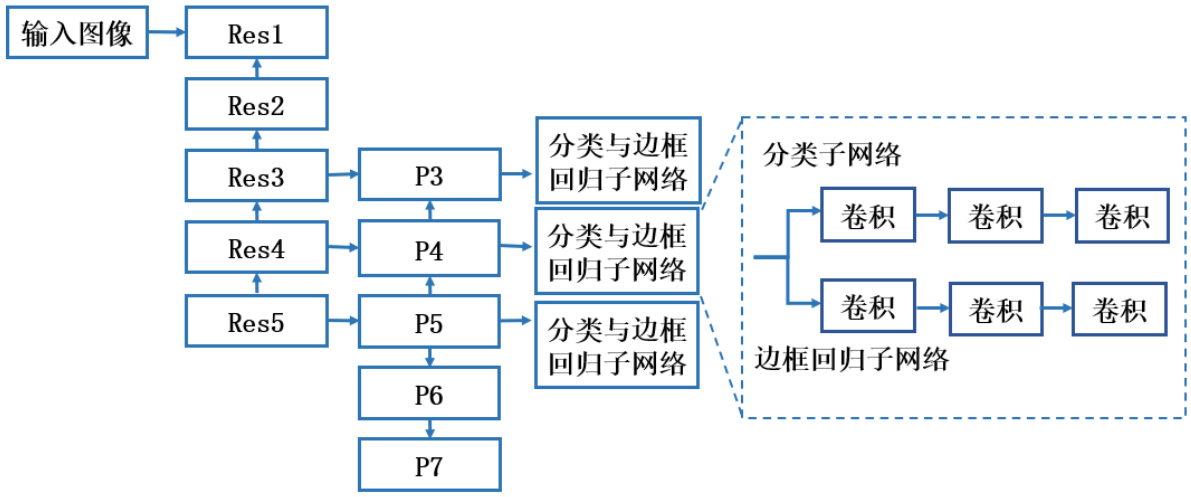


图 4-1 RetinaNet 的流程图

RetinaNet 算法模型如图 4-1 所示。其结构采用了经典的主干网络+Neck+Head 模式，RetinaNet 将输入图像传入骨干网络以提取图像中的特征，该网络通常采用的是 ResNet 深度神经网络结构。通常残差网络由有 Res1~Res5 共 5 个模块组成，如图中的 Res1-Res5 为 ResNet 充当特征提取网络。RetinaNet 选取 Res3~5 共 3 个模块作为初始检测层，经过下采样得到初始特征。然后，利用特征金字塔强化检测层的特征，分别将得到的低层特征和上采样后的高级特征进行特征融合，融合后的特征经过一个 3x3 的卷积得到用于检测的强化后的特征。图中的 P3—P7 为 RetinaNet 算法的 Neck 模块中特征金字塔网络（FPN）其中一个层级，P3 为最高分辨率的层级，用于捕捉图像中的小目标特征，P4—P7 层级的分辨率逐渐递减，最终整合为整体 Neck 结构用于捕捉各层级的特征。本文通过特征金字塔（FPN）对初始检测层 Res3~5 进行强化，进而得到了 P3~5 层，通过下采样率 2.0 的卷积层由 P5 层生成 P6 和 P7 层，最后将得到的 5 层不同尺度的特征图输入分类与边框回归子网络，进行目标分类和定位。RetinaNet 的另一个核心是引入焦点损失（Focal Loss）解决了类别不平衡问题，该算法在训练中更加关注难以分类的目标，提高了模型在少数类别和小目标上的检测性能。这使得 RetinaNet 成为一种在实际应用中广泛使用的目标检测算法。

中国知网 https://www.cnki.net

4.2.2 多尺度模型

识别尺度差异巨大的目标一直是是计算机视觉领域的一项挑战，构建图像金字塔一直是解决该类多尺度模型问题的主要方法之一。早期，基于图像金字塔构建的特征金字塔是解决该问题的标准方案，如图 4-2。特征图像金字塔使用图像金字塔构建特征金字塔，需要独立计算每一层不同尺度图像的特征，并产生多尺度结果。每一层特征都具有很强的语义性，但过多的特征导致模型推理时间增加，计算速度较慢，降低了特征图像金字塔的实用性。因此，早期部分目标检测模型默认不使用特征图像金字塔。

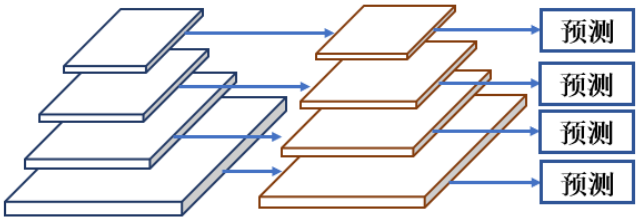


图 4-2 特征化图像金字塔

随着神经网络的发展，目标检测更多时候选用卷积神经网络（ConvNet）计算特征。ConvNet 计算的特征有助于模型在更高级别特征层上预测语义信息，并且使用 ConvNet 对计算尺度方差具有更好的鲁棒性，有利于模型在单一尺度图像上计算特征并识别，如图 4-3。通过 ConvNet 计算识别单尺度图像具有很好的鲁棒性，但在结果上不够准确。

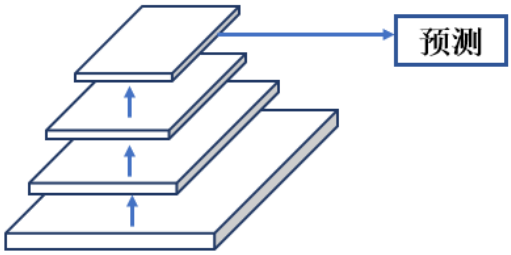


图 4-3 单尺度特征预测

经过深度 ConvNet 逐层计算特征层次结构发现，在不同尺度下可以观察到不同特征，特征层次结构整体呈现为多尺度金字塔形状，这种多尺度金字塔结构会产生不同空间分辨率的特征图。高分辨率特征图可以观察到更多细节信息，几何细节信息表征能力强，但感受野较小，语言信息表征能力弱，适合更注重细节而缺少语义信息的小目标检测模型；低分辨率特征图可以观察到整体趋势，语言信息表征能力强，但感受野较大，空间几何信息表征能力弱，适合检测拥有更多像素的大目标物体。单阶段目标检测算法 SSD 首次尝试使用通过 ConvNet 逐层计算得到的多尺度金字塔结构，如图 4-4 所示。SSD 模型金字塔放弃重用已经计算好的图像层，从网络高层开始构建金字塔并添加几个新层，减少低级特征计算，在这个过程中 SSD 不需要额外的计算成本，直接在前向传播中计算的不同层的多尺度特征图。该方法在处理多尺度目标检测问题上有着较好的效果，但弃用拥有低级特征的高分辨率特征图像会造成细节信息的缺乏，不适用于小目标的检测。

中国知网 https://www.cnki.net

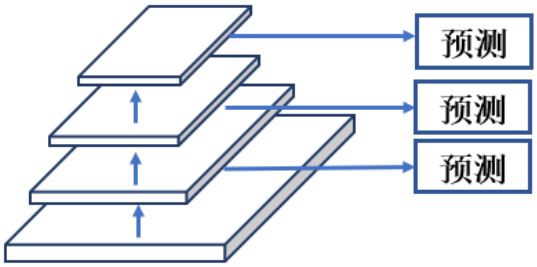


图 4-4 ConvNet 金字塔特征层次结构

由此可知，小目标检测需要一个具有强语义信息的同时，还能保证高分辨率图像细节特征的多尺度模型。2017 年，Lin 等提出了特征金字塔[22]（FPN），一种用于处理目标检测中不同尺度物体的技术，如图 4-5。它构建了一种自上而下和横向连接的架构，将低分辨率、语义强的特征与高分辨率、语义弱的特征结合起来。特征金字塔的核心思想是通过不断降低图像分辨率来获得尺度变换构建一组具有不同分辨率的特征图，以适应不同尺度的目标，这些特征图被组织成金字塔形状，底层对应于较大尺度的特征，而顶层对应于较小尺度的特征。

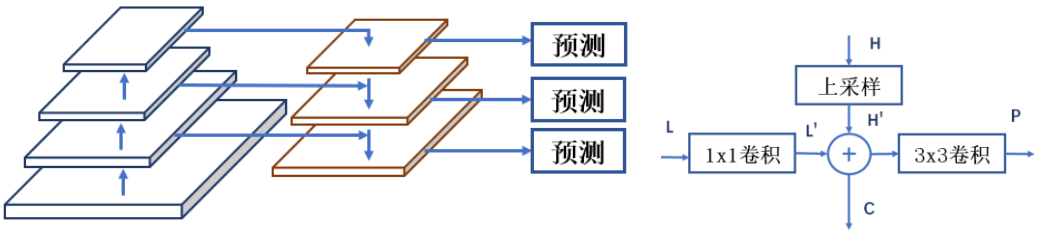


图 4-5 特征金字塔

一直以来，深层特征图中含有浅层特征图所缺乏的高级语义信息，而经过卷积层的不断作用，深层特征图也逐渐丢失浅层特征图中的丰富位置和细节信息。许多检测模型都只在最顶层的特征图上做检测，这使得定位小目标的能力较差。而 FPN 的主要思想是将深层特征图中的丰富的语义信息通过一定的方式传递到浅层特征图中，使得浅层的特征图中也能包含一定的语义信息，从而增强多个尺度上的语义表达。如图 4-5 所示，左边对应着主干网络的前向传播过程，右边则对应着自顶向下的 FPN 结构。FPN 先是对输入的特征图经过 1×1 卷积核减少通道数，然后通过横向连接与右边上采样后的特征图进行特征融合，最后经过 3×3 的卷积核得到预测结果，其中 C 模块主要是用于消除上采样的混叠效应。

在目标检测任务中，特征金字塔的应用尤为显著。经典的目标检测框架，如 RetinaNet 采用了特征金字塔结构，通过在不同层次的特征金字塔上执行目标检测，这些方法能够有效地捕捉和处理不同尺度的目标，在小目标检测中至关重要。

4.2.3 查询机制

在目标检测任务中，查询机制（Query）通常是指训练好的模型在新的、初次接触的输入图像中寻找并识别目标的过程。在训练阶段，目标检测模型学习了目标的特征；在查询阶段，模型利用在训练过程中学到的知识，对新输入的图像或视频进行分析，

中国知网 https://www.cnki.net

以定位识别其中的目标。查询机制主要包含锚框生成、前向传播、目标分类、位置回归和非极大值抑制等。有的模型可能还包含多尺度查询或级联查询等。

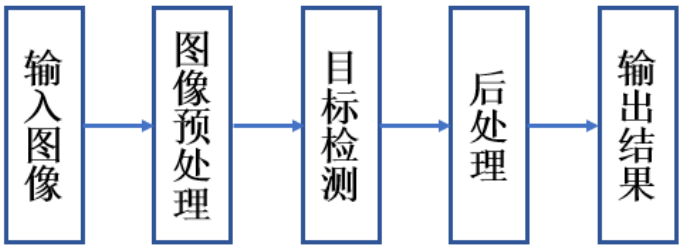


图 4-6 查询机制流程图

以 RetinaNet 为例，在这样的单阶段目标检测算法中，查询过程是通过神经网络的前向传播来实现。查询的基本步骤如图 4-6 所示：

首先，将用户提供的待检测的图像作为模型查询的输入图像。为了符合模型的要求需要对输入图像进行必要的预处理，该预处理一般包括调整图像大小和像素值的标准化等操作。

其次，将预处理后的图像输入网络模型进行前向传播。通过模型的神经网络层和从底层到顶层的特征金字塔，提取图像中的语义特征。模型会在每个特征金字塔层生成一组锚框作为模型用于检测目标的候选框，锚框以不同的尺度和宽高比设计，以适应不同大小和形状的目标。对于每个锚框，模型执行目标分类和边界框回归的任务，目标分类阶段输出目标类别的概率，而边界框回归阶段调整锚框的位置以更好地匹配目标的实际位置。

最后，进行一些后处理步骤，例如应用非极大值抑制（NMS）。对模型输出的目标框应用 NMS 操作，以去除高度重叠的冗余框，确保每个目标只有一个最终的检测结果，最终输出被选中的目标框及其对应的类别概率，这整个过程构成了目标检测在输入图像中进行目标检测的查询机制。需要注意的是，这一过程是在模型的前向传播中隐含进行的，而没有显式的查询生成步骤。查询机制是目标检测模型在实际应用中的关键阶段，能将训练好的模型应用到新的数据上，以获得模型对目标的检测结果，对于实时目标检测、视频分析等有着重要意义。

查询方法也可以根据任务的具体需求和模型的特性有所异同，如查询任务不同，查询方法可以分为：单图像查询、批量查询、视频查询和实时查询等。如查询模型的特性不同，查询方法可以分为：多尺度查询、增量查询、级联查询、增量查询、远程查询等。以下是一些常见的目标检测中的查询方法简单概述：

单图像查询：目标检测模型被应用于一张图像，以检测并定位图像中的目标，这是目标检测任务中最基本的查询形式。

批量查询：在某些场景下，可能需要一次性查询多个图像或视频帧，这种情况下，批量查询方法可以有效提高查询效率，通过并行处理多个输入来减少总体查询时间。

视频查询：对视频进行目标检测时，查询方法需要涉及时间顺序。如将目标检测用于视频每一帧检测目标，以获取每一帧中目标的类别和位置信息。此外，还可以使

中国知网 https://www.cnki.net

用目标跟踪技术，通过时序信息将视频中前一帧的检测结果作为当前帧的先验信息来增强检测。

实时查询：在实时查询中，目标检测模型需要在实时输入流上实时执行。这要求查询方法能够在极短的时间内生成目标检测结果，以适应实时应用的需求。

多尺度查询：对于不同尺度的目标，多尺度查询方法能够使模型对不同尺度的目标具有良好的检测性能。常见于通过特征金字塔以实现在输入数据的不同尺度上执行目标检测。

增量查询：在增量学习场景中，模型可能需要通过查询新数据来进行在线学习。这可以通过将新数据引入到模型中，并对模型的参数进行微调或在线更新来实现。

级联查询：通过级联多个目标检测器，逐步提高检测的准确性。这个策略的目标是通过串联多个检测阶段，过滤掉更多的负样本，提高模型对正样本的准确性，特别是在面对难以检测的情况时。

有监督查询和无监督查询：有监督查询是指使用有标签的数据进行监督学习任务的目标检测。无监督查询可以对没有标签的数据进行目标检测，并根据模型的输出进行后续分析。

远程查询：在一些分布式场景中，可以使用远程查询将目标检测任务分布到不同的计算节点或设备上，以实现大规模的目标检测。

这些查询方法根据不同的应用场景，模型性能和任务需求，可以选择合适的方法来实现目标检测。

4.3 QS-RetinaNet 模型概述

对小目标检测在的低分辨率特征图像中存在小目标信息丢失、低层特征图像中存在检测小目标计算成本较大等问题，本文提出一种基于级联查询的高分辨率稀疏小目标检测算法。

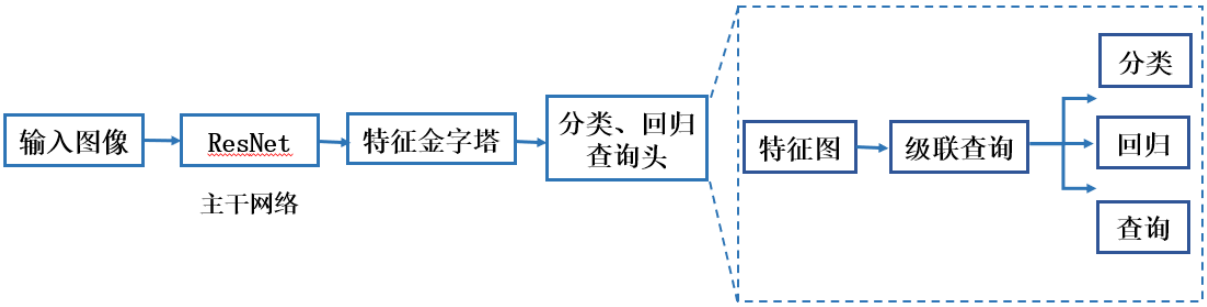


图 4-7 QS- RetinaNet 模型流程

QS-RetinaNet 算法流程如图 4-7 所示。本文为解决小目标在高级特征图中有效特征较少的问题，在 RetinaNet 中重用 CNN 不同层的多尺度特征图，添加额外的金字塔级别来构建特征金字塔，增强特征金字塔对小目标有效特征的提取能力。其次，为解决低级特征图中小目标分布稀疏导致的计算冗余问题，提出一种级联特征金字塔多层级特征的查询机制，通过高级特征图的位置信息指导低级特征图的小目标检测，减少在高分辨率特征图中小目标检测的计算冗余，增加小目标特征在特征融合过程中的权重，

中国知网 https://www.cnki.net

加快小目标检测结果的计算。最后，为解决小目标检测在不同层损失权重不平衡的问题，提高分类、回归和查询头的预测精度，本文采用基于 FocalLoss 的查询头，减少负样本数量，平衡不同层计算正负样本损失的权重。

4.4 方法设计

RetinaNet 是一种广泛使用的目标检测模型，在小目标检测方面有着不错的表现。然而小目标检测仍然存在目标与背景相似，大小不一，易受遮挡和噪声影响等问题，为了提高小目标检测效果，本文还需要一些改进措施。

一种方法是通过修改特征金字塔增加特征图中的有效信息。小目标检测可以通过缩放输入图像的大小或降低卷积的下采样率来保持特征图的高分辨率，较高的分辨率特征图能保存更详细的细节信息，从而增加特征图中小目标的有效分辨率。然而，仅仅为了获取有效信息而增高特征图分辨率，目标检测过程会产生相当大的计算成本。

另一种方法是结合小目标分布稀疏的特点引入级联查询机制，利用上下文信息在计算复杂度增加的情境下节约计算成本。级联查询可以先通过一个快速的目标检测器对目标进行初步检测，然后使用一个相对较慢但更准确的目标检测器对初步检测中的潜在目标区域进行二次检测。级联查询的优势在于能够通过多个阶段的过滤来提高整体的检测准确性，特别是在面对具有挑战性的场景或小目标的情况下检测，但是因为需要执行多个检测阶段，所以会增加计算成本和推理时间。本文将级联查询机制与小目标的空间分布非常稀疏的特性相结合，先通过级联查询第一阶段确定小目标粗略位置，而后在级联查询第二阶段精确识别目标，在提高整体检测准确性的同时降低小目标检测的计算量。

4.4.1 特征金字塔的改进

传统方法中，不同尺度的目标在不同级别上进行处理，这使得大目标往往在低分辨率特征上被检测到，而小目标通常在高分辨率特征上被检测到。目标检测领域常用特征金字塔来构建一组具有不同分辨率的特征图，以适应不同尺度目标的检测。一些学者提出通过重用卷积神经网络主干中不同层的多尺度特征图构建特征金字塔来增加小目标检测过程中的高分辨率图像特征，以解决在下采样过程中小目标特征消除的问题。特征金字塔提供了低分辨率到高分辨率多尺度特征，同时节省了在主干网中从低到高使用多尺度分辨率特征图的计算成本。因此，本文选择在 RetinaNet 中添加额外的金字塔级别，以增加小目标检测中的高分辨率特征图。但随着图像分辨率的增加计算量也相应增加，数据显示如果单纯增加特征金字塔层数，小目标检测头将增加约 3 倍的计算量。为了在使用高分辨率特征图的基础上节约计算成本，本文根据特征金字塔的特性对检测方式做出一点改良。

考虑到特征金字塔高度结构化的特性，尽管在低分辨率特征图中本文无法准确检测小目标，但仍然可以较为准确地推断小目标的存在和其潜在的目标区域。同时我们观察到大多数情况下小目标的空间分布非常稀疏，这使得本文在高分辨率特征图上提

中国知网 https://www.cnki.net

取小目标特征时会浪费相当多的计算量在没有小目标的区域。综合两种特性，我们自然想到在低分辨率图中检测小目标大概位置，而在高分辨率图中准确识别小目标。我们将这样的想法应用在 RetinaNet 网络，如图 4-7，在 QS-RetinaNet 网络中，由输入图像得到符合小目标预测标准的特征图需要经过两部分：由 ResNet-50 作为主干网络，输出多尺度特征图；将多尺度特征图在 FPN 中进行特征融合，得到具有较高分辨率和较丰富语义信息的多尺度特征图像。假设输入图像的尺寸为$H \times W$时，FPN 特征图的尺寸P随特征金字塔级别l逐层变换，即$P = \{P_l \in R^{H' \times W' \times C}\}$。这里$(H', W')$通常等于$\left(\left\lfloor \frac{H}{2^l} \right\rfloor, \left\lfloor \frac{W}{2^l} \right\rfloor\right)$。检测头由四个 3×3 卷积层组成，除了分类，回归和查询，还有一个额外的 3×3 卷积层用于预测。

4.4.2 级联查询加速计算

由 4.2.2 可知，因为高分辨率特征图可以观察到更多细节信息，几何细节信息表征能力强，所以更适合注重细节而缺少语义信息的小目标检测模型。但小目标在图像空间中常表现出聚集和稀疏分布的特点，而高分辨率图像需要大量的内存进行计算，密集的计算范式会降低算法性能。因此，考虑到小目标在特征图中具有稀疏分布和像素占比低的特点，本文提出了一种基于级联查询的方法，利用上下文信息通过定位辅助检测来降低高分辨率特征图的计算成本，该方法需要在高级低分辨率的特征图上先进行预测，大概定位小目标并快速筛选出潜在的目标区域，然后准确计算低级高分辨率特征图上相应位置的小目标，更精确地定位和识别目标。这个过程可以看作是一个级联查询过程：第一阶段粗略地查询小目标大致位置，输出结果为查询键；第二阶段使用上一级第一阶段的位置结果辅助查询下级特征图，更精确地识别小目标高分辨率特征，输出结果为查询值；最后对查询后的特征图进一步预测，得到分类、回归和新的查询特征，并将查询的关键位置集作为下一级的查询键。具体情况如下。

为了预测高层特征图中小目标的潜在目标区域，本文添加了一个与分类子网络和回归子网络并行的查询子网络。查询头接收 FPN 融合后的预测特征图P_l作为输入，步幅为2^l，并输出热图$V_l \in R^{H' \times W'}$，其中$V_l^{n,m}$表示在网格中(n, m)位置存在小目标的概率。在训练过程中，本文将每个层级上的小目标尺度定义为小于预定义阈值s_l的目标，并设s_l为P_l上中心点的最小回归范围。为了计算小目标中心位置与特征图上每个位置之间的距离，我们设小目标 a 的中心位置为(x_a, y_a)，并通过计算结果编码查询头的特征图。若小目标中心位置与特征图上每个位置之间的距离小于预定义的阈值s_l，则设该位置为 1，否则为 0。

然后，设小目标 a 在预测特征图P_l上的查询为q，将预测分数大于α位置设为q_l^a。将编码后的查询结果映射到下一层特征图P_{l-1}上的四个最近邻，得到小目标 a 在P_{l-1}层的关键位置$\{k_{l-1}^a\}$。综合第P_{l-1}层上的所有关键位置，得到集合$\{k_{l-1}\}$。小目标 a 在$l-1$层的关键位置$\{k_{l-1}^a\}$计算方式如下：

$$\{k_{l-1}^a\} = \{(2x_l^a + n, 2y_l^a + m), \forall \mathrm{n}, \mathrm{m} \in \{0,1\}\}, \tag{4-1}$$

最后，为了构建稀疏矩阵P_{l-1}^v得到值特征作为查询的位置信息，我们将P_{l-1}层上的

中国知网 https://www.cnki.net

关键位置集合作为索引从该层提取特征。使用稀疏卷积核 spconv×4 计算$l-1$层的结果，如图 4-8，通过关键位置信息对特征图上的相应特征进行分类，回归和查询检测，并计算下一层查询。

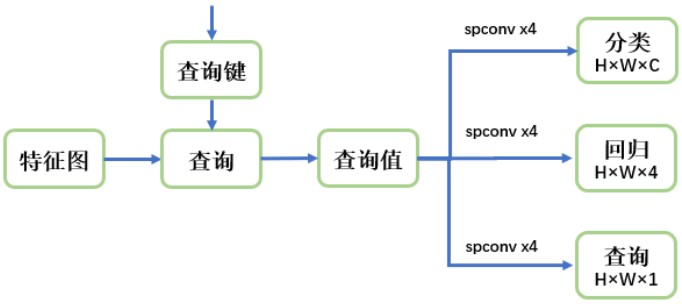


图 4-8 级联查询

为了最大限度地提高推理速度，本文采用级联查询方式。如对P_{l-2}的查询只能从$\{k_{l-1}\}$生成，通过利用上下文的信息指导查询。这种方法可以避免从单个特征图中直接生成检测结果，同时查询键限制了下层特征中相应关键位置的数量随着层级的降低呈现指数增加。

4.4.3 改进后的 QS-RetinaNet 模型训练

对小目标检测在的低分辨率特征图像中存在小目标信息丢失，低层特征图像中存在检测小目标计算成本较大等问题，本文提出一种基于级联查询的高分辨率稀疏小目标检测算法。

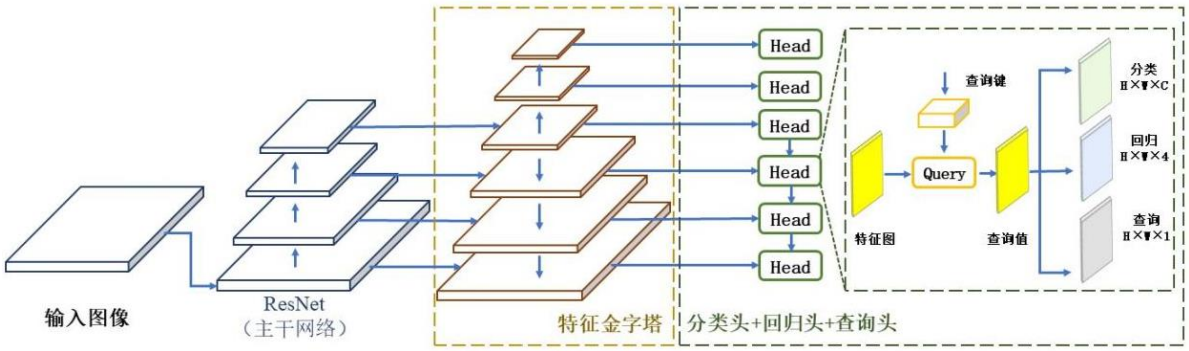


图 4-9 QS-RetinaNet 网络模型

QS-RetinaNet 网络模型如图 4-9 所示，本文参考最初的 RetinaNet 模型训练方式训练分类和回归子网络，使用 FocalLoss 和二进制编码的查询目标图训练与回归头并行的查询子网络：为了计算P_l上每个位置(x,y)与所有小目标中心位置在特征图上对应的真实值位置之间的最小距离矩阵D_l，设第l层预测特征图上的小目标对应的真实值为$gt_l=(x_l^g,y_l^g,w_l^g,h_l^g)$，$D_l$的计算公式如下：

$$D_l[x][y]=\min_g\left\{\sqrt{\left(x-x_l^g\right)^2+\left(y-y_l^g\right)^2}\right\}, \tag{4-2}$$

那么真实值查询图V_l^*定义为：

$$V_l^*[x][y]=\begin{cases}1, D_l[x][y]<s_l\\0, D_l[x][y]\geq s_l\end{cases}, \tag{4-3}$$

中国知网 https://www.cnki.net

对于每个级别P_l，损失函数定义如下：

$$L_l(U_l, R_l, V_l) = L_{FL}(U_l, U_l^*) + L_r(R_l, R_l^*) + L_{FL}(V_l, V_l^*), \quad (4\text{-}4)$$

其中U_l，R_l，V_l分别是分类输出、回归器输出和查询分数输出，U_l^*，R_l^*和V_l^*是它们对应的 GT 图；L_{FL}是焦点损失（**Focal Loss**），L_r是边界框回归损失。总的损失函数为：

$$L_{all} = \sum_l \beta_l * L_l, \quad (4\text{-}5)$$

为了防止当模型中加入更高分辨率特征时训练样本的分布发生明显变化，本文通过β_l重新平衡每层的损失。原因是高分辨率特征图中会产生过多的训练样本，极大影响对高层特征图的样本学习。本文通过β_l降低高分辨率特征图像的权重，可以平衡训练时小目标样本的选取权重，使模型更多地关注低分辨率特征图。

4.5 实验及结果分析

本章的研究内容是针对单阶段目标检测模型中的 RetinaNet 目标检测算法进行改进，使其能提升对小目标的检测效果。在特征提取方面，在特征金字塔中添加额外的金字塔级别P_2，并且通过由粗略位置到精确检测的级联查询引导加速基于特征金字塔的目标检测器的推理速度。

本章实验环境为 Ubuntu 操作系统，CPU 为 Intel®Core™ i7-12700 CPU@2.30 GHz，内存为 16GB。GPU 为 NVIDIA GeForce RTX 3090，显存为 8 GB，内存大小为 16 GB。使用 PyTorch 深度学习框架和 Python 编程语言进行 RetinaNet 模型的实现和优化。同时，使用 CUDA11.3.1 和 CUDNN8.2.1 对 GPU 进行加速。

4.5.1 实验设置

表 4-1 QS-RetinaNet 实验参数设置

参数名	参数值	说明
Weight decay	0.0001	防止模型过拟合的正则化项
Batch size	16	每次迭代中使用的样本数
Leaning rate	0.01	控制模型参数更新的步长
Epochs	50	模型训练的总轮数

在进行小目标检测算法改进的实验时，需要设置实验参数，以便对算法性能进行评估和比较，

COCO 数据集具备了大规模的图像和丰富的标注，其包含了多种复杂场景中的目标，有助于模型学习更丰富的视觉特征，是当前目标检测领域数据集的权威和标杆。这个数据集以 scene understanding 为目标，是一个大型的、丰富的目标检测数据集，其主要从复杂的日常场景中截取，图像中的目标通过精确的分割进行位置的标定。图像包括 328,000 影像和 2,500,000 个标签，提供的类别有 80 类，有超过 33 万张图片，其中 20 万张有标注，整个数据集中个体的数目超过 150 万个。

VisDrone2019 数据集具备了大规模的图像和丰富的标注，其包含了多种复杂场景中的目标，有助于模型学习更丰富的视觉特征，是当前小目标检测领域的热门数据集。

中国知网 https://www.cnki.net

该数据集由天津大学机器学习和数据挖掘实验室 AISKYEYE 团队收集，是一个大型的、丰富的目标检测数据集，其数据主要由无人机摄像头捕获。提供的类别有 10 类，图像包括 261908 帧影像，10209 幅静态图像和超过 260 万个标签。VisDrone2019 数据集因为训练效率高、标注信息丰富等优势，作为本文第三章的实验数据集。该数据集同时也兼具语义特征丰富、正负样本均衡和场景复杂更适合现实生活的优点。综上所述，在本章的实验中，仍然决定用 VisDrone2019 数据集作为主要的实验数据集。

4.5.2 本文模型与经典模型对比结果分析

表 4-2 本章模型在 VisDrone2019 数据集上改进前后对比

模型	骨干网络	有无改进	mAP	FPS
Faster R-CNN	ResNet-50	无	31.1	38
YOLOv5	ResNet-50	无	33.5	42
RetinaNet	ResNet-50	无	29.3	35
QS-RetinaNet	ResNet-50	有	35.8	46

为了验证本文算法的有效性及先进性，将本文算法模型 QS-RetinaNet 与 Faster R-CNN 以及 YOLOv5 的算法模型进行对比。其中 Faster R-CNN 为 2015 年提出的经典的目标检测算法；YOLOv5 是 2020 年发布的一种快速且高效的目标检测算法。本章实验通过与该模型进行指标对比，显示出本文算法的有效性。

由表 4-2 的实验结果可看出，本文模型均优于所比较模型。相对于改进前的 RetinaNet 来说，本文模型在平均精度跟检测速度评价指标数值上分别提升了 22.1%和 31.4%；相较于 Faster R-CNN 和 YOLOv5 而言，mAP 指标平均提升了 11.0%，FPS 指标平均提升了 15.2%。本次实验表明了，本章添加额外的金字塔级别来构建特征金字塔，提高特征图中小目标的有效分辨率，增强特征金字塔对小目标特征的提取能力可以使平均精度指标 mAP 有效提升。在运算速度 FPS 方面，提出一种级联特征金字塔多层级特征的查询机制，通过高级特征图的位置信息指导低级特征图的小目标检测，减少在高分辨率特征图中小目标检测的计算冗余，使得指标提升总体而言，本文模型在对比实验中均取得了最好的效果。

4.5.3 消融实验分析

表 4-3 QS-RetinaNet 消融实验结果

模型	骨干网络	有无改进	mAP	FPS
RetinaNet	ResNet-50	无	29.3	35
(A)FPN	ResNet-50	无	33.9	31
(B)CSQ	ResNet-50	无	29.1	43
(C)QS-RetinaNet	ResNet-50	有	35.8	46

为了能够更加深入地分析模型网络结构，明确每个改进点的效果以及必要性，本文对二维高斯分布建模、高斯距离样本分配度量和分层标签分配策略三个改进分别进行了 A-C 共三个消融实验，其中 RetinaNet 为本文的基线模型，FPN 表示本章第一个改进点：特征金字塔的改进；CSQ 表示本章第二个改进点级联查询加速计算；QS-

中国知网 https://www.cnki.net

RetinaNet表示同时加入两个改进点。因为本实验在VisDrone2019、TinyPerson和COCO数据集中实验结果的趋向性是一致的，所以本文以更适合作为指标分析的VisDrone2019数据集的实验结果为本文的分析对象。实验结果如表4-3所示：

通过对 VisDrone2019 数据集的实验分析可得到结论：实验（**A**）进行了特征金字塔的改进后，相对于基线模型RetinaNet来说，平均精度mAP提升了15.6%。实验结果表明，添加额外的金字塔级别来构建特征金字塔，提高特征图中小目标的有效分辨率，增强特征金字塔对小目标特征的提取能力，从而使得精度指标提升。然而，重用卷积神经网络主干中不同层的多尺度特征图势必会使得数据量也相应地增加，由于直接重用主干网络的高分辨率图节省了上采样的计算成本，所以体现出来的检测速度指标FPS与基线网络相比下降。

实验（**B**）进行了级联查询加速计算后，相对于基线模型 RetinaNet 来说，检测速度FPS提升了22.9%。实验结果表明，该改进通过高级特征图的位置信息指导低级特征图的小目标检测，减少在高分辨率特征图中小目标检测的计算冗余，增加小目标特征在特征融合过程中的权重，加快小目标检测结果的计算，从而使得检测速度指标 FPS显著提升。但相较于实验（**A**）来说，精度指标下降了 14.1%，从而知道当只进行级联查询加速计算改进时，仅仅通过优化基于 FocalLoss 的查询损失函数来平衡不同层的损失，调整正负样本权重，无法最大程度得提升模型对精度的提升。

实验（**C**）结合了本章的两个改进点，相对于基线模型 RetinaNet 来说，平均精度mAP和检测速度FPS分别提升了22.1%，31.4%。在融合前两个创新点之后，模型无论从精度方面或是检测速度方面，指标均大幅提升，同时也是所有消融实验中指标最高的。实验结果表明，本章两个创新均对本文模型的小目标识别效果起到正反馈作用。

4.5.4 可视化结果分析

为了更直观得观察本文提出的算法模型检测效果，本节选用模型检测后的各类结果图片做可视化分析，具体如下所示：



图4-10 针对小目标检测在高级特征图中有效分辨率较少的改进结果可视化

中国知网 https://www.cnki.net

针对小目标检测在高级特征图中有效分辨率较少的问题，本文在 RetinaNet 中重用 **CNN** 不同层的多尺度特征图，添加额外的金字塔级别来构建特征金字塔，增强特征金字塔对小目标有效特征的提取能力。如图 4-10 所示，图像中能够检测出的最小目标对象和最小目标数量都很充分，本文模型在高级特征图中既提取了更丰富的语义信息，同时对细节信息的关注度并未降低，高级特征图中的有效分辨率较高。

4.6 本章小结

本章主要研究了 QS-RetinaNet 小目标的检测方法，在 RetinaNet 中重用 CNN 不同层的多尺度特征图，添加额外的金字塔级别来构建特征金字塔，提高特征图中小目标的有效分辨率，增强特征金字塔对小目标特征的提取能力。其次提出一种级联特征金字塔多层级特征的查询机制，通过高级特征图的位置信息指导低级特征图的小目标检测，减少在高分辨率特征图中小目标检测的计算冗余，增加小目标特征在特征融合过程中的权重，加快小目标检测结果的计算。优化基于 FocalLoss 的查询损失函数，平衡不同层的损失，调整正负样本权重，增加小目标模型对整个特征金字塔的关注度，提高边界框回归精度。

实验表明 QS-RetinaNet 有效地提升模型对小目标的检测效果。通过对比实验验证了改进方法的可行性。在原有 RetinaNet 基础上添加的高分辨率特征图像能够有效提升目标检测性能，再使用改进后的级联查询模块能进一步提升检测精度，提高目标物体识别速度。实验结果表明，本章提出的改进方法在小目标检测方面具有很好的应用价值，对于深度学习在目标检测领域的发展和应用具有一定的参考意义。

中国知网 https://www.cnki.net

第五章 结论与展望

随着人工智能技术的不断发展和进步，目标检测成为计算机视觉领域的一项重要任务，旨在于图像中准确地检测出目标位置，并为每个目标分配正确的类别标签。小目标检测作为目标检测任务中的重难点问题，近年来受到人工智能和计算机视觉领域的广泛关注，成为当下的一个重要研究课题。但是，目前的目标检测技术在小目标检测方面还存在着以下问题：小目标检测中基于 IoU 阈值的方法中对位置偏差非常敏感问题；标签分配存在样本分配不平衡的问题；低分辨率特征图中小目标有效分辨率较少，高分辨率级特征图中小目标分布稀疏，存在高分辨率特征图计算量冗余的问题。本文针对以上问题分别提出了 EGDA-RetinaNet 和 QS-RetinaNet 算法模型，并完成了相关的验证性实验。本文获得的主要成果如下：

（1）针对基于 IoU 阈值的方法中对位置偏差非常敏感问题，本研究在 RetinaNet 中引入有效感受野的概念，根据感受野有效性服从高斯分配的特点，对特征金字塔图像的特征点构建二维高斯分布建模，直接获得样本分配度量，加强检测算法对有效小目标特征的提取。

（2）针对标签分配存在样本分配不平衡的问题，本研究采用有效感受野与真实值概率分布区域之间的高斯距离作为度量标准，提高了小目标检测的准确性。通过计算特征点有效距离进行样本排序，引入分配特征掩码以减少低质量样本，提高小目标样本选取有效性，增强小目标检测性能。

（3）针对小目标在低分辨率特征图中有效分辨率较少，在高分辨率特征图中小目标分布稀疏导致的计算冗余问题，本研究重用 CNN 不同层的多尺度特征图，添加额外的金字塔级别来构建特征金字塔。提出在 RetinaNet 中使用级联特征金字塔多层级特征的查询机制，通过高级特征图的位置信息指导低级特征图的小目标检测，减少在高分辨率特征图中小目标检测的计算冗余，增加小目标特征在特征融合过程中的权重，加快小目标检测结果的计算。

（4）针对小目标检测在不同层损失权重不平衡，样本分配不均的问题，本研究采用基于 FocalLoss 的查询头，平衡不同层计算正负样本损失的权重，减少低质量样本的数量。

在基于高斯有效距离和样本分层分配的小目标检测算法中，相对于基线模型本文模型在平均精度评价指标数值上提升了 24%。在基于级联查询的高分辨率稀疏小目标检测算法中，相对于基线模型本文模型在平均精度跟检测速度评价指标数值上分别提升了 22.1%，31.4%。

本文还存在以下可以改进的展望：

（1）本文的改进算法面对的对象主要是无人机视觉应用的数据集，然而在现实生活中小目标对象出现的频率和种类更多、更隐蔽且更复杂。因此在未来的研究中，可以尝试将小目标检测算法用于检测与现实生活更接近的目标，引入多种判断指标，根据指标高低进行针对性改进，提高小目标检测算法模型的泛化能力。

中国知网 https://www.cnki.net

（2）本文的小目标检测算法主要应用在二维图像上，如今三维点云、SLAM、3D 视觉等关于立体物体的机器视觉方向成为了研究的前沿。本文的下一步工作可以将小目标检测算法用于三维点云等前沿方向，在三维视觉领域也能精准检测出小目标物体。

（3）本文的方法可能存在对不同数据类型适应性不足的问题，特别是当面对多样化的目标类型或复杂环境时，单一的二维高斯分布建模可能无法完美适应每种情况。为了进一步提高方法的适应性，本文考虑在未来的研究中采用数据增强技术，增加不同环境下的数据样本，提升方法的鲁棒性。

（4）本文的方法以无人机图像分析为重点，在未来的研究中可以将方法思路延伸到其他视觉领域，如智能交通、智慧医疗、卫星图像等。虽然这些领域面临不同的挑战，例如医学影像的高分辨率和背景噪声，卫星图像的尺度差异和复杂背景，但通过对现有方法进行适当的调整和优化，仍然具有一定应用潜力。

中国知网 https://www.cnki.net

参考文献

[1] 李翔, 何淼, 罗海波. 一种面向遮挡行人检测的改进 YOLOv3 算法[J]. 光学学报, 2022, 42(14): 152-161.

[2] 袁翔, 程塨, 李戈, 等. 遥感影像小目标检测研究进展[J]. 中国图象图形学报, 2023, 28(6): 1662-1684.

[3] Girshick R, Donahue J, Darrell T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation[C]. Proceedings of the IEEE Conference On Computer Vision And Pattern Recognition. Columbus, USA: IEEE, 2014: 580-587.

[4] Girshick R. Fast R-CNN[C]. 2015 IEEE International Conference on Computer Vision (ICCV). Santiago, Chile: IEEE, 2015: 1440-1448.

[5] Ren S, He K, Girshick R, et al. Faster R-CNN: Towards real-time object detection with region proposal networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2015, 39(6): 1137-1149.

[6] Bochkovskiy A. Yolov4: Optimal speed and accuracy of object detection[J]. arXiv preprint arXiv:2004.10934, 2020.

[7] Wang C Y, Bochkovskiy A, Liao H Y M. YOLOv7: Trainable bag-of-freebies sets new state-of-the-art for real-time object detectors[C]. Proceedings of the IEEE/CVF Conference On Computer Vision And Pattern Recognition. Boston, USA: IEEE, 2023:7464-7475.

[8] Ge Z, Liu S, Wang F, et al. Yolox: Exceeding yolo series in 2021[J]. arXiv preprint arXiv:2107.08430, 2021.

[9] Liu W, Anguelov D, Erhan D, et al. Ssd: Single shot multibox detector[C]. Computer Vision–ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11–14, 2016, Proceedings, Part I 14. Springer International Publishing, 2016: 21-37.

[10] Wang J, Yang W, Guo H, et al. Tiny object detection in aerial images[C].2020 25th International Conference On Pattern Recognition (ICPR). Milan, Italy: IEEE, 2021: 3791-3798.

[11] Dalal N, Triggs B. Histograms of oriented gradients for human detection[C].2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR'05). San Diego, CA: IEEE, 2005: 886-893.

[12] Lowe D G. Distinctive image features from scale-invariant keypoints[J]. International Journal Of Computer Vision, 2004, 60: 91-110.

[13] Oyallon E, Rabin J. An analysis of the SURF method[J]. Image Processing on Line, 2015, 5: 176-218.

[14] Viola P, Jones M. Rapid object detection using a boosted cascade of simple features[C]. Proceedings Of The 2001 IEEE Computer Society Conference on Computer Vision And Pattern Recognition. Kauai, HI: IEEE, 2001: 1-6.

[15] Pang Y, Yuan Y, Li X, et al. Efficient HOG human detection[J]. Signal processing, 2011, 91(4): 773-781.

[16] Felzenszwalb P F, Girshick R B, McAllester D, et al. Object detection with

中国知网 https://www.cnki.net

discriminatively trained part-based models[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2009, 32(9): 1627-1645.

[17] Law H, Deng J. Cornernet: Detecting objects as paired keypoints[C]. Proceedings of The European Conference On Computer Vision (ECCV). Munich, Germany: IEEE, 2018: 734-750.

[18] Duan K, Bai S, Xie L, et al. Centernet: Keypoint triplets for object detection[C]. Proceedings Of The IEEE/CVF International Conference On Computer Vision. Seoul, Korea: IEEE, 2019: 6569-6578.

[19] Li Z, Yang L, Zhou F. FSSD: feature fusion single shot multibox detector[J]. arXiv preprint arXiv:1712.00960, 2017.

[20] Liu S, Huang D. Receptive field block net for accurate and fast object detection[C]. Proceedings Of The European Conference On Computer Vision (ECCV). Munich, Germany: IEEE, 2018: 385-400.

[21] Zhang S, Wen L, Bian X, et al. Single-shot refinement neural network for object detection[C]. Proceedings Of The IEEE Conference On Computer Vision And Pattern Recognition. Salt Lake City: IEEE, 2018: 4203-4212.

[22] Lin T Y, Dollár P, Girshick R, et al. Feature pyramid networks for object detection[C]. Proceedings Of The IEEE Conference On Computer Vision And Pattern Recognition. Honolulu, Hawaii: IEEE, 2017: 2117-2125.

[23] Liu S, Qi L, Qin H, et al. Path aggregation network for instance segmentation[C]. Proceedings Of The IEEE Conference On Computer Vision And Pattern Recognition. Salt Lake City: IEEE, 2018: 8759-8768.

[24] Ghiasi G, Lin T Y, Le Q V. Nas-fpn: Learning scalable feature pyramid architecture for object detection[C]. Proceedings Of The IEEE/CVF Conference On Computer Vision And Pattern Recognition. Long Beach, CA: IEEE, 2019: 7036-7045.

[25] Tan M, Pang R, Le Q V. Efficientdet: Scalable and efficient object detection[C]. Proceedings Of The IEEE/CVF Conference On Computer Vision And Pattern Recognition. Seattle, USA: IEEE, 2020: 10781-10790.

[26] Fu C Y, Liu W, Ranga A, et al. Dssd: Deconvolutional single shot detector[J]. arXiv preprint arXiv:1701.06659, 2017.

[27] Huang G, Liu Z, Van Der Maaten L, et al. Densely connected convolutional networks[C]. Proceedings of the IEEE Conference On Computer Vision And Pattern Recognition. Honolulu, Hawaii: IEEE, 2017: 4700-4708.

[28] Xu H, Jiang C H, Liang X, et al. Reasoning-rcnn: Unifying adaptive global reasoning into large-scale object detection[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Long Beach, CA: IEEE, 2019: 6419-6428.

[29] Lim J S, Astrid M, Yoon H J, et al. Small object detection using context and attention[C]. 2021 International Conference on Artificial Intelligence in Information and Communication (ICAIIC). Jeju Island, Korea (South): IEEE, 2021: 181-186.

[30] Han J, Ding J, Li J, et al. Align deep features for oriented object detection[J]. IEEE Transactions On Geoscience And Remote Sensing, 2021, 60: 1-11.

中国知网 https://www.cnki.net

[31] Ou J, Wang J, Xue J, et al. Infrared image target detection of substation electrical equipment using an improved faster R-CNN[J]. IEEE Transactions on Power Delivery, 2022, 38(1): 387-396.

[32] Du D, Zhu P, Wen L, et al. VisDrone-DET2019: The vision meets drone object detection in image challenge results[C]. Proceedings Of The IEEE/CVF International Conference on Computer Vision Workshops. Seoul, Korea (South): IEEE, 2019: 213-226.

[33] Zhang H, Cisse M, Dauphin Y N, et al. mixup: Beyond empirical risk minimization[J]. arXiv preprint arXiv:1710.09412, 2017.

[34] Yun S, Han D, Oh S J, et al. Cutmix: Regularization strategy to train strong classifiers with localizable features[C]. Proceedings Of The IEEE/CVF International Conference on Computer Vision. Seoul, Korea: IEEE, 2019: 6023-6032.

[35] DeVries T, Taylor G W. Improved regularization of convolutional neural networks with cutout[J]. arXiv preprint arXiv:1708.04552, 2017.

[36] Oh J, Yun C. Provable benefit of cutout and cutmix for feature learning[C]. 2nd Workshop on High-Dimensional Learning Dynamics. Vancouver, Canada: IEEE, 2024: 1-82.

[37] Lin T Y, Maire M, Belongie S, et al. Microsoft coco: Common objects in context[C]. Computer Vision–ECCV 2014: 13th European Conference, Zurich, Switzerland, September 6-12, 2014, Proceedings, Part V 13. Springer International Publishing, 2014: 740-755.

[38] Redmon J, Divvala S, Girshick R, et al. You only look once: Unified, real-time object detection[C]. Proceedings of the IEEE Conference on Computer Vision And Pattern Recognition. Las Vegas, NV: IEEE, 2016: 779-788.

[39] Ross T Y, Dollár G. Focal loss for dense object detection[C]. proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 2980-2988.

[40] Tian Z, Shen C, Chen H, et al. FCOS: Fully convolutional one-stage object detection. arXiv 2019[J]. arXiv preprint arXiv:1904.01355, 2019.

[41] Yang Z, Liu S, Hu H, et al. Reppoints: Point set representation for object detection[C]. Proceedings of the IEEE/CVF international conference on computer vision. 2019: 9657-9666.

[42] Everingham M, Eslami S M A, Van Gool L, et al. The pascal visual object classes challenge: A retrospective[J]. International Journal of Computer Vision, 2015, 111: 98-136.

[43] Geiger A, Lenz P, Stiller C, et al. The kitti vision benchmark suite[J]. International Journal of Robotics Research, 2015, 2(5): 1-13.

[44] Villani C. Optimal transport: old and new[M]. Berlin: springer, 2009: 93-111.

[45] Kullback S, Leibler R A. On information and sufficiency[J]. The Annals of Mathematical Statistics, 1951, 22(1): 79-86.

[46] Bishop C M. Pattern recognition and machine learning[J]. Springer Google Schola, 2006, 2: 1122-1128.

[47] Paszke A, Gross S, Massa F, et al. Pytorch: An imperative style, high-performance deep learning library[C]. Proceedings of the 33rd International Conference on Neural Information Processing Systems. New York: ACM, 2019: 8026-8037.

中国知网 https://www.cnki.net

[48] Chen K, Wang J, Pang J, et al. MMDetection: Open mmlab detection toolbox and benchmark[J]. arXiv preprint arXiv:1906.07155, 2019.

[49] Deng J, Dong W, Socher R, et al. Imagenet: A large-scale hierarchical image database[C]. 2009 IEEE Conference On Computer Vision And Pattern Recognition. Miami, USA: IEEE, 2009: 248-255.

[50] Abadi M, Barham P, Chen J, et al. {TensorFlow}: a system for {Large-Scale} machine learning[C]. 12th USENIX symposium on operating systems design and implementation (OSDI 16). Savannah: USENIX, 2016: 265-283.

[51] Tajbakhsh N, Shin J Y, Gurudu S R, et al. Convolutional neural networks for medical image analysis: Full training or fine tuning?[J]. IEEE Transactions On Medical Imaging, 2016, 35(5): 1299-1312.

[52] Jia Y, Shelhamer E, Donahue J, et al. Caffe: Convolutional architecture for fast feature embedding[C]. Proceedings of the 22nd ACM International Conference on Multimedia. New York: ACM, 2014: 675-678.

[53] Voorhees E M, Harman D. TREC: experiment and evaluation in information retrieval[M]. Cambridge: MIT Press, 2005.

[54] Everingham M, Van Gool L, Williams C K I, et al. The pascal visual object classes (voc) challenge[J]. International Journal of Computer Vision, 2010, 88: 303-338.

[55] Kynkäänniemi T, Karras T, Laine S, et al. Improved precision and recall metric for assessing generative models[C]. Proceedings of the 33rd International Conference on Neural Information Processing Systems. New York: ACM, 2019: 3927-3936.

[56] Park D, Kim S. Probabilistic Precision and Recall Towards Reliable Evaluation of Generative Models[C]. Proceedings of the IEEE/CVF International Conference on Computer Vision. Paris, France: IEEE, 2023: 20099-20109.

中国知网 https://www.cnki.net