分类号	
学校代码	10700
学　号	2210321253

西安理工大学

硕士学位论文

（专业学位）

面向森林火情监测的图像检测分割方法研究

何　阳

专 业 类 别：电子信息硕士

工 程 领 域：控制工程

指 导 教 师：张友民　教授

企 业 导 师：张立东　高级工程师

申 请 日 期：2024年6月

中国知网　https://www.cnki.net

论文题目：面向森林火情监测的图像检测分割方法的研究

学科名称：电子信息

研 究 生：何阳　　签 名：_____

指导教师：张友民 教授　　签 名：_____

张立东 高级工程师　　签 名：_____

摘　要

森林是地球的重要组成部分，人们用肺于人来比喻森林于地球，由此可见森林的重要性。但是森林火灾一直威胁着森林环境，当前森林火情监测其他方法存在成本高、早期火情监测难度大等问题。无人机以其灵活、准确及成本低的优点广泛应用于森林火情监测工作。本文以森林火情监测为出发点，以图像检测为方法，开展基于无人机图像的检测和分割方法研究，辅助林业人员识别早期森林火灾并估计森林火灾危害程度，主要内容包括：

（1）针对在地面端准确快速的进行火情检测任务，提出了一种基于 Re-yolo 的森林火情检测方法。该方法利用 Yolov3 目标检测网络进行优化，在主要框架不变的前提下应用参数重构方法、跨阶段部分结构以及 SE 权重注意力模块等优化策略，保证模型检测速度的前提下提升模型对于森林火情检测的准确性。Re-yolo 方法检测速度为 33.8FPS，并且检测精度超过 Yolov3 模型以及 Yolov5-s 等其他目标检测方法。

（2）针对无人机机载计算机算力有限，一般方法无法在无人机监测火情的过程中达到实时监测的问题。本节研究内容目的是设计一种适用于计算能力不强的机载计算机端的深度学习方法，根据这一目的，本文提出了基于 Reyolo-tiny 的轻量化方法，实现在低算力条件下对火情的有效监测。为了增强轻量化后模型的检测能力，先对 Re-yolo 模型进行修改，增强其检测精度。接着通过将增强后 Re-yolo 模型的主干网络替换为轻量化模型，然后通过滤波器剪枝的模型压缩方法对模型进行处理，得到一种基于 Re-yolo 的轻量化方法，提出一种轻量化思路，使得模型对森林火情检测达到实时准确检测的要求。

（3）针对难检测目标检测困难、检测精度不高的问题，提出一种基于查询机制改进的实例分割方法 Query-maskrcnn。对于地面端精确的火情监测任务，在 Maskrcnn 的模型框架下引入基于查询的解码器输出头，并在像素解码器中引入特征对齐模块。该方法在保证检测分割实时性的前提下提高检测分割精度，实验结果最优模型的检测速度为 17.5FPS，基本实现了实时检测分割，平均像素准确率 MPA 值达到 91.8%，超过 Maskrcnn 等方法。

关键词： 森林火情监测；图像目标检测；图像实例分割；轻量化模型；Yolov3；Maskrcnn

*本研究得到国家自然基金重点项目（编号：61833013）资助

中国知网 https://www.cnki.net

Title：RESEARCH ON IMAGE DETECTION SEGMENTATION METHOD FOR FOREST FIRE MONITORING

Major：Electronic Information

Name：Yang HE **Signature:_____**

Supervisor：Prof. Youmin ZHANG **Signature:_____**

Associate Prof. Lidong ZHANG **Signature:_____**

Abstract

Forests are an important part of the earth, and people use lungs to compare forests to the earth, which shows the importance of forests. However, forest fires have always threatened the forest environment, and other methods of forest fire monitoring have problems such as high cost and difficulty in early fire monitoring. UAVs are widely used in forest fire monitoring due to their flexibility, accuracy and low cost. Based on forest fire monitoring and image detection, this paper carries out research on detection and segmentation methods based on UAV images, so as to assist forestry personnel to identify early forest fires and estimate the degree of forest fire hazards, Key features include:

(1) In order to accurately and quickly carry out the fire detection task on the ground side, a forest fire detection method based on Re-yolo was proposed. In this method, the Yolov3 object detection network is used for optimization, and the optimization strategies such as parameter reconstruction method, cross-stage partial structure and SE weight attention module are applied under the premise that the main framework remains unchanged, so as to improve the accuracy of the model for forest fire detection under the premise of ensuring the detection speed of the model. The detection speed of the Re-yolo method is 33.8 FPS, and the detection accuracy exceeds that of the Yolov3 model and other object detection methods such as Yolov5-s.

(2) In view of the limited computing power of the UAV airborne computer, the general method cannot achieve real-time monitoring in the process of UAV fire monitoring. The purpose of this research is to design a deep learning method for airborne computers with low computing power, and according to this purpose, this paper proposes a lightweight method based on Reyolo-tiny to achieve effective fire monitoring under low computing power conditions. In order to enhance the detection ability of the lightweight model, the Re-yolo model was modified to enhance its detection accuracy. Then, by replacing the backbone network of the enhanced Re-yolo model with a lightweight model, and then processing the

*This work was supported by the Key Project of National Natural Foundation of China (No.61833013)

中国知网 https://www.cnki.net

model by the model compression method of filter pruning, a lightweight method based on Re-yolo is obtained, and a lightweight idea is proposed, so that the model can meet the requirements of real-time and accurate detection of forest fires.

(3) In order to solve the problems of difficult object detection and low detection accuracy, an instance segmentation method Query-maskrcnn based on query mechanism was proposed. For the accurate fire monitoring task on the ground side, a query-based decoder output header is introduced under the model framework of Maskrcnn, and a feature alignment module is introduced into the pixel decoder. Under the premise of ensuring the real-time performance of detection segmentation, the detection speed of the optimal model is 17.5FPS, which basically realizes real-time detection segmentation, and the average pixel accuracy MPA value reaches 91.8%, which exceeds the detection accuracy of Maskrcnn.

Keywords: Forest fire monitoring; Image object detection; Image instance segmentation; lightweight model; Yolov3; Maskrcnn

中国知网 https://www.cnki.net

目　录

1 绪论.....1
1.1 研究背景及意义.....1
1.2 国内外研究现状.....3
1.2.1 基于无人机的森林火情监测.....3
1.2.2 基于计算机视觉的传统方法.....5
1.2.3 基于计算机视觉的深度方法.....6
1.3 主要研究内容.....9
1.4 论文组织结构.....10
2 基于 Re-yolo 准确快速的森林火情监测方法.....13
2.1 引言.....13
2.2 Yolov3 目标检测方法.....13
2.2.1 Yolov3 整体结构.....14
2.2.2 Yolov3 特征融合方法.....15
2.2.3 Yolov3 预测方法.....16
2.3 Re-yolo 目标检测方法.....17
2.3.1 Re-yolo 主干网络结构.....17
2.3.2 Re-yolo 基本结构.....19
2.3.3 卷积参数重构后的基本结构.....21
2.3.4 Re-yolo 输出阶段.....24
2.4 实验及结果分析.....25
2.4.1 评价指标.....26
2.4.2 实验数据集的制作.....26
2.4.3 消融实验.....27
2.4.4 对比实验.....28
2.4.5 检测结果.....29
2.5 本章小结.....30
3 基于 Reyolo-tiny 高效实时的轻量化方法.....31
3.1 引言.....31
3.2 增强后 Re-yolo 的整体结构.....31
3.2.1 增强后 Re-yolo 的主干网络.....33
3.2.2 增强后 Re-yolo 的颈部网络.....34
3.2.3 增强后 Re-yolo 的输出头.....35
3.2.4 增强后 Re-yolo 的其它组件.....35
3.3 Re-yolo 的轻量化处理.....36

中国知网　https://www.cnki.net

3.3.1 轻量化模型.....36
3.3.2 模型压缩.....41
3.4 实验准备与评价指标.....44
3.4.1 实验环境设置.....44
3.4.2 实验评估指标.....45
3.5 实验及结果分析.....45
3.5.1 结构重组轻量化实验结果.....45
3.5.2 滤波器剪枝实验结果.....47
3.5.3 检测结果.....49
3.6 本章小结.....50
4 基于实例分割的多火点与遮挡火点监测方法.....53
4.1 引言.....53
4.2 Maskrcnn 实例分割方法.....53
4.2.1 Maskrcnn 整体结构.....55
4.2.2 感兴趣区域对齐.....56
4.3 Query-maskrcnn 实例分割方法.....56
4.3.1 特征融合网络.....57
4.3.2 基于查询机制的解码器.....60
4.3.3 最初的优化思路.....61
4.4 实验数据及评价指标.....62
4.4.1 实验的环境及平台.....62
4.4.2 实验数据集及制作过程.....62
4.4.3 实验评价指标.....63
4.5 实验及结果分析.....63
4.5.1 分割结果.....63
4.5.2 对比试验.....65
4.6 本章小结.....65
5 总结与展望.....67
5.1 总结.....67
5.2 展望.....68
参考文献.....69

中国知网 https://www.cnki.net

1 绪论

1.1 研究背景及意义

森林是自然界重要组成部分，孕育着人类和其它生物，占据陆地生态系统大部分面积。森林拥有维持生命多样性、抵御风尘沙暴、改善土地质量、净化环境等自然界不可缺少的作用，是人类生存与发展的物质前提[1,2]。由于各种原因，每年都有数百公顷的森林发生火情，这无疑给国家和每一个人都带来了巨大的压力。为了扑灭这些火灾，投入了大量的人力、物力、财力，进行后续的善后工作。森林火情不仅严重威胁着生态系统，还对人类经济、基础设施以及人类和动物的生命构成威胁[3,4]。更深入地理解，森林火情的快速对流传播和长期燃烧特性，使得及时控制早期火情成为减少火灾损失的最有效手段。森林火灾对自然生态环境的破坏是毁灭性的，它不仅焚毁了森林，还可能导致土壤侵蚀、水源污染等一系列问题[5]。森林火情对地球环境造成了严重的伤害，在火灾救援中浪费了大量的资源。为了减少森林资源流失，及早发现火灾便显得十分重要，发现火灾的速度越快越好，及时扑灭大火。



（a）澳大利亚森林火灾　（b）亚马逊森林火灾

（c）大兴安岭森林火灾　（d）中国凉山州森林火灾

图 1-1 各国森林大火的相关图片

Fig.1-1 Related pictures of forest fires in various countries

近些年以来，国内外都曾报道出一些严重的森林大火，尽管当地都及时进行了处理，但是森林大火仍对自然界和人类的生命财产造成了极大危害。澳大利亚 2019 年 9 月发生森林大火，根据文章所述，澳大利亚发生的这次森林火情无情的将至少二十三人的生命夺

中国知网 https://www.cnki.net

去，焚毁了至少一千七百座建筑。火情燃烧过的土地至少八万四千平方公里，八万四千平方公里等同七十个纽约，如图 1-1 所示；亚马逊森林大火频发，在二零一九年,亚马逊森林大火数量将达到七点二万起,而这次火灾造成的全球一氧化碳和二氧化碳排放量将明显攀升，不但对人们的身体健康造成了危害，也加重了世界气候变暖，一系列的连带后果将不堪设想。另外此次火灾对周边城市也产生了很大危害,因为周边城市中天空都被黑云所笼罩,且不分黑夜与白天，雨水中也含有由植物燃烧所产生的高毒性化合物,见图 1-1（b）；2018 年 6 月，在内蒙古自治区大兴安岭地区爆发了自然火灾，而火势已经扩散至整个黑龙江省大兴安岭地区，火灾过火面积约 5100 公顷。经调查发现起火原因是雷击造成，如图 1-1（c）；2020 年 3 月，森林火情突发在四川省西昌市。据新闻所述，在救援扑灭这次森林火情过程中，风向与风力突变，导致林业人员及消防员牺牲 19 人。造成各地土地过火面积达 3047.8 公顷，直接经济损失高达 9731.12 万元，如图 1-1（d）所示。

随着人类社会的发展以及自然界的环境变化，森林大火比以往发生的可能性变大，人类越来越关注这个问题，并实施不同方法对森林大火进行预防与监测。随着机械制造业以及人工智能技术的发展，监测森林火情的方式也从以前的人工监测发展到现在的计算机智能监测以及卫星遥感监测。监测森林火情的方法可分为以下五种，其中分别为：人工地面巡逻、人工塔台俯瞰、飞机巡逻、卫星遥感以及无人机与计算机视觉方法。

其中人工地面巡逻主要依靠林业工作人员定时对森林规定路线进行巡视，这种方法所需人力、时间太多，存在效率低、无法及时发现火情隐患等问题；人工塔台俯瞰方法，同样的也是依靠林业工作人员监测森林是否存在火情隐患，这种方法同样存在与人工巡视相同的问题；飞机巡逻方法，这种方法是指林业工作人员通过飞机在森林上空进行飞行，工作人员在上空对森林进行监测，这种方法成本太高并且实施困难；由于卫星遥感方法生成图像时间短、监测面积大等特点，卫星遥感方法可以更好地预测和估算火灾发展及过火面积，但对于早期的森林火情，卫星遥感方法难以监测[6]。

近几年，无人机技术发展迅速，无人机以其灵活、方便、成本低的优点，逐渐应用于各种工作环境中并表现优秀。同样地，无人机应用于森林火情监测环境中，基于无人机的火情监测方法得到广泛关注与研究。利用无人机监测火情拥有以下优点：1）可监测范围广；2）可以挂载多种传感器；3）前期投入少，无人机对作业环境的要求低，运维成本低；4）无人机用更少的材料制作，更少的燃料飞行，更容易回收；5）执行任务时的灵活性高；6）能够在高危地区长时间作业而不会危及救援人员生命安全；7）同时近距离飞行，传感器影像分辨率高，有利于火情监测并提供实时火场信息方便快速、准确救援灭火，无人机甚至可以直接作为灭火飞行器[7,8]。相比于以上其它森林火情监测方法，无人机不仅为林业工作人员减少工作压力，而且更加便捷、成本低，并且可以更加优秀地完成森林火情监测任务。

基于无人机完成森林火情监测任务不仅对无人机的飞行提出了要求，同时也需要高精度且快速的视觉监测算法。本文以森林火情监测为背景，基于无人机的视觉监测方法，分

中国知网 https://www.cnki.net

析无人机所拍摄森林火情图像的特征，研究并设计地面端以及无人机机载计算机检测分割方法。其中地面端以计算机算力强的优势，通过检测及分割方法对难以监测到的火情进行分析监测。无人机虽然飞行巡视便捷，但是机载计算机算力不够强，针对到这个问题，使用模型压缩方法得到轻量化模型，使得无人机可以进行实时监测的任务。

1.2 国内外研究现状

森林火灾一旦发生，那便是毁灭性的，对自然界以及人类社会都是巨大的危害，并且恢复的过程也是漫长的，所消耗的人力财力也是巨大的。能够在火灾发生早期预防森林火情，可以减少森林火灾对自然界的危害、尽量避免并减少人员伤亡以及对人类社会的财产危害。所以，需要能够高效率、高精度的方法完成对森林火情进行监测的任务。无人机以其飞行能力强、使用便捷、成本低的优点得到的研究人员的广泛关注，将无人机应用于各种复杂环境下的监测任务重，其中就包括森林火情监测任务。所以，本文研究的面向森林火情监测的图像检测分割方法的研究具有理论意义以及现实应用价值，为保护环境、预防森林火灾提供帮助。

1.2.1 基于无人机的森林火情监测

森林环境是自然界的重要组成部分，是动物栖息生存的地方，森林同样给人类提供了大量的资源。我国以及全世界各个国家每年都有大面积森林环境被火灾所危害，森林火灾所造成的危害以及经济损失难以估量[9]。

森林易发生火灾、森林环境复杂等问题的存在，严重威胁着林业工作人员和消防人员的生命安全以及森林环境。无人机（Unmanned aerial vehicle，UAV）这种新出现的航空平台，能够优秀的完成火点的监测任务、森林巡逻保护任务、森林火场侦查任务，还能够协助消防人员开展灭火和救援行动[10]。

无人机被用于森林火情监测任务最早是在 1961 年，是由美国林业局的森林火灾实验室开展的[11,12]。蒙大拿州在 1996 年开发了一套基于无人机进行森林火灾监测任务的系统，这架飞机叫 Firebird2001 无人机，无人机上装有可视化摄像机用于拍摄森林火情。匈牙利在 2004 年在消防系统中首次使用 Firebird2001，对该套系统进行森林火情监测任务的能力进行测试[13]。美国国家航天局（National aeronautics and space administration, NASA）以及加州林业局使用带有红外扫描功能的无人机在 2006 年进行森林火情监测任务，并成功完成，这架无人机名为“牵牛星”，如图 1-2（a）所示。美国于 2007 年发生森林火情，美国国家航天局使用无人机进行森林大火危害程度的评估任务，并估计森林大火所造成的损失，这架无人机名为“伊哈纳”，如图 1-2（b）所示。在这之后国内外研究人员以及高校开始投入研究基于无人机进行森林火情监测的任务，使用无人机对森林火情进行监测的方法受到广泛研究。Yuan C 等在文献[14]中提出了基于无人机完整的森林火情监测方法。Jiao Z 等人在文章中提出利用无人机拍摄的森林火灾图像的的颜色特征，利用小波分析进行进一步处理，通过多组实验证明，能够有效地测出森林火焰和烟雾部分图像，并可在无

中国知网 https://www.cnki.net

人机平台上进行实时检测[15]。



（a）牵牛星 Altair 无人机



（b）Ikhana 无人机

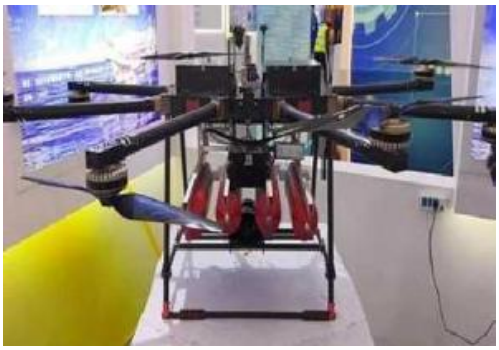
图 1-2 森林火灾探测中使用的无人机

Fig.1-2 UAV used in forest fire detection

湖南联通于 2018 年 10 月研发基于 5G 回传技术的无人机森林防火巡视预警应用系统，该系统应用于湖南长沙橘洲公园和岳麓山。无人机调度平台通过将 5G 网络宽带高、延迟低进行结合，实现对公园进行火情监测，如图 1-3（a）所示；西北工业大学李占科教授带领团队于 2019 年成功研发名为“天雷一号”的无人机。“天雷一号”应用于应对森林火情等场景，该款无人机装有干粉装填的灭火弹，其覆盖面积可达 40 平方米，可进行有效灭火，如图 1-3（b）；佛山于 2019 年 12 月遭受森林火灾，这场大火覆盖面积大、火场同时有不同方向火线。大疆使用名为大疆“御”Mavic 2 无人机对火灾现场进行监测，迅速得到火情具体位置。在确定火情具体位置后，名为“经纬”M210 V2 无人机进一步获取火场信息，该无人机搭载双光热成像相机以及远摄变焦云台，通过无人机送回的火场信息，消防人员得以迅速制定灭火方案，如图 1-3（c）所示；西北大学灵龙无人机团队研发的无人机于 2021 年 3 月在央视财经频道进行路演，该款无人机为垂直起降无人机，同时飞行速度可达到 210KM/H，其速度是同类型无人机的二倍，同时该无人机可搭载 2 个灭火弹对 50 平方米范围进行快速精准灭火，如图 1-3（d）所示。



（a）湖南联通 5G 无人机巡航



（b）“天雷一号”灭火无人机

中国知网 https://www.cnki.net



（c）佛山森林火灾救援现场



（d）“灵龙”无人机

图 1-3 面向森林火情的无人机应用

Fig.1-3 UAVs applications for forest fires

由上文可以得到结论，国内外研发无人机应用在森林火情监测的环境中，取得了很多成就，并大大减少火灾对森林的危害以及提高灭火效率，减少火灾对自然界以及人类生命财产安全的危害。无人机对火情进行监测，重要的是进行监测任务，能够准确快速的监测到火情是及时灭火的关键条件，做到“监测灭火一体化”。

1.2.2 基于计算机视觉的传统方法

使用无人机对森林火情进行监测任务的前提，是通过视觉传感器获取无人机下方拍摄区域的具体情况，接着进行实时监测、传输、反馈任务。需要在无人机上搭载机载计算机，对视觉传感器所拍摄区域进行分析是否存在火情、火情具体位置以及火情规模大小等更多信息。这个任务可以在空中无人机端以及地面端同步进行，将无人机巡航技术与计算机视觉技术进行融合，才可以更好的完成森林火情监测任务。计算机视觉技术已发展近 30 年，从时间顺序划分可分为两类，基于各种物理规则的算法、基于机器学习的算法。其中通过是否需要人工设计提取目标区域特征，可以将计算机视觉技术分为传统火情检测分割方法以及深度学习火情检测分割方法。

传统火情检测分割方法需要根据火情物理特性设计火情特征来确定火情可疑区域。一般传统火情检测分割方法可分为两类，一种是针对烟雾的检测分割方法，另一种是针对火焰的检测分割方法。在早期的森林火情中，会先有烟雾的出现，其次才会有火苗到火场的出现。由于烟雾的物理特征很容易与云层、雾气重合，本文着重对火焰进行分析。如下图 1-4 所示为传统火焰检测分割方法结构。

传统火情检测分割方法的过程大致可以分为以下几个步骤:首先是对图像进行预处理操作，接着选取出图像中疑似目标的区域、提取目标区域中的特征、最后检测出目标，即火情区域，具体步骤流程如图 1-4 所示。图像的预处理进程包括对图像大小进行调整、去掉图像噪点、增强图像得到更清晰的目标区域。接着提取前景环境，可使用帧差法、图像分割或图像建模等。接着便是特征提取模块，进行人工设计特征，根据火情的物理特性，火情特征可分为静态特征（颜色、圆度、尖角等）与动态特征（闪动、频率等）。接下来将特征送入到识别判定模块中进行检测，检测出火情后进行报警。

中国知网 https://www.cnki.net

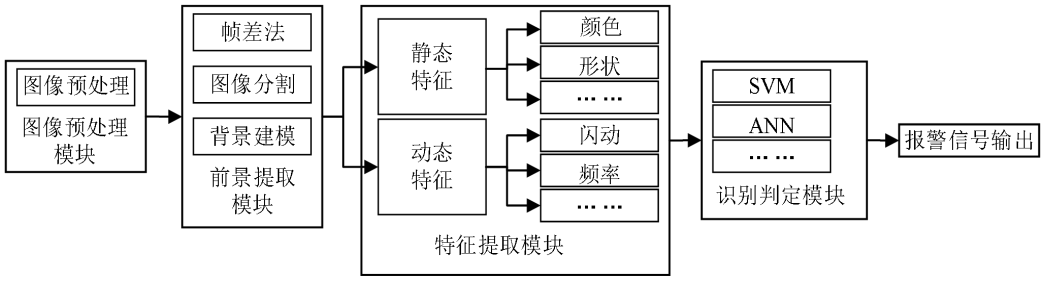


图 1-4 传统森林火情检测分割结构

Fig.1-4 Forest fire detection and segmentation structure based on traditional method

图像预处理的常用方法有对图像灰度化处理、对直方图进行均衡化处理、对图像进行增强或滤波处理等方法。文献[16]中，根据烟雾的物理特性，这里对烟雾的颜色进行分析，使用暗通道分析方法对图像进行处理，得到一种对烟雾区域进行颜色增强的方法；提取前景阶段，将目标区域与背景进行区分开，以便后续精准检测目标，避免对整张图像进行处理。文献[17]中采用背景帧差以及颜色特性将前景区域提取出来，文献[18]中采用模糊积分方法从图像中提取出烟雾前景区域;特征提取模块中对火焰及烟雾的物理特征进行分析，从而得到火情区域。文献[19]中对火焰的颜色特征进行分析，对烟雾的纹理特征进行分析，使用不同色彩空间对火焰及烟雾进行识别。文献[20]中采用二维离散小波变换从图像及视频流中提取烟雾的动态特征，从而对烟雾进行识别。在传统检测方法中不可缺少的是分类器，包括支持向量机（Support vector machines, SVM）、人工神经网络（Artificial neural networks, ANN）等分类器用于识别火灾，在文献[21]与[22]中使用支持向量机分类器识别与检测火情，在[23]中通过获取火焰的颜色和纹理特征，先将 RGB 颜色空间图像转化为其他颜色空间（YCbCr、HSV 以及 Lab 颜色空间），然后采用灰度共生矩阵(GLCM)提取火焰区域的颜色特征，并且采用局部匹配二值模式（LBP）提取纹理特征。最后，将所提取到的颜色特征以及纹理特征送入到分类器中得到检测结果。这种方法检测速度很低，并不适用于森林火情这种实时的检测环境。

传统火情检测分割方法核心在于人工利用火焰及烟雾的物理特征,进行手动设计繁多的火焰及烟雾特征,在一般环境内检测效果较为优秀。但是又因为火焰及烟雾形状不固定，在复杂的背景环境下，比如图中存在遮挡及光照变化等现象时，传统的检测算法是存在问题的，比如检测精度低、误检、漏检等问题。同样的，又因为手动设计的火情特征数量繁多，会占据计算机大量的计算空间，会导致算法无法达到实时的效果，甚至速度很慢。传统火情检测分割方法存在鲁棒性差、监测精度低、运算量大等问题，这些问题可以利用深度学习算法进行解决。

1.2.3 基于计算机视觉的深度方法

近年来，随着计算机技术的发展，计算机计算能力日益强大，有关深度学习的研究与算法发展进度快速，且在目标分割、目标检测与识别等研究领域产出了良好的方法，从而为森林环境监测提供了新的解决思路。与传统方法不同，基于深度学习的森林环境监测方

中国知网 https://www.cnki.net

法避免了复杂的图像预处理过程，且能够自动地学习灾害的高级特征表示，极大提高了森林火情监测的精准度。基于深度学习方法对森林火情进行监测可分为目标检测方法、分割方法以及适用于边缘设备的轻量化方法。

深度学习火情检测分割方法通常都要比传统火情检测分割方法效果要好，传统火情检测分割方法是利用火焰烟雾的物理特性来设计特征提取模块，从而检测出火焰烟雾目标区域，深度学习火情检测分割方法多为卷积神经网络（Convolutional neural network，CNN）组成，使用 CNN 计算视频、图像中的特点，自动的从中提取出火焰或烟雾高维度的、丰富的特征。深度学习火情检测分割方法与传统火情检测分割方法相比，监测效果更好，避免了手动设计火情特征的复杂度。综上分析，深度学习火情检测分割方法可以更高效的表达火焰烟雾特征，对火情区域检测分割效果更好，同时降低了计算机视觉技术对火情区域的误检率及漏检率。如下图 1-5 所示为传统火焰检测分割方法结构。

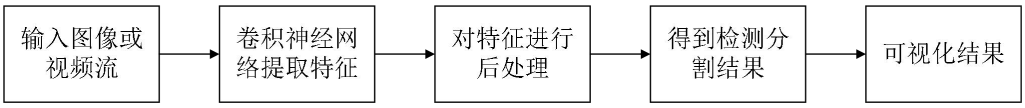


图 1-5 基于深度学习的森林火情检测分割结构

Fig.1-5 Forest fire detection and segmentation structure based on deep learning method

（1）基于目标检测方法的森林火情监测

从传统森林火情检测分割方法发展到深度学习森林火情检测和分割方法的过程中，有研究人员将两种方法进行结合，用结合后的算法完成火情目标检测任务。这种方法先采用传统方法对采集到的图像进行预处理，然后才将经过处理过后的图像送入到深度卷积神经网络中提取图像中火焰及烟雾的特征。文献[24]是通过对图像变化的对比，即图像背景不变，前景区域发生变化的方法提取出图像中的目标区域，但是又由于有其他类似烟雾的云层或其他干扰噪音，使用暗通道方法对图像再处理，消除噪音，最后得到火焰烟雾可疑区域，再将图像送入到深度卷积神经网络中提取特征。这种方法相比传统森林火情检测分割方法，检测分割精度更高，但是方法模型计算量大，在实际应用中运算速度慢，无法做到实时检测分割的效果，无法满足实际应用的要求。

随着计算机硬件的发展，深度学习方法也在迅速发展，检测精度及速度越来越好的模型层出不穷。在文献[25]中，提出一种名为 Firenet 的方法，设计了一套基于无人机的林火监测系统。在文献[26]中，Frizzi 等人在美国亚桑那州森林使用无人机对火情进行拍摄收集，同时制作了名为 FLAME（Fire luminosity airborne-based machine learning evaluation）的航空森林火灾数据集。Frizzi 等人使用 Xception 模型对 FLAME 数据集进行训练，得到火情检测方法。在文献[27]中，对 ATT U-Net 语义分割模型进行优化，将 Squeezenet 深度学习方法的主干网络嵌入到原始模型中，同时引入深度卷积（Depthwise convolution）以及通道重排方法（Channel shuffle），以此获得鲁棒性更强、学习特征能力更强的方法。以上方法在特定场景与数据集中检测效果很好，但是在环境复杂或者不同环境下检测精度

中国知网 https://www.cnki.net

不高，无法做到实时精准的检测效果。

（2）基于分割方法的森林火情监测

分割方法比检测方法出现得晚，分割方法不同于目标检测方法，分割方法是像素级检测，检测结果更细致、更精准，相对的难度要更高。分割方法可以分为语义分割方法以及出现较晚的实例分割方法，语义分割对图像不同类别目标进行像素级分类，得到不同类别在图像中像素的具体位置，实例分割不以类别进行分割，而是将图像中各个目标的具体位置全部分割出来。实例分割方法可以说是语义分割与目标检测方法的结合体，能够更加精细地监测出图像中目标的具体位置，适合精细的、环境复杂的监测任务。

语义分割方法如文献[28，29]中提出的。文献[28]中提出的 U-net 语义分割方法，U-net 模型结构由像素编码器与像素解码器组成，像素编码器对图像进行下采样，提取图像特征，像素解码器将像素编码器输出的特征图进行上采样操作，将特征图恢复到原本图像大小，进而得到语义分割结果。文献[29]中提出的 Deeplabv3+语义分割方法，Deeplabv3+在像素编码器中加入带有空洞卷积的空间金字塔池化模块，引入多尺度语义信息，提升模型对于目标边缘的分割精度。实例分割如文献[30]中提出的 Maskrcnn 为出现较早的实例分割方法，Maskrcnn 为两阶段分割模型，先提取图像特征，然后在图像中选取出可疑目标区域，最后通过全卷积模块得到实例分割结果。这种方法虽然分割精度较高，但是分割速度慢，无法适用于森林火情监测任务。文献[31]中提出的 Yolact++实例分割方法，Yolact++在特征提取网络中加入可变形卷积，提高模型对不同形状、不同大小目标的分割精度，通过在分割输出头引入新的分支，优化分割输出结果，消耗少量计算量得到效果显著的分割精度。在文献[32]中，提出一种基于 Deeplabv3+改进的语义分割模型对火情进行分析与监测，在原始模型的像素解码器中加入低层特征，将加入的低层特征与原本存在的高层特征进行特征融合，提高模型中的语义细节信息，进而提高模型的分割精度。在文献[33]中，作者提出一种分割方法对火情进行监测。先通过 Efficientnet 对图像特征进行提取，再使用语义分割模型 Deeplabv3+对火情目标进行分割处理。在文献[34]中，得到一种复合模型，使用 Shufflenet 对火情目标进行分类，使用 WSFS 对火情目标进行分割，使用轻量化之后的 Faster-rcnn 模型对火情目标进行检测。但是这种方法模型过于复杂，不适用于实际应用。本文使用实例分割方法对森林火情目标进行监测，得到不同目标在图中更加准确、精细的像素位置。

（3）基于轻量化模型的森林火情监测

轻量化方法可以通过直接设计轻量化模型得到，也可以通过对复杂模型使用模型压缩方法得到。如文献[35]中提出 Mobilenetv2，Mobilenetv2 在模型中引入深度可分离卷积、线性瓶颈层以及反转残差结构，以此提升模型分类精度的同时，减少模型参数量并加快模型运行速度。文献[36]中提出一种名为 I-firenet 的轻量化方法，将模型部署于无人机机载计算机等边缘设备上，对火情进行实时监测。在文献[37]中作者使用通道剪枝的方法对 Yolov3 进行轻量化处理，进而使用轻量化后的 Yolov3 对火情进行检测。其中将模型中权

中国知网 https://www.cnki.net

重系数小的，不重要的层数进行删除，进而达到减少模型参数的目的，然而不降低模型的检测精度，加快模型的检测速度。文献[38]中作者对 Yolov2 进行轻量化处理，将轻量化处理后的模型 Yolov2-tiny 移植到边缘设备开发板上，虽然可以快速地生成检测结果，但是误检率、漏检率极高，不适用于森林火情监测任务。在文献[39]中，作者对 Yolox 进行轻量化处理，然后通过 TensorRT 加速处理之后，进而将轻量化 Yolox 部署到无人机的机载计算机上，达到快速高效的检测效果。以上轻量化方法虽然模型参数量、模型检测实时性达到要求，但是检测精度并不高，检测精度与检测速度之间的平衡关系表现不够好。

针对森林火情监测的图像检测和分割任务，国内外已产出很多优秀方法。然而现有方法仍存在以下不足：1）使用无人机采集到的森林图像所包含面积大，这也就存在背景大而目标小的问题。尤其是在火灾发生早期，火情目标更小，更难进行监测；2）火情有时会存在多个目标、不同大小的目标以及目标被遮挡问题，这些问题都增加了对火情检测分割的难度；3）火情出现的背景复杂，会有多种不同类别背景，这也会影响对火情检测分割的精准度；4）使用无人机对森林火情进行监测，能否达到实时的效果，是一项重要的指标。但是由于无人机上搭载的机载计算机运算能力不如地面端，并且一般高精度的深度学习方法计算量大，检测速度同样是森林火情监测任务的难点和挑战。由上述研究现状以及实际监测中的具体情况，本文对基于无人机使用深度学习的方法，对森林火情进行检测和分割任务得出以下结论。上述方法在实际火情监测中仍存在缺陷，比如模型精度不高、模型漏检、模型参数量大等问题。首先是火情目标监测困难，火情目标不固定，火情会因为地形、风向等因素存在不确定因素，需要检测能力更强的方法对森林火情进行监测。其次是森林环境复杂，存在遮挡火情的情况，需要对遮挡火情以及小目标火情进行更加精细的检测分割。最后是无人机等边缘设备需要检测能力更强、检测速度更快、模型参数量更小的检测方法，使用更快更轻更准的方法完成空中端的森林火情监测任务。

1.3 主要研究内容

本文总结学习国内外对森林火情监测的方法，结合监测过程中的实际情况。对深度学习方法的目标检测模型、实例分割模型以及轻量化方法进行研究，利用不同方法的特性解决上述的问题。设计了基于深度学习的图像检测和分割方法，以下为本文的三个研究内容。

（1）针对在地面端准确快速的进行火情检测任务，研究了 Yolo 系列目标检测方法，最后选择 Yolov3 作为本方法的基础，将 Yolov3 目标检测方法作为基础方法进行优化，在主要框架不变的前提下应用参数重构方法、跨阶段部分结构以及 SE 权重注意力模块等其它优化策略，从而提出一种基于 Re-yolo 模型精准实时的森林火情检测方法，保证模型检测速度的前提下提升模型对于火情检测的准确性。制作并扩充森林火情目标检测数据集，从 FLAME 航空数据集中选取 6218 张图像，为了提高模型的鲁棒性，对数据集扩充 3646 张不同背景的火情图像，数据集共 9864 张图像。

（2）针对无人机机载计算机算力有限，而一般准确度高的方法计算量又大，无法在

中国知网 https://www.cnki.net

无人机监测火情的过程中达到实时效果的问题。在实验内容一的基础上，本文研究了Mobilenet 系列、Shufflenet 系列等轻量化模型，并研究了通道剪枝、模型蒸馏、替换模型等模型压缩方法。通过对比，最后选择 Moblieone 的轻量化结构对 Re-yolo 目标检测方法进行替换，同时使用滤波器剪枝方法对模型进行压缩处理，实现在低算力条件下对火情的有效监测，提出一种模型轻量化的思路。

（3）针对多火点、小目标火点以及遮挡火点检测难、检测精度不高的问题，研究了多种实例分割算法，最后选择 Maskrcnn 模型作为本方法的基础，对火情目标区域进行像素级检测。将 Maskrcnn 实例分割方法作为基础方法进行优化，在 maskrcnn 的模型框架下引入基于查询的解码器输出头，并在像素解码器中引入特征对齐模块，从而提出一种针对地面端精准的火情分割方法。同时制作实例分割数据集，数据集共有 1047 张图像。

1.4 论文组织结构

本文一共分为五章，主要是围绕面向森林火情监测的图像检测和图像分割这一主题为中心思想，研究基于无人机实时精准的森林火情监测方法，论文章节的组织结构如图 1-6 所示。

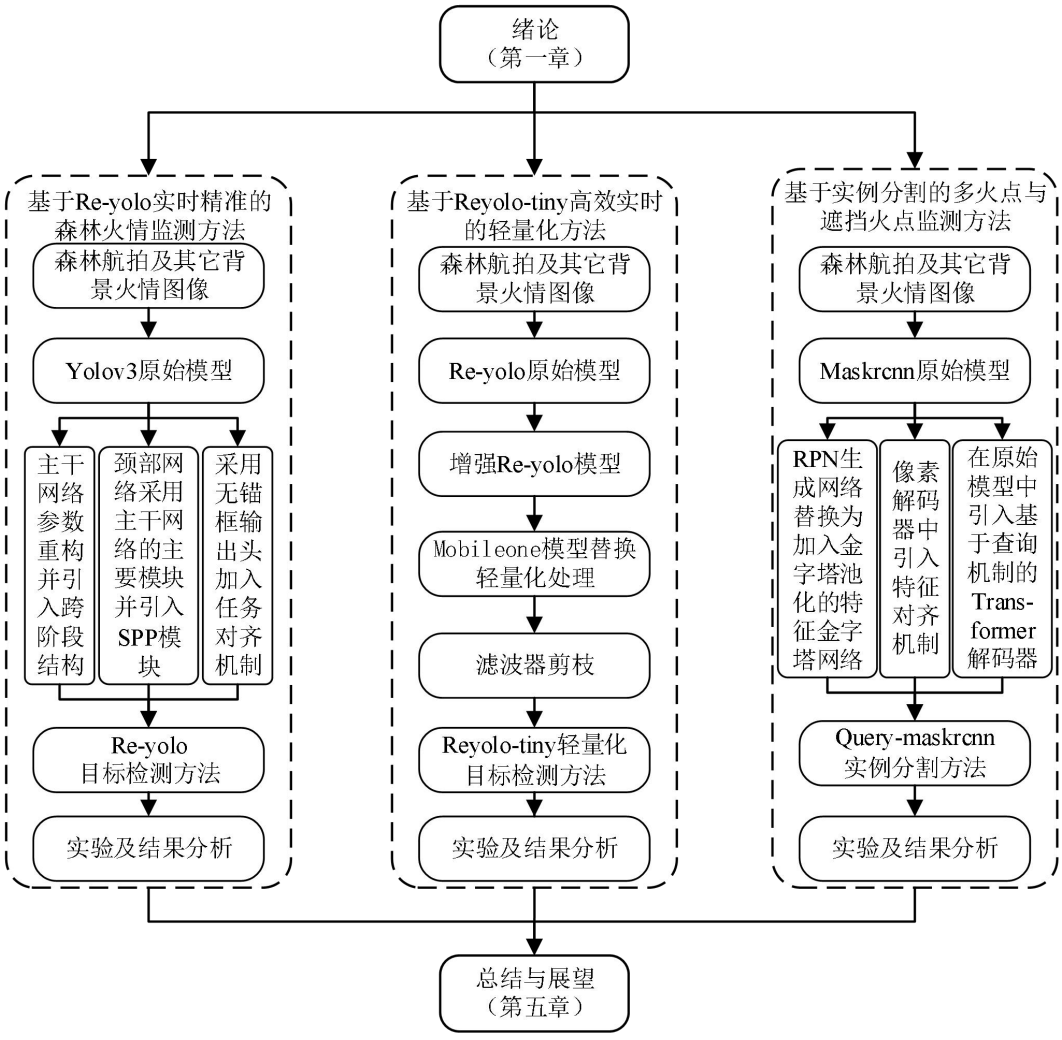


图 1-6 论文章节的组织结构

Fig.1-6 The organization of the thesis chapters

第一章：绪论。对国内外发生的森林火灾案例进行说明，这些火灾对自然界和人类造

中国知网 https://www.cnki.net

成极大危害，证明了森林对自然界和人类的重要性以及森林火灾严重的危害性，以此得出本课题研究的理论意义和重要性。而后，对国内外基于无人机的森林火情监测任务以及基于图像的计算机视觉方法的研究现状进行分析和总结。从而引出本文的主要研究内容以及全文组织结构。

第二章：基于 Yolov3 改进的实时精准的森林火情监测方法。首先介绍针对本方法所制作的目标检测数据集，并对本方法的思路进行阐述。然后对基础模型 Yolov3 以及本方法 Re-yolo 的整体结构进行分析，接下来分析参数重构方法、跨阶段连接结构、权重注意力、颈部结构中的空间金字塔池化、输出头中的无锚框方法和任务对齐机制以及最后的损失函数等优化方法。最后通过对比实验、消融实验以及检测结果，证明了本文方法 Re-yolo 的优秀性和可行性。

第三章：基于 Re-yolo 改进的高效实时的轻量化方法。首先介绍轻量化模型对于基于无人机的森林火情监测任务的重要性和必要性，并对本方法的思路进行阐述。然后对通道剪枝、模型蒸馏等模型压缩方法，以及 Mobilenet、Shufflenet 等轻量化模型进行分析。此章节对 Re-yolo 采用不同轻量化方法进行轻量化，最后通过对比得到最合适的模型 Reyolo-tiny。

第四章：基于实例分割的多火点与遮挡火点监测方法。首先介绍针对本方法所制作的实例分割数据集，并对本方法的思路进行阐述。然后对基础模型 Maskrcnn 以及本方法的整体结构进行分析，接下来分析加入金字塔池化的特征金字塔网络、特征对齐机制以及基于查询的解码器输出头等优化策略。此章节应用对原始模型 Maskrcnn 采用不同优化思想进行优化，最后通过对比得到最优模型，并将得到的最优模型与其他优秀实例分割模型以及原始模型进行对比，证明本方法的优秀性和可行性。

第五章：总结与展望。总结目前对于研究内容完成的工作，并提出本文方法中的一些未完全优化的地方，同时对后续的研究和工作进行规划展望。

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

2 基于 Re-yolo 准确快速的森林火情监测方法

2.1 引言

森林火情监测任务一般希望能够在火情发生早期对火情进行有效监测并及时灭火，但是又由于无人机搭载的视觉传感器所拍摄的图像包括的范围大、目标小的问题，需要监测能力更强的方法对森林火情进行高效精准的监测。

计算机视觉技术从传统的图像检测方法发展到基于深度学习的图像检测方法，检测精度更高。传统图像检测方法是针对火情物理特征人工手动设计特征提取方法，基于深度学习的图像检测方法使用卷积对图像特征自动提取特征，卷积自动提取特征相比较人工手动设计特征更加快速、更加全面，能够提取更多特征，因此基于深度学习方法要比传统方法检测更加准确。但是，基于深度学习方法的计算量要更大，对硬件要求的条件更高，要在无人机监测森林火情任务中做到实时监测的效果仍是一大挑战。Yolov3 以其优秀的检测速度和检测精度倍受研究人员关注[40]，经常应用在工业现实应用中，广泛应用在各个环境、各个应用领域中解决现实问题。并且 Yolov3 的检测精度、速度表现效果好，故本文对 Yolov3 进行研究，使用参数重构方法[41]以及跨阶段连接模块[42]对 Yolov3 主干网络及颈部结构进行优化，提升 Yolov3 的特征提取能力，进一步提升 Yolov3 的检测精度，同时平衡检测精度和检测速度之间的关系。并应用其他优化策略对 Yolov3 进行优化，从而提出 Re-yolo 方法，用以完成实时精准的对森林火情进行监测任务。

本章的安排如下：首先对 Yolov3 进行介绍，从 Yolov3 的整体结构介绍开始到细分的主干网络、颈部网络以及输出头结构。然后提出优化后的 Re-yolo 方法，先介绍 Re-yolo 方法的整体网络结构，然后重点介绍其中的主干网络及颈部结构中的主要模块，它在保证模型速度的同时提升模型对火情检测的精准度。接下来是其他优化策略，注意力模块、无锚框输出[43]、损失函数[44,45]、特征对齐机制[46]等。最后使用数据集对 Re-yolo 以及其它方法进行学习，将 Re-yolo 及其它方法的检测结果进行对比，同时对 Re-yolo 进行消融实验，以此证明 Re-yolo 的各个模块及 Re-yolo 的有效性和优秀性。

2.2 Yolov3 目标检测方法

Yolov3 检测精度以及检测速度表现都很好，在平衡检测精度和速度方面表现得也很优秀，故本文首先考虑使用 Yolov3 作为基础方法对森林火情进行监测。Yolov3 网络结构由三个主要阶段组成，分别为主干网络、颈部网络、输出头。主干网络为 Darknet53，主要模块为残差结构块，主干网络可分为 5 个阶段，每个阶段的数量分别为 1、2、8、8、4。颈部结构采用 FPN 结构融合主干网络三个不同阶段、大小不同的特征图。输出头采用基于锚框的输出方式，使用损失函数等得到输出框，对火情区域进行预测。

中国知网 https://www.cnki.net

2.2.1 Yolov3 整体结构

深度学习目标检测模型一般由主干网络、颈部网络和输出头组成。图像输入到目标检测模型中，先经过翻转、裁剪、批归一化等图像预处理操作，丰富输入的图像，提升训练模型后的鲁棒性；然后将预处理后的图像送入到主干网络中，主干网络提取预处理后图像的特征，得到不同大小、维度的图像特征；接着，主干网络提取到的图像特征送入颈部网络中进行处理，颈部网络将不同大小、维度的图像特征进行融合；最后颈部网络将融合后的图像特征送入到输出头中进行处理，输出头对图像中目标进行定位和分类，得到预测结果。得到预测结果之后，模型中损失函数对预测到的结果和数据集中的真实数据进行对比，根据差值再对模型预测进行调整，直到准确预测目标的位置和类别。以上便是目标检测方法的结构和预测流程，Yolov3 同样是以这样的方式进行预测，如图 2-1 为 Yolov3 网络的网络流程图。

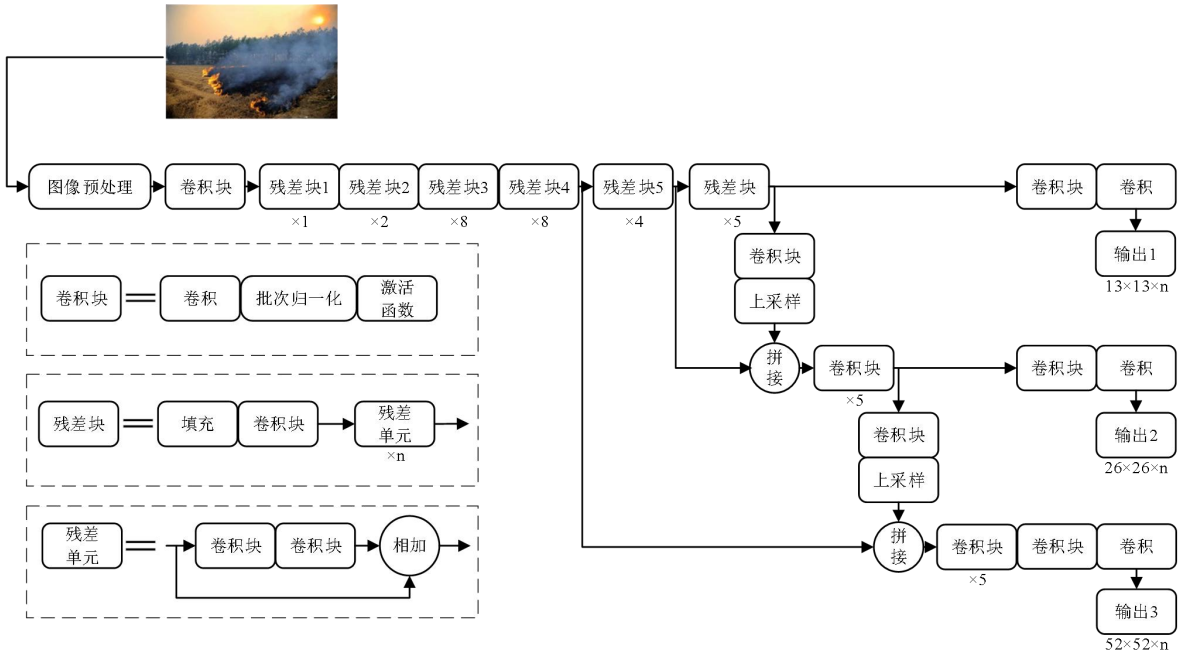


图 2-1 Yolov3 网络流程图

Fig.2-1 The network flowchart of Yolov3

Yolov3 选择 Darknet53 作为其主干网络，颈部结构为特征金字塔网络（Feature pyramid network，FPN），输出头对特征进行处理，对火情目标进行定位于分类，因此 Yolov3 有三个损失函数对模型预测进行调整，分别是目标置信度损失、目标类别损失以及目标定位损失。由图 2-1 中，Yolov3 网络中基本模块有卷积块、残差块、残差单元。其中卷积块由 3×3 卷积、批次归一化、Leakyrelu 损失函数组成，残差单元中由，残差块由大小为 1×1、3×3 的卷积结构构成，残差块由卷积块和残差单元组成。其中 Yolov3 主干网络的详细架构如表 2-1 所示，其中给出了 Yolov3 主干网络中卷积以及输出特征图的大小。由表中可以得出，主干网络首先是一层 3×3 大小的根茎层，根茎层用于提取图像特征、增大感受野，然后是 5 个阶段残差块，每个阶段残差块数量分别为 1、2、8、8、4。

中国知网 https://www.cnki.net

表 2-1 Yolov3 主干网络的详细架构

Tab.2-1 Detailed architecture of the Yolov3 backbone network

输入数据	操作	数量	步长	输出通道	输出特征图大小
512×512×3	Conv 3×3	1	-	32	256×256×32
256×256×32	Conv 3×3	1	2	64	256×256×64
256×256×64	Conv 1×1	1	-	32	256×256×32
128×128×32	Conv 3×3	1	-	64	256×256×64
256×256×64	Conv 3×3	2	2	128	128×128×128
128×128×128	Conv 1×1	2	-	64	128×128×64
128×128×64	Conv 3×3	2	-	128	128×128×128
128×128×128	Conv 3×3	8	2	256	64×64×256
64×64×256	Conv 1×1	8	-	128	64×64×128
64×64×128	Conv 3×3	8	-	256	64×64×256
64×64×256	Conv 3×3	8	2	512	32×32×512
32×32×512	Conv 1×1	8	-	256	32×32×256
32×32×256	Conv 3×3	8	-	512	32×32×512
32×32×512	Conv 3×3	4	2	1024	16×16×1024
16×16×1024	Conv 1×1	4	-	512	16×16×512
16×16×512	Conv 3×3	4	-	1024	16×16×1024

2.2.2 Yolov3 特征融合方法

之前的方法中，主干网络提取完图像特征后，直接在特征图中进行预测。例如文献[47]中，主干网络提取完图像特征后直接送入到区域建议网络中（Region Proposal Network，RPN）。目标可疑区域被区域建议网络在特征图中生成的大量检测框检测出，接着感兴趣区域池化（Region of interest pooling，ROI pooling）模块收集感兴趣区域以及特征图，综合这两种信息得到建议特征图，接下来才将得到的建议特征图送入到输出头中进行分类、定位及回归任务。这种方法计算量大，而且提取到的图像特征单一，对小目标检测能力较弱。Yolov3 没有采用区域建议网络，主干网络提取特征之后，将提取到的不同大小的特征图送入到特征金字塔网络中进行特征融合，增强模型的预测能力。其中送入特征金字塔网络的特征图分别是来自于主干网络中第三阶段、第四阶段、第五阶段残差块的输出，以输入图像大小为 512×512×3 为例，这三个特征图的大小分别是 64×64×256、32×32×512、16×16×1024。结合图 2-1 的 Yolov3 网络流程图以及表 2-1 的 Yolov3 主干网络的详细架构一起来分析，这里仍然以输入图像大小为 512×512×3 为例。主干网络一共五个阶段残差块，每个阶段残差块数量分别为 1、2、8、8、4。第五个阶段残差块输出的特征图分别用于输出向输出头用于定位和分类，以及用于特征融合。特征融合部分，第五阶段残差块输

中国知网 https://www.cnki.net

出大小为 16×16×1024 的特征图先经过 5 层卷积大小为 3×3 的卷积块，然后经过上采样得到大小为 32×32×256 的特征图，然后与第四阶段残差块输出大小为 32×32×512 的特征图进行特征融合，得到大小为 32×32×768 的特征图，至此完成第五阶段残差块和第四阶段残差块输出特征图的特征融合。接下来第四阶段与第五阶段融合后的图像特征同样分别用于输出向输出头进行定位和分类，以及进行特征融合。大小为 32×32×768 的特征图首先经过五层卷积大小为 3×3 的卷积块，然后同样经过上采样得到大小为 64×64×128 的特征图，然后与第三阶段残差块输出大小为 64×64×256 的特征图进行特征融合，得到大小为 64×64×384 的特征图，用于输出向输出头进行特征融合。至此便完成了主干网络的特征融合阶段，分别得到大小为 64×64×384、32×32×768、16×16×1024 的特征图，不同大小的特征图送入输出头，增强模型鲁棒性，提升模型对不同大小目标的预测能力。

2.2.3 Yolov3 预测方法

颈部结构输出大小分别为 64×64×384、32×32×768、16×16×1024 的特征图，这三个不同大小的特征图再经过卷积的下采样，最终得到输出的预测结果。Yolov3 的预测原理是分别将图像分为 16×16、32×32、64×64 的网格，每个网格负责一个区域的预测，其中 16×16 的网格负责检测相对在图中较大的物体，64×64 的网格负责检测在图中较小的物体。预测过程就是计算出最终预测框的坐标 b_x、b_y 以及预测框的宽和高 b_w、b_h，计算过程如下。

$$b_x = \sigma(t_x) + c_x \tag{2-1}$$

$$b_y = \sigma(t_y) + c_y \tag{2-2}$$

$$b_w = p_w e^{t_w} \tag{2-3}$$

$$b_h = p_h e^{t_h} \tag{2-4}$$

其中 c_x、c_y 表示划分好网格的坐标，划分好的网格比如某层特征图大小为 16×16，那么划分好的网格就有 16×16 个，例如特征图第三行第五列的网格，它的坐标 c_x 为 3、c_y 为 5。其中 p_w、p_h 表示先验框的边长，即模型进行预测之前生成检测框的大小。其中 t_x、t_y、t_w、t_h 表示预测框的坐标及大小，这里的预测框是数据集中提前标注的，以供模型进行预测学习，最终模型得到的预测框的坐标大小为 b_x、b_y、b_w、b_h。对于输入大小为 512×512 的图像，模型多尺度输出特征图大小分别为 16×16、32×32、64×64，那么模型会生成 16128 个预测框。模型生成预测框后的下一步是对预测出的预测框进行得分排序及非极大抑制筛选，如图 2-2 为一组预测框的筛选过程。

中国知网 https://www.cnki.net

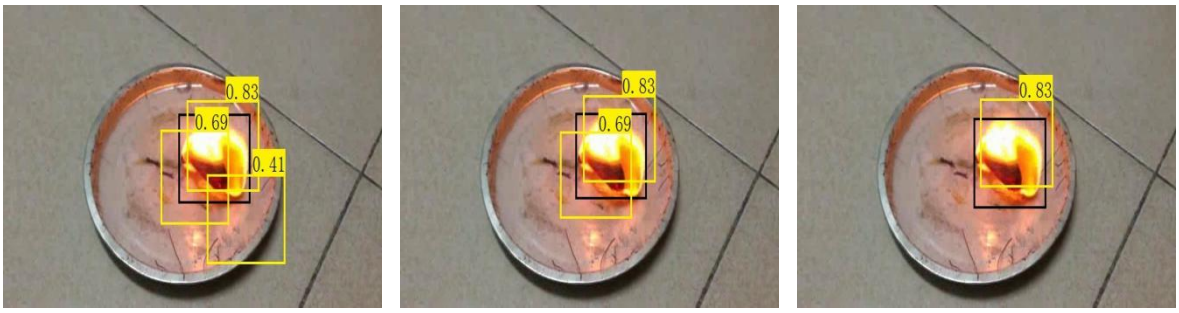


图 2-2 预测框的筛选过程

Fig.2-2 The filtering process for the prediction box

图 2-2 从左往右为 Yolov3 对火焰预测过程中预测框的筛选过程，黑色边框是数据集中人工标注的真实框。Yolov3 预测过程中生成三个预测框，概率置信度分别为 0.41、0.69、0.83。首先直接通过预测概率分数过滤一部分预测框，假设将概率分数阈值设置为 0.5，那么预测框概率低于 0.5，则直接被舍去。然后使用非极大抑制（Non-maximum supression，NMS）方法对其它预测效果不好的预测框进行处理，解决多个预测框检测一个物体的问题，消除检测框冗余的问题。非极大抑制的原理关键在于，选择一个预测概率分数最高的预测框，或者也可以使用数据集中标注的真实框。然后计算选择的预测框与其它预测框的重合程度，去除掉重合度超过交并比（Intersection over union，IOU）阈值的边框。接下来迭代处理，找出最优预测框。其中交并比的计算如公式 2-5 所示，假设有两张图像 A 与 B，它们的交并比指两张图像面积的重合部分除以两张图像面积的并集。

$$IOU_{AB} = \frac{A \cap B}{A \cup B} \tag{2-4}$$

2.3 Re-yolo 目标检测方法

使用无人机进行森林火情监测的任务，一般无人机所拍摄的森林环境目标较小，因此需要特征提取能力强、检测精度高的方法来进行预测工作，这便对模型的预测能力提出了要求。Yolov3 虽然预测能力强，经常应用于各类工业环境当中，对于较大的目标，Yolov3 具有较强的检测能力。但是对于检测小目标火情任务重，会出现不少的误检、漏检情况。需要检测能力更强的模型完成火情监测的任务，但是这样就会带来一个问题，模型检测能力越强，意味着模型计算量越大，检测速度就会随之下降，如何在模型的检测准确度和检测速度之间进行平衡，这就成了需要解决的问题。基于此问题，本文优化 Yolov3 大量使用的残差结构，引入参数重构方法以及跨阶段连接方法，得到新的基本结构，并引入其它优化策略，进而提出基于 Re-yolo 目标检测模型的森林火情监测方法。

2.3.1 Re-yolo 主干网络结构

由文献[48]及后续的研究可知，模型网络的层数越深，模型提取特征的能力越强，模型提取到的特征越细节、越丰富。在文献[48]中，作者对模型前五层进行反池化操作，将前五层的特征图可视化，如图 2-3 所示。对可视化的结果进行分析可得：Layer1 层提取图

中国知网 https://www.cnki.net

像的底层特征，即颜色特征、边缘特征等；Layer2 层提取形状特征，即可以提取边框、波纹等较为细节的特征；Layer3、Layer4、Layer5 层提取更高级、更细节的特征。如图 2-3 中所示，Layer3、Layer4、Layer5 层提取到图像的更为高级、更为细节的特征，即网格、文字、花瓣、人像等特征。

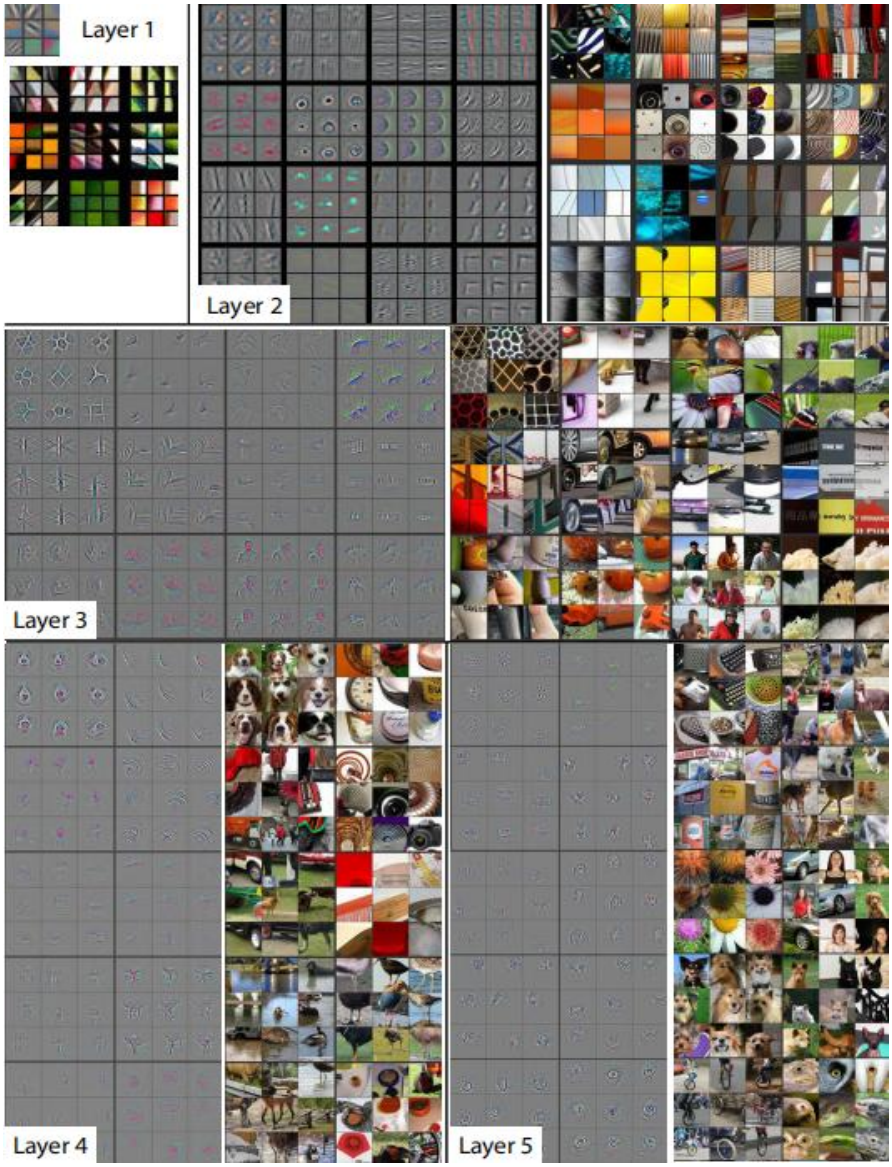


图 2-3 ZFnet 模型前五层的特征图可视化

Fig.2-3 The visualization of the feature map of the first five layers of the ZFnet model

随着网络不断加深，使得最新生成的特征图的语义信息与网络初始特征图关联越来越小；深层特征图尺寸虽然较小，但是保留了大量丰富的语义信息，较浅层的特征图尺寸较大，保留了图像的结构、颜色、边缘、位置等基础信息。又因为主干网络中提取到的特征会送到后续结构中进一步处理，颈部结构提取主干特征第三阶段、第四阶段、第五阶段输出的特征并进行融合，故 Re-yolo 采用 1、2、8、8、4 的主干结构数量安排，提取更多的深层语义特征，提高网络的精度。Re-yolo 主干网络结构如图 2-4 所示。

中国知网 https://www.cnki.net

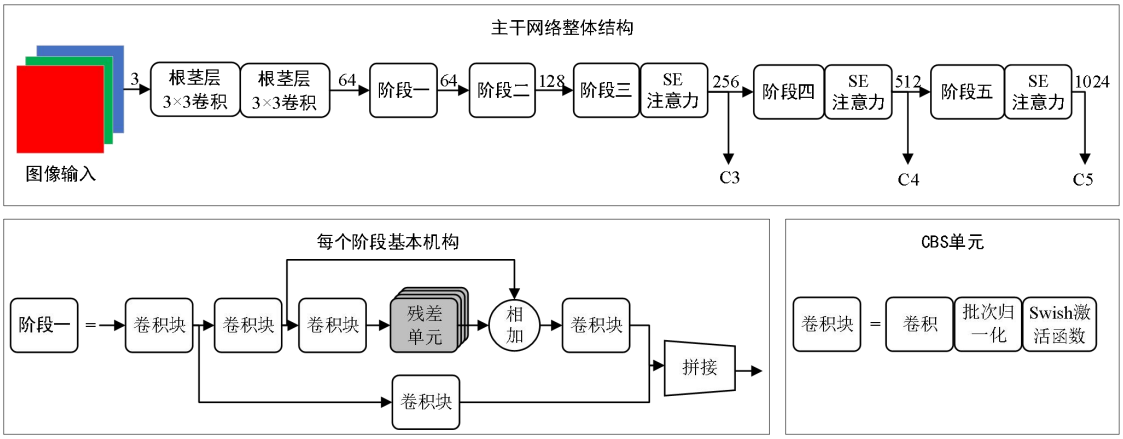


图 2-4 Re-yolo 主干网络结构

Fig.2-4 The backbone network structure of Re-yolo

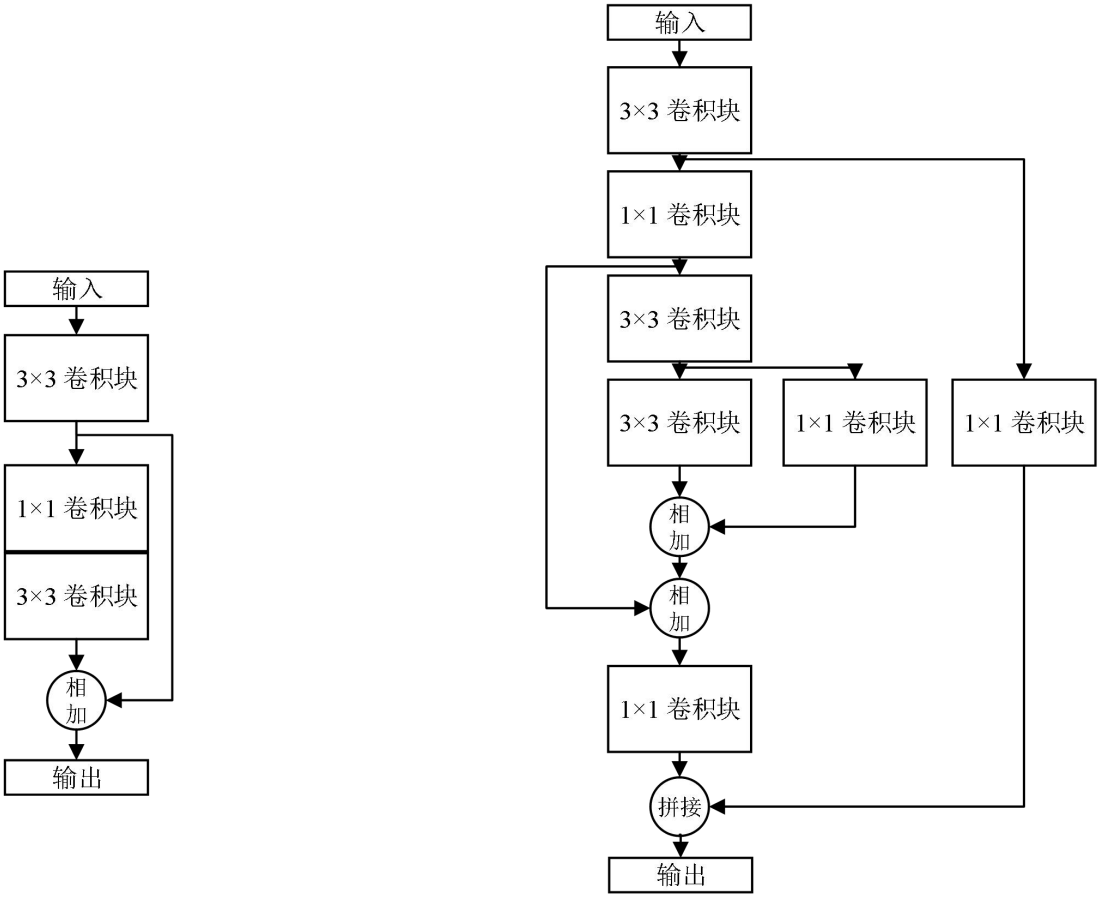
其中的每个阶段中除了固定的 3×3 卷积层以外，由基本结构单元组成。基本结构的数量与 Yolov3 一致，图像输入后经过 2 层根茎层，进行下采样，扩大特征提取感受野，紧接着特征图经过五个阶段，其中每个阶段的重复次数分别为 1、2、8、8、4。这里重复部分为基本结构单元中的内环残差组件，基本结构单元中的内环残差组件在图 2-2 中是每个阶段基本结构单元中的深灰色部分 Re-res。并在主干网络中加入 SE 注意力模块以增强模型精度，经过实验发现加入的 SE 注意力模块也不能太多，否则效果并不好，同时经过研读文献以及实验发现 SE 注意力模块加入在网络末端效果最好，故将其加入到第三阶段、第四阶段、第五阶段后面。这便是 Re-yolo 的主干网络。

2.3.2 Re-yolo 基本结构

在 Re-yolo 网络框架中，主干网络中第一阶段、第二阶段、第三阶段、第四阶段、第五阶段的重复次数分别为 1、2、8、8、4，图像输入先经过 Stem 层提取图像特征，进行下采样，并扩大网络的感受野，然后经过后续阶段进一步提取特征，接下来将特征送入到后续的颈部网络。其中主干网络中的基本结构如图 2-5 中所示，值得一提的是，颈部网络中同样采用与主干网络中相同的基本结构来代替原本的卷积结构。图 2-5（a）为 Yolov3 的基本结构，Yolov3 是由一个残差结构构成，基本结构的重复部分为残差结构，并且其卷积的激活函数采用 Leakyrulu 激活函数。

Re-yolo 主干网络中每个阶段的基本结构如图 2-5（b）所示，相较于 Yolov3 主干网络的基本结构，同时加深了网络的深度以及加宽了网络的宽度。深度学习网络模型的深度越深，网络对于非线性表达能力越好、能更好的去拟合特征，可以学习更为复杂的变化、拟合更为复杂的输入。并且网络越深，网络的每一层要做的事情更为简单，因此网络拥有更强的表达能力和逐层的特征学习；深度学习网络能够学习到更加丰富的特征，比如不同方向、不同频率的纹理特征，如果网络模型太窄，网络每层能够捕获到的特征有限，此时网络再深也不能提取到足够信息进行传递。

中国知网 https://www.cnki.net



（a）Yolov3 的基本结构　　（b）Re-yolo 的基本结构

图 2-5 Yolov3 与 Re-yolo 的基本结构

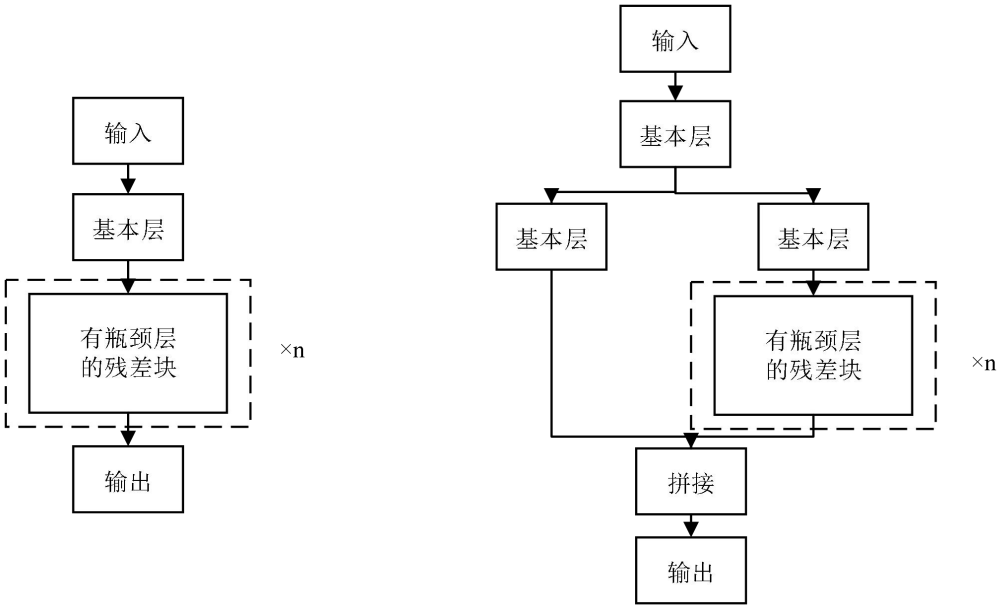
Fig.2-5 The basic structure of Yolov3 and Re-yolo

Re-yolo 采用跨阶段部分结构（Cross stage partial，CSP），以此来加宽网络模型的宽度、加深网络模型的深度。跨阶段部分结构是一种主干网络的格式，跨阶段部分结构初衷就是为了减少计算量并增强梯度的表现，增强了网络的学习能力，使轻量化网络仍具有足够的精度。同时跨阶段部分结构移除了计算瓶颈，过高的计算瓶颈会导致更多周期来完成推理过程，使得模型的预测速度变慢。在网络中的每一层均匀分配计算量，从而有效提高每层的利用率；降低内存成本。跨阶段部分结构的主要思想是在图像或者特征图输入模型中某个阶段结构之前，即 Re-yolo 中每个阶段的重复部分，将输入分成两部分，其中一部分通过残差块进行计算，另一部分直接通过卷积调整维度，然后两部分的结果进行拼接操作，输出特征。如图 2-6 所示为残差结构块与跨阶段部分结构块的对比图。

接下来分析一张图像输入到 Re-yolo 方法中，Re-yolo 的主干网络如何处理输入的图像数据并生成特征图。以输入图像大小为 446×446×3 为例，一张 446×446×3 的图像输入到 Re-yolo 模型中，首先经过两层 3×3 卷积的根茎层，进行下采样提取特征并扩大感受野，然后输出维度为 64 的特征图到第一阶段中，第一阶段结构如图 2-2（b）所示。第一阶段的重复数量为 1，输出 64 维特征图到第二阶段，第二阶段的重复数量为 2，输出 128 维特征图到第三阶段，第三阶段的重复数量为 8，经过 SE 注意力模块，输出 256 维特征图到

中国知网 https://www.cnki.net

第四阶段，第四阶段的重复数量为 8，经过 SE 注意力模块，然后输出 512 维特征图到第五阶段，第五阶段的重复数量为 4，接着输出特征图为 1024，最后经过 SE 注意力模块，将三个 SE 注意力模块的输出特征作为主干网络的输出 C_3、C_4、C_5 送入到颈部结构中。



（a）残差结构　　（b）跨阶段部分结构

图 2-6 残差结构与跨阶段部分结构

Fig.2-6 The structure of resdual block and cross stage partial block

在上文与中所提及的重复部分便是图 2-5 中的残差块，在图 2-5（b）Re-yolo 的基本结构中有两个嵌套的残差结构，重复部分在这里是外层残差结构所包括的所有结构，其中也包括内层残差结构。内层结构是经过卷积参数重构处理的残差块，卷积参数重构的内容将在下文 2.3.3 节中进行分析。

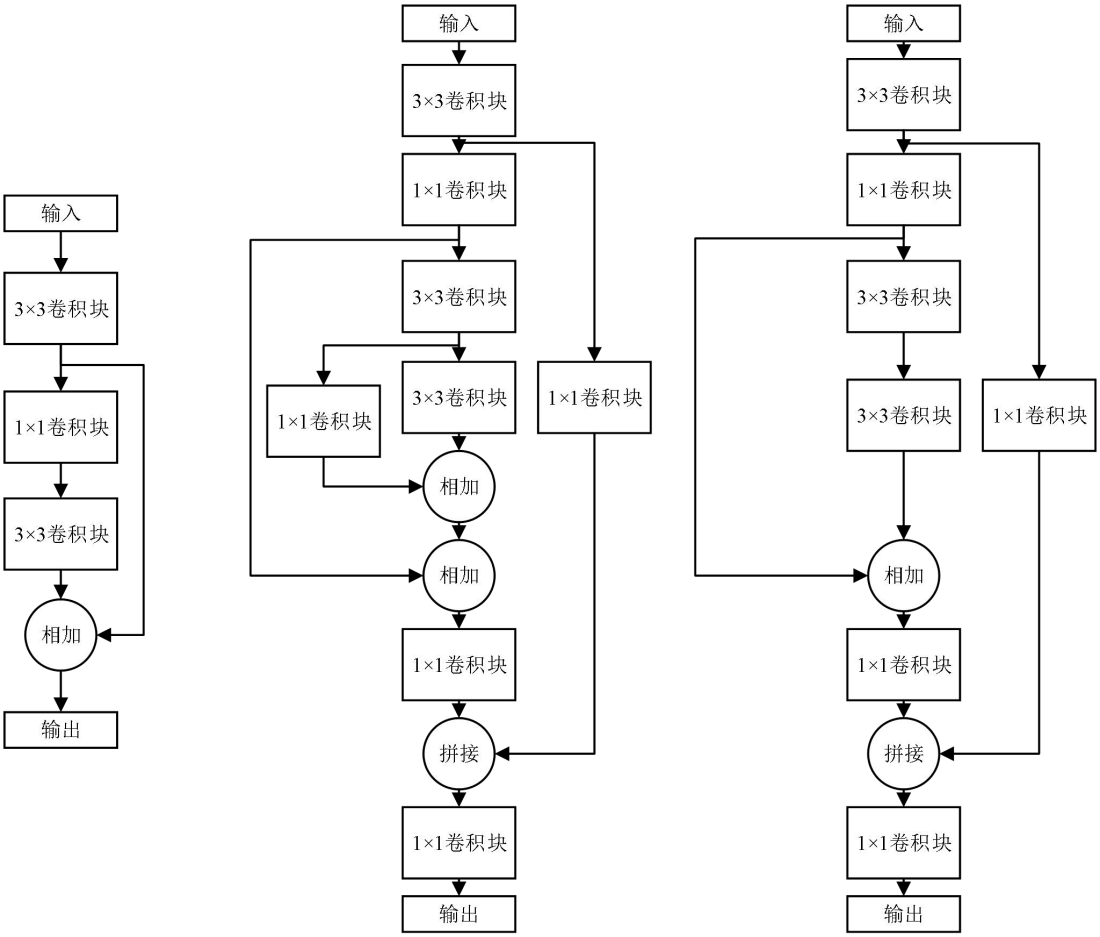
2.3.3 卷积参数重构后的基本结构

上一节中跨阶段连接方法在确保模型检测速度提升的同时，有效提升模型检测精度，没有对模型的检测速度产生负面影响。本文在考虑到森林早期火情检测任务需要更快的检测速度，以及更精准的检测精度，本文引入卷积参数重构方法对模型的基本结构进行优化。

卷积参数重构方法是一种提升模型性能的轻量化技巧，卷积参数重构方法的核心是使用计算方法与卷积的特点与计算方式使得训练过程中与预测过程中采用不同的结构。在训练过程中采用残差结构，用于提取更多、更丰富的图像特征，提升模型检测精度；预测阶段采用单分支结构的卷积，用于提升模型的预测速度。训练阶段的残差结构与预测阶段的单分支卷积不是单独存在的，通过计算以及卷积处理将训练阶段的残差结构转化为仅有 3×3 卷积的单分支结构，用于预测阶段使用，以此保留模型的特征提取能力的同时提升模型的速度。卷积参数重构方法是应用到如图 2-5（b）所展示的 Re-yolo 的基本结构的内环残差上，经过卷积参数重构后，残差结构变为单分支卷积结构，为了更好的对比基本结构的优化及变化，本文将 Yolov3 的基本结构、Re-yolo 在训练阶段的基本结构、Re-yolo 在

中国知网 https://www.cnki.net

预测阶段的基本结构进行展示对比，如图 2-7 所示。



（a）Yolov3 基本结构　（b）Re-yolo 基本结构（训练阶段）　（c）Re-yolo 基本结构（预测阶段）

图 2-7 Yolov3 与 Re-yolo（训练/预测阶段）的对比

Fig.2-7 Comparison of Yolov3 and Re-yolo (training/prediction phase)

如图 2-7（a）所示，Yolov3 基本结构为残差结构；图 2-7（b）为 Re-yolo 在训练阶段的基本结构，在 Yolov3 残差结构的基础上进行嵌套，跨阶段进行连接，加宽模型宽度；图 2-7（c）为 Re-yolo 在预测阶段的基本结构，对 Re-yolo 训练阶段基本结构中的内环嵌套的残差结构进行卷积参数重构，得到单分支的卷积结构。其中 Re-yolo 一方面在模型基本结构上进行优化改进，另一方面将激活函数进行修改。Yolov3 采用 Leakyrelu 作为其激活函数，Re-yolo 采用 Swish 激活函数替换 Yolov3 使用的 Leakyrelu 激活函数。与 Leakyrelu 激活函数相比，Swish 激活函数在全部范围内都连续可微分，更加适合模型更深、更宽的网络，但是会带来额外的计算量。经过实验，发现 Swish 激活函数在预测准确度带来的好处比其带来的额外计算量要多，所以本文仍然选择 Swish 激活函数作为 Re-yolo 的激活函数。

卷积参数重构方法是将批次归一化层与卷积的计算公式进行结合，以及将 1×1 卷积分支、1×1 卷积分支以及恒等映射分支之间进行融合。本文通过这样的方法将 Yolov3 的残差结构转化为 Re-yolo 的单分支结构，如图 2-8 所示为 Re-yolo 训练阶段残差结构转化

中国知网 https://www.cnki.net

为 Re-yolo 预测阶段单分支结构的转变过程。

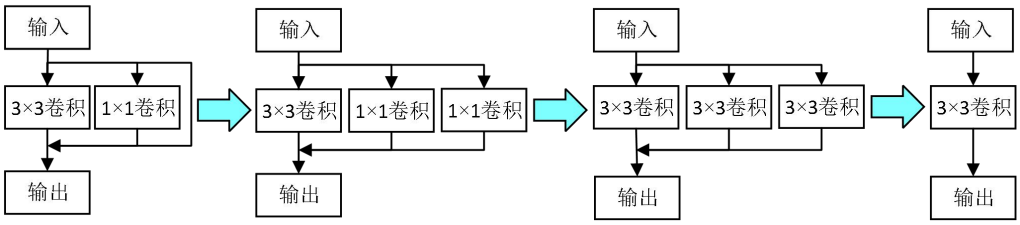


图 2-8 训练/预测阶段残差结构的转化过程

Fig.2-8 Comparison of residual structures in training/prediction stages

Re-yolo 基本结构的训练阶段转化为预测阶段首先将批次归一化层与卷积层进行融合，得到单独的卷积结构分支。批次归一化层的作用是增加网络的收敛速度，使得网络训练变得更加容易，故批次归一化层普遍存在于卷积层中。公式 2-5 为卷积的基本计算公式，输入变量 x，进入权重 W 计算后再加上偏置 b 后输出结果。公式 2-6 为 BN 层的计算公式，其中 x 为输入、Υ 与 β 分别为尺度因子与平移因子、μ 为批处理数据均值、σ^2 为批处理数据方差、ω 是为了避免除数为 0 所使用的微小正数。接下来将公式 2-5 代入到公式 2-6 中得到公式 2-7。对公式 2-7 进行整理后得到公式 2-8，公式 2-8 可以看作一个新的卷积公式。公式 2-8 中 $\Upsilon/\sqrt{var+\in}$ 可以看作卷积层与 BN 层融合后的新权重 W_{fused}，$\Upsilon\times(b-mean)/\sqrt{var+\omega}$ 可以看作融合后的偏置 b_{fused}。这样便完成了卷积层与 BN 层的融合。

$$conv(x)=W(x)+b \tag{2-5}$$

$$BN(x)=\Upsilon*\frac{x-\mu}{\sqrt{\sigma^2+\omega}}+\beta \tag{2-6}$$

$$BN(conv(x))=\Upsilon*\frac{W(x)+b-\mu}{\sqrt{\sigma^2+\omega}}+\beta \tag{2-7}$$

$$BN(conv(x))=\frac{\Upsilon}{\sqrt{\sigma^2+\omega}}\times W(x)+\frac{\Upsilon\times(b-\mu)}{\sqrt{\sigma^2+\omega}}=W_{fused}(x)+b_{fused} \tag{2-8}$$

如图 2-8 所示，完成了卷积与批次归一化层之间的融合，接下来对不同分支进行融合，分别是卷积核大小分别为 3×3 卷积、1×1 卷积的卷积分支以及恒等映射分支。首先恒等映射分支与卷积之间的融合，恒等映射分支可以看作以单位矩阵为核心的 1×1 卷积。确保恒等映射分支与的输入与 1×1 卷积分支输出一致，便可以直接进行转化，这样就可以将恒等映射分支转化为卷积核大小为 1×1 的卷积分支。接下来是 3×3 卷积分支与 1×1 卷积分支之间的融合，1×1 卷积分支在 3×3 大小的特征图上进行卷积，它的过程是卷积从左往

中国知网 https://www.cnki.net

右，从上至下依次计算特征图，卷积核经过 3×3 特征图的所有位置。对 1×1 卷积进行填充操作得到 3×3 的卷积，其中只有卷积中心有值，卷积外围为 0。让填充后的 3×3 卷积经过一个 5×5 的特征图，可以发现此时的的计算结果与 1×1 卷积的计算结果一致，1×1 卷积与填充后的 3×3 卷积中心在特征图上走过同样的位置。即可以通过填充操作使得 1×1 卷积转化为 3×3 卷积，输入值与输出结果一致。这样残差结构的不同分支都转化为 3×3 卷积，最后由于卷积的可加性，分别将三条卷积分支的权重与偏置进行相加便得到了最终的卷积核大小为 3×3 的卷积单分支结构。由此便完成了对 Re-yolo 基本结构的卷积参数重构。

2.3.4 Re-yolo 输出阶段

在 Yolov3 方法中，输出头是基于锚框的（Anchor-based）单分支结构，其分类与定位在同一条分支中进行预测，使用基于锚框的机制产生密集的边框，使得网络可直接在此基础上进行目标分类及边界框坐标回归。训练稳定密集的边框可有效提高网络目标召回能力，对于目标检测来说提升非常明显。但是缺点也有很多，首先是基于锚框机制中，需要设定的超参：尺度和长宽比是比较难设计的，这需要较强的先验知识；其次冗余框非常之多，即完全不包含目标的背景框，这会造成正负样本严重不平衡问题，也是单阶段算法难以赶超两阶段算法的原因之一；最后预测框的回归与交并比（Intersection over union，IOU）阈值的设置也是一个问题。

本文从文献[44]得到启示，分类任务和定位任务具有独立性。分类任务与定位任务所关注的重点不同，分类任务更加关注模型提取到的特征与数据集中设定的哪些类别最为相近，而定位更加关注预测框与真实框的位置坐标。当前，大部分单阶段预测模型通过并行使用两个独立的分支独立地执行分类任务与定位任务，其中包括 Yolov3 也是并行使用两个独立分支进行预测。这样的双分支设计可能会导致分类和定位之间缺乏交互，因此目标检测模型的定位任务和分类任务会存在空间不对齐的情况，从而需要对边界框进行参数修正。又从文献[45]中得到启示，文中对目标检测任务的分类和定位两个子任务进行解读，指出全连接网络组成的输出头更适合分类任务，全卷积组成的输出头更适合定位任务。因此，原本 Yolov3 的输出头的分类任务和定位任务是在一条分支上同时进行的，会存在分类与定位的任务不匹配的情况、检测精度低、误判断的情况。

根据上文分析，本文提出方法 Re-yolo 的输出头采用无锚框（Anchor-free）的预测方法，可以规避上面说到的基于锚框的预测方法并减少计算量，但是同时也存在着一些问题，比如正负样本极端不平衡的分配；当两个目标的中心点重叠时，会有语义的模糊性，无法判断是哪个目标。这些问题可以通过配合任务对齐机制进行解决，从而让无锚框的检测和分割都进一步达到实时、高精度的检测能力，如图 2-9 为 Re-yolo 输出头结构。

中国知网 https://www.cnki.net

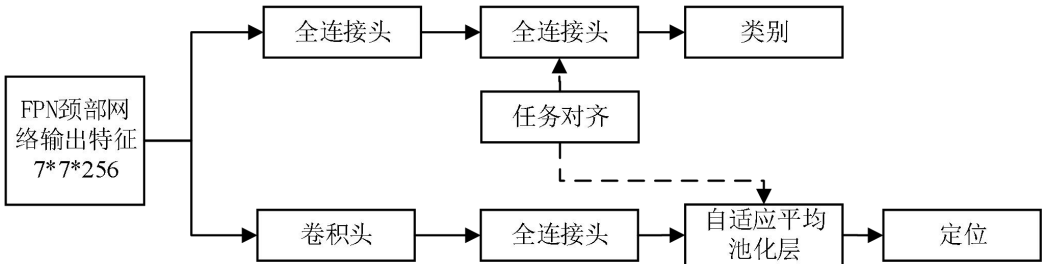


图 2-9 Re-yolo 输出头结构

Fig.2-9 The output head structure of Re-yolo

本文 Re-yolo 的输出头结构如图 2-6 所示，特征金字塔网络（Feature pyramid network，FPN）结构的颈部网络输出大小为 7×7×256 的特征图到输出头中，Re-yolo 采用多分支输出头结构，定位与分类两个任务在两条平行的分支同时进行，并且分类任务采用全连接输出头进行采样，定位任务采用卷积输出头进行采样。同时针对正负样本极端不平衡的匹配问题，在 Re-yolo 输出头中引入样本分配与任务对齐机制，用以增强两个任务之间的交互性。同时引入任务对齐学习（Task align learning，TAL）机制，用来分配最佳的锚点与样本。避免了无锚框预测方法正负样本分配不均衡、以及语义模糊性的问题。Re-yolo 同时采用更加优秀的损失函数来进行定位、分类与回归。其中分类损失函数采用 Varifocalloss，定位与回归分别采用 Distrifocalloss 与广义交并比（Generalized intersection of union，GIOU）来进行完成[51]。

$$GIOU = IOU - \frac{|A_c - U|}{|A_c|} \tag{2-9}$$

Re-yolo 中采用广义交并比代替交并比来对模型生成的负样本检测框进行抑制，公式 2-9 为广义交并比的工作原理。假设存在真实框 B、预测框 C，要计算出它们的广义交并比，先计算出 B 与 C 的交并比，A_c 为能够包含真实框 B 与预测框 C 的最小框的面积，U 为 B 与 C 的并集。交并比只关注真实框与预测框的重合部分，而广义交并比还关注其它非重合部分区域，这样能更好的反应真实框与预测框的重合度。

2.4 实验及结果分析

本文采用 FLAME 数据集来训练 Re-yolo 和其它对比方法，FALME 数据集是使用无人机在森林上空对火情进行拍摄，火焰目标小、检测难度大，更加贴合真实的森林火情监测任务。但是 FLAME 数据集背景和目标过于单一，考虑到不同背景和不同目标，对数据集进行扩充，丰富样本。本文分别训练 Re-yolo、Yolov3 以及其它方法，对它们的检测精度以及检测速度（Frames per second，FPS）进行评估对比；并对 Re-yolo 进行消融实验，证明优化后各个模块的有效性。所有网络是用 Windows 10 系统，训练和测试的 CPU 使用 i7-9700k、GPU 使用 Nvidia RTX 2080 Ti。权重衰减参数与非阻尼动量分别设置为 0.0005 与 0.99，初始学习率设置为 0.005，训练迭代次数为 300。

中国知网 https://www.cnki.net

2.4.1 评价指标

本文参照文献[9]中对模型性能进行评估的评价指标，分别采用检测精度（Accuracy）、检测速度（FPS）、召回率（Recall）以及 F_1 分数评估 Re-yolo 的检测性能。

（1）检测精度

检测精度指正样本个数除以总样本个数的结果，计算公式如 2-10 所示。

$$A=\frac{TP+TN}{TP+FN+FP+TN} \tag{2-10}$$

其中 A 指检测精度，TP 是真阳性的个数，即正样本预测正确结果的个数，TN 是真阴性的个数，即负样本预测错误的个数，TP 与 TN 属于预测正确。FP 是假阳性的数量，即正样本预测错误结果的个数，FN 为假阴性数，即负样本预测错误的个数，FP 与 FN 属于预测错误。

（2）检测速度

FPS 是指每秒处理的帧数，用于评价模型的检测效率，即用来衡量提出的火情监测方法的速度。

（3）召回率

召回率指将 TP 除以数据集中原本就有的正样本的数量，召回率越高，代表实际负样本被预测出来的概率越高，模型鲁棒性强、精度高，召回率如公式 2-11 所示。

$$Recall=\frac{TP}{TP+FP} \tag{2-11}$$

（3）F_1 分数

F_1 分数是在检测精度与召回率之间找一个平衡点，用以综合两者之间的表现。F_1 分数如公式 2-12 所示，其中 R 为召回率。

$$F_1=\frac{2\times A\times R}{A+R} \tag{2-11}$$

2.4.2 实验数据集的制作

本文在森林火情航空数据集 FLAME 中选用 6178 张图像作为数据集的一部分。另外，过拟合指可以很好的预测出数据集中的目标，但是无法成功预测其他背景的相同目标。为了防止训练出的网络出现过拟合的问题，本文扩充了原本的数据集，在其中加入 3686 张其他背景的火情图像。如图 2-10（a）所示为 FLAME 数据集中的样本，图 2-10（b）为扩充的样本之一。

中国知网 https://www.cnki.net

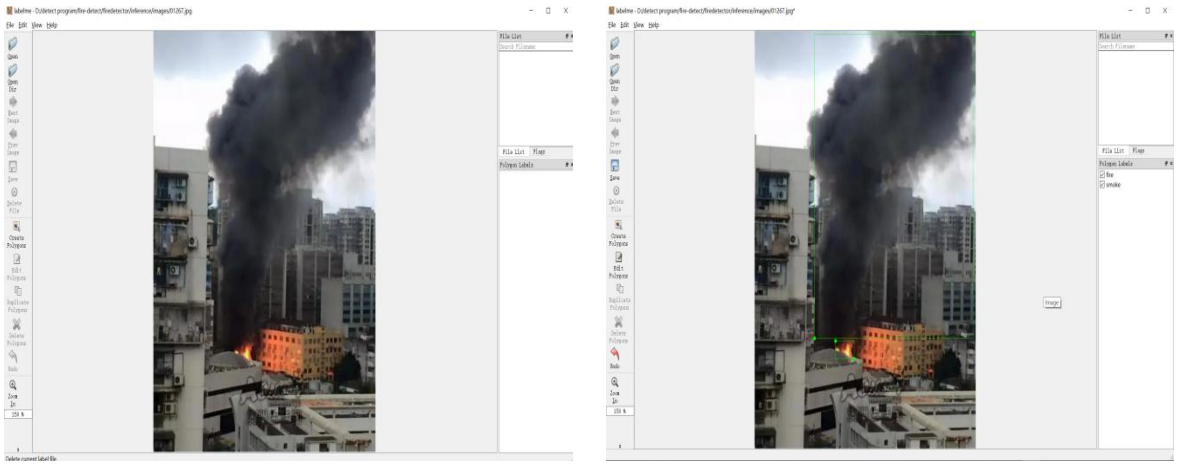


（a）FLAME 中样本之一　　（b）扩充数据集的样本之一

图 2-10 数据集中部分样本

Fig.2-10 Partial samples in the dataset

本文的数据集有两种类别，分别为烟雾以及火焰。数据集分为训练集与测试集，使用训练集中的样本训练网络，测试集用于测试网络能否准确的预测出目标。数据集共有 9864 张图像，训练集共有 8878 张图像，验证集共有 986 张图像，训练集与验证集的比例为 9：1。本文制作数据集的工具是 Labelme，如图 2-11（a）为 Labelme 的界面，图 2-11（b）为数据集真实框的制作过程。



（a）Labelme 的界面　　（b）数据集真实框的制作过程

图 2-11 Labelme 的界面及数据集真实框的制作过程

Fig.2-11 The interface of Labelme and the process of creating the real frame of the dataset

2.4.3 消融实验

Re-yolo 在 Yolov3 的基础上添加的所有模块及优化策略的有效性通过进行消融实验得到验证。在消融实验的过程中，Yolov3 与前文所述 Re-yolo 的各模块均采用相同的参数设置（学习率、迭代次数等）。以 Yolov3 在数据集上训练结果为比较基准。表 2-2 为在 Yolov3 上增加不同模块的网络在数据集训练的检测精度、FPS、召回率以及 F1 分数。

中国知网 https://www.cnki.net

表 2-2 消融实验结果

Tab.2-2 Results of ablation experiment

	检测精度	检测速度	召回率	F1 分数
Yolov3（baseline）	0.712	33.1	0.816	0.760
+New backbone	0.768（+5.6%）	34.0（+0.9）	0.831	0.798
+SE	0.778（+1.0%）	33.6（-0.4）	0.839	0.807
+New FPN	0.826（+4.8%）	34.1（+0.5）	0.852	0.839
+PPM	0.835（+0.9%）	33.4（-0.7）	0.858	0.846
+Anchor-free	0.824（-1.1%）	34.0（+0.6）	0.858	0.840
+Task align（Re-yolo）	0.843（+1.9%）	33.8（-0.2）	0.871	0.857

由表 2-2 中可以看到本文加入跨阶段新模块的主干网络以及颈部网络 FPN 带来了极高的提升，并且也在检测速度上带来了提升。其它模块也在不影响模型检测实时性的前提下提高模型的检测精度。最后两条，模型中替换为无锚框检测机制以及任务对齐机制是看作一起的，因为任务对齐机制是在无锚框检测机制之后加上的，可以看到经过这两点，检测精度提升了 0.7%，检测速度提升了 0.4FPS，同时召回率以及 F_1 分数也同样提升。由此可见 Re-yolo 所添加的新方法对模型的性能提升起到了非常关键的作用，尤其是在 Re-yolo 的主干网络以及颈部结构中所引入的跨阶段部分结构以及卷积参数重构方法。

2.4.4 对比实验

当模型检测速度高于 20FPS 时，则认为模型可以实现实时检测。本文分别训练 Re-yolo、Yolov3[40]、mobilenetv2-yolov3、Efficientdet[51]以及 Yolov5-s 小模型 5 种目标检测模型（其中 mobilenetv2-yolov3 是在 Yolov3 的框架下将主干网络替换为 Mobilenetv2 的主干网络所得到的方法），分别得到这些模型的检测精度、检测速度、召回率以及 F1 分数，如表 2-3 所示。

表 2-3 Re-yolo 与其他模型检测精度和检测速度的比较

Tab.2-3 Comparison of detection accuracy and detection speed between Re-yolo and other models

	检测精度	检测速度	召回率	F1 分数
Re-yolo	0.843	33.8	0.871	0.857
Yolov3	0.712	33.1	0.816	0.760
mobilenetv2-yolov3	0.687	42.7	0.741	0.712
Efficientdet	0.803	36.0	0.826	0.814
Yolov5-s	0.831	35.2	0.868	0.849

由表 2-3 可得本文提出的方法 Re-yolo 不管在检测精度还是在检测速度上都超过了 Yolov3，检测精度提升了 0.131，检测速度提升了 0.7。表中可以看到检测速度第一高的是 mobilenetv2-yolov3，为 42.7。第二高的是 Efficientdet，为 36.0。而检测精度最高的是本文的 Re-yolo。本文方法 Re-yolo 与 Efficientdet 相比，虽然检测速度没有 Efficientdet 快，但相差并不多，并且都已达到了实时的效果。根据以上分析来看，本文的方法是更加优秀

中国知网 https://www.cnki.net

的，可以在实时的检测速度下达到更高的准确率，Re-yolo 可以在早期森林火情监测中更加实时精准的完成火情监测任务。

2.4.5 检测结果

本文在数据集中随机选取 5 张图像分别在 Yolov3 方法以及 Re-yolo 方法上进行检测，如图 2-12 所示原图、Yolov3 所检测出的结果以及 Re-yolo 所检测出的结果。



（a）原图　　（b）Yolov3 检测结果　　（c）Re-yolo 检测结果

图 2-12 原图、Yolov3 检测结果、Re-yolo 检测结果对比图

Fig.2-12 Comparison of original image, Yolov3 detection results, and Re-yolo detection results

如图 2-12 中展示的检测结果中，第一列为原图，第二列为 Yolov3 的检测结果，第三列为 Re-yolo 的检测结果。从图中可以观察到，一些被 Yolov3 所未能检测到的目标、检

中国知网 https://www.cnki.net

测错误的目标或者检测边框不够准确的情况可以在 Re-yolo 中得到修正。例如，第一行至第五行中，很多漏检的的目标被 Re-yolo 所检测出来。这些漏检目标中包括一些小目标，例如第一行与第二行。也包括一些较大的目标，如第三行与第五行中，有两个目标，图像中间一个，图像右下角一个，Yolov3 只检测出位于图像中央的目标，而 Re-yolo 将火焰目标全部检测了出来。

2.5 本章小结

针对在地面端准确快速地进行火情检测任务，本文提出了一种基于 Re-yolo 的火情检测方法。这里首先分析 Yolov3 的整体结构，包括其主干网络、颈部网络以及预测方法。然后分析本文方法 Re-yolo 的整体结构，与 Yolov3 整体结构进行对比。接下来分析优化方法，引入参数重构方法、跨阶段部分结构以及任务对齐机制等优化策略，保证模型检测速度的前提下提升模型对于火情检测的准确性。最后通过对比实验、消融实验得到 Re-yolo 方法的优秀性。通过上文以及实验结果验证，证明 Re-yolo 目标检测方法可以完成快速准确的火情监测，并且对于小目标的检测结果同样有效，早期检测出森林火情有助于及早发现和扑灭森林火灾。

中国知网 https://www.cnki.net

3 基于 Reyolo-tiny 高效实时的轻量化方法

3.1 引言

上文介绍了地面端对于森林火情监测的目标检测方法 Re-yolo，这种方法对于火情监测任务，实时性与精度表现都很好，可以在地面端准确实时的监测森林火情。但是地面端的硬件条件要更好，地面端计算机的运算能力远强于小型无人机上搭载的机载计算机，将 Re-yolo 方法应用在空中无人机实时监测森林火情任务的话，监测速度会大幅度下降。Re-yolo 方法由于采用了卷积参数重构方法，降低了模型的计算量，极大提升模型的预测速度。Re-yolo 方法在地面端可以达到实时的效果，但是在无人机的机载计算机上检测速度仍需要提升。对于无人机空中监测森林火情的任务，监测准确度固然重要，但是更加重要的是监测速度，因为森林火情一旦发生，救火任务刻不容缓，需要在第一时间监测火情情况。因而对于基于无人机的森林火情监测任务，监测速度相比于监测准确度要更重要一些，但同时也不能完全为了监测速度而降低太多监测准确度。本文对 Re-yolo 方法进行轻量化处理，引入结构轻量化方法，并使用模型剪枝对结构轻量化后的方法进行滤波器剪枝处理，提升 Re-yolo 检测速度的同时保留其检测精度，以此提供一种轻量化思路与适用于空中端的轻量化模型。

本章节的安排如下：首先对增强后的 Re-yolo 模型进行分析；然后分别对特征提取网络、特征融合网络以及预测输出头的原理和结构进行分析；接下来分析本文采用的轻量化方法以及轻量化后检测模型，并且分析滤波器剪枝的过程。最后给出相应的实验评价以及对比实验结果，以此证明本文轻量化思路的可靠性以及轻量化后模型的有效性。

3.2 增强后 Re-yolo 的整体结构

随着计算机硬件以及深度学习模型的发展，在基于图像的计算机视觉任务上，各种优秀的的基于图像的目标检测方法层出不穷，越来越多研究人员将研究重点转移到这个方面，目标检测任务的精度和效率越来越高、越来越好。其中尤其是 Yolo 系列目标检测模型最为瞩目，受到广大研究人员的研究与关注。Yolo 系列目标检测网络版本众多，Yolo 系列的开山之作是 Yolov1[53]，Yolov1 于 2015 年提出，在当时可以快速准确的完成目标检测任务；Yolov1 的原作者在接下来提出了 Yolov2[54]，Yolov2 如同其文章名称一样可以更快更好更强的进行目标检测任务；仍是原作者在 2017 年提出 Yolov3[40]，Yolov3 一出在目标检测、深度学习领域引起广泛关注，由于其检测的精度与速度，直到现在 Yolov3 仍在各个检测环境进行应用；再之后值得一提的是 Yolov4[55]与 Yolov5，这两个模型并非 Yolov3 原作者所提出，而是由相关公司提出的，这两个模型在 Yolo 家族中首次采用跨阶段连接网络，进一步提升模型检测速度与精度，达到一个全新的高度。之后研究人员继续丰富 Yolo 系列，相继提出 Yolox、Yolov6、Yolov7[56]等全新方法，本文采用 Re-yolo 目标检测方法作为基础模型，进而提出一种模型轻量化思路与适用于空中端的轻量化模型。

中国知网 https://www.cnki.net

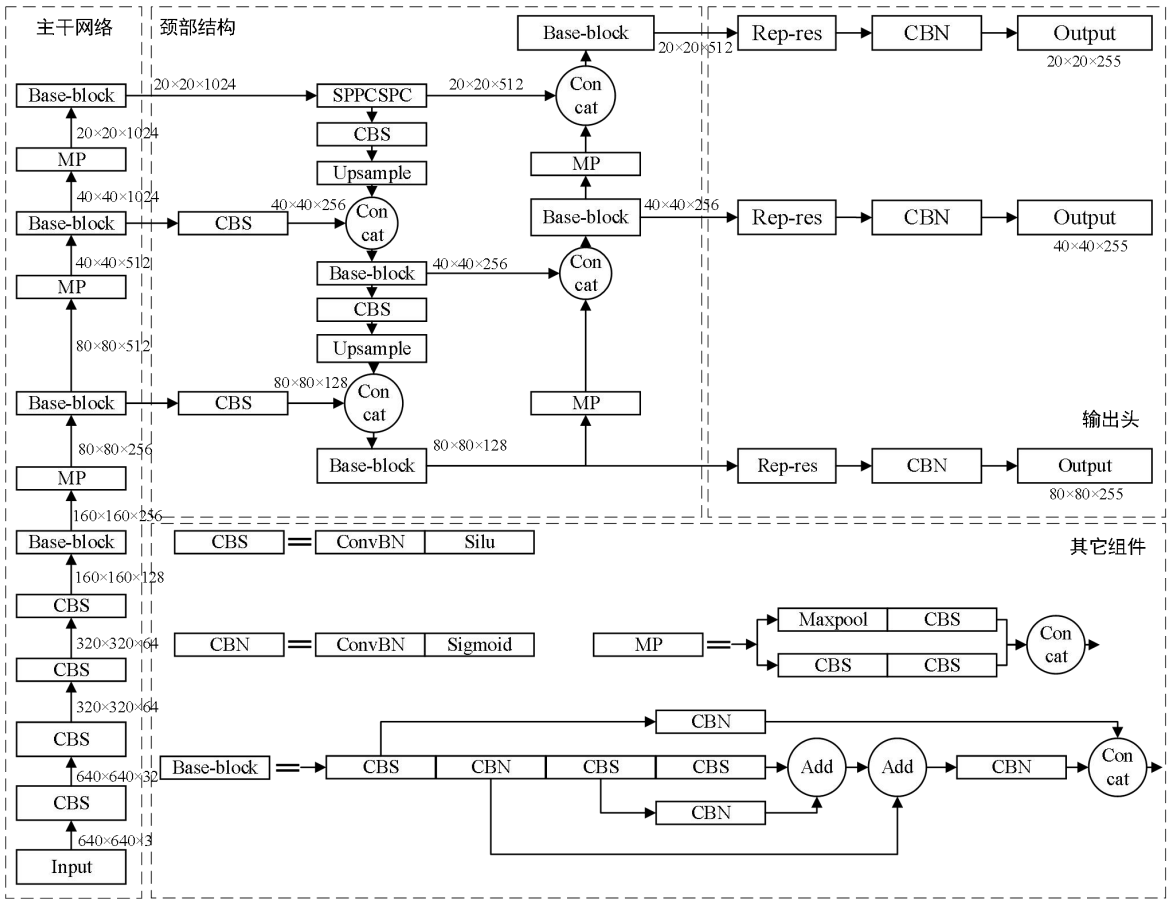


图 3-1 增强后 Re-yolo 的整体结构

Fig.3-1 The overall structure of enhanced Re-yolo

如图 3-1 为增强后 Re-yolo 的整体结构，Re-yolo 整体结构可分为用于提取图像特征的主干网络、用于融合图像特征图的颈部结构以及用于计算定位、分类等输出结果的输出头结构。为了提高轻量化处理后模型的检测精度，本文分别对主干网络、颈部结构以及输出头进行调整，增强模型的特征提取融合能力，提升模型的检测精度。由图中不难看出，增强后 Re-yolo 的整体结构相比于原始 Re-yolo 方法要更复杂一些，其中引入了一些新的方法与新的结构。其中修改的地方如下：（1）在主干网络中加入 MP 结构，进行降维并减少模型参数量，并通过多分支结构提升模型的特征提取能力；（2）将主干网络的结构进行修改，图像输入后，先经过四层带有 Silu 的卷积结构。然后再将特征图送入 Re-yolo 的基础结构与 MP 结构，其中增强后 Re-yolo 的基本结构与原始 Re-yolo 的基本结构相同；（3）颈部结构中引入 SPPCSPC 结构，并在原本 Re-yolo 颈部结构中自下而上的融合图像特征；（4）输出头中引入 Rep-res 结构，提升模型在训练阶段特征提取能力的同时，提升模型在预测阶段的预测速度。将这种输出方式称作辅助输出头，辅助输出头只存在于训练阶段，预测阶段仍采用原先输出头。这样做的目的是以增加训练成本为代价，提升模型的特征提取能力，提高模型的预测精度，同时不影响预测阶段模型的检测速度。

中国知网 https://www.cnki.net

3.2.1 增强后 Re-yolo 的主干网络

图 3-1 中给出了增强后 Re-yolo 的整体结构，本文给出详细的细节信息，以输入模型图像大小为 640×640×3 为例，细节信息如表 3-1 所示。

表 3-1 主干网络的详细架构

Tab.3-1 Detailed architecture of the backbone network

输入数图像大小	操作	数量	步长	输出通道	输出特征图大小
640×640×3	Conv 3×3	1	1	32	640×640×32
640×640×32	Conv 3×3	1	2	64	320×320×64
320×320×64	Conv 3×3	1	1	64	320×320×64
320×320×64	Conv 3×3	1	2	128	320×320×128
320×320×128	Base-block	11	-	256	160×160×256
160×160×256	MP	13	-	256	80×80×256
80×80×256	Base-block	13	-	512	80×80×512
80×80×512	MP	13	-	512	40×40×512
40×40×512	Base-block	13	-	1024	40×40×1024
40×40×1024	MP	13	-	1024	20×20×1024
20×20×1024	Base-block	13	-	1024	20×20×1024

Re-yolo 主干结构中使用的结构块组件有 CBS、Base-block 以及 MP，这些结构块组件的组成图在图 3-1 中其它组件中进行展示。由图中可得，CBS 组件是由卷积层、批次归一化层以及激活函数 Silu 组成。Silu 激活函数与 Relu 激活函数最大的区别在于非线性部分不同，其中 Relu 激活函数在输出大于 0 的部分直接输出，其它输出 0，这样的做法使得模型的训练更加高效，Relu 激活函数如公式 3-1 所示；Silu 激活函数相比于 Relu 激活函数，越接近 0 函数曲线越平滑，并使得模型的输出在 0 到 1 之间，这些特性使得 Silu 激活函数比 Relu 激活函数更适用于目标检测网络，Silu 激活函数如公式 3-2 所示。

$$f(x)=\begin{cases} x, \ if \ \mathrm{x}>0 \\ 0, \ if \ \mathrm{x}\le 0 \end{cases} =\max(0,x) \tag{3-1}$$

$$Silu(x)=x\times sigmoid(x)=\frac{x}{1+e^{-x}} \tag{3-2}$$

本文以输入 Re-yolo 大小为 640×640×3 的图像为例，图像首先经过带有卷积核大小为 3×3 卷积的 CBS 结构，输出通道为 32，得到输出为 640×640×32 的特征图。大小为 640×640×32 的特征图经过带有卷积核大小为 3×3 卷积的 CBS 结构，这两层卷积的输出通道都为 64，经过两层 CBS 结构得到大小为 320×320×64 的特征图。大小为 320×320×64 的特征图经过带有卷积核大小为 3×3 卷积的 CBS 结构，这层卷积的输出通道为 128，输出大小为 320×320×128 的特征图。经过这四层 CBS 结构，提取图像特征，扩大感受野。

中国知网 https://www.cnki.net

接着图像进入网络更深的层数，首先经过 11 层 Base-block 结构，输出大小为 160×160×256 的特征图。接着经过 13 层 MP 结构与 13 层 Base-block 结构，输出大小为 80×80×512 的特征图。接着再经过 13 层 MP 结构与 13 层 Base-block 结构，输出大小为 40×40×1024 的特征图。最后再经过 13 层 MP 结构与 13 层 Base-block 结构，输出大小为 20×20×1024 的特征图。其中大小为 80×80×512、40×40×1024、20×20×1024 的特征图作为输入输出向颈部结构进行特征融合。由上述可得，增强后 Re-yolo 模型的主干结构很深，能够提取更深层次语义特征，但同样的也会带来一定的计算量。关于主干网络中的 MP 结构在下文进行详细介绍。

3.2.2 增强后 Re-yolo 的颈部网络

增强后 Re-yolo 的颈部网络与原始 Re-yolo 的颈部结构不同，原始 Re-yolo 采用带有金字塔池化模型的特征金字塔网络，而增强后 Re-yolo 采用带有 SPPCSPC 的路径聚合特征金字塔网络（Path aggregation feature pyramid network，PAFPN）。特征金字塔网络自上而下的融合图像特征，而路径聚合特征金字塔网络在自上而下的融合特征的基础上，再进行自下而上的融合特征。路径聚合特征金字塔网络如图 3-2 所示。

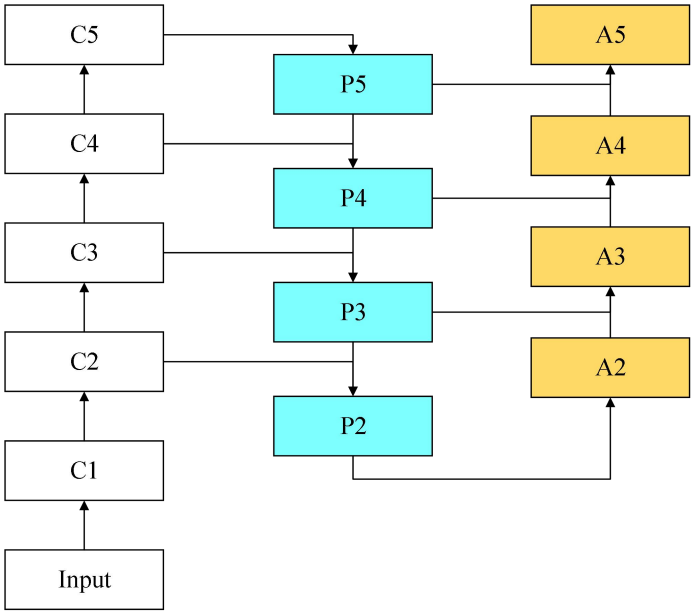


图 3-2 路径聚合特征金字塔网络

Fig.3-2 Path aggregation feature pyramid network

图中首先输入图像到主干网络中，主干网络中的特征图由 C_n（n=1,2,3,4,5）进行表示。然后主干网络提取到的的特征图送入金字塔网络中进行特征融合，特征融合后的特征图由 P_n（n=1,2,3,4,5）进行表示，进行自上而下的特征融合。接着将金字塔网络中初步融合的特征图再进行自下而上的特征融合，得到特征图 A_n（n=1,2,3,4,5）。最后再将路径聚合特征金字塔网络融合好的特征图送入输出头进行下一步预测操作。在文献[57]中，路径聚合特征金字塔网络的连接部分是短接连接操作，本文中模型在路径聚合特征金字塔网络的连接部分是张量连接操作。

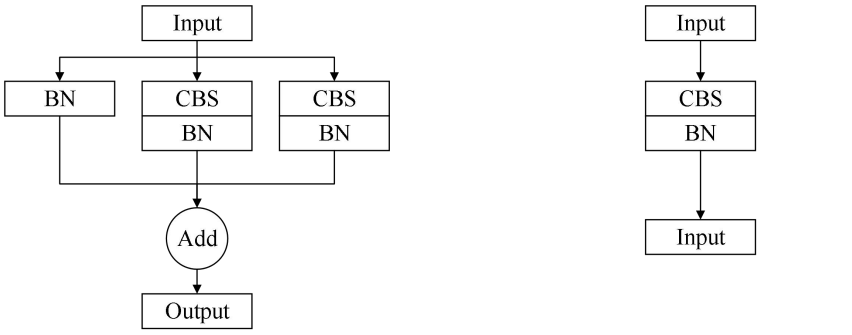
中国知网 https://www.cnki.net

路径聚合特征金字塔提出了自下而上的路径增强模式，用下层特征图语义丰富、定位精准的特点来增强模型的特征表达能力，并将下层到上层的特征路径缩短，从而使模型特征表达能力更强、预测能力更高效。

3.2.3 增强后 Re-yolo 的输出头

增强后 Re-yolo 颈部网络融合后的特征 P3、P4、P5 输入到输出头后，首先经由 Rep-res 结构调整特征图的通道，然后再由 1×1 的卷积对图像中的目标进行定位、分类，得到目标检测后的结果。

关于辅助输出头，在训练阶段，牺牲模型的运算速度，提高模型的特征提取能力以及预测精度。而在预测阶段，增强后 Re-yolo 的输出头将训练阶段的辅助输出头转换为简单的卷积结构，从而达到提升模型的特征提取能力、提升模型的预测精度的同时，保持模型在预测阶段的检测速度，大大提高模型的预测效率。实现这一结果的操作是使用卷积参数重构方法，与原始 Re-yolo 相同，增强后 Re-yolo 的输出头在训练阶段采用特征提取能力更强的残差网络作为辅助输出头。通过卷积参数重构方法，增强后 Re-yolo 模型在预测阶段采用简单的单分支卷积结构作为预测输出头。如图 3-3 为增强后 Re-yolo 分别在训练阶段与预测阶段的 Rep-res 结构。



（a）训练阶段输出头结构　　（b）预测阶段输出头结构

图 3-3 增强后 Re-yolo 训练阶段/预测阶段的输出头结构

Fig.3-3 The output head structure for enhanced Re-yolo training/prediction phase

如图 3-3（a）为增强后 Re-yolo 在训练阶段的输出头结构，图 3-3（b）为增强后 Re-yolo 在预测阶段的输出头结构，在原始 Re-yolo 方法中已详细介绍这种方法的原理，在此便不再赘述。

3.2.4 增强后 Re-yolo 的其它组件

上文分析了增强后 Re-yolo 方法用于提取图像特征的主干网络、用于融合图像特征的颈部结构以及输出头的输出方式，本节对增强后 Re-yolo 使用的组件进行分析。这些组件分别是 MP 模块、SPPCSPC 模块。

MP 模块在增强后 Re-yolo 的主干网络中重复使用，MP 模块与 Base-block 模块一起出现，用于进行下采样操作，如图 3-4 所示为 MP 模块的结构。MP 模块有两条分支，第一条分支首先经过一个最大池化层操作，用于下采样，接着经过一个卷积核大小为 1×1

中国知网 https://www.cnki.net

的卷积调整特征图通道数。第二条分支首先经过一个卷积核大小为 1×1 的卷积调整特征图通道数，然后将特征图送入卷积核大小为 3×3、步长为 2 的卷积，这里的卷积用于进行下采样操作。最后将这两个分支的特征图进行拼接叠加操作，得到 MP 模块的输出。

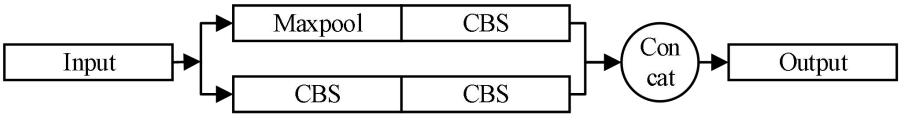


图 3-4 MP 模块的结构

Fig.3-4 The structure of the MP module

增强后 Re-yolo 在颈部结构中使用 SPPCSPC 模块，在上文分析的原始 Re-yolo 中，这里使用的是金字塔池化模块，SPPCSPC 是增强后 Re-yolo 基于空间金字塔池化（Spatial pyramid pooling，SPP）模块引入跨阶段连接进行修改增强的。空间金字塔池化模块的作用是增强感受野，这使得模型能够适应不同大小、不同分辨率的图像特征图，通过不同大小的最大池化来获得不同大小的感受野。如图 3-5 所示为 SPPCSPC 模块的结构，有两条分支，第一条分支是原始的空间金字塔池化模块，第一条分支中存在四层最大池化层，这四条池化层大小分别为 1×1、5×5、9×9、13×13。这四条不同大小的池化分支代表模型模型能够处理不同大小的对象，这四种不同尺度的池化层，用于区分大目标与小目标，提升模型的检测精度。SPPCSPC 的第二条分支是一个跨阶段连接操作，将输入 SPPCSPC 模块的特征图并行的分为两部分，其中一部分经过卷积的操作，另一部分经过空间金字塔池化操作，最后将这两个分支的输出结果进行叠加拼接。以这个方式提升模型的检测精度，同时减少了一半的计算量，提升模型的检测速度。

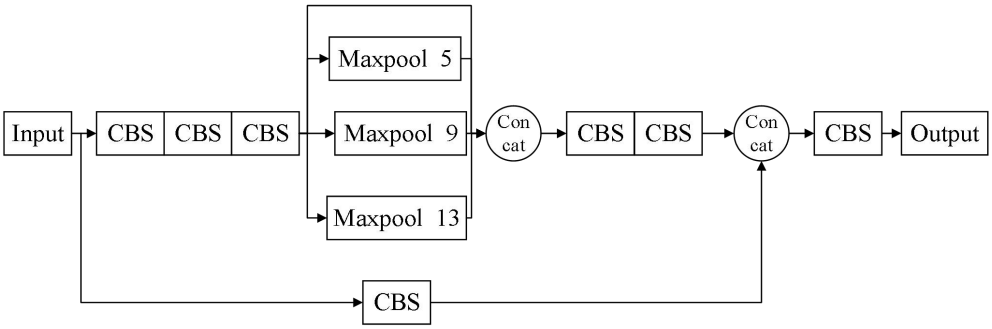


图 3-5 SPPCSPC 模块的结构

Fig.3-5 The structure of the SPPCSPC module

3.3 Re-yolo 的轻量化处理

3.3.1 轻量化模型

本文提出的 Re-yolo 目标检测方法有更高效的特征提取能力以及更精准的检测精度，本章针对无人机机载计算机算力有限的问题，考虑了两个阶段的轻量化方法对增强后 Re-yolo 模型进行轻量化处理。第一阶段是使用 Xception[58]系列模型、Mobilenet[59,60,61]系列模型、Shufflenet[62,63]系列模型等轻量化模型的特征提取网络对 Re-yolo 的模型进行替换。

中国知网 https://www.cnki.net

经过实验，本文选择用 Mobileone[64]轻量化方法的主要模块对 Re-yolo 进行替换。第二阶段使用滤波器剪枝方法对经过第一阶段轻量化处理后的 Re-yolo 进行简化、加速。

本文对 Re-yolo 模型进行轻量化处理，首先想到的是将轻量化模型与 Re-yolo 进行结合，以此减少模型的计算量，提升模型的检测速度。首先是 Mobilenet 轻量化模型系列，Mobilenet 系列有 4 个方法，分别是 Mobilenetv1、Mobilenetv2、Mobilenetv3 以及 Mobileone。Mobilenetv1 的主要思想是提出了深度可分离卷积（Depthwise separable convolution，DSC），用深度可分离卷积来代替普通卷积，以此来大幅度降低模型的计算量与参数量，从而提升模型的检测速度。

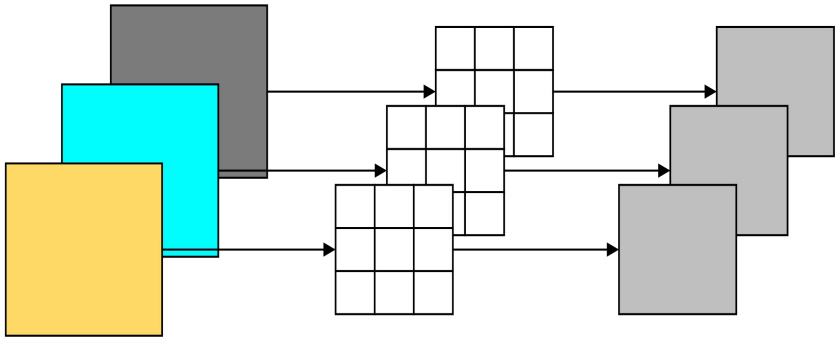


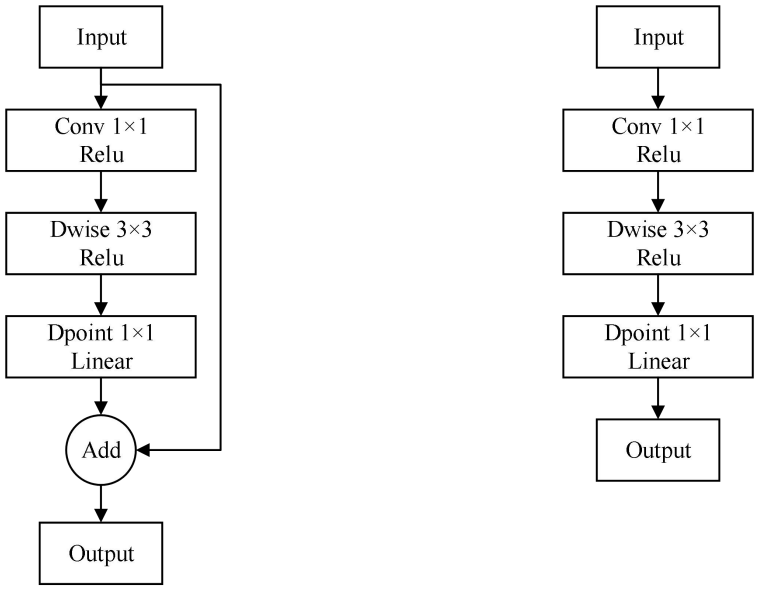
图 3-6 逐通道卷积操作

Fig.3-6 Depthwise convolution operation

深度可分离卷积由逐通道卷积以及逐像素卷积结合，逐通道卷积的一个卷积核只卷积一个通道的值，即一个通道只被一个卷积进行卷积提取特征图，如图 3-6 为逐通道卷积的工作原理。逐通道卷积的一个卷积核对输入图像的一个通道进行卷积，反过来讲，一个通道只被一个卷积核卷积。假设输入逐通道卷积的特征图大小为 3×3×3，通道数为 3，逐通道卷积的卷积核数量与输入特征图的通道数相同，经过卷积操作随即生成 3 张特征图。逐通道卷积输出的特征图数量与输入层的通道相同，无法扩展特征图，并且这样做无法有效利用不同通道在相同空间位置上的特征，逐点卷积的出现解决了这个问题，逐点卷积对逐通道卷积输出的特征图进行加权组合，输出新的特征图。深度可分离卷积可以通过减少卷积参数来提升模型速度，但相应的模型精度会有所降低，并且其内存访问量很高，无法在 GPU 上达到一个很快的速度。

Mobilenetv2 在 Mobilenetv1 的基础上提出倒置残差模块，倒置残差模块如图 3-7 所示，图 3-7（a）为逐通道卷积步长为 1 的倒置残差模块，图 3-7（b）为逐通道卷积步长为 1 的倒置残差模块。对于逐通道步长为 1 的倒置残差模块，这个模块由三个卷积，第一步是用于调整维度的 1×1 卷积，第二步是逐通道卷积与逐点卷积的组合，最后将特征图进行相加操作。以这种方法大幅减少模型计算量，提高模型速度。

中国知网 https://www.cnki.net



（a）步长为 1 的倒置残差模块　　（b）步长为 2 的倒置残差模块

图 3-7 倒置残差模块结构

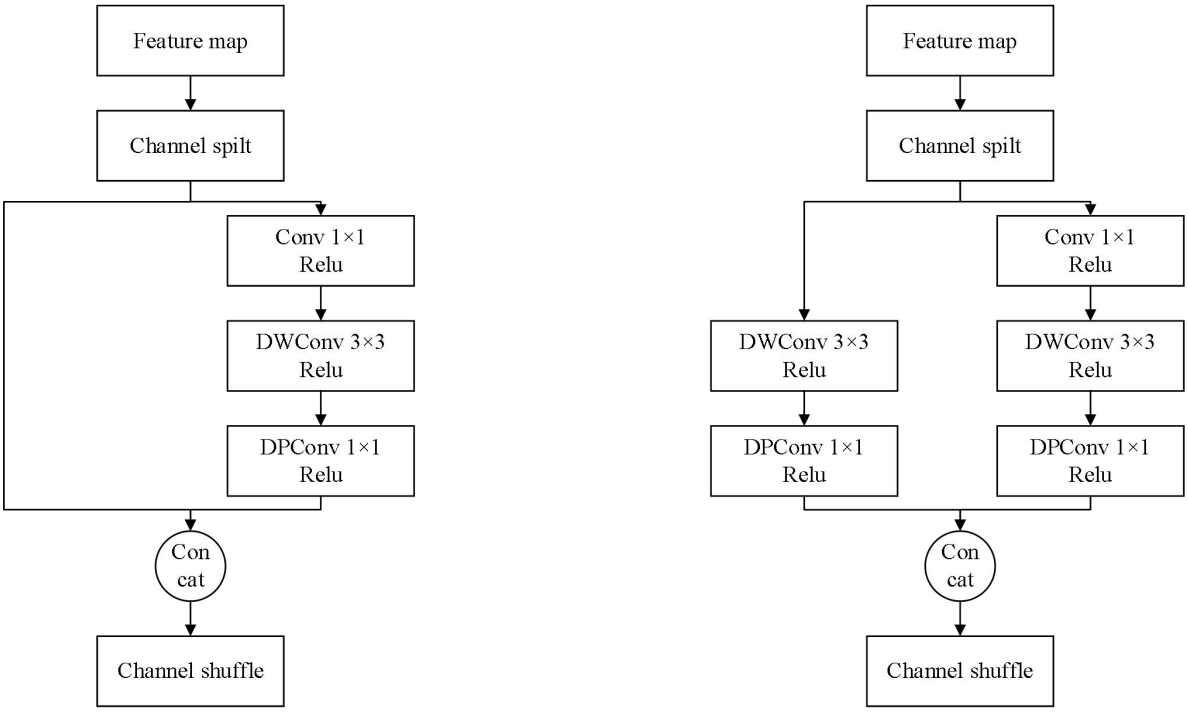
Fig.3-7 The structure of inverted residual module

Shufflenetv1 与 Mobilenetv2 类似，也采用了带有深度可分离卷积的残差结构。区别在于 Shufflenetv1 将残差结构中用于调整特征图维度的 1×1 卷积替换为通道混洗操作，将 1×1 卷积所消耗的时间省去，增强不同特征之间的信息交互。Shufflenetv2 通过分析 Mobilenetv2 与 Shufflenetv1 分别在 GPU 与 ARM 上的运行速度以及时间分布，提出了四点关于轻量化的思路：（1）当卷积的输入与卷积的输出通道数量相同时，模型的内存损失量（Memory access cost，MAC）在计算过程中最少；（2）分组卷积的数量越多，模型所需要的内存损失量就越多；（3）模型中的不同分支进行不同碎片化的操作，即不同分支进行不同的卷积或池化操作，这样碎片化的操作同样会加大内存损失量；（4）模型中像素操作，如激活函数、相加操作、叠加操作等同样会产生大量延时。

基于上述问题，Shufflenetv2 提出基本模块，Shufflenetv2 的基本模块如图 3-8 所示，图 3-8（a）为逐通道卷积步长为 1 的基本模块，图 3-8（b）为逐通道卷积步长为 2 的基本模块。与 Shufflenetv1 的基本模块相比，这里去掉了分组卷积以及相加操作，将相加操作换成了叠加操作。在步长为 2 的基本结构中，将平均池化层换成深度可分离卷积操作，同时在模块的末端加入通道混洗操作，减少模型计算量。

Mobileone 轻量化模型是苹果公司于 2023 年提出的，Mobileone 类似于 Re-yolo 方法采用卷积参数重构技巧，模型中由一个主要模块组成。Mobileone 主干网络由 8 个阶段，前 6 个阶段主要模块的数量分别为 1、2、8、5、5、1，经过 6 个阶段的主要模块的处理后输出特征图到平均池化层，最后再通过线性层将特征图转为一维的特征。

中国知网 https://www.cnki.net



（a）步长为 1 的 Shufflenetv2 基本模块　　（b）步长为 2 的 Shufflenetv2 基本模块

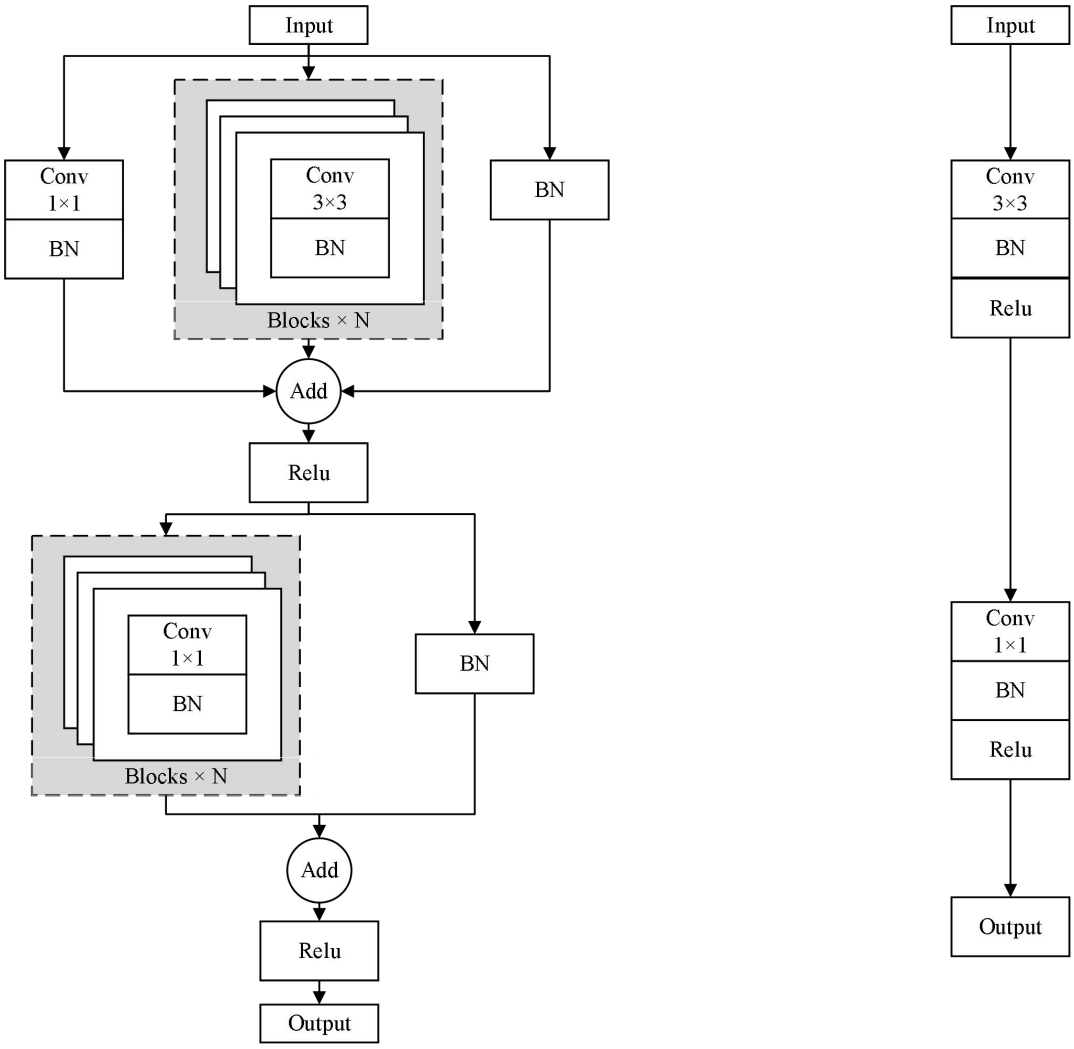
图 3-8 Shufflenetv2 基本模块的结构

Fig.3-8 The structure of the Shufflenetv2 base module

如图 3-9 为 Mobileone 模型的主要模块，其主要模块同样采用卷积参数重构方法处理，训练阶段与预测阶段使用不同结构，用以提升训练阶段的特征提取能力以及预测精度，减少预测阶段的计算量并提高模型预测的速度。如图 3-9（a）为 Mobileone 训练阶段的主要模块，图 3-9（b）为 Mobileone 预测阶段的主要模块，其训练阶段的主要模块是基于 Mobilenet 的深度可分离卷积结构进行建立的。

由于 Mobileone 轻量化目标检测方法的优秀性，本文使用 Mobileone 的主干网络替换 Re-yolo 的主干网络，并将 Re-yolo 中的基本卷积模块替换为 Mobileone 模型的基本模块，如图 3-10 所示为替换轻量化主干网络以及主要模块后的结构图。由图中可得，轻量化后的 Re-yolo 与原本的 Re-yolo 整体结构不变。本文在 Re-yolo 整体结构的基础上，将主干网络替换为 Mobileone 的主干网络，并将颈部网络中的基本卷积块替换为 Mobileone 的基本结构。本文以输入图像大小为 224×224×3 为例，第一阶段基本模块中滤波器数量为 64，即第一阶段输出通道为 64，图像经过第一阶段基本模块提取特征后输出大小为 112×112×64 的特征图；第二阶段基本模块中滤波器数量为 64，即第二阶段输出通道为 64，图像经过第二阶段基本模块提取特征后输出大小为 56×56×64 的特征图；第三阶段基本模块中滤波器数量为 128，即第三阶段输出通道为 128，图像经过第三阶段基本模块提取特征后输出大小为 28×28×128 的特征图。

中国知网 https://www.cnki.net



（a）训练阶段的基本模块　　（b）预测阶段的基本模块

图 3-9 Mobileone 在训练阶段/预测阶段的基本模块

Fig.3-9 The basic module of Mobileone in the training phase/prediction phase

第四阶段基本模块中滤波器数量为 256，即第四阶段输出通道为 256，图像经过第四阶段基本模块提取特征后输出大小为 14×14×256 的特征图;第五阶段基本模块中滤波器数量为 256，即第五阶段输出通道为 256，图像经过第五阶段基本模块提取特征后输出大小为 14×14×256 的特征图；第六阶段基本模块中滤波器数量为 512，即第六阶段输出通道为 512，图像经过第六阶段基本模块提取特征后输出大小为 7×7×512 的特征图。其中最后三个阶段基本结构输出的特征图输出向颈部网络进行特征融合，至此 Re-yolo 的轻量化处理的第一步完成将这一步得到的模型称为 Reyolo-Mobileone，接下来对模型进行剪枝操作，进一步减少模型的计算量。

中国知网 https://www.cnki.net

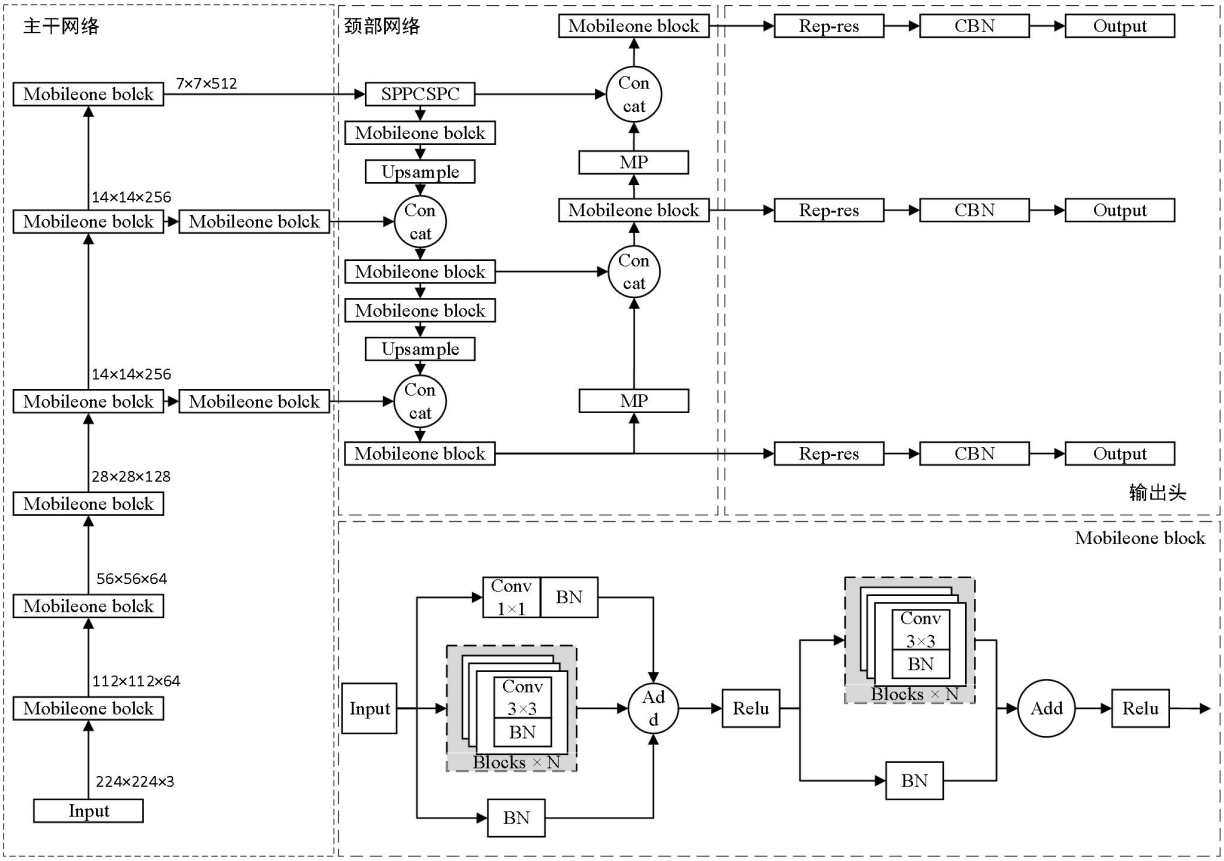


图 3-10 Reyolo-Mobileone 替换轻量化主干网络以及主要模块后的结构

Fig.3-10 The structure of Reyolo-Mobileone replaces the lightweight backbone network and the main module

3.3.2 模型压缩

由于计算机和工业界应用硬件在配置上的差别，计算机的计算能力要远远强于工业界应用硬件，那么研究人员使用计算机提出的优秀的检测算法模型需要实际落地在工业界应用中，通常会出现检测速度慢、延迟时间长、效率低下的问题。于是深度学习一个全新的领域进而出现，模型压缩方法可以将复杂且计算量大的模型转换为一个简单且计算量小的轻量化模型，在模型压缩的过程中减少计算量、内存占有、运算时间，进而使得模型可以在工业界硬件成功落地，达到实时的检测速度并保持高准确率的检测精度。通过上述可得，模型压缩方法是对复杂模型进行加速、轻量化的技术，近年来模型压缩的主流方法有以下 5 种：数值量化方法，即模型量化方法、模型稀疏化方法，即模型剪枝、知识蒸馏方法、轻量化网络设计、张量分解方法。其中模型剪枝方法通过对模型进行剪枝直接减少模型中的参数量，受到广泛研究人员的关注，本文使用模型剪枝方法对 Re-yolo 进一步进行轻量化。

模型剪枝方法的步骤一般有三步，首先正常训练原模型，然后对模型进行剪枝处理，接下来重新训练模型，在模型的检测精度与预测速度达到预期目标之前，以上三个步骤循环迭代，直到模型的检测精度与预测速度达到预期目标。模型剪枝一般来讲分为两种，其中一种是权重剪枝，权重剪枝只是将模型中的部分权重去掉，并不会改变模型的网络结构，这种做法虽然对模型进行了简化，但是这种对模型进行剪枝的方式，并不能达成工业界硬

中国知网 https://www.cnki.net

件的高速精准检测效果。另一种方法是对结构直接进行剪枝，这种剪枝方法与权重剪枝不同在于将模型中部分结构直接删除，这种剪枝方法对工业界硬件设备较为友好，受到研究人员的广泛研究。对结构直接剪枝可分为两种常用的剪枝方式，首先是对模型中的通道进行剪枝，对通道进行剪枝方法的出发点是卷积层、模型模块中通道的计算量。在文献[65]中认为残差网络以及密集连接网络这种跨层结构对硬件设备不太友好，这是因为网络多层的输入来自于前面同一层的输出，并且卷积层操作在批次归一化层之后才对特征图进行操作。根据以上分析，在模型中加入通道选择方法来选择出重要的通道，忽略掉不重要且对模型负担大的通道，以此来节省模型的计算量与参数量。第二种剪枝方式是对模型中的滤波器进行剪枝，对滤波器进行剪枝方法的出发点是滤波器中权重的计算量。在文献[66]中认为在滤波器参数中所存在的形状是很重要的，对滤波器的形状与参数进行学习并将其分开，通过将卷积进行变换，进而实现滤波器剪枝，将剪枝后的模型称为 Reyolo-tiny。

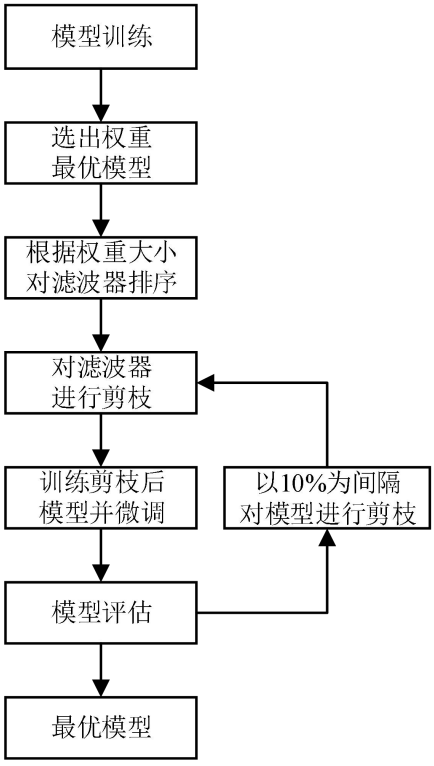


图 3-11 滤波器剪枝的实现过程

Fig.3-11 The implementation process of filter pruning

如图 3-11 为本文滤波器剪枝的具体过程，本文滤波器剪枝的实现过程主要分为以下几步：

（1）用数据集对原始模型进行训练；

（2）计算训练后模型中所有滤波器的权重，并求和；

（3）根据上一步中得到的滤波器的权重大小，对滤波器进行排序；

（4）根据上一步中对滤波器的排序，将权重最小的第 *i* 层滤波器以及第 *i* 层输出的特征图进行剪枝。同样的，第 *i*+1 层滤波器也同样剪枝，剪枝的范围同时也包括 *i*+1 层输

中国知网 https://www.cnki.net

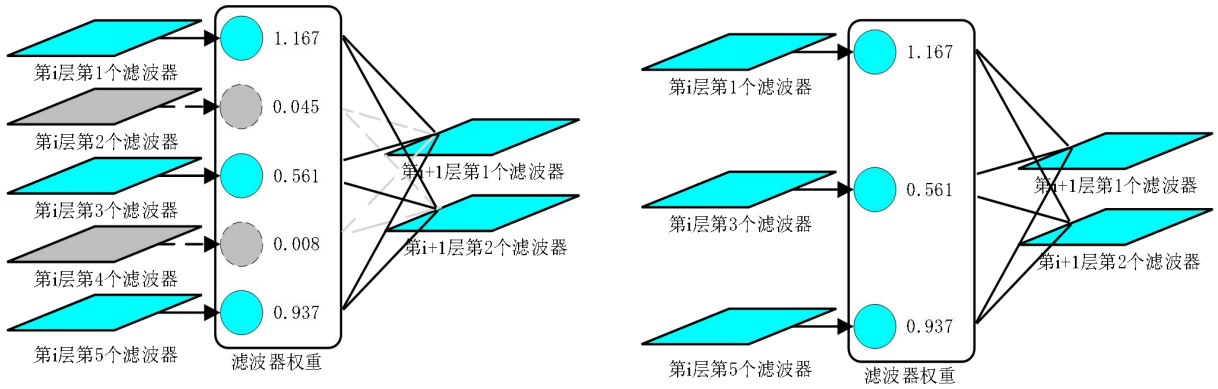
出的特征图；

（5）在原本第 i 层滤波器与第 i+1 层滤波器的位置重新构建新的滤波器层，在构建新的滤波器层的同时将余下的权值转移到新的模型中；

（6）以上便完成了模型剪枝，接着对剪枝后的模型进行训练并评估结果；

（7）剪枝后模型评估后再将模型送到第（4）步，再次对模型剪枝并进行评估。使得每次剪枝都在更好的模型上进行，迭代进行剪枝操作，直到模型能够满足剪枝目标需求。

本文的模型剪枝方法主要思路如下，计算第 i 层所有滤波器的权重值，用 L_1 范数进行表示，接着选择出对模型影响最小的滤波器，同时剪枝掉这层滤波器输出的特征图。如图 3-12 为本文滤波器剪枝的具体做法。



（a）剪枝之前的滤波器　　（b）剪枝之后的滤波器

图 3-12 滤波器剪枝的具体做法

Fig.3-12 The specific practices for filter pruning

图 3-12（a）为剪枝之前的滤波器，图 3-12（b）为剪枝之后的滤波器。图中以模型中第 i 层与第 i+1 层滤波器的关系为例，选取第 i 层中的 5 个滤波器，认为每个滤波器每个通道的重要程度可以与 BN 层相关。如果某一个滤波器的通道与 BN 层之间对应的权重关系够小的话，则认为这个滤波器及滤波器后的通道在模型中并不重要，并且占用计算空间，那么就将这个滤波器剪枝掉。由图中可以得到第 i 层的第 1 个滤波器的通道与 BN 层之间对应的权重为 1.167，第 i 层的第 2 个滤波器的通道与 BN 层之间对应的权重为 0.045，第 i 层的第 3 个滤波器的通道与 BN 层之间对应的权重为 0.561，第 i 层的第 4 个滤波器与 BN 层之间所对应的权重为 0.008，第 i 层的第 2 个滤波器的通道与 BN 层之间对应的权重为 0.937。第 i 层的第 2 个滤波器和第 4 个滤波器的通道与 BN 层之间对应的权重远低于其它，则认为这两个滤波器在模型中并不重要，于是将这两个滤波器及滤波器的通道进行剪枝。

更加细节的从计算方式来讲本文剪枝方法，具体思路在滤波器与 BN 层之间引入一个尺度因子超参数 γ，将这个尺度因子当做衡量某个滤波器是否重要的关键元素。引入的这个尺度因子 γ，与每个滤波器及滤波器的通道所对应，同时与每个通道的输出求乘积。接下来，结合尺度因子与滤波器的权重关系对尺度因子进行系数正则化处理。然后按照大小

中国知网 https://www.cnki.net

关系对滤波器及滤波器通道与 BN 层权重关系进行排序，选出较小的值。最后在排序好的权重管制中选出较小的值，将其对应的尺度因子、滤波器及其对应的通道进行剪枝。模型训练的损失函数如公式 3-3 所示，公式第一项为模型损失函数，第二项为正则化处理的尺度因子，其中γ为尺度因子，λ为惩罚系数因子。

$$L=\sum_{(x,y)} l(f(x,W),y)+\lambda\sum_{\gamma} g(\gamma) \tag{3-3}$$

本文中正则稀疏化采用 L_1 正则化，即公式 3-3 后半部分 $g(\gamma)$ 指取绝对值。另外，公式 3-4 为批次归一化层 BN 的具体计算方法，公式 3-5 为 BN 层输出计算方式。其中μ和σ为输入值的均值与方差，γ和β为可训练的仿射参数。

$$\hat{Z}=\frac{Z_{in}-\mu}{\sqrt{\sigma^2+\theta}} \tag{3-4}$$

$$Z_{out}=\gamma\hat{Z}+\beta \tag{3-5}$$

3.4 实验准备与评价指标

3.4.1 实验环境设置

本文对 Re-yolo 轻量化模型使用的数据集仍然采用本文第一个实验内容使用的目标检测数据集，不同的在于在数据集中加入了烟雾分类，即目前数据集中类别有两个，分别为火焰与烟雾。本文使用制作好的森林火情目标检测数据集分别在 Re-yolo、替换结构后的 Re-yolo、剪枝后的 Re-yolo 以及对比方法进行训练，实验环境是 Pytorch 深度学习环境，在深度学习环境 Pytorch 上进行训练、测试并根据结果进行评估。在实验之前，对模型的超参数进行设置，如表 3-2 所示为 Re-yolo 轻量化实验的超参数设置值。

如表中所示，模型训练所用数据集总共 9864 张图像，其中训练集共 8878 张图像，验证集共 986 张图像，训练集与验证集的比例为 9:1。模型训练总代数为 300 代，其中冻结代数为 50epochs。模型在训练时会同时对几张不同图像进行训练，这个数量由批量大小而定，模型在训练冻结解冻中，输入的批量大小为 8，模型在解冻后正常训练时输入批量大小为 4。输入模型的图像大小为 512×512×3，即在原始图像输入之后，需要对图像进行放大、缩小以及重新裁剪操作，将输入的不同大小图像变为 512×512×3。模型设置的学习率为 0.002。

另外，在模型训练开始之前对输入数据进行数据增强处理，本文使用 Mosic 以及 Mixup 数据增强方法。Mosic 数据增强方法的做法是将 4 张不同图像进行裁剪之后，将裁剪之后的图像拼接得到一张图像，作为训练图像。Mosic 以这种方法丰富数据集背景，并且提高数据输入的批量大小，提高模型泛化性。

中国知网 https://www.cnki.net

表 3-2 Re-yolo 轻量化实验的超参数

Tab.3-2 Hyperparameters of the Re-yolo lightweight experiment

超参数	设置值
训练集数目（training set）	8878
验证集数目（validation Set）	986
训练总代数（epochs）	300
冻结代数（freeze epochs）	50
批量大小（batch size）	8（冻结时）、4（解冻时）
输入图像大小	（512，512）
学习率	0.002
Mosic 数据增强概率	0.5
Mixup 数据增强概率	0.5

Mixup 数据增强方法对数据集进行混合，将数据集中不同的类别进行融合、混合，以这个方式对数据集进行扩充处理。本文 Mosic 设置值为 0.5，Mixup 设置值为 0.5。另外需要说明的是模型数据集增强只存在于训练的前 150 代。模型使用随机梯度下降（Stochastic gradient descent，SGD）作为训练的优化器。对模型学习率进行预热处理，加快模型收敛速度，提升模型的训练效果。实验中使用余弦退火衰减方法作为学习率衰减方式。

3.4.2 实验评估指标

本章实验与第一个研究内容方向相同，都是目标检测方法。因此本章仍使用检测精度、检测速度、召回率以及 F1 分数作为评估模型好坏的指标。不同的在于本文对 Re-yolo 进行轻量化处理，加入了对模型的参数量、浮点数运算以及剪枝率。检测速度与检测精度同样重要，检测速度可以直观地评价出模型经过轻量化处理后是否在实时性上做的更好；Re-yolo 经过替换模型主要模块与主干网络，经过滤波器剪枝等轻量化处理后，模型的检测精度会有一定幅度的变化，要得到一个轻量化、检测快速的目标检测方法的同时，还要保证模型检测能力不要下降才是最重要的，使用检测精度用来衡量这一要求是否达标。在本章中使用参数量、浮点数运算以及剪枝率对滤波器剪枝方法进行衡量，用于对模型剪枝进行评价。

3.5 实验及结果分析

3.5.1 结构重组轻量化实验结果

本文首先对 Mobilenet、Shufflenet 以及 Mobileone 等轻量化方法进行分析，研究这些轻量化方法的模块与其它方法之间的不同。并用这些方法的主干网络以及主要轻量化模块对 Re-yolo 进行替换，将替换后的方法称为 Reyolo-Mobilenet、Reyolo-Shufflenet、Reyolo-Mobileone。分别在检测检测精度、检测速度、召回率、F1 分数、参数量、浮点数运算以及剪枝率上进行对比。由表 3-3 所示为使用上述不同方法替换 Re-yolo 后的对比结

中国知网 https://www.cnki.net

果。

表 3-3 使用不同方法替换 Re-yolo 的对比结果

Tab.3-3 Comparison of Re-yolo using different methods to replace

实验指标 \ 检测模型		Re-yolo	Reyolo-Mobilenet	Reyolo-Shufflenet	Reyolo-Mobileone
火焰	检测精度	93.47%	79.31%	83.87%	91.65%
	检测速度	28.7	39.1	36.8	32.9
	召回率	89.14%	74.92%	80.31%	87.73%
	F1 分数	91.25%	77.05%	82.05%	89.65%
	参数量	59.14MB	39.07MB	32.57MB	42.39MB
	浮点数运算	89.92G	71.33G	63.41G	81.63G
	剪枝率	0	0	0	0
烟雾	检测精度	89.17%	71.89%	76.14%	82.94%
	检测速度	26.7	39.1	36.8	32.9
	召回率	86.43%	67.93%	72.98%	78.42%
	F1 分数	87.78%	69.85%	74.53%	80.62%
	参数量	59.14MB	39.07MB	32.57MB	42.39MB
	浮点数运算	89.92G	71.33G	63.41G	81.63G
	剪枝率	0	0	0	0

由表 3-3 中对 Re-yolo、Reyolo-Mobilenet、Reyolo-Shufflenet 以及 Reyolo-Mobileone 实验结果的统计可得，上述方法对火焰检测中，Re-yolo 检测精度为 93.47%，在这些模型中是最高的，但相应的其检测速度是最慢的，检测速度为 28.7FPS，参数量也是最大的。由上述对 Re-yolo 的实验结果分析可得，Re-yolo 以检测速度不高、参数量大为代价，换来了精准的检测能力。使用 Mobilenetv2 主干网络替换掉 Re-yolo 主干网络后得到的目标检测方法 Reyolo-Mobilenet 虽然检测速度最快，达到了 39.1FPS，并且参数量最低，Reyolo-Mobilenet 的参数量降低到了 39.07MB。由上述对 Reyolo-Mobilenet 的实验结果分析可得，虽然 Reyolo-Mobilenet 参数量降低了很多，并且检测速度也提升巨大，但是对火焰的检测精度降低了非常多。本文还使用 Shufflenetv3 对 Re-yolo 进行轻量化处理，由上表可得，Reyolo-Shufflenet 准确率为 83.87%，相较于 Reyolo-Mobilenet 有所提升，但是相较 Re-yolo 还是降低了很多，相应的检测速度有所提升并且参数量有所降低。最后本文使用 Mobileone 的主干网络与主要模块对 Re-yolo 进行替换，替换后的模型 Reyolo-Mobileone 的检测精度为 91.65%，仅比 Re-yolo 降低了不到 1.82%，检测速度为 32.9FPS，参数量为 42.39MB，检测速度与参数量相较于 Re-yolo 效果更好。结合表 4-3 与上述可得，Reyolo-Mobilenet 检测速度最高且参数量最小，但是检测精度很低；Reyolo-Shufflenet 虽然检测速度与参数量相较 Re-yolo 有所改善，但是检测精度仍然很低。经过实验验证，上

中国知网 https://www.cnki.net

述这些方法均已达到实时的检测效果，并且差别并不大，但是对于火情检测，还是需要检测精度相对高的方法。综合上述分析，本文选择用 Mobileone 的主干网络与主要模块对 Re-yolo 进行替换与优化，为下文滤波器剪枝做出轻量化的第一步。

3.5.2 滤波器剪枝实验结果

本章对于 Re-yolo 的轻量化处理分为两个步骤，第一步使用 Mobileone 的主干网络及主要模块对 Re-yolo 进行替换，修改 Re-yolo 的模型结构；第二步使用有关模型压缩的滤波器剪枝方法对 Re-yolo 进行剪枝，达到轻量化的效果。下文对 Re-yolo 轻量化处理第二步的实验结果进行分析及展示。

由上述分析，由检测精度与精测速度之间的平衡关系可得，使用 Reyolo-Mobileone 作为第一步轻量化后的最优模型，对 Reyolo-Mobileone 进行滤波器剪枝处理。首先对 Reyolo-Mobileone 的主干网络进行滤波器剪枝，剪枝率从 10%开始每隔 10%对模型剪枝一次，以此规律剪枝率直到 90%。对不同剪枝率下的模型进行分析，分析模型分别对火情的检测精度、检测速度、参数量以及浮点数运算，进而得到最优剪枝率下的 Reyolo-Mobileone，如表 3-4 所示为使用不同剪枝率对主干网络进行剪枝的结果。

表 3-4 使用不同剪枝率对主干网络剪枝的实验对比

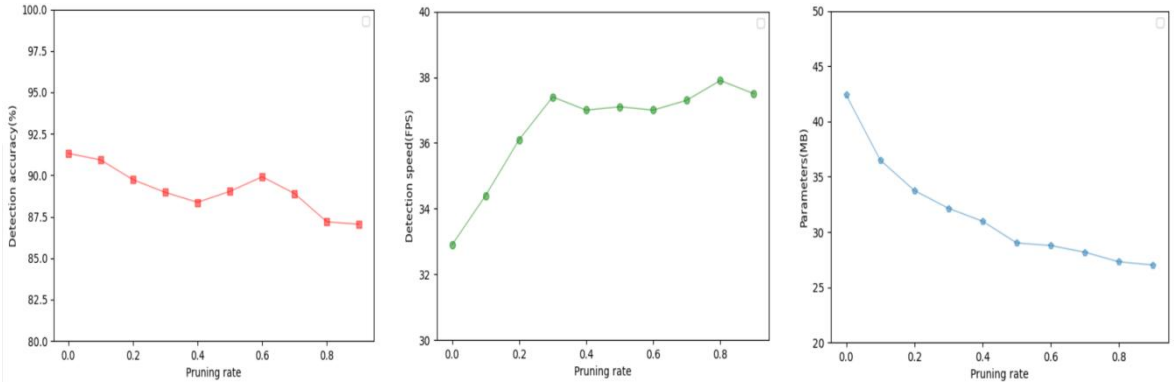
Tab.4-4 Experimental comparison of pruning of trunk networks using different pruning rates

参数 / 剪枝率	检测精度	检测速度	参数量 Parameters	计算量 FLOPs
0%	91.32%	32.9FPS	42.39MB	81.63G
10%	90.93%	34.4FPS	36.50 MB	75.94G
20%	89.74%	36.1FPS	33.75 MB	69.47G
30%	88.97%	37.4FPS	32.14 MB	62.12G
40%	88.37%	37.0FPS	30.97 MB	60.82G
50%	89.03%	37.1FPS	29.01 MB	59.52G
60%	89.91%	37.0FPS	28.77MB	59.37G
70%	88.90%	37.3FPS	28.17 MB	59.08G
80%	87.19%	37.9FPS	27.30MB	58.42G
90%	87.05%	37.5FPS	27.01MB	58.16G

Reyolo-Mobileone 原始模型的检测精度 91.32%、检测速度为 32.9FPS、模型参数量为 42.39MB、计算量 FLOPs 为 81.63G。剪枝率 90%的情况下对模型剪枝后检测精度为 87.05%、检测速度为 37.5FPS、模型参数量为 27.01MB、计算量 FLOPs 为 58.16G。虽然剪枝率越高，模型检测速度与模型参数量表现越好，但是检测精度同样随着剪枝率变高而变低，不能认为剪枝率为 90%的模型为最佳模型。为如图 3-13 所示为 Reyolo-Mobileone 在不同剪枝率下，检测精度、检测速度、模型参数量的折线图变化情况，从折线图中可以更加直观

中国知网 https://www.cnki.net

看出模型在不同剪枝率下的性能变化，进而选择出最佳的模型。



（a）检测精度变化情况　　（b）检测速度变化情况　　（c）模型参数量变化情况

图 3-13 不同剪枝率下检测精度、检测速度、模型计算量的变化情况

Figure 3-13 Changes in detection accuracy, detection speed, and parameters under different pruning rates

图 3-13（a）为 Reyolo-Mobileone 在不同剪枝率下检测精度的变化情况，图 4-13（b）为 Reyolo-Mobileone 在不同剪枝率下检测速度的变化情况，图 3-13（a）为 Reyolo-Mobileone 在不同剪枝率下模型参数量的变化情况。本文将表 3-4 使用不同剪枝率对主干网络剪枝的实验对比与图 3-13 不同剪枝率下检测精度、检测速度、模型计算量的变化情况结合起来分析，可以得出随着剪枝率的变大，检测精度的大致趋势也随之变低，剪枝率为 0 的情况下，检测精度最高。但是在剪枝率为 40%时，检测精度发生转折，直到剪枝率为 60%时，达到这次检测精度转折的最高值 89.91%，在这之后检测精度再次随着剪枝率的变大而变低。检测速度的大致趋势随着剪枝率的变大而变快，在剪枝率为 80%时，检测速度达到最大值 37.9FPS，其次是在剪枝率为 30%时，检测速度达到 37.4FPS。模型参数量完全随着剪枝率的变大而变小，模型参数量变化情况的折线图较为平滑，即模型参数量在剪枝率为 90%的情况下最小，模型参数量在剪枝率为 90%时为 27.01MB。本文认为，将模型剪枝轻量化后不能仅考虑检测速度与模型参数量的变化情况，模型参数量虽然随着剪枝率变高而变小，但是评估模型检测性能主要在于检测精度与检测速度。又由于模型参数量在剪枝率为 50%之后，变化变得平缓，故本文将检测精度与检测速度的变化情况结合起来对模型进行评估。这里仅考虑剪枝后模型的性能变化，检测精度与检测速度变化图中比较特殊的节点分别是：在剪枝率为 10%时，检测精度最高，检测精度为 90.93%；其次是在剪枝率为 60%时，检测精度为 89.91%；在剪枝率为 80%时，检测速度最高，检测速度为 37.9FPS；其次是在剪枝率为 30%时，检测速度为 37.4FPS。在检测速度的变化情况中，剪枝率为 30%、60%、80%时，检测速度分别为 37.4FPS、37.0FPS、37.9FPS，相差不过 1FPS。剪枝率在 60%时，检测精度为 89.91%，与原始基础模型相差不过 2%。剪枝率为 10%时，检测速度为 34.4FPS，剪枝率在 60%时，检测速度要比剪枝率为 10%时的检测速度高出将近 3FPS。在剪枝率为 60%时，检测精度为 89.91%，仅比 Reyolo-Mobileone 检测精度降低了 1.41%，但是检测速度提高了 4.1FPS，模型计算量降低。综合上述分析，本文

中国知网 https://www.cnki.net

认为在剪枝率为 60%时，剪枝效果最好。综合上文实验结果的展示与分析，可以得到使用 Mobileone 的主干网络与基本模块对 Re-yolo 进行轻量化处理效果最好，这里以对火焰检测为例，检测精度与检测速度分别为 91.65%与 32.9FPS，检测精度相较 Re-yolo 变化了 1.82%，检测速度提高了 4.2FPS。剪枝率为 60%时，模型性能最好，检测精度与检测速度分别为 89.91%与 37FPS，检测精度变化了 3.23%，检测速度提高了 8.3FPS，模型参数量下降了 30.37MB。第一步模型替换轻量化后的方法称作 Reyolo-Mobileone，第二步剪枝后的方法称作 Reyolo-tiny。

3.5.3 检测结果

以上对 Re-yolo 的轻量化方法进行分析，经过对比实验得到模块替换轻量化后的最佳模型 Reyolo-Mobileone，又通过对比检测精度、检测速度以及模型参数量的变化情况得到最终剪枝轻量化后的方法 Reyolo-tiny，最终得到一种模型替换轻量化以及滤波器剪枝的轻量化思路。

图 3-14 展示了经过模型替换轻量化处理以及滤波器剪枝轻量化处理后 Reyolo-tiny 对森林火情以及其它背景火情的检测输出结果，分别对 FLAME 航空森林火情数据集中的火焰及烟雾进行检测，对其它环境背景下的火焰及烟雾进行检测。

如图 3-14（a）为数据集中的原图，3-14（b）为对火焰烟雾的检测结果。从图中可得没有误检，并能将火焰及烟雾实时准确的检测出来，且网络使用于不同环境背景，因此网络具有较强的泛化能力和鲁棒性。



中国知网 https://www.cnki.net



（a）原图　　（b）检测结果

图 3-14 Reyolo-tiny 火焰烟雾检测结果

Fig.3-14 The flame and smoke detection results of Reyolo-tiny

3.6 本章小结

本章针对模型结构复杂、模型计算量大、模型检测速度慢的问题，通过将模型替换轻量化方法与模型滤波器剪枝方法进行结合，得到基于 Reyolo-tiny 的森林火情轻量化检测方法，同时得到一种模型轻量化的思路。

本章对增强后 Re-yolo 目标检测模型轻量化过程分为两个阶段，第一个阶段通过对 Mobilenet 系列、Shufflenet 系列、Mobileone 等轻量化模型进行分析与研究，然后使用这些轻量化模型的主干网络及主要模块对 Re-yolo 进行替换应用，将模型替换轻量化后的方法从检测精度、检测速度、模型参数量的评价指标进行分析对比，得到效果最好的 Reyolo-Mobileone。第二个阶段使用模型滤波器剪枝的轻量化方法对 Reyolo-Mobileone 进行剪枝轻量化处理，使用不同剪枝率对模型进行剪枝。仍然是通过从检测精度、检测速度、

中国知网 https://www.cnki.net

模型参数量的评价指标对模型进行分析对比，得到剪枝率为 60%时，检测能力表现最好的模型 Reyolo-tiny。剪枝率为 60%时，模型参数量为 59.37G，检测精度为 89.91%，检测速度为 37.0FPS。至此得到一种模型轻量化的方法思路与轻量化方法 Reyolo-tiny。

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

4 基于实例分割的多火点与遮挡火点监测方法

4.1 引言

目前，随着深度学习方法以及视觉图像监测技术的不断发展，基于视觉图像的无人机监测方法已大范围的应用于森林火情监测任务中，研究人员研究得到更多的、更好的方法对森林火情进行监测。研究人员们通过搭载视觉传感器及机载计算机的无人机对森林火情进行拍摄，然后通过使用基于深度学习方法的图像检测分割方法对火情进行监测，得到森林火情的严重程度以及过火方向，为及时消灭火灾提供有力支援。

使用无人机搭载的摄像头、照相机等视觉传感器获得森林火情，将视觉传感器所获得到的森林火情图像传输至计算机，通过基于深度学习的视觉图像监测技术进行处理，对图像中的森林火情进行检测分割，这是当前最先进的基于视觉图像的无人机监测方法的思路。要完成这个任务，对于森林火情环境，目前仍面临众多挑战与困难：（1）无人机所拍摄的图像，火情目标小，在整张图像中像素占比少，给监测分割任务带来不小的阻力；（2）一般森林火情发生的时候，同一个地点存在不止一个目标，火情在图像中分布不均且密集，降低检测分割方法的效率；（3）森林环境复杂，遮挡物多，火情容易被树枝等遮挡，容易产生漏检、误检等问题。本章采用实例分割方法对多目标火点、被遮挡的火点进行监测分割，实例分割是像素级的图像检测方法，相比于目标检测方法，分割难度更大，但是更适合对于多火点及遮挡火点的监测任务。在实例分割方法中，Maskrcnn 结构简单并且分割能力强、效率高，大量研究人员对 Maskrcnn 展开研究与应用。本文对 Maskrcnn 进行研究，为了增强对于小目标火点及遮挡火点的分割能力，同时保证实时分割的前提下，在 Maskrcnn 中引用加入特征对齐机制的像素解码器，引入基于查询的解码器输出头，优化掉后处理步骤（如 NMS 等），加入查询机制提高模型性能，从而提出本文方法 Query-maskrcnn。

本章的安排如下：首先对 Maskrcnn 进行介绍。然后提出优化方法，先介绍优化后方法与 Maskrcnn 之间的结构对比，对优化方法进行分析，重点介绍基于查询的解码器输出头，它能提升模型对小目标火点及遮挡火点的分割能力。最后使用数据集对 Query-maskrcnn 以及其它方法进行学习，将 Query-maskrcnn 及其它方法的检测结果进行对比，以此分析评价 Query-maskrcnn 的分割能力。

4.2 Maskrcnn 实例分割方法

目前对使用图像技术对目标进行监测的方法有图像分类、图像目标检测、图像语义分割以及图像实例分割。上文的 Re-yolo 方法属于目标检测方法，Maskrcnn 模型及本文提出的 Query-maskrcnn 属于实例分割方法，那么如何对目标检测、语义分割、实例分割方法进行区分，如图 4-1 所示为不同监测方法的监测结果。

中国知网 https://www.cnki.net



（c）森林火情语义分割结果　　（d）森林火情实例分割结果

图 4-1 森林火情监测不同方法的监测结果

Fig.4-1 Results of different methods of forest fire monitoring

图 4-1（a）为一张森林火情原图，图 4-1（b）为用目标检测方法对森林火情的监测结果，图 4-1（c）为用语义分割对森林火情的监测结果，图 4-1（d）为实例分割方法对森林火情的监测结果。由图中可以得到，目标检测方法用边框检测出火情在图中的位置，语义分割方法与实例分割方法都是像素级别的检测方法，对图中的像素进行分类，以此得到目标在图中的具体位置。语义分割与实例分割都属于目标分割领域，一般来说目标分割指语义分割，研究人员对语义分割方法已研究发展很长时间，取得大量研究成果。近几年，研究人员才开始研究实例分割方法。相比于语义分割方法，实例分割方法在语义分割方法的基础上对同类物体进行更精细的分割，分割更精细、精准，所以需要监测能力更强的模型。

Maskrcnn[67]是一种实例分割方法，其框架比较灵活，通过添加不同分支来完成不同的图像监测任务，可以完成目标检测任务、语义分割任务、实例分割任务、姿势识别任务等。Maskrcnn 优点很多，比如其监测速度高、监测精度高、简单易于使用。

为了使得 Maskrcnn 具有快速的监测速度，作者选用经典的目标检测模型 Faster-rcnn[68]用于提取图像特征，选用经典的语义分割模型全卷积网络（Fully convolutional network，

中国知网 https://www.cnki.net

FCN）用于在图像中分割出目标。其中 Faster-rcnn 可以很好地完成目标检测任务，FCN 可以精准地完成语义分割任务，这两个模型都是各自领域的经典模型。Maskrcnn 将这两个方法进行融合，并对 Faster-rcnn 中的感兴趣区域（Region of interest，ROI）池化进行优化，提出感兴趣区域对齐策略，使得 Maskrcnn 成为检测速度快、检测精度高的实例分割方法。为了得到简单并易于使用的特点，Maskrcnn 就是在 Faster-rcnn 的基础上增加了全卷积网络分支来生成掩膜，对火情目标进行分割。更细节的来讲，Maskrcnn 组成结构为主干网络、区域建议网络、感兴趣区域对齐、全卷积分割分支及检测分支。由于 Maskrcnn 模型简单且易于使用，研究人员经常在 Maskrcnn 的基础上更换其主干网络、输出头等来获得不同性能的方法。本文便是通过这种方式对 Maskrcnn 进行优化，得到监测分割能力更强的实例分割模型。

4.2.1 Maskrcnn 整体结构

Maskrcnn 整体结构如图 4-2 所示，主干网络使用残差网络 Resnet50，残差网络在上一章详细介绍，这里仅对图像在 Resnet50 网络处理输出的结果进行分析。将大小 H×W×3 的图像输入 Resnet50 后，在 Resnet50 的 5 个阶段会分别输出一个特征图，按照先后顺序，这 5 张输出的特征图大小依次为 H/2×W/2、H/4×W/4、H/8×W/8、H/16×W/16、H/32×W/32 前几层特征图一般含有较多的细节信息，比如颜色、轮廓、纹理等特征；后面生成的特征图一般具有较多的细节信息，比如颜色、轮廓、纹理等特征，但是噪声或无关信息等影响因素多；后面生成的特征图一般具有较多的语义特征，比如类别、属性等特征，但是分辨率小，这导致后面生成的特征图丢失一部分图像信息。考虑到这个问题，Maskrcnn 同样采用特征金字塔网络进行特征融合，对主干网络输出不同大小的特征图进行融合，得到增强后的特征图。

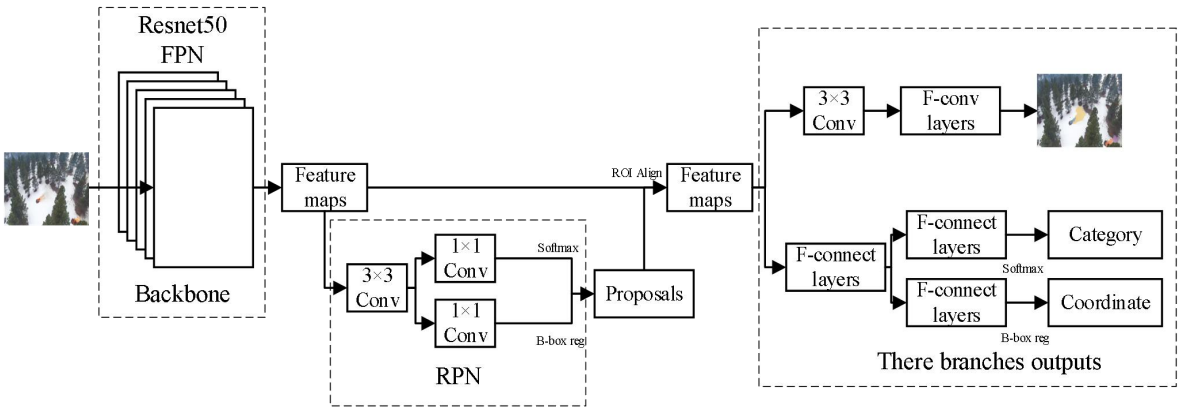


图 4-2 Maskrcnn 的整体结构

Fig.4-2 The overall structure of the Maskrcnn

特征金字塔网络输出增强后的特征图后，特征图输入区域推荐网络中（Region proposal network，RPN），区域推荐网络用于帮助模型找出找到可疑目标区域。区域推荐网络输出的边框后，这些边框和特征大小是不一样的，通过感兴趣区域对齐（Region of

中国知网 https://www.cnki.net

interest align，ROI align）将这些边框所代表的特征进行尺寸统一。最后将特征送入输出头中，得到掩膜分割结果、分类结果以及置信度结果。

4.2.2 感兴趣区域对齐

在将特征送入输出头之前，需要将特征转为相同的大小，接着将特征改变成一维的特征，从而才能进行分类、回归等任务。感兴趣区域对齐用于将感兴趣区域进行对齐，即先将原图和特征图的像素对应起来，然后将输入的特征图和固定的特征进行对应。Fast-rcnn中使用感兴趣区域池化（Region of interest pooling，ROI pooling）操作将特征对应起来，但是感兴趣区域池化在对特征进行对应的过程中会造成较大误差，实例分割任务对精准度要求高，故 Maskrcnn 提出感兴趣区域对齐机制避免较大量化误差。

感兴趣区域对齐操作的步骤如下：（1）按照模型输出的要求，将区域建议网络输出的边框进行等分，但是等分后边框的各个点可能落不在规定的像素点上；（2）在特征图中每个块上选取四个固定的点，在这每个点的周围，得到距离最近的四个规定像素点。然后将这四个规定像素点进行双线性插值操作，以此求得一开始选取到四个固定点的值；（3）经过第二步，可得出每个块内会生成四个固定点的值，接下来在每个块的这些值中得到最大值。以每个块中得到的最大值作为每个块的输出值，最后得到 2×2 大小的输出。

4.3 Query-maskrcnn 实例分割方法

森林火情监测任务对于监测方法要求较高，首先森林环境复杂，存在遮挡、类似火情等情况给火情监测带来阻力；森林发生火灾，森林可燃物多，火势发展迅速，会存在多个火点目标存在的情况；森林火情需尽量在火情发生早期监测到，为后续灭火工作保驾护航，那么就需要监测方法能够精准快速地监测出图像中的小目标。是否为小目标的衡量标准，目标边界框的宽高与图像的宽高的比例小于一定值，这个值一般为 0.1，根据目标在图像中覆盖的像素与图像中总像素的比例进行衡量。目前存在的实例分割方法可以分为三类，分别为基于区域的实例分割方法、基于实例激活的实例分割方法以及基于查询的实例分割方法。

基于区域的实例分割方法首先检测目标的边框，提取特向特征，应用区域感兴趣机制提取目标区域特征，接着根据目标区域特征进行分类任务和掩膜分割任务。但是基于区域的方法会生成大量冗余边框及区域建议，严重影响模型的分割效率。如 Maskrcnn 实例分割方法，Maskrcnn 遵循对目标先进行检测再进行分割的顺序进行操作，这种分割方法会生成大量重复冗余的区域建议，进而影响到模型的分割效率。针对这一问题，研究人员提出基于全卷积网络（Fully convolution network，FCN）端到端的分割方法[69,70,71]，这一方法分割效率有所提升，但是因为密集的预测，目标分割仍依赖于人工设计的后处理操作，影响模型效率，如非极大值抑制（Non-maximum suppression，NMS）方法。

基于实例激活的方法通过选取一部分特殊的点，如中心点、边框点等，在预测过程中对这些选取的特殊点进行训练，以此来对目标进行分割。比如方法[72,73,74]，其中基于实例

中国知网 https://www.cnki.net

激活的分割方法 SOLO 以目标类别近似于目标在图像的中心位置为中心思想。SOLO 将图像分为 S×S 个网格，进而在图中获得 S^2 个中心点，根据目标中心点坐标分配给后来获得的中心点，再通过全卷积操作得到后续的分割结果。

随着 DETR[75]在目标检测领域的使用和发展，研究人员对实例分割研究的重点转向基于查询的单阶段实例分割方法。这种方法与 Maskrcnn 或 SOLO 实例分割方法使用全卷积网络进行分割不同，基于查询的单阶段实例分割方法使用可学习的查询机制和功能强大的注意力结构进行分类及分割。比如方法[76,77]，具有端到端集预测的编码器-解码器的卷积主干可以在实例分割任务上取得良好性能。尽管基于查询方法具有出色的性能，但是基于查询的模型通常在计算上过于昂贵，无法进行实际应用。

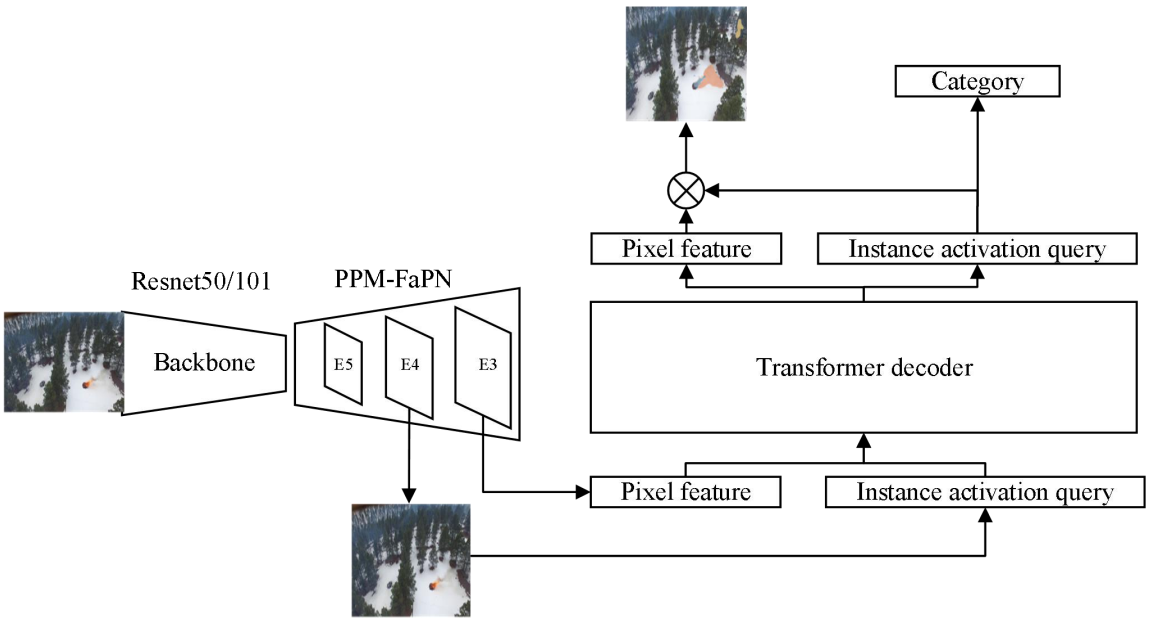


图 4-3 Query-maskrcnn 的整体结构

Fig.4-3 The overall structure of the Query-maskrcnn

根据以上提出的问题，需要分割能力更强的方法对森林火情进行监测分割。本文使用更适用于分割小目标及多目标的特征对齐金字塔网络（Feature-align pyramid network，FaPN）替换特征金字塔网络。引入基于查询机制的解码器输出头提升模型的分割精度及速度，获得边界清晰的火情分割结果。主干网络仍然使用残差网络 Resnet50。基于此，提出基于 Query-maskrcnn 实例分割模型的森林火情监测方法，如图 4-3 为 Query-maskrcnn 整体结构。

4.3.1 特征融合网络

特征融合旨在将具有更多细节信息的低层特征、具有更多语义信息的高层特征进行融合，得到融合后的特征图。融合后的特征图将低层特征与高层特征的优点结合起来，使得模型能够得到多个不同尺度下的特征，进而增强模型的监测能力。特征融合的输入是具有不同分辨率的特征图，如公式 4-1 所示为输入第 i 层的特征，$P_{i_i}^{in}$ 指输入第 i 层的特征。

中国知网 https://www.cnki.net

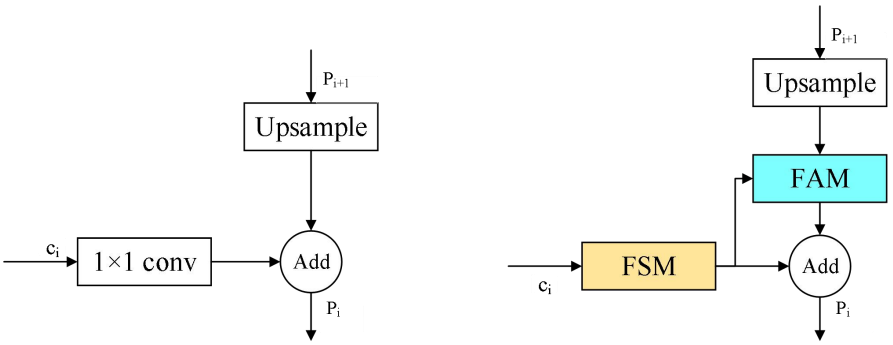
公式 4-2 所示 P_i^{out} 为第 i 层输出融合后的特征，其中 f 是有效融合不同输入特征的方法，并输出融合后的特征列表 $P_{i_j}^{out}$ 。

$$P_i^{in} = (p_{i_1}^{in}, p_{i_2}^{in}, \ldots, p_{i_j}^{in}) \tag{4-1}$$

$$P_i^{out} = f(p_{i_j}^{out}) = (p_{i_1}^{out}, p_{i_2}^{out}, \ldots, p_{i_j}^{out}) \tag{4-2}$$

为了得到更加精准的、边界更加清晰的分割结果，在特征融合网络中，本文使用特征对齐金字塔网络 FaPN 代替 Maskrcnn 的特征金字塔网络 FPN。同时在主干网络最后一个阶段输出后面加入金字塔池化模块（Pyramid pooling module，PPM），扩大图像感受野。当前大多数模型主干网络提取完图像特征后，将图像特征直接送入颈部结构进行特征融合，忽视了特征图之间特征对齐的问题。大多数模型在融合特征的上采样过程中直接在特征图上添加像素，这样会导致模型中上下文存在特征映射不对齐的情况，进而影响模型的分割预测结果。

特征对齐金字塔网络在特征对齐网络的基础上引入一个特征对齐模块（Feature align module，FAM），特征对齐模块能够学习图像中像素的变换偏移量，进而对齐上采样后上下文的特征。同样的引入特征选择模块（Feature selection module，FSM），以此强调低层图像特征。将特征对齐模块以及特征选择模块集成在自上而下的特征金字塔网络中。



（a）FPN 连接环节　　（b）FaPN 连接环节

图 4-4 FPN 与 FaPN 的连接环节对比

Fig.4-4 Comparison of FPN and FaPN connections

由图 4-4 可得，从主干网络输出的特征图由 C_i 表示，特征融合网络中的特征图由 P_i 表示。主干网络输出的特征图经过 FSM 处理，特征融合网络中特征图经过 FAM 处理，其中 FSM 如图 4-5 所示。

中国知网 https://www.cnki.net

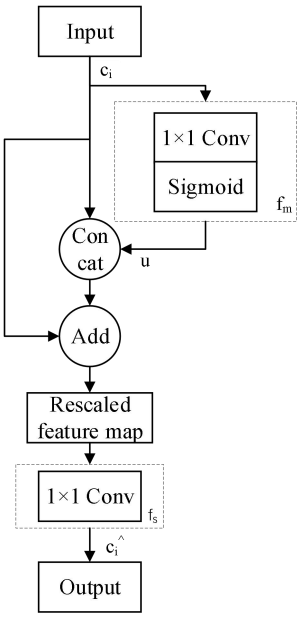


图 4-5 特征选择模块

Fig.4-5 Feature selection module

FSM 是由权重注意力 SE（Squeeze-and-excitation）模块受到启发的，主要区别在于输入和缩放特征映射之间引入了额外的直接连接，这避免了任何特定的通道相应被放大或抑制。提出的 FSM 操作流程如上图，由主干网络输入的特征图 C_i 首先通过全局平均池化提取输入特征图 C_i 的全局信息 Z_i，然后经过特征重要性建模处理。特征重要性建模 f_m 是一个 1×1 的卷积层，在卷积层后面是 sigmoid 激活函数，通过 f_m 对输入的特征图 C_i 的重要性进行建模，接着输出一个向量 u，如公式 4-3 所示。将主干网络输入的特征图 C_i 与 f_m 输出的向量 u 进行拼接操作，将拼接得到的的特征图添加到特征图 C_i 中，得到重新缩放后的特征图。最后在重新缩放的特征图上引入特征选择层 f_s，特征选择层为一个 1×1 的卷积操作，用于选择性的保留重要的特征映射并删除无用的特征映射，提高模型效率，以此来减少通道数量，如公式 4-4 所示。

$$u = f_m\left(Z_i\right) \tag{4-3}$$

$$C_i^{\wedge} = f_s(C_i + u \times C_i) \tag{4-4}$$

特针对齐模块核心在于采用可变形卷积网络（Deformable convolution network，DCN），产生偏移抵消使得两层特征图之间位置进行匹配。公式 4-5 为可变形卷积求得主干网络输出特征图以及特征融合网络特征图之间的偏差抵消值，公式 4-6 为特征图经过特征对齐模块求得的最终结果。

$$\Delta_i = f_o([C_{i-1}^{\wedge}, P_i^u]) \tag{4-5}$$

$$P_i^{\wedge} = f_a(P_i, \Delta_i) \tag{4-6}$$

中国知网 https://www.cnki.net

其中 f_o 与 f_a 分别为可变形卷积生成的偏差抵消以及最终卷积操作，C_i 及 P_i 分别为主干网络输出的特征图及特征融合网络中的特征图，Δ_i 为主干网络输出的特征图及特征融合网络中特征图经过可变形卷积处理后得到的结果。

4.3.2 基于查询机制的解码器

本文引入基于查询的解码器结构进行实例分割，获得高精度的分割结果。为了减少基于查询解码器的迭代更新计算负担，引入实例激活引导的查询，从低层特征图中选择较高语义特征的像素作为基于查询解码器的初始查询；为了增强像素特征的表现能力，减少解码器繁重的设计和计算量，本文在基于查询的解码器中加入双路径结构，分别处理查询特征以及像素特征，查询特征以及像素特征交替更新，加快模型学习迭代更新的速度。

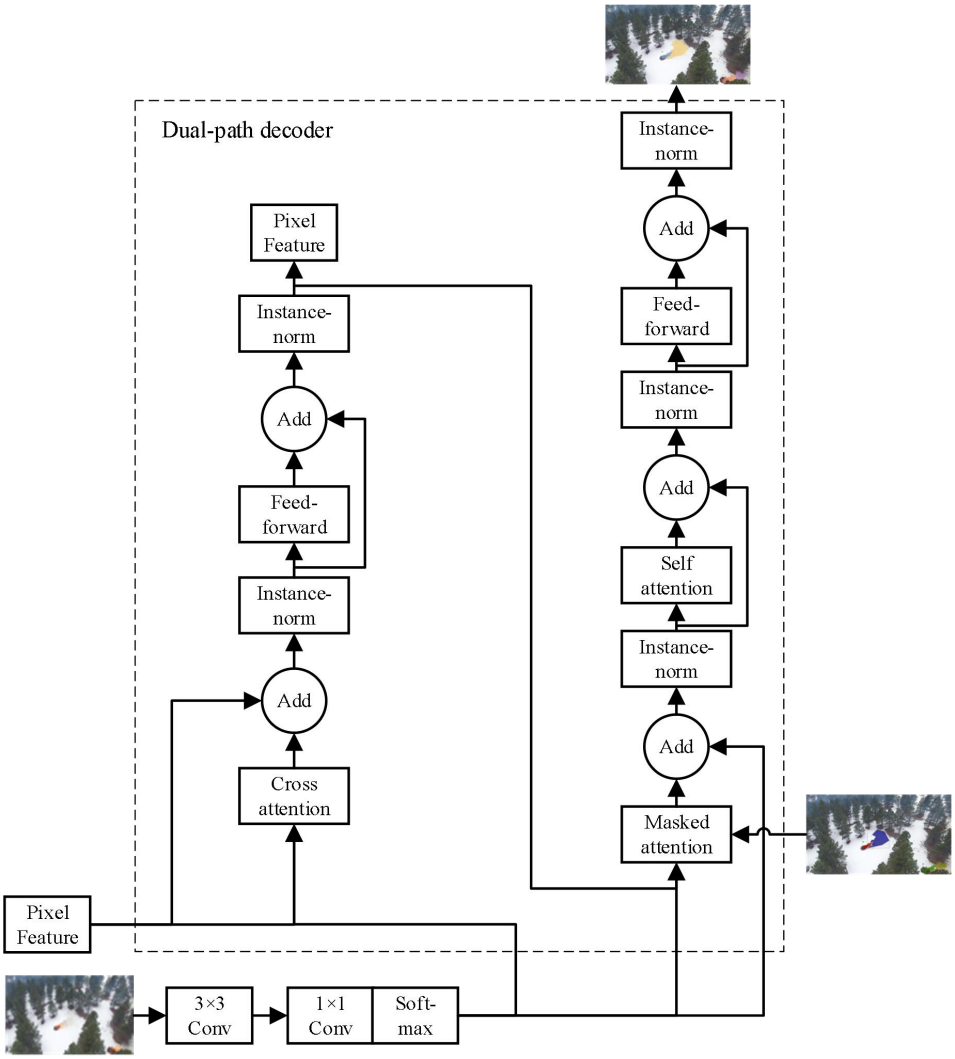


图 4-6 基于查询的双路径解码器结构

Fig.4-6 Query-based dual-path decoder structure

如图 4-6 所示为基于查询的解码器结构，本文解码器采用双路径结构，分别预测像素特征和最终分割预测结果。基于查询解码器的输入分别为特征融合网络中第三阶段的像素特征、第四阶段的特征图以及地面真实掩膜。其中输入的第四阶段特征图作为初始查询输入，第四阶段特征图在输入解码器之前先进行分类处理，通过分类处理得到的类别映射到

中国知网 https://www.cnki.net

第四阶段特征图上。第三阶段的像素特征和第四阶段的特征图同时输入到预测像素特征分支中，经过处理得到最终的像素特征结果。图像分割结果分支输入量分别为第四阶段特征图、地面真实掩膜图以及像素特征预测分支的预测结果。

Query-maskrcnn 的损失函数由三部分组成，分别为实例激活引导损失、掩膜预测损失以及地面真实引导学习损失，如公式 4-7 所示。其中实例激活引导损失如公式 4-8 所示，其中 λ 为查询超参数，L_{cls-q} 为查询的交叉熵损失与定位损失之和。公式 4-9 为掩膜预测损失，其中 λ_{ce} 和 λ_{dice} 分别为交叉熵损失和 dice 损失的超参数，L_{ce}^{i} 和 λ_{dice} 分别为第 i 层的交叉熵损失和 dice 损失，D 表示模型第 D 层基于查询的解码器。

$$L = L_{IA-q} + L_{pred} + L_{pred}^{'} \tag{4-7}$$

$$L_{IA-q} = \lambda_{\text{cls}-q} \times L_{cls-q} \tag{4-8}$$

$$L_{pred} = \sum_{i=0}^{D} (\lambda_{ce} L_{ce}^{i} + \lambda_{dice} L_{dice}^{i}) + \lambda_{cls} L_{cls}^{i} \tag{4-8}$$

4.3.3 最初的优化思路

本文对特征融合网络中引入特征对齐金字塔网络、在模型中引入基于查询的解码器网络，得到 Query-maskrcnn 之前，先在 maskrcnn 的基础上进行优化，得到了分割速度上的有效提升，但是在分割精度上有所降低的方法。如图 4-7 所示为初次优化的整体思路，此方法不是最终采用的优化方法，将此方法称为 Re-maskrcnn。

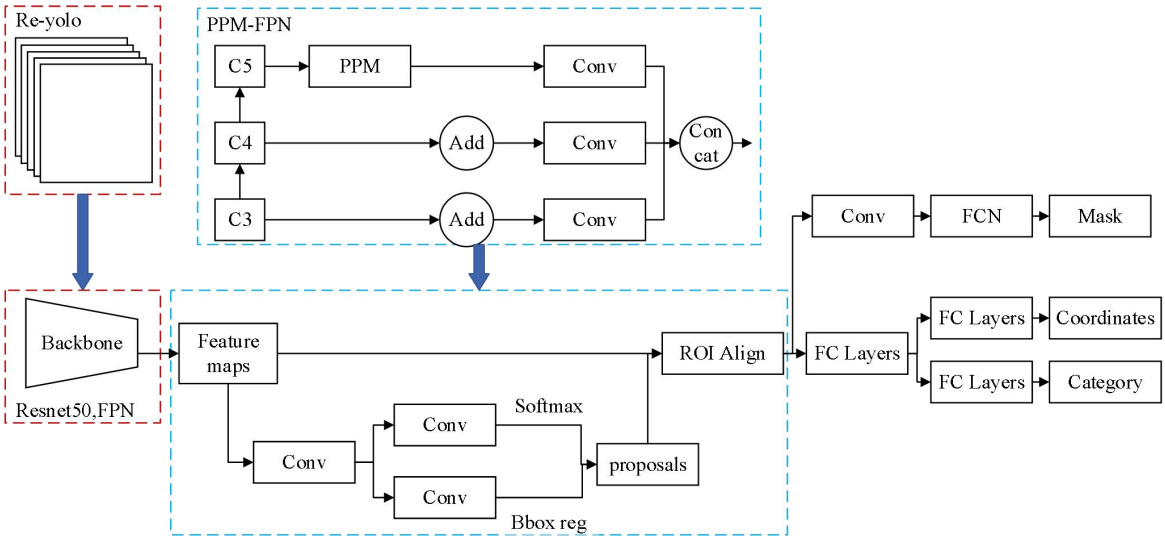


图 4-7 初次优化的整体思路

Fig.4-7 The overall idea of the initial optimization

由图中可得，Re-maskrcnn 用 Re-yolo 中特征提取网络替换 Maskrcnn 的 Resnet50 网络，同时将 Maskrcnn 的区域建议网络替换为引入金字塔池化模型（Pyramid pooling module，PPM）的特征金字塔网络，预测输出头仍采用全卷积网络进行分割输出。以第二章中

中国知网 https://www.cnki.net

Re-yolo 的实验结果为参照样本，本文最初以为会得到分割精度与分割速度同步提升的模型，但是结果并未如预期中一样，具体实验结果在 4.5.3 节中进行展示。

4.4 实验数据及评价指标

本节首先介绍实验的环境及平台，以及训练模型所用的数据集及数据集制作过程。其次引入评价指标对 Query-maskrcnn 实例分割方法的分割性能进行评估，并且通过对比试验证明本文方法 Query-maskrcnn 的实用性与优秀性。

4.4.1 实验的环境及平台

本文三个实验内容均使用深度学习框架 Pytorch，所有工作均使用同一台电脑设备。如表 4-1 为电脑设备关于 CPU、GPU、操作系统、深度学习库等配置参数的展示。

表 4-1 实验平台的配置参数

Tab.4-1 Configuration of the experimental platform

参数名称	参数规格
CPU	Intel Core i7-9700k
GPU	NVIDIA RTX2080-8G
RAM	16GB
操作系统	Windows 10
深度学习库	Pytorch 1.6
程序语言	Python 3.6

4.4.2 实验数据集及制作过程

本文数据集仍然采用森林航空火情数据集 FLAME，如图 4-8 实例分割数据集制作，将火情目标在图中用精细的点分割出来，分为火焰与烟雾两个类别。



图 4-8 实例分割数据集的制作

Fig.4-8 Creation of instance segmentation datasets

中国知网 https://www.cnki.net

4.4.3 实验评价指标

实例分割与语义分割的评价指标相同，本文评价指标选取三个方面来给出，分别是平均像素准确率（Mean pixel accuracy，MPA）、平均交并比（Mean intersection over union，MIoU）以及分割速度 FPS，以此来评估所提算法的分割性能。其中，平均像素准确率及平均像素准确率和平均交并比用来衡量算法的分割精度，FPS 用于衡量算法的处理速度和效率）

像素准确率的含义是预测类别正确的像素占总像素的比例，像素准确率对应于第二章中目标检测的评价指标准确率。平均像素表示对每个类别求出像素准确率，然后对这些准确率累加求平均，如公式 4-9 所示。其中 k 为数据集中类别数、P_{ii} 代表 TP 值、TP 值指实际正类预测为正类的数量、P_{ij} 代表 FP 值、FP 值指实际负类预测为正类的数量。

$$MPA = \frac{1}{k+1}\sum_{i=0}^{k}\frac{p_{ii}}{\sum_{j=0}^{k}p_{ij}} \tag{4-9}$$

在上一章介绍过交并比，目标检测中交并比指模型对目标的预测边框与数据集中真实框的交集与并集的比值。对于实例分割的交并比，与目标检测中的交并比大同小异，目标检测中是检测框与真实框之间的交并比，对于实例分割，交并比表示预测掩码与真实掩码之间的交并比。平均交并比通过计算分割模型对每一类别的预测值和真实值的交集与并集之比，然后对这些交并比累加并求平均值，公式如 4-10 所示。

$$MIoU = \frac{1}{k+1}\sum_{i=0}^{k}\frac{p_{ii}}{\sum_{j=0}^{k}p_{ij}+\sum_{j=0}^{k}p_{ji}-p_{ii}} \tag{4-10}$$

对本文实例分割的分割速度仍采用 FPS 进行评估，FPS 指模型每秒处理多少帧图像，如公式 4-11 所示。一般认为实例分割的 FPS 处理速度高于或等于 16FPS，就已达到实时分割的效果。

$$FPS = \frac{Frame}{Second} \tag{4-11}$$

4.5 实验及结果分析

本文分别训练 Query-maskrcnn、Maskrcnn、SOLO、Yolact 以及其它方法，对它们的平均像素准确率、平均交并比以及检测速度进行评估对比；值得一提的是，本文得到 Query-maskrcnn 之前采用第二章的思路对 Maskrcnn 进行优化，虽然分割速度有所提升，但是准确率却有所降低，将这种方法称为 Re-maskrcnn。所有网络是用 Windows 10 系统，训练和测试的 CPU 使用 I7-9700k、GPU 使用 Nvidia RTX 2080 Ti。

4.5.1 分割结果

本文在数据集中选取 5 张图像展示其分割结果，如图 3-8 所示。

中国知网 https://www.cnki.net



（a）原图　　（b）标签可视化　　（c）Query-maskrcnn 实例分割结果

图 4-9 原图、标签可视化结果以及分割结果

Fig.4-9 Original image, label visualization results, and segmentation results

从左往右三列分别为原图、数据集可视化图像、经 Query-maskrcnn 实例分割后的结果。由图 4-9 中的分割结果，针对小目标及被森林遮挡的火情目标，Query-maskrcnn 表现

中国知网 https://www.cnki.net

出良好的火情监测能力，能够准确地给出火情分割结果。

4.5.2 对比试验

本文用4.4.2制作的实例分割数据集分别训练Maskrcnn、Re-maskrcnn、Query-maskrcnn以及SOLO实例分割方法，分别结合平均像素准确率、平均交并比以及运行速度FPS这些评价指标对上述实例分割方法进行评估。如表4-2展示了Maskrcnn、Re-maskrcnn、Query-maskrcnn以及SOLO[73]的平均像素准确率、平均交并比以及运行速度FPS。

表4-2 Query-maskrcnn与其他模型准确率和检测速度的比较

Tab.4-2 Comparison of accuracy and detection speed between Query-maskrcnn and other models

模型名称	MPA	MIoU	分割速度
Maskrcnn	83.4%	80.7%	13.8FPS
Re-maskrcnn	77.2%	73.8%	28.1FPS
Query-maskrcnn	**91.8%**	**88.6%**	**17.5FPS**
SOLO	87.6%	85.2%	25.4FPS

由表中可得，本文最初的优化方法Re-maskrcnn运行速度达到了28.1，虽然Re-maskrcnn在运行速度上达到了很大的突破，但是对于在地面端对森林火情进行分割任务，更重要的分割精度，Re-maskrcnn的平均像素准确率相较Maskrcnn降低了6.2%，只有77.2%，从准确率的角度考虑，认为Re-maskrcnn并没有达到预期的优化效果。Query-maskrcnn的平均像素准确率最高，远远超过Maskrcnn，运行速度也要高于Maskrcnn，并且Query-maskrcnn的运行速度超过16，认为已经达到实时的效果。SOLO实例分割方法虽然平均像素准确率与运行速度都超过了Maskrcnn，并且运行速度也远远高于本文方法Query-maskrcnn，但是本文认为分割精度更为重要，并且Query-maskrcnn的运行速度已达到实时效果。综上所述，Query-maskrcnn模型在森林火情数据集中能更加准确的完成实例分割任务，并且运行速度也已达到实时效果。经过上文及实验数据分析可以得出结论，Query-maskrcnn能够在地面端为森林火情监测任务提供有效帮助。

4.6 本章小结

对于基于实例分割的多火点与遮挡火点的森林火情监测任务，本章首先分析了目标检测、语义分割、实例分割之间的不同，并对目前实例分割的方法进行分析，实例分割方法分别是基于区域的实例分割方法、基于实例激活的方法、基于查询的但阶段实例分割方法。然后介绍了Maskrcnn的组成结构。接下来主要对本文优化后的实例分割方法Query-maskrcnn的组成结构进行分析，并对优化方法特征对齐金字塔网络、基于查询的解码器进行分析。最终实验表明，Query-maskrcnn不论是平均像素精准度还是运行速度都超过了Maskrcnn，拥有更强的实例分割能力，能够更好的完成多火点与遮挡火点的森林火情监测任务。

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

5 总结与展望

5.1 总结

森林与人类的生存息息相关，但在森林环境中，极易发生火灾，一旦发生森林火灾，就会对人类和自然界造成巨大伤害，且森林恢复周期时间长。为了预防火灾，能在火灾发生早期及时监测火情目标，帮助林业工作人员与消防人员及时发现与消灭森林火灾，本文以基于无人机的森林火情监测为任务背景，研究基于深度学习的图像处理方法，设计了以下内容：

（1）针对在地面端准确快速的进行火情检测任务，本文提出一种基于 Re-yolo 的森林火情目标检测方法，该方法适用于在地面端对森林火情进行监测。该方法在研究 Yolov3 方法的基础上，对目标检测模型 Yolov3 在检测精度与检测速度上进一步优化。在 Yolov3 的主要模型框架下，使用跨阶段连接结构加深模型深度并加宽模型宽度，提高模型检测精度、减少模型计算量的同时加快模型的检测速度。对于森林火情监测任务，检测精度很重要，但是检测速度同样不能忽视。为了提高模型检测速度的同时不降低模型的检测精度，减少模型计算量，本文在 Yolov3 模型上使用参数重构方法对模型进行优化，使得模型在训练阶段使用特征提取能力强的残差结构，模型在预测阶段残差结构重构为计算速度快的单分支卷积结构。使用跨阶段连接与卷积参数重构方法对模型结构进行优化之后，为了提高模型性能，在模型中加入注意力机制、金字塔池化模型以及特征对齐机制。数据集采用 FLAME 森林航空火情数据集，为了提高模型的检测泛化性与鲁棒性，本文对数据集进行扩充，加入了其它背景的火情目标。实验结果表明，在扩充后的火情数据集上，Re-yolo 目标检测方法检测精度相较 Yolov3 提高了 0.131，检测精度达到了 0.843，检测速度加快了 0.7FPS，检测速度达到 33.8FPS。

（2）针对无人机机载计算端计算能力不强，一般的深度学习方法无法在无人机上达到实时监测效果的问题，本文提出一种基于 Reyolo-tiny 的轻量化方法，同时提出一种模型轻量化的思路。本文提出的模型轻量化思路分为两个阶段，第一阶段是使用 Mobileone 的主干网络以及主要模块对 Re-yolo 进行替换，达到轻量化的效果，加快模型检测速度、减少模型参数量的同时保证模型的检测精度。第二个阶段使用滤波器剪枝方法对第一阶段轻量化处理后的模型进行模型剪枝，使用不同剪枝率对模型进行剪枝。经过实验结果对比，本文得到模型在剪枝率为 60%的情况下，性能表现最好。实验结果表明，在实验一使用的目标检测数据集上，Reyolo-tiny 轻量化目标检测方法检测速度相较 Re-yolo 加快了 8.3FPS，检测速度达到了 37.0FPS，Reyolo-tiny 轻量化目标检测方法模型参数量相较 Re-yolo 下降了 30.37MB，模型参数量达到了 28.77MB，Reyolo-tiny 轻量化目标检测方法检测精度相较 Re-yolo 下降了 3.56%，检测精度达到了 89.91%。对 Re-yolo 轻量化处理后，检测速度与模型参数量明显改善的同时保持检测精度，得到一种适用于无人机端的轻量化目标检测方法。

中国知网 https://www.cnki.net

（3）针对多火点、小目标火点以及遮挡火点检测困难、检测精度不高的问题，本文设计提出一种基于 Query-maskrcnn 的实例分割方法对森林火情进行监测。森林环境复杂，森林火情发生后，极易存在火点分布不均现象，树枝、树干等遮挡物遮挡住火情的现象，这些问题导致森林火情难以监测。本文使用像素级检测的实例分割方法对森林火情进行更加精细的监测。本文提出方法基于 Maskrcnn 实例分割方法，对 Maskrcnn 方法的结构进行研究，取消 Maskrcnn 模型中计算时间长、计算参数大的区域建议网络。本文在特征融合网络中加入一种特征对齐机制，这种特征融合机制分为两个模块。其中一个是特征对齐模块，特征对齐模块用于对齐特征融合网络上采样后上下文特征；另一个是特征选择模块，特征选择模块用于加强低层特征，提高模型的分割准确度。本文自制实例分割数据集，数据集总共 1047 张图像。试验结果表明，在实例分割数据集上，Query-maskrcnn 实例分割方法分割精度相较 Maskrcnn 提高了 8.4%，平均像素准确率达到了 91.8%，实例分割速度加快了 3.7FPS，实例分割速度达到了 17.5FPS。

综合上文描述总结，本文提出三种面向森林火情监测的方法，分别是地面端目标检测方法、地面端实例分割方法以及空中端轻量化目标检测方法。从三种不同角度为森林火情监测任务提供一定应用价值与优化思路。

5.2 展望

使用无人机对森林火情进行监测仍是一个困难的、需要解决更多挑战的实际问题，使用无人机对森林火情进行监测大体可分为两部分内容，一部分是无人机的飞行控制任务，另一部分是空中监测任务，这两个部分相互配合，同样都很重要。本文针对空中监测任务，考虑到不同情况下、不同应用环境下，提出三种方法，这三种方法在本文数据集中表现较好，但是如果在实际的森林环境下应用，本文认为仍有改进的空间与未解决的困难：

（1）本文所提出的三种方法均未在无人机进行部署，未来可将将轻量化模型 Reyolo-tiny 等其它算法应用部署于无人机机载计算机等其它边缘设备上，对模型进行评估与飞行实验，同时可用机载计算机上的 TensorRT 方法对模型进一步进行加速处理，实现无人机的实时监测与扑救火情任务。

（2）本文使用的数据集是基于 FLAME 航空森林火情数据集的，收集到的图像背景单一，多为雪地与树枝，并且存在目标分布不均、背景密集等特征。目前已公开的无人机森林火情数据集不多，模型使用 FLAME 航空森林火情数据集训练得到的模型泛化性差，不适用于所有森林背景环境。可以扩充开发更多无人机航空拍摄的森林火情图像数据，以此提升模型的泛用性。

中国知网 https://www.cnki.net

参考文献

[1] 向生寿.区域经济发展与森林资源保护问题及其解决策略.南方农业，2021, 15(17):112-113.

[2] 孙晓芳. 基于边缘计算的森林火灾视频识别技术的研究.东北林业大学,2020.

[3] Martinez J R, Arrue B C, Ollero A, et al. Computer vision techniques for forest fire perception. Image and vision computing, 2008, 26(4): 550-562.

[4] Kolarić, Darko. Integrated system for forest fire early detection and management. Periodicum Biologorum, 2007, 110(2):205-211.

[5] Yuan C, Zhang Y, Liu Z. A survey on technologies for automatic forest fire monitoring, detection, and fighting using unmanned aerial vehicles and remote sensing techniques. Canadian journal of forest research, 2015, 45(7): 783-792.

[6] 刘志勇,蒋岳新,申志强,李帅,赵雪.利用卫星系统提升我国森林火灾监测能力探讨[J].航天器工程,2019,28(06):96-100.

[7] 梁宁, 袁新利, 刘晓东. 无人机在森林防火领域的应用及发展[J]. 森林防火, 2020(01): 50-54.

[8] 张友民, 余翔, 屈耀红, 刘丁. 无人机自主控制关键技术新进展[J]. 科技导报, 2017, 35(07): 39-48.

[9] 李萌娜.基于深度学习的无人机森林火灾图像识别与分割研究[D].西安理工大学,2022. DOI:10.27398/d.cnki.gxalu.2022.000591.

[10] Sudhakar S, Vijayakumar V, Kumar C S, et al. Unmanned Aerial Vehicle (UAV) based Forest Fire Detection and monitoring for reducing false alarms in forest-fires[J]. Computer Communications, 2020, 149: 1-16.

[11] Ambrosia V G, Wegener S, Zajkowski T, et al. The Ikhana unmanned airborne system (UAS) western states fire imaging missions: from concept to reality (2006–2010)[J]. Geocarto International, 2011, 26(2): 85-101.

[12] Yuan C, Liu Z, Zhang Y.UAV-based forest fire detection and tracking using image processing techniques[C]. International Conference on Unmanned Aircraft Systems (ICUAS'15). IEEE, 2015: 639-643.

[13] Jiao Z, Zhang Y, Xin J, Yi Y, Liu D and Liu H. Forest Fire Detection with Color Features and Wavelet Analysis Based on Aerial Imagery. 2018 Chinese Automation Congress (CAC), 2018, pp. 2206-2211, doi: 10.1109/CAC.2018.8623473.

[14] Yuan C, Liu Z, Zhang Y. Aerial images-based forest fire detection for firefighting using optical remote sensing techniques and unmanned aerial vehicles[J]. Journal of Intelligent & Robotic Systems, 2017, 88(2): 635-654.

中国知网 https://www.cnki.net

[15] Hossain F M A, Zhang Y M, Tonima M A. Forest fire flame and smoke detection from UAV-captured images using fire-specific color features and multi-color space local binary pattern[J]. Journal of Unmanned Vehicle Systems, 2020, 8(4): 285-309.

[16] Dimitropoulos K, Barmpoutis P, Grammalidis N. Spatio-temporal flame modeling and dynamic texture analysis for automatic video-based fire detection[J]. IEEE transactions on circuits and systems for video technology, 2014, 25(2): 339-351.

[17] Naimeng C, Wanjun Y, Xiaoyu W. Smoke detection for early forest fire in aerial photography based on GMM background and wavelet energy[C]//2021 IEEE International Conference on Power Electronics, Computer Applications (ICPECA). IEEE, 2021: 763-765.

[18] 李巨虎,范睿先,陈志泊.基于颜色和纹理特征的森林火灾图像识别[J].华南理工大学学报(自然科学版),2020,48(01):70-83.

[19] Kosmas D, Panagiotis B, Nikos G. Spatio-temporal flame modeling and dynamic texture analysis for automatic video-based fire detection. IEEE transactions on circuits and systems for video technology, 2014, 25(2): 339-351.

[20] Zhao Y, Ma J, Li X, et al. Saliency detection and deep learning-based wildfire identification in UAV imagery. Sensors, 2018, 18(3): 712.

[21] Hossain A, Zhang Y, Tonima A. Forest fire flame and smoke detection from UAV-captured images using fire-specific color features and multi-color space local binary pattern. Journal of Unmanned Vehicle Systems, 2020, 8(4): 285-309.

[22] Gaur A, Singh A, Kumar A and Kapoor A. Video flame and smoke based fire detection algorithms: A literature review. Fire Technology, 2020, 56(5): 1943-1980.

[23] Gupta T, Liu H and Bhanu B. Early Wildfire Smoke Detection in Videos. International Conference on Pattern Recognition (ICPR), 2021, pp. 8523-8530.

[24] Liu T, Cheng J, Du X, Luo X, Zhang L, Cheng B, Wang Y. Video Smoke Detection Method Based on Change-Cumulative Image and Fusion Deep Network[J]. Sensors, 2019, 19(23).

[25] Zhao Y, Ma J, Li X, and Jie Z. Saliency detection and deep learning-based wildfire Identification in UAV imagery. Sensors, 2018, 18(3): 712.

[26] Frizzi S, Bouchouicha M, Ginoux J M, et al. Convolutional neural network for smoke and fire semantic segmentation[J]. IET Image Processing, 2021, 15(3): 634-647.

[27] 张昕,管志浩.一种改进的林火实例分割深度学习模型[J].福建电脑,2021,37(12):8-11.

[28] Ronneberger O. Fischer P. Brox T. U-Net: Convolutional Networks for Biomedical Image Segmentation. Medical Image Computing and Computer-Assisted Intervention-MICCAI 2015. MICCAI 2015. Lecture Notes in Computer Science(), vol 9351.

中国知网 https://www.cnki.net

[29] Chen L, Zhu Y, Papandreou G, Schroff F, Adam H. Encoder-Decoder with Atrous Separable Convolution for Semantic Image Segmentation. Computer Vision-ECCV 2018. ECCV 2018. Lecture Notes in Computer Science(), vol 11211.

[30] He K, Gkioxari G, Dollár P and Girshick R. Mask R-CNN. In 2017 IEEE International Conference on Computer Vision (ICCV), Venice, Italy, 2017, pp. 2980-2988, doi: 10.1109/ICCV.2017.322.

[31] Bolya D, Zhou C, Xiao F and Lee Y. YOLACT++ Better Real-Time Instance Segmentation. In IEEE Transactions on Pattern Analysis and Machine Intelligence, vol. 44, no. 2, pp. 1108-1121, 1 Feb. 2022, doi: 10.1109/TPAMI.2020.3014297.

[32] 宁阳,杜建超,韩硕等.改进 DeeplabV3+的火焰分割与火情分析方法[J].西安电子科技大学学报,2021,48(05):38-46.DOI:10.19665/j.issn1001-2400.2021.05.006.

[33] Khan S, Muhammad K, Hussaint T, et al. Deep smoke: deep learningmodel for smoke detection and segmentation in outdoor environments[J]. Expert Systems withApplications, 2021, 182: 115125.

[34] Pan J, Ou X, Xu L. Acollaborative region detection and grading framework for forest fire smoke using weakly supervised fine segmentation and lightweight faster-RCNN[J]. Forests, 2021, 12(6): 768.

[35] Sandler M, Howard A, Zhu M, Zhmoginov A and Chen L. MobileNetV2: Inverted Residuals and Linear Bottlenecks. In 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition, Salt Lake City, UT, USA, 2018, pp. 4510-4520, doi: 10.1109/CVPR.2018.00474.

[36] Jeong S W, Yoo J. I-firenet: A lightweight CNN to increase generalization performance for realtime detection of forest fire in edge AI environments[J]. Journal of Institute of Control, 2020, 26(9): 802-810.

[37] Qian H，Shi F，Chen W，et al. A fire monitoring and alarm systembased on channel-wise pruned YOLOv3[J]. Multimedia Tools and Applications，2021：1-19.

[38] 栗俊, 毛鹏, 淡文, 等. 基于 YOLOv2-Tiny 的无人机火灾检测与云台跟踪研究[J]. 消防科学与技, 2022, 41（1）: 108-112.

[39] 谢雪嵩.基于无人机双光图像的森林火灾检测方法研究[D].西安理工大学,2023.DOI:10.27398/d.cnki.gxalu.2023.000787.

[40] Redmon J and Farhadi A. YOLOv3: An Incremental Improvement[J]. arXiv preprint arXiv:1804.02767, 2018.

[41] Xiao H, Zhang X, Ma N, Han J, Ding G, and Sun J. Repvgg: Making vgg-style convnets great again. In proceedings of the IEEE/CVF Conference on Computer Vision and pattern Recognition, pages 13733-13742,2021.

中国知网 https://www.cnki.net

[42] Wang C, Mark H L, Yeh I, Wu Y, Chen P, Hsieh J. Cspnet: A new backbone that can enhance learning capability of cnn. In Proceedings of the IEEE/CVF conference on computer vision and pattern recognition workshops, pages 390-391, 2020.

[43] Ge Z, Liu S, Wang F, Li Z,Sun J, et al. Yolox: Exceeding yolo series in 2021[J]. arXiv preprint arXiv:2107.08430, 2021.

[44] Zhang H, Wang Y, Dayoub F, and Sunderhauf N. Varifocalnet: An iou-aware dense object detector. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pages 8514–8523, 2021. 3, 4.

[45] X. Li, C. Lv, W. Wang, G. Li, L. Yang and J. Yang. Generalized Focal Loss: Towards Efficient Representation Learning for Dense Object Detection. In IEEE Transactions on Pattern Analysis and Machine Intelligence, vol. 45, no. 3, pp. 3139-3153, 1 March 2023.

[46] Feng C, Zhong Y, Gao Y, Matthew Scott, and Weilin Huang. Tood: Task-Aligned one-stage object detection. In proceedings of the IEEE/CVF International Conference on Computer Vision, pages 3510-3519, 2021.

[47] Girshick R .Fast R-CNN[J].Computer Science, 2015.DOI:10.1109/ICCV.2015.169.

[48] Matthew D, Rob F. Visualizing and Understanding Convolutional Networks.Computer Vision – ECCV 2014. ECCV 2014. Lecture Notes in Computer Science, vol 8689.

[49] Song G, Liu Y, and Wang X. Revisiting the sibling head in object detector. In CVPR, 2020.2.

[50] Wu Y, Chen Y, Yuan L, Liu Z，Wang L, Li H, and Fu Y . Rethinking classification and localization for object detection. In CVPR, 2020. 2.

[51] Rezatofighi H, Tsoi N, Gwak J, Sadeghian A, Reid I and Savarese S. Generalized Intersection Over Union: A Metric and a Loss for Bounding Box Regression. In IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), Long Beach, CA, USA, 2019, pp. 658-666, doi: 10.1109/CVPR.2019.00075.

[52] Tan M, Pang R and Le Q. EfficientDet: Scalable and efficient object detection. In 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2020.

[53] 、Redmon J, Divvala S, Girshick R and Farhadi A. You Only Look Once: Unified, Real-Time Object Detection. In 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), Las Vegas, NV, USA, 2016, pp. 779-788.

[54] Redmon J and Farhadi A. YOLO9000: Better, Faster, Stronger. In 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), Honolulu, HI, USA, 20

中国知网 https://www.cnki.net

17, pp. 6517-6525.

[55] Bochkovskiy A, Wang C, Mark H. YOLOv4: Optimal Speed and Accuracy of Objec t Detection [J]. arXiv preprint arXiv:2004.10934, 2020.

[56] Wang C, Bochkovskiy A and Liao M. YOLOv7: Trainable Bag-of-Freebies Sets Ne w State-of-the-Art for Real-Time Object Detectors. In 2023 IEEE/CVF Conference o n Computer Vision and Pattern Recognition (CVPR), Vancouver, BC, Canada, 2023, pp. 7464-7475, doi: 10.1109/CVPR52729.2023.00721.

[57] Liu S, Qi L, Qin H, Shi J and Jia J. Path Aggregation Network for Instance Segm entation. In 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognitio n, Salt Lake City, UT, USA, 2018, pp. 8759-8768, doi: 10.1109/CVPR.2018.00913.

[58] Chollet F. Xception: Deep Learning with Depthwise Separable Convolutions. In 201 7 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), Honolulu, HI, USA, 2017, pp. 1800-1807, doi: 10.1109/CVPR.2017.195.

[59] Howard A, Zhu M, Chen B, Kalenichenko D, Wang W, Weyand T, Andreetto M, A dam H. (2017). MobileNets: Efficient Convolutional Neural Networks for Mobile Vi sion Applications. ArXiv, abs/1704.04861.

[60] Sandler M, Howard A, Zhu M, Zhmoginov A and Chen L. MobileNetV2: Inverted Residuals and Linear Bottlenecks. In 2018 IEEE/CVF Conference on Computer Visi on and Pattern Recognition, Salt Lake City, UT, USA, 2018, pp. 4510-4520, doi: 1 0.1109/CVPR.2018.00474.

[61] Howard A et al. Searching for MobileNetV3. In 2019 IEEE/CVF International Conf erence on Computer Vision (ICCV), Seoul, Korea (South), 2019, pp. 1314-1324, doi: 10.1109/ICCV.2019.00140.

[62] Zhang X, Zhou X, Lin M and Sun J. ShuffleNet: An Extremely Efficient Convoluti onal Neural Network for Mobile Devices. In 2018 IEEE/CVF Conference on Compu ter Vision and Pattern Recognition, Salt Lake City, UT, USA, 2018, pp. 6848-6856, doi: 10.1109/CVPR.2018.00716.

[63] Ma N, Zhang X, Zheng HT, Sun J. ShuffleNet V2: Practical Guidelines for Efficien t CNN Architecture Design. In: Ferrari, V., Hebert, M., Sminchisescu, C., Weiss, Y. (eds) Computer Vision – ECCV 2018. ECCV 2018. Lecture Notes in Computer Sc ience(), vol 11218.

[64] Vasu P, Gabriel J, Zhu J, Tuzel O and Ranjan A. MobileOne: An Improved One m illisecond Mobile Backbone. In 2023 IEEE/CVF Conference on Computer Vision an d Pattern Recognition (CVPR), Vancouver, BC, Canada, 2023, pp. 7907-7917, doi: 1 0.1109/CVPR52729.2023.00764.

中国知网 https://www.cnki.net

[65] Liu Z, Li J, Shen Z, Huang G, Yan S and Zhang C. Learning Efficient Convolutional Networks through Network Slimming. In 2017 IEEE International Conference on Computer Vision (ICCV), Venice, Italy, 2017, pp. 2755-2763.

[66] Meng F, Cheng H, Li K and Sun X. Pruning Filter in Filter. In Proceedings of the 34th International Conference on Neural Information Processing Systems (NIPS'20). Curran Associates Inc, Red Hook, NY, USA, Article 1479, 17629–17640.

[67] He K , Gkioxari G ,Piotr Dollár,et al.Mask R-CNN[J].IEEE Transactions on Pattern Analysis & Machine Intelligence, 2017.DOI:10.1109/TPAMI.2018.2844175.

[68] Ren S, He K, Girshick R and Sun J. Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks. In IEEE Transactions on Pattern Analysis and Machine Intelligence, vol. 39, no. 6, pp. 1137-1149, 1 June 2017, DOI: 10.1109/TPAMI.2016.2577031.

[69] Shelhamer E, Long J and Darrell T. Fully Convolutional Networks for Semantic Segmentation. In IEEE Transactions on Pattern Analysis and Machine Intelligence, vol. 39, no. 4, pp. 640-651，1 April 2017, doi: 10.1109/TPAMI.2016.2572683.

[70] Ronneberger O, Fischer P, Brox T. U-net: Convolutional networks for biomedical image segmentation[C]//International Conference on Medical image computing and computer-assisted intervention. Springer, Cham, 2015: 234-241.

[71] Chen L, Papandreou G, Kokkinos I, et al. Deeplab: Semantic image segmentation with deep convolutional nets, atrous convolution, and fully connected crfs[J]. IEEE transactions on pattern analysis and machine intelligence, 2017, 40(4): 834-848.

[72] Chen L C, Zhu Y, Papandreou G, et al. Encoder-decoder with atrous separable convolution for semantic image segmentation[C]//Proceedings of the European conference on computer vision (ECCV). 2018: 801-818.

[73] Wang X, Kong T, Shen C, Jiang Y, Li L. SOLO: Segmenting Objects by Locations. In: Vedaldi, A., Bischof, H., Brox, T., Frahm, JM. (eds) Computer Vision - ECCV 2020. ECCV 2020. Lecture Notes in Computer Science(), vol 12363.

[74] Wang X, Zhang R, Kong T, Li L, Shen C. SOLOv2: Dynamic, Faster and Stronger. ArXiv, abs/2003.10152.

[75] Cheng B, Misra I, Schwing A, Kirillov A and Girdhar R. Masked-attention Mask Transformer for Universal Image Segmentation. In 2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), New Orleans, LA, USA, 2022, pp. 1280-1289, doi: 10.1109/CVPR52688.2022.00135.

[76] Bolya D, Zhou C, Xiao F and Lee Y. YOLACT: Real-Time Instance Segmentation. In 2019 IEEE/CVF International Conference on Computer Vision (ICCV), Seoul, Ko

中国知网 https://www.cnki.net

rea (South), 2019, pp. 9156-9165, doi: 10.1109/ICCV.2019.00925.

[77] Cheng B, Schwing A, Kirillov A. Per-Pixel Classification is Not All You Need for Semantic Segmentation. Neural Information Processing Systems.

中国知网 https://www.cnki.net